

一种基于结构信息的深度学习框架，用于建模 TCR-肽段-HLA 相互作用

收稿日期：2026年3月18日

接收日期：2026年9月14日

Published online: 25 September 2026

 检查更新曹凯¹、李瑞^{1,2}、Martin Strazar¹、埃里克·M·布朗¹、Phuong N. U. Nguyen¹、Marie-Madlen Pust^{1,2}、Park Jihye¹、Daniel B. Graham^{1,2}、Orr Ashenberg^{1,3}、Caroline Uhler^{1,4}✉ & Ramnik J. Xavier^{1,2,3,5}✉

T 细胞受体 (TCR)、肽段与人白细胞抗原 (HLA) 之间的相互作用构成了抗原特异性 T 细胞免疫的基础。尽管预测方法已取得显著进展，但针对 TCR-肽段-HLA 识别过程的精确建模仍相对滞后，这限制了其在癌症领域中的 TCR 及新表位优先排序、以及自身免疫性疾病中抗原识别等应用。本文介绍 StriMap，这是一个统一的框架，通过整合识别界面处的物理化学特性、序列上下文及结构特征，预测 TCR-肽段-HLA 相互作用。StriMap 实现了最先进的性能，同时提升了泛化能力，可在癌症与自身免疫性疾病领域广泛应用。作为案例研究，我们从 43,241 种细菌蛋白中筛选了 1300 万条肽段，并鉴定出若干候选分子模拟物，这些模拟物经实验验证可激活表达强直性脊柱炎 (AS) 相关 TCR 的 T 细胞。其中一条经严格验证的肽段在炎症性肠病患者 (IBD) 中显著富集，提示可能存在共同的微生物触发因素。总体而言，StriMap 为合理设计免疫疗法及解析自身免疫性疾病的抗原驱动机制提供了重要框架。

T细胞介导的免疫依赖于通过T细胞表面表达的T细胞受体 (TCRs) 对由人类白细胞抗原 (HLA) 分子呈递的抗原肽进行识别¹。这种HLA限制性肽表位识别是适应性免疫的核心机制，既能检测受感染或发生转化的细胞，又可维持对自身抗原的耐受性。这一相同的识别系统虽可实现广谱免疫监视，但当其调控失常或发生偏移时，亦可决定疾病进程。癌症与自身免疫性疾病是两大极具挑战且至关重要的领域，其中抗原特异性T细胞识别在疾病发生机制与治疗策略中均起核心作用。在癌症领域，筛选TCRs与新表位的能力为个体化免疫治疗及疫苗研发奠定基础

^{2,3}；在自身免疫性疾病领域，识别疾病相关抗原及潜在分子模拟物，可揭示致病诱因并实现抗原特异性干预^{4,5}。

尽管已有多种实验平台可检测TCR与肽-HLA (pHLA) 复合物的相互作用⁶⁻⁸，但这些方法仍耗时且成本高昂，限制了TCR或肽多样性的研究覆盖范围。这些局限性催生了对计算方法的迫切需求⁹。计算模型已在该识别级联反应的不同阶段取得进展。诸如NetMHCpan¹⁰等肽-HLA呈递预测工具已广泛应用于抗原呈递建模¹¹⁻¹⁴，但它们无法直接预测下游TCR识别过程。系统性地绘制下游TCR-pHLA相互作用图谱

¹美国马萨诸塞州剑桥市，麻省理工学院与哈佛大学博德研究所。²美国马萨诸塞州波士顿市，麻省总医院及哈佛医学院分子生物学系。³美国马萨诸塞州剑桥市，麻省理工学院与哈佛大学博德研究所 Klarman 细胞观察室。⁴美国马萨诸塞州剑桥市，麻省理工学院。⁵美国马萨诸塞州波士顿市，麻省总医院炎症性肠病研究中心。

✉ 电子邮箱：cuhler@mit.edu; rxavier@broadinstitute.org

识别能力仍尚未充分发展⁹。这一困难反映了交互空间的组合复杂性、识别过程的结构可塑性，以及现有实验数据的有限性与偏倚性——这一点已在最新基准研究^{15–17}中得到体现。

深度学习已开始被用于模拟这些过程，但许多方法仍主要依赖于序列的表征，并将pHLA呈递与TCR–pHLA识别视为独立任务^{18–25}，这可能导致无法捕捉二者间的条件依赖性与共享结构约束，从而限制其在训练分布之外泛化能力。近年来，基于结构的分析方法——包括SageTCR²⁶、NetTCR-struc²⁷、TRAP²⁸、STAG²⁹及STAG-LLM³⁰——已证实整合结构信息对于构建免疫识别界面的价值。然而，此类方法通常仅依赖有限数量的实验解析TCR–pHLA复合物结构，或依赖预测的全三分子复合物结构，而后者在柔性TCR–pHLA界面中的准确性与通量仍面临挑战。这些限制可能制约蛋白质组规模候选筛选及新预测TCR–pHLA相互作用的前瞻性实验验证。因此，亟需构建一个可扩展的框架，该框架既能整合来自单个分子链的结构信息约束，又无需依赖精确的全复合物结构预测；同时，该框架还需明确建立肽段–HLA呈递作用与下游TCR识别之间的关联，并支持对候选分子进行可实验验证的优先级排序。

为弥补这一空白，本研究开发了 **StriMap**（基于结构的**TRi**-分子相互作用**图谱构建**）——一个统一的深度学习框架，将抗原呈递与 TCR 识别建模为耦合生物过程，整合互补的序列、结构及上下文特征，以捕捉免疫识别的决定性因素。基于从多项独立研究中提取的多样化公共数据集，StriMap 在与主流 HLA 呈递及 TCR 特异性模型进行基准测试时，均持续取得顶尖性能。我们进一步验证了 StriMap 在癌症与自身免疫疾病研究中的实用性：在癌症领域，StriMap 可实现以 TCR 为核心的复发性新表位优先级排序，并为个性化疫苗设计提供新表位筛选支持；在自身免疫疾病领域，我们应用 StriMap 探究 HLA-B27 结合的细菌肽段与含有强直性脊柱炎相关保守基序 TRBV9 的 TCR 之间的关联。利用少量近期发布的疾病特异性数据以及大规模公共TCR–pHLA数据集，我们训练该模型以筛选来自43,241种与AS相关的肠道细菌蛋白质的1300万条肽段，并根据预测结合评分对候选肽段进行排序。值得注意的是，排名靠前的肽段均经实验验证可激活表达代表性TRBV9 TCR的T细胞。匹配的宏基因组与宏转录组分析表明，来自链球菌菌株的一种已验证肽段在 IBD 患者中富集，提示这两种自身免疫性疾病之间存在共同的抗原触发机制。综上所述，这些结果凸显了StriMap作为一个通用框架的价值，可将抗原呈递与TCR识别在癌症及自身免疫性疾病中建立关联，用户可通过以下网络门户访问：www.strimap.com。

结果

StriMap 概述

为了系统性地建模T细胞介导免疫背后的三分子相互作用（图1a），我们开发了StriMap——一个整合了物理化学、序列上下文及结构特征的统一深度学习框架。StriMap的核心是序列与结构特征提取器（SSFE），这是一个多模态编码器，用于学习分子识别的生物物理决定因素（图1b）。对于每个输入（肽段、HLA及配对的TCR α/β 链），SSFE通过融合三个互补通道生成综合表征：(i)残基级别的物理化学特

征³¹（补充表1）；(ii)来自预训练蛋白质语言模型（如ESM2³²、ProtT5³³）的进化序列上下文；以及(iii)由ESMFold³²预测并经等变图神经网络（EGNN）³⁴处理的三维结构特征，以编码空间几何信息（详见“方法”部分）。聚合交叉注意力机制用于在残基级别整合这些互补的多模态表征。我们进一步引入一种双线性注意力网络³⁵（BAN），用于建模分子组分间的残基–残基相互作用（图1c）。为体现免疫识别的层级特性，StriMap采用耦合架构：先对肽段–HLA呈递过程进行建模，随后利用该模型对TCR识别过程在底层肽段–HLA景观上进行条件化约束（图1d, e），从而确保生物学一致性。针对已验证的TCR–pHLA阴性配对样本稀缺问题，我们引入动态且考虑突变效应的阴性采样策略，以增强真实结合配体与邻近伪结合配体之间的区分能力。这些架构与训练方法的创新共同使StriMap成为癌症免疫治疗中TCR或新表位优先级筛选，以及自身免疫性疾病相关抗原识别的统一框架（图1f），我们将在后续章节对此进行系统性评估。

StriMap 提升了 pHLA 与 TCR–pHLA 基准测试的性能表现

我们在两个相关任务——pHLA呈递预测和TCR–pHLA相互作用预测——上，使用从先前独立研究中精选、并具备已发表的训练/测试数据分割的基准数据集，将StriMap与已发表的代表性前沿模型进行了对比评估，以确保可比性（见补充表2和3）。为了提供全面且透明的比较，只要可行的实现方案及兼容的输入要求允许，我们就在所有评估数据集上对纳入的方法进行了重新基准测试，采用统一的预处理流程、数据分割方式及评估指标。仅当已发表结果与相同数据集分割及评估协议相符时，我们才采用这些结果。我们考虑了三种测试类型：分布内（ID）测试——测试样本取自与训练集相同的潜在分布；跨研究或队列的分布偏移（DS）测试——数据集级偏移；以及表位级分布外（OOD）泛化测试——测试表位未在训练集中出现过，由此形成从ID到DS再到OOD的逐级严格化评估体系。对于每个基准测试，除非另有说明，否则 StriMap 均仅在对应的训练子集上进行训练或微调，并在原始研究定义的预测试子集上进行评估；各数据集对应的正样本与负样本数量已汇总于补充数据1中。

在多个pHLA呈递基准测试^{12,13,22}中，StriMap均取得了整体最佳性能，并在日益严格的ID/DS/OOD设置下仍保持稳健性（图2a），其扩展的指标级基准测试结果已汇总于补充图1。性能提升在各HLA等位基因中也保持一致：在与deepAntigen一同推出的Que等人数据集（ID）²²上，StriMap相较deepAntigen²²提升了每等位基因的 AUPRC 值（图2b）；而与更多前沿预测器进行的更广泛每等位基因比较，进一步证实了其在各HLA类中的一致性能提升（补充图2）。StriMap在所有评估中均持续超越NetMHCpan¹¹，凸显出相较于文献中广泛使用的参考方法具有显著优势。这些优势最终转化为肿瘤新抗原优先筛选：遵循BigMHC采用的免疫原性微调流程，我们在PRIME1.0/PRIME2上对StriMap进行了微调。0新抗原免疫原性数据，并在Tesla（肿瘤新抗原选择联盟）³⁶与Cedar（癌症表位数据库与分析资源）³⁷两个基准数据集上评估所得的StriMap-IM模型（图2c）。StriMap-IM在Cedar数据集上取得最优性能，在Tesla数据集上位列第二，且优于deepAntigen-IM、NetMHCpan11以及U、V、q：可学习参数E：表征1I：多头注意力T：表征2




图1 | StriMap框架概览。 **a** T细胞介导的免疫识别的生物学背景。细胞毒性T细胞通过T细胞受体 (TCR) 与靶细胞表面呈递的肽-HLA (pHLA) 复合物的相互作用来识别靶细胞。这种三分子相互作用构成了抗原特异性免疫监视的基础，也是StriMap的生物学基础。 **b** 序列与结构特征提取器 (SSFE) 的架构。给定一个蛋白质氨基酸序列，SSFE整合了三种互补的编码器：i) 物理化学编码器，用于计算残基级别的物理化学特征；ii) 基于序列的上下文编码器（如ESM2或ProtT5），提供上下文序列嵌入；iii) 基于结构的几何编码器（如ESMFold），生成3D结构表征。结构信息随后通过多层等变图神经网络 (EGNN) 进行处理。所有特征均通过门控交叉注意力机制和层归一化进行融合，最终生成统一表征。 **c** 双线性注意力网络 (BAN) 利用可学习的双线性投影来建模两个表示之间的成对交互作用，从而生成多头注意力图。 **d** 肽段-HLA相互作用预测器的架构。肽段和HLA序列分别由SSFE编码，并通过

Transformer模块进行处理，随后经过门控交叉注意力机制和BAN融合。融合后的表示被输入到一个线性层中，生成一个介于0到1之间的交互分数。 **e** TCR-肽段-HLA相互作用预测器的架构。TCR α/β 链、肽段和HLA序列分别由SSFE编码，然后通过一个特征聚合模块处理，该模块整合并利用了从肽段-HLA预测器中学习的嵌入表示。聚合后的特征进一步通过门控交叉注意力机制和BAN进行整合，融合后的表示通过一个线性层映射，生成一个介于0到1之间的交互分数。 **f** StriMap的下游应用。StriMap可实现肽段-HLA及TCR-肽段-HLA相互作用的系统性建模，有助于为癌症免疫治疗与疫苗研发筛选具有免疫原性的新表位优先级，并助力发现致病性或免疫优势表位。本工具基于BioRender构建。Kang, H. (<https://BioRender.com/vhrtfon>)。

在两个基准测试中均发现了额外的肽段-HLA呈递预测因子。这些结果证实，基于StriMap构建的表征方法在实际新抗原优先级筛选中具有应用价值——在此类场景中，仅有有限数量的候选抗原可被推进至实验验证阶段。

为探究StriMap在聚合准确率之外还能学到什么，我们利用从多个来源整合而成的综合数据集训练了一个pHLA模型。该数据集存在等位基因不平衡现象（补充图3）。对所学嵌入空间的可视化分析揭示出具有生物学意义的组织结构：簇的分离不仅反映了单个HLA等位基因的特征，还体现了每个等位基因内部由不同肽结合特性决定的细粒度异质性（图2d及补充图4）。例如，在HLA-B*27:05中，肽段被划分为两个主要Leiden簇（2号与21号），二者具有截然不同的基序：簇2重现了第2位为Arg、C末端为Leu的典型偏好模式；而簇21在第2位则表现出非典型偏好，表明其存在超越单一有序基序的亚等位基因结构。与嵌入层级的结构分析相呼应，基于注意力机制的分析进一步揭示了等位基因特

异性的结合位点分布特征，以及肽段残基与HLA接触残基之间独特的相互作用模式——包括HLA-A*02:01与HLA-A*02:03等密切相关等位基因间的差异（补充图5）。最后，对已充分表征的流感病毒表位 (gilg-fvftl) 进行系统性饱和和诱变实验，结果显示预测结合评分具有等位基因及位点特异性敏感性（补充图6）。值得注意的是，在代表性HLA等位基因中，经典锚定位点P2与P9的突变诱导敏感性显著高于非锚定位点，这证实StriMap能够捕捉肽段-HLA结合背后具有生物学意义的约束条件。

接下来，我们在多个独立基准测试集^{6,15-17,38}上，针对更为重要的TCR-pHLA相互作用预测任务对StriMap进行了评估。序列相似性分析证实，这些数据集中的测试TCR与训练数据存在显著差异，从而确保评估的是真正的泛化能力，而非对高度相似克隆型的记忆（补充图7）。鉴于TCR特异性研究领域的快速扩展




图 2 | StriMap 对 pHLA 呈递及 TCRpHLA 识别实现了稳健预测。a 在 ID（分布内）、DS（分布偏移）及 OOD（分布外）设置下，各基准数据集上的 pHLA 呈递预测性能。数值表示 AUPRC 分数，颜色强度表示该方法在各数据集上的排名。图中同时标注了阳性样本（Pos.）与阴性样本（Neg.）的数量。b 在 Que 等人数据集（ID）上，StriMap 与 deepAntigen 对单个 HLA 等位基因的性能（AUPRC）对比。虚线表示性能持平。c 在 tesla 与 cedar 新抗原基准数据集上的 AUPRC 对比。数据点表示多次 bootstrap 迭代中的 AUPRC 中值（n = 1000），误差条表示 95% bootstrap 置信区间。“-IM”表示根据 BigMHC 工作流程，在 PRIME1.0/PRIME2.0 新抗原免疫原性数据上微调的模型。d 肽段嵌入向量的 UMAP 图，左侧按 10 个最丰富的 HLA 等位基因着色，右侧按 Leiden 聚类着色。两个对应于 HLA-B*27:05 的聚类（虚线椭圆）显示出不同的肽段结合基序（右侧）。e 在 ID 和 DS 设置下，TCR-pHLA 相互作用预测性能在基准数据集上的表现。数值表示 AUPRC 或特定基准的评分，颜色强度表示各方法在各自数据集上的排名。图中显示了阳性样本（Pos.）

与阴性样本（Neg.）的数量。f 在 IMMREP22 基准数据集上，StriMap 与 NetTCR（左）及 MixTCRpred（右）的每肽 AUROC 比较。虚线表示性能持平。g 在相同评估协议下，StriMap 及其消融变体的 AUROC 与 AUPRC 比较。点表示 bootstrap 迭代（n = 1000）中的性能中值，误差条表示 95% 的 bootstrap 置信区间。StriMap-w/o-alpha 排除 TCRα 链输入，StriMap-only-concat 将跨组件交互模块替换为简单拼接，StriMap-w/o-Stru 移除结构信息，StriMap-w/o-DNS 移除动态负采样。h 基于 Minervina 等人数据集的 SARS-CoV-2 队列中 TCR 的结合位点百分位分布。箱线图显示中位数（中心线）、第 25 和第 75 百分位数（箱体边界）以及 1.5 倍四分位距（须线）。样本量（非突变蛋白/T 细胞受体）：inf 组，n = 1,164/76；inf_vax1 组，n = 303/137；inf_vax2 组，n = 40/48；inf_vax2 组，n = 401/175；vax2_inf 组，n = 962/172。对于 vax2 组，仅可获得突变蛋白特异性 T 细胞受体数据（n = 92）。P 值（如上图所示）采用 Benjamini-Hochberg 校正的双侧 Mann-Whitney U 检验得出。

针对预测工具，我们在补充数据2中汇总了代表性既往方法及其关键方法学特征，随后将StriMap与选定的前沿模型进行基准测试。只要存在可运行的实现方案及兼容的输入要求，我们均采用统一预处理流程、数据集划分方式及评估指标重新运行相关方法；仅当已发表结果与当前划分方案及评估协议一致时，才采用这些已发表结果。若基准测试数据集

包含预定义的正负样本对，我们直接使用原始标签以遵循已发表的评估协议；对于缺乏明确负样本对的数据集，我们通过随机TCR与pHLA洗牌生成负样本，同时排除已知正样本，此做法与既往基准测试实践一致³⁹。此外，我们还引入动态负样本采样（DNS）技术——在模型训练的每个训练周期重新生成负样本，以扩展有效负样本空间。

总体而言, StriMap 在 ID 和 DS 两种设置下均展现出优异性能 (图 2e), 并在 Zhang 等人 (ID)、Minervina 等人 (DS) 及 IMMREP22 数据集上进行了单肽对比分析 (补充图 8–10); 图 2f 重点展示了 IMMREP22 数据集上的单肽 AUROC 对比结果, 其中 StriMap 的性能优于 NetTCR¹⁸ 与 MixTCRpred²⁴ 这两种广泛使用的参考方法。值得注意的是, Lu 等人的基准测试¹⁷ 采用了保留 TCR–HLA 配对但打乱肽段身份的肽段置换负样本 (补充图 11)。在此方案下, 负样本主要可通过肽段–HLA 兼容性而非真正的 TCR 特异性识别来区分, 这可能会提升性能。由于 StriMap 同时对 pHLA 呈递与 TCR–pHLA 识别进行联合建模, 它能够有效利用肽段–HLA 兼容性信号, 从而在该协议下获得显著更高的性能。相比之下, 忽略 HLA 信息或仅单独建模 TCR–pHLA 相互作用的方法在结构上处于劣势。

为评估配对 TCR 链信息的贡献, 我们首先在 Zhang 等人的数据集上保留相同的训练与评估流程, 同时移除 TCR α 链输入。此举使 AUROC 从 0.737 降至 0.662, AUPRC 从 0.507 降至 0.400, 表明 α 链提供了超越仅使用 β 链所能获得的显著特异性信息。消融分析进一步显示, 移除结构模块 DNS, 或将跨组件交叉注意力/BAN 交互模块替换为简单拼接操作, 均会导致 AUROC / AUPRC 相较于完整模型下降 (图 2g)。除消融分析外, 按肽段长度分层的评估表明, StriMap 支持可变长度肽段输入, 并在 pHLA 与 TCR–pHLA 两项基准测试中, 于所评估的肽段长度范围内均保持稳健性能 (补充图 12a、b)。Shap 分析则从模态与组件两个层面量化了细粒度特征的重要性, 识别出序列与 pHLA 上下文是预测结果的主要驱动因素, 而物理化学及结构特征则提供了重要贡献, 验证了我们多模态设计的有效性 (补充图 12c、d)。值得注意的是, 与单独使用的肽段及 HLA 特征相比, 整合后的 pHLA 上下文展现出更显著的 Shap 分数。这体现了我们的架构设计: 融合后的 pHLA 上下文能够捕捉二者间的协同功能动态, 并在归因过程中自然吸纳各自独立的预测权重。

为评估在临床队列中的泛化性, 我们在 Minervina 等人构建的数据集³⁸ 中分析了 SARS-CoV-2 相关的 TCR–pHLA 相互作用, 该数据集包含 14 条肽段 (5 条刺突蛋白肽段及 9 条非刺突蛋白肽段) 对应的 3,570 个 TCR。研究队列包括: 康复者的感染后样本 (inf)、接种一剂疫苗后的康复者样本 (inf_vax1)、接种两剂疫苗后立即采集的样本 (inf_vax)、疫苗接种后康复者样本 (inf_vax2)、已接种疫苗的初始个体样本 (vax2) 以及突破性感染样本 (vax2_inf) (图 2h)。我们对所有类别中每条刺突蛋白或非刺突蛋白肽段的 TCR 结合评分进行预测, 并将结果汇总为百分位结合秩分布 (图 2h)。在各类别内, 采用经 Benjamini–Hochberg 校正的双侧 Mann–Whitney U 检验比较刺突蛋白特异性与非刺突蛋白特异性 TCR。接种相关队列 (“vax”) 在接种刺突蛋白疫苗后, 预期会产生更强的刺突蛋白特异性 T 细胞应答; 事实上, 我们确实观察到刺突蛋白特异性 TCR 的预测结合秩分布更优。这一效应在 inf_vax 队列中最为显著: 在同一队列内, 刺突蛋白特异性 TCR 的预测结合排名百分位数显著高于非刺突蛋白特异性 TCR (校正后 $P < 1 \times 10^{-4}$), 这与近期研究发现的疫苗接种可驱动刺突蛋白特异性克隆型的扩增与激活相一致。相比之下, 在后期时间点 (inf_vax2) 及突破性感染病例 (vax2_inf) 中, 这种差异逐渐减弱且不再具有统计学显著性, 这可能反映了疫苗诱导的免疫应答逐渐减弱, 以及个体在再次接触抗原后 T 细胞受体库的多样化。

我们进一步在 IMMREP23 挑战赛中评估了 StriMap¹⁶, 该挑战赛中参与者可整合官方数据集之外的外部训练数据, 但不同方法所使用的具体数据来源并未完全公开。我们比较了三种训练策略: (i) 仅使用主办方提供的数据进行训练; (ii) 使用从多种公开研究中整合而成的综合数据集进行训练^{15,16,23,40–42} (补充图 13); 以及 (iii) 结合多种负采样策略的集成策略 (补充图 14a)。采用集成策略时, StriMap 以 AUC0.1 = 0.6943 位列第三 (补充图 14b; AUC0.1 的定义详见 “方法” 部分)。值得注意的是, 前两种方法 (IMW -detect 与 MixTCRpred_s2) 使用了未公开的内部数据, 这使得将性能提升归因于模型架构还是数据变得复杂。我们进一步在零样本 (OOD) 设置下评估了 StriMap, 测试表位未在训练集中出现; 尽管仅使用了三个未见过的表位, 其性能仍优于随机基线, 表明模型具备部分泛化能力, 但效果仍有限, 这可能归因于表位间的显著差异 (补充图 14c)。这些结果表明, 少样本学习在实际应用中往往更为可靠, 同时仍为癌症 TCR 及新表位优先级排序等下游应用场景提供了动力。

癌症免疫治疗中 TCR 与新表位的优先筛选

癌症中的体细胞突变可产生新表位, 这些新表位经加工后由 HLA 分子呈递, 并能被 T 细胞识别 (图 3a), 这为基于 T 细胞的免疫疗法提供了关键理论依据。为验证其转化应用价值, 我们将 StriMap 应用于两项临床相关的癌症免疫治疗任务: (i) 在过继性 T 细胞治疗背景下, 针对复发性突变肽–HLA 配对进行 TCR 导向的优先级筛选; (ii) 为个性化癌症疫苗设计进行新表位优先级筛选 (图 3b)。这两种应用场景反映了 T 细胞免疫治疗中常见的决策节点——其中仅有少量候选分子可进行实验验证。在癌症优先级分析中, 我们使用基于全面 TCR–pHLA 数据集训练的 StriMap 模型 (补充图 13), 未进行任务特异性微调; 阳性/阴性样本计数汇总于补充数据 1 中。

我们首先考虑了任务 1, 即在已知存在复发性癌症相关突变的背景下, 旨在识别适用于过继性细胞治疗的同源 TCR。其中, TP53 基因突变是跨多种肿瘤类型中最常见且特征最明确的癌症驱动突变之一, 且已有若干 TP53 衍生突变肽段被证实能在患者体内引发 T 细胞应答⁴³。利用代表性 TP53 热点突变及经 tapir 最初评估的实验观测到的同源 TCR²⁵ (图 3c 及补充数据 3), 我们在完全零样本 (OOD) 设置下——即训练过程中既未见过该肽段也未见过相关 TCR——评估了 StriMap 对突变肽段–HLA 查询进行抗原特异性 TCR 排序的能力。所有正样本与负样本均直接取自 tapir (7 个同源 TCR; 3144 个负样本), 并与 tapir 及 NetTCR-2.0¹⁸ 基准模型进行对比, 具体结果见原始研究²⁵。

在以 TCR 为核心的排序任务中, 我们的目标是解决突变特异性效应问题, 即突变肽段与野生型肽段仅相差一个或几个氨基酸。要区分这种细微差异, 可能需要采用氨基酸级别的建模方法, 而非仅将非同源肽段对视为负样本。为了更好地反映这一生物学背景, 我们引入了一种考虑突变的负样本采样策略, 通过在肽段或 TCR CDR3 α/β 区域中随机替换氨基酸来生成负样本。在 TCR 排序任务中, 无论是使用 AUROC 还是 AUPRC 数据集, StriMap 变体均优于 tapir、NetTCR-2.0 及 tapir-plus (后者使用 StriMap 无法获取的专有内部 TCR 功能数据训练), 其中 StriMap-M2 (肽段–突变负样本) 取得了最佳整体性能, 而 StriMap-M1 (TCR–突变负样本) 则相较于基础模型展现出中等提升 (图 3d)。




图3 | StriMap 支持两种与 T 细胞免疫治疗相关的临床任务。a 肿瘤免疫微环境中 T 细胞识别的示意图，重点展示了 TCR 与肿瘤细胞上呈递的新表位-HLA 复合物之间的相互作用。b StriMap 框架概述，用于联合分析 HLA 呈递与 TCR 识别。全外显子组测序 (WES)、HLA 分型及 TCR 测序可确定候选新表位及患者特异性 TCR 池，随后使用 StriMap 的 pHLA 与 TCR-pHLA 预测工具进行下游优先级排序评估。c 代表性 TP53 癌症突变、其对应新表位，以及实验观测到的识别每个新表位的 TCR 数量。d StriMap 与 tapir 及 NetTCR 在给定突变型 pHLA 查询时对同源 TCR 进行优先级排序的性能对比，评估指标为 AUROC 与 AUPRC。tapir-plus 表示使用公共数据集及额外内部专有 TCR 功能数据训练的 tapir 模型，而 StriMap 无法访问此类数据。StriMap-M2 表示使用在肽段中随机突变一到两个氨基酸生成的负样本进行微调，而 StriMap-M1 则表示使用在 TCR CDR3 α 和/或 CDR3 β 区域中随机突变一到三个氨基酸

生成的负样本进行微调。作为参考，随机基线为 AUROC = 0.5 且 AUPRC = 0.002。图 e 展示了 TP53 衍生新表位的 TCR 排序结果。每个点代表特定新表位的 TCR-pHLA 相互作用。颜色表示不同的新表位，虚线标出了排名前 20 的 TCR 候选分子。(f) 使用结合 TCR-pHLA 与 pHLA 预测因子的综合评分，在黑色素瘤患者特异性 TCR 池条件下，StriMap 对免疫原性新表位的优先级排序性能 (AUROC 与 AUPRC) 与仅使用 pHLA 的 StriMap 模型及 NetMHCpan-4.2-EL 和 NetMHCpan-4.2-BA 相比的结果。作为参考，随机基线为 AUROC = 0.5 且 AUPRC = 0.047。图 g 展示了 TCR 参与预测与仅使用 pHLA 预测时，真实免疫原性新表位在各排序位点上的召回率-排名曲线。红色标记表示真实发现事件。NetMHCpan-4.2 EL 与 BA 分别代表洗脱配体模式与结合亲和力预测模式。图 a-b 使用 BioRender 绘制。Kang, H. (<https://BioRender.com/geveyxr>)。

为了确定这种考虑突变的采样策略是否具有模型无关性，我们将该策略应用于基线模型 (epact-M2 和 NetTCRM2)。尽管这两种模型均表现出显著的 AUROC 提升 (见补充图 15)，但出现了明显的架构依赖性：基于 Transformer 的复杂模型 (StriMap 和 epact) 在 AUPRC 指标上获益显著，而像 NetTCR 这样较简单的网络架构则未能展现出 AUPRC 的提升。这表明，表征能力较低的模型难以充分学习由单个氨基酸突变引发的精细交互变化。这些结果表明，考虑突变的负采样策略对于建模癌症相关抗原识别尤为有效。

与整体性能指标一致，StriMap 在最高排名的 TCR 候选分子中，相较于其他竞争方法，显示出对真实结合分子的富集效果提升 (图 3 e)。例如，多个经实验验证的识别新表位 drnifrhsvv 与 vvpdeppev 的 TCR 均被 StriMap 列入前 20 名，而其他方法对这些真实性分子的排名则普遍显著偏低。这一能力对 T 细胞治疗至关重要——因为只有少数高排名候选分子能进入成本高昂的实验验证与临床开发阶段。接下来，我们通

过比较突变型与野生型肽段-HLA 结合环境，探究 StriMap 能否解析固定 TCR 的突变特异性效应。由于野生型肽段可能因 TCR 识别能力有限或 HLA 呈递效率低下而缺乏免疫原性，此类比较有助于厘清潜在驱动因素。值得注意的是，预测到的差异主要源于 pHLA 呈递能力的变化，而非推断的 TCR-pHLA 结合评分发生大幅偏移 (补充图 16)。以 C135Y 突变为例，预测的 HLA 呈递评分从野生型的 0.06 上升至 0.65 (突变体)，而推断的 TCR-pHLA 评分仅从 0.61 小幅上升至 0.65，这表明免疫原性的增强主要与 HLA 呈递能力的提升相一致。综上，这些结果阐明了联合建模 pHLA 呈递与 TCR 识别机制，如何使 StriMap 能够预测：突变驱动效应更倾向于与 HLA 呈递改变相关，还是与 TCR 识别改变相关。

接下来，我们在任务 2 中评估了 StriMap，这是一个以新表位为核心的补充性研究场景，其中可获得患者特异性 TCR 谱系，其目标是为疫苗开发筛选具有免疫原性的新表位 (图 3b)。我们使用了来自黑色素瘤

数据集²的成对新抗原与TCR谱系数据，包括从肿瘤浸润淋巴细胞（TILs）及匹配的外周血单个核细胞（PBMCs）中克隆扩增的TCR谱系。该数据集共包含106个候选肽段突变，其中5个已通过实验证实可引发T细胞免疫应答。候选新表位采用综合评分进行排序，该评分整合了预测的新表位-HLA呈递能力与TCR谱系中预测的TCR相互作用评分；我们将这一综合评分框架称为StriMap-joint。利用考虑突变的StriMap-M2模型，我们通过前30个排序的TCR-pHLA对的平均相互作用评分，对每个候选新表位进行总结，从而捕捉患者扩增T细胞谱系的整体识别潜力。StriMap-joint consistently achieved higher AUROC and AUPRC scores than both the pHLA-only StriMap model and NetMHCpan_4. 原始研究²中采用的基于2的基准方法（EL与BA），凸显了将TCR识别显式纳入新表位优先级排序的优势（图3f）。这一优势对于选择用于聚合的顶级TCR-pHLA配对数量具有稳健性（补充图17）。Recallrank分析——即统计排序候选列表中所有经实验验证的免疫原性新表位的排名位置——进一步表明：与仅使用pHLA或基于NetMHCpan的方法相比，采用联合模型时，真实免疫原性新表位在排序中会更早出现（图3g）。

综上所述，这些结果表明，StriMap对肽呈递与TCR识别的联合建模，可在两种癌症免疫治疗场景中支持零样本优先排序。通过捕捉pHLA呈递中由突变驱动的变化及其对TCR结合的下游影响，StriMap为过继性细胞治疗中的TCR选择以及个性化癌症疫苗中的新表位排序提供了一个统一框架。

在AS中全蛋白质组范围内鉴定细菌模拟肽

在证实StriMap工具在癌症免疫治疗中的实用性后，我们进一步探究：这种对肽段-HLA呈递与TCR识别的联合建模方法，是否可推广至自身免疫性T细胞识别研究——此类研究中相关抗原触发因子通常尚不明确。我们以强直性脊柱炎（AS）为研究对象，该疾病是典型的HLA-B27相关炎症性疾病；此前已有证据表明，AS与HLA-B27存在强关联，且疾病相关TCR中富集的保守TRBV9基序可能参与疾病发病机制。AS领域长期存在的一个核心问题是：环境暴露因素（尤其是肠道微生物抗原）如何与HLA-B27相互作用，从而启动或放大自身反应性T细胞应答？分子模拟机制提供了可能的解释路径：由HLA-B27呈递的微生物肽段可激活那些同时与自身抗原发生交叉反应的TCR，从而将细菌抗原暴露与自身免疫性炎症联系起来。因此，我们聚焦于细菌肽段——并非将其视为任意的外源抗原，而是将其作为候选环境触发因子，这些肽段既可由HLA-B27呈递，也可被AS相关TRBV9 TCR识别。为构建一个兼具生物学基础性与临床相关性的检索空间，我们基于文献证据筛选出一组与强直性脊柱炎（AS）相关的肠道细菌菌株队列，涵盖四大主要菌门：芽孢杆菌门/厚壁菌门、疣微菌门、拟杆菌门及变形菌门。最终选定的菌株组合包含16株菌株，共提供43,241个已注释蛋白，用于后续肽段定量分析（补充表4）。该实验设计使我们得以探究：在蛋白质组尺度的细菌检索空间中，StriMap是否能够有效筛选出既具备HLA-B27呈递潜能、又可能被疾病相关T细胞受体（TCRs）识别的微生物肽段。

为了评估StriMap是否能在真实的转化医学场景中跨患者泛化，我们设计了一个以TRBV9 TCR为核心的跨患者少样本推理工作流程（图4a）。具体而言，我们使用患者1（TRBV9 TCRAS3.1）和患者2（TRBV9 TCRs AS4.1-AS4.4）的TCR结合数据作为参考输入，然后针对来自独立患者3的查询TRBV9 TCR（AS8.4）预测其肽段结合特异性。选择AS

8.4是因为它不在用于少样本训练的五个TRBV9 TCR之列⁴⁴，从而实现了样本外评估；同时，它在原始研究中测试的其他TRBV9 TCR中，对阳性对照肽段表现出最强的激活作用⁴⁴。这一设计模拟了在拥有有限疾病特异性监督数据的情况下，对新患者进行部署的情景，同时仍可利用大型公共训练资源（补充数据1）。为验证训练后的模型在此场景下是否依赖于生物学上合理的识别决定簇，我们对实验解析的AS相关TCR-YEIH-HLA-B*27:05复合体结构（包括AS4.2、AS4.3和AS8）进行了残基属性分析。4（补充图18）。该分析表明，高重要性残基均集中于TCR α 与TCR β 链的CDR3区域，这证实StriMap捕获的是具有生物学相关性的TCR识别区域，而非广泛分布的序列信号。

随后，我们在模拟发现所需的规模下，对细菌肽段进行了全蛋白质组计算机筛选（图4b）。对于每个细菌蛋白质组，我们使用滑动窗口（k=9，步长=1）生成了重叠的9聚体肽段，最终获得13,068,902个候选9聚体肽段池。接着，我们将StriMap以两阶段、双任务的方式应用：(i) 预测HLA-B*27:05呈递评分；(ii) 预测疾病相关TRBV9 TCRs的识别能力，从而将呈递与识别过程整合至单一筛选流程中。在我们的实施方案中，我们保留了预测得分最高的HLA-B*27:05结合肽段（相对于随机肽段背景排名前3%；共568,982条肽段）用于下游TCR筛选（图4c）。在筛选出高置信度的HLA-B*27:05候选肽段后，我们使用StriMap TCR-pHLA预测器评估每条候选肽段与五种先前报道对多种HLA-B*27:05结合肽段具有反应性的疾病相关TRBV9 TCRs（AS3.1、AS4.1-AS4.4）之间的相互作用⁴⁴。随后，我们根据五个TCR上预测结合分数的平均值对肽段进行排序，并筛选出七个排名靠前的细菌肽段——每个肽段均被预测可与至少两个TRBV9 TCR发生强相互作用。我们采用这一多TCR筛选标准，旨在反映疾病相关TRBV9 TCR已知的交叉反应特性，并优先选择那些具有激活多种TRBV9克隆型的广泛潜力候选肽段，而非仅针对单一TCR的特异性肽段，从而提升其转化应用价值。接下来，我们评估这些候选肽段对样本外查询TCR AS8.4的预测反应性。我们将候选细菌肽段与阴性对照及两个既往报道的阳性对照进行基准测试：前者为人源自身肽段trliapiak，后者为细菌模拟肽lrvmmlapf。此外，为严格验证该模型的区分能力，我们还纳入人源同源肽段——这些肽段通过BLAST比对筛选出与筛查库中细菌序列具有高度线性序列相似性——作为严格特异性验证，以证明StriMap模型能够区分真实结构模拟物与仅具序列邻近性的无关肽段。排名靠前的候选肽包括源自链球菌属（*Streptococcus* spp.）及嗜黏蛋白阿克曼菌（*A. muciniphila*）的肽段，以及多个高分候选肽（如arvmalmpf、grilalvpk、primmismk、prlpltpvf）在该跨患者少样本设置中位列预测结果前列（图4d）。本次计算筛选的主要结论是：StriMap可将庞大的疾病相关微生物蛋白质组空间，缩减为仅包含若干候选HLA-B27呈递细菌肽段的集合，这些肽段被预测可与AS相关的TRBV9 TCR结合。

TRBV9+ T细胞激活的实验验证为在HLA-B*27:05限制性环境下实验验证StriMap优先筛选的候选模拟肽，我们构建了一套发现型工作流程：通过计算筛选确定候选TCR-肽-HLA相互作用，进而进行靶向测试与迭代优化（图5a）。与既往主要测试已知表位、结合活性读数或整体肽段免疫原性的验证方案不同，本工作流程整合了蛋白质组尺度的发现分析。




图 4 | 通过跨患者预测实现 AS 相关细菌模拟肽的计算发现。a AS 相关细菌队列及跨患者少样本预测实验设置。我们从文献中筛选出一组此前已被报道与强直性脊柱炎 (AS) 相关的肠道细菌菌株队列，涵盖四大门：芽孢菌门 (包括链球菌属、*R. gn-avus* 等)、疣微菌门 (*A. muciniphila*)、拟杆菌门 (*P. copri*, *P. melaninogenica*) 以及变形菌门 (*K. pneumoniae*, *E. coli*, *Parasutterella excrementihominis*)。为评估模型对未见患者 TCR 的泛化能力，我们构建了跨患者推理流程：以患者 1 (AS3.1) 与患者 2 (AS4.1–AS4.4) 的 TRBV9 TCR 结合数据作为参考输入训练特异性模型，随后利用 StriMap 对来自独立患者 3 (AS8.4) 的查询 TRBV9 TCR 进行肽段结合特异性预测，以此模拟少样本学习场景。b 大规模计算机模拟 9 聚肽筛选流程。提取并处理所选细菌队列的蛋白质组数据，共包含 43,241 个蛋白质。本研究采用窗口大小为 $k=9$ 、步长为 1 个氨基酸的滑动窗口法，生成了约 1300 万个 9 聚肽肽库。

StriMap 计算框架执行双重任务预测：任务 1 预测 HLA-B*27:05 呈递的可能性；任务 2 预测被特定 TRBV9 TCRs (如 AS8.4) 识别的概率。c 全队列中 HLA-B27 高亲和力 9 聚肽的分布图谱。该柱状图展示了每种细菌菌株所预测的高亲和力 9 聚肽的分布情况及总数。肺炎克雷伯菌 (*K. pneumoniae*) 和大肠杆菌 (*E. coli*) 等菌株显示出高密度的潜在 HLA-B27 结合肽，这凸显了它们在分子模拟假说中的重要性。d 候选细菌肽的预测反应性评分。来自不同菌门的代表性肽段按其针对目标 TCR 的预测反应性评分进行排序。将链球菌属 (*Streptococcus* spp.) 和嗜黏蛋白阿克曼菌 (*A. muciniphila*) 中的高分候选肽与阳性及阴性对照进行比较，以揭示细菌抗原与 AS 相关 TCRs 之间潜在的交叉反应性。a、b 图使用 BioRender 制作。Kang, H. (<https://BioRender.com/77gafpz>)。

对于新预测的细菌模拟肽，我们采用了 TCR 定义的功能激活检测法 (补充表 5)。我们构建了内源性 TCR 敲除的 Jurkat 细胞系，并通过慢病毒转导重新表达 TRBV9-TCRAS8.4 (见“材料与方法”)。抗原呈递细胞 (APCs) 是通过转导 293 T 细胞以表达 HLA-B*27:05 而制备的。随后，将 T 细胞与预先用候选肽孵育过的 APCs 共培养，并通过检测 CD69 表面表达及 NFAT 驱动的 ZsGreen 报告基因的荧光强度来评估 T 细胞活化情况；其中 ZsGreen 的表达由活化 T 细胞核因子 (NFAT) 应答元件调控，用以反映下游 TCR 信号通路活性 (图 5b; “材料与方法”)。

尽管并非所有候选肽均被预测可与 AS8.4 结合，我们仍对全部 10 种肽段进行了测试，以直接评估该模型区分激活剂 (CD69+ZsGreen+) 与非结合物的能力。我们观察到，针对三种预测为阳性结合物的肽段——arvmalmpf (源自 *Streptococcus anginosus*, *S. mutans* 及 *S. parasanguinis*; 阳性率 49.5%)、primmismk (源自 *Prevotella copri* 与 *Segatella copri*; 阳性率 1.29%) 以及 grilalvpk (源自 *Akkermansia muciniphila*; 阳性率 0.97%)——均引发了显著的 T 细胞活化反应 (图 5c 及补充图 19)。为便于比较，我们同时设置了两个既往报道的阳性对照 (trlialipk, 7.0%; lrvmmalpf, 57.8%)、两个阴性对照 (rrfderrr, 0.057%; gilgfvtl, 0.084%) 以及背景条件组 (无肽段; 无 APC/无肽段)，上述所有实验组均仅引发极微弱的活化反应。

StriMap 对十种肽段的预测结果与实验结果高度吻合：三种激活肽段 (arvmalmpf, grilalvpk, primmismk) 均位列候选肽段前列，而非激活肽段则 consistently 获得较低评分。为了进一步验证这些结果，我们

在实验验证的肽段-TCR 对上对多种建模策略进行了基准测试：将三种激活肽段标记为阳性样本，其余肽段标记为阴性样本，并根据每种方法预测的评分计算 AUROC / AUPRC (见补充图 20)。在两项指标上，StriMap 均显著优于逻辑回归、Yang 等人⁴⁴使用的基于氨基酸频率的基线模型，以及 NetTCR-2.2¹⁹。值得注意的是，在少样本设置中引入有限的实验反馈可提升性能，这表明 StriMap 能够有效利用稀疏的实验验证数据，优化疾病特异性 TCR-抗原识别预测。

最后，鉴于已有报道将潜在致病性链球菌属与 AS、IBD 及 AS-IBD 重叠现象相关联^{45,46}，我们探究这些经实验验证的候选蛋白是否具有更广泛的临床关联。我们针对基于宏基因组组合组装构建的翻译后非冗余微生物蛋白质目录⁴⁷进行了精确 k -mer 搜索。该蛋白质目录涵盖来自 156 例携带 IBD 的个体 (包括溃疡性结肠炎患者 [UC, $n=29$] 与克罗恩病患者 [CD, $n=82$]) 以及来自 IBD 队列中的健康对照者 ($n=45$)^{48–50}、来自男性生活方式验证研究 (MLVS) 的健康对照者 ($n=361$)⁵¹，以及 970 例经病原体确诊的胃肠炎患者⁵²。所有宏基因组样本均具备匹配的宏转录组数据，使我们能够评估编码候选肽段蛋白质的基因的转录活性。在十种候选肽中，含有 ARVMALMPF 基序的五种蛋白质在克罗恩病或溃疡性结肠炎患者中相较于健康对照组显著更常见且富集度更高；而含有 primmismk 的两种蛋白质在非 IBD 样本中则更为常见且转录水平




图5 | AS相关微生物模拟肽的实验验证。a 发现框架概览：StriMap 优先筛选候选疾病相关 TCR-肽段-HLA 相互作用进行实验验证及迭代优化。b 验证 AS 相关 TCR AS 8.4 与候选肽段间相互作用的实验流程：将 CD8+ Jurkat T 细胞转导以表达 AS8.4 TCR，并与负载候选细菌肽段的 HLA-B*27:05 抗原呈递细胞（APCs）共培养。c 肽段刺激后 T 细胞活化的流式细胞术分析。通过 CD69（y 轴）与 NFAT（活化 T 细胞核因子）驱动的 ZsGreen 报告基因活性（x 轴）的共表达来量化活化程度。三种细菌肽段均诱导了显著的 T 细胞活化，其效果与阳性对照组相当；而阴性对照组及背景对照组仅显示微弱活化。活化细胞富集于 CD69*ZsGreen+ 象限。图中展示的是两次独立实验中其中一次的代表性流式细胞图；两次实验均呈现出一致的活化模式。d

对临床队列中细菌肽候选物的宏基因组与宏转录组分析。热图展示了健康对照组、感染性胃肠炎患者、克罗恩病（CD）患者及溃疡性结肠炎（UC）患者中肽相关特征的相对分布情况，数据均经过 Z 分数标准化处理。e 不同诊断组间肽相关特征的统计学比较。对健康组、感染性胃肠炎组、UC 组及 CD 组分别进行了 Kruskal-Wallis 检验。具有显著组间差异（ $p < 0.05$ ）的特征进一步采用事后 Dunn 检验及多重比较校正进行评估。所有两两比较的精确 P 值及 Bonferroni 校正后 P 值均列于补充表 6。MGX 宏基因组学；MTX 宏转录组学。a、b 图使用 BioRender 制作。Kang, H. (<https://BioRender.com/gu35ufi>).

上调（图5d、e及补充表6）。特别值得注意的是，arvmalmpf——在筛选阶段以最高评分被预测（图4d），且本研究证实其可激活AS8.4+ T 细胞——在 IBD 患者群体中均表现出一一致的富集现象，这支持了AS与 IBD 之间可能存在共同微生物触发因子的假说。

讨论

深度学习已在生物医学领域取得重大进展，但将其应用于新的生物学场景仍面临挑战——尤其在数据稀疏、类别不平衡及数据集偏倚等条件下。我们并未单纯依赖规模日益扩大的数据集，而是致力于开发能够在有限监督条件下更精准捕捉生物结构的模型，并将这一原则应用于 TCR 抗原特异性预测——这是感染、癌症及自身免疫性疾病研究中的核心问题。T 细胞介导的免疫反应依赖于一个识别级联过程：肽段由 HLA 分子呈递，随后与多样化的 T 细胞受体结合。由于该三分子过程的相互作用空间呈组合爆炸式增长、识别过程受结构约束但具有一定灵活性，且可用实验数据既稀疏又存在偏倚，因此对此过程的建模极具难度。本文提出的 StriMap 是一个统一框架，它综合利用互补的物理化学

特征、序列上下文信息及结构信息表征，同步对肽段-HLA 呈递过程与 TCR 识别过程进行建模。StriMap 的一项核心概念性突破，在于将其将抗原呈递与 TCR 识别视为一个耦合的生物过程，而非两个独立的预测任务。通过将 TCR 识别与肽段-HLA 配型景观相关联，StriMap 构建了一条生物学上自洽的决策路径，有助于区分免疫原性变化究竟源于呈递机制的改变，还是源于 TCR 结合状态的改变。此外，StriMap 可在大规模数据中整合基于结构的约束条件，且无需依赖实验解析的复合物结构，从而实现对界面几何构型的推理能力——这一能力已超越现有结构数据库的覆盖范围。在实践中，我们发现训练策略是对模型架构的关键补充：动态且考虑突变效应的负样本采样策略，可使模型接触真实场景中的近似错误诱饵，这在临床环境中尤为重要——因为新抗原与自身抗原的差异往往仅在于单个氨基酸。StriMap 的实用性在两种截然不同的疾病应用场景中得到了充分体现——这两种场景均要求对候选靶点进行严格的优先级排序。在癌症免疫治疗领域，StriMap 可在零样本条件下提升顶级候选靶点中真实结合物的富集率；这一应用场景与临床实践高度契合，因为患者特异性新抗原本质上具有新颖性。该工具还实现了以下联合建模功能：

呈现与识别为在仅能实验测试少量候选物时，优先选择TCR和疫苗新表位提供了实用框架。尽管本文聚焦于黑色素瘤及TP53突变，但我们预期这一优先选择策略可推广至其他癌症情境。在自身免疫性疾病领域，StriMap将大规模微生物序列空间与抗原特异性T细胞应答相连接：通过将疾病相关的TRBV9 TCR克隆型与HLA-B*27:05限制的微生物肽谱相结合，我们鉴定出经实验验证可激活自身免疫相关T细胞的细菌肽段。其中一个已验证肽段在IBD队列中的富集现象进一步表明，共享的微生物抗原驱动因子可能促成重叠的炎症表型，这揭示了StriMap如何将大规模计算机筛选转化为可验证的机制假说。值得注意的是，功能性分子模拟往往依赖于共享的生化热点，而非严格的整体结构同源性⁵³。StriMap成功捕捉了这些非线性几何约束，从而能够识别出多种超越简单序列或结构比对的细菌模拟物。

我们将StriMap构想为一个针对特定任务的预测框架，旨在快速评估庞大的肽段-HLA及TCR-pHLA候选空间，同时明确整合抗原呈递与TCR识别机制。从实际临床应用视角出发，StriMap可在两阶段工作流程中补充其他结构建模方法（如AlphaFold3⁵⁴）。在此工作流程中，StriMap首先用于筛选出可处理的候选新表位或TCR-pHLA配对集合，随后采用结构建模方法生成关于所选靶点间相互作用机制的假说。

仍存在若干局限性与机遇。首先，由于TCR-pHLA数据较为稀疏且在表位空间中分布不均，对完全全新表位实现完全零样本泛化仍具挑战性⁵⁵。因此，我们的研究结果表明，评估零样本性能时应侧重于功能优先级排序，而非仅依赖AUROC、OOD等综合指标基准测试。例如IMMREP23仅包含少量未见过的表位（ $n=3$ ），这限制了全局性能统计量的可解释性。相比之下，StriMap在临床相关排序场景中展现出强大的实用价值：它将经过验证的TP53特异性TCR列为癌症免疫治疗中的顶级候选物，并在自身免疫性疾病领域从约1300万个细菌9聚体中优先筛选出一小批激活肽。这种Top-K精准度往往是转化医学成功的关键决定因素，因为它直接决定了哪些候选物会被选中进行昂贵的实验验证。尽管如此，利用有限任务或患者特异性数据进行小样本适配，对于在需要更高精确度的应用场景中进一步提升模型准确率，仍是一种可靠的策略。

其次，基于结构的表征方法可优化界面建模，但可能无法捕捉影响识别过程的构象动力学；引入结构不确定性（如系综预测）或动力学启发特征，或可进一步提升预测性能。与此方向一致，正在进行的IMMREP25 Kaggle挑战赛凸显了结构感知型TCR-pHLA建模的重要性，尽管由于迄今尚未发表性能最优的基于结构的模型，直接对比仍较为有限。此外，许多主流模型均基于AlphaFold3⁵⁴预测构建，但其计算成本与通量限制制约了其在蛋白质组规模筛选中的应用。StriMap通过隐式建模界面，并采用两阶段漏斗策略——利用快速序列编码器进行大规模pHLA筛选，同时专门调用ESMFold衍生的单体结构来处理TCR识别这一复杂任务——从而规避上述局限。这种审慎的权衡策略，使得在数百万候选分子中实现高效优先级排序成为可能。第三，我们目前的实施方案主要聚焦于HLA I类分子与CD8+ T细胞的识别；将该框架拓展

至HLA II类分子呈递及CD4+ T细胞识别，对于扩大其转化医学应用价值具有重要意义。

为促进模型的广泛应用与迭代优化，我们搭建了网络门户及训练界面，支持基于本地数据集进行预测及快速微调，使用户在整合稀疏实验反馈的同时，仍能保留大规模预训练所得知识（补充图21）。我们相信，这种将耦合建模、结构感知表征与实验室-闭环验证相结合的策略，将有助于弥合计算预测与机制性免疫学之间的鸿沟，从而在癌症免疫治疗及抗原驱动型自身免疫性疾病研究领域推动更高效的新药发现。

方法

StriMap 框架

StriMap是一个统一的深度学习框架，用于在残基分辨率水平上建模pHLA结合及TCR对pHLA复合物的识别。该框架由两个模块化组件构成：(i)一个肽-HLA预测器，用于学习可迁移的pHLA表征；(ii)一个TCR-pHLA预测器，利用预训练的pHLA特征。这两个组件均基于统一的序列与结构特征提取器（SSFE）以及采用双线性注意力网络（BAN）实现的基于注意力的残基级相互作用建模构建而成。

序列与结构特征提取器（SSFE）

给定长度为 L 的输入蛋白质序列，SSFE通过整合物理化学特性、序列上下文及结构相关信息，构建残基级别的表征。这三种模式均被独立编码，随后再融合在一起。

物理化学编码

残基 i 使用一个20维物理化学描述符向量 $\mathbf{S}^{phys}_i \in \mathbb{R}^{d_{phys}}$ 进行编码，该向量源自AAindex³¹（选取的属性包括疏水性、电荷、极性、分子体积及侧链柔度；经氨基酸熵 z 分数标准化处理）（见补充表1）。对于长度为 L 的序列，其物理化学特征将被整合为一个矩阵。

$$\mathbf{S}^{phys} = [\mathbf{S}^{phys}_1, \dots, \mathbf{S}^{phys}_L]^T \in \mathbb{R}^{L \times d_{phys}}, d_{phys} = 20. \quad (1)$$

为使该模式与模型的潜在空间对齐，我们采用一个全连接层，将特征映射至 d 维空间：

$$\mathbf{X}^{phys} = \text{Linear}(\mathbf{S}^{phys}) \in \mathbb{R}^{L \times d}, \text{其中 } d = 256. \quad (2)$$

序列上下文编码

为捕捉超越局部氨基酸特性的进化与上下文信息，我们采用预训练的蛋白质语言模型ESM2（6.5亿参数）³²。对于输入序列，从ESM2的最终Transformer层中提取残基级语义嵌入，随后经过一个全连接层：

$$\mathbf{S}^{sem} = \text{ESM2}(\mathbf{S}), \mathbf{S}^{sem} \in \mathbb{R}^{L \times d_{sem}}, d_{sem} = 1280. \quad (3)$$

$$\mathbf{X}^{sem} = \text{Linear}(\mathbf{S}^{sem}) \in \mathbb{R}^{L \times d}, \text{其中 } d = 256. \quad (4)$$

几何结构编码

蛋白质结构信息源自ESMFold预测的三维结构。对于残基 i ，我们提取一个结构描述符向量 $\mathbf{X}^{struct}_i \in \mathbb{R}^{d_{struct}}$ ，其中 $d_{struct}=17$ ，该向量包含主链扭转角（以正弦与余弦对形式编码）、二级结构状态、相对溶剂可及性、残基接触计数以及预测置信度分数（pLDDT）。此外，我们还保

留C α 原子的笛卡尔坐标: $\mathbf{r}_i \in \mathbb{R}^3$ 。

为了明确建模空间关系, 将残基表示为几何图中的节点, 并应用一个堆叠的 SE(3) 等变图神经网络 (EGNN)。对于 EGNN 的第 l 层, 节点特征与坐标的更新公式如下:

$$\mathbf{m}_{ij} = \phi_m(\mathbf{h}_i^{(l)}, \mathbf{h}_j^{(l)}, \|\mathbf{r}_i^{(l)} - \mathbf{r}_j^{(l)}\|^2), \quad (5)$$

$$\mathbf{r}_i^{(l+1)} = \mathbf{r}_i^{(l)} + \sum_{j \neq i} (\mathbf{r}_i^{(l)} - \mathbf{r}_j^{(l)}) \phi_r(\mathbf{m}_{ij}), \quad (6)$$

$$\mathbf{m}_i = \sum_{j \neq i} \mathbf{m}_{ij}, \quad (7)$$

$$\mathbf{h}_i^{(l+1)} = \phi_h(\mathbf{h}_i^{(l)}, \mathbf{m}_i), \quad (8)$$

其中 ϕ_m , ϕ_r 与 ϕ_h 均为可学习多层感知机。节点特征初始化为 $\mathbf{h}_i^{(0)} = \mathbf{X}_{\text{struct}}$, 以及 $\mathbf{r}_i^{(0)} = \mathbf{r}_i$ 。该坐标更新公式保证了 SE(3) 等变特性。

最后, 基于结构的几何编码被定义为从最终层 N 出发, 再经过一个全连接层后得到的节点嵌入:

$$\mathbf{S}^{\text{struct}} = \mathbf{h}^{(N)} \in \mathbb{R}^{L \times d_{\text{egnn}}}, \quad (9)$$

$$\mathbf{X}^{\text{struct}} = \text{Linear}(\mathbf{S}^{\text{struct}}) \in \mathbb{R}^{L \times d}, \quad d = 256, \quad (10)$$

其中 d_{egnn} 表示 EGNN 的隐藏维度。

多模态特征融合

理化特性与序列上下文特征通过门控交叉注意力机制进行融合。给定 $\mathbf{X}^{\text{phys}}$ 与 $\mathbf{X}^{\text{sem}}$, 交叉注意力计算如下:

$$\mathbf{A} = \text{Attn}(\mathbf{Q} = \mathbf{X}^{\text{phys}}, \mathbf{K} = \mathbf{X}^{\text{sem}}, \mathbf{V} = \mathbf{X}^{\text{sem}}), \quad (11)$$

在哪里

$$\text{Attn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V}. \quad (12)$$

可学习的 g

ating function controls modality contribution:

$$\omega_1 = \sigma(\text{Linear}([\mathbf{X}^{\text{phys}}; \mathbf{A}])), \quad (13)$$

$$\mathbf{E}^{\text{seq}} = \text{LayerNorm}((\mathbf{1})_1 \cdot \mathbf{X}^{\text{phys}} + (1 - (\mathbf{1})_1) \cdot \mathbf{A}), \quad (14)$$

结构感知嵌入向量与序列衍生特征进一步整合, 最终残基表征的计算公式如下:

$$(\mathbf{1})_2 = \sigma(\text{线性}([\mathbf{E}^{\text{seq}}; \text{Attn}(\mathbf{E}^{\text{seq}}, \mathbf{X}^{\text{struct}}, \mathbf{X}^{\text{struct}})])), \quad (15)$$

$$\mathbf{E}^{\text{f}} = (\mathbf{1})_2 \cdot \mathbf{E}^{\text{seq}} + (1 - (\mathbf{1})_2) \cdot \text{Attn}(\mathbf{E}^{\text{seq}}, \mathbf{X}^{\text{struct}}, \mathbf{X}^{\text{struct}}). \quad (16)$$

其中 $(\mathbf{1})_k \in \mathbb{R}$, $k \in \{1, 2\}$ 是通过 Sigmoid 激活函数 $\sigma(\cdot)$ 获得的标量门控系数。

交互建模: 双线性注意力网络 (BAN)

为构建精细化的接触界面模型, 并捕捉两条蛋白质链 (如肽段与 HLA, 或 TCR 与 pHLA) 残基间的复杂依赖关系, 我们采用了双线性注

意力网络。与常将信息压缩至单一维度的标准点积注意力机制不同,

BAN 通过双线性兼容性函数建模残基间的成对相互作用, 并在无需显式构建完整外积张量的前提下, 聚合具有相互作用特征的代表。

我们使用可学习的权重矩阵 $\mathbf{U} \in \mathbb{R}^{D \times D}$ 和 $\mathbf{V} \in \mathbb{R}^{D \times D}$, 将两个表示 $\mathbf{E} \in \mathbb{R}^{L_e \times D}$ 和 $\mathbf{T} \in \mathbb{R}^{L_t \times D}$ 投影到维度为 $D = 256$ 的联合空间中。E 的第 i 个残基与 T 的第 j 个残基的变换后特征如下:

$$\tilde{\mathbf{e}}_i = \mathbf{U}^\top \mathbf{E}_i, \quad \tilde{\mathbf{t}}_j = \mathbf{V}^\top \mathbf{T}_j, \quad (17)$$

其中 $\tilde{\mathbf{e}}_i, \tilde{\mathbf{t}}_j \in \mathbb{R}^D$ 。

每个残基对的交互分数 S_{ij} 均通过可学习参数 $\mathbf{q} \in \mathbb{R}^D$ 计算得出, 用以衡量双线性兼容性, 计算公式如下:

$$S_{ij} = \tilde{\mathbf{e}}_i^\top \mathbf{q} \cdot \text{diag}(\mathbf{q}) \cdot \tilde{\mathbf{t}}_j, \quad (18)$$

其中 $\mathbf{S} \in \mathbb{R}^{L_e \times L_t}$ 。

注意力图 $\mathbf{I}_{ij}$ 通过显式的二维 Softmax 函数进行归一化处理:

$$\mathbf{I}_{ij} = \frac{\exp(S_{ij})}{\sum_{a=1}^{L_e} \sum_{b=1}^{L_t} \exp(S_{ab})}, \quad (19)$$

其中 $\mathbf{I} \in \mathbb{R}^{L_e \times L_t}$ 。

合并后的交互向量 $\mathbf{z}$ 是通过对所有残基对进行哈达玛积 (o) 而推导得出的:

$$\mathbf{z} = \text{BatchNorm}\left(\sum_{i=1}^{L_e} \sum_{j=1}^{L_t} \mathbf{I}_{ij} \cdot (\tilde{\mathbf{e}}_i \odot \tilde{\mathbf{t}}_j)\right), \quad (20)$$

其中 $\mathbf{z} \in \mathbb{R}^{D}$ 。

肽段-HLA 预测模型

该肽-HLA 预测器整合了 SSFE、Transformer 编码器、交叉注意力机制以及 BAN。

设 $\mathbf{S}^{\text{pep}}$ 和 $\mathbf{S}^{\text{hla}}$ 分别表示肽段与 HLA 的氨基酸序列。该模型通过残基级序列编码及基于注意力的交互建模, 接受可变长度的肽段输入, 而无需将肽段固定为 9 聚体; 肽段长度则在批量处理过程中通过填充与掩码机制隐式处理。肽段与 HLA 的残基特征首先由 SSFE 模块独立编码:

$$\mathbf{E}^{\text{fused:pep}} = \text{SSFE}(\mathbf{S}^{\text{pep}}), \quad \mathbf{E}^{\text{fused:hla}} = \text{SSFE}(\mathbf{S}^{\text{hla}}), \quad (21)$$

以及 Transformer 模块:

$$\mathbf{E}^{\text{pep}} = \text{Transformer}(\text{使用 } \mathbf{E}^{\text{fused:pep}}), \quad \mathbf{E}^{\text{hla}} = \text{Transformer}(\text{使用 } \mathbf{E}^{\text{fused:hla}}). \quad (22)$$

后应用双向交叉注意力机制:

$$\mathbf{P} = \text{LayerNorm}(\mathbf{E}^{\text{pep}} + \text{Attn}(\mathbf{E}^{\text{pep}}, \mathbf{E}^{\text{hla}}, \mathbf{E}^{\text{hla}})), \quad (23)$$

$$\mathbf{H} = \text{LayerNorm}(\mathbf{E}^{\text{hla}} + \text{Attn}(\mathbf{E}^{\text{hla}}, \mathbf{E}^{\text{pep}}, \mathbf{E}^{\text{pep}})). \quad (24)$$

BAN 被应用于肽残基与 HLA 结合口袋残基之间——这些残基已被

预先定义为 34 个典型结合沟槽位点¹¹——从而生成一个相互作用向量。

$$\mathbf{z}_{pHLA} = \text{BAN}(\mathbf{P}, \mathbf{H}) \quad (25)$$

该结果被输入到一个采用Sigmoid激活函数的多层感知机中，以预测肽段-HLA结合评分。重要的是，尽管完整的pHLA模型通过 SSFE 模块原生支持多模态结构融合，但在训练和推理过程中，肽段的结构分支可被选择性禁用。这种灵活的设计在超大规模虚拟筛选（如全蛋白质组筛选）中最大化计算吞吐量——在此类场景中，序列与物理化学特征已足以满足呈递建模需求，而完整的三分子结构架构则在下游TCR识别任务中全面发挥作用。

TCR-肽段-HLA预测模型

TCR-pHLA预测模型用于预测TCR α/β 异二聚体对pHLA复合物的特异性识别。该模型采用多阶段训练流程及精细的相互作用层级结构，以应对四级复合体日益增加的复杂性。

特征聚合器：预训练与迁移学习

为稳定并引导TCR-pHLA识别的学习过程，pHLA预测器首先进行预训练，随后作为特征聚合器重复使用。这种迁移学习策略确保模型在构建TCR相互作用模型前，能够充分利用已建立的pHLA复合物稳定性知识。

令 $\mathbf{H}^{pre}$ 与 $\mathbf{P}^{pre}$ 分别表示从冻结的 pHLA 预测器中提取的预训练嵌入向量（对应 HLA 与肽段），令 $\mathbf{H}^{task}$ 与 $\mathbf{P}^{task}$ 表示在 TCR-pHLA 流程中生成的任务特定嵌入向量。这些表征通过门控融合机制进行整合：

$$\omega_{hla} = \sigma(\text{Linear}([\mathbf{H}^{task}; \text{Attn}(\mathbf{H}^{task}, \mathbf{H}^{pre}, \mathbf{H}^{pre})])) \quad (26)$$

$$(1)_{pep} = \sigma(\text{Linear}([\mathbf{P}^{task}; \text{Attn}(\mathbf{P}^{task}, \mathbf{P}^{pre}, \mathbf{P}^{pre})])) \quad (27)$$

$$\mathbf{H}^{agg} = \text{LayerNorm}(\omega_{hla} \cdot \mathbf{H}^{task} + (1 - \omega_{hla}) \cdot \text{Attn}(\mathbf{H}^{task}, \mathbf{H}^{pre}, \mathbf{H}^{pre}))) \quad (28)$$

$$\mathbf{P}^{agg} = \text{LayerNorm}(\omega_{pep} \cdot \mathbf{P}^{task} + (1 - \omega_{pep}) \cdot \text{Attn}(\mathbf{P}^{task}, \mathbf{P}^{pre}, \mathbf{P}^{pre}))) \quad (29)$$

预训练表征 $\mathbf{H}^{pre}$ 与 $\mathbf{P}^{pre}$ 提供了对 pHLA 复合物的呈递感知表征，包含肽段-HLA 相容性及 HLA 限制性上下文信息。相比之下， $\mathbf{H}^{task}$ 与 $\mathbf{P}^{task}$ 则直接针对 TCR 识别进行优化。该设计并不假定 TCR 结合是由决定肽段-HLA 呈递的相同残基或特征所驱动；相反，预训练分支提供稳定的 pHLA-上下文先验，而任务特定分支则学习与 TCR 结合相关的特征。这两个表征通过一个输入依赖性门控机制相结合，该机制控制每个 pHLA 输入中两者的相对贡献，从而使模型能够在呈递感知上下文与 TCR 识别特异性信息之间取得平衡。

交互层级：SSFE + 变换器 + 交叉注意力 + BAN

在完成特征聚合后，TCR-pHLA 相互作用通过以下分层操作序列进行建模：

- 设 $\mathbf{S}^{tcra}$ 和 $\mathbf{S}^{trcb}$ 分别表示 TCR α 链与 TCR β 链的氨基酸序列。残基特征由 SSFE 模块与 Transformer 块独立编码：

$$\mathbf{E}^{tcra} = \text{Transformer}(\text{SSFE}(\mathbf{S}^{tcra})), \quad \mathbf{E}^{trcb} = \text{Transformer}(\text{SSFE}(\mathbf{S}^{trcb})) \quad (30)$$

- CDR3 片段提取：该模型识别并提取高变区 CDR3 α 与 CDR3 β 片段。对于每条链，令 $i\alpha_{start}$ 、 $i\beta_{start}$ 及 $i\alpha_{end}$ 、 $i\beta_{end}$ 分别为锚定残基的索引。片段 $\mathbf{E}^{cdr3a}$ 与 $\mathbf{E}^{cdr3b}$ 的提取公式如下：

$$\mathbf{E}^{cdr3a} = \mathbf{E}^{tcra}[i\alpha_{start} : i\alpha_{end}], \quad \mathbf{E}^{cdr3b} = \mathbf{E}^{trcb}[i\beta_{start} : i\beta_{end}] \quad (31)$$

- 多通道交叉注意力机制：TCR 环与 pHLA 聚合特征之间交换互信息，以优化对接取向：

$$\mathbf{T}^{cdr3a} \leftarrow \text{LayerNorm}(\mathbf{E}^{cdr3a} + \text{Attn}(\mathbf{E}^{cdr3a}, \mathbf{P}^{agg}, \mathbf{P}^{agg})), \quad (32)$$

$$\mathbf{T}^{cdr3b} \leftarrow \text{LayerNorm}(\mathbf{E}^{cdr3b} + \text{Attn}(\mathbf{E}^{cdr3b}, \mathbf{P}^{agg}, \mathbf{P}^{agg})), \quad (33)$$

$$\mathbf{T}^{tcra} \leftarrow \text{LayerNorm}(\mathbf{E}^{tcra} + \text{Attn}(\mathbf{E}^{tcra}, \mathbf{H}^{agg}, \mathbf{H}^{agg})), \quad (34)$$

$$\mathbf{T}^{trcb} \leftarrow \text{LayerNorm}(\mathbf{E}^{trcb} + \text{Attn}(\mathbf{E}^{trcb}, \mathbf{H}^{agg}, \mathbf{H}^{agg})), \quad (35)$$

- 双线性交互建模：基于第 3.3 节所述的 BAN 架构，该模型计算四个不同的交互向量：

$$\mathbf{z}_{cdr3a}^{-pep} = \text{BAN}(\mathbf{T}^{cdr3a}, \mathbf{P}^{agg}), \quad \mathbf{z}_{cdr3b}^{-pep} = \text{BAN}(\mathbf{T}^{cdr3b}, \mathbf{P}^{agg}) \quad (36)$$

$$\mathbf{z}_{tcra}^{-hla} = \text{BAN}(\mathbf{T}^{tcra}, \mathbf{H}^{agg}), \quad \mathbf{z}_{trcb}^{-hla} = \text{BAN}(\mathbf{T}^{trcb}, \mathbf{H}^{agg}) \quad (37)$$

- 预测头：这些向量被拼接成一个全局交互表示 $\mathbf{z}_{total}$ ，然后经过一个带有 sigmoid 激活函数的多层感知机（MLP），最终输出 TCR-pHLA 结合评分。

负采样

为在有限的经实验验证的负样本条件下提升区分度并抑制捷径学习现象，我们采用了两种互补的负样本采样策略：基于动态洗牌法的负样本策略，以及考虑变异特性的硬负样本策略。

动态负采样

由于关于TCRpHLA相互作用预测的综合性阴性结合数据较为匮乏，我们为训练构建了阴性样本对。常用策略包括：(i)固定pHLA，随机洗牌TCR以生成不匹配配对，同时排除所有已知的阳性配对；以及(ii)将pHLA与来自健康供体的背景TCR进行配对。我们采用基于洗牌的策略，以避免在使用健康供体背景时可能出现的阳性与阴性TCR谱系分布不匹配问题³⁹。具体而言，我们以3:1的阴性/阳性比例采样阴性样本。与训练前固定单一阴性样本集不同，我们在训练过程中动态再生洗牌的

阴性样本（例如每轮训练时），此举在保持阳性样本集不变的前提下，扩展了有效阴性样本空间，同时降低了对有限静态阴性样本池的依赖。

考虑突变的硬负样本采样

在癌症突变分析中，我们还引入了一种考虑突变特性的策略，用于构建硬负样本，从而更准确地反映区分突变体与密切相关的自身上下文环境这一生物学挑战。具体而言，我们通过微小的序列扰动生成诱饵对：

- 肽段突变：对于阳性肽段，我们随机替换1-2个残基，以生成仅进行最小扰动的诱饵肽，此类诱饵肽预期可降低肽段与HLA及/或TCR的识别相容性。
- TCR CDR3 突变：我们在 CDR3 环(s)内随机突变 1-3 个残基（排除保守锚定位点），以生成可能改变特异性的近邻诱饵序列。

我们注意到，该策略可能引入标签噪声，因为部分受扰动的序列仍可能保留可测量的结合能力。然而，在此构建框架下，实验验证的阳性样本平均而言仍会比突变诱饵分子表现出更高的结合倾向性，这使得这些硬阴性样本在缺乏全面阴性样本测量时，仍可作为训练与评估的有效近似选择。

培训目标

模型采用焦点损失进行训练，以解决类别不平衡问题。对于标签 $y \in \{0,1\}$ 及预测概率 p ，损失函数定义为：

$$L = -\alpha y (1-p)^y \log(p) - (1-\alpha)(1-y)p^y \log(1-p), \quad (38)$$

其中 α 用于平衡正类与负类样本，而 y 则用于强化难例样本的权重。该策略迫使模型将真实的分子识别与高度相似的诱饵相互作用区分开来，从而显著提升特异性。

培训详情

- 优化器：AdamW，学习率为 1×10^{-4} ，并启用权重衰减。
- 正则化：采用 0.1 的 Dropout 率，以及最大范数为 2.0 的梯度裁剪。
- 交叉验证：对于 Peptide-HLA 预测器，采用 5 折交叉验证，早期停止参数为 5 个 epoch；对于 TCRpHLA 预测器，采用 10 折交叉验证，早期停止参数为 10 个 epoch；两种验证均基于验证集 AUROC。最大 epoch 数设定为 100。
- 批大小：批大小设置为 256。
- 硬件：所有模型均在 NVIDIA A6000 GPU 上使用 PyTorch 框架进行训练。

评估指标

我们使用 AUROC、AUPRC、召回率、真实发现率（TDR）以及 AUC0.1 来评估模型的性能。AUROC（受试者工作特征曲线下面积）用于衡量模型在所有可能的分类阈值下，将阳性交互作用排在阴性交互作用之上的能力。由于许多免疫学预测任务具有高度不平衡性，我们还报告了 AUPRC（精确率-召回率曲线下面积），该指标对从大量阴性样本中恢复罕见阳性交互作用更为敏感。

在候选物优先级分析中，召回率定义为在排名靠前的预测结果中回收到的经实验验证的阳性样本所占比例；TDR 则定义为在排名靠前的候选物中经实验验证为阳性的样本所占比例，该指标可为后续验证所

选候选物中的富集程度提供实用量化依据。

在 IMMREP23 基准测试中，我们遵循原始挑战协议采用 AUC0.1 指标。该指标表示仅计算至假阳性率 0.1 时 ROC 曲线下部分的面积。此评估标准聚焦于 ROC 曲线上高特异性区域，因此在假阳性代价较高且仅能实验验证少量预测的 TCR-表位相互作用的场景中，该指标对于模型评估具有重要价值。

模态级 Shap 分析

为解析多模态架构，并定量评估不同数据模态与生物组分的全局重要性，我们构建了一个定制化、精确的 Shap（Shapley Additive exPlanations）框架。标准 Shap 计算工具包（如 KernelSHAP）通常针对高维特征空间设计，且多依赖近似算法；鉴于本研究旨在评估有限数量的宏观特征（即数据模态或生物组分，记为 M ），我们摒弃了近似算法，直接计算精确的 Shapley 值，以确保数学严谨性的最大化。

具体而言，对于测试集中的每个样本，我们均在所有 2^M 种可能的输入模态组合（联盟）上评估模型的预测输出。掩码输入被替换为从背景数据集分布中抽取的期望值。

第 i 个模态的确切模态 Shap 值 ϕ_i 随后被计算为其对所有不包含 i 的可能子集 S 的边际贡献的加权平均值：

$$\phi_i = \sum_{S \subseteq M \setminus \{i\}} \frac{|S|!(|M| - |S| - 1)!}{|M|!} (v(S \cup \{i\}) - v(S)), \quad (39)$$

其中 $v(S)$ 表示给定活性模态子集 S 时模型的预测结果。这种基于消融的精确方法，可为每个模块对推断出的 TCR-pHLA 相互作用的贡献提供高度稳健的量化评估。

实验细节

质粒构建。AS8.4 TCR 序列 TRBV901-TRBJ2-301 和 TRAV2101-TRAJ2801 取自国际免疫基因信息系统（IMGT/GENE-DB，<https://www.imgt.org/>）。CDR3 区段与 Yang 等人报道的序列一致（ β : cassvgtyst-dtqyf; α : cavnspgsgagsyqltf）。基因片段针对智人进行了密码子优化，与 P2A 连接器连接，并组装至 pLX307 载体中。正确组装通过桑格测序法（CCIB DNA Core，波士顿麻省总医院）验证。

细胞系。Jurkat E6.1（ATCC；TIB-152）、HEK293T（ATCC；CRL-3216）及 Plat-A（Cell Biolabs，美国加利福尼亚州圣迭戈；RV-102）细胞均在 37 °C 及 5% 二氧化碳条件下培养。Jurkat 与 Plat-A 细胞使用 RPMI-1640 培养基（Thermo Fisher；61870036）培养；HEK293T 与 Plat-A 细胞则使用 DMEM 培养基（Thermo Fisher；10569010）培养。培养基中均添加 10%（体积比）热灭活胎牛血清（Thermo Fisher；26140079）及 100 $\mu\text{g/ml}$ 青霉素-链霉素混合溶液（Thermo Fisher；15140-122）。每 3 个月使用支原体检测试剂盒（InvivoGen；rep-mys-50）对细胞系进行支原体阴性筛查。

CRISPR-Cas9 敲除内源性 TCR。以消除内源性 TCR。在 Jurkat 细胞中，针对 TCR α 恒定区（TRAC）和 TCR β 恒定区（TRBC1）均使用与 Cas9-GFP 蛋白（IDT；10008100）复合的合成向导 RNA（sgRNA）进行靶向。核糖核蛋白复合物的组装比例为 Cas9-GFP（IDT；10008100）与 sgRNA（IDT）的摩尔比 1:2。所使用的 sgRNA 序列如下：针对 TRAC，分别为 5'-tggattgagctctcagc-3' 和 5'-

acaaaactgtgctagacatg-3; 针对TRBC1, 分别为5'-cgtagaactggacttgacag-3和5'-cccaccagctcagctccacg-3。Jurkat 细胞使用 4D-Nucleofector™ X Unit (Lonza) 及 SE Cell Line 4D-Nucleofector™ X Kit S (Lonza; V4 XC-1032) 进行核糖核蛋白复合物的电穿孔转染。采用CL-120程序, 随后将细胞立即转移至2 mL预热的 RPMI 培养基 (含10% FBS) 中。5天后, 将细胞与PE标记的抗人TCR $\alpha\beta$ 抗体 (克隆号IP26; BioLegend, 产品编号306708) 以1:100稀释比例在100 μ L总染色体积中于冰上染色30分钟。使用Bigfoot™ Spectral细胞分选仪 (Thermo Fisher Scientific) 分选TCR $\alpha\beta$ 阴性细胞, 分选后纯度 $\geq$ 95.0%。

慢病毒载体的制备与转导。HEK293T 细胞被使用TransIT®-LT1转染试剂 (Mirus Bio; MIR 2300) 以4:4:1的比例共转染质粒psPAX2 (Addgene #12260) 与pMD2.G (Addgene #12259)。72小时后收集上清液, 过滤后于-80 °C保存。病毒浓度采用Lenti-X™ GoStix™ Plus试剂盒 (Takara Bio; 631280) 测定。TCR基因敲除Jurkat 细胞在含8 μ g/mL聚凝胺 (Sigma-Aldrich; TR-1003-G) 的条件下, 通过离心转染法 (1000 $\times$ g, 90分钟, 32 °C) 进行病毒转导。48小时后, 持续施加2 μ g/mL嘌呤霉素处理5天。AS8.4 TCR的表达通过PE标记的抗人TCR $\alpha\beta$ 抗体 (克隆号IP26; BioLegend, 货号306708) 与APC标记的抗人CD3抗体 (克隆号UCHT1; BioLegend, 货号300411) 染色验证。两种抗体均以1:100比例稀释, 总染色体积为100 μ L, 细胞于冰上孵育30分钟。

CD8 $\alpha\beta$ 与 NFAT -ZsGreen 报告基因的逆转录病毒递送。CD8 α -CD8 β -8 $\times$ NFAT -ZsGreen 构建体 (Addgene #153417) 被包装于 Plat-A 细胞中。使用 TransIT-LT1 (Mirus Bio; MIR 2300) 进行转染。分别于 48 小时和 72 小时后收集上清液, 并用 Lenti-X 浓缩仪 (Takara Bio; 631231) 进行 10 倍浓缩。Jurkat-AS8.4 细胞按上述方法进行离心感染, 随后培养 72 小时。接着, 将细胞与 PerCP 标记的抗人 CD8 α 抗体 (克隆号 RPA -T8; BioLegend, 产品编号 301030) 以 1:100 的稀释比例混合, 在总染色体积为 100 μ L 的条件下, 于冰上染色 30 分钟。随后分选 CD8 α 阳性细胞, 分选后纯度 $\geq$ 95.0%。

HEK293T-B2M-HLA-B*27:05 抗原呈递细胞的构建 编码人 β 2-微球蛋白 (B2M) 及 HLAB *27:05 的慢病毒载体按上述方法包装。HEK293T细胞在含8 μ g/mL聚溴化物的条件下, 通过离心转染法 (1000 $\times$ g, 90分钟, 32 °C) 进行转导, 随后用嘌呤霉素 (2 μ g/mL, 5 天) 进行筛选, 并通过使用 FITC 标记的小鼠抗人HLA-B27抗体 (克隆号HLA-ABC-m3; Bio-Rad, 产品编号MCA116F) 以1:100稀释比例, 在总染色体积为100 μ L中于冰上染色30分钟, 以评估细胞表面表达情况。

肽刺激实验。将HEK293T-HLA-B*27细胞 (每孔 1×10^5 个细胞) 接种于96孔U型底培养板中, 每孔加入100 μ L DMEM 完全培养基。24小时后, 将合成肽 (GenScript; HPLC 纯度 $\geq$ 95.0%) 溶于水, 并以终浓度100 μ M加入。将肽与HEK293T-HLA-B*27细胞在37 °C、5% CO₂条件下预孵育60分钟。随后, 加入含 1×10^5 个Jurkat-AS8.4- NFAT -ZsGreen细胞的100 μ L RPMI + 10% FBS培养基。共培养体系继续培养24小时 (37 °C, 5% CO₂)。

细胞被收集后, 用APC标记的抗人CD69抗体 (克隆号FN50; BioLegend, 产品编号985206) 以1:100的稀释比例, 在含2% FBS的100 μ L PBS溶液中, 于冰上染色30分钟 (见补充表7)。染色结束后, 细胞经洗涤, 并重悬于300 μ L含2% FBS的PBS溶液中。数据使用Cytek® Aurora光谱流式细胞仪 (Cytek Biosciences, Fremont, CA, USA) 及SpectroFlo v3.0.3软件采集, 并采用FlowJo™ v10.10.0软件 (BD Biosciences,

San Jose, CA, USA) 进行分析。Jurkat细胞通过前向散射与侧向散射特性鉴定, 随后进行单细胞门控。T细胞活化程度以活单细胞Jurkat细胞中CD69阳性及 NFAT -ZsGreen阳性细胞的百分比表示。肽刺激实验在两次独立实验中完成。

报告摘要

有关研究设计的更多信息, 请参阅本文附带的《Nature Portfolio》报告摘要。

数据可用性

本研究中使用最终模型权重、训练数据以及分析的AS相关微生物肽均已通过Zenodo公开获取 (<https://doi.org/10.5281/zenodo.18002170>)。本研究所涉及的基准数据集均通过其原始出版物公开, 包括黑色素瘤数据集² (<https://doi.org/10.1016/j.cell.2025.06.019>)、Albert 等人¹² (<https://doi.org/10.1038/s42256-023-00694-6>)、Chu 等人¹³ (<https://doi.org/10.1038/s42256-022-00459-7>)、IMMREP22¹⁵ (<https://doi.org/10.1016/j.immuno.2023.100024>)、IMMREP23¹⁶ (<https://www.kaggle.com/competitions/tcr-specificity-prediction-challenge>)——Lu 等人¹⁷ (<https://doi.org/10.1038/s41592-025-02910-0>)、Que 等人²² (<https://doi.org/10.1038/s41467-025-60461-6>)、tesla³⁶ (<https://doi.org/10.1016/j.cell.2020.09.015>)、cedar³⁷ (<https://cedar.iedb.org>)、Minervina 等人³⁸ (<https://doi.org/10.1038/s41590-022-01184-4>)、Zhang 等人²³ (<https://doi.org/10.1038/s42256-024-00913-8>)、TP53 数据集⁴³ (<https://doi.org/10.1158/2326-6066.CIR-22-0040>)。其余所有数据均收录于本文及其补充材料中, 或可根据要求向通讯作者索取。原始数据已随本文一同提供。

代码可用性

开源StriMap代码库可在<https://github.com/uhlerlab/strimap-tools>及Zenodo平台<https://doi.org/10.5281/zenodo.21925295> (参考文献³⁶) 获取。一个实现StriMap预测平台的公开可用网络服务器可通过www.strimap.com访问, 该平台为肽段-HLA结合及TCR-HLA识别提供批量预测、分析、可视化及模型微调功能。

参考文献

1. Punt, J., Stranford, S., Jones, P. & Owen, J. 《Kuby 免疫学》。(Macmillan Higher Education, 2018)。
2. Blass, E. 等。一种多佐剂个性化新抗原疫苗可在黑色素瘤中诱导强效免疫应答。Cell 188,5125–5141.e27 (2025)。
3. Klebanoff, C. A., Chandran, S. S., Baker, B. M., Quezada, S. A. & Ribas, A. T 细胞受体疗法: 对细胞内癌症蛋白质组的免疫靶向治疗。《自然·药物发现》22,996–1017 (2023)。
4. Theofilopoulos, A. N., Kono, D. H. & Baccala, R. 自身免疫的多条通路。《自然·免疫学》18,716–724 (2017)。
5. Buckner, J. H. 自身免疫性疾病的抗原特异性免疫治疗。《自然·风湿病学》21,88–97 (2025)。
6. Zhang, S.-Q. 等。单细胞中 T 细胞受体抗原特异性的高通量测定。《自然·生物技术》36,1156–1159 (2018)。
7. Kula, T. 等。T-scan: 一种用于系统性地发现 T 细胞表位的全基因组分析方法。Cell 178,1016–1028 (2019)。
8. Joglekar, A. V. & Li, G. 的 T 细胞抗原发现。《自然·方法》第 18 卷, 第 873–880 页 (2021)。
9. Hudson, D., Fernandes, R. A., Basham, M., Ogg, G. & Koohy, H. 我们能否利用数字生物学与机器学习技术预测 T 细胞特异性? 《自然·免疫学综述》23,511–521 (2023)。
10. Nilsson, J. B., Greenbaum, J., Peters, B. & Nielsen, M. NetMHCpan-4.2: 利用迁移学习与结构特征提升 CD8+ 表位预测性能。Front. Immunol. 16,1616113 (2025)。

11. Reynisson, B., Alvarez, B., Paul, S., Peters, B. & Nielsen, M. NetMHCpan-4.1 与 NetMHCIIpan-4.0: 通过同步基序反卷积及整合 MS 洗脱配体数据, 提升对 MHC 抗原呈递能力的预测精度。《Nucleic Acids Res.》48, W449–W454 (2020)。
12. Albert, B. A. 等。深度神经网络预测 I 类主要组织相容性复合体表位呈递, 并采用迁移学习评估新表位的免疫原性。《自然·机器学习》5,861–872 (2023)。
13. Chu, Y. 等。一种基于变换器的模型, 用于预测肽–HLA I 类分子结合能力, 并优化用于疫苗设计的突变肽。*Nat. Mach. Intell.* 4,300–311 (2022)。
14. Strazar, M. 等。通过 HLA-II 免疫肽组分析结合深度学习, 揭示抗原性的特征, 为抗原发现提供依据。《Immunity》56,1681–1698.e13 (2023)。
15. Meysman, P. 等。T 细胞受体表位预测问题的解决方案基准研究: IMMREP22 研讨会报告。《免疫信息学》(Amst.) 9,100024 (2023)。
16. Nielsen, M. 等。IMMREP23 TCR-表位预测挑战的经验总结。《免疫信息学》(Amst.) 16,100045 (2024)。
17. Lu, Y. 等。预测 TCR-表位结合识别能力的计算方法评估。《自然·方法》23,248–259 (2026)。
18. Montemurro, A. 等。NetTCR-2.0 利用成对的 TCR α 与 β 序列数据, 可实现 TCR-肽段结合能力的精准预测。Commun. Biol. 4,1060 (2021)。
19. Jensen, M. F. & Nielsen, M. NetTCR 2.2 —— 通过结合泛特异性与肽段特异性训练策略、损失函数缩放以及序列相似性整合, 提升 TCR 特异性预测性能。eLife 12, RP93934 (2024)。
20. Lu, T. 等。基于深度学习的 T 细胞受体抗原结合特异性预测。《自然·机器学习》3,864–875 (2021)。
21. Gao, Y. 等。用于 T 细胞受体–抗原结合识别的全肽元学习。《自然·机器学习》5,236–249 (2023)。
22. Que, J. 等。利用图卷积网络在原子水平上识别 T 细胞抗原。《自然·通讯》16,5171 (2025)。
23. Zhang, Y. 等。基于表位锚定的对比迁移学习: 用于配对 CD8+ T 细胞受体–抗原识别。《自然·机器学习》6,1344–1358 (2024)。
24. Croce, G. 等。基于深度学习的 TCR-表位相互作用预测揭示了双 α T 细胞中的表位特异性链。Nat. Commun. 15,3211 (2024)。
25. Fast, E., Dhar, M. & Chen, B. tapir: 用于预测罕见及新型靶点的 aT 细胞受体语言模型。bioRxiv <https://doi.org/10.1101/2023.09.12.557285>(2023)。
26. Li, X., Sun, C., Huang, W., Wang, Y. & Ma, B. SageTCR: 一种基于结构的模型, 整合残基级与原子级表征, 以提升 TCR-pMHC 结合预测性能。Brief. Bioinform. 26, bbaf496 (2025)。
27. Deleuran, S. N. & Nielsen, M. NetTCR-struc: 一种基于结构的 TCR-pMHC 相互作用预测方法。Front. Immunol. 16,1616328 (2025)。
28. Ge, J. 等。TRAP: 一种基于对比学习的增强框架, 用于实现鲁棒性更强的 TCR-pMHC 结合预测, 并提升其泛化能力。Chem. Sci. 16, 9881–9894 (2025)。
29. Slone, J. K., Conev, A., Rigo, M. M., Reuben, A. & Kavraki, L. E. 基于图神经网络从结构预测 TCRpMHC 结合特异性。IEEE Trans. Comput. Biol. Bioinform. 22,171–179 (2025)。
30. Slone, J. K. 等。STAG-LLM: 利用蛋白质语言模型与计算生成的三维结构预测TCR-pHLA结合能力。Comput. Struct. Biotechnol. J. 27,3885–3896 (2025)。
31. Kawashima, S. & Kanehisa, M. AAindex: 氨基酸索引数据库。Nucleic Acids Res. 28,374 (2000)。
32. Lin, Z. 等。利用语言模型进行原子级蛋白质结构的进化尺度预测。《科学》杂志 379,1123–1130 (2023)。
33. Elnaggar, A. 等。ProtTrans:通过自监督学习探索生命语言。IEEE Trans. Pattern Anal. Mach. Intell. 44,7112–7127 (2022)。
34. Garcia Satorras, V., Hoogeboom, E. & Welling, M. E. (n) 等变图神经网络。第38届国际机器学习会议论文集 PMLR 139,9323–9332 (2021)。
35. Kim, J.-H., Jun, J. & Zhang, B.-T. 双线性注意力网络。载于《第32届神经信息处理系统国际会议论文集》第1571–1581页 (Curran Associates Inc., Red Hook, NY, USA, 2018) 。
36. Wells, D. K. 等。通过联盟研究策略揭示的肿瘤表位免疫原性关键参数可提升新抗原预测效能。《Cell》183,818–834.e13 (2020)。
37. Kosaloglu-Yalcin 及合作者。《癌症表位数据库与分析资源》(cedar)。《核酸研究》51, D845–D852 (2023)。
38. Minervina, A. A. 等。SARS-CoV-2 抗原暴露史可塑造记忆性 CD8+ T 细胞的表型与特异性。《自然·免疫学》23,781–790 (2022)。
39. Dens, C., Laukens, K., Bittremieux, W. & Meysman, P. T 细胞表位特异性挑战中负向数据偏倚的陷阱。《自然·机器学习》5,1060–1062 (2023)。
40. Vita, R. 等。免疫表位数据库 (IEDB): 2024 年更新版。《核酸研究》53, D436–D443 (2025)。
41. Shugay, M. 等。VDJdb: 一个经过人工筛选的、包含已知抗原特异性的 T 细胞受体序列数据库。Nucleic Acids Res 46, D419–D427 (2018)。
42. Povlsen, H. R. 等。通过单细胞测序数据的驱动式过滤优化 T 细胞受体抗原配对。《Elife》12, e81810 (2023)。
43. Kim, S. P. 等。采用自体肿瘤浸润淋巴细胞及靶向人类实体瘤常见 p53 新抗原的 T 细胞受体工程化 T 细胞的过继性细胞疗法。《Cancer Immunol. Res.》10,932–946 (2022)。
44. Yang, X. 等。自身免疫相关 T 细胞受体可识别 HLA-B*27 结合的肽段。《自然》杂志 612,771–777 (2022)。
45. Thompson, K. N. 等。肠道微生物组的改变揭示了不同炎症性关节炎表型中关键类群及代谢通路的作用。《科学·转化医学》15, eabn 4722 (2023)。
46. Sternes, P. R. 等。强直性脊柱炎与炎症性肠病患者肠道微生物组的显著差异提示其在发病机制中发挥不同作用, 且与疾病活动度相关。《Arthritis Res. Ther.》24,163 (2022)。
47. Delgado, L. F. & Andersson, A. F. 评估用于生物群落特异性基因目录的宏基因组组装方法。《Microbiome》第 10 卷, 第 72 页 (2022) 。
48. Franzosa, E. A. 等。炎症性肠病中肠道微生物组的结构与代谢活性。*Nat. Microbiol.* 4,293–305 (2019)。
49. Gevers, D. 等。新发克罗恩病患者的未接受过治疗的微生物组研究。《Cell Host Microbe》15,382–392 (2014)。
50. Hall, A. B. 等。在炎症性肠病患者中富集的一种新型 *Ruminococcus gnavus* 进化枝。*Genome Med* 9,103 (2017)。
51. Mehta, R. S. 等。成年男性队列中人类粪便微生物组的稳定性。《自然·微生物学》3,347–355 (2018)。
52. Cunningham-Oakes, E. 等。通过对 1000 例人类腹泻样本进行宏基因组与宏转录组测序,提升肠道传染病诊断效能。Genome Med 17,55 (2025)。
53. Adams, J. J. 等。T 细胞受体信号传导受肽-主要组织相容性复合体对接几何结构的限制。《Immunity》35,681–693 (2011)。
54. Abramson, J. 等。利用 AlphaFold 3 实现生物分子相互作用的精准结

55. Wang, N. 等。深度肽段识别谱分析可解析 TCR 特异性，并助力发现疾病相关抗原。《自然·生物技术》(2026)。
56. Cao, K. uhlerlab/strimap-tools: strimap-tools 首次发布 (版本 v 1.0.0) [计 算 机 软 件]。Zenodo <https://doi.org/10.5281/zenodo.21925295>(2026)。

致谢

我们感谢 Q. Gong、C. Li、F. Chen、C. Krishna、W. Jin、B. Shao、L. Yuan、X. Zhang、J. Zhang、R. Zhang 及 S. Liu 在方法设计方面提供的宝贵讨论。同时，我们感谢 E. Forte、T. Reimels 及 H. Kang 对本文稿提供的有益讨论与反馈。

作者贡献

R.J.X. 与 C. U. 负责本研究的整体指导；K.C.、M.S.、E. M. B. 及 P. N. U. N. 共同负责本研究的构思；K.C. 负责模型构建；K.C.、M-M. P. 及 J. P. 负责数据分析；D. B.G. 与 R. L. 负责 AS 实验的设计；R. L. 负责 AS 实验的实施；O. A. 与 D. B.G. 提供了关键性见解。

K.C.、R.L.、M.S.、M-M.P.、O.A.、D.B.G.、C.U. 及 R.J.X. 共同撰写了本手稿。

资金

K.C. 部分研究经费来自阿斯利康公司提供的奖学金、麻省理工学院与哈佛大学联合设立的埃里克与温迪·施密特中心，以及美国国立卫生研究院 (DK 135492)。C. U. 部分研究经费来自 NCCIH /NIH (1DP2AT012345)、NIDDK /NIH (5RC2DK135492-02)、ONR (N00014-24-1-2687)、美国能源部 (DE-SC 0023187) 以及麻省理工学院机器学习与健康联合诊所 (J-Clinic for Machine Learning and Health)。

R.J.X. 的研究工作得到了美国国立卫生研究院 (DK043351、AI110495 及 DK 135492) 以及 The Leona M. and Harry B. Helmsley Charitable Trust 的资助。

利益冲突

R.J.X. 是 Convergence Bio 的联合创始人，同时担任 Nestlé 与 Magnet BioMedicine 的科学顾问委员会成员，以及 MoonLake Immunotherapeutics 的董事会董事。C. U. 担任 Immunai 与 Relation Therapeutics 科学顾问委员会成员，并曾获得阿斯利康 (AstraZeneca) 与 Janssen Pharmaceuticals 的资助性研究支持。上述机构均未参与本研究。其余作者声明无利益冲突。

补充信息

补充信息：在线版本包含可在<https://doi.org/10.1038/s41467-026-78063-1>处获取的补充材料。

通讯及材料索取事宜，请联系 Caroline Uhler 或 Ramnik J. Xavier。

关于同行评审信息：《Nature Communications》谨向 Mate Manczinger 及其他匿名评审人对本研究的评审工作做出贡献表示感谢。同行评审文件已可供获取。

重印及授权相关信息请参阅以下网址：

<http://www.nature.com/reprints>

出版方声明：Springer Nature 对于已发表地图中的司法管辖权主张及机构隶属关系保持中立立场。

开放获取：本文采用“知识共享 署名-非商业性使用-禁止演绎 4.0 国际许可协议”授权，该许可允许在任何媒介或格式下进行非商业性使用、分享、分发及复制，但您须向原作者及来源提供适当署名，提供指向本《知识共享许可协议》的链接，并标明您是否对许可材料进行了修改。根据本许可协议，您无权分享基于本文或其部分内容改编的衍生材料。本文中的图像或其他第三方材料均包含在本文的《知识共享许可协议》范围内，除非相关材料在署名栏中另有说明。若某材料未包含在本文的《知识共享许可协议》中，且您的预期用途不受法定法规许可或超出许可范围，则您需直接向版权持有人获取许可。如需查看本许可协议全文，请访问<http://creativecommons.org/licenses/by-nc-nd/4.0/>。

© 作者 2026

本篇已发表文章将提前分享，以便您更快获取最新研究成果。该文章可供引用，并拥有永久有效的 DOI 标识。最终修订版将自动取代本版本。