利用 AlphaFold 实现高精度蛋白质结构预测

https://doi.org/10.1038/s41586-021-03819-2

收稿日期：2021年5月11日

接收日期：2021年7月12日

在线发布日期：2021年7月15日

开放获取

检查更新

John Jumper [1,4]✉、Richard Evans [1,4]、Alexander Pritzel [1,4]、Tim Green [1,4]、Michael Figurnov [1,4]、Olaf Ronneberger [1,4]、Kathryn Tunyasuvunakool [1,4]、Russ Bates [1,4]、Augustin Zidek [1,4]、Anna Potapenko [1,4]、Alex Bridgland [1,4]、Clemens Meyer [1,4]、Simon A. A. Kohl [1,4]、Andrew J. Ballard [1,4]、Andrew Cowie [1,4]、Bernardino Romera-Paredes [1,4]、Stanislav Nikolov [1,4]、Rishub Jain [1,4]、Jonas Adler [1]、Trevor Back [1]、Stig Petersen [1]、David Reiman [1]、Ellen Clancy [1]、Michal Zielinski [1]、Martin Steinegger [2,3]、Michalina Pacholska [1]、Tamas Berghammer [1]、Sebastian Bodenstein [1]、David Silver [1]、Oriol Vinyals [1]、Andrew W. 第一作者[1]、Koray Kavukcuoglu [1]、Pushmeet Kohli [1]及 Demis Hassabis [1,4]✉

蛋白质对生命至关重要，而解析其结构有助于从机制层面理解其功能。通过海量的实验研究[1–4]，已有约10万种独特蛋白质的结构被解析[5]，但这仅占已知数十亿种蛋白质序列的一小部分[6,7]。单种蛋白质结构解析所需耗时数月乃至数年，这一过程已成为结构研究覆盖率的瓶颈。亟需精准的计算方法来填补这一空白，推动大规模结构生物信息学发展。仅凭氨基酸序列预测蛋白质可能采取的三维结构——即“蛋白质折叠问题”中的结构预测环节[8]——五十余年来始终是重要的开放性研究课题[9]。尽管近期取得进展[10–14]，现有方法仍远未达到原子级精度，尤其在缺乏同源结构时更为明显。本文首次提出一种计算方法，即使在缺乏已知相似结构的情况下，仍能以原子级精度规律性地预测蛋白质结构。我们在极具挑战性的第 14 届蛋白质结构预测关键评估（CASP14）[15]中，对基于该技术的全新重构版神经网络模型 AlphaFold 进行了验证，结果表明：在大多数案例中，其预测精度与实验结构相当，且显著优于其他方法。AlphaFold 最新版本的底层支撑是一种创新的机器学习方法，该方法将关于蛋白质结构的物理与生物学知识，以及多序列比对信息，整合至深度学习算法的设计之中。

用于预测的计算方法的发展
基于蛋白质序列推演的三维（3D）蛋白质结构
已沿着两条相辅相成的路径推进，这两条路径分别聚焦于
物理相互作用或演化历史。物理相互作用。
该计划深度整合了我们对分子层面的认知。
为前者的热力学或动力学模拟提供驱动力。
蛋白质物理学[16]或其统计近似方法[17]。尽管在理论方面
尽管这一方法极具吸引力，但它已被证明对……而言极具挑战性。
即使是中等大小的蛋白质，也因计算上的困难而难以处理
分子模拟中蛋白质稳定性的环境依赖性
以及构建足够精确的蛋白质模型所面临的困难
物理学。这一演化方案提供了一种替代方案。
近年来，关于蛋白质结构约束条件的研究逐渐兴起
基于蛋白质进化史的生物信息学分析，
与已解析结构的同源性[18,19]以及成对进化相关性。
[20–24]。这一生物信息学方法已从以下方面受益匪浅：
已提交实验蛋白质结构的数量持续稳步增长
蛋白质数据库（PDB）[5]，以及基因组测序技术的迅猛发展
以及用于解释的深度学习技术的快速发展
这些相关性。尽管取得了这些进展，当代物理学领域
而基于进化历史的分析方法所产生的预测结果
在大多数情况下，其精度仍远低于实验精度。
其紧密同源物尚未通过实验手段解析，而这一点已
限制了它们在众多生物学应用中的实用性。

在本研究中，我们开发了据我们所知首个计算模型。
一种能够将蛋白质结构预测精度提升至接近实验水平的方法
在大多数情况下具有较高精度。我们所采用的 AlphaFold 神经网络
该开发项目已纳入 CASP14 评估（2020 年 5 月至 7 月）；
以团队名称“AlphaFold2”提交，且内容截然不同
来自我们 CASP13 AlphaFold 系统的模型[10]）。CASP 评估结果为
每两年利用近期解析出的尚未被利用的结构进行一次
已存入 PDB 或公开披露，因此该测试为盲法测试。

[1]DeepMind，英国伦敦。[2]首尔大学生物科学学院，韩国首尔。[3]首尔大学人工智能研究所，韩国首尔。[4]以下作者贡献相同：John Jumper、Richard Evans、Alexander Pritzel、Tim Green、Michael Figurnov、Olaf Ronneberger、Kathryn Tunyasuvunakool、Russ Bates、Augustin Zidek、Anna Potapenko、Alex Bridgland、Clemens Meyer、Simon A. A. Kohl、Andrew J. Ballard、Andrew Cowie、Bernardino Romera-Paredes、Stanislav Nikolov、Rishub Jain、Demis Hassabis。
✉电子邮箱：jumper@deepmind.com；dhcontact@deepmind.com

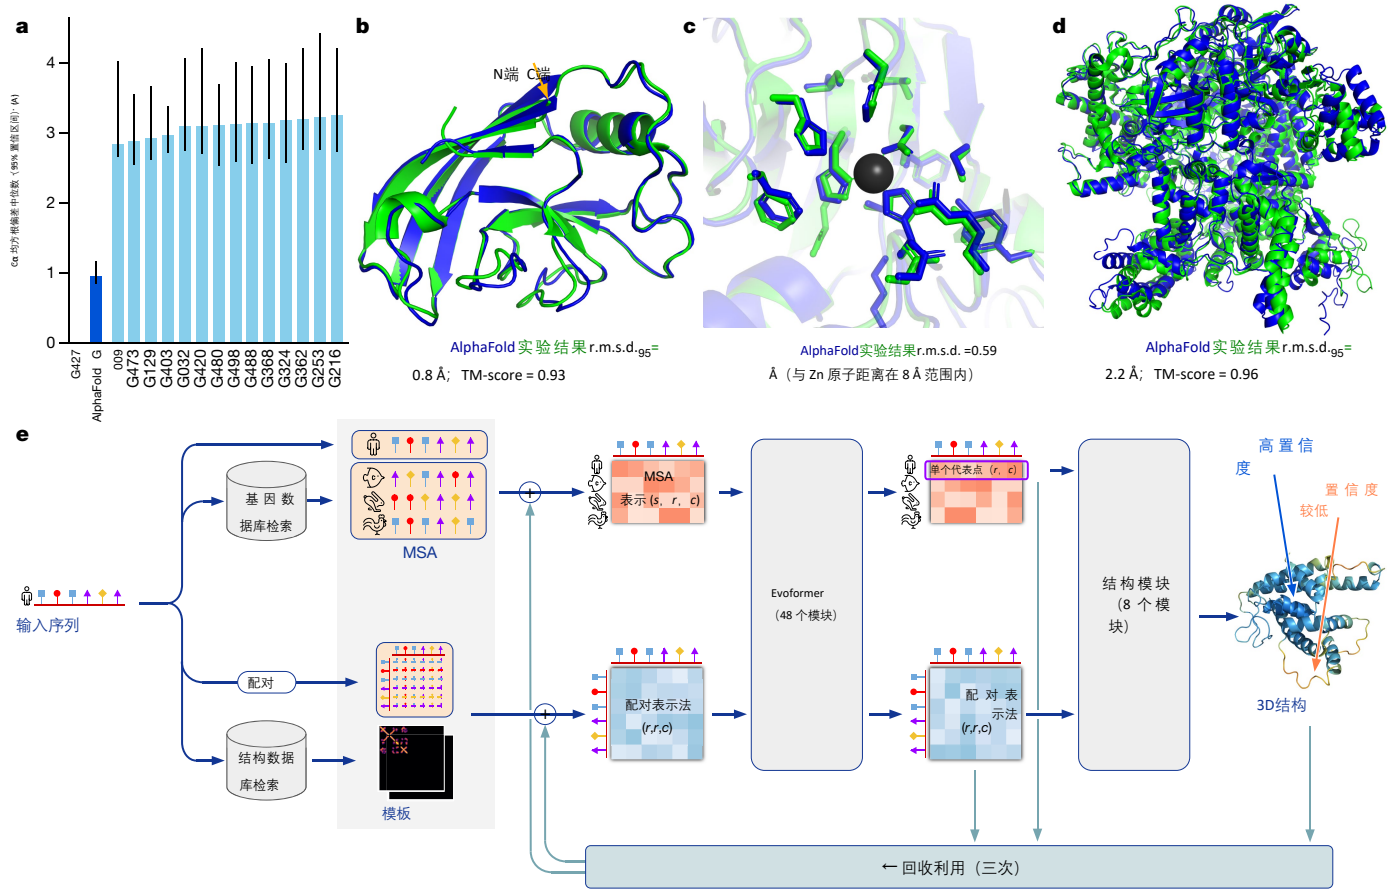


图 1 | AlphaFold 可生成高度精确的结构。a，AlphaFold 在 CASP14 数据集（*n*= 87 个蛋白质结构域）上的性能，以排名前 15 位的结果（共 146 个参赛结果）为参照，组编号对应 CASP 为参赛者分配的编号。数据为中位数及该中位数的 95% 置信区间，基于 10,000 个自助抽样样本估算得出。**b**，我们对 CASP14 目标结构 T1049（PDB 6Y4F，蓝色）的预测结果与真实（实验）结构（绿色）的对比。晶体结构中 C 末端的四个残基为*B*-因子异常值，未予显示。**c**，CASP14 目标结构 T1056（PDB 6YJ1）一个预测效果良好的锌结合位点示例（AlphaFold 能准确预测侧链，尽管它并不直接预测锌离子）。**d**，CASP 针对 T1044（PDB 6VR4）——一个由 2,180 个残基组成的单链——进行了预测，且其结构域堆积准确（该预测是在 CASP 使用 AlphaFold 且未进行干预的情况下完成的）。**e**，模型架构。箭头表示本文所述各组件之间的信息流。阵列形状以括号内标注：s 表示序列数（N_{seq}，见正文）；*r*表示残基数（N_{res}，见正文）；*c*表示通道数。

对于所采用的方法而言，它长期以来一直是评估结构预测准确性的金标准[25,26]。

在CASP14评估中，AlphaFold 的结构精度远高于其他竞争方法。AlphaFold 的结构主链精度中位数为 0.96 Å RMSD $_{95}$（95% 残基覆盖率下的 Cα 原子均方根偏差）（95% 置信区间 = 0.85–1.16 Å），而次优方法的主链精度中位数为 2.8 Å RMSD $_{95}$（95% 置信区间 = 2.7–4.0 Å）（基于 CASP 结构域测定；主链精度参见图1a，全原子精度参见补充图 14）。作为该精度的参照点，碳原子的宽度约为 1.4 Å。除了能生成高度精确的结构域模型（图1b）外，当主链精度极高时，AlphaFold 还能生成高度精确的侧链（图1c）；即使存在优质模板时，其性能仍显著优于基于模板的方法。AlphaFold 的全原子精度为 1.5 Å RMSD $_{95}$（95% 置信区间 = 1.2–1.6 Å），而最佳替代方法的精度为 3.5 Å RMSD $_{95}$（95% 置信区间 = 3.1–4.2 Å）。本方法可适用于极长蛋白质，并能准确识别结构域及进行结构域堆积分析（参见图1d，其中展示了对一个不含结构同源物的 2,180 个残基蛋白质的预测结果）。最后，该模型可提供每个残基级别的精确可靠性评估，从而确保这些预测结果可被可靠地应用。

我们在图2b中证明，AlphaFold在CASP14任务中展现的高精度同样适用于近期发布的海量PDB结构样本；在该数据集中，所有结构均于我们的训练数据截止点后提交至PDB，并均以完整链形式进行分析（详见方法部分、附图15及附表6）。此外，当主链预测准确时，我们观察到侧链预测亦具有高精度（图2b）；同时，我们证实本研究的置信度度量指标——预测局部距离差异测试（pLDDT）——能可靠地预测对应预测结果的Cα局部距离差异测试（lDDT-Cα）精度（图2c）。我们还发现，全局叠加度量指标模板建模分数（TM-score）[27]亦可被准确估算（图2d）。总体而言，这些分析结果验证了：AlphaFold在CASP14蛋白质数据集上表现出的高精度与高可靠性，同样适用于未经人工整理的近期PDB提交数据集——这与预期相符（关于该高精度特性可推广至新折叠结构的验证，详见补充方法1.15及附图11）。

AlphaFold 网络

AlphaFold 通过整合新型神经网络架构，以及基于蛋白质结构进化、物理与几何约束设计的训练流程，显著提升了结构预测的准确性。具体而言，我们提出了以下创新：一种可将多序列比对（MSA）与成对特征联合嵌入的新型架构；一种可实现精准端到端结构预测的新型输出表示及相应损失函数；以及一种新型等变注意力机制。

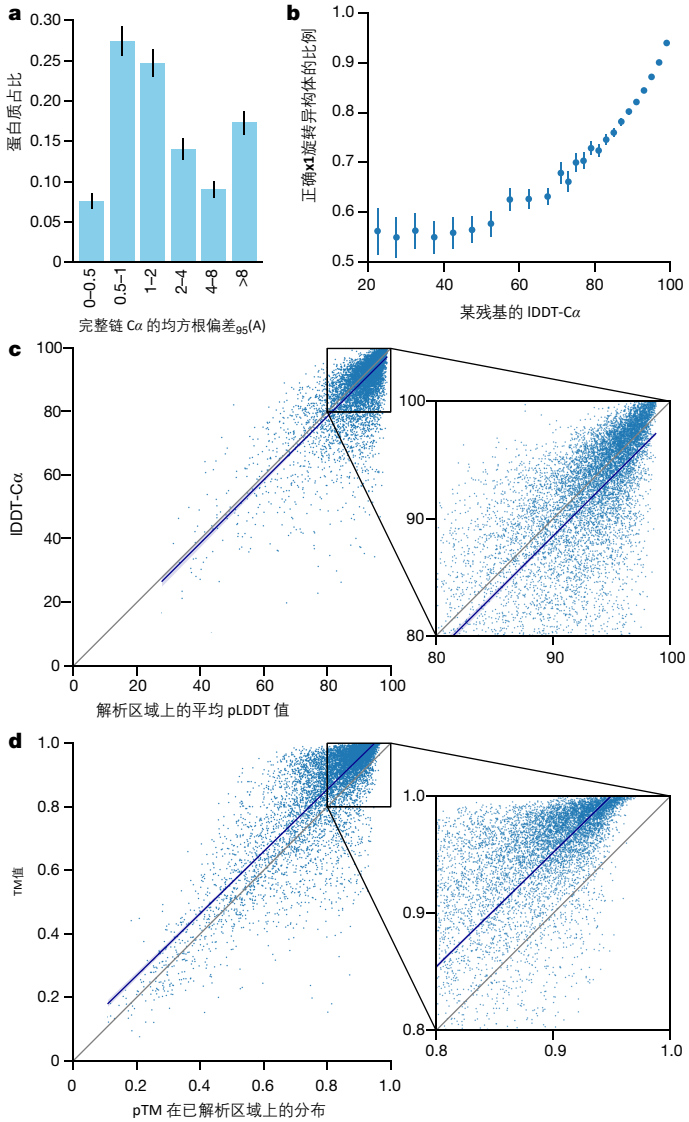


图 2 | AlphaFold 对近期 PDB 结构的预测准确率。所分析的结构均比训练集中任何结构的年代更晚。为减少冗余，已施加进一步过滤处理（详见“方法”部分）。**a**，主链原子分布直方图

完整链的均方根偏差（Cα 95%覆盖率下的均方根偏差）。误差条表示95%置信区间（遵循泊松分布）。本数据集已排除那些拥有模板（通过hmmsearch识别）、且覆盖超过1%链长区域时序列一致性超过40%的蛋白质（*n*=3,144条蛋白质链）至训练集。整体中位数为1.46 Å（95%置信区间=1.40–1.56 Å）。需注意该指标对结构域堆积及结构域精度高度敏感；对于堆积情况不确定或存在堆积错误的某些链，预期会出现较大的均方根偏差。**b**，主链精度与侧链精度之间的相关性。筛选条件为：包含至少一个观测到的侧链且分辨率优于2.5 Å的结构（*n*=5,317条蛋白质链）；侧链进一步筛选标准为*B*-因子<30 Å²。若预测的扭转角在40°以内，则该旋转异构体被判定为正确。每个数据点代表一个lDDT-Cα值区间，当lDDT-Cα值大于70时，点宽为2个单位；否则点宽为5个单位。数据点代表平均准确率；误差条表示基于每个残基计算的均值的 95% 置信区间（Student *t*检验）。**c**，链上置信分数与真实准确率的对比。最小二乘线性拟合结果为：lDDT-Cα = 0.997 × pLDDT − 1.17（皮尔逊相关系数）

r= 0.76）。*n*= 10,795 条蛋白质链。线性拟合的阴影区域表示基于 10,000 个 Bootstrap 样本估算的 95% 置信区间。在配套论文[39]中，还提供了关于 pLDDT 作为置信度度量指标的额外可靠性量化分析。**d**，pTM 与完整链 TM-score 的相关性。最小二乘线性拟合结果为：TM-score = 0.98 × pTM + 0.07（皮尔逊相关系数 r = 0.85）。*n*= 10,795 条蛋白质链。线性拟合的阴影区域表示基于 10,000 个 Bootstrap 样本估算的 95% 置信区间。

架构设计包括：利用中间损失实现预测结果的迭代优化；采用掩码 MSA 损失与结构特征联合训练；以及通过自蒸馏与精度自估计，从未标注的蛋白质序列中学习。

AlphaFold 网络利用给定的蛋白质一级氨基酸序列及其同源蛋白的比对序列作为输入，直接预测该蛋白质所有重原子的三维坐标（图1e；关于输入数据的详细信息，包括数据库选用、MSA 构建及模板使用，请参阅“方法”部分）。下文将对核心思路与关键组件进行阐述；完整网络架构及训练流程详见“补充方法”部分。

该网络包含两个主要阶段。首先，网络主干通过重复堆叠一个我们称为Evoformer的新型神经网络模块来处理输入，从而生成an $N_{seq} \times N_{res}$ 数组（N_{seq}表示序列数；N_{res}表示残基数），该数组代表经处理的MSA；以及an $N_{res} \times N_{res}$数组，该数组代表残基对。MSA表征的初始化采用原始MSA（但关于处理极深MSA的具体细节，请参阅补充方法 1.2.7）。Evoformer模块包含若干基于注意力机制及非基于注意力机制的组件。我们在《解析神经网络》章节中提供的证据表明：在Evoformer模块内部，一个具体的结构假设会早期形成，并持续被优化完善。Evoformer模块的核心创新在于引入了新的机制，用于在MSA与残基对表征之间交换信息，从而实现对空间与进化关系的直接推理。

在网络主干之后是结构模块，该模块为蛋白质的每个残基引入以旋转和平移形式表达的显式三维结构（全局刚体框架）。这些表征初始化为平凡状态——所有旋转均设为恒等变换，所有位置均设为原点；但随后会迅速构建并优化出具有精确原子细节的高精度蛋白质结构。本模块的核心创新包括：打破链式结构限制，从而实现对结构所有部分的同步局部优化；引入一种新的等价变换器，使网络能够隐式地推演未显式表征的侧链原子；以及设置一个损失项，该项对残基取向的正确性赋予显著权重。无论是在结构模块内，还是在整个网络中，我们都通过反复将最终损失函数应用于输出结果，并将这些输出结果递归地输入至相同模块，进一步强化了迭代优化理念。利用整个网络进行的迭代优化（我们将其称为“循环利用”，该方法与计算机视觉领域的相关研究[28,29]相关）可在仅需少量额外训练时间的情况下显著提升模型精度（详见补充方法 1.8）。

Evoformer

该网络构建模块——命名为 Evo former（图1e、3a）——的核心原理是将蛋白质结构预测视为三维空间中的图推理问题，其中图的边由邻近残基定义。配对表示法的元素编码了残基间关系的信息（图3b）；MSA 表示法的列向量编码输入序列中的单个残基，而行向量则代表这些残基出现的序列。在此框架下，我们为每个模块定义若干更新操作，并将这些不同更新操作依次应用于各模块中。

MSA 表示法通过逐元素外积对配对表示法进行更新，随后沿 MSA 序列维度求和。与先前研究[30]不同，该操作在每个块内执行，而非仅在网络中执行一次，从而实现了从动态演化的 MSA 表示法到配对表示法的持续信息交互。

在配对表示法中，存在两种不同的更新模式，这两种模式均源于对配对一致性要求的考量。

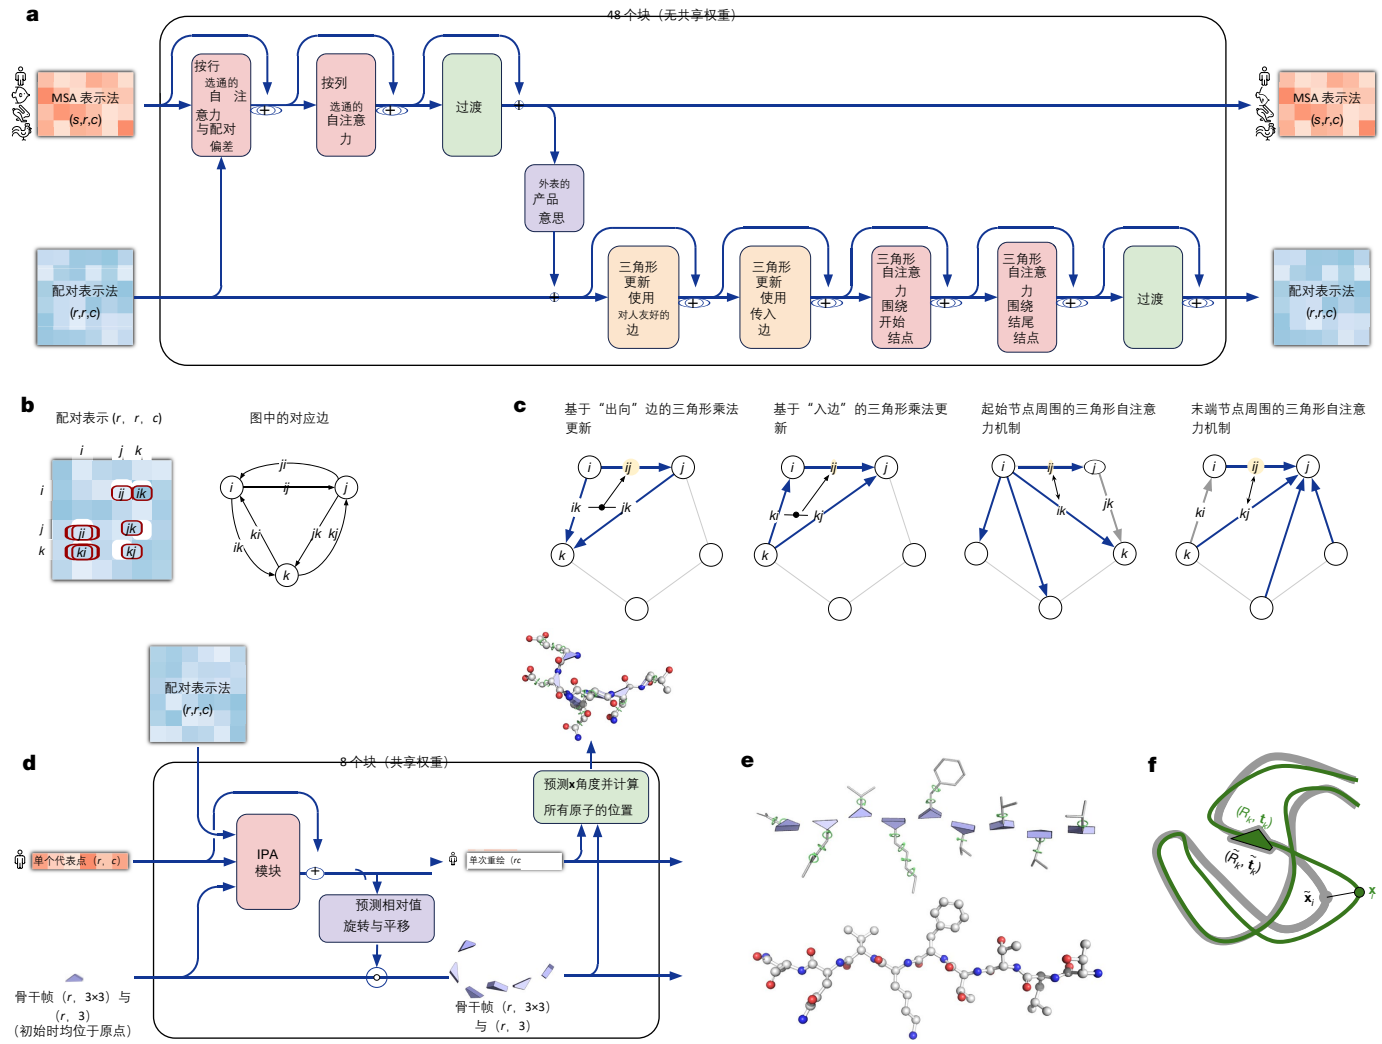


图 3 | 架构细节。a，Evoformer 模块。箭头指示信息流方向，阵列形状标注于括号内。**b**，将配对表示解释为图结构中的有向边。**c**，三角形乘法更新与三角形自注意力机制。圆形代表残基，配对表示中的条目以有向边形式呈现，且每个子图中被更新的边均为 ij。**d**，包含不变点注意力（IPA）的结构模块。模块。单一表示形式为 MSA 表示形式中第一行的副本。**e**，残基表示法：将每个残基表示为一个主链的自由漂浮刚体（蓝色三角形）及侧链的χ角（绿色圆圈）。对应的原子结构如下图所示。**f**：帧对齐点误差（FAPE）。绿色：预测结构；灰色：真实结构；$(R_k, \mathbf{t}_k)$：帧；$\mathbf{x}_i$：原子位置。

为了使氨基酸的成对描述能够被表示为单个三维结构，必须满足诸多约束条件，其中包括距离上的三角不等式。基于这一直觉，我们将成对表示的更新操作基于涉及三个不同节点的边构成的三角形进行组织（图3c）。具体而言，我们在轴向注意力机制中[31]引入一个额外的对数几率偏置，以涵盖该三角形中的“缺失边”；同时，我们定义了一种非注意力更新操作——“三角形乘法更新”，该操作利用两条边来更新缺失的第三条边（详见补充方法 1.6.5）。三角形乘法更新最初是作为注意力机制的一种更具对称性且计算成本更低的替代方案而开发的；仅使用注意力机制或仅使用乘法更新的网络均能生成高精度结构，但将两种更新方式结合使用可获得更高的精度。

在 MSA 表示中引入轴向注意力机制的 Wealsousea 变体。在 MSA 的序列级注意力计算过程中，我们将来自配对堆栈的额外 logits 投影至 MSA 注意力机制上。这一机制通过从配对表示向 MSA 表示提供信息流，从而优化该循环过程，确保整个 Evoformer 模块能够充分融合配对表示与 MSA 表示之间的信息，并为结构模块内的结构生成做好准备。

端到端结构预测

结构模块（图3d）基于一个具体的三维骨架结构运行，该结构采用配对表示法以及来自主干结构的MSA表示法中的原始序列行（单一路径表示）。该三维骨架结构被表示as N_{res}独立的旋转与平移操作，每个操作均基于全局坐标系（残基坐标系）进行（图3e）。这些旋转与平移操作——表征N-Cα-C原子的几何构型——优先优化蛋白质骨架的取向，从而使每个残基侧链的位置在该坐标系内受到高度约束。相反，肽键几何构型则完全不受约束；在应用该结构模块时，可观察到该网络结构频繁违反链约束条件，而解除此约束后，即可对链的所有局部区域进行精细优化，且无需解决复杂的环闭合问题。在微调阶段，通过引入违反损失项来促进肽键几何构型的合规性。肽键几何构型的精确约束仅能在使用Amber [32]力场进行结构预测后弛豫时实现。经验表明，这种最终弛豫过程并不会提升模型在全局距离测试（GDT）[33]或

lDDT-Cα [34]中的预测精度，但确实能消除干扰性的立体化学违规，且不会牺牲预测精度。

残基气体表示通过两个阶段进行迭代更新（图3d）。首先，采用一种我们称为“不变点注意力”（IPA）的几何感知注意力操作，在不改变三维位置的前提下，更新an N_{res}个神经激活值集合（单一表示）；随后，利用更新后的激活值对残基气体执行一种等变更新操作。IPA 操作将每个常规注意力查询向量、键向量及值向量与在每个残基局部坐标系中生成的三维点相结合，使得最终输出值对全局旋转与平移具有不变性（详见“方法”部分中的“IPA”小节）。这些三维查询向量与键向量还赋予注意力机制强烈的空间/局部性偏好，这恰好契合蛋白质结构的迭代优化需求。在完成每次注意力操作及逐元素转换块运算后，该模块会为每个主链框架的旋转与平移计算更新量。将这些更新量应用于每个残基的局部坐标系中，使得整个注意力与更新模块对残基气体构成一个等变操作。

侧链χ角度的预测以及结构最终每个残基的精度（pLDDT）均通过在网络最终激活值上构建小型残基级网络来计算。TM-score（pTM）的估计值则源自一对误差预测，该预测是通过从最终配对表示进行线性投影而获得。最终损失函数（我们称之为帧对齐点误差（FAPE）（图3f））将预测的原子位置与真实位置在多种不同对齐方式下进行比对。对于每种对齐方式——即将预测帧（R_k, $\mathbf{t}_k$）与对应真实帧对齐——我们pute the distance of all predicted atom positions $\mathbf{x}_i$与真实原子位置之间的距离。由此得到的resulting $N_{frames} \times N_{atoms}$个距离值均通过钳位L [1]损失函数进行惩罚。这种机制为原子相对于每个残基的局部帧保持正确性提供了强导向，从而确保原子在侧链相互作用中保持正确性，同时也为AlphaFold提供了手性预测的主要依据（见补充方法1.9.3及补充图9）。

使用带标签与不带标签数据进行训练

AlphaFold 架构仅通过 PDB 数据上的监督学习即可达到高精度，但我们仍可采用一种与“含噪声学生自蒸馏”[35]类似的方法进一步提升精度（图4a）。具体流程如下：我们利用已训练好的网络，对来自 Uniclust 30 [36]的约 350,000 条多样化序列进行结构预测，并构建一个经过筛选的高置信度子集的新预测结构数据集；随后，我们再次从零开始训练同一架构，将 PDB 数据与这一新预测结构数据集共同用作训练数据——其中采用的裁剪与 MSA 子采样等多种数据增强策略，使得网络难以复现先前预测的结构。这一自蒸馏流程有效利用了未标注的序列数据，显著提升了最终网络的预测精度。

此外，我们在 MSA 中随机掩码或突变单个残基，并采用基于 Transformer 的双向编码器表征（BERT）[37]目标函数，以预测 MSA 序列中被掩码的片段。该目标函数促使网络学习解读系统发育与共变关系，而无需将特定相关性统计量硬编码至特征中。BERT 目标函数与常规 PDB 结构模型在相同训练样本上联合训练，且不同于近期独立研究[38]中的做法，本方法未进行预训练。

解读神经网络

为探究 AlphaFold 如何预测蛋白质结构，我们在网络中的 48 个 Evoformer 模块中，分别训练了一个独立的结构模块，同时保持主网络的所有参数不变（见补充方法 1.14）。结合我们的循环训练阶段，共生成一条包含 192 个中间结构的轨迹——每个完整 Evoformer 模块对应一个中间结构——其中每个中间结构均代表网络在该模块阶段对最可能结构的置信度。令人惊讶的是，生成的轨迹在经过前几个模块后变得异常平滑，这表明 AlphaFold 对结构预测的改进是持续渐进的，直至达到无法再优化的状态（具体精度轨迹参见图4b）。这些轨迹也揭示了网络深度的作用：对于像 SARS-CoV-2 的 ORF8（T1064）这类极具挑战性的蛋白质，网络需经过多层次的二级结构元件搜索与重组，方能最终收敛至一个优质结构；而对于其他蛋白质（如 LmrP，T1024），网络则可在前几层内即找到最终结构。CASP14 对靶标 T1024、T1044、T1064 及 T1091 的结构演化轨迹展示了在多种蛋白质尺寸及复杂条件下，该过程呈现出清晰的迭代构建特征，相关视频详见补充视频 1–4。在补充方法 1.16 及补充图 12、13 中，我们对 AlphaFold 各层生成的注意力图进行了解析。

图 4a 展示了 AlphaFold 各组件的详细消融分析，这些分析证明多种不同机制共同影响着 AlphaFold 的准确性。关于每个消融模型的详细描述、其训练细节、消融结果的深入讨论，以及 MSA 深度对每个消融实

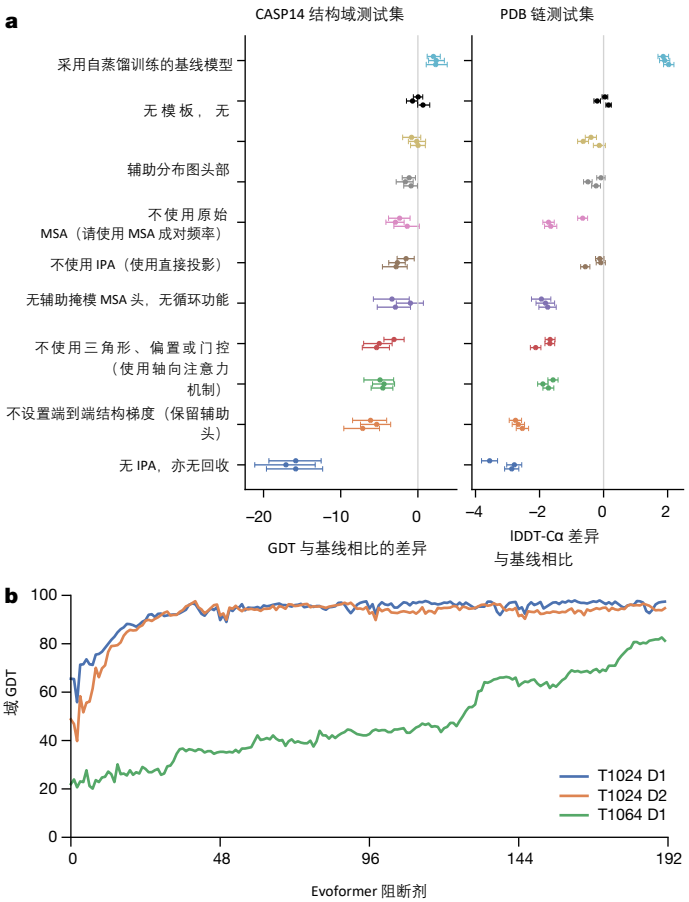


图 4 | 神经网络解析。a，针对两个目标数据集的消融实验结果：CASP14 域数据集（n= 87 个蛋白质域）以及 PDB 测试集——模板覆盖率 ≤30%、序列一致性为 30% 的蛋白质链数据集（n= 2,261 条蛋白质链）。域使用 GDT 评分，链使用 lDDT-Cα 评分。消融结果以与三个基准种子模型平均值的差值形式呈现。均值（点）及 95% 自助法百分位区间（误差条）均基于 10,000 个样本的自助法估计值计算得出。**b**，在 CASP14 目标蛋白 LmrP（T1024）和 Orf8（T1064）上，展示 4 次循环迭代及 48 个 Evoformer 模块的域 GDT 演化轨迹，其中 D1 与 D2 分别对应 CASP 评估中定义的独立域。T1024 的两个域在神经网络早期即获得正确结构，而 T1064 的结构则多次变化，需接近整个神经网络深度才能最终收敛至正确结构。注：48 个 Evoformer 模块各包含一次循环迭代。

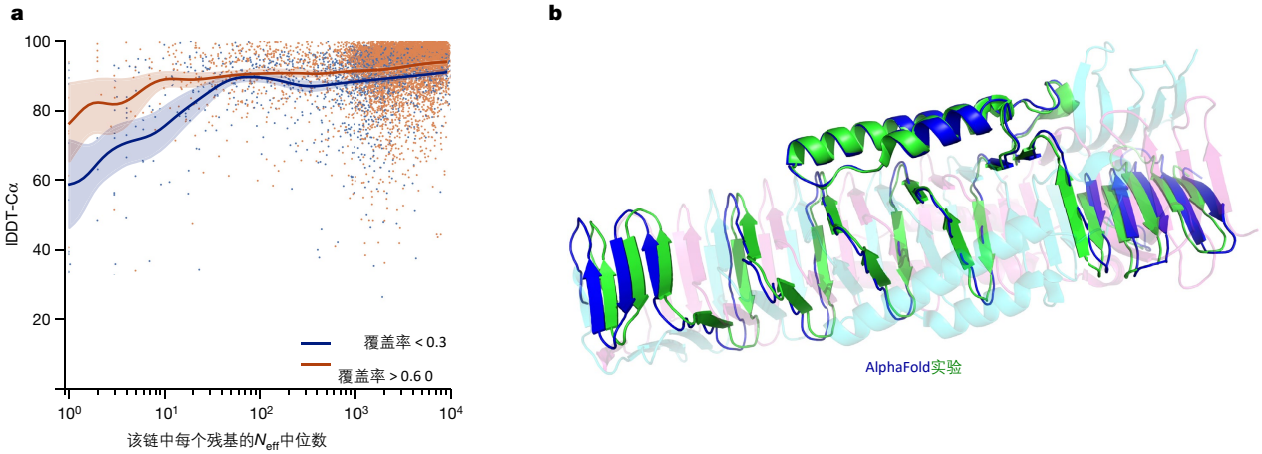


图 5 | MSA 深度与跨链接触的影响。a，基于训练数据截断条件后，从 PDB 中选取冗余度降低的蛋白质数据集，并限定仅包含长程接触中不同异源多聚体链间占比不超过 25% 的蛋白质，所得骨架结构精度（lDDT-Cα）结果。我们进一步根据模板覆盖率在 30% 序列一致性下，将蛋白质分为两类：覆盖链段比例超过 60% 的蛋白质链（n= 6,743）与覆盖链段比例低于 30% 的蛋白质链（n= 1,596）。MSA 深度通过统计 MSA 中每个位点的非缺失残基数（using the N_{eff}加权方案；详见方法部分），再取各残基值的中位数计算得出。曲线通过高斯核平均平滑法获得（窗口大小为 0.2 个单位in $\log_{10}(N_{eff})$）；阴影区域为使用 10,000 个样本进行 bootstrap 抽样后估算的 95% 置信区间。**b**，一个相互缠绕的同源三聚体（PDB 6SK0）在未输入化学计量比信息、仅使用弱模板的情况下仍被准确预测（蓝色为预测结果，绿色为实验数据）。

验的影响，均可在补充方法 1.13 及补充图 10 中找到。

MSA 深度与跨链接触

尽管 AlphaFold 在绝大多数已提交的 PDB 结构中均具有较高的准确率，但我们注意到仍存在一些会影响其准确率或限制该模型适用性的因素。该模型采用多序列比对（MSA），当中位比对深度低于约 30 条序列时，其准确率会显著下降（详见图5a）。我们观察到一种阈值效应：当 MSA 深度超过约 100 条序列时，性能提升幅度较小。我们推测，在神经网络训练初期，MSA 信息有助于粗略地定位正确结构；但将该预测结果进一步优化为高精度模型时，则并不关键依赖 MSA 信息。我们观察到的另一重要局限是：对于链内或同型接触数远少于异型接触数的蛋白质，AlphaFold 的性能明显较弱（更多细节见配套论文[39]）。这种情况常见于大型复合体中的桥接结构域——此类结构域的蛋白质构象几乎完全由与复合体中其他链的相互作用决定。相反，AlphaFold 通常能够对同源聚合物提供高精度预测结果，即使这些聚合物链已显著相互缠绕（图5b）。我们预计，AlphaFold 的相关原理可轻松应用于未来系统中完整异源复合物的预测，从而解决具有大量异源接触位点的蛋白质链的预测难题。

相关工作

蛋白质结构预测领域的发展历程漫长且多元，已有众多综述对此进行了详尽阐述[14,40–43]。尽管将神经网络应用于结构预测已有悠久历史[14,42,43]，但直到近年这些技术才开始切实提升结构预测性能[10,11,44,45]。这些方法有效利用了计算机视觉系统的快速进步[46]——将蛋白质结构预测问题转化为将“进化耦合图谱”[22–24]转换为“蛋白质距离矩阵图谱”，进而将距离预测结果整合至启发式系统中，最终生成三维坐标预测结果。近期已有若干研究致力于直接预测三维坐标[47–50]，但这些方法的准确性仍不及传统的手工构建结构预测流程[51]。与此同时，基于注意力机制的网络在语言处理领域[52]以及近年来在计算机视觉领域[31,53]取得的成功，激发了人们探索基于注意力机制的方法来解析蛋白质序列[54–56]。

讨论

我们在设计 AlphaFold 时所采用的方法论，是将生物信息学方法与物理方法相结合：我们利用物理与几何归纳偏置，构建能够从 PDB 数据中学习的组件，且仅需极少的人工设计特征（例如，AlphaFold 无需氢键评分函数即可有效构建氢键）。由此构建的网络能够从 PDB 中有限的数据中更高效地学习，同时仍能应对结构数据的复杂性与多样性。

特别是，AlphaFold 能够处理物理环境的缺失问题，并在具有挑战性的情况下（例如相互缠绕的同源蛋白，或仅在存在未知血红素基团时才能折叠的蛋白质）生成精确的模型。处理结构条件不充分的能力，对于从 PDB 结构中学习至关重要——因为 PDB 收录了所有已解析结构的完整条件范围。总体而言，AlphaFold 的训练目标是生成最有可能作为 PDB 结构组成部分出现的蛋白质结构。例如，若仅凭序列即可预测特定化学计量比、配体或离子存在，AlphaFold 则更倾向于生成隐式满足这些约束条件的结构。

AlphaFold 已为实验研究界展现出其实用价值，既适用于分子置换研究[57]，也适用于解读低温电子显微镜图谱[58]。此外，由于 AlphaFold 可直接输出蛋白质坐标，其预测耗时从图形处理器（GPU）数分钟至数小时不等，具体取决于蛋白质序列长度（例如：对于含 384 个残基的模型，每模型耗时约 1 个 GPU 分钟；详见“方法”部分）。这为在蛋白质组乃至更广泛尺度上预测蛋白质结构开辟了极具前景的可能性——在配套论文[39]中，我们展示了 AlphaFold 应用于整个人类蛋白质组的实践[39]。

可用基因组测序技术与数据的激增已彻底革新了生物信息学领域，但实验性结构解析固有的挑战却阻碍了我们对结构认知的同等程度拓展。通过构建精确的蛋白质结构模型，

结合本预测算法以及实验科学界已构建的规模庞大且经过精心整理的结构与序列数据库，我们期望加速推动结构生物信息学的发展，使其与基因组学革命保持同步。我们期待 AlphaFold——以及将其技术应用于其他生物物理学问题的计算方法——能成为现代生物学研究不可或缺的工具。

在线内容

所有方法、补充参考文献、《Nature Research》期刊报告摘要、原始数据、扩展数据、补充信息、致谢、同行评审信息；作者贡献及利益冲突详情；以及数据与代码可用性声明，均可于以下网址获取：https://doi.org/10.1038/s41586-021-03819-2。

1. Thompson，M. C.，Yeates，T. O. & Rodriguez，J. A.《原子分辨率大分子结构测定方法的进展》。*F1000Res*。**9**，667 (2020)。
2. Bai，X.-C.，McMullan，G. & Scheres，S. H. W. 冷冻电镜如何革新结构生物学。*Trends Biochem. Sci*.**40**，49–57 (2015)。
3. Jaskolski，M.，Dauter，Z. & Wlodawer，A.《大分子晶体学简史——以家族树及其诺贝尔奖成果为例》。*FEBSJ*.**281**，3985–4009 (2014)。
4. Wuthrich，K. 获取蛋白质核磁共振结构的方法。*Nat. Struct. Biol.***8**，923–925 (2001)。
5. wwPDB Consortium. 蛋白质数据库：3D 大分子结构数据的全球统一存档库。*Nucleic Acids Res*.**47**，D520–D528 (2018).
6. Mitchell, A. L.等.MGnify:2020 年推出的微生物组分析资源.*Nucleic Acids Res*.**48**,D570–D578 (2020).
7. Steinegger，M.，Mirdita，M. & Soding，J. 蛋白质水平组装可将宏基因组样本中的蛋白质序列回收率提升数倍。*Nat. Methods* **16**，603–606 (2019)。
8. Dill，K. A.，Ozkan，S. B.，Shell，M. S. & Weikl，T. R. 蛋白质折叠问题。*Annu. Rev. Biophys*.**37**，289–316 (2008)。
9. Anfinsen，C. B.《蛋白质链折叠的调控原理》。*《科学》* **181**，223–230（1973）。
10. Senior, A. W.等人.利用深度学习势函数改进蛋白质结构预测.*《自然》* **577**,706–710 (2020).
11. 王 S.、孙 S.、李 Z.、张 R. 及徐 J.。基于超深度学习模型的蛋白质接触图精准从头预测。*PLOS Comput. Biol.***13**，e1005324 (2017)。
12. Zheng, W.等.CASP13 中基于深度学习的接触图引导蛋白质结构预测.*Proteins* **87**,1149–1164 (2019).
13. Abriata，L. A.，Tamo，G. E. & Dal Peraro，M. A. CASP13 中三级结构预测技术的又一次重大突破，为未来的评估工作指明了新方向。*Proteins* **87**，1100–1112 (2019)。
14. Pearce，R. & Zhang，Y. 深度学习技术已对蛋白质结构预测与蛋白质设计产生深远影响。*Curr. Opin. Struct. Biol*.**68**，194–207 (2021)。
15. Moult，J.，Fidelis，K.，Kryshtafovych，A.，Schwede，T. & Topf，M.《蛋白质结构预测技术批判性评估》第十四轮。*CASP 14 摘要集* https://www.predictioncenter.org/casp14/doc/CASP14_Abstracts.pdf(2020)。
16. Brini，E.，Simmerling，C. & Dill，K. 利用物理学讲述蛋白质故事。*《科学》* **370**，eaaz 3041 (2020)。
17. Sippl，M. J. 基于平均力势计算构象系综：一种基于知识的球状蛋白局部结构预测方法。*J. Mol. Biol*.**213**，859–883 (1990).
18. Sali，A. & Blundell，T. L. 基于空间约束满足的蛋白质比较建模。*J. Mol. Biol*.**234**，779–815 (1993).
19. Roy，A.，Kucukural，A. & Zhang，Y. I- TASSER：一个用于自动化蛋白质结构与功能预测的统一平台。*《自然·实验流程》* **5**，725–738（2010）。
20. Altschuh，D.，Lesk，A. M.，Bloomer，A. C. & Klug，A. 与烟草花叶病毒相关的病毒中协同氨基酸替换与功能的相关性。*J. Mol. Biol*.**193**，693–707 (1987)。
21. Shindyalov，I. N.，Kolchanov，N. A. & Sander，C. 通过分析相关突变，能否预测蛋白质结构中的三维接触？*Protein Eng*.**7**，349–358 (1994).
22. Weigt，M.，White，R. A.，Szurmant，H.，Hoch，J. A. & Hwa，T. 通过消息传递法鉴定蛋白质-蛋白质相互作用中的直接残基接触。*Proc. Natl Acad. Sci. USA* **106**，67–72 (2009)。
23. Marks, D. S.等.基于进化序列变异计算的蛋白质三维结构.*PLoS ONE* **6**,e28766 (2011).
24. Jones，D. T.，Buchan，D. W. A.，Cozzetto，D. & Pontil，M. PSICOV：利用稀疏逆协方差估计在大规模多重序列比对中精确预测结构接触。*《生物信息学》* **28**，184–190（2012）。
25. Moult，J.，Pedersen，J. T.，Judson，R. & Fidelis，K. 一项用于评估蛋白质结构预测方法的大规模实验。*Proteins* **23**，ii–iv (1995)。
26. Kryshtafovych，A.，Schwede，T.，Topf，M.，Fidelis，K. & Moult，J. 蛋白质结构预测方法的批判性评估（CASP）第13轮。*Proteins* **87**，1011–1020 (2019)。
27. Zhang，Y. & Skolnick，J. 用于蛋白质结构模板质量自动评估的评分函数。*Proteins* **57**，702–710 (2004)。
28. Tu，Z. & Bai，X. 自动上下文及其在高级视觉任务与三维脑图像分割中的应用。*IEEE Trans. Pattern Anal. Mach. Intell*.**32**，1744–1757 (2010).
29. Carreira，J.，Agrawal，P.，Fragkiadaki，K. & Malik，J. 基于迭代误差反馈的人体姿态估计。载于*《IEEE 计算机视觉与模式识别会议论文集》*，第 4733–4742 页（2016）。
30. Mirabello，C. & Wallner，B. rawMSA：基于原始多序列比对的端到端深度学习。*PLoS ONE* **14**，e0220182 (2019)。
31. Huang, Z.等人.《CCNet:用于语义分割的交叉注意力机制》.载于*《IEEE/ CVF 国际计算机视觉会议论文集》*第603–612页(2019).
32. Hornak, V.等人:多种 Amber 力场的比较及改进型蛋白质主链参数的开发.*Proteins* **65**, 712–725 (2006).
33. Zemla，A. LGA：一种用于在蛋白质结构中寻找三维相似性的方法。*Nucleic Acids Res*.**31**，3370–3374 (2003).
34. Mariani，V.，Biasini，M.，Barbato，A. & Schwede，T. lDDT：一种基于距离差异检验、用于比较蛋白质结构与模型的局部无叠加评分方法。*《生物信息学》* **29**，2722–2728 (2013)。
35. 谢 Q.、Luong M.-T.、Hovy E. 及 Le Q. V.。带噪声学生模型的自训练提升 ImageNet 分类性能。载于*《IEEE/ CVF 计算机视觉与模式识别会议论文集》*第 10687–10698 页（2020）。
36. Mirdita, M.等.Uniclust:基于聚类及深度注释的蛋白质序列与比对数据库.*Nucleic Acids Res*.**45**,D170–D176 (2017).
37. Devlin，J.，Chang，M. -W.，Lee，K. & Toutanova，K. BERT：用于语言理解的深度双向 Transformer预训练。In *Proc. 2019年 North American 分会会议，Computational Linguistics 协会：Human Language 技术* 1,4171–4186 (2019)。
38. Rao，R. 等人。MSA 变换器。载于*《第 38 届国际机器学习会议论文集》*PMLR 139, 8844–8856 (2021)。
39. Tunyasuvunakool, K.等人.针对人类蛋白质组的高精度蛋白质结构预测.*《自然》* https://doi.org/10.1038/s41586-021-03828-1(2021).
40. Kuhlman，B. & Bradley，P.《蛋白质结构预测与设计研究进展》。*Nat. Rev. 《Mol. Cell Biol.》* **20**，681–697 (2019)
41. Marks，D. S.，Hopf，T. A. & Sander，C. 基于序列变异的蛋白质结构预测。*Nat. Biotechnol*.**30**，1072–1080 (2012)。
42. Qian，N. & Sejnowski，T. J. 利用神经网络模型预测球状蛋白质的二级结构。*J. Mol. Biol*.**202**，865–884 (1988)
43. Fariselli，P.，Olmea，O.，Valencia，A. & Casadio，R. 基于神经网络与相关突变预测接触图。*Protein Eng*.**14**，835–843 (2001)
44. Yang, J.等人:利用预测的残基间取向改进蛋白质结构预测.*Proc. Natl Acad. Sci. USA* **117**,1496–1503 (2020).
45. Li, Y.等人.通过深度残差卷积网络从三个共进化矩阵推导出高精度蛋白质接触图谱.*PLOS Comput. Biol.*.**17**,e1008865 (2021).
46. He，K.，Zhang，X.，Ren，S. & Sun，J. 基于深度残差学习的图像识别。载于*《IEEE 计算机视觉与模式识别会议论文集》*，第 770–778 页（2016）。
47. AlQuraishi，M. 蛋白质结构的端到端可微分学习。*Cell Syst*.**8**，292–301 (2019).
48. Senior，A. W. 等。在第 13 届蛋白质结构预测关键评估（CASP13）中采用多种深度神经网络进行蛋白质结构预测。*Proteins* **87**，1141–1148 (2019)。
49. Ingraham，J.，Riesselman，A. J.，Sander，C. & Marks，D. S. 利用可微分模拟器学习蛋白质结构。载于*《国际学习表示会议论文集》*(2019)。
50. Li，J. 通用变换几何网络。预印本发布于https://arxiv.org/abs/1908.00723 (2019)。
51. Xu，J.，McPartlon，M. & Li，J. 基于深度学习的蛋白质结构预测方法——无需共进化信息。*Nat. Mach. Intell*.**3**，601–609 (2021)。
52. Vaswani，A. 等人。《注意力即所需》。载于*《神经信息处理系统进展》*第 5998–6008 页（2017）。
53. Wang，H. 等人。Axial-deeplab：用于全景分割的独立轴向注意力模型。载于*《欧洲计算机视觉会议》*第 108–126 页（Springer，2020）。
54. Alley，E. C.，Khimulya，G.，Biswas，S.，AlQuraishi，M. & Church，G. M. 基于序列深度表征学习的统一化理性蛋白质工程。*Nat. Methods* **16**，1315–1322 (2019)。
55. Heinzinger, M.等人.通过蛋白质序列迁移学习构建生命语言建模方法.*BMC Bioinformatics* **20**,723 (2019).
56. Rives, A.等人.通过将无监督学习应用于 2.5 亿条蛋白质序列,揭示了生物结构与功能.*Proc. Natl Acad. Sci. USA* **118**,e2016239118 (2021).
57. Pereira, J.等人在CASP14中实现了高精度蛋白质结构预测.*《Proteins》* https://doi.org/10.1002/prot.26171(2021).
58. Gupta, M.等研究者利用冷冻电镜与人工智能技术解析了 SARS-CoV-2 Nsp2 蛋白的结构——该蛋白是一种参与宿主关键生理过程的多功能蛋白.预印本见:https://doi.org/10.1101/2021.05.10.443524(2021).

出版者注Springer Nature 对于已发表地图中的司法管辖权主张及机构隶属关系保持中立立场。

开放获取本文采用知识共享署名许可协议授权。4.0 国际许可，允许使用、共享、改编及分发以及在任何媒介或格式中复制本作品，但您须向原作者及来源提供适当署名、提供指向知识共享许可协议的链接，并标明是否对作品进行了修改。本文中的图像或其他第三方素材均包含在本作品的知识共享许可协议范围内，除非该素材的署名栏另有说明。若相关素材未包含在本作品的知识共享许可协议中，且您的预期使用方式不受法定法规许可或超出许可范围，则您需直接向版权持有人获取许可。如需查看本许可协议的副本，请访问http://creativecommons.org/licenses/by/4.0/。

© 作者 2021

方法

完整算法细节

关于各组件及其设计动机的详尽说明详见补充方法 1.1–1.10；此外，伪代码见补充信息中的算法 1–32，网络示意图见补充图 1–8，输入特征见补充表 1，其他补充细节见补充表 2、3。训练与推理相关细节详见补充方法 1.11–1.12 及补充表 4、5。

IPA

IPA 模块整合了成对表示、单点表示及几何表示，以更新单点表示（见补充图 8）。上述每种表示均向共享注意力权重贡献亲和力值，随后利用这些权重将其对应值映射至输出端。IPA 在三维空间中运行：每个残基在其局部坐标系中生成查询点、键点与值点；这些点通过与其相互作用的残基的主链坐标系投影至全局坐标系；最终，这些投影点被重新投影回局部坐标系。三维空间中的亲和力计算采用平方距离，而坐标变换机制确保了该模块对全局坐标系具有不变性（算法细节、不变性证明及完整多头版本描述详见补充方法 1.8.2 “不变性点注意力（IPA）”章节）。另一种基于经典几何不变性构建成对特征以替代学习所得三维点的相关构建方法，已应用于蛋白质设计[59]。

除 IPA 之外，系统还在抽象单表示上计算标准点积注意力，并在配对表示上计算特殊注意力。配对表示同时增强了对应注意力过程中的 logits 与 value 值，这也是配对表示调控结构生成的主要机制。

输入与数据源

网络的输入包括：一级序列、通过 jackhmmer [60]和 HHBlits [61]等标准工具构建的多序列比对（MSA）中获取的进化相关蛋白质序列，以及（在可用时）少量同源结构的三维原子坐标（模板）。对于 MSA 和模板，搜索过程均针对高召回率进行优化；原始 MSA 中可能出现伪匹配，但这与网络的训练条件保持一致。

所使用的序列数据库之一——Big Fantastic Database (BFD)——是专门构建并公开发布的（参见“数据可用性”部分），已被多个 CASP 团队使用。 BFD 是公开可用的最大蛋白质家族集合之一，包含 65,983,866 个以多序列比对（MSA）和隐马尔可夫模型（HMM）表示的蛋白质家族，涵盖了来自参考数据库、宏基因组和宏转录组的 2,204,359,010 条蛋白质序列。

BFD 的构建分为三个步骤。首先，从 UniProt（Swiss-Prot & TrEMBL，2017-11）[62]以及海洋真核生物参考目录[7]中收集了 2,423,213,294 条蛋白质序列，以 30% 的序列相似性进行聚类，同时使用 MMseqs2/Linclust [63]确保较短序列的比对覆盖率达到 90%。最终得到 345,159,030 个聚类。为提高计算效率，我们剔除了所有成员数少于三个的聚类，最终保留 61,083,719 个聚类。其次，我们从 Metaclust NR（2017-05；剔除所有长度短于 150 个残基的序列）[63]中选取 166,510,624 条代表性蛋白质序列，利用 MMseqs2 [64]将其与聚类代表序列进行比对。符合序列相似性与覆盖度标准的序列被归入得分最高的聚类；其余 25,347,429 条无法归入的序列则单独聚类，并作为新聚类加入，最终完成聚类过程。第三，对于每个聚类，我们使用 FAMSA [65]计算了 MSA，并遵循 Uniclust HH-suite 数据库协议[36]计算了 HMM。

本研究中使用了以下版本的公共数据集。我们的模型基于2019年8月28日下载的PDB [5]副本进行训练。在预测阶段查找模板结构时，我们使用了2020年5月14日下载的PDB副本，以及2020年5月13日下载的PDB70 [66]聚类数据库。在训练和预测阶段进行MSA检索时，我们分别使用了 Uniref90 [67] v.2020_01、 BFD 、Uniclust30 [36] v.2018_08 以及 MGnify [6] v.2018_12。对于序列蒸馏，我们使用Uniclust30 [36] v.2018_08构建蒸馏结构数据集。完整细节见补充方法1.2节。

对于在 BFD + Uniclust30 上进行的 MSA 搜索，以及针对 PDB70 的模板搜索，我们使用了 hh-suite v.3.0-beta.3（版本日期：2017年7月14日）中的 HHBlits [61]和 HHSearch [66]。对于在 Uniref90 及聚类后的 MGnify 上进行的 MSA 搜索，我们使用了 HMMER3 [68]中的 jackhmmer。对于结构的约束弛豫，我们使用了 OpenMM v.7.3.1 [69]及 Amber99sb 力场[32]。对于神经网络构建、运行及其他分析，我们使用了 TensorFlow [70]、Sonnet [71]、NumPy [72]、Python [73]以及 Colab [74]。

为了量化不同序列数据源的影响，我们使用相同的模型重新运行 CASP14蛋白质分析，但改变了多序列比对（MSA）的构建方式。移除 BFD 使平均准确率下降0.4 GDT，移除Mgnify使平均准确率下降0.7 GDT，同时移除两者则使平均准确率下降6.1 GDT 。在每种情况下，我们发现大多数靶标的准确率变化极小，但少数异常值则表现出极大的差异（超过20 GDT）。这一结果与图5中的发现一致：MSA的深度相对不重要，直到其接近约30条序列的阈值时，MSA大小的影响才变得相当显著。我们观察到，包含 BFD 与Mgnify的效果大多重叠，但对于在UniRef中代表性不足的靶标类别而言，至少包含其中一个宏基因组数据库至关重要；而若要达到完整的 CASP 准确率，则必须同时包含这两个数据库。

训练方案

为了训练，我们使用了来自PDB数据库的结构，这些结构的最后发布日期为2018年4月30日。链的采样基于40%序列相似性聚类后的簇大小反比原则。随后，我们将这些链随机裁剪为256个残基，并组装成批大小为128的批次。我们在Tensor Processing Unit (TPU) v3上训练模型，每个TPU核心使用1个批次大小，因此模型使用了128个TPUv3核心。模型训练直至收敛（约1000万样本），之后使用更长的384个残基裁剪片段、更大的MSA堆栈以及降低的学习率进行微调（具体配置见补充方法1.11）。初始训练阶段大约需要1周时间，微调阶段则额外需要约4天时间。

该网络由 FAPE 损失函数及若干辅助损失函数监督。首先，将最终的配对表示线性投影至分箱距离分布（距离图）预测，并使用交叉熵损失进行评分。其次，我们对输入的MSA应用随机掩码处理，并要求网络利用类似BERT的损失函数[37]，从输出MSA表示中重建被掩码区域。第三，结构模块的输出单一表示用于预测按残基分箱的lDDT-Cα值。最后，在训练阶段使用辅助侧链损失函数，在微调阶段使用辅助结构违规损失函数。详细描述及权重分配见补充信息。

首先，利用上述目标函数训练初始模型，对包含完整多序列比对（MSA）的 355,993 条序列组成的 Uniclust 数据集进行结构预测。随后，将这些预测结果用于训练最终模型——该最终模型采用相同的超参数，仅调整采样策略：75% 的采样次数从 Uniclust 预测集中选择子采样后的 MSA，25% 的采样次数从已聚类 PDB 集中选择。

我们使用不同的随机种子训练了五种不同的模型——其中部分模型使用模板，部分模型则不使用——以增强预测结果的多样性（详见补充表 5

及补充方法 1.12.1）。在 CASP14 赛后，我们还对这些模型进行了微调，引入 pTM 预测目标（补充方法 1.9.7），并将所得模型用于图2d的绘制。

推理方案

我们对五个训练好的模型进行推断，并利用预测的置信度分数为每个目标选择最佳模型。

使用我们在 AlphaFold 中配置的 CASP14，我们对神经网络主干进行了多次运行，每次运行时选择不同的 MSA 聚类中心（有关集成流程的详细信息，请参阅补充方法 1.11.2）。生成结构预测的总时间因蛋白质长度而异，使用单个模型在 V100 GPU 上运行的代表性时间分别为：256 个残基时 4.8 分钟，384 个残基时 9.2 分钟，2,500 个残基时 18 小时。这些时间均使用我们的开源代码测得，且该开源代码的运行速度显著快于我们在 CASP14 中使用的版本，因为我们现已采用 XLA 编译器[75]。

自引入 CASP14 以来，我们发现未采用集成方法的网络准确率与采用集成方法的网络相当或更为接近，因此对于大多数推理任务，我们均采用集成方法。在不使用集成时，该网络的运行速度可提升 8 倍；单个模型的代表性运行时间分别为：256 个残基时为 0.6 分钟，384 个残基时为 1.1 分钟，2,500 个残基时为 2.1 小时。

对大分子蛋白质的结构进行推断时，其内存需求很容易超出单个GPU的承载能力。对于配备16 GB显存的V100显卡，在不使用集成计算模块的情况下，我们可预测长度约1,300个残基的蛋白质结构；而针对256及384个残基的蛋白质推断，则需占用单个GPU的全部显存。内存使用量与残基数量呈近似二次方关系，因此对于2,500个残基的蛋白质，需启用统一内存模式，方可显著突破单个V100的显存限制。在本云计算环境中，单个V100显卡用于处理2,500个残基的蛋白质推断任务，但为确保充足的内存资源，我们同时调用了四块GPU。

检索基因序列数据库以准备输入数据，以及对结构进行最终弛豫处理，虽需额外中央处理器（CPU）时间，但无需使用 GPU 或 TPU。

指标

预测结构与来自PDB的真实结构根据lDDT指标[34]进行比较，该指标在不需要对链结构进行域分割的情况下，可反映域准确性。距离计算要么基于所有重原子（lDDT），要么仅基于Cα原子以评估主链准确性（lDDT-Cα）。由于lDDT-Cα仅关注Cα原子，因此不包含结构违规及原子间冲突的惩罚项。 CASP 中的域准确性以 GDT [33]表示，而TM-score [27]则用作全链全局叠加度量指标。

我们还报告了采用 ther.m.s.d $_{95}$（Cα在95%覆盖率下的均方根偏差）计算得出的准确度值。我们执行五次迭代操作：(1)在当前选定的Cα原子上，对预测结构与PDB结构进行最小二乘对齐（首次迭代时使用全部Cα原子）；(2)筛选出对齐误差最低的95% Cα原子。最终迭代中所选原子的 ther.m.s.d. 即为 ther.m.s.d $_{95}$。该指标对可能源于晶体结构伪影的表观误差具有更强的鲁棒性，尽管在某些情况下，剔除5%的残基仍可能包含真实的建模误差。

近期 PDB 序列测试集

为对近期PDB序列进行评估（图2a–d、4a、5a），我们使用了2021年2月15日下载的PDB副本。结构筛选条件为发布日期晚于2018年4月30日（此为AlphaFold训练集收录的日期上限）。随后对链进行进一步筛选，剔除仅含单个氨基酸的序列以及任一残基位点存在模糊化学成分的序列。去除完全重复序列后，以具有最多解析Cα原子的链作为代表序列。继而，剔除解析残基少于16个、含未知残基或经NMR法解析的结构。鉴于PDB中包含大量近乎重复的序列，我们从PDB数据中40%序列聚类结果每个簇内选取分辨率最高的链。此外，我们剔除了所有α碳原子解析残基少于80个的序列，以及残基数超过1,400的链。最终数据集包含10,795条蛋白质序列。

基于先前模板相似性对近期PDB数据集进行过滤的步骤如下：使用默认参数，对2021年2月15日下载的PDB SEQRES fasta文件运行HmMsearch。若相关结构的发布日期早于2018年4月30日，则接受该模板匹配结果。查询序列中的每个残基位置均被赋予该位置所有模板匹配结果中的最大相似性值。随后，根据各图注中所述方法，结合最大相似性与序列覆盖度进行过滤。

MSA深度分析基于计算查询序列每个位点上的标准化有效序列数（N_{eff}）而进行。每个residue N_{eff}值是通过统计该位点在MSA中非空位残基的数量，并using the N_{eff}方案[76]对序列进行加权计算得出，其中加权阈值设定为在任一序列中均非空位区域上测得的序列一致性阈值为80%。

报告摘要

关于研究设计的更多信息，请参阅本文附带的《Nature Research 研究报告摘要》。

数据可用性

所有输入数据均可从公开渠道免费获取。

来自PDB的结构被用于训练及作为模板（https://www.wwpdb.org/ftp/pdb-ftp-sites；相关序列数据及40%序列聚类信息另见https://ftp.wwpdb.org/pub/pdb/derived_data/ 及 https://cdn.rcsb.org/resources/sequence/clusters/bc-40.out）。训练所用PDB版本下载于2019年8月28日，而CASP14模板搜索则使用2020年5月14日下载的版本。模板搜索同时采用了PDB70数据库，下载于2020年5月13日（https://wwwuser.gwdg.de/~compbiol/data/hhsuite/databases/hhsuite_dbs/）。

我们展示了来自PDB数据库、登录号为6Y4F [77]、6YJ1 [78]、6VR4 [79]、6SKO [80]、6FES [81]、6W6W [82]、6T1Z [83]及7JTL [84]的实验结构。

在训练和预测阶段进行MSA检索时，我们使用了UniRef90 v.2020_01（https://ftp.ebi.ac.uk/pub/databases/uniprot/previous_releases/release-2020_01/uniref/）、 BFD（https://bfd.mmseqs.com）、Uniclust30 v.2018_08（https://wwwuser.gwdg.de/~compbiol/uniclust/2018_08/）以及MGnify clusters v.2018_12（https://ftp.ebi.ac.uk/pub/databases/metagenomics/peptide_database/2018_12/）。Uniclust30 v.2018_08还被用作构建蒸馏结构数据集的输入。

代码可用性

AlphaFold 模型的源代码、训练权重及推理脚本均已根据开源许可证发布于https://github.com/deepmind/alphafold。

神经网络使用 TensorFlow v.1（https://github.com/tensorflow/tensorflow）、Sonnet v.1（https://github.com/deepmind/sonnet）、JAX v.0.1.69（https://github.com/google/jax/）以及 Haiku v.0.0.4（https://github.com/deepmind/dm-haiku）开发。 XLA 编译器与 JAX 捆绑提供，且没有独立的版本号。

对于在 BFD +Uniclust30 上进行的 MSA 搜索，以及针对 PDB70 的模板搜索，我们使用了 hh-suite v.3.0-beta 中的 HHBlits 和 HHSearch。2017年7月14日发布的版本 3（https://github.com/soedinglab/hh-suite）。对于在 UniRef90 及聚类后的

MGnify 上进行的 MSA 搜索，我们使用了 HMMERv.3.3 中的 jackhmmer（http://eddylab.org/software/hmmer/）。对于结构的约束弛豫，我们使用了 OpenMM v.7.3.1（https://github.com/openmm/openmm）并配合 Amber99sb 力场。

BFD 的构建使用了 MMseqs2 v.925AF（https://github.com/soedinglab/MMseqs2）和 FAMSA v.1.2.5（https://github.com/refresh-bio/ FAMSA）。

数据分析采用 Python v.3.6（https://www.python.org/）、NumPy v.1.16.4（https://github.com/numpy/numpy）、SciPy v.1.2.1（https://www.scipy.org/）、seaborn v.0.11.1（https://github.com/mwaskom/seaborn）、Matplotlib v.3.3.4（https://github.com/matplotlib/matplotlib）、bokeh v.1.4.0（https://github.com/bokeh/bokeh）、pandas v.1.1.5（https://github.com/pandas-dev/pandas）、plotnine v.0.8.0（https://github.com/has2k1/plotnine）、statsmodels v.0.12.2（https://github.com/statsmodels/statsmodels）及 Colab（https://research.google.com/colaboratory）。TM-score 计算使用 TM-align v.20190822（https://zhanglab.dcmb.med.umich.edu/TM-align/）。结构可视化通过 Pymol v.2.3.0（https://github.com/schrodinger/pymol-open-source）完成。

59. Ingraham，J.，Garg，V. K.，Barzilay，R. & Jaakkola，T. 基于图的蛋白质设计的生成式模型。载于*《第 33 届神经信息处理系统会议论文集》*(2019)。
60. Johnson，L. S.，Eddy，S. R. & Portugaly，E. 隐马尔可夫模型速度启发式方法与迭代式 HMM 搜索流程。*BMC Bioinformatics* **11**，431 (2010)。
61. Remmert，M.，Biegert，A.，Hauser，A. & Soding，J. HHblits：基于 HMM-HMM 比对的超快速蛋白质序列迭代搜索。*Nat. Methods* **9**，173–175 (2012)。
62. UniProt 联盟。《UniProt：2021 年的通用蛋白质知识库》。*Nucleic Acids Res*。**49**，D480–D489 (2020)。
63. Steinegger，M. & Soding，J. 以线性时间复杂度对大规模蛋白质序列集进行聚类分析。*Nat. Commun.***9**，2542 (2018) .
64. Steinegger，M. & Soding，J. MMseqs2 为大规模数据集分析提供了高灵敏度的蛋白质序列搜索功能。*Nat. Biotechnol*.**35**，1026–1028 (2017).
65. Deorowicz，S.，Debudaj-Grabysz，A. & Gudys，A. FAMSA：针对庞大蛋白质家族的快速且精确的多序列比对。*Sci. Rep*.**6**，33964 (2016)。
66. Steinegger, M. 等.HH-suite3:用于快速远程同源检测与深度蛋白质注释.*BMC Bioinformatics* **20**,473 (2019).
67. Suzek，B. E.，Wang，Y.，Huang，H.，McGarvey，P. B. & Wu，C. H. UniRef clusters：一种全面且可扩展的替代方案，用于提升序列相似性检索性能。*Bioinformatics* **31**，926–932 (2015)。
68. Eddy，S. R. 加速轮廓 HMM 搜索。*PLOS Comput. Biol*.**7**，e1002195 (2011) .
69. Eastman, P.等人.OpenMM 7:分子动力学高性能算法的快速开发.*PLOS Comput. Biol*.**13**,e1005659 (2017).
70. Ashish, A. M. A.等人,《TensorFlow:异构系统上的大规模机器学习》,预印本发布于https://arxiv.org/abs/1603.04467(2015).
71. Reynolds, M.等人.开源 Sonnet —— 用于构建神经网络的新库.*DeepMind* https://deepmind.com/blog/open-sourcing-sonnet/(2017年4月7日).
72. Harris, C. R.等.使用 NumPy 进行数组编程. *《自然》* **585**,357–362(2020).
73. Van Rossum，G. & Drake，F. L.*Python 3 Reference Manual*(CreateSpace，2009)。
74. Bisong，E. 著于*《在 Google Cloud 平台上构建机器学习与深度学习模型：面向初学者的全面指南》*第 59–64 页（Apress，2019）。
75. TensorFlow. XLA：TensorFlow 优化编译器。https://www.tensorflow.org/xla(2018)。
76. Wu，T.，Hou，J.，Adhikari，B. & Cheng，J. 影响基于深度学习的残基间接触预测的若干关键因素分析。*Bioinformatics* **36**，1091–1098 (2020)。
77. Jiang, W.等研究者报道,MrpH———一类新型金属结合黏附素——需要锌离子来介导生物膜形成. *PLoS Pathog*.**16**,e1008707 (2020).
78. Dunne，M.，Ernst，P.，Sobieraj，A.，Pluckthun，A. & Loessner，M. J. 葡萄球菌噬菌体 2638A 内溶素的 M23 肽酶结构域。*PDB* https://doi.org/10.2210/pdb6YJ1/pdb(2020)。
79. Drobysheva, A. V.等.类 crAss 噬菌体病毒颗粒 RNA 聚合酶的结构与功能.*《自然》* **589**,306–309(2021).
80. Flaugnatti, N.等.VgrG 刺突蛋白对细菌 T6SS 磷脂酶效应蛋白的负载与抑制作用的结构基础. *EMBO J*.**39**,e104129 (2020) .
81. ElGamacy, M.等人.一种基于界面的设计策略催生了一种新型波纹状蛋白质结构.*ACS Synth. Biol*.**7**,2226–2235 (2018).
82. Lim, C. J.等人.人类 CST 蛋白的结构揭示其以十聚体形式与端粒 DNA 结合.*《科学》* **368**,1081–1085 (2020).
83. Debruycker, V.等人.多药转运蛋白 LmrP 中嵌入的脂质结构为多特异性机制提供了线索.*Nat. Struct. Mol. Biol*..**27**,829–835 (2020).
84. Flower, T. G.等.SARS-CoV-2 ORF8 的结构:一种快速进化的免疫逃逸蛋白.*Proc. Natl Acad. Sci. USA* **118**, e2021785118 (2021).

致谢我们谨向 A. Rrustemi、A. Gu、A. Guseynov、B. Hechtman、C. Beattie、C. Jones、C. Donner、E. Parisotto、E. Elsen、F. Popovici、G. Necula、H. Maclean、J. Menick、J. Kirkpatrick、J. Molloy、J. Yim、J. Stanway、K. Simonyan、L. Sifre、L. Martens、M. Johnson、M. O'Neill、N. Antropova、R. Hadsell、S. Blackwell、S. Das、S. Hou、S. Gouws、S. Wheelwright、T. Hennigan、T. Ward、Z. Wu、Z. Avsec 以及研究平台团队所做出的贡献致以谢意；

M. 感谢 Mirdita 在数据集方面提供的帮助；感谢 M. Piovesan-Forster、A. Nelson 和 R. Kemp 在项目管理方面给予的支持；感谢 JAX 、TensorFlow 及 XLA 团队提供的详细支持，以及助力实现 AlphaFold 复杂性的机器学习模型；感谢我们在 DeepMind、Google 和 Alphabet 的同事给予的鼓励与支持；以及感谢 J. Moult 和 CASP14 组织者，还有那些提供了结构数据以支持评估工作的实验人员。

M.S. 感谢韩国国家研究基金会提供的资助（2019R1A6A1A10073437、2020M3A9G7103933）以及首尔国立大学“创新开拓型研究人员计划”的支持。

作者贡献J.J. 与 D. H. 主导了本研究。J.J.、R. E.、A. Pritzel、M. F.、O. R.、R. B.、A. Potapenko、S.A. A. K.、B. R.-P.、J. A.、M. P.、T. Berghammer 及 O.V. 共同开发了神经网络架构及训练流程。T.G.、A.Z.、K.T.、R. B.、A. B.、R. E.、A.J. B.、A.C.、S. N.、R.J.、D. R.、M.Z. 及 S. B. 负责数据、分析及推理系统的开发。D. H.、K. K.、P. K.、C. M. 及 E.C. 统筹研究工作。T.G. 负责技术平台搭建。P. K.、A.W.S.、K. K.、O.V.、D.S.、S. P. 及 T. Back 提供了技术建议与创意支持。M.S. 构建了 BFD 基因组数据库，并在 HHBlits 项目中提供技术协助。D. H.、R. E.、A.W.S. 及 K. K. 共同构思了 AlphaFold 项目。J.J.、R. E. 及 A.W.S. 共同构思了端到端方法。J.J.、A. Pritzel、O. R.、A. Potapenko、R. E.、M. F.、T.G.、K.T.、C. M. 及 D. H. 共同撰写了论文。

利益冲突J.J.、R. E.、A. Pritzel、T.G.、M. F.、O. R.、R. B.、A. B.、S.A.A. K.、D. R. 及 A.W.S. 均已以 DeepMind Technologies Limited 名义提交非临时专利申请 16/701,070 与 PCT/EP2020/084238，以及临时专利申请 63/107,362、63/118,917、63/118,918、63/118,921 及 63/118,919，上述申请均处于待审状态，且均与用于预测蛋白质结构的机器学习相关。其余作者声明无利益冲突。

补充信息

补充信息在线版本包含可在https://doi.org/10.1038/s41586-021-03819-2获取的补充材料。

通讯及材料索取请寄至 J.J. 或 D. H.

同行评审信息*Nature*谨此感谢 Mohammed AlQuraishi、Charlotte Deane 及 Yang Zhang 对本研究同行评审工作的贡献。

重印及授权信息可在http://www.nature.com/reprints 获取。

nature research

通讯作者：John Jumper，Demis Hassabis

最后由作者更新：2021年7月11日

报告摘要

《Nature Research》致力于提升我们发表研究成果的可重复性。本表格旨在为研究报告提供统一的框架，以确保报告的一致性与透明度。
如需了解更多关于《Nature Research》政策的信息，请参阅我们的编辑政策及编辑政策核查清单。

统计量

在进行所有统计分析时，请确认以下项目均已包含在图注、表注、正文或“方法”部分中。

n/a	已确认
☐	☒ 每个实验组/条件下的确切样本量（*n*），以离散数值及测量单位表示
☒	☐ 关于测量是否取自不同样本，或是否对同一样本进行了重复测量的说明
☐	☒ 所使用的统计检验及其是单侧还是双侧检验 *仅对常规检测项目仅需以名称进行描述；对于更复杂的检测技术，则应在“方法”部分予以说明。*
☒	☐ 所有已检验协变量的描述
☐	☒ 对任何假设或校正措施的说明，例如正态性检验及多重比较校正
☐	☒ 对统计参数的完整描述，包括集中趋势（如均值）或其他基础估计量（如回归系数），以及变异程度（如标准差）或与之相关的不确定性估计量（如置信区间）。
☒	☐ 对于零假设检验，需提供检验统计量（如*F*、*t*、*r*）及其置信区间、效应量、自由度与*P*值*；若适用，请将P值以精确值形式给出。*
☐	☒ 关于贝叶斯分析，需考虑先验分布的选择及马尔可夫链蒙特卡洛方法的设置。
☒	☐ 对于分层及复杂研究设计，需确定适宜的检验层级，并完整报告研究结果。☒ 效应量估计值（例如 Cohen
☐	‘s *d*、Pearson’ s *r*），以及这些估计值的计算方式

我们关于生物学家统计学的网页资源库收录了涵盖上述诸多要点的相关文章。

软件与代码

关于计算机代码可用性

数据收集

AlphaFold 模型的源代码、训练权重及推理脚本将在论文发表后，依据开源许可证发布于https://github.com/deepmind/。

神经网络使用 TensorFlow v1（https://github.com/tensorflow/tensorflow）、Sonnet v1（https://github.com/deepmind/sonnet）、JAX v0.1.69（https://github.com/google/jax/）以及 Haiku v0.0.4（https://github.com/deepmind/dm-haiku）开发。XLA 编译器与 JAX 捆绑提供，且没有独立的版本号。

对于在 BFD +Uniclust30 上进行的 MSA 搜索，以及针对 PDB70 的模板搜索，我们使用了 hh-suite v3.0-beta 中的 HHBlits 和 HHSearch。2017年7月14日（https://github.com/soedinglab/hh-suite）。对于在 UniRef90 及聚类后的 MGnify 上进行的 MSA 搜索，我们使用了 HMMER v3.3 中的 jackhmmer（http://eddylab.org/software/hmmer/）。对于结构的约束弛豫，我们使用了 OpenMM v7.3.1（https://github.com/openmm/openmm）及 Amber99sb 力场。

BFD 的构建使用了 MMseqs2 版本 925AF（https://github.com/soedinglab/MMseqs2）和 FAMSA v1.2.5（https://github.com/refresh bio/ FAMSA）。

数据分析

数据分析采用 Python v3.6（https://www.python.org/）、NumPy v1.16.4（https://github.com/numpy/numpy）、SciPy v1.2.1（https://www.scipy.org/）、seaborn v0.11.1（https://github.com/mwaskom/seaborn）、Matplotlib v3.3.4（https://github.com/matplotlib/matplotlib）、bokeh v1.4.0（https://github.com/bokeh/bokeh）、pandas v1.1.5（https://github.com/pandas-dev/pandas）、plotnine v0.8.0（https://github.com/has2k1/plotnine）、statsmodels v0.12.2（https://github.com/statsmodels/statsmodels）以及 Colab（https://research.google.com/colaboratory）。TM-score 计算使用 TM-align v20190822（https://zhanglab.dcmb.med.umich.edu/TM-align/）。结构可视化采用
使用 Pymol v2.3.0 (https://github.com/schrodinger/pymol-open-source) 创建。

对于采用定制算法或软件，且这些工具对研究至关重要但尚未在已发表文献中描述的论文，作者必须向编辑和审稿人提供相关软件。我们强烈建议将相关代码部署至社区代码仓库（如 GitHub）。如需更多信息，请参阅《自然·研究》关于提交代码与软件的指南。

数据

关于数据可用性的政策信息

所有稿件均须包含一份数据可用性声明。该声明应在适用情况下提供以下信息：

- 公开可用数据集的登录号、唯一标识符或网页链接
- 包含关联原始数据的图表列表
- 关于数据可用性所受任何限制的说明

所有输入数据均可从公开渠道免费获取。

来自PDB的结构被用于训练及作为模板（https://www.wwpdb.org/ftp/pdb-ftp-sites；相关序列数据及40%序列聚类信息另见https://ftp.wwpdb.org/pub/pdb/derived_data/ 及https://cdn.rcsb.org/resources/sequence/clusters/bc-40.out）。训练所用PDB版本下载于2019年8月28日，而CASP14模板搜索则使用2020年5月14日下载的版本。模板搜索同样采用PDB70数据库，下载于2020年5月13日（https://wwwuser.gwdg.de/~compbiol/data/hhsuite/databases/hhsuite_dbs/).）。

我们展示了来自 PDB 数据库中登录号为 6Y4F77、6YJ178、6VR479、6SK080、6FES81、6W6W82、6T1Z83 及 7JTL84 的实验结构。

在训练和预测阶段进行 MSA 检索时，我们使用了 UniRef90 v2020_01（https://ftp.ebi.ac.uk/pub/databases/uniprot/previous_releases/release-2020_01/uniref/）、BFD（https://bfd.mmseqs.com）、Uniclust30 v2018_08（https://wwwuser.gwdg.de/~compbiol/uniclust/2018_08/），与 MGnify 聚类v2018_12（https://ftp.ebi.ac.uk/pub/databases/metagenomics/peptide_database/2018_12/））。
Uniclust30 v2018_08 随后被用作构建蒸馏结构数据集的输入数据。

领域专项报告

请选择下方最符合您研究需求的选项。若您尚不确定，请在做出选择前阅读相关章节。☒ 生命科学 ☐ 行为与社会科学 ☐ 生态、进化与环境科学

如需查阅包含所有章节的文档参考副本，请参阅nature.com/documents/nr-reporting-summary-flat.pdf。

生命科学研究设计

所有研究均须就上述事项进行披露，即便披露结果为否定性结论。

样本量	未设定样本量；该方法在完整的 CASP14 基准数据集以及所有未包含在训练集中的 PDB 链（遵循下文所述的排除标准）上进行了评估。
数据排除标准	近期构建的PDB数据集已经过筛选（完整细节参见“方法”部分）。简言之，该筛选排除了以下类型的分子链：可解析残基过少的链、长度超过1400个残基的链、通过核磁共振（NMR）解析的链，或含有未知/模糊残基的链。此外，该数据集还进行了冗余度降低处理（通过从序列聚类中选取代表性条目实现），并对部分图表应用了基于序列相似性的过滤条件，以剔除与训练集过于相似的条目（详见“方法”部分及图表图注）。
复制	不适用，本研究未描述任何实验工作。所得结果系基于一种即将公开的计算方法得出。

随机化 不适用，因为我们并未对两组数据进行比较。 盲法 不适用，因为我们并未对两组数据进行比较。

针对特定材料、系统及方法的报告

我们要求作者提供关于若干类材料、实验系统及方法的相关信息，这些内容在众多研究中均有应用。请针对所列每项材料、系统或方法，说明其是否与您的研究相关。若您不确定某项条目是否适用于您的研究，请在选择回答前参阅相应章节。

材料与实验系统

n/a	参与本研究
☒	☐ 抗体
☒	☐ 真核细胞	古生物学与考
☒	☐
☒	☐ 古学	动物及其他生物体	
☒	☐
☒	☐ 人类研究受试者	临床数据
☒	☐ 需警惕的双用途研究

方法

n/a	参与本研究
☒	☐ 染色质免疫沉淀
测序☒	☐ 流式细胞术
☒	☐ 基于 MRI 的神经影像学