基于深度学习势函数的蛋白质结构预测改进方法

https://doi.org/10.1038/s41586-019-1923-7

收稿日期：2019年4月2日

接收日期：2019年12月10日

在线发表日期：2020年1月15日

Andrew W. Senior [1,4]*、Richard Evans [1,4]、John Jumper [1,4]、James Kirkpatrick [1,4]、Laurent Sifre [1,4]、Tim Green [1]、Chongli Qin [1]、Augustin Zidek [1]、Alexander W. R. Nelson [1]、Alex Bridgland [1]、Hugo Penedones [1]、Stig Petersen [1]、Karen Simonyan [1]、Steve Crossan [1]、Pushmeet Kohli [1]、David T. Jones [2,3]、David Silver [1]、Koray Kavukcuoglu [1]及Demis Hassabis [1]

蛋白质结构预测可用于根据蛋白质的氨基酸序列[1]推导出其三维构象。这一问题具有基础性重要意义，因为蛋白质的结构在很大程度上决定了其功能[2]；然而，通过实验手段确定蛋白质结构仍颇具挑战。近年来，借助遗传信息，该领域已取得显著进展：通过分析同源序列中的共变关系，可推断哪些氨基酸残基存在空间接触，这有助于蛋白质结构的预测[3]。本文我们证明，可通过训练神经网络对成对残基间的距离进行精准预测——此类预测所提供的结构信息量远超接触预测。基于此信息，我们构建了平均力势[4]，该势函数能准确描述蛋白质构象。研究发现，所得势函数可通过简单梯度下降算法优化，从而无需复杂采样流程即可生成蛋白质结构。最终构建的系统命名为AlphaFold，即使对于同源序列较少的蛋白质，仍能实现高精度预测。在近期开展的《蛋白质结构预测关键评估》[5]（CASP13）——一项针对该领域现状的盲法评估——中，AlphaFold 在 43 个自由建模结构域中，有 24 个结构域构建了高精度结构（其模板建模（TM）评分[6]达到 0.7 或更高）；而次优方法（采用采样与接触信息）在 43 个结构域中仅对 14 个结构域实现了同等精度。AlphaFold 代表了蛋白质结构预测领域的重大突破。我们预期，这种精度的提升将有助于深入理解蛋白质的功能与异常机制，尤其在尚未通过实验测定同源蛋白结构的案例中[7]。

蛋白质是大多数生物过程的核心。其功能在于
蛋白质的功能取决于其结构，因此理解蛋白质结构至关重要。
数十年来，这一课题一直是生物学领域面临的重大挑战。尽管
尽管已开发出多种实验性结构解析技术，且其精度已得到提升，但这些技术仍面临困难且耗时较长。
消耗[2]。因此，数十年的理论研究一直试图
根据氨基酸序列预测蛋白质结构。

CASP [5]是一项每两年举办一次的盲法蛋白质结构预测评估活动。由结构预测领域社区主导，用于评估相关进展的基准测试准确性。2018年，AlphaFold 与来自世界各地的 97 个研究团队共同参与了提交 CASP13 [8]。每个小组最多提交 5 个结构预测结果。针对 84 条已通过实验测定结果的蛋白质序列中的每一条结构被隔离。评估人员将蛋白质划分为 104 类。用于评分的域，并将其分别归类为适用于模板分析的域。基于建模的方法（TBM），其中采用具有相似序列的蛋白质一种已知结构，且该同源结构在.....中被修饰
基于序列差异）或需进行自由建模（FM，适用于无同源结构可用之情形），以及一个中间类别（FM/TBM）。图1a显示 AlphaFold
相较于其他任何系统，本系统在预测 FM 结构域数量方面均能以更高精度实现。
尤其是在 0.6–0.7 的 TM 分数区间内。TM 分数——其取值范围为
取值范围为 0 至 1——用于衡量拟议结构的整体（主链）形状与天然结构的匹配程度。评估人员
根据各参与小组的汇总且取上限的 z 分数，将 98 个参与小组进行排序。
按类别对结构进行分类。AlphaFold 实现了
在 FM 类别（五局制）中，综合 Z 分数为 52.8，与.....相比
次接近组别（322）的数值为 36.6。将 FM 与 TBM/FM 相结合时
在各类别中，AlphaFold 的得分为 68.3，而对照结果为 48.2。AlphaFold 是能够以高精度预测此前未知的折叠结构（图1b）。
尽管仅采用 FM 技术而未使用模板，AlphaFold
根据评审专家的评估，在 TBM 类别中也取得了良好成绩。
基于 0 截断值的 Z 分数，在“Top-One”模型中排名第四或第一
针对五折交叉验证模型而言，AlphaFold 的准确性在很大程度上归因于对距离预测精度的影响，这一点可从以下方面看出：

相应接触预测结果具有高精度（图1c及扩展数据图 2a）。

[1]DeepMind，英国伦敦。[2]弗朗西斯·克里克研究所，英国伦敦。[3]伦敦大学学院，英国伦敦。[4]以下作者贡献相同：Andrew W. Senior、Richard Evans、John Jumper、James Kirkpatrick、Laurent Sifre *电子邮箱：andrewsenior@google.com

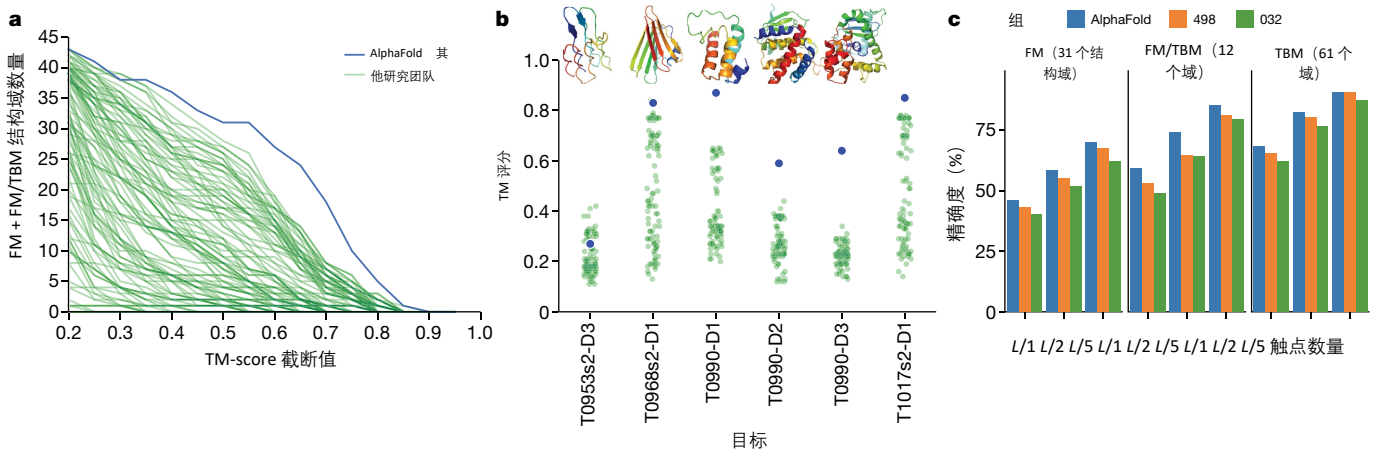


图1 | AlphaFold在CASP13评估中的性能表现。a：针对给定TM-score阈值，AlphaFold与其他97个分组所预测的FM（FM + FM/TBM）结构域数量。**b**：对于CASP13评估者识别出的六个新折叠结构，将AlphaFold的TM-score与其他分组及天然结构进行对比。T1017s2-D1的结构暂不公开。**c**：CASP13中针对最可能出现的L、*L*/2或L/5接触位点的长程接触预测精确率（其中L为结构域长度）。AlphaFold在CASP13中针对接触预测采用的距离分布（经阈值处理），与CASP13中两个最佳排名的接触预测方法——498（RaptorX-Contact [26]）及032（TripletRes [32]）——在“所有分组”目标上的预测结果进行对比，并采用T0953s2的最新结构域定义。

迄今为止最成功的FM方法[9–11]均依赖于片段组装策略。在这些方法中，结构是通过随机采样过程——例如模拟退火[12]——构建的，该过程旨在最小化基于从蛋白质数据库（PDB）[13]中提取的汇总统计量推导出的统计势能。在片段组装中，结构假设会被反复修正——通常通过改变短片段形状，同时保留可降低势能的调整——最终获得低势能结构。模拟退火算法需进行数千次此类移动操作，且需重复多次运行，方能充分覆盖低势能结构空间。

近年来，通过利用从相关序列中提取的进化共变数据[14]，结构预测的准确性已显著提升。与目标序列相似的序列是通过从DNA测序获取的庞大蛋白质序列数据集中进行搜索，并与目标序列进行比对，进而生成多序列比对（MSA）来发现的。在MSA的序列中，两个氨基酸残基位点上的共变关系可用于推断哪些残基可能处于接触状态。通常将两个残基的β-碳原子间距小于8 Å时，判定二者存在接触。目前已采用多种方法[15–18]——包括神经网络[19–22]——基于MSA计算的特征来预测一对残基发生接触的概率。这些接触预测结果被整合至结构预测流程中：通过修改统计势能函数，引导蛋白质折叠过程生成更符合预测接触条件的结构[11,23]。其他研究[24,25]曾采用残基间距离的预测结果，尤其在距离几何方法中[26–28]。未包含协变特征的神经网络距离预测被用于构建进化双残基距离依赖性统计势函数[25]，该势函数随后用于对结构假说进行排序。此外，quark pipeline [11]在TBM分析中采用了基于模板的距离分布约束。

在本研究中，我们提出了一种用于蛋白质结构预测的深度学习方法，其流程如图 2a所示。我们证明：通过训练神经网络（图 2b），使其根据蛋白质序列对蛋白质结构进行精准预测，进而通过梯度下降法最小化该势能函数，即可构建出具有蛋白质特异性的学习所得势能函数，并据此准确预测蛋白质结构（图 2c）。该神经网络预测结果包含主链扭转角及残基间的成对距离；距离预测相较于接触预测能提供更具体的结构信息，并为神经网络赋予更丰富的训练信号。通过联合预测多个距离值，网络可传递既符合共变规律、又兼顾局部结构及邻近残基特性的距离信息。这些预测概率分布可整合构建出简洁且具原理性的蛋白质特异性势能函数。我们进一步证明：借助梯度下降法，仅需有限次采样，即可轻松寻得能最小化该蛋白质特异性势能函数的扭转角集合。我们还证明，整个蛋白质链可被同步优化，从而无需将长链蛋白质分割为若干假设结构域——这些结构域通常按常规做法分别进行独立建模（参见“方法”部分）。

AlphaFold的核心组件是一个卷积神经网络，该网络基于PDB结构训练，用于预测蛋白质中成对残基ij的C_β原子间的距离d_{ij}。基于蛋白质的氨基酸序列表示S以及从该序列的多序列比对（S）中提取的特征，该网络——其结构与用于图像识别任务的网络相似[29]——可为L× L距离矩阵中任意64×64区域内的每对ij预测一个离散概率分布$P(d_{ij}|S$，MSA(S))，如图**2b**所示。通过整合这些预测结果，构建覆盖整个距离图谱的完整距离分布预测集，称为距离分布图（源自距离直方图）。针对某CASP 蛋白T0955的典型距离分布图预测结果如图3c，d所示。该分布的众数（图**3c**）可与真实距离值（图**3b**）高度吻合。与单个残基（残基29）的所有距离分布示例如图**3d**所示。我们发现，距离预测结果与残基间真实距离高度吻合（图**3e**）。此外，该网络还能建模其预测结果中的不确定性（图**3f**）。当预测分布的标准差较低时，预测结果更为精确——这一现象在图**3d**中亦清晰可见：距离分布中置信度更高的预测区间（分布峰值更高且标准差更小）往往更准确，且真实距离更靠近该峰值；而分布范围更广、置信度较低的预测区间，即使真实距离未靠近峰值，仍会对正确值赋予概率分布。距离预测的高精度，以及由此衍生的接触预测精度（图**1c**），源于神经网络设计及其训练过程中的多因素协同作用：数据增强、特征表示、辅助损失函数、图像裁剪与数据整理（详见“方法”部分）。

为生成符合距离预测的结构，我们通过将样条函数拟合至负对数概率，并对所有残基对求和，构建了一个平滑势能函数V_{distance}（详见方法部分）。我们利用所有残基的主链二面角（φ，ψ）对蛋白质结构进

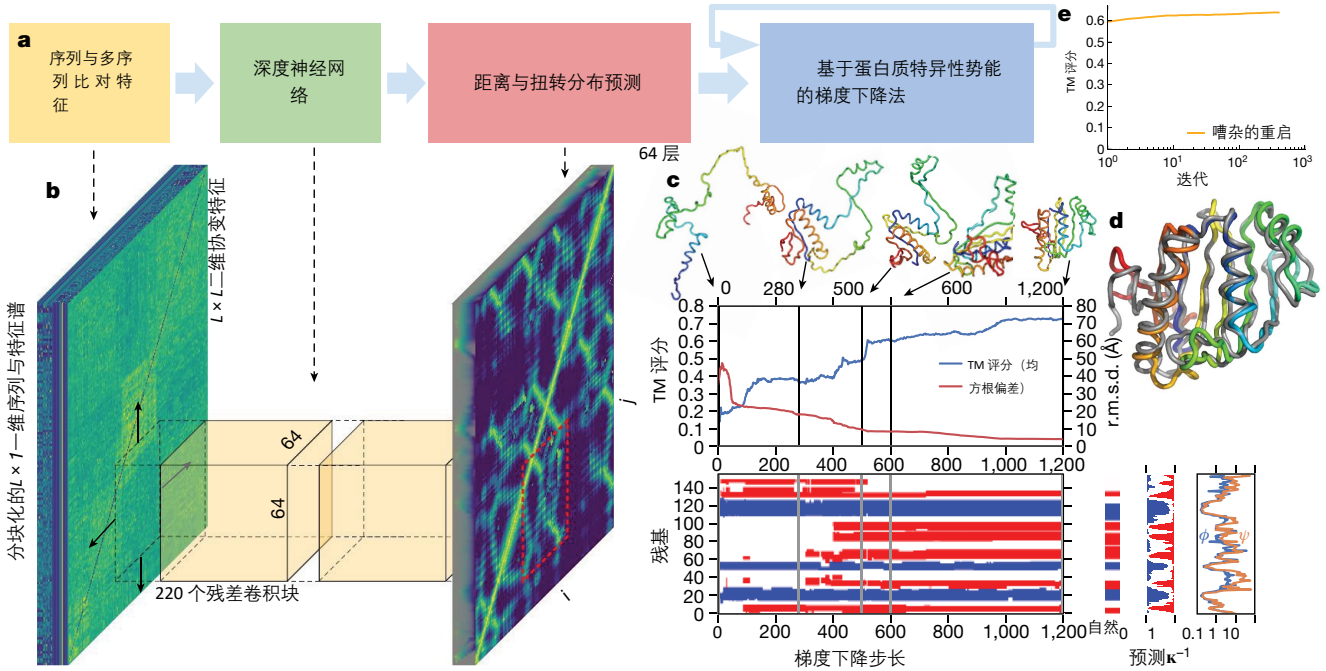


图 2 | CASP13 靶标 T0986s2 的折叠过程示意图。CASP 靶标 T0986s2，*L*= 155，PDB：6N9V。**a**，结构预测的步骤。**b**，神经网络基于 MSA 特征预测整个 L × *L* *距离图*，并为 64 × 64 残基区域分别累积预测结果。**c**，展示了一次梯度下降迭代过程（1,200 步），将 TM 分数与均方根偏差（r.m.s.d.）随步数变化绘制成图，并附结构的五幅快照。同时展示了二级结构（源自 SST [33]）（螺旋为蓝色，链段为红色）、天然二级结构（Nat.）、神经网络生成的二级结构预测概率，以及扭转角预测的不确定性（以拟合φ与ψ预测值的冯·米塞斯分布的κ^{-1}表示）。尽管梯度下降的每一步均贪婪地降低势能，但仍可实现大幅全局构象变化，最终形成紧密堆积的分子链。**d**，最终首次提交结果与天然结构（灰色）叠加显示。**e**，针对每个靶标梯度下降迭代次数，将最低势能结构的平均 TM 分数（基于测试集，*n*= 377）以对数尺度呈现。

行参数化，并构建一个可微分的蛋白质几何模型 x=$G(\varphi, \psi)$，用以计算所有残基i的C_β坐标$\mathbf{x}_i$，进而推导出每个结构中的残基间距离$d_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|$，并将$V_{\text{distance}}$表示为$\varphi$与$\psi$的函数。对于具有$L$*个残基*的蛋白质，该势能函数会累加来自边缘分布预测的L^2个项；为校正先验分布的过度表征，我们在对数域中从距离势能函数中减去参考分布[30]。参考分布用于建模与蛋白质序列无关的距离分布$P(d_{ij}|\text{length})$，其计算方式是在相同结构上训练一个精简版的距离预测神经网络，且不输入序列或MSA特征。接触预测网络的独立输出头则用于预测主链扭转角的离散概率分布$P(\varphi_i,\psi_i|S$，MSA(S))。在拟合阿冯·米塞斯分布后，将该分布用于在势能函数中添加平滑扭转建模项V_{torsion}。最后，为防止空间位阻冲突，我们将Rosetta [9]的$V_{\text{score2_smooth score}}$引入势能函数——因其包含范德华项。我们对势能函数中的三个项均采用乘性权重；但无论权重如何组合，其性能均未显著优于等权重分配方案。

由于组合势能V_{total}（φ，ψ）中的每一项都是（φ，ψ）的可微函数，因此可通过梯度下降法针对这些变量进行优化。此处我们采用 L-BFGS [31]。结构初始化时，从P（φ_i, $\psi_i|S$，MSA（S））中采样扭转角值。图 2c 展示了一条最小化该势能的单条梯度下降轨迹，揭示了这种贪婪优化过程如何逐步提升精度并引发大规模构象变化。二级结构部分由基于预测扭转角分布的初始化设定。整体精度（TM 分数）迅速提升，经过数百步梯度下降后，结构精度已收敛至该势能的局部最优解。

我们基于采样初始值重复优化过程，从而获得一组低势能结构池；随后从该池中进一步采样新的结构初始值，并引入主链扭转角噪声（即“含噪声重启”），进而扩充该结构池。仅需数百轮迭代后，优化过程即收敛，此时选取势能最低的结构作为最佳候选结构。图 2 展示了梯度下降算法多次重启过程中最佳得分结构的精度演变趋势，结果表明仅需数次迭代即可实现优化收敛。与仅基于预测扭转角分布持续采样相比，含噪声重启可发现 TM 分数略高的结构（在测试集上，平均值分别为 0.641 与 0.636，详见扩展数据图 4）。

图**4a**显示，距离图精度（采用距离图的局部距离差异测试lDDT_{12}衡量；详见“方法”部分）与最终实现结构的TM评分高度相关。图4b展示了改变势能构建方式的影响：完全移除距离势能时，TM评分为0.266；将距离图表征的分辨率降至六个区间以下（通过对相邻区间取平均），会导致TM评分下降；移除扭转势能、参考校正或$V_{\text{score2_smooth}}$均仅使精度轻微降低。最后一步“松弛”处理（将侧链堆积与梯度下降交替进行）采用Rosetta [9]，结合Talaris2014势能与经参考校正的距离势能样条拟合，引入侧链原子坐标后，TM评分平均小幅提升0.007。

我们证明，一个精心设计的深度学习系统能够准确预测残基间距离，并可用于构建表征蛋白质结构的蛋白质特异性势能函数。此外，我们还证明该势能函数可通过梯度下降法进行优化，从而实现精确的结构预测。

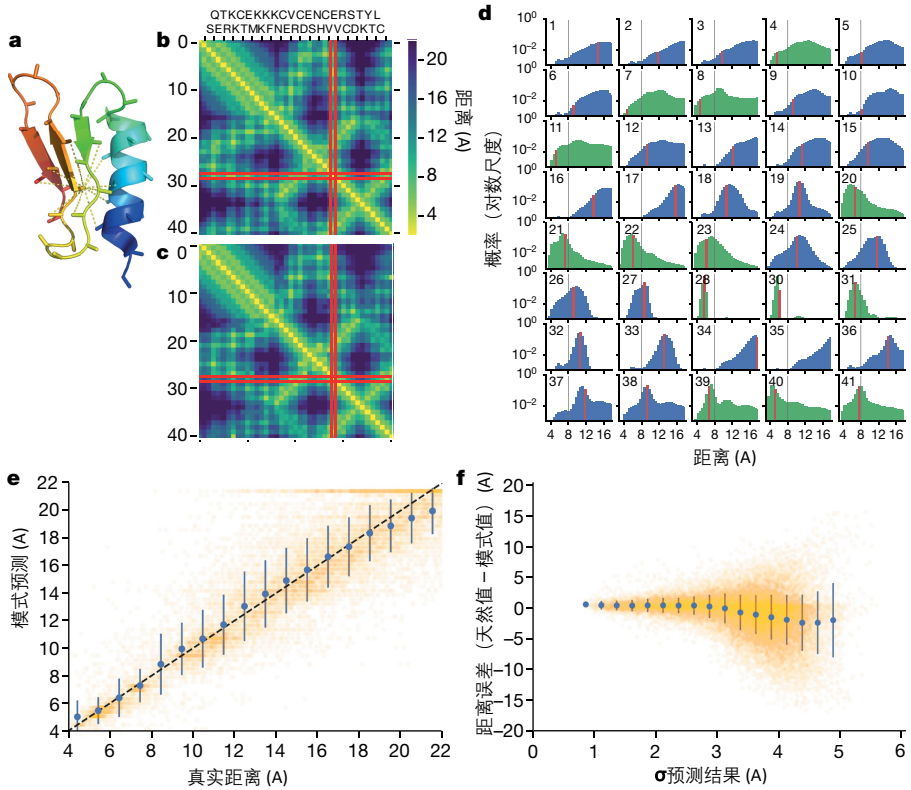


图 3 | 预测距离分布与真实距离的对比。

a–d，CASP 目标 T0955，*L*=41，PDB 5W9F。**a**，天然结构图显示残基 29 的from the C_β原子与其他原子间距离小于 8 Å 的情况。**b**、**c**，天然残基间距离（**b**）及距离预测分布模式（**c**），突出显示残基 29。**d**，残基 29 与其余所有残基间距离的预测概率分布图。对应天然距离的区间以红色标出，8 Å 阈值以黑色绘制。真实接触对的分布以绿色绘制，非接触对以蓝色绘制。**e**、**f**，CASP 目标 T0990，*L*=552，PDB 6N9V。**e**，所有残基对中预测距离与真实距离的众数分布图（仅包含距离 ≤22 Å 的残基对，排除标准差 > 3.5 Å 的分布；*n*= 28,678）。数据为按 1 Å 区间计算的均值 ± 标准差。**f**，众数距离预测误差与距离分布标准差的关系图（仅包含天然距离 > 22 Å 的残基对；*n*= 61,872）。数据以 0.25 Å 区间呈现，显示为均值 ± 标准差。T0990 的真实距离矩阵与距离分布图见扩展数据图 2b、c。

尽管FM预测结果的准确性极少接近实验结构数据，但CASP13评估表明：AlphaFold系统已实现了前所未有的FM预测精度；且该FM方法无需使用模板即可达到与模板建模方法相当的性能，并开始具备提供生物学洞见所需的精度（参见“方法”部分）。我们希望我们所开发的这些方法

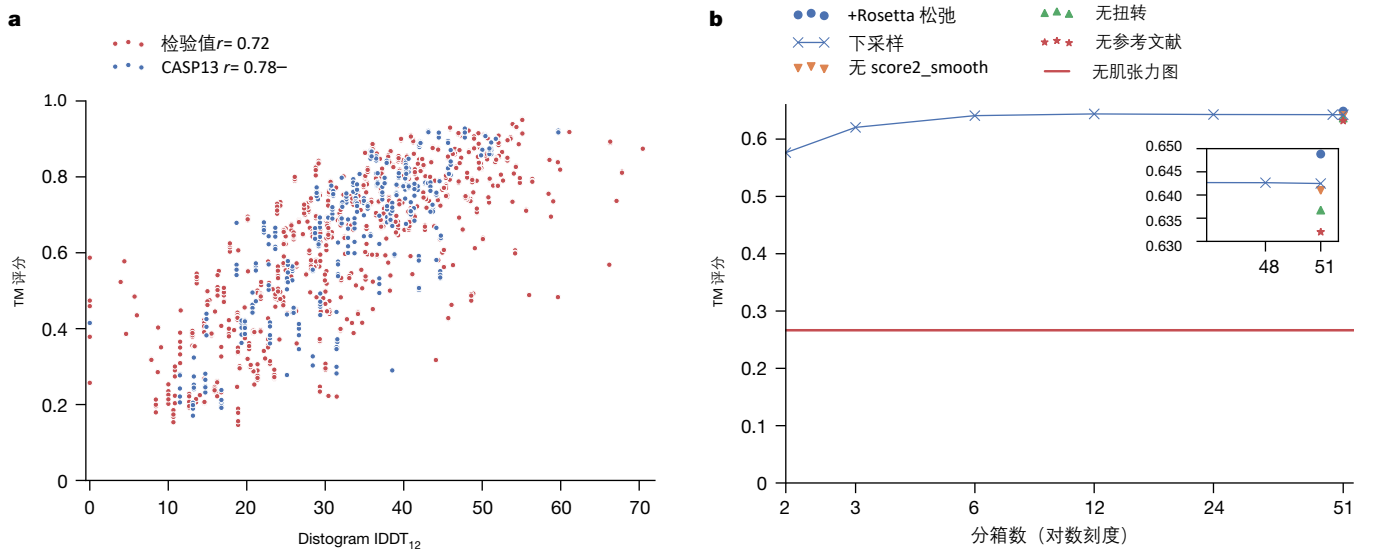


图 4 | TM 分数与距离分布图准确度的对比，以及 TM 分数对势能不同分量的依赖性。

a，TM 分数与distogram lDDT$_{12}$的对比图，并标注皮尔逊相关系数；数据涵盖 CASP13（*n*= 500：所有结构域使用 500 个候选结构，排除 T0999）及测试集（*n*= 377）数据集。**b**，测试集（*n*= 377）上的平均 TM 分数与在降采样距离图时所使用的直方图分箱数之间的关系，并与移除势能函数的不同组分或添加 Rosetta 弛豫处理的情况进行对比。

所述方法可进一步开发并应用于惠及蛋白质科学的所有领域，从而为未知结构的蛋白质序列提供更精准的预测。

在线内容

所有方法、补充参考文献、《自然·研究》期刊报告摘要、原始数据、扩展数据、补充信息、致谢、同行评审信息；作者贡献及利益冲突详情；以及数据与代码可用性声明，均可在以下网址获取：https://doi.org/10.1038/s41586-019-1923-7。

1. Dill，K. A.，Ozkan，S. B.，Shell，M. S. & Weikl，T. R. 蛋白质折叠问题。*Annu. Rev. Biophys.***37**，289–316 (2008)。
2. Dill，K. A. & MacCallum，J. L.《蛋白质折叠问题：*50年回顾*》，**338**，1042–1046（2012）。
3. Schaarschmidt，J.，Monastyrskyy，B.，Kryshtafovych，A. & Bonvin，A. M. J. J. CASP12 中接触预测的评估：共进化与深度学习的成熟应用。*Proteins* **86**，51–66 (2018)。
4. Kirkwood，J.《流体混合物的统计力学》。*J. Chem. Phys.***3**，300–313 (1935)。
5. Kryshtafovych，A.，Schwede，T.，Topf，M.，Fidelis，K. & Moult，J.《蛋白质结构预测方法批判性评估（CASP）——第13轮》。*Proteins* **87**，1011–1020 (2019)。
6. Zhang，Y. & Skolnick，J. 用于蛋白质结构模板质量自动评估的评分函数。*Proteins* **57**，702–710 (2004)。
7. Zhang，Y. 蛋白质结构预测：何时具有实用价值？*Curr. Opin. Struct. Biol.***19**，145–155 (2009).
8. Senior，A. W. 等。在第 13 届蛋白质结构预测关键评估（CASP13）中采用多种深度神经网络进行蛋白质结构预测。*Proteins* **87**，1141–1148 (2019)。
9. Das，R. & Baker，D. 使用 Rosetta 进行大分子建模。*Annu. Rev. Biochem.***77**，363–382 (2008)。
10. Jones，D. T. 利用 fragfold 预测新型蛋白质折叠结构。*Proteins* **45**，127–132 (2001)。
11. 张 C.、Mortuza S. M.、何 B.、王 Y. 及张 Y.。基于模板与无模板的 I- TASSER 及夸克流程建模：利用 CASP12 中的预测接触图。*Proteins* **86**，136–151 (2018)。
12. Kirkpatrick，S.，Gelatt，C. D. Jr & Vecchi，M. P. 基于模拟退火法的优化。《*科学*》**220**，671–680 (1983)。
13. Berman, H. M.等.《蛋白质数据银行》.《*核酸研究*》.**28**,235–242(2000).
14. Altschuh，D.，Lesk，A. M.，Bloomer，A. C. & Klug，A. 与烟草花叶病毒相关的病毒中协同氨基酸替换与功能的相关性。*J. Mol. Biol.***193**，693–707 (1987)。
15. Ovchinnikov，S.，Kamisetty，H. & Baker，D. 利用进化信息对蛋白质界面间的残基-残基相互作用进行稳健且准确的预测。*eLife* **3**，e02030 (2014)。
16. Seemayer，S.，Gruber，M. & Soding，J. CCMpred——基于相关突变快速且精准地预测蛋白质残基-残基接触。*Bioinformatics* **30**，3128–3130 (2014)。
17. Morcos, F.等人.残基共进化直接耦合分析可捕捉跨多个蛋白质家族的天然接触.*Proc. Natl Acad. Sci. USA* **108**,E1293–E1301 (2011).
18. Jones，D. T.，Buchan，D. W.，Cozzetto，D. & Pontil，M. PSICOV：利用稀疏逆协方差估计在大规模多序列比对中精确预测结构接触。《*生物信息学*》**28**，184–190（2012）。
19. Skwark，M. J.，Raimondi，D.，Michel，M. & Elofsson，A. 利用识别类蛋白质接触模式改进接触预测。*PLOS Comput. Biol.***10**，e1003889 (2014)。
20. Jones，D. T.，Singh，T.，Kosciolek，T. & Tetchner，S. MetaPSICOV：整合共进化分析用于精确预测蛋白质中接触位点及长程氢键的方法。《*生物信息学*》**31**，999–1006 (2015)。
21. 王 S.、孙 S.、李 Z.、张 R. 及徐 J.。基于超深度学习模型的蛋白质接触图精准从头预测。*PLOS Comput. Biol.***13**，e1005324 (2017)。
22. Jones，D. T. & Kandathil，S. M. 利用全量数据实现蛋白质接触预测的高精度卷积神经网络与极简序列特征。《*生物信息学*》**34**，3308–3315 (2018)。
23. Ovchinnikov, S.等人通过将共进化信息整合至 Rosetta 中,提升了 CASP11 中的从头结构预测性能.*Proteins* **84**,67–75 (2016).
24. Aszodi，A. & Taylor，W. R. 基于多序列比对估算多肽α-碳原子间距。*J. Math. Chem.***17**，167–184 (1995).
25. Zhao，F. & Xu，J. 一种用于蛋白质结构与功能研究的位点特异性距离依赖性统计势。*Structure* **20**，1118–1126 (2012)。
26. Xu，J. & Wang，S. 基于距离的蛋白质结构预测在 CASP13 中的深度学习分析。*Proteins* **87**，1069–1081 (2019)。
27. Aszodi，A.，Gradwell，M. J. & Taylor，W. R. 基于少量距离约束的全局折叠结构确定。*J. Mol. Biol.***251**，308–326 (1995)。
28. Kandathil，S. M.，Greener，J. G. & Jones，D. T. 使用 DeepMetaPSICOV 预测 CASP13 中的残基间接触。*Proteins* **87**，1092–1099 (2019)。
29. He，K.，Zhang，X.，Ren，S. & Sun，J. 基于深度残差学习的图像识别。载于*Proc. IEEE Computer Vision 与 Pattern Recognition 会议* 770–778 (2016)。
30. Simons，K. T.，Kooperberg，C.，Huang，E. & Baker，D. 利用模拟退火与贝叶斯评分函数，基于具有相似局部序列的片段组装蛋白质三级结构。*J. Mol. Biol.***268**，209–225 (1997).
31. Liu，D. C. & Nocedal，J. 关于大规模优化中的有限记忆 BFGS 方法。*Math. Program.***45**，503–528 (1989).
32. Li，Y.，Zhang，C.，Bell，E. W.，Yu，D.-J. & Zhang，Y. 利用深度残差神经网络整合多种原始共进化特征，用于 CASP13 接触图预测。*蛋白质* **87**，1082–1091 (2019)。
33. Konagurthu，A. S.，Lesk，A. M. & Allison，L. 基于蛋白质坐标数据推导二级结构的最小消息长度推断。*Bioinformatics* **28**，i97–i105 (2012)。

出版者注Springer Nature 对于已发表地图中的司法管辖权主张及机构隶属关系保持中立立场。

© 作者，根据与 Springer Nature Limited 签订的独家许可协议，2020 年

方法

扩展数据图 1a 展示了 MSA 构建、特征提取、距离预测、势能构建及结构实现中所涉及的步骤。

工具

以下工具及数据集版本被用于CASP系统及后续实验：PDB（2018年3月15日版）；CATH（2018年3月16日版）；基于v.3.0-beta.3版本的HHblits（三次迭代，E=1×10 $^{-3}$）；HHpred网络服务器；Uniclust30（2017年10月版）；PSI-blast v.2.6.0 nr数据集（截至2017年12月15日）（三次迭代，E=1×10 $^{-3}$）；SST 网络服务器（2019 年 3 月版）；BioPython v.1.65；Rosetta v.3.5；用于结构可视化的PyMol 2.2.0；TM-align（2016年5月21日版）。

数据

我们的模型均基于从 PDB [13]中提取的结构进行训练。我们通过利用 CATH [34]中 35% 序列相似性的聚类代表样本，提取非冗余结构域。由此共生成 31,247 个结构域，并将其划分为训练集与测试集（分别包含 29,427 个与 1,820 个蛋白质），确保来自同一同源超家族（CATH 分类中的 H 级）的所有结构域均被归入同一划分组中。此外，来自 CASP 11 与 CASP12 的 FM 结构域所属 CATH 超家族亦被排除在训练集之外。从测试集中，我们按同源超家族随机选取单个结构域，最终构建出用于本文结果展示的 377 个结构域子集。需注意的是，该子集的预测准确率高于 CASP13 测试集。

CASP13 的提交结果取自 CASP13 结果页面，并额外展示了针对“所有组别”链的 CASP13 数据集结果，这些结果基于 CASP13 PDB 文件，采用 CASP 结构域定义进行评分。接触预测准确率重新计算自第 032 和 498 组的提交结果（以 RR 文件形式），并与 AlphaFold 在 CASP13 提交中使用的全程预测图进行比较。接触预测概率则通过累加每个分布中距离小于 8 Å 区域的概率质量，从全程预测图中获取。

对于每个训练序列，我们使用 HHblits [36]在 Uniclust30 [35]数据集中搜索并比对与之相似的蛋白质序列，随后利用返回的多序列比对（MSA）生成谱特征——包括每个残基的位置特异性替换概率，以及共变异特征——后者是与 CCMpred [16]类似的、通过正则化伪似然训练得到的 Potts 模型的参数。CCMPred 使用参数的 Frobenius 范数，而我们对每个残基对ij同时将该范数（1 个特征）与原始参数（484 个特征）输入网络。此外，我们还向网络提供明确表征 MSA 中空位与缺失的特征。为使网络更擅长对浅层 MSA 进行预测，并作为数据增强的一种手段，我们在计算基于 MSA 的特征前，从 HHblits MSA 中随机抽取半数序列作为样本。每个结构域均包含 10 个此类样本。我们另使用 PSI-blast [37]提取额外的谱特征。

距离预测神经网络采用以下输入特征进行训练（各特征数量如括号内所示）。

- HHblits 比对数（标量）。
- 序列长度特征：1-热编码氨基酸类型（21个特征）；谱特征：PSI-blast（21个特征）、HHblits谱（22个特征）、无间隙谱（21个特征）、HHblits偏置值、HMM谱（30个特征）、Potts模型偏置值（22个特征）；缺失概率（1个特征）；残基索引（残基编号的整数索引，对于多片段结构域则为连续编号，以5位最不重要位及一个标量编码）。
- 序列长度平方特征：Potts 模型参数（484 个特征，采用 Nesterov 动量 0.99 进行 500 次梯度下降拟合，未进行序列重加权）；Frobenius 范数（1 个特征）；间隔矩阵（1 个特征）。

z分数取自 CASP13 评审专家的结果（http://predictioncenter.org/casp13/zscores_final.cgi？formula=assessors）。

距离图预测。残基间距离由深度神经网络预测。该网络架构为深度二维扩张卷积残差网络。此前，曾使用过一种二维残差网络，其前接一维嵌入层以进行接触预测[21]。我们的网络全程采用二维结构，并包含220个残差块[29]，这些残差块均配备扩张卷积层[38]。每个残差块（如扩展数据图1b所示）由一系列神经网络层[39]构成，这些层交替包含三个批归一化层、两个1×1投影层、一个3×3扩张卷积层以及指数线性单元（ELU）[40]非线性激活函数。相邻层依次采用1、2、4、8像素的扩张尺寸，以加速信息在裁剪区域内的传播。对于最后一层，采用了位置特定偏置，其中偏置值按残基偏移量（上限为32）及分箱编号进行索引。

该网络采用随机梯度下降法，并使用交叉熵损失函数进行训练。其目标是对残基中C_β原子（或甘氨酸中的C_α原子）之间的距离进行量化。我们将2–22 Å的区间划分为64个等宽区间。网络的输入是一个二维特征数组，其中每个i，j特征均由i与j对应的一维特征，以及i，j对应的二维特征拼接而成。

每个独立训练轮均采用早停策略进行交叉验证，并使用 27 个 CASP 11 FM 领域作为验证集；模型则通过基于 27 个 CASP12 FM 领域的交叉验证进行筛选。

神经网络超参数

- 7 组，每组包含 4 个块，每块具有 256 个通道，依次循环使用 1、2、4、8 倍放大倍率。
- 48 组，每组包含 4 个区块，共 128 个通道，依次循环使用扩张值 1、2、4、8。
- 优化：同步随机梯度下降
- 批大小：在 8 个 GPU 工作节点上，每个节点执行 4 个采样的批处理。
- 0.85 的丢弃保留概率。
- 非线性： ELU 。
- 学习率：0.06。
- 辅助损失权重：二级结构：0.005；可及表面积：0.001。在运行 100,000 步后，这些辅助损失权重被衰减至原值的 1/10。
- 学习率在 150,000、200,000、250,000 及 350,000 步时衰减 50%。
- 训练时间：完成 600,000 步约需 5 天。

裁剪后的距离矩阵。为限制内存占用并避免过拟合，该网络始终在距离矩阵的 64×64 区域上进行训练与测试——即选取 64 个连续残基与另一组 64 个连续残基之间的成对距离。对于每个训练域，将整个距离矩阵划分为互不重叠的 64×64 裁剪区域。通过训练非对角线裁剪区域，可建模出间距超过 64 个残基的残基间的相互作用。每个裁剪区域包含代表两个 64 残基片段相邻分布的距离矩阵。既往研究[22]已表明，接触预测仅需有限上下文窗口。需注意的是：靠近对角线区域（i=j）的距离预测编码了蛋白质局部结构的预测信息；对于任意裁剪区域，其距离值均由该裁剪区域内 i 与 j 区间所代表的两个片段的局部结构决定。利用与i及j范围均对应的对角线方向二维输入特征来增强输入数据，可为预测每个片段的结构以及片段间的距离提供额外信息。可以看出，若片段结构能被准确预测（例如，若片段被可靠地预测为螺旋或折叠

结构），则对片段间单一接触点的预测将强力约束所有其他片段对之间的距离。

在训练过程中，每次使用某个域时对其裁剪区域的偏移量进行随机化处理，可形成一种数据增强方式：单个蛋白质即可生成数千个不同的训练样本。若进一步向原子坐标添加与真实分辨率成正比的噪声，则目标距离会产生变异，从而进一步增强该效果。数据增强技术（MSA 子采样与坐标噪声）结合 dropout [41]，可有效防止网络对训练数据过拟合。

为预测所有 L × *L*残基对的距离分布，本研究将多个 64 × 64 的网格图进行组合。为避免边缘效应，我们采用不同偏移量生成若干此类网格图，并将它们进行平均处理，同时对网格图中心区域的预测结果赋予更高权重。为进一步提升精度，我们还将四个独立训练模型（各采用略有不同的超参数）的预测结果进行平均。扩展数据图 2b、c 展示了针对三结构域 CASP13 靶标 T0990 的真实距离与距离图预测结果的众数示例。

由于该网络具备丰富的表征能力，能够同时整合MSA的轮廓特征与共变特征，我们认为该网络可直接用于预测二级结构。通过对网络倒数第二层的二维激活值分别在*i* 与*j*方向上分别进行均值池化与最大池化操作，我们在网络中附加了一个一维输出头，用于根据 DSSP [42]的方法，为每个残基在i与j方向上预测八类二级结构标签。Q3预测（区分三种螺旋/折叠/卷曲类别）的最终准确率达到84%，与当前最先进预测方法[43]相当。每个残基的相对可及表面积（ASA）亦可被预测。

一维聚合激活值被用于预测边缘拉马钱德兰分布$P(\varphi_i, \psi_i|S$，MSA (S))，针对每个残基独立计算，将其近似为以10°为间隔的离散概率分布（共1,296个区间）。在CASP13实验中，我们采用了一个专门用于预测距离图、二级结构及ASA值的网络所生成的距离图；而扭转角预测则取自第二个类似网络——该网络同时用于预测距离图、二级结构、ASA值及扭转角，且前者的验证更为充分。

扩展数据图 3b 表明，distogram 准确性的一个重要因素（此前在接触预测系统中亦已发现）is N_{eff}，即多序列比对（MSA）中有效序列数 [20]。该数值指在 MSA 中获取的序列数（在 62% 序列一致性阈值下剔除冗余序列），随后将其除以目标蛋白中的残基数，用以表征 MSA 中共变信息的丰富程度。

距离势能。距离分布图的概率值是在离散距离区间内估算得出的；因此，为构建一个可微分的势能函数，该分布采用三次样条函数进行插值处理。由于最终区间整合了所有超过 22 Å 距离区间的概率质量，且较大距离的预测精度较低，故势能函数仅拟合至 18 Å 范围内（该阈值由交叉验证确定），此后则采用恒定值进行外推。扩展数据图 3c（下图）展示了改变距离直方图分辨率对结构精度的影响。

为预测参考分布，我们在同一数据集上训练一个类似的模型。该参考分布并不以序列为条件，但为了考虑我们预测距离时所涉及的原子，我们仍提供一个二元特征$\delta_{\alpha\beta}$，用以指示该残基是否为甘氨酸（C_α 原子）或非甘氨酸（C_β），以及蛋白质的总长度。

距离势能由所有残基对 i，*j*的距离的负对数似然值之和构建而成（见补充材料公式 (1)）。若引入参考状态，则该势能即转化为在全条件模型与背景模型下，各距离对应的对数似然比（见补充材料公式 (2)）。

扭转量被建模为在预测的扭转分布下取负对数似然值的变量。由于我们已获得各边缘分布的预测结果——且每个边缘分布均可能呈现多峰特性——因此难以对扭转量进行联合优化。为整合所有概率质量，尽管会以牺牲多峰分布的建模保真度为代价，我们仍对边缘分布预测结果拟合了一个单峰 von Mises 分布。该势能函数则对所有残基 i 求和（见补充材料公式 (3)）。

最后，为防止空间位阻，本研究采用 Rosetta 的$V_{\text{score2_smooth}}$引入了范德华项。扩展数据图 3c（上图）展示了势能函数中不同项对结构预测准确性的影响。

通过梯度下降法实现结构优化。为实现能最小化所构建势能的结构，我们构建了理想蛋白质主链几何结构的可微分模型，将主链原子坐标表示为扭转角（φ、ψ）的函数：$\mathbf{x}=G(\varphi, \psi)$。待最小化的完整势能由距离项、扭转角项及score2_smooth项之和构成（见补充材料公式 (4)）。尽管无法保证这些势能具有同等量级，但我们仍为各项引入了缩放参数，并基于CASP12 FM结构域数据集通过交叉验证确定参数值。实践中，对所有项赋予相同权重可获得最佳结果。

由于V_{total}中的每一项均对扭转角可微，给定一组初始扭转角φ、ψ（这些扭转角可从预测的扭转边缘分布中采样获得），我们便可使用梯度下降算法（例如L- BFGS [31]）来最小化V_{total}。优化后的结构取决于初始条件，因此我们会使用不同初始化方式重复优化多次。我们维护一个包含20个势能最低的结构的池子；一旦该池子填满，我们就从那些在骨架扭转角上添加30°噪声的结构中初始化90%的轨迹（其余10%仍从预测的扭转分布中采样）。在CASP13中，我们为每条链进行了5,000次优化运行。图2c展示了每个蛋白质的TM评分随重启次数的变化趋势。由于较长链的优化耗时更长，此计算任务被分配至(50 +*L*)/2个并行工作节点上完成。扩展数据图 4 展示了随计算时间变化的相似曲线，其中始终将从预测的边缘分布中起始采样与从既往结构库中重新起始采样进行对比。

准确性。我们将最终结构与伦理实验确定的结构进行比较，采用TM score、GDT_TS（全局距离测试，总分[44]）及r.m.s.d.等指标来评估其准确性。上述所有准确性指标均要求候选结构与实验结构之间进行几何对齐。另一种无需对齐的准确性评估方法是lDDT [45]，该指标统计在候选结构中、序列偏移量≥ *rresidues*时，天然构象中成对distances D_{ij}小于15 Å且与真实值差异在给定容差范围内的比例（as d_{ij}），并对0.5、1、2及4 Å的容差值分别取平均值（无需立体化学验证），具体如补充材料公式(5)所示。

由于距离图可预测成对距离，我们可以引入 lDDT DLDDT ——一种与 lDDT 类似的度量指标，它直接由距离图的概率计算得出，如补充公式(6)所示。由于序列中邻近残基之间的距离通常较短，更容易预测，且在决定整体折叠拓扑结构方面并非关键因素，因此我们设定 r = 12，仅考虑序列间隔 ≥12 的残基之间的距离。由于我们预测的是C_β距离，在本研究中，我们均使用C_β距离来计算 lDDT 和 DLDDT 。扩展数据图 3 显示，DLDDT_{12}与实际结构的lDDT_{12}具有高度相关性（对于 CASP 13，皮尔逊相关系数 r = 0.92）。

未进行结构域分割的全链分析。若对长度为L的蛋白质采用每个残基两个扭转角进行参数化，则结构空间的维度将随 2L 增长；因此，对大尺寸蛋白质的结构搜索难度显著增加。传统上，该问题可通过将较长蛋白质链分割为若干片段——称为结构域——并分别进行独立折叠来解决。然而，仅凭序列信息进行结构域分割本身即存在困难且易出错。在本研究中，我们摒弃了结构域分割策略，而是对完整链进行折叠分析。通常，多序列比对（MSA）基于给定的结构域分割构建；而本研究采用滑动窗口法，通过计算全链 MSA 来预测基准全序列距离图。随后，我们对该链的子序列分别计算 MSA，窗口大小依次为 64、128 和 256，偏移量取 64 的整数倍。每个 MSA 均生成一个独立距离图，该距离图对应于全链距离图的非对角方阵区域。最后，我们将所有这些距离图按 MSA 中序列数量加权求平均，从而获得一个更精确的全链平均距离图——该图在可获取大量比对结果的区域具有更高准确性。在 CASP13 评估中，完整链均采用 Rosetta 软件进行弛豫处理，所用势能为$V_{\text{Talaris2014}}+0.2\,V_{\text{distance}}$（权重由交叉验证确定），且所有系统的提交结果均基于该势能进行排序。

CASP13 的结果。对于 CASP13，五项 AlphaFold 提交结果均来自三个不同的系统，且所有系统均采用了基于神经网络距离预测的势能函数。未在此详述的系统已在另一篇论文[8]中予以说明。在 T0975 之前，使用了基于模拟退火与片段组装（并采用 40 区间距离分布）的两种系统；从 T0975 起，则采用新训练的 64 区间距离分布预测结果，结构生成分别通过本文所述的梯度下降系统（三次独立运行）及其中一种片段组装系统（五次独立运行）完成。五项提交结果均从这八种结构（每次独立运行中生成的势能最低结构）中选出，其中首次提交（首位）为梯度下降法生成的势能最低结构；其余四项提交结果为其他四个最优结构，若第 2、3 或 4 位均未选出结构，则第五项提交为梯度下降法生成的结构。T0999 的所有提交结果均通过梯度下降法生成。扩展数据图 5a 展示了每个提交案例所采用的方法，并与 T0975 之前针对目标仅进行一次梯度下降法运行所生成的“回补”结构进行了对比。扩展数据图 5b 表明，在 CASP 后续阶段采用的梯度下降法在每一类别中的表现均优于片段组装法。扩展数据图 5c 将 AlphaFold 对 FM 及 FM/TBM 结构域的提交结果与次优组 322 的准确性进行了比较。CASP13 FM 的评估人员采用专家视觉检查[46]为每个目标筛选最佳提交结果，发现 AlphaFold 产生的最佳模型数量几乎是次优组的两倍。

AlphaFold 预测结果的生物学相关性。预测结构具有广泛的应用场景，且每种场景对准确性的要求各不相同——从整体理解蛋白质折叠构象，到解析结合区域中侧链的详细构型。仅凭接触预测即可为生物学研究提供重要线索[47]，例如将特定突变靶向引入以破坏蛋白质稳定性。图1c及扩展数据图 2a 表明，AlphaFold 的接触预测准确度已超越当前最先进预测方法。在扩展数据图 6–8 中，我们进一步展示了以下结果：AlphaFold 的精度提升有助于更精准地解析蛋白质功能（扩展数据图 6）；优化蛋白质-蛋白质相互作用的界面预测（扩展数据图 7）；改进结合口袋预测（扩展数据图 8）；以及提升晶体学中的分子置换成功率。

迄今为止，仅基于模板的预测方法能够提供最准确的预测结果。尽管 AlphaFold 无需使用模板即可匹配 TBM，且在某些情况下其性能优于其他方法（例如在 T0981-D5,72.8 GDT_TS 和 T0957s1-D2,88.0 GDT_TS 这两个 TBM 困难结构域中，AlphaFold 的排名第一模型比任何其他排名第一的提交结果均高出 12 GDT_TS），但其在 FM 靶标上的预测精度仍落后于 TBM 靶标，且对于困难结构的精细解析仍不可完全依赖。在对 CASP13 的 TBM 预测结果用于分子置换性能的评估中，另一项研究[48]指出，AlphaFold 的预测结果（原始坐标，不含 B 因子）所获得的对数似然增益略高于其他任何研究团队，这表明这些优化后的结构可辅助 X 射线晶体学中的相位测定。

距离图神经网络的解析。我们已经证明，深度距离预测神经网络能够实现高准确率，但我们仍希望探究该网络是如何得出其距离预测结果的——尤其是模型输入如何影响最终预测。这有助于深化我们对蛋白质折叠机制的理解，或为模型优化提供方向。然而，深度神经网络本质上是其输入的复杂非线性函数，因此这一归因问题具有难度、定义不充分，且已成为一项持续的研究课题。尽管如此，已有多种此类分析方法：在本研究中，我们采用集成梯度法[49]对已训练的距离图神经网络进行分析，以揭示影响网络对特定距离预测的输入特征分布。

在扩展数据图9中，展示了针对T0986s2中选定的I、J*输出对*，$_c|S^{I,J}_{i,j,c}|$的积分绝对梯度总和曲线图（定义见补充材料公式(7)–(9)）；而在扩展数据图10中，每个输出对的前10个重要归因输入对均显示于AlphaFold预测的顶级结构之上。这些归因图谱具有稀疏性且高度结构化，紧密反映了蛋白质的预测几何构象。对于所展示的四个接触对（1、2、3、5），所有最重要的归因对均位于该输出对之一或两者所属的二级结构内部或之间。在案例1中，螺旋残基以及螺旋两端延伸的链段间的连接均具有重要作用，这可能暗示螺旋结构承受着张力；在案例2中，所有最重要的残基对均连接同一对链段；而在案例3中，链段间连接对与链段残基的组合最为显著。在图 5 中，最重要的配对涉及邻近二级结构元件在链状结构与螺旋结构中的排布。对于非接触型配对（图 4），最重要的输入配对则是预测蛋白质结构中在几何位置上位于 I 与 J 之间的残基。此外，大多数具有高贡献度的输入配对本身均处于接触状态。

由于该网络的任务是预测空间几何结构，而输入端缺乏可用结构信息，这些相互作用模式表明：该网络正利用中间预测结果来发现关键相互作用，并将相关信息从相关残基中引导至最终预测的优化过程。

报告摘要

关于研究设计的更多信息，请参阅本文附带的《Nature Research 研究报告摘要》。

数据可用性

我们的训练集、验证集和测试集划分（CATH 领域代码）可从以下网址获取：://github.com/deepmind/deepmind-research/tree/master/alphafold_casp13。

本研究中使用的公开数据集版本如下：PDB 2018-03-15；CATH 2018-03-16；Uniclust30 2017-10；以及 PSI-blast nr 数据集（截至 2017 年 12 月 15 日）。

代码可用性

用于生成距离图、参考距离图及扭转预测神经网络的源代码，以及CASP13靶标的神经网络权重与输入数据，均可在https://github.com/deepmind/deepmind research/tree/master/alphafold_casp13处用于科研及非商业用途。我们在实验过程中使用了多个开源库，特别是HHblits [36]、PSI-blast [37]，以及机器学习框架TensorFlow（https://github.com/tensorflow/tensorflow）与TensorFlow库Sonnet（https://github.com/deepmind/sonnet）——后者提供了各模型组件的实现[50]。此外，我们还根据许可协议使用了Rosetta [9]。

34. Dawson, N. L.等.CATH:一种通过结构与序列预测蛋白质功能的扩展资源.*Nucleic Acids Res.***45**,D289–D295 (2017).
35. Mirdita, M.等.Uniclust:基于聚类及深度注释的蛋白质序列与比对数据库.*Nucleic Acids Res.***45**,D170–D176 (2017).
36. Remmert，M.，Biegert，A.，Hauser，A. & Soding，J. HHblits：超高速迭代算法基于 HMM–HMM 比对的蛋白质序列检索。*Nat. Methods* **9**，173–175 (2012).
37. Altschul, S. F.等人.Gapped blast 与 PSI-blast:新一代蛋白质数据库检索程序.*Nucleic Acids Res.***25**,3389–3402 (1997).
38. Yu，F. & Koltun，V. 基于扩张卷积的多尺度上下文聚合。预印本发布于*arXiv* https://arxiv.org/abs/1511.07122（2015）。
39. Oord, A. d.等.Wavenet:一种用于原始音频的生成模型.预印本发布于*arXiv* https://arxiv.org/abs/1609.03499(2016).
40. Clevert，D. -A.，Unterthiner，T. & Hochreiter，S. 基于指数线性单元（ELUs）的快速精准深度网络学习。预印本发布于*arXiv* https://arxiv.org/abs/1511.07289（2015）。
41. Srivastava，N.，Hinton，G.，Krizhevsky，A.，Sutskever，I. & Salakhutdinov，R. Dropout：一种防止神经网络过拟合的简单方法。*J. Mach. Learn. Res.***15**，1929–1958 (2014).
42. Kabsch，W. & Sander，C.《蛋白质二级结构词典：氢键与几何特征的模式识别》。*Biopolymers* **22**，2577–2637 (1983)。
43. Yang, Y.等.蛋白质二级结构预测领域六十五年来的漫长征程:最后的冲刺?*Briefings Bioinf.***19**,482–494 (2018).
44. Zemla，A.，Venclovas，C.，Moult，J. & Fidelis，K. CASP3 蛋白质结构预测的处理与分析。*Proteins* **37**，22–29 (1999)。
45. Mariani，V.，Biasini，M.，Barbato，A. & Schwede，T. lDDT：一种基于距离差异检验、用于比较蛋白质结构与模型的局部无叠加评分方法。*《生物信息学》* **29**，2722–2728 (2013)。
46. Abriata，L. A.，Tamo，G. E. & Dal Peraro，M. A. CASP13 中三级结构预测技术的又一次重大突破，为未来的评估工作指明了新方向。*Proteins* **87**，1100–1112 (2019)。
47. Kayikci, M.等.利用蛋白质接触图谱对非共价接触进行可视化与分析.*Nat. Struct. Mol. Biol.***25**,185–194 (2018).
48. Croll, T. I.等人在《CASP13》中对基于模板的建模方法进行了评估.*Proteins* **87**,1113–1127 (2019).
49. Sundararajan，M.，Taly，A. & Yan，Q. 深度网络的公理化归因方法。载于*《第34届国际机器学习会议论文集》* **第70卷**，第3319–3328页（2017）。
50. Abadi，M. 等人。Tensorflow：一个用于大规模机器学习的系统。载于*《第 12 届 USENIX 操作系统设计与实现研讨会论文集（OSDI 16）》*第 265–283 页（2016）。
51. Soding，J.，Biegert，A. & Lupas，A. N. 用于蛋白质同源检测与结构预测的 HHpred 交互式服务器。*Nucleic Acids Res.***33**，W244–W248 (2005).
52. Cong, Q.等.一种用于 CASP9 无自由能建模结构预测评估的自动方法.*《生物信息学》* **27**,3371–3378 (2011).
53. Zhang，Y. & Skolnick，J. TM-align：一种基于 TM-score 的蛋白质结构比对算法。*Nucleic Acids Res.***33**，2302–2309 (2005).
54. Tovchigrechko，A.，Wells，C. A. & Vakser，I. A. 蛋白质模型的对接。*Protein Sci.***11**，1888–1896 (2002)。
55. Audet, M.等.米索前列醇与分娩诱导剂前列腺素E_2受体结合的晶体结构.*Nat. Chem. Biol.***15**,11–17 (2019).

致谢我们感谢 C. Meyer 在论文撰写过程中提供的协助；感谢 B. Coppin、O. Vinyals、M. Barwinski、R. Sun、C. Elkin、P. Dolan、M. Lai 及 Y. Li 的贡献与支持；感谢 O. Ronneberger 审阅本论文；感谢 DeepMind 团队其余成员提供的支持；同时感谢 CASP13 组委会及提供结构数据的实验研究人员，他们的贡献为本研究评估提供了重要基础。

作者贡献R. E.、J.J.、J. K.、L.S.、A.W.S.、C.Q.、T.G.、A.Z.、A. B.、H. P. 及 K.S. 在 D.S.、K. K. 和 D. H. 的指导下设计并构建了 AlphaFold 系统。D.T.J. 就蛋白质结构预测方法提供了建议与指导。S. P. 参与了软件工程工作。S.C.、A.W.、R. N.、K. K. 及 D. H. 负责项目管理。J. K.、A.W.S.、T.G.、A. Z.、A. B.、R. E.、P.K. 及 J.J. 对论文中的 CASP 结果进行了分析。A.W.S. 与 J.K. 共同撰写论文，J.J.、R. E.、L.S.、T.G.、A. B.、A.Z.、D.T.J.、P. K.、K. K. 及 D. H. 亦参与撰稿。A.W.S. 担任团队负责人。

利益冲突A.W.S.、J. K.、T.G.、J.J.、L.S.、R. E.、H. P.、C.Q.、K.S.、A.Z. 及 A. B. 已提交与利用机器学习预测蛋白质结构相关的临时专利申请。其余作者声明无利益冲突。

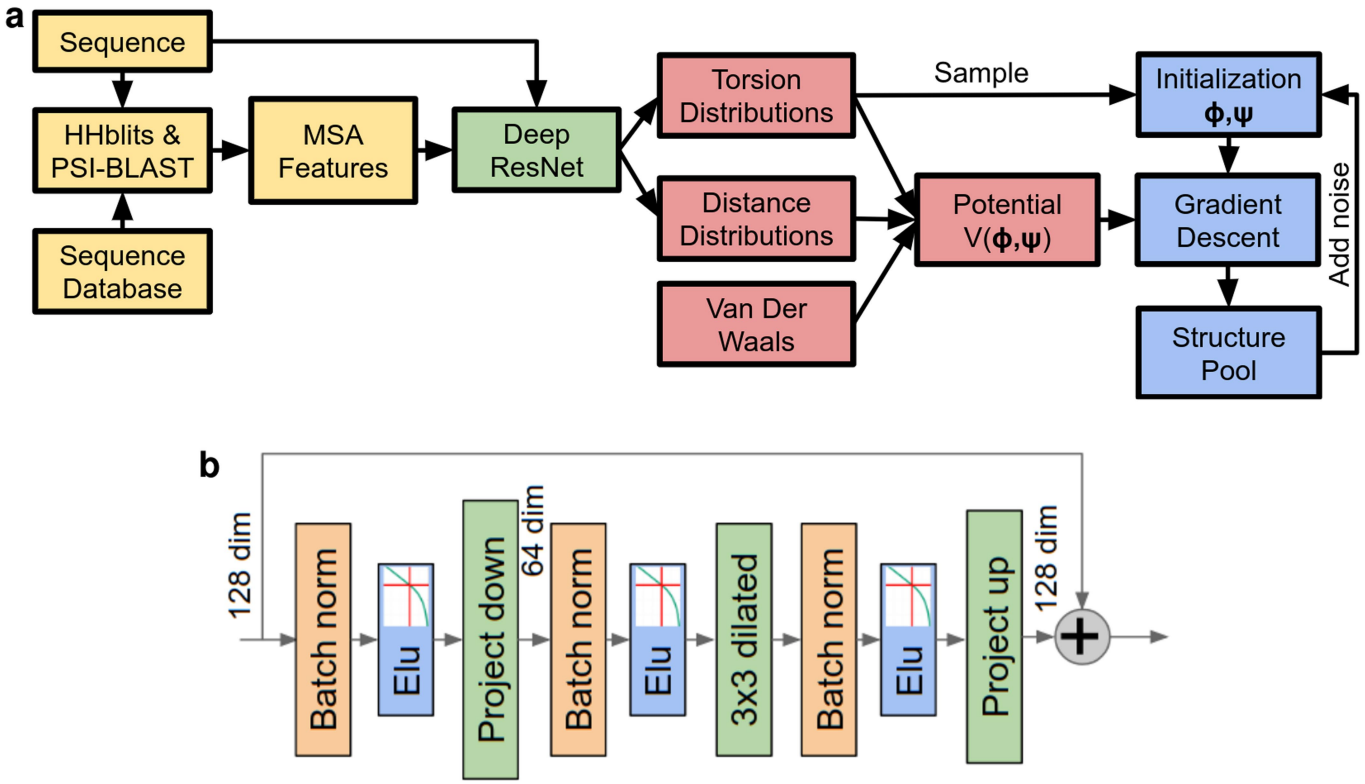
补充信息

补充信息可在以下网址获取：https://doi.org/10.1038/s41586-019-1923-7。

通讯及材料索取请致函 A.W.S.

同行评审信息*Nature*谨向 Mohammed AlQuraishi 及其他匿名评审人对本研究的评审工作所作贡献表示感谢。

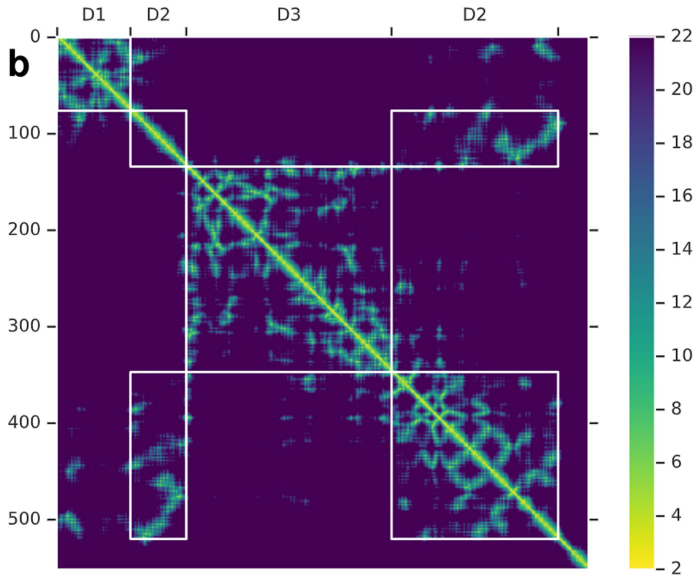
重印及授权信息可在http://www.nature.com/reprints 获取。

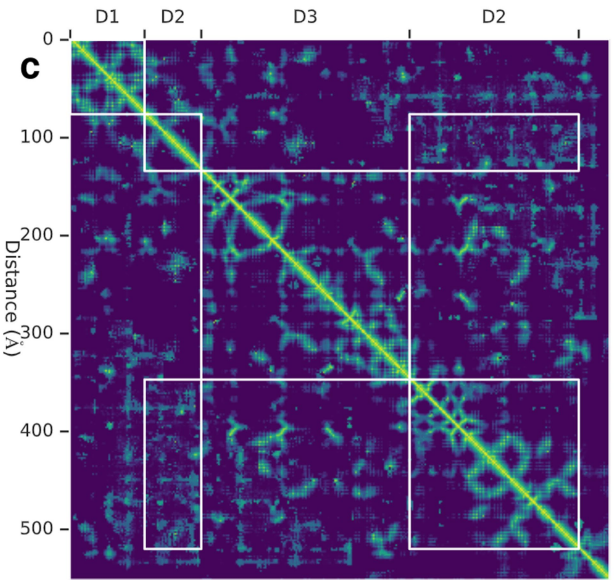


扩展数据图 1 | 折叠系统与神经网络示意图。a，整体折叠系统示意图。特征提取阶段（通过序列数据库搜索构建多序列比对，并计算基于多序列比对的特征）以黄色标示；结构预测神经网络以绿色标示；势场构建以红色标示；结构实现以蓝色标示。**b**，深度残差卷积网络单个模块中所用层结构示意图。对降维后的激活值应用扩张卷积操作，该模块的输出与前一层的表征相加。残差网络的旁路连接使得梯度能够无衰减地反向传播，从而支持超深网络的训练。

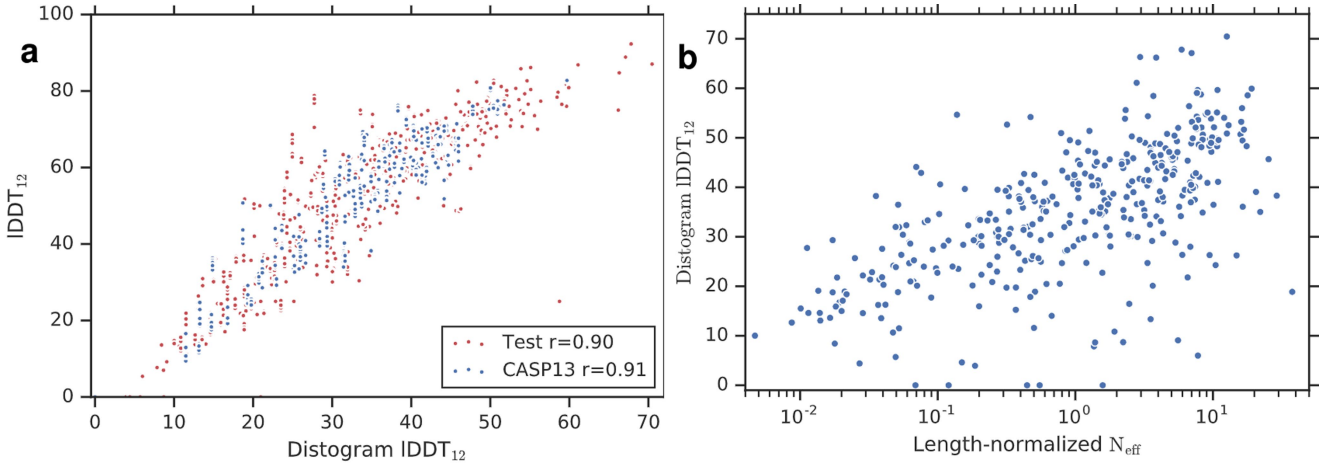
a

Contact precisions		L long			L/2 long			L/5 long		
Set	*N*	AF	498	032	AF	498	032	AF	498	032
FM	31	**46.1**	43.1	40.1	**58.5**	54.9	51.6	**69.9**	67.3	61.9
FM/TBM	12	**59.1**	53.0	48.9	**74.2**	64.5	64.2	**85.3**	81.0	79.6
TBM	61	**68.3**	65.5	61.9	**82.4**	80.3	76.4	**90.6**	90.5	87.1





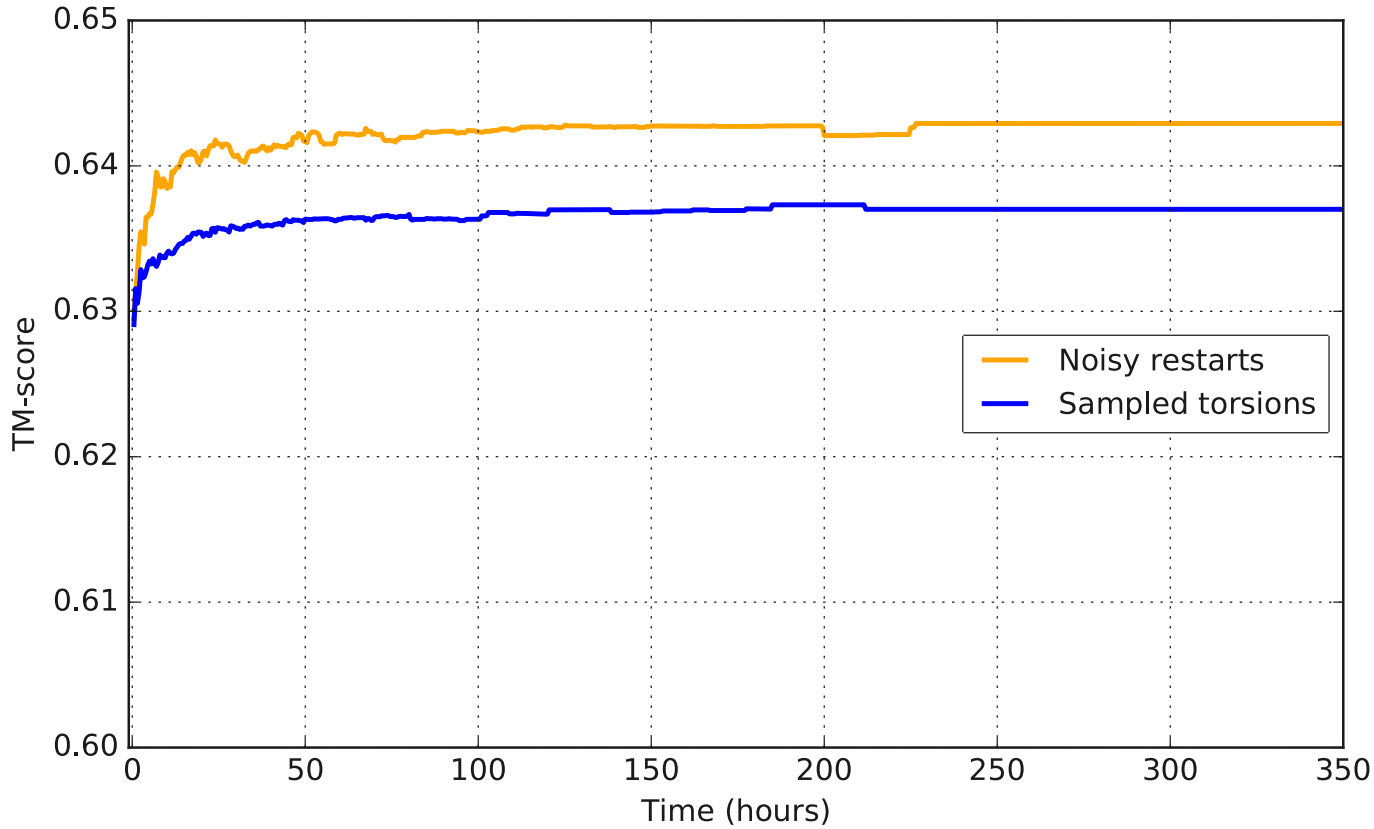
扩展数据图 2 | CASP13 接触预测精度。a，CASP13 中针对最可能出现的 L、*L*/2 或 L/5 接触位点进行长程接触预测的精度（如图 1c所示），其中 Liste 表示结构域长度。AlphaFold (AF) 在 CASP13 中使用的、经阈值处理以适配接触预测的距离分布，与 CASP13 中排名前两位的接触预测方法——498（RaptorX-Contact [26]）和 032（TripletRes [32]）——在“所有组别”靶标上提交的结果进行对比，并采用针对 T 0953s2 的最新结构域定义。**b**、**c**，CASP13 靶标 T0990 的真实距离（**b**）及预测距离分布图（**c**）的众数。 CASP 将该链划分为三个结构域（如所示：D3 插入于 D2 中），对应分别有 39、36 和 42 个 HHblits 比对结果（数据源自 CASP 官网）。



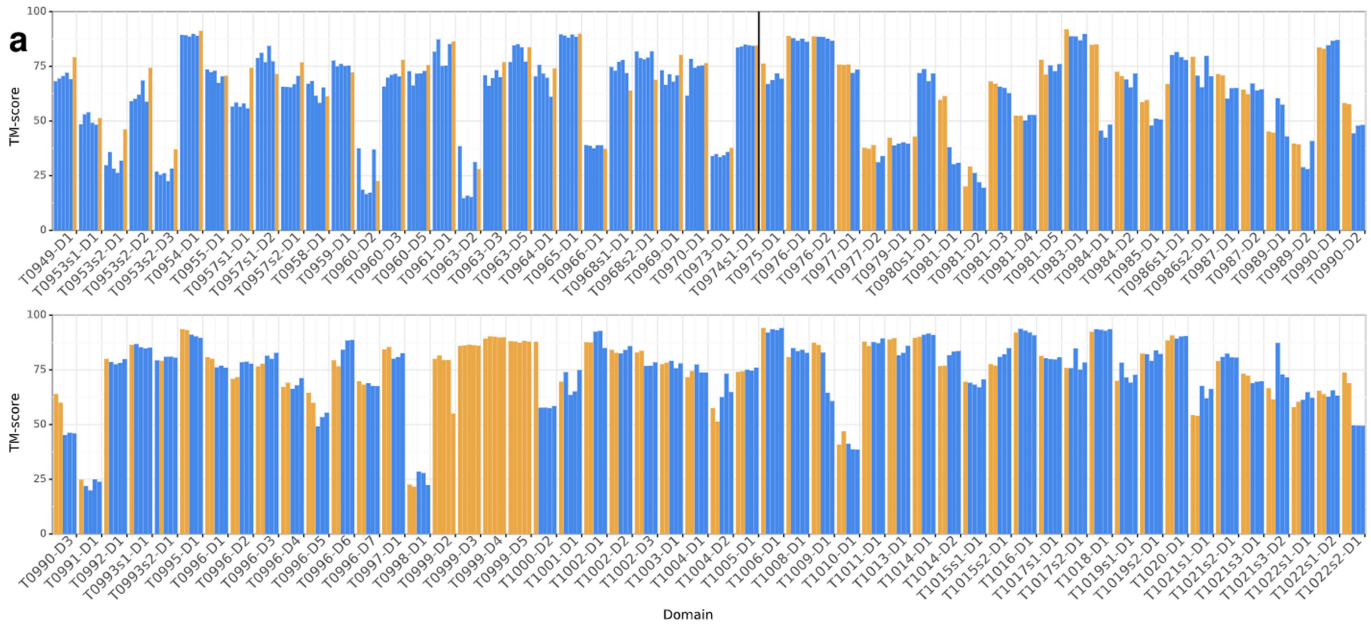
c

Potential	Bins	TM-score	GDT_TS	lDDT	RMSD (Å)	$-\log_{10} P$
Full + relax	51/64	0.649	65.8	54.2	5.94	7.3
Full	51/64	0.642	65.0	53.9	5.91	–
W/o reference	51/64	0.632	64.3	50.0	6.64	4.0
W/o score2_smooth	51/64	0.641	64.8	53.7	5.93	1.2
W/o torsions	51/64	0.637	64.3	53.6	6.04	8.2
W/o distogram	51/64	0.266	29.1	19.1	14.88	130
Full	48/64	0.643	65.0	54.1	5.90	
Full	24/32	0.643	65.0	53.8	5.89	
Full	12/16	0.644	65.1	53.9	5.85	
Full	6/8	0.641	64.6	53.7	5.94	
Full	3/4	0.620	62.4	52.8	6.22	
Full	2/3	0.576	58.2	49.3	8.38	

扩展数据图 3 | 结构准确性分析。a，lDDT$_{12}$与distogram lDDT$_{12}$的对比图（参见“方法”部分中的“准确性”小节）。对于 CASP13 实验，distogram 准确性能很好地预测实际结构的 lDDT 值（尤其对于中程及长程残基对，以及如图**4a**所示的 TM 分数）(n= 500：针对排除 T0999 的结构域设置的诱饵样本) 及测试集 (n= 377) 数据集。数据以皮尔逊相关系数呈现。**b**，DLDDT$_{12}$与多序列比对中有效序列数 (N_{eff}) 的关系图，该数值已按序列长度 (n= 377) 进行归一化处理。有效序列数与此距离图精度度量值呈正相关 (r= 0.634)。**c**，基于测试集 (n= 377) 计算的不同形式势能函数梯度下降优化后的结构精度指标。上图：剔除势能函数中的特定项，并展示后续采用 Rosetta 弛豫法优化的效果；“P”表示针对双尾配对数据t检验，该势能函数与“Full”模型产生显著差异的显著性水平；“Bins”表示样条拟合前划分的区间数及完整分布中的区间数。在 CASP13 中，样条拟合范围限定于 64 个区间中的前 51 个。下图：降低距离图分布的分辨率。原始的 64 个分箱分布图预测结果通过累加相邻分箱的方式，以 2 倍因子反复进行下采样；在每种情况下，均对超出 18 Å 的范围（即分箱的最后一四分之一区间）进行恒定外推。最后一行中的双级势能函数旨在与接触预测结果进行对比，其构建方式为累加 8 Å 以下及 8–14 Å 区间内的概率质量，并对超出 14 Å 的范围进行恒定外推。本表中的 TM 评分已绘制于图**4b**中。

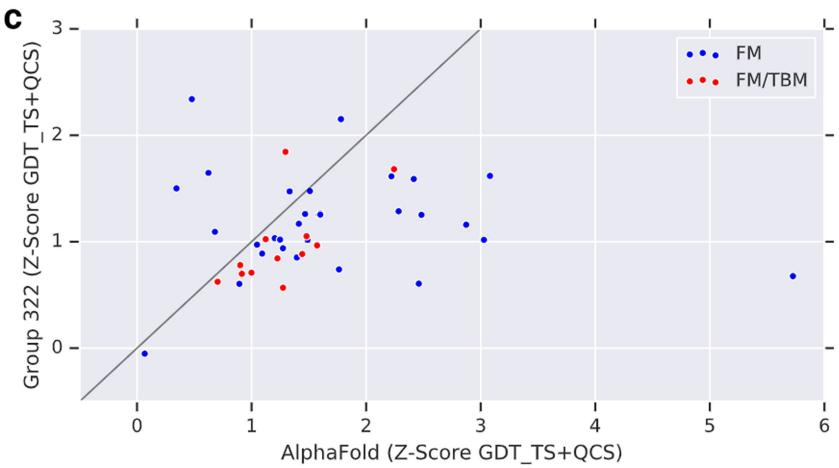


扩展数据图 4 | TM 分数与按测试集取平均值计算得到的每个目标结构的计算时间对比图。结构实现仅需适度的计算资源，且可在多台机器上并行执行。采用含噪声重启的全局优化（橙色曲线）与基于采样扭转角初始化的优化结果（蓝色曲线）进行对比。计算量以（基于 CPU 的）机器数量与耗时之乘积衡量，且可高度并行化。目标结构越长，优化所需时间也越长。图 2e 展示了 TM 分数随梯度下降迭代次数增加而上升的趋势。n= 377。

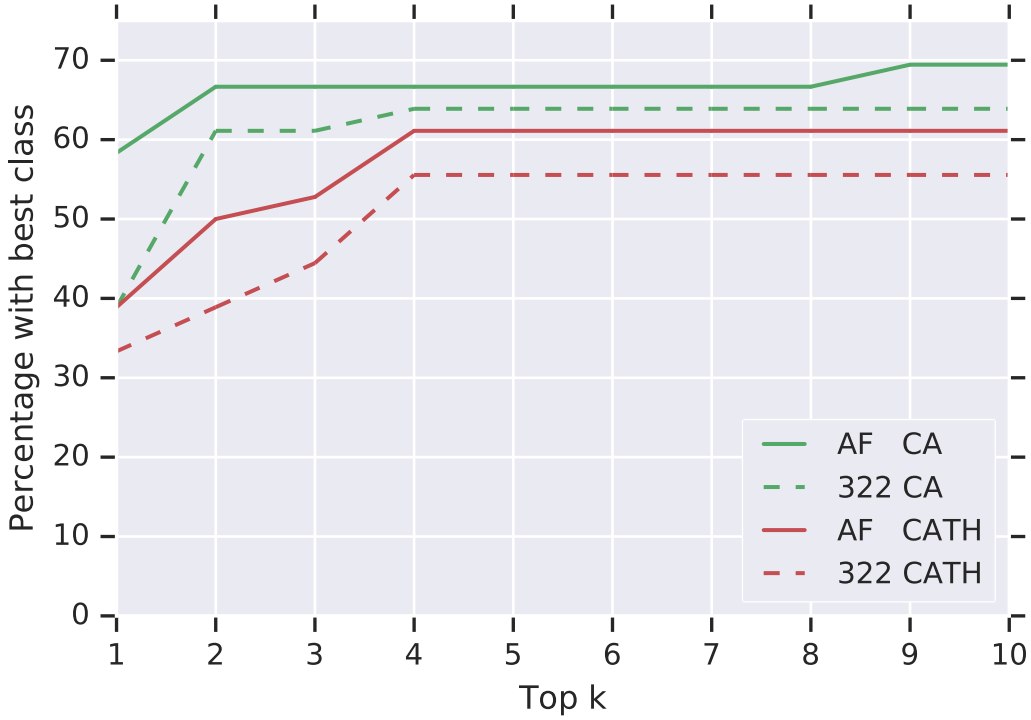


b

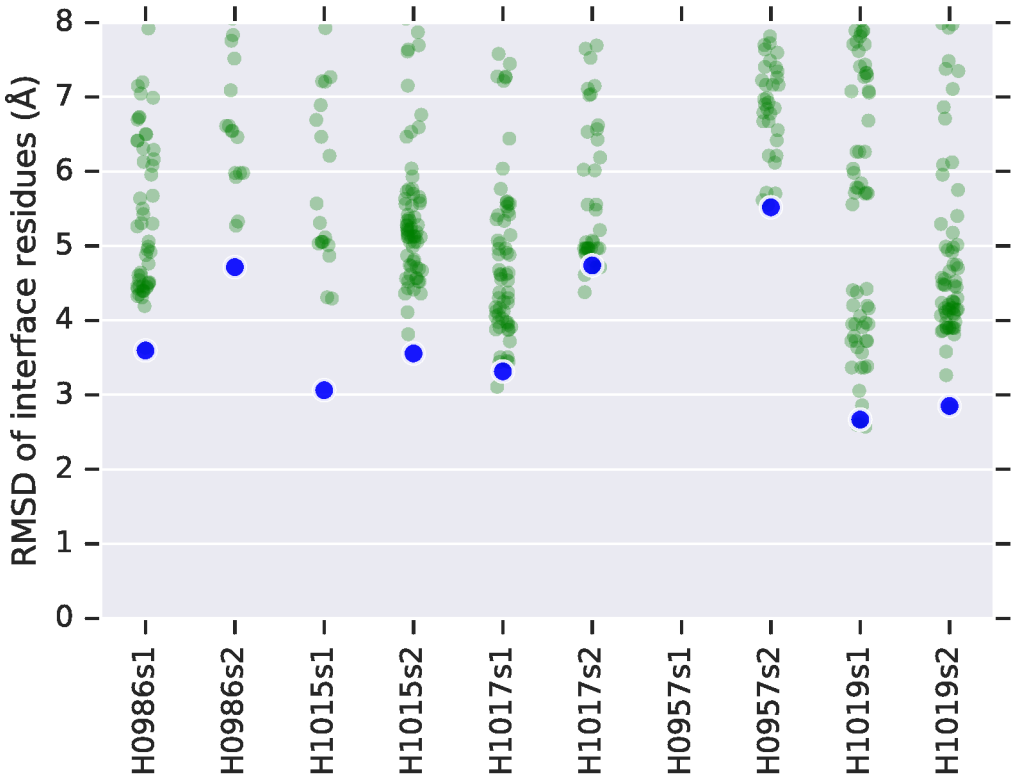
Method	FM	TBM/FM	TBM	All
Top-1	58.0	68.1	76.2	69.9
Best-of-5	62.6	73.6	78.6	73.2
1× gradient descent	58.4	71.6	76.3	70.4
1× fragment assembly	54.3	69.9	74.5	68.0



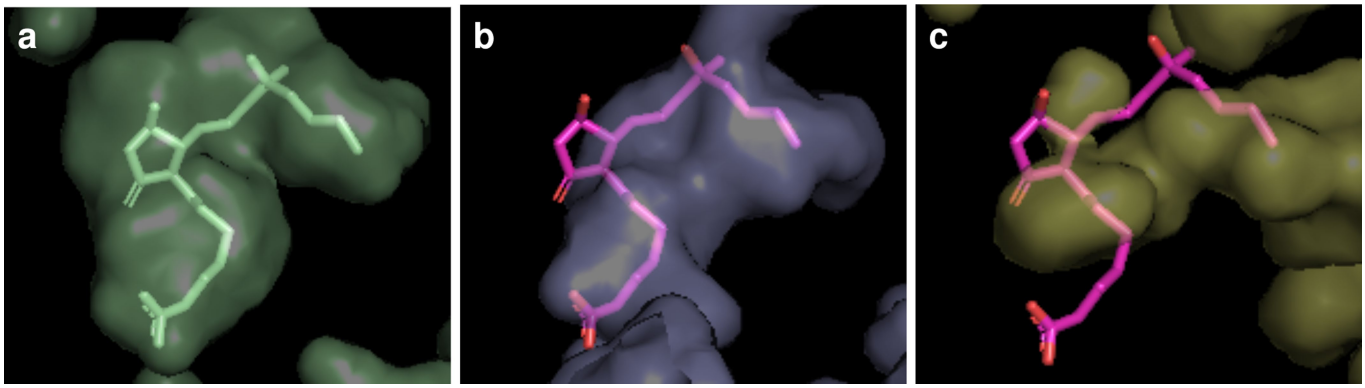
扩展数据图5 | AlphaFold CASP13实验结果。a：展示五个AlphaFold CASP13提交样本的TM评分。采用片段组装策略的模拟退火结果以蓝色标示，梯度下降法结果以黄色标示。梯度下降法仅用于T0975及后续靶标，因此在黑色虚线左侧，我们还展示了使用已部署系统对每个早期靶标进行单次“回填”梯度下降运行的结果。T0999（1,589个残基）基于HHpred [51]同源匹配结果进行人工分割。**b**：AlphaFold CASP13提交样本的平均TM评分
(n= 104 个结构域)，将首个提交的模型、五选一最佳模型（GDT_TS 分数最高的提交）、一次完整链梯度下降单次运行（针对 T0975 及后续靶标的 CASP13 运行，针对早期靶标采用反向填充法）以及一次带有结构域分割功能的片段组装 CASP13 单次运行（针对 T0999 采用梯度下降提交法）进行对比。**c**，评估者对 GDT TS + QCS [52]、 CASP FM (n= 31) 及 FM/TBM (n= 12) 结构域的五选一最佳模型所计算的公式标准化 (z) 分数，将 AlphaFold 与最接近的竞争模型（第 322 组）进行比较，并按结构域类别着色。AlphaFold 表现更优（P= 0.0032，单尾配对t检验）。



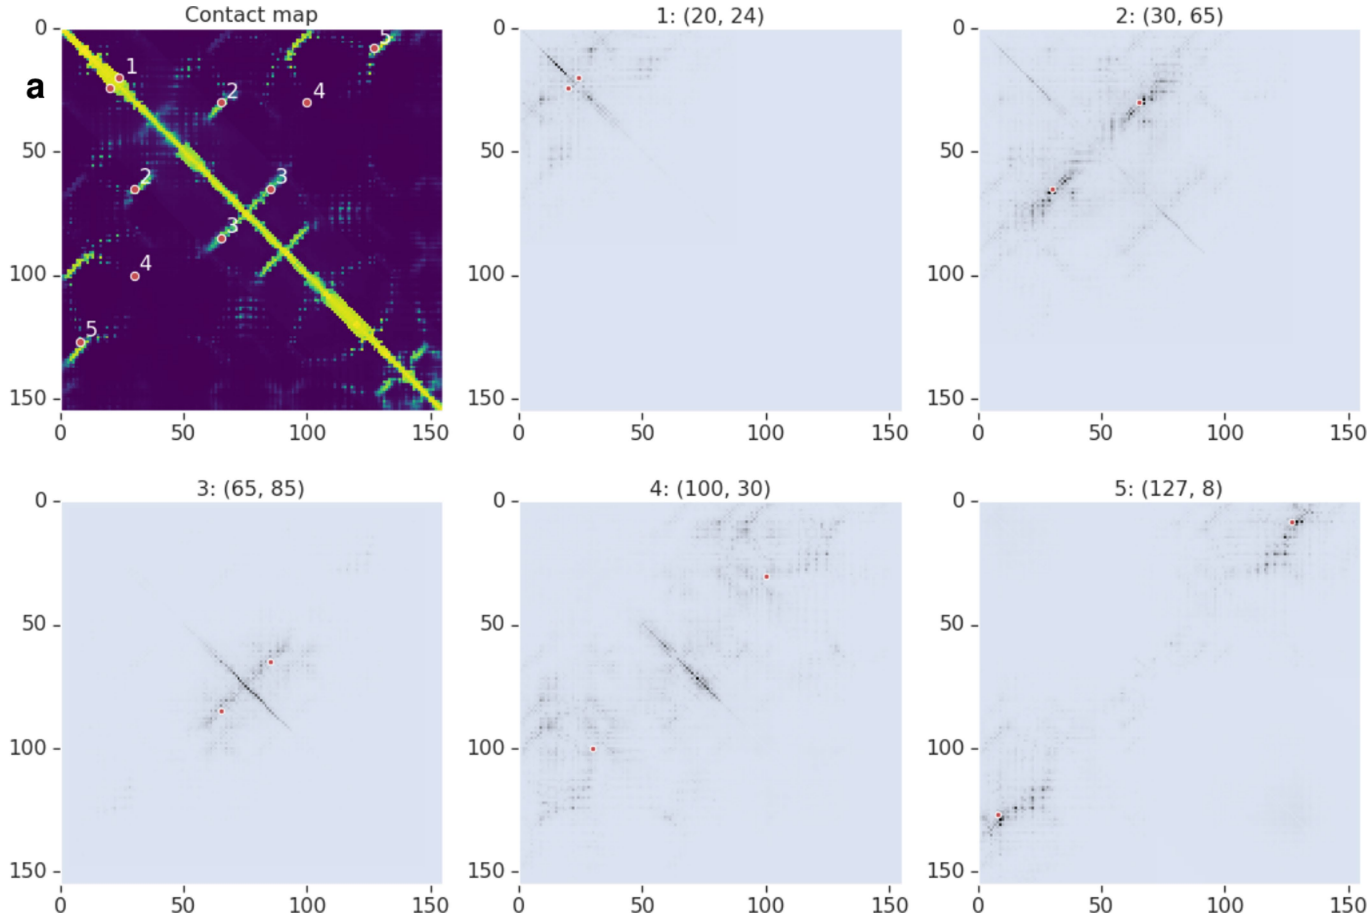
扩展数据图6 | 通过CATH数据库中的结构搜索正确识别折叠结构。蛋白质功能通常可通过寻找已知功能的同源蛋白来推断。本文证明，AlphaFold的FM预测在基于结构的CATH数据库同源结构域搜索中具有更高准确性。针对每个FM或TBM/FM结构域，我们将首个提交结果与真实标签结果，使用TM-align [53]与全部30,744个CATHS40非冗余结构域进行比对。对于36个具有良好真实标签匹配度（评分>0.5）的结构域，我们统计了以下比例：具有相同CATH编码的结构域（CATH代码为红色，CA代码为绿色；CATH结果与AlphaFold结果相近）作为评分>0.5的*前k个匹配结果*中，成为最佳真实标签匹配的比例。图中展示了AlphaFold及次优候选集（322个结构域）的对比曲线。AlphaFold预测能更精准地确定匹配折叠结构，而准确识别匹配的CATH结构域可为新蛋白质的功能研究提供重要线索。



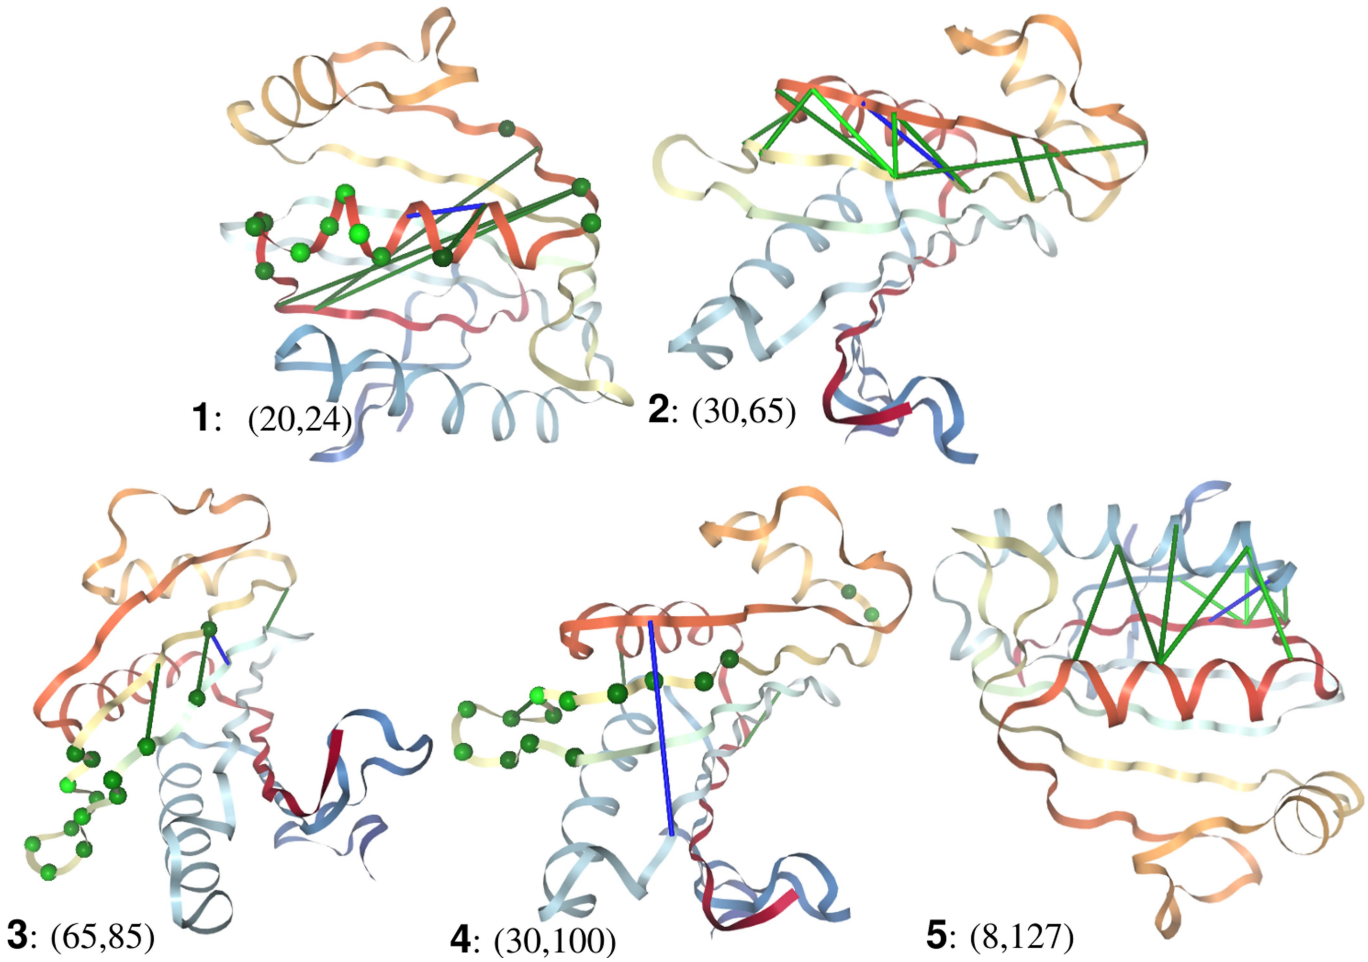
扩展数据图 7|界面预测准确率。蛋白质-蛋白质相互作用是理解蛋白质功能的重要研究领域，尽管在采用预测结构进行分子对接方面已取得一定进展[54]（均方根偏差可达 6 Å），但由于需要高精度预测，该领域迄今仍主要依赖基于模板的模型。本图显示，AlphaFold 的预测结果可提升异源二聚体结构中链段界面区域的预测精度，且可能更适用于分子对接——尽管分子对接并非 AlphaFold 系统组成部分，且所有提交样本均为独立链段而非复合物结构。针对五个全组别异源二聚体 CASP13 靶标，我们计算了所有组别链段提交样本（绿色）相对于靶标复合物的界面残基（与真实链间重原子距离＜10 Å 的残基）的全原子均方根偏差值。结果＞8 Å 的数据未予展示。AlphaFold（蓝色）在界面区域持续呈现高预测精度，且在 5 个靶标中的 4 个靶标上，对两条链的界面预测均小于 5 Å。



扩展数据图8 | T1011的配体结合口袋可视化图。T1011（PDB 6M9T）为与米索前列醇-FA结合的EP3受体[55]。**a**，展示配体位于结合口袋中的天然结构。**b**、**c**，AlphaFold提交的第5个结果（78.0 GDT TS）（**b**）——在未知配体信息的情况下生成——显示的结合口袋与真实口袋的相似度高于其他最佳提交结果（322，模型3,68.7 GDT TS）。(c)两项提交结果均基于与配体口袋相邻的螺旋区中相同的残基子集，与天然蛋白质进行对齐，并连同内部口袋及天然配体位置一同进行可视化展示。



扩展数据图9|距离图网络的归属度分布图。T0986s2的接触概率图，以及输入二维特征针对五对不同残基对（I，J）的预期距离所计算的积分梯度绝对值之和$\sum_c|S^{I,J}_{i,j,c}|$的分布图：(1)螺旋自接触；(2)长程链间接触；(3)中程链间接触；(4)非接触；(5)超长程链间接触。每对残基在图中以两个红点表示，颜色越深表示归属度权重越高。



扩展数据图 10 | 预测结构上显示归因值。对于 T0986s2（TM 分数为 0.8），选取扩展数据图 9 中所示五个输出对中每个输出对具有最高归因值的前 10 个输入对（包括自配对），以线条（自配对则为球体）表示，并根据灵敏度进行颜色编码——颜色越浅表示灵敏度越高；输出对则以蓝色线条表示。

nature research

通讯作者 s): 安德鲁·资深

报告摘要

《自然·研究》旨在提升我们发表研究成果的可重复性。本表格为报告工作提供规范性与透明度保障。如需更多关于《自然·研究》政策的信息，请参阅作者与审稿人指南及编辑政策核查清单。

统计参数

在报告统计分析结果时，请确认以下项目已出现在相关位置（例如：图注、表注、正文或“方法”部分）。

n/a	确认的	
☐	☒	精确样本量(“)针对每个实验组/实验条件，以离散数值及测量单位表示
☐	☒	用于指示测量数据是否取自不同样本，抑或是对同一样本进行了重复测量。
☐	☒	所使用的统计检验及其是单侧还是双侧 仅对常规检测项目仅需以名称说明；对更复杂的检测技术则应在“方法”部分予以描述。
☐	☒	所有已检验协变量的描述
☐	☒	对任何假设或修正措施的说明，例如正态性检验及多重比较校正
☐	☒	对统计量的完整描述，包括集中趋势（例如均值）或其他基础估计量（例如回归系数），以及变异度（例如标准差）或相关的不确定性估计值（例如置信区间） 对于零假设检验，需提供检验统计量（如 F、t、r）、置信区间、效应量、自由度及 P 值；若适用，请将 P值以精确值形式给出。
☒	☐	对于贝叶斯分析，需考虑先验分布的选择及马尔可夫链蒙特卡洛方法的设置。
☒	☐	
☒	☐	
☐	☒	对于分层及复杂研究设计，需确定适合开展的检验层级，并完整报告研究结果；同时提供效应量估计值（如 Cohen‘s d、Pearson’ s r），并说明其计算方式。
☐	☒	清晰定义的误差条 明确说明错误所在。*Or* 条线分别代表（例如：SD、SE、CI）

我们关于生物学家统计知识的网页资源或许对您有所帮助。

软件与代码

关于计算机代码可用性

数据收集	为对数据进行摄取与预处理，我们使用了以下工具：PDB 2018-03-15；CATH 2018-03-16；基于版本 3.0-beta.3 的 HHblits；HHpred 网络服务器；uniclust30 2017-10；PSL-BLAST 2.6.0 版本；SST 网络服务器（2019年3月）；Biopython V1.65；Rosetta V3.5；TM-align 20160521，以及使用 Python 2.7 编写的自定义代码。更多详细信息请参阅方法部分。
数据分析	本研究采用的网络均基于 TensorFlow 库并添加了自定义扩展模块。CASP13 竞赛中使用的距离预测网络的推理代码将开源。分析工作均使用基于 Python 2.7 编写的自定义代码完成，可视化结果则采用 PYMol 2.2.0 软件生成。更多细节请参阅“方法”部分。

对于采用定制算法或软件、且这些工具对研究至关重要但尚未在已发表文献中描述的论文，作者须应编辑/审稿人要求提供相关软件。我们强烈建议将代码部署至社区代码仓库（例如 GitHub）；更多详情请参阅《自然·研究》期刊发布的“代码与软件提交指南”。