

使用语言模型模拟五亿年的演化

托马斯·海耶斯^{1*} 罗尚·拉阿^{1*} 哈利尔·阿金^{1*} 尼古拉斯·J·索弗罗尼耶夫^{1*} 德尼兹·奥克泰^{1*} 林泽铭^{1*} 罗
伯特·维尔库尔^{1*} 文森特·Q·陈^{2,3} 乔纳森·迪顿¹ 马里乌斯·维格特¹ 罗希尔·巴德昆德里¹ 伊尔赫姆·沙夫卡特¹ 龚
俊¹ 亚历山大·德里¹ 劳尔·S·莫利纳¹ 尼尔·托马斯¹ 尤瑟夫·汗⁴ 切坦·米什拉¹ 卡罗琳·金¹ 利亚姆·J·巴尔蒂² 马
修·内梅斯² 帕特里克·D·徐^{2,3} 汤姆·塞尔库¹ 萨尔瓦托雷·坎迪多¹ 亚历山大·里维斯¹ †

摘要

超过三十亿年的演化产生了生物学图像，编码在自然蛋白质的空间中。在这里，我们展示了通过演化生成的标记训练的语言模型能够作为演化模拟器，生成与已知蛋白质相距甚远的功能蛋白质。我们提出了ESM3，这是一种前沿的多模态生成语言模型，能够在蛋白质的序列、结构和功能上进行推理。ESM3可以遵循组合其模态的复杂提示，并对生物对齐高度响应。我们已向ESM3提示以生成具有思维链的荧光蛋白。在我们合成的生成物中，我们发现了一个与已知荧光蛋白相距甚远的明亮荧光蛋白（58% 相似性）。同样距离较远的自然荧光蛋白在五亿年以上的演化中是分离的。

序列和数亿个结构揭示了生命中变异模式的规律。一个共识正在形成，这些序列背后是蛋白质生物学的基本语言，可以通过语言模型理解（6–11）。

目前已经开发和评估了一些蛋白质序列的语言模型（5–10，12–17）。研究发现，语言模型中出现的表示反映了蛋白质的生物结构和功能（6–8，18），且这些表示是在没有任何监督下学习到的（19，20），并且随着规模的增长而得到改善（5，21）。在人工智能领域，已经发现缩放法则可以预测随着规模的增加能力的增长，描述了计算、参数和数据的前沿（22–24）。

我们提出了ESM3，一种前沿的多模态生成模型，能够对蛋白质的序列、结构和功能进行推理。ESM3作为一种生成性掩码语言模型，针对每种模态对离散标记进行训练。结构推理是通过将三维原子结构编码为离散标记来实现的，而非最近预测（25）和生成模型（26–中采用的复杂架构和在三维空间中的扩散。

引言

今天存在的蛋白质在数十亿年的自然进化过程中发展成其当前形态，经历了一个庞大的进化筛选过程。在地质时间上进行的平行实验中，自然创造了随机突变并应用选择，通过各种各样的序列、结构和功能过滤蛋白质。

因此，我们观察到的蛋白质中的模式反映了塑造其随时间演化的生物学深层隐藏变量的作用。地球自然多样性的基因测序调查正在对序列（1–3）和结构（4,5）进行分类，这些蛋白质包含十亿

28) 蛋白质。离散标记的全对全建模具有可扩展性，并允许ESM3接收其所有模态的任意组合的提示，从而实现对新蛋白质的可控生成，遵循提示组合的要求。

ESM3 在其最大规模上经过了 1.07×10^{24} 浮点操作 (FLOPs) 的训练，涵盖了 27.8 亿种蛋白质和 7710 亿个独特标记，并具备 980 亿个参数。将 ESM3 扩展到 980 亿参数的规模，能够在序列、结构和功能的表示上实现改进，以及在生成评估上的提升。我们观察到 ESM3 对提示具有高度的响应性，并能够为复杂的提示组合找到创造性的解决方案，包括那些我们在自然界中找不到匹配结构的解决方案。所有规模的模型都可以更好地对齐以跟随提示，而较大的模型对对齐的响应性更强，显示出在对齐后解决最具挑战性的提示的能力更卓越。

*平等贡献¹EvolutionaryScale, PBC²Arc Institute³
加利福尼亚大学伯克利分校⁴在EvolutionaryScale, PBC实
习期间完成的工作 †通讯至
<arives@evolutionaryscale.ai>.

我们报告了使用 ESM3 生成一种新的绿色荧光蛋白 (GFP)。荧光蛋白负责水母和珊瑚的发光颜色 (29), 并且是现代生物技术中的重要工具 (30)。它们具有优雅的结构: 一个由 11 条 β 链组成的桶形结构, 中心穿过一条螺旋, 这构成了由蛋白质自身原子形成的发光发色团。这一机制在自然界中是独特的——没有其他蛋白质能够自发地从其自身结构中形成荧光发色团——这表明即使对于自然界而言, 产生荧光也是一项困难的任务。

我们新开发的蛋白质, 命名为 esmGFP, 与维多利亚水母 GFP 的序列一致性为 36%, 与已知最相似的荧光蛋白的序列一致性为 58%。尽管 GFP 在数十年来作为蛋白工程的目标受到极大关注, 但据我们所知, 这样远源的新型 GFP 仅通过在自然界中的发现被识别。

在可预测的时间尺度上, 自然界中的 GFP 也发生了类似数量的多样化。从这个角度理解, 产生一种与现有蛋白质距离如此遥远的新型荧光蛋白, 似乎相当于模拟了超过五亿年的进化。

ESM3

ESM3 基于蛋白质的序列、结构和功能进行推理。所有三种模式通过标记表示, 并作为单独的轨道输入和输出, 这些轨道在模型内融合为单一的潜在空间。ESM3 的训练目标是生成性掩码语言建模:

$$\mathcal{L} = -\mathbb{E}_{x,m} \left[\frac{1}{|m|} \sum_{i \in m} \log p(x_i | x_{\setminus m}) \right]$$

随机掩码 m 应用于标记 x 描述蛋白质, 并且模型通过监督训练来预测已经被掩盖的标记的身份。在训练过程中, 掩码是使用噪声调度进行采样的, 该噪声调度变化了被掩盖的位置的比例, 使得 ESM3 可以看到许多不同的掩盖序列、结构和功能的组合, 并预测任何其他组合的各个模态的补全。这与传统的掩码语言建模 (31) 不同, 因为监督作用于所有可能的掩盖率, 而不是单一的固定掩盖率。这种监督将所有可能的下一个标记的预测的概率分布因式分解, 以给出任何之前标记组合的条件, 确保标记能够从任何起始点以任何顺序生成 (32–34)。

为了从 ESM3 生成, 标记被逐步采样。从完全或部分被屏蔽的上下文开始, 标记

可以一次或同时以任意顺序采样, 直到所有位置完全取消屏蔽 (图 1A)。除了能够生成内容, ESM3 的训练目标对于表征学习也非常有效。较高的屏蔽率提高了生成能力, 而较低的屏蔽率则提高了表征学习。我们选择使用一种噪声调度来训练 ESM3, 以平衡生成能力与表征学习 (附录 A.2.2)。

ESM3 是双向变换器。序列、结构和功能标记在输入时嵌入并融合, 然后经过变换器模块的堆叠处理 (图 1B)。在模型输出端, 浅层多层感知机 (MLP) 头将最终层表示投影到每个轨道的标记概率。ESM3 使用分词, 而不是专门的架构组件, 以在学习到的多模态特征空间中表示蛋白质的复杂性。这使得高效且高度可扩展的训练成为可能。

蛋白质结构通过离散自编码器进行标记化 (35), 该编码器的训练目标是将三维结构压缩成离散标记 (图 1C)。我们提出了一种不变的几何注意机制, 以高效处理三维结构。该机制在每个氨基酸的键几何定义的局部参考框架中操作, 并允许局部框架通过转换为全局框架实现全局交互 (附录 A.1.6)。每个氨基酸周围的局部结构邻域被编码为一系列离散标记, 为每个氨基酸生成一个标记。

在预测或生成蛋白质结构时, ESM3 输出的结构标记通过解码器进行处理, 后者重建完整的原子结构。自编码器经过训练以编码和重建原子坐标, 采用几何损失来监督成对距离和键向量及法线的相对方向 (附录 A.1.7.3.1)。这种分词技术实现了蛋白质结构的近乎完美重建 ($<0.5^\circ$ 在 CAMEO 上的 RMSD, 图. S3)。

由于每个结构标记的局部邻域包含有关结构邻近部分的信息, 我们还为模型提供了一种通过第一层变换器块直接基于几何注意机制对主链原子坐标进行条件化的方式。为了支持更高层次的结构抽象, 我们包含了描述二级结构 (SS8) 标记和溶剂可接触表面积 (SASA) 标记的轨道。描述生物活性的关键字标记, 例如结合、酶功能及结构域或折叠分类, 允许对蛋白质的架构和功能进行更高级别的语义描述。残基级注释标记指示个别残基的功能, 例如催化位点和翻译后修饰。

使用语言模型模拟五亿年的进化




图1. ESM3是一个生成性语言模型，它对蛋白质的序列、结构和功能进行推理。(A)使用ESM3进行迭代采样。生成一个 α/β 水解酶。序列、结构和功能都可用于提示模型。在每个时间步 t ，采样一部分掩蔽位置，直到所有位置被解掩。(B)ESM3架构。序列、结构和功能在输入和输出中表示为离散标记轨道。模型是一个由变换器模块组成的系列，其中所有轨道在一个单一的潜在空间中融合；第一个模块中的几何注意力允许对原子坐标进行条件化。ESM3经过监督以预测掩蔽标记。(C)结构标记化。每个氨基酸周围的局部原子结构被编码为标记。(D)模型在三个尺度下训练：1.4B、7B和98B参数。在测试集上的负对数似然作为训练FLOPs的函数显示对每个输入轨道条件的响应，随着FLOPs的增加而改善。(E)来自ESM3 98B的无条件生成（根据与训练集中最近序列的序列一致性着色），通过ESM3嵌入，并通过UMAP投影，与来自UniProt的随机采样序列（灰色）并排。生成结果多样、高质量，并覆盖自然序列的分布。

最大的ESM3模型在2.78十亿个自然蛋白质上进行训练, 这些蛋白质来自序列和结构数据库 (2, 36–39)。由于相对于序列, 只有一小部分结构是通过实验确定的, 我们利用预测的结构 (4, 5)。序列使用隐藏马尔可夫模型库进行功能关键词的注释 (40)。我们还生成具有逆折叠模型的合成序列 (在附录中描述 A.2.1.3), 包括预测的结构。总体而言, 这使得训练数据的数量增加到3.15十亿个蛋白质序列、2.36亿个蛋白质结构, 以及5.39亿个带有功能注释的蛋白质, 总计7710亿个唯一标记。训练数据集的完整细节在附录中描述 A.2.1。

我们在三个规模上训练ESM3模型: 14亿、70亿和980亿个参数。在最初的一系列实验中, 为了评估对架构超参数的表征学习性能反应, 我们发现对深度的增加反应大于对宽度的反应。这为最终架构选择相对较深的网络提供了指导, 其中980亿参数模型包含216个变换器模块 (附录 A.1.5)。

将ESM3从14亿参数扩展到98亿参数, 导致测试集所有轨道上的损失显著改善, 其中序列损失的改善最为明显 (图1D, 图. S11)。这些测试损失的降低促进了更好的表征学习 (表S7 和图. S8)。在单一序列结构预测中, ESM3 98B超过了ESMFold (0.895对比0.865的平均局部距离差异测试, LDDT, CAMEO测试集; 表S8)。从模型中生成的序列, 未使用提示 (无条件生成) 产生了高质量的蛋白质——平均预测LDDT (pLDDT) 0.84 和预测模板建模评分 (pTM) 0.52——在序列 (平均成对序列一致性0.155) 和结构 (平均成对TM分数0.48) 上都表现出多样性, 涵盖了已知蛋白质的分布 (图. 1E, 图. S13)。

尽管已有大量研究致力于为蛋白质创建专门的架构和训练目标, 但我们的结果表明, 利用分词、有效的架构和掩码标记预测进行语言建模的扩展, 能够在表征和生成应用中持续带来改进。该方法使模型能够构建一个从数据中学习的共享多模态表示空间, 而不是明确地硬编码到其架构中, 这在计算和数据不断增加的情况下, 可以学习到越来越丰富和更通用的特征空间。在接下来的章节中, 我们将展示该方法在蛋白质的可控生成中实现了高保真度。

基于ESM3的可编程设计

我们探索了ESM3按照不同组成遵循复杂提示的能力。ESM3可以根据其每个输入轨道的指令进行提示: 序列、结构坐标、二级结构 (SS8)、溶剂可接触表面积 (SASA) 和功能关键词。这使得可以在多个抽象层次上指定提示, 从原子级别的结构到描述功能和折叠拓扑的高层关键词。

我们评估ESM3在每个轨道独立跟随提示的能力 (图. 2A)。为每个轨道构建一组提示, 采用暂时保留的自然蛋白质测试集 (附录 A.3.7)。生成的结果使用ESMFold评估其与提示的一致性以及结构预测的置信度 (pTM)。我们为每个轨道定义一致性度量: 约束位点RMSD (cRMSD), 即提示的坐标 (即骨架原子的位置信息) 与生成中相应坐标之间的RMSD; SS3准确性, 提示和生成之间三类二级结构匹配的残基比例; SASA Spearman ρ , SASA提示与生成中对应区域之间的相关性; 关键词回收率, 即被InterProScan恢复的提示关键词的比例 (40)。在所有轨道中, 7B参数ESM3找到了遵循提示的解决方案, 并且其结构被ESMFold (pTM > 0.8) 自信地预测。

无条件生成反映了自然蛋白质的分布。由于我们观察到ESM3能够忠实地遵循提示, 因此我们推测提示可以引导模型生成与训练集和自然蛋白质不同的蛋白质。首先, 我们测试模型跟随分布之外提示的能力。我们构建了一组提示, 将来自于被保留结构的SS8和SASA结合在一起 (TM < 0.7 到训练集)。在这些提示下, 尽管模型继续生成一致的球状结构 (平均 pTM 0.85 ± 0.03), 与训练集的相似性分布 (通过TM-score和序列一致性测量) 发生了变化, 变得更加新颖 (与最近的训练集蛋白质的平均序列一致性 < 20%和平均TM-score 0.48 ± 0.09 ; 图2B顶部)。为了测试模型推广到超出自然蛋白质分布的结构的能力, 我们使用从一组与训练数据集中的自然蛋白质不同的人工对称蛋白质设计得出的二级结构提示 (附录 A.3.8)。同样, ESM3生成的结果具有高置信度 (pTM > 0.8, pLDDT > 0.8), 且与训练集中的蛋白质具有低序列和结构相似性 (序列一致性 < 20%和TM-score 0.52 ± 0.10 ; 图2B底部), 表明该模型可用于生成与自然界中存在的蛋白质序列和结构高度不同的蛋白质。

使用语言模型模拟五亿年的演化




图2. 使用ESM3的生成编程。(A) ESM3能够根据其输入轨道的提示进行响应。每个轨道对提示的忠实度密度如图所示。生成结果在与提示的一致性(主链cRMSD、SS3准确性、SASA Spearman ρ 、关键词恢复)以及高结构预测置信度(pTM)方面达到了一致性。(B) ESM3可以被提示生成与训练集和自然蛋白质在结构(左侧)和序列(右侧)上有所不同的蛋白质。相较于无条件生成(红色), 响应来自于分布外自然结构(上面面板)和计算设计的对称蛋白质(下面面板)的提示, 提示生成(蓝色)趋向于更加新颖的空间。(C) ESM3对于一系列复杂提示的组合生成创造性的解决方案。我们展示了通过关键词或二级结构指定的高层次指令与原子级别的基序组成。忠实于提示的效果通过与参考结构的相似性(针对关键词提示)以及全原子RMSD(针对基序提示)来展示。解决方案与提取基序的支架有明显不同(中位TM-score为 0.36 ± 0.14), 并且对于许多基序(例如血清素、钙、蛋白酶抑制剂和Mcl-1抑制剂结合位点), 我们未能发现与包含相同基序的其他蛋白质之间的显著相似性。(D) 一个特别创造性行为的示例。ESM3在保持活性位点结构的同时, 将一个丝氨酸蛋白酶的体积压缩了33%。

ESM3能够遵循复杂的提示, 并具备从不同轨迹和不同抽象层次构建提示的能力。为了评估这一能力, 我们对ESM3提出了需要解决单个原子空间坐标的图案提示, 包括参与远离序列的残基之间的三级接触的原子, 例如催化中心和配体结合位点。我们将图案提示与指定折叠架构的提示相结合。对于每个独特的图案和支架组合, 我们生成样本, 直到出现成功 (全原子 RMSD $< 1.5^\circ\text{A}$, 包括侧链原子的原子坐标; TM > 0.6 与折叠层级提示的代表性结构; SS3准确性 $> 80\%$ 用于二级结构提示; 以及对支架的高信心, 具有 pTM > 0.8 和 pLDDT > 0.8 的值)。

我们发现ESM3能够解决各种此类任务 (图. 2C)。它在不检索图案原始支架的情况下做到这一点 (中位数TM分数为 0.40 ± 0.10 与参考蛋白质对比; 附录 A.3.9)。在某些情况下, 支架是从具有相似图案的现有蛋白质中转移过来的 (例如, ESM3设计的锌结合图案的 α -螺旋支架与Ni²⁺-结合蛋白质高度相似, PDB: 5DQW, 5DQY; 图. 2C, 行3列1)。对于许多图案 (例如, 血清素、钙、蛋白酶抑制剂和Mcl-1抑制剂的结合位点), Foldseek (41) 未能找到与包含相同图案的其它蛋白质的显著相似性。在这些情况下, 我们观察到图案有时已被移植到完全不同的折叠中 (例如, 一个蛋白酶抑制剂结合位点图案在一个 β -桶中, 最接近于膜结合的铜转运蛋白, PDB: 7PGE; 图. 2C, 行3列3)。在其他情况下, 支架似乎完全新颖, 例如一个设计用于支撑Mcl-1抑制剂结合图案的 α/β 蛋白, 其与PDB、ESMAtlas和AlphaFold数据库中所有已知蛋白质的结构相似性较低 (最大TM分数 < 0.5 ; 图. 2C, 行4列1)。总体而言, 生成的解决方案具有高设计性, 即在使用ESM-IF1进行反向折叠后, 对原始结构的自信恢复 (42) 以及使用ESMFold进行重新折叠 (中位值pTM 0.80 ± 0.08 ; scTM 0.96 ± 0.04 ; 附录 A.3.9)。

通过提示工程的实验, 我们观察到对提示的尤其富有创意的响应。在这里, 我们突出一个蛋白质压缩的例子 (图. 2D)。从自然胰蛋白酶 (PDB 1Y3V) 开始, 我们使用催化三联体的序列和坐标作为提示, 并使用描述胰蛋白酶的功能关键词, 但将整体生成长度减少了三分之一 (从223减少到150个残基)。ESM3 维持了活性位点的协调性 (全原子 RMSD 0.73°A) 以及高设计性下的整体折叠 (pTM 0.84 , scTM 平均值 0.97 , 标准差 0.006), 尽管序列长度显著减少并且折叠仅通过功能关键词提示进行指定 (附录 A.3.10)。

这些示例展示了ESM3在任何输入轨道中找到针对提示的创造性解决方案的能力, 无论是单独使用还是组合使用。这一能力使得在蛋白质设计中能够采取一种理性的方法, 在从高级拓扑到原子坐标的不同抽象层次上提供控制, 利用生成模型来架起提示与生物复杂性之间的桥梁。

生物对齐

尽管我们观察到基础模型在规模上的性能有了显著提升, 但更大的模型可能具有我们未观察到的更强隐含能力。基础ESM3模型可以被提示执行诸如三级结构模板搭建和提示组成等困难任务, 尽管这些模型并未为这些目标进行明确优化。由于我们评估生成输出的属性——例如对提示的遵循程度或支架的置信度——在预训练期间仅被模型间接感知, 因此通过微调将模型直接对齐到生成任务可能会造成更大的能力差异, 尤其是在更大的模型中。

我们研究基础模型如何被对齐 (43, 44) 以生成满足挑战性提示的蛋白质。对于每个模型, 我们构建一个由主链原子坐标提示组成的数据集, 该提示包含连续的残基区间和指定接触氨基酸身份的三级结构模板。我们为每个提示生成多个蛋白质序列, 并使用ESM3对每个序列进行折叠, 评估其与提示的一致性 (主链cRMSD) 及结构预测置信度 (pTM)。高质量样本与同一提示下的低质量样本配对, 以构建偏好数据集 (附录 A.4)。然后, ESM3利用偏好优化损失 (45, 46) 进行微调, 从而使模型相对于低质量样本更倾向于高质量样本。

在对每个基础模型进行对齐后, 我们评估它们的绝对性能以及生成分布的变化。我们专注于一系列挑战性的提示, 这些提示要求协调处于三级接触的残基的主链原子。我们评估生成高质量支架的能力 (pTM > 0.8), 该支架遵循高分辨率的提示 (主链cRMSD $< 1.5^\circ\text{A}$), 并使用ESM-Fold进行评估。我们来自46个配体结合基序的保持数据集中的氨基酸身份和主链原子坐标对每个模型进行提示 (附录 A.4.5)。对于每个基序, 我们通过排列残基的顺序、改变它们在序列中的位置以及改变序列的长度创建1024个提示。每个提示生成一个单一的蛋白质。每个基序的1024个生成用于构建在128个生成后解决的三级协调任务的比例的无偏估计器。

用语言模型模拟五亿年的进化




图3. 解决复杂任务的能力随着对齐而通过规模增加。ESM3按照与从提示生成构建的偏好对的数据集相结合的三维协调提示进行对齐，其中具有良好所需属性得分（高pTM，低cRMSD）的正样本与得分较低的负样本成对。偏好调整损失鼓励模型对正样本赋予更高的可能性。在训练后，通过提示与三维接触残基的主链原子坐标评估模型。(A) 我们展示了细调对通过128代解决的任务比例（Pass@128；2个标准误差条）的影响。随着模型规模的增长，之间出现了巨大的差距。对齐的响应显示出最大模型在解决复杂任务方面的潜在能力。(B) 为每个三维构型生成的不同解决方案数量（在TM > 0.8处聚类）。在细调后，对于那些成功的配体，通常会有许多独特的解决方案。(C) 在98B规模下，展示了基本模型（左）和对齐模型（右）在多个随机选择的配体中的提示生成密度。在对齐后，对提示的忠实度（主链cRMSD）和生成质量（pTM）往往显著改善。

操作 (Pass@128; 附录 A.4.5).

对齐的模型解决的三级协调任务数量是基础模型的两倍（图.3A）。虽然基础模型在解决任务的百分比上表现出差异（1.4B为9.5%，7B为19.0%，98B为26.8%；图.3A），但通过对齐揭示了更大的能力差异（对于1.4B、7B和98B模型，分别从9.5%增加到18.8%、19.0%增加到37.4%、26.8%增加到65.5%）。偏好调优模型不仅解决了更大比例的任务，而且每个任务找到的解决方案数量也更多，这通过不同结构簇的数量（TM > 0.8）以及主链 cRMSD < 1.5 Å 和 pTM > 0.8 进行评估（图.3B）。观察到每个配体结合模式的 ESMFold pTM 和主链 cRMSD 的分布发生了变化（图.3C；图.S17）。在98B规模下，微调模型在46个测试配体中的37个上产生了比基础模型更多的不同成功簇，而其余9个配体则未被基础模型或对齐模型解决，这表明对齐几乎普遍提高了对提示的忠诚度和对生成蛋白质的结构预测的信心。与仅最大化正例可能性的监督微调基线相比，偏好调优在所有规模上均导致更大幅度的改进（附录A.4.6）。

我们的对齐实验揭示了不同模型规模之间能力的显著差异。与未对齐的基模型相比，最大的对齐模型在对齐前后都有显著提升，同时与小规模模型相比亦是如此。通过对齐，这些模型学会了从少量示例中进行泛化：生成的分布发生变化，从而提升了

支架的质量和与提示的一致性，增加了解决的任务比例和不同解决方案的数量。

对齐要求模型通过示例进行学习。识别通过微调示例所展示的潜在属性的能力，并将这些展示推广到新任务，意味着对微调所访问属性的内部表示存在。这种表示空间是通过预训练过程学习的，在此过程中模型在进化过程中学习蛋白质，这表明它反映并包含了蛋白质生物学的巨大多样性和复杂性。这种表示空间可能包含支持多种生物特性泛化的特征。较大模型对齐的更大响应性表明，它们的内部表示空间更好地近似那些潜在属性，这是通过在预训练中学习的特征而改善迁移深能力的证据，且随着规模的增加而提高。

生成一个新的荧光蛋白

我们希望了解基础的预训练ESM3模型是否具有生成功能性蛋白质的足够生物学保真度。我们着手创建一种与现有蛋白质序列相似度较低的功能性绿色荧光蛋白（GFP）。我们选择荧光作为功能，因为它难以实现、易于测量，并且是自然界中最美丽的机制之一。

负责水母的荧光和珊瑚鲜艳颜色的47，GFP家族中的蛋白质是独特的

使用语言模型模拟五亿年的进化




图4. 生成新的荧光蛋白与思维链。(A) 我们使用残基的序列和结构提示ESM3，以形成和催化发色团反应所需的结构，以及来自天然GFP的部分中心α螺旋的结构（左）。通过思维链，ESM3生成设计候选（右）。(B) ESM3在两次实验中发现了一种与其他已知GFP相距较远的明亮GFP。我们在大肠杆菌裂解液中测量荧光。上排为板的照片。下排为板读荧光定量。已知GFP的阳性对照用紫色圆圈标记，没有GFP序列或没有大肠杆菌的阴性对照用红色圆圈标记。在第一次实验中（左），我们表达了具有不同序列一致性的设计。一个与已知荧光蛋白的序列一致性较低（57%）的显著设计出现在标记为B8的孔中（底部黑圈突出，顶部白圈）。我们从孔B8中的蛋白质继续思维链进行第二次实验（右）。在标记为C10的孔中出现一个明亮设计（与已知荧光蛋白的序列一致性为58%，底部黑圈，顶部白圈），我们将其指定为esmGFP。(C) esmGFP的荧光强度与常见GFP相似。在实验2中显示了一部分蛋白质的归一化荧光。(D) esmGFP的激发和发射光谱与EGFP的光谱重叠。(E) esmGFP预测结构的中心α螺旋和β桶内部的两个剪裁视图。esmGFP相对于其最近邻tagRFP的96个突变以蓝色显示。(F) 不同分类群之间荧光蛋白序列一致性的累积分布。esmGFP与所有其他FP的相似性水平通常在比较同一类内的序列时发现，但跨越不同的目。(G) 三个示例刺胞动物GFP与esmGFP的时间（百万年MY）进化距离与序列一致性。(H) 从GFP序列一致性估计的时间（MY）进化距离。我们估计esmGFP与已知最接近的蛋白质相隔超过五亿年的自然进化。

利用语言模型模拟五亿年的进化

它们在无需辅因子或底物的情况下形成发色团的能力上(30)。这一特性允许将GFP序列插入其他生物的基因组中,以可视化标记分子、细胞结构或过程,提供了一种已广泛应用于生物科学的基础工具包。

GFP家族已成为几十年来蛋白质工程努力的研究对象,但功能变异的绝大多数多样性仍源自自然界的勘探。理性设计和突变技术已产生了具有改进特性的GFP序列——例如更高的亮度或稳定性,或者不同颜色的变体——这些变体包含少量突变(通常为5到15个,基于总计238个氨基酸编码序列)。在少数情况下,科学家们利用高通量实验和机器学习,已经能够引入多达40-50个突变(即80%的序列一致性),同时保留荧光性(48-50)。

生成一种新的GFP需要物化其荧光所基于的复杂生物化学和物理学。在所有GFP中,一个自催化过程由蛋白质核心中的三个关键氨基酸形成发色团。GFP的独特结构,一个扭曲的中心 α 螺旋被一个内侧面向协调残基的十一个链 β 螺旋筒包围,使这一反应成为可能(51)。一旦形成,发色团不仅必须吸收光,还必须发出光以实现荧光。光的发射对发色团的局部电子环境高度敏感。GFP的适应度景观反映了实现其功能所需的活性位点及其周围三级相互作用的精确配置,因为少量随机突变就足以将荧光降低到零(48,52)。

为了生成新的GFP序列,我们直接提示基础预训练的7B参数ESM3生成一个以Thr62、Thr65、Tyr66、Gly67、Arg96、Glu222位置为条件的229残基蛋白,这些残基对于形成和催化发色团反应至关重要(图4A)。此外,我们还依据1QY3中实验结构的58到71残基的结构进行条件处理,这些残基已知对发色团形成的能量优势在结构上非常重要(53)。具体而言,输入中提供了序列标记、结构标记和主链的原子坐标,生成从几乎完全掩蔽的对应于229残基的标记数组开始,除了用于条件处理的标记位置。

我们使用以下链式思维程序生成设计。模型首先生成结构标记,有效地创建了蛋白质骨架。骨架在活性位点的原子协调上具有足够良好的表现,但整体结构与1QY3骨架有所区别。

通过过滤器传递到链的下一步骤。我们将生成的结构添加到原始提示中,以生成基于新提示的序列。然后,我们进行迭代联合优化,在优化序列和结构之间交替进行。我们拒绝失去活性位点原子协调的链式思维(附录A.5.1)。我们从生成协议的迭代联合优化阶段的中间和最终点中提取出数万种候选GFP设计。我们根据与已知荧光蛋白的序列相似性对设计进行分类,并使用各种指标对设计进行过滤和排名(详细信息见附录A.5.1.5)。

我们在一个96孔板上进行了首次实验,测试了88种设计,评估了每个序列相似性桶中的最佳生成物。每种生成的蛋白质都在大肠杆菌中合成、表达,并在485 nm的激发波长下测量荧光活性(见图.4B左)。我们的测量亮度与一些具有更高序列一致性的设计的阳性对照相似,这些设计与自然存在的绿荧光蛋白(GFPs)相比。我们还在B8孔中识别出一个设计(用黑圈突出显示),该设计与1QY3序列的序列一致性仅为36%,而与现存最近的荧光蛋白tagRFP的序列一致性为57%。该设计的亮度比自然GFPs低50倍,且其发色团的成熟过程超过一周,而不是在一天之内,但它在我们所知未在自然界或通过蛋白质工程中发现的新序列空间部分中表现出功能信号。

我们继续从B8孔设计的序列出发,开展思路链,以生成具有更高亮度的蛋白质,采用与上述相同的迭代联合优化和排名程序。我们创建了第二个96孔板的设计,并使用相同的孔板读数检测,我们发现该组中的一些设计拥有与自然中发现的GFPs相当的亮度。最佳设计位于第二个板的C10孔(见图.4B右),我们将其指定为esmGFP。

我们发现esmGFP在自然绿荧光蛋白的分布中表现出亮度。我们评估了在发色团成熟的0、2和7天的荧光强度,并绘制了这些esmGFP测量结果,与B8的重复、B8的发色团敲除体及三种自然的绿荧光蛋白avGFP、cgreGFP、ppluGFP一起展示(图4C)。esmGFP的成熟时间比我们测量的已知绿荧光蛋白要长,但在两天后却达到了相当的亮度。为了验证荧光是由预期的Thr65和Tyr66介导的,我们展示了将这些残基突变为甘氨酸的B8和esmGFP变体失去了荧光活性(图.S21)。

对esmGFP的激发和发射光谱的分析显示,其峰值激发发生在496 nm,在相对于EGFP的489 nm峰值处发生了7 nm的偏移,

使用语言模型模拟五亿年的进化

尽管两种蛋白质在512纳米的峰值处发射(图4D)。谱形状表明, es- mGFP的激发光谱具有更窄的全宽半最大值(FWHM)(esmGFP为39纳米, EGFP为56纳米), 而它们的发射光谱的FWHM则高度相似(分别为35纳米和39纳米)。总体而言, esmGFP表现出与已知绿荧光蛋白相一致的光谱特性。

接下来, 我们希望了解esmGFP与已知蛋白质的比较。通过对非冗余蛋白序列数据库进行BLAST (54) 搜索, 以及对ESM3训练集进行MMseqs (55) 搜索, 报告的首要命中都是tagRFP, 它也是与B8最近的邻居, 具有58%的序列一致性, 共表示在序列中的96个突变。tagRFP是一个设计变体, 而esmGFP在自然界中最近的野生型序列是eqFP578, 一种红色荧光蛋白, 其不同于esmGFP有107个序列位置(53%一致性)。esmGFP和tagRFP之间的序列差异贯穿整个结构(图4E), 其内部发生了22个突变, 而该区域因发色团的接近性和高密度的相互作用, 已知对突变高度敏感(56)。

对648种天然和设计的GFP样荧光蛋白序列对齐的检查显示, esmGFP的相似度水平与所有其他FPs相似, 这种相似度通常在比较属于同一分类学类的序列时发现(图4F)。例如, esmGFP与其他FPs的差异类似于属于石珊瑚(Scleractinia)和海葵(Actiniaria)这两个属于海洋无脊椎动物更大分类类Anthozoa的分类学顺序之间FPs的差异(图4G)。与esmGFP最接近的FPs来自Anthozoa类(珊瑚和海葵; 平均序列一致性51.4%), 但esmGFP也与来自水母(Hydrozoa)的FPs共享某些序列一致性, 其中发现了avGFP(平均序列一致性33.4%; 图S22)。

我们可以从进化生物学中获得对蛋白质通过自然进化产生所需时间的洞察, 这一蛋白质与之具有相似的序列一致性。在图. 4G中, 我们展示了esmGFP以及三种珊瑚纲GFP。我们采用了一个时间校准的系统发育分析, 该分析针对珊瑚纲(57)估算了最后共同祖先至今的百万年前(MYA)时间, 以估计这些物种之间的进化时间。利用一个较大的数据集, 该数据集包含六种珊瑚纲GFP和我们拥有准确最后共同祖先MYA及GFP序列一致性的物种, 我们构建了一个简单的估算器, 该估算器将光合荧光蛋白之间的序列一致性与物种间的百万年进化时间(图. 4H)相联系, 以对照自然进化。基于此分析, 我们估计esmGFP代表了超过五亿年的进化等效。

从在自然界中发现的最接近的蛋白质。

讨论

我们发现, 语言模型能够达到一个与自然进化所探索的蛋白质设计空间相距甚远的区域, 并生成功能蛋白, 这些蛋白质的发现将需要经过数亿年的进化才能实现。蛋白质语言模型并未明确地在进化的物理约束内工作, 而是可以隐含地构建出进化可能遵循的众多潜在路径的模型。

蛋白质可以被视为存在于一个有序空间中, 在该空间内, 每个蛋白质都与每个与其相邻的蛋白质相距一个突变事件(58)。进化的结构出现在这个空间内, 作为一个网络, 将所有蛋白质通过进化可能采取的路径连接起来。进化可以遵循的路径是每个蛋白质转变为下一个蛋白质的路径, 而不导致其所处系统的功能集体损失。

语言模型在这个空间中看待蛋白质。它将蛋白质的数据视为填充这个空间, 在某些区域密集而在其他区域稀疏, 揭示出进化可及的部分。由于下一个标记是由进化生成的, 因此, 解决预测下一个标记的训练任务就意味着语言模型必须预测进化如何在可能蛋白质的空间中移动。

模拟是对现实的计算表示。从这个意义上讲, 能够预测进化可能结果的语言模型可以被认为是这种模拟器。ESM3是一个新兴的模拟器, 它是通过解决在进化生成的数据上进行标记预测任务而学习到的。已经有人理论化神经网络发现它们被训练以预测的数据的潜在结构(59, 60)。通过这种方式, 解决标记预测任务将要求模型学习决定进化可以采取哪些步骤的深层结构, 即蛋白质的基本生物学。

在ESM3生成新型荧光蛋白时, 最引人入胜的是到B8的第一思路。到B8最近邻的突变有96个, 有 $\binom{229}{96} \times 19^{96}$ 种可能的蛋白质, 其中只有极少数能够具有功能, 因为即使在仅经过几次随机突变后, 荧光的强度也会急剧下降。在B8周围发现C10及其他明亮设计的存在, 确认了在到B8的第一思路中, ESM3发现了一部分蛋白质空间, 尽管尚未被自然探索, 但其中充满了荧光蛋白。

使用语言模型模拟五亿年的演化

- [7] M. Heinzinger, A. Elnaggar, Y. Wang, C. Dallago, D. Nechaev, F. Matthes 和 B. Rost. 通过迁移学习建模生命语言的各个方面的蛋白质序列. BMC 生物信息学, 20(1):723, 2019.
- [8] A. Rives, J. Meier, T. Sercu, S. Goyal, Z. Lin, J. Liu, D. Guo, M. Ott, C. L. Zitnick, J. Ma等. 生物结构和功能是通过将无监督学习扩展到250百万个蛋白质序列而出现的。美国国家科学院院刊, 118(15):e2016239118, 2021年4月。国际标准连续出版物号 0027-8424, 1091-6490。数字对象标识符: 10.1073/pnas.2016239118。网址<https://www.pnas.org/content/118/15/e2016239118>。出版社: 美国国家科学院部门: 生物科学。
- [9] A. Madani, B. Krause, E. R. Greene, S. Subramanian, B. P. Mohr, J. M. Holton, J. L. Olmos, C. Xiong, Z. Z. Sun, R. Socher, J. S. Fraser 和 N. Naik. 大语言模型在不同家族中生成功能性蛋白质序列。自然生物技术, 41(8):1099–1106, 2023年8月。国际标准连续出版物号 1546-1696。数字对象标识符: 10.1038/s41587-022-01618-2。网址<https://www.nature.com/articles/s41587-022-01618-2>。出版社: 自然出版集团。
- [10] N. Ferruz, S. Schmidt, 和 B. Höcker. ProtGPT2 是一种用于蛋白质设计的深度无监督语言模型。自然通讯, 13(1):4348, 2022年7月。
- [11] R. Verkuil, O. Kabeli, Y. Du, B. I. Wicky, L. F. Milles, J. Dauparas, D. Baker, S. Ovchinnikov, T. Sercu, 和 A. Rives. 语言模型超越自然蛋白质进行泛化。bioRxiv, 第2022年12页, 2022年。
- [12] A. Elnaggar, M. Heinzinger, C. Dallago, G. Ri-hawi, Y. Wang, L. Jones, T. Gibbs, T. Feher, C. Angerer, D. Bhowmik, 和 B. Rost. Prot-Trans: 通过自监督深度学习和高性能计算破解生命代码的语言。IEEE模式分析与机器智能交易, 14(8):1–1, 2021年7月。doi: 10.1109/TPAMI.2021.3095381。网址<https://www.osti.gov/pages/biblio/1817585>。机构: 橡树岭国家实验室 (ORNL), 田纳西州橡树岭 (美国)。
- [13] D. 赫斯洛, N. 扎尼切利, P. 诺廷, I. 波利, 和 D. 马克斯. RITA: 一项关于扩展生成性蛋白质序列模型的研究, 2022年7月。URL <http://arxiv.org/abs/2205.05789>. arXiv:2205.05789 [cs,q-bio].
- [14] E. 奈坎普, J. A. 拉弗洛, E. N. 温斯坦, N. 内克, 和 A. 马达尼. ProGen2: 探索蛋白质语言模型的边界。细胞系统, 第 14 卷 (第 11 期): 968–978.e3, 2023年11月。国际标准连续出版物号 2405-4712, 2405-4720。数字对象标识符: 10.1016/j.cels.2023.10.002。URL[https://www.cell.com/cell-systems/abstract/S2405-4712\(23\)00272-7](https://www.cell.com/cell-systems/abstract/S2405-4712(23)00272-7)。出版社: 埃尔塞维尔。
- [15] S. Alamdari, N. Thakkar, R. van den Berg, A. X. Lu, N. Fusi, A. P. Amini, 和 K. K. Yang. 通过进化扩散生成蛋白质: 序列是你所需要的一切。bioRxiv, 第 2023–09 页, 2023。
- [16] M. Heinzinger, K. Weissenow, J. G. Sanchez, A. Henkel, M. Mirdita, M. Steinegger, 和 B. Rost. 蛋白质序列和结构的双语语言模型, 2024年3月。网址<https://www.biorxiv.org/content/10.1101/2023.07.23.550085v2>。页面: 2023.07.23.550085 5 章节: 新结果。
- [17] J. Su, C. Han, Y. Zhou, J. Shan, X. Zhou, 和 F. Yuan. Saprot: 具有结构感知词汇的蛋白质语言建模。bioRxiv, 第 2023–10 页, 2023。
- [18] J. Meier, R. Rao, R. Verkuil, J. Liu, T. Sercu 和 A. Rives. 语言模型使无监督预测突变对蛋白质功能的影响成为可能。神经信息处理系统进展, 34, 2021年7月。数字对象标识符: 10.1101/2021.07.09.450648。网址 <http://biorxiv.org/lookup/doi/10.1101/2021.07.09.450648>。
- [19] J. Vig, A. Madani, L. R. Varshney, C. Xiong, R. Socher 和 N. F. Rajani. Bertology 与生物学相遇: 阐释蛋白质语言模型中的注意力。arXiv 预印本 arXiv:2006.15222, 2020。
- [20] R. Rao, J. Meier, T. Sercu, S. Ovchinnikov 和 A. Rives. 变压器蛋白语言模型是无监督的结构学习者。在国际学习表征会议上, 页码 2020.12.15.422761。冷泉港实验室, 2021年12月。数字对象标识符: 10.1101/2020.12.15.422761。
- [21] B. Chen, X. Cheng, L.-a. Gengyang, S. Li, X. Zeng, B. Wang, G. Jing, C. Liu, A. Zeng, Y. Dong, 等. xtri-mopglm: 统一的100b规模预训练变换器, 用于破译蛋白质语言。bioRxiv, 第 2023–07页, 2023年。
- [22] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu 和 D. Amodei. 神经语言模型的缩放法则, 2020年1月。网址<http://arxiv.org/abs/2001.08361>。arXiv:2001.08361 [cs,stat].

使用语言模型模拟五亿年的进化

- [23] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell 等人。语言模型是少量样本学习者。神经信息处理系统进展, 33:1877–1901, 2020。
- [24] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. d. L. Casas, L. A. Hendricks, J. Welbl, A. Clark, T. Hennigan, E. Noland, K. Millican, G. v. d. Driessche, B. Damoc, A. Guy, S. Osindero, K. Simonyan, E. Elsen, J. W. Rae, O. Vinyals, and L. Sifre. 训练计算最优大语言模型. *arXiv*, 2022年3月。doi: 10.48550/arXiv.2203.15556. 网址<https://arxiv.org/abs/2203.15556v1>。
- [25] J. Abramson, J. Adler, J. Dunger, R. 埃文斯, T. 格林, A. 普里策尔, O. 罗内贝格, L. Willmore, A. J. Ballard, J. Bambrick, S. W. Bodenstern, D. A. 埃文斯, C.-C. Hung, M. O' Neill, D. Reiman, K. Tunyasuvunakool, Z. Wu, A. Zengmulyt'e, E. Arvaniti, C. Beattie, O. Bertolli, A. Bridgland, A. Cherepanov, M. Congreve, A. I. Cowen-Rivers, A. Cowie, M. 费古尔诺夫, F. B. Fuchs, H. Gladman, R. Jain, Y. A. Khan, C. M. R. Low, K. Perlin, A. 波塔彭科, P. Savy, S. Singh, A. Stecula, A. Thillaisundaram, C. Tong, S. Yakneen, E. D. Zhong, M. Zielinski, A. Zidek, V. Bapst, P. Kohli, M. Jaderberg, D. Hassabis, 和 J. M. Jumper. 生物分子相互作用的精确结构预测, 使用 AlphaFold 3. 自然, 630(8016):493–500, 2024年6月。国际标准连续出版物号 1476-4687。doi: 10.1038/s41586-024-07487-w. 网址<https://www.nature.com/articles/s41586-024-07487-w>。出版商: 自然出版集团。
- [26] J. L. Watson, D. Juergens, N. R. Bennett, B. L. Trippe, J. Yim, H. E. Eisenach, W. Ahern, A. J. Borst, R. J. Ragotte, L. F. Milles, B. I. M. Wicky, N. Hanikel, S. J. Pellock, A. Courbet, W. Sheffler, J. Wang, P. Venkatesh, I. Sappington, S. V. Torres, A. Lauko, V. De Bortoli, E. Mathieu, S. Ovchinnikov, R. Barzilay, T. S. Jaakkola, F. DiMaio, M. Baek, 和 D. Baker. 使用 RFdiffusion 的蛋白质结构和功能的新颖设计。自然, 620(7976):1089–1100, 2023年8月。国际标准连续出版物号 1476-4687。doi: 10.1038/s41586-023-06415-8. 网址<https://www.nature.com/articles/s41586-023-06415-8>。出版商: 自然出版集团。
- [27] J. B. Ingraham, M. Baranov, Z. Costello, K. W. Barber, W. Wang, A. Ismail, V. Frappier, D. M. Lord, C. Ng-Thow-Hing, E. R. Van Vlack, S. Tie, V. Xue, S. C. Cowles, A. Leung, J. V. Rodrigues, C. L. Morales-Perez, A. M. Ayoub, R. Green, K. Puentes, F. Oplinger, N. V. Panwar, F. Obermeyer, A. R. Root, A. L. Beam, F. J. Poelwijk, 和 G. Grigoryan. 利用可编程生成模型照亮蛋白质空间。自然, 623(7989):1070–1078, 2023年11月。国际标准连续出版物号 1476-4687. 数字对象标识符: 10.1038/s41586-023-06728-8. 网址<https://www.nature.com/articles/s41586-023-06728-8>。出版商: 自然出版集团。
- [28] Y. Lin, M. Lee, Z. Zhang, 和 M. AlQuraishi. 从众多中选择一个: 使用 genie 2 在结构宇宙的尺度上设计和支架蛋白质, 2024年5月。网址<https://arxiv.org/abs/2405.15489>。
- [29] O. Shimomura, F. H. Johnson, 和 Y. Saiga. 从发光水母瑞威水母中提取、纯化及瑞威蛋白的性质, 一种生物发光蛋白。细胞与比较生理学杂志, 59(3):223–239, 1962年。doi: <https://doi.org/10.1002/jcp.1030590302>. 网址<https://onlinelibrary.wiley.com/doi/abs/10.1002/jcp.1030590302>。
- [30] R. Y. Tsien. 绿色荧光蛋白。生物化学年鉴, 67:509–544, 1998年。国际标准连续出版物号 0066-4154. doi: 10.1146/annurev.biochem.67.1.509.
- [31] J. Devlin, M.-W. Chang, K. Lee, 和 K. Toutanova. Bert: 用于语言理解的深度双向变换器的预训练。arXiv 预印本 arXiv:1810.04805, 2018年。
- [32] H. Chang, H. 张, L. Jiang, C. Liu, 和 W. T. Freeman. Maskgit: 掩码生成图像变换器。发表在IEEE计算机视觉与模式识别会议 (CVPR), 2022年6月。
- [33] B. Uria, I. Murray, 和 H. Larochelle. 一种深度且可解的密度估计器。发表在第31届国际机器学习大会 - 第32卷, ICML' 14, 第I-467–I-475页。JMLR.org, 2014年。
- [34] J. Austin, D. D. Johnson, J. Ho, D. Tarlow, 和 R. van den Berg. 离散状态空间中的结构化去噪扩散模型, 2023年。
- [35] A. v. d. Oord, O. Vinyals, 和 K. Kavukcuoglu. 神经离散表征学习。神经信息处理系统进展, 2017年。
- [36] B. E. Suzek, Y. Wang, H. Huang, P. B. McGarvey, C. H. Wu, 和 U. Consortium. UniRef簇: 一种全面且可扩展的替代方案, 用于改进序列相似性搜索。生物信息学, 31(6): 926–932, 2014年。出版社: 牛津大学出版社。

用语言模型模拟五亿年的进化

- [37] L. 理查森, B. 艾伦, G. 巴尔迪, M. 贝拉科切亚, M. L. 比莱斯基, T. 伯代特, J. 伯金, J. 卡巴列罗-佩雷斯, G. 科克伦, L. J. 科尔韦尔, T. 柯蒂斯, A. 埃斯科巴-塞佩达, T. A. 古尔比奇, V. 卡莱, A. 科罗贝尼科夫, S. 拉杰, A. B. 罗杰斯, E. 萨哈罗娃, S. 桑切斯, D. J. 威尔金森, 和 R. D. 芬恩. MG-nify: 微生物组序列数据分析资源在2023年的应用。核酸研究, 51(D1): D753–D759, 12 2022. 国际标准连续出版物号 0305-1048. 数字对象标识符: 10.1093/nar/gkac1080. 网址<https://doi.org/10.1093/nar/gkac1080>.
- [38] T. H. 奥尔森, F. 博伊尔斯和C. M. 迪恩. 观察到的抗体空间: 一个多样化的数据库, 包含清理、注释和翻译的单价和双价抗体序列。蛋白质科学, 31 (1): 141–146, 2022. doi: <https://doi.org/10.1002/pro.4205>. 网址<https://onlinelibrary.wiley.com/doi/abs/10.1002/pro.4205>.
- [39] S. K. 伯利, H. M. 伯曼, C. 比卡迪亚, C. 毕, L. 陈, L. 迪·科斯坦佐, C. 克里斯蒂, K. 达伦伯格, J. M. 杜阿尔特, S. 达塔, Z. 冯, S. 哥什, D. S. 古德塞尔, R. K. 格林, V. 古拉诺夫, D. 古任科, B. P. 哈德森, T. 卡尔罗, Y. 梁, R. 洛, H. 南孔, E. 佩萨赫, I. 佩里斯科娃, A. Prli, C. 兰德尔, A. 罗斯, P. 罗斯, R. 萨拉, M. 塞克哈兰, C. 邵, L. 谭, Y.-P. 陶, Y. 瓦拉萨塔瓦, M. 费希特, J. 韦斯特布鲁克, J. 吴, H. 杨, J. 余, M. 朱拉夫列娃和C. 扎尔德基. RCSB 蛋白质数据银行: 推动基础生物学、生物医学、生物技术和能源研究与教育的生物大分子结构。核酸研究, 47, 2019. doi: 10.1093/nar/gky1004. 网址<https://academic.oup.com/nar/article-abstract/47/D1/D464/5144139>.
- [40] T. Paysan-Lafosse, M. Blum, S. Chuguransky, T. Grego, B. L. Pinto, G. Salazar, M. Bileschi, P. Bork, A. Bridge, L. Colwell, J. Gough, D. Haft, I. Letunic, A. Marchler-Bauer, H. Mi, D. Natale, C. Orengo, A. Pandurangan, C. Rivoire, C. J. A. Sigris, I. Silli-toe, N. Thanki, P. D. Thomas, S. C. E. Tosatto, C. Wu 和 A. Bateman. 2022年的InterPro. 核酸研究, 51(D1): D418–D427, 2023年1月. 国际标准连续出版物号 0305-1048. 数字对象标识符: 10.1093/nar/gkac993. 网址<https://doi.org/10.1093/nar/gkac993>.
- [41] M. van Kempen, S. Kim, C. Tumescheit, M. Mirdita, J. Soding 和 M. Steinegger. 《Foldseek: 快速而准确的蛋白质结构搜索》。bioRxiv, 2022年2月. doi: 10.1101/2022.02.07.479398. 网址<http://bioRxiv.org/lookup/doi/10.1101/2022.02.07.479398>.
- [42] C. Hsu, R. Verkuil, J. Liu, Z. Lin, B. Hie, T. Sercu, A. Lerer 和 A. Rives. 从数百万个预测结构中学习逆折叠。在 K. Chaudhuri, S. Jegelka, L. Song, C. Szepes-vari, G. Niu 和 S. Sabato, 编辑, 第39届国际机器学习会议论文集, 第162卷机器学习研究论文集, 第8946–8970页. PMLR, 2022年6月. 网址<https://proceedings.mlr.press/v162/hsu22a.html>. 国际标准连续出版物号: 2640-3498.
- [43] D. M. Ziegler, N. Stiennon, J. Wu, T. B. Brown, A. Radford, D. Amodei, P. Christiano, 和 G. Irving. 从人类偏好中微调语言模型。arXiv 预印本 arXiv:1909.08593, 2019年. 网址<https://arxiv.org/abs/1909.08593>.
- [44] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, 和 R. Lowe. 训练语言模型以依据人类反馈遵循指令, 2022年3月. 网址<http://arxiv.org/abs/2203.02155>. arXiv:2203.02155 [cs].
- [45] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning 和 C. Finn. 直接偏好优化: 您的语言模型实际上是一个奖励模型, 2023年12月. 网址<http://arxiv.org/abs/2305.18290>. arXiv:2305.18290 [cs].
- [46] R. Y. Pang, W. Yuan, K. Cho, H. He, S. Sukhbaatar 和 J. Weston. 迭代推理偏好优化, 2024年5月. 网址<http://arxiv.org/abs/2404.19733>. arXiv:2404.19733 [cs].
- [47] Y. A. Labas, N. G. Gurskaya, Y. G. Yanushevich, A. F. Fradkov, K. A. Lukyanov, S. A. Lukyanov 和 M. V. Matz. 绿色荧光蛋白家族的多样性与演化。美国国家科学院院刊, 99 (7): 4256–4261, 2002年4月. doi: 10.1073/pnas.062552299. 网址<https://www.pnas.org/doi/full/10.1073/pnas.062552299>. 出版商: 美国国家科学院院刊。
- [48] L. Gonzalez Somermeyer, A. Fleiss, A. S. Mishin, N. G. Bozhanova, A. A. Igolkina, J. Meiler, M.-E. Alaball Pujol, E. V. Putintseva, K. S. Sarkisyan 和 F. A. Kondrashov. GFP适应性景观的异质性与数据驱动蛋白质设计。eLife, 11: e75842, 2022年5月. 国际标准连续出版物号 2050-084X. 数字对象标识符: 10.7554/eLife.75842. 网址<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9119679/>.

使用语言模型模拟五亿年的进化

- [49] S. Biswas, G. Kuznetsov, P. J. Ogden, N. J. Conway, R. P. Adams, 和 G. M. Church. 朝着机器引导的蛋白质设计迈进. *bioRxiv*, 第337154页, 2018年。数字对象标识符: 10.1101/337154。网址<https://www.biorxiv.org/content/early/2018/06/02/337154>.
- [50] S. Biswas, G. Khimulya, E. C. Alley, K. M. Esvelt, 和 G. M. Church. 数据高效深度学习的低-n 蛋白质工程. *自然方法*, 18(4): 389–396, 2021.
- [51] M. Orm^o, A. B. Cubitt, K. Kallio, L. A. Gross, R. Y. Tsien, 和 S. J. Remington. 维多利亚水母绿色荧光蛋白的晶体结构. *科学*, 273(5280):1392–1395, 1996年9月. doi: 10.1126/science.273.5280.1392. 网址 <https://www.science.org/doi/10.1126/science.273.5280.1392>. 出版社: 美国科学促进会.
- [52] K. S. Sarkisyan, D. A. Bolotin, M. V. Meer, D. R. Usmanova, A. S. Mishin, G. V. Sharonov, D. N. Ivankov, N. G. Bozhanova, M. S. Baranov, O. Soylemez, N. S. Bogatyreva, P. K. Vlasov, E. S. Egorov, M. D. Logacheva, A. S. Kondrashov, D. M. Chudakov, E. V. Putintseva, I. Z. Mamedov, D. S. Tawfik, K. A. Lukyanov, 和 F. A. Kondrashov. 绿色荧光蛋白的局部适应度景观. *自然*, 533(7603):397–401, 2016年5月。国际标准连续出版物号 14764687。数字对象标识符: 10.1038/nature17995。网址<https://www.nature.com/articles/nature17995>. 出版商: 自然出版集团。
- [53] D. P. Barondeau, C. D. Putnam, C. J. Kassmann, J. A. Tainer 和 E. D. Getzoff. 通过被捕获的中间体结构揭示绿色荧光蛋白发色团合成的机制和能量. *美国国家科学院院刊*, 100(21):12111–12116, 2003年10月. doi: 10.1073/pnas.2133463100. 网址 <https://www.pnas.org/doi/full/10.1073/pnas.2133463100>. 出版者: 美国国家科学院院刊。
- [54] C. Camacho, G. Coulouris, V. Avagyan, N. Ma, J. Papadopoulos, K. Bealer 和 T. L. Madden. BLAST+: 架构与应用. *BMC 生物信息学*, 10:1–9, 2009.
- [55] M. Steinegger 和 J. S^oding. Mmseqs2 使得对大规模数据集进行敏感的蛋白质序列搜索成为可能. *《自然生物技术》*, 35(11): 1026–1028, 2017.
- [56] J. Y. Weinstein, C. Martⁱ-G^omez, R. Lipsh- Sokolik, S. Y. Hoch, D. Liebermann, R. Nevo, H. Weissman, E. Petrovich-Kopitman, D. Margulies, D. Ivankov, D. M. McCandlish, 和 S. J. Fleishman. 设计的活性位点库揭示了数千种功能性GFP变体. *自然通讯*, 14(1):2890, 2023年5月。ISSN 2041- 1723. doi: 10.1038/s41467-023-38099-z. 网址<https://www.nature.com/articles/s41467-023-38099-z>. 出版商: 自然出版集团。
- [57] A. M. Quattrini, E. Rodr^íguez, B. C. Faircloth, P. F. Cowman, M. R. Brugler, G. A. Farfan, M. E. Hellberg, M. V. Kitahara, C. L. Morrison, D. A. Paz-Garc^ía, J. D. Reimer, 和 C. S. McFadden. 古气候海洋条件塑造了珊瑚及其骨骼在深时间中的演化. *自然生态与进化*, 4(11):1531–1538, 2020年8月。国际标准连续出版物号 2397-334X。数字对象标识符: 10.1038/s41559-020-01291-1. 网址<https://www.nature.com/articles/s41559-020-01291-1>.
- [58] J. Maynard Smith. 自然选择与蛋白质空间的概念. *自然*, 225(5232):563–564, 1970.
- [59] G. E. Hinton, J. L. McClelland 和 D. E. Rumelhart. 分布式表示. 收录于《人工智能的哲学》, 1986年.
- [60] N. Tishby, F. C. Pereira 和 W. Bialek. 信息瓶颈方法. arXiv 预印本 physics/0004057, 1999年.
- [61] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser 和 I. Polosukhin. 只需关注. 收录于《神经信息处理系统进展》, 第5998–6008页, 2017年。网址<https://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf>.
- [62] R. Xiong, Y. Yang, D. He, K. Zheng, S. Zheng, C. Xing, H. Zhang, Y. Lan, L. Wang 和 T.-Y. Liu. 变换器架构中的层归一化. arXiv:2002.04745, 2020年.
- [63] J. 贾姆帕, R. 埃文斯, A. 普里策尔, T. 格林, M. 费古尔诺夫, O. 罗内贝格, K. 图尼亚苏瓦纳库尔, R. 贝茨, A. ^zidek, A. 波塔彭科, 等. 使用 AlphaFold 进行高精度蛋白质结构预测. *自然*, 596(7873):583–589, 2021.
- [64] W. 卡布什 和 C. 桑德. 蛋白质二级结构词典: 氢的模式识别

使用语言模型模拟五亿年的进化

- 结合与几何特征。《生物聚合物: 生物分子原始研究》, 1983年。
网址 <http://arxiv.org/abs/2205.14135>. arXiv:2205.14135 [计算机科学].
- [65] J. Su, Y. Lu, S. Pan, B. Wen, 和 Y. Liu. RoFormer: 增强型变换器与旋转位置嵌入, 2021年10月. URL<http://arxiv.org/abs/2104.09864>. arXiv:2104.09864 [cs] 版本: 2.
- [66] N. Shazeer. GLU 变体改善变换器, 2020年2月. URL<http://arxiv.org/abs/2002.05202>. arXiv:2002.05202 [cs,stat].
- [67] A. Chowdhery, S. Narang, J. Devlin, M. Bosma, G. Mishra, A. Roberts, P. Barham, H. W. Chung, C. Sutton, S. Gehrmann, P. Schuh, K. Shi, S. Tsvyashchenko, J. Maynez, A. Rao, P. Barnes, Y. Tay, N. Shazeer, V. Prabhakaran, E. Reif, N. Du, B. Hutchinson, R. Pope, J. Bradbury, J. Austin, M. Isard, G. Gur-Ari, P. Yin, T. Duke, A. Levskaya, S. Ghemawat, S. Dev, H. Michalewski, X. Garcia, V. Misra, K. Robinson, L. Fedus, D. Zhou, D. Ippolito, D. Luan, H. Lim, B. Zoph, A. Spiridonov, R. Sepassi, D. Dohan, S. Agrawal, M. Omernick, A. M. Dai, T. S. Pillai, M. Pellat, A. Lewkowycz, E. Moreira, R. Child, O. Polozov, K. Lee, Z. Zhou, X. Wang, B. Saeta, M. Diaz, O. Firat, M. Catasta, J. Wei, K. Meier-Hellstern, D. Eck, J. Dean, S. Petrov, 和 N. Fiedel. PaLM: 通过路径扩展语言建模, 2022年4月. URL <http://arxiv.org/abs/2204.02311>. arXiv:2204.02311 [cs].
- [68] T. Henighan, J. Kaplan, M. Katz, M. Chen, C. Hesse, J. Jackson, H. Jun, T. B. Brown, P. Dhariwal, S. Gray, C. Hallacy, B. Mann, A. Radford, A. Ramesh, N. Ryder, D. M. Ziegler, J. Schulman, D. Amodei, 和 S. McCandlish. 自回归生成建模的缩放法则. *CoRR*, abs/2010.14701, 2020. 网址<https://arxiv.org/abs/2010.14701>. eprint:2010.14701.
- [69] N. Wies, Y. Levine, D. Jannai, 和 A. Shashua. 哪种变压器架构适合我的数据? 自注意力中的词汇瓶颈, 2021年.
- [70] J. Ingraham, V. Garg, R. Barzilay 和 T. Jaakkola. 基于图的蛋白质设计的生成模型. 在神经信息处理系统的进展, 第12页. 麻省理工学院, 2019年. 网址<https://www.mit.edu/~vgraham/GenerativeModelsForProteinDesign.pdf>.
- [71] T. Dao, D. Y. Fu, S. Ermon, A. Rudra 和 C. Ré. FlashAttention: 具有 IO 感知的快速且内存高效的精确注意力, 2022年6月.
- [72] J. Su, C. Han, Y. Zhou, J. Shan, X. Zhou 和 F. Yuan. SaProt: 基于结构感知词汇的蛋白质语言建模, 2024年4月. 网址<https://www.biorxiv.org/content/10.1101/2023.10.01.560349v5>. 页面: 2023.10.01.560349 部分: 新结果.
- [73] A. v. d. Oord, O. Vinyals 和 K. Kavukcuoglu. 神经离散表示学习. *arXiv:1711.00937 [cs]*, 2018年5月. 网址<http://arxiv.org/abs/1711.00937>. arXiv:1711.00937.
- [74] A. Razavi, A. van den Oord, 和 O. Vinyals. 利用 VQ-VAE 生成多样化的高保真图像- 2. *CoRR*, abs/1906.00446, 2019年. 网址<http://arxiv.org/abs/1906.00446>.
- [75] A. Roy, A. Vaswani, A. Neelakantan, 和 N. Parmar. 关于向量量化自编码器的理论与实验. *CoRR*, abs/1805.11063, 2018年. 网址<http://arxiv.org/abs/1805.11063>.
- [76] J. Yu, Y. Xu, J. Y. Koh, T. Luong, G. Baid, Z. Wang, V. Vasudevan, A. Ku, Y. Yang, B. K. Ayan, B. Hutchinson, W. Han, Z. Parekh, X. Li, H. Zhang, J. Baldridge, 和 Y. Wu. 扩展自回归模型用于内容丰富的文本转图像生成, 2022年.
- [77] T. U. Consortium. UniProt: 在2023年的通用蛋白质知识库. 核酸研究, 51 (D1):D523–D531, 2022年11月. 国际标准连续出版物号 0305-1048. 数字对象标识符: 10.1093/nar/gkac1052. 网址<https://doi.org/10.1093/nar/gkac1052>.
- [78] I.-M. A. Chen, K. Chu, K. Palaniappan, A. Ratner, J. Huang, M. Huntemann, P. Hajek, S. J. Ritter, C. Webb, D. Wu, N. J. Varghese, T. B. K. Reddy, S. Mukherjee, G. Ovchinnikova, M. Nolan, R. Seshadri, S. Roux, A. Visel, T. Woyke, E. A. Eloie-Fadrosch, N. C. Kypides, 和 N. N. Ivanova. IMG/M 数据管理与分析系统 v.7: 内容更新和新特性. 核酸研究, 51(D1):D723–D732, 2022年11月. 国际标准连续出版物号 0305-1048. 数字对象标识符: 10.1093/nar/gkac976. 网址<https://doi.org/10.1093/nar/gkac976>.
- [79] M. Steinegger 和 J. Söding. MMseqs2 实现了对大规模数据集分析的敏感蛋白质序列搜索. 自然生物技术, 35(11): 1026–1028, 2017年11月. 国际标准连续出版物号 1546-1696. 数字对象标识符: 10.1038/nbt.3988. 网址<https://www.nature.com/articles/nbt.3988>. 编号: 11 出版商: 自然出版集团.

使用语言模型模拟五亿年的进化

- [80] P. Jones, D. Binns, H.-Y. Chang, M. Fraser, W. Li, C. McAnulla, H. McWilliam, J. Maslen, A. Mitchell, G. Nuka, S. Pesseat, A. F. Quinn, A. Sangrador-Vegas, M. Scheremetjew, S.-Y. Yong, R. Lopez, and S. Hunter. InterProScan 5: 基因组规模蛋白质功能分类。生物信息学, 30(9):1236–1240, 2014年01月。ISSN 1367-4803. doi: 10.1093/bioinformatics/btu031. 网址<https://doi.org/10.1093/bioinformatics/btu031>.
- [81] P. Kunzmann 和 K. Hamacher. biotite: 一个统一的开源计算生物学框架, 使用 Python。BMC 生物信息学, 19(1):346, 2018年10月。国际标准连续出版物号 1471-2105。数字对象标识符: 10.1186/s12859-018-2367-z。网址<https://doi.org/10.1186/s12859-018-2367-z>。
- [82] W. G. Touw, C. Baakman, J. Black, T. A. te Beek, E. Krieger, R. P. Joosten 和 G. Vriend. 一系列与 PDB 相关的数据库, 以满足日常需求。核酸研究, 43(D1): D364–D368, 2015年1月。国际标准连续出版物号 0305-1048。数字对象标识符: 10.1093/nar/gku1028. 网址<https://doi.org/10.1093/nar/gku1028>。
- [83] I. Loshchilov 和 F. Hutter. 解耦权重衰减正则化。arXiv:1711.05101, 2017.
- [84] Y. Zhao, A. Gu, R. Varma, L. Luo, C.-C. Huang, M. Xu, L. Wright, H. Shojanazeri, M. Ott, S. Shleifer, A. Desmaison, C. Balioglu, P. Damania, B. Nguyen, G. Chauhan, Y. Hao, A. Mathews 和 S. Li. Py-torch fsdp: 扩展完全分片数据并行的经验, 2023.
- [85] NVIDIA. Transformer 引擎。<https://github.com/NVIDIA/TransformerEngine>, 2024.
- [86] B. Lefaudeux, F. Massa, D. Liskovich, W. Xiong, V. Caggiano, S. Naren, M. Xu, J. Hu, M. Tintore, S. Zhang, P. Labatut, D. Haziza, L. Wehrstedt, J. Reizenstein 和 G. Sizov. xformers: 一个模块化和可黑客化的变换器建模库。<https://github.com/facebookresearch/xformers>, 2022.
- [87] Y. Dong, J.-B. Cordonnier 和 A. Loukas. 注意力并不是你所需的全部: 纯注意力在深度上以双指数速度失去秩。在国际机器学习大会上, 页码2793–2803。PMLR, 2021.
- [88] M. Dehghani, J. Djolonga, B. Mustafa, P. Padlewski, J. Heek, J. Gilmer, A. P. Steiner, M. Caron, R. Geirhos, I. Alabdulmohsin, R. Jenatton, L. Beyer, M. Tschannen, A. Arnab, X. Wang, C. Riquelme Ruiz, M. Minderer, J. Puigcerver, U. Evci, M. Kumar, S. V. Steenkiste, G. F. Elsayed, A. Mahendran, F. Yu, A. Oliver, F. Huot, J. Bastings, M. Collier, A. A. Gritsenko, V. Birodkar, C. N. Vasconcelos, Y. Tay, T. Mensink, A. Kolesnikov, F. Pavetic, D. Tran, T. Kipf, M. Lucic, X. Zhai, D. Keysers, J. J. Harmsen 和 N. Houlsby. 将视觉变换器扩展到220亿参数。在 A. Krause, E. Brunskill, K. Cho, B. Engelhardt, S. Sabato 和 J. Scarlett 主编, 第四十届国际机器学习会议论文集, 卷202的机器学习研究论文集, 第7480–7512页。PMLR, 2023年7月23日至29日。网址<https://proceedings.mlr.press/v202/dehghani23a.html>。
- [89] M. Wortsman, P. J. Liu, L. Xiao, K. E. Everett, A. A. Alemi, B. Adlam, J. D. Co-Reyes, I. Gur, A. Kumar, R. Novak, J. Pennington, J. Sohl-Dickstein, K. Xu, J. Lee, J. Gilmer 和 S. Kornblith. 用于大规模变换器训练不稳定性的缩小代理。在第十二届学习表征国际会议, 2024年。网址<https://openreview.net/forum?id=d8w0pmvXbZ>。
- [90] G. Yang, E. Hu, I. Babuschkin, S. Sidor, X. Liu, D. Farhi, N. Ryder, J. Pachocki, W. Chen, 和 J. Gao. 通过零样本超参数转移调整大型神经网络。在 M. Ranzato, A. Beygelzimer, Y. Dauphin, P. Liang, 和 J. W. Vaughan 主编的神经信息处理系统进展, 第34卷, 第17084–17097页。Curran Associates, Inc., 2021. 网址https://proceedings.neurips.cc/paper_files/paper/2021/file/8df7c2e3c3c3be098ef7b382bd2c37ba-Paper.pdf.
- [91] G. Yang, D. Yu, C. Zhu, 和 S. Hayou. 张量程序 VI: 在无限深度神经网络中的特征学习。在第十二届学习表征国际会议, 2024. 网址<https://openreview.net/forum?id=17pVDnpwwl>.
- [92] J. Haas, A. Barbato, D. Behringer, G. Studer, S. Roth, M. Berton, K. Mostaguir, R. Gumienny, 以及 T. Schwede. 连续自动模型评估 (CAMEO) 补充了对 CASP12 中结构预测的关键评估。《蛋白质: 结构与功能与生物信息学》, 86 (补充1): 387–398, 2018年3月。国际标准连续出版物号 10970134。数字对象标识符: 10.1002/prot.25431。出版商: 约翰·威利与儿子公司。
- [93] A. Kryshchuk, T. Schwede, M. Topf, K. Fidelis, 以及 J. Moult. 蛋白质结构预测方法的关键评估 (CASP) ——轮次

使用语言模型模拟五亿年的演化

- XIV. 蛋白质: 结构与生物信息学, 89(12):1607–1617, 2021. 国际标准连续出版物号 1097-0134. 数字对象标识符: 10.1002/prot.26237. 网址 <https://onlinelibrary.wiley.com/doi/abs/10.1002/prot.26237>。电子版: 抱歉, 我无法满足该请求。
- [94] A. Kryshchuk, M. Antczak, M. Szachniuk, T. Zok, R. C. Kretscher, R. Rangan, P. Pham, R. Das, X. Robin, G. Studer, J. Durairaj, J. Eberhardt, A. Sweeney, M. Topf, T. Schwede, K. Fidelis, 和 J. Moulton. CASP15中的新预测类别。蛋白质, 91(12):1550–1557, 2023年12月。国际标准连续出版物号 0887-3585。数字对象标识符: 10.1002/prot.26515。网址 <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10713864/>。
- [95] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. 王, L. 王 和 W. 陈. LoRA: 大语言模型的低秩适应, 2021年10月. 网址 <http://arxiv.org/abs/2106.09685>. arXiv:2106.09685 [cs].
- [96] L. McInnes, J. Healy 和 J. Melville. UMAP: 统一流形近似与投影用于降维, 2020年九月. 网址 <http://arxiv.org/abs/1802.03426>. arXiv:1802.03426 [cs,stat].
- [97] B. Hie, S. Candido, Z. Lin, O. Kabeli, R. Rao, N. Smetanin, T. Sercu 和 A. Rives. 一种用于生成性蛋白质设计的高级编程语言. bioRxiv, 页码 2022年12月, 2022.
- [98] N. Hulo, A. Bairoch, V. Bulliard, 序列长度, L. Cerutti, E. De Castro, P. S. Langendijk-Genevaux, M. Pagni, 以及 C. J. A. Sigrist. PROSITE 数据库。《核酸研究》, 34(数据库期): D227–230, 2006年1月。国际标准连续出版物号 1362-4962。数字对象标识符: 10.1093/nar/gkj063。
- [99] C. Zhang, X. Zhang, P. Freddolino, 以及 Y. Zhang. BioLiP2: 生物相关配体-蛋白质相互作用的更新结构数据库。《核酸研究》, 52(D1): D404–D412, 2023年7月。国际标准连续出版物号 0305-1048。数字对象标识符: 10.1093/nar/gkad630. 网址 <https://doi.org/10.1093/nar/gkad630>。
- [100] M. G. Azar, M. Rowland, B. Piot, D. Guo, D. Calandriello, M. Valko, 和 R. Munos. 一个理解人类偏好的学习的普遍理论范式, 2023年11月. 网址 <http://arxiv.org/abs/2310.12036>. arXiv:2310.12036 [cs,stat].
- [101] K. Ethayarajh, W. Xu, N. Muennighoff, D. Jurafsky 和 D. Kiela. KTO: 模型对齐作为前景理论优化, 2024年6月. 网址 <http://arxiv.org/abs/2402.01306>. arXiv:2402.01306 [cs].
- [102] L. Gao, J. Schulman, 和 J. Hilton. 奖励模型过度优化的缩放法则。在第四十届国际机器学习会议论文集, ICML’23. JMLR.org, 2023。
- [103] M. Chen, J. Tworek, H. Jun, Q. Yuan, H. P. de Oliveira Pinto, J. Kaplan, H. Edwards, Y. Burda, N. 约瑟夫, G. Brockman, A. Ray, R. Puri, G. Krueger, M. Petrov, H. Khlaaf, G. Sastry, P. Mishkin, B. Chan, S. Gray, N. Ryder, M. Pavlov, A. Power, L. Kaiser, M. 巴伐利亚, C. Winter, P. Tillet, F. P. Such, D. 卡明斯, M. Plappert, F. Chantzis, E. Barnes, A. Herbert-Voss, W. H. Guss, A. Nichol, A. Paino, N. Tezak, J. Tang, I. Babuschkin, S. Balaji, S. Jain, W. Saunders, C. Hesse, A. N. Carr, J. Leike, J. Achiam, V. Misra, E. Morikawa, A. Radford, M. 骑士, M. Brundage, M. Murati, K. Mayer, P. Welinder, B. McGrew, D. Amodei, S. McCandlish, I. Sutskever 和 W. Zaremba. 评估在代码上训练的大型语言模型, 2021。
- [104] J. Ho 和 T. Salimans. 无分类器扩散引导。arXiv 预印本 arXiv:2207.12598, 2022。
- [105] W. Kabsch. 一个与两个向量集相关的最佳旋转的解决方案。晶体学报 A 部分, 32(5):922–923, 1976. doi: <https://doi.org/10.1107/S0567739476001873>. 网址 <https://onlinelibrary.wiley.com/doi/abs/10.1107/S0567739476001873>。
- [106] S. M. Hartley, K. A. Tiernan, G. Ahmetaj, A. Cretu, Y. Zhuang, 和 M. Zimmer. AlphaFold2 和 RoseTTAFold 预测后转录修饰。GFP样蛋白中的色团形成。PLOS ONE, 17(6):e0267560, 2022年6月。国际标准连续出版物号 1932-6203。数字对象标识符: 10.1371/journal.pone.0267560. 网址 <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0267560>. 出版社: 公共科学图书馆。
- [107] J. Salazar, D. Liang, T. Q. Nguyen, 和 K. Kirchhoff. 掩码语言模型评分。arXiv:1910.14659, 2019年。
- [108] L. Somermeyer. 同源gfp适应度峰值。 <https://archhive.softwareheritage.org/sw/h1:cnt:a4c63cdf2f4524c8d5c813a1972a5ac649266e2b>, 2022年。
- [109] K. Katoh 和 D. M. Standley. MAFFT 多序列对齐软件版本7: 改进

使用语言模型模拟五亿年的进化

在性能和可用性方面。《分子生物学与进化》，30(4):772-780，2013。

- [110] T. J. Lambert. FPbase: 一个可社区编辑的荧光蛋白数据库。自然方法, 16 (4) : 277-278, 2019年4月。国际标准连续出版物号1548-7105。数字对象标识符: 10.1038/s41592-019-0352-8。网址 <https://www.nature.com/articles/s41592-019-0352-8>。出版商: 自然出版集团。
- [111] S. Seabold和J. Perktold. statsmodels: 使用Python进行计量经济学和统计建模。在第九届科学中的Python会议上, 2010年。
- [112] R. A. x. B. 负责任的AI与生物设计。负责任的AI及生物设计。 <https://responsiblebiodesign.ai/>, 2024年。访问日期: 2024-6-20。
- [113] 疾病控制中心。选择的病原体 and 毒素清单。 <https://www.selectagents.gov/sat/list.htm>, 2024年5月。访问日期: 2024-5-24。
- [114] 人类健康服务部。合成核酸的供应商和用户筛选框架指南。技术报告, 2023。URL <https://aspr.hhs.gov/legal/synna/Documents/SynNA-Guidance-2023.pdf>。
- [115] P. Notin, A. W. Kollasch, D. Ritter, L. van Niek-erk, S. Paul, H. Spinner, N. Rollins, A. Shaw, R. Weitzman, J. Frazer, M. Dias, D. Franceschi, R. Orenbuch, Y. Gal, 和 D. S. Marks. ProteinGym: 蛋白质设计和适应性预测的大规模基准。 *bioRxiv*, 页面 2023.12.07.570727, 2023年12月。URL <https://www.biorxiv.org/content/10.1101/2023.12.07.570727v1>。
- [116] T. A. Hopf, J. B. Ingraham, F. J. Poelwijk, C. P. Schärfe, M. Springer, C. Sander, 和 D. S. Marks. 基于序列共变的突变效应预测。自然生物技术, 35(2):128, 2017年2月。国际标准连续出版物号 15461696。doi: 10.1038/nbt.3769。URL <http://www.nature.com/articles/nbt.3769>。出版商: 自然出版集团。

附录A 材料与方法

	21
A.1 架构	21
A.1.1 符号	21
A.1.2 概述	21
A.1.3 分词	21
A.1.4 ESM3 输入和前向传递	21
A.1.5 变换器	23
A.1.6 几何注意力	24
A.1.7 结构标记器	26
A.1.8 函数标记化	31
A.1.9 其他轨迹	36
A.1.10 ESM3 推理	37
A.2 训练 ESM3	37
A.2.1 预训练数据	37
A.2.2 预训练任务	39
A.2.3 训练细节	41
A.3 模型评估	42
A.3.1 模型	42
A.3.2 数据	42
A.3.3 表征学习	42
A.3.4 结构预测	42
A.3.5 条件似然	43
A.3.6 无条件生成	43
A.3.7 响应式评估	45
A.3.8 可引导设计	48
A.3.9 提示的组合	48
A.3.10 多模态编辑示例	50
A.4 对齐	52
A.4.1 算法	52
A.4.2 偏好调整直觉	53
A.4.3 评估指标	53
A.4.4 训练数据集	54
A.4.5 评估数据集: 三级协调	54
A.4.6 监督微调	54
A.4.7 训练超参数	54
A.5 GFP	56
A.5.1 生成和选择	56
A.5.2 实验方法和数据分析	61
A.5.3 序列搜索和比较	63
A.5.4 系统发育分析	63
A.6 开放模型	64
A.6.1 ESM3开放缓解	64
A.6.2 ESM3开放评估	66

A. 材料与方法

A.1. 架构

A.1.1. 符号

在以下内容中, 我们使用 L 表示序列长度, d 表示嵌入维度, $\{a..b\}$ 表示从 a 到 b 的闭集合整数, 以及 $[a, b]$ 一个实数区间。 $SE(3)$ 是特殊的欧几里得群, 我们用它来表示框架 (附录A.1.6.1)。

A.1. 2. 概述 ESM3 是一种全对全生成模型, 它既对不同轨迹进行条件处理, 又生成多种不同轨迹。作为输入, ESM3 对多种轨迹进行条件处理, 如附录A.1.5.1中所描述, 并且作为输出, ESM3 生成了在附录A.1.5.2中详细说明了的预测。生成管道如下。分词 首先, 原始输入按附录A.1.3中所述进行分词。结构输入通过 VQ-VAE 进行分词 (附录A.1.7)。功能关键词通过使用局部敏感哈希 (LSH) 对功能关键词的 TF-IDF 变换进行量化来进行分词, 详细说明见附录A.1.8。变换器主干 标准变换器 (61, 62) 架构处理后分词输入。几何注意力 (算法6 和图 S2) 直接处理结构坐标作为输入。模型输出是标记空间上的逻辑值, 可以进行采样以获得附录A.1.5.2中描述的输出。整体架构在图中示意 S1。解码器 大多数轨迹可以简单地解码为附录 A.1.3中详细说明了的标记。结构标记必须通过模型进行解码——我们使用一个700M参数的变换器模型来做到这一点, 后期训练 (附录A.1.7.2)。解码器使用序列标记和结构标记直接预测坐标、pTM 和 pLDDT (63)。功能令牌使用一个小型的 3 层变换器进行解码, 后期训练以反转 LSH 量化程序 (附录A.1.8.2.1)。

A.1. 3. 分词 所有轨迹都表示为标记序列, 每个氨基酸位置指定标记。在分词过程中, 特殊的序列开始标记 (BOS) 和序列结束标记 (EOS) 分别被预置和添加到序列中。序列蛋白质序列被标记为20种标准氨基酸, 加上BOS、EOS、mask、pad和unknown。

我们保留四种非标准氨基酸, 如林等所述。

(5), B - 天冬酰胺, U - 硒氨酸, Z - 谷氨酸, 和 O - 精氨酸。这总共是29个标记。

结构结构标记化在附录A.1.7.1中进行了描述。ESM3使用4096的代码本大小和4个特殊标记 - EOS、BOS、mask和pad。

二级结构二级结构被视为标准的8类标记 (64), 加上unknown和mask, 总共10个标记。mask标记在嵌入过程中被强制设为0向量。

SASA 表示 SASA 的连续值通过离散化为固定的 16 个区间进行标记化。SASA 区间边界通过在 100 个随机结构上计算 SASA 得出, 确保每个区间内包括相等数量的残基。未知和掩码共用于 18 个标记。掩码标记在嵌入过程中被强制为零向量。

功能注释我们将功能注释标记化为关键词包, 如附录A.1.8中所述。关键词通过局部敏感哈希量化为每个残基 8 个标记, 每个标记可以是 255 个标记之一。存在三个特殊标记: 空集、无注释和掩码。再次强调, 掩码标记在嵌入过程中被强制为零向量。

残基注释 InterPro 注释被标记化为一个多热特征向量 (1478 维), 涵盖可能的 InterPro 标签 (40)。输入注释限制为最多 16 个。当不存在注释时, 我们强制添加零向量。

A.1.4. ESM3 输入和前向传递

如上所述, ESM3 可以采用多个轨道, 所有这些轨道均可通过掩蔽选择性禁用。在以下内容中, 我们简洁地表示 ESM3 的输入为

$$\mathbf{x}_{\text{inputs}} = \begin{cases} x_{\text{structure}} \in \{0..4099\}^L, x_{\text{ss8}} \in \{0..10\}^L, \\ x_{\text{sasa}} \in \{0..18\}^L, x_{\text{func}} \in \{0..258\}^{L \times 8}, \\ x_{\text{res}} \in \{0, 1\}^{L \times 1478}, x_{\text{plddt}} \in [0, 1]^L, \\ x_{\text{avgplddt}} \in [0, 1] \end{cases}$$

我们现在呈现 ESM3 前向传递的高级算法:

使用语言模型模拟五亿年的进化




图 S1. ESM3 架构。ESM3 是一个掩码语言模型, 它对蛋白质序列、结构和功能进行推理, 这些均作为输入和输出的标记轨道表示。标记在输入到变压器堆时被嵌入并求和。第一个模块 (右侧扩展) 包含一个额外的几何注意力层, 用于处理原子坐标输入。在训练期间, 随机掩码会被采样并应用于每个轨道。掩码标记位置在输出时被预测。

利用语言模型模拟五亿年的演化

算法1 esm3

输入: x_{inputs}

- 1: $z_{(0)} = \text{嵌入}(x_{inputs}) \triangleright \mathbb{R}^{L \times d}$
- 2: 对于 $l \in \{1, \dots, n_{layers}\}$ 执行“嵌入”
- 3: $z_{嵌入} = \text{嵌入}(z_{(l-1)})$
- 4: 结束对于
- 5: 对于轨迹在期望输出轨迹中进行
- 6: $z_{track} = \text{回归_头}(z_{(n_{layers})} \text{ 嵌入})$
- 7: 结束对于
- 8: 返回跟踪特定逻辑值 $z_{track} \in \mathbb{R}^{L \times c_{track}}$

在接下来的几个部分中，我们详细说明每个组件。

A.1.5. 变换器

我们的网络基于变压器架构 (61)，综合了若干后续改进：我们使用预层归一化 (Pre-LN) 而不是后层归一化 (Post-LN) (62)，采用旋转嵌入 (rotary embeddings) (65) 而非绝对位置嵌入，同时将 ReLU 非线性替换为 SwiGLU (66)。隐藏维度被设置为大约 $\frac{8}{3}d$ ，经过四舍五入至训练效率的256倍数。线性层或层归一化中不使用偏差，正如 PaLM (67) 所建议的。我们通过文献和内部实验观察到，这些架构变更提高了模型的稳定性和性能。

我们所做的一个核心架构修改是在网络的第一个块中仅插入几何注意力子层 (算法2，第3行)。

算法2 变换器

输入: $x \in \mathbb{R}^{L \times d}, T \in SE(3)^L$

- 1: $s = \sqrt{\frac{2}{n_{layers}}}$ $\triangleright \mathbb{R}$
- 2: $x = x + s \cdot \text{多头自注意力}(x)$ $\triangleright \mathbb{R}^{L \times d}$
- 3: $x = x + s \cdot \text{几何注意力}(x, T)$ $\triangleright \mathbb{R}^{L \times d}$
- 4: $x = x + s \cdot \text{SwiGLU多层感知机}(x)$ $\triangleright \mathbb{R}^{L \times d}$

ESM3-small (1.4B) 是一款48层网络，而 ESM3-medium (70亿) 具有96层，ESM3-large (98B) 拥有216层。我们尝试了不同的宽度与深度比例，观察到深度相比于宽度有更高的收益。先前的研究也表明，像我们这样的模态更有利于更深的网络 (68, 69)。详细的网络规格可以在表S1中找到。

A.1.5.1. 嵌入

ESM3 有 7 个独特的输入轨道：(a) 序列（氨基酸标记），(b) 结构坐标，(c) struc-

ture 标记，(d) 8 类二级结构标签 (SS8)，(e) 经过量化的溶剂可接触表面积 (SASA) 值、(f) 功能关键字标记以及 (g) 残基 (InterPro) 注释的二进制特征。

在预训练期间仅使用两个额外的轨道：

(h) 每个残基的置信度 (pLDDT) 和 (i) 平均置信度 (pLDDT)。在推理阶段，这些值是固定的，这些轨道相当于添加一个常量向量 z_{pLDDT} 。

结构坐标通过几何注意力进行解析，并未被嵌入。

对于基于关键字的功能标记，每个残基的八个整数被转换为一个“子嵌入” (算法3 第 5 行)，然后拼接以形成每个残基的嵌入 (算法3 第 6 行)。对于 InterPro 残基注释，输入是多热的。为了创建一个嵌入向量，我们对“开启”特征的嵌入进行求和（相当于算法3 第 7 行上的矩阵乘法）。

最大的模型，98B，在附录A.1.9.2中详细介绍了额外的分类法跟踪，仅在预训练的最后30K步骤中启用。

所有嵌入作为输入相加，进入网络架构的第一层。

算法3 编码

输入: $x_{inputs} =$

$\{x_{seq}, x_{structure}, x_{ss8}, x_{sasa}, x_{func}, x_{res}, x_{pLDDT}, x_{avgpLDDT}\}$

- 1: $z_{seq} = \text{嵌入}(x_{seq}) \triangleright \mathbb{R}^{L \times d}$
- 2: $z_{structure} = \text{嵌入}(x_{structure}) \triangleright \mathbb{R}^{L \times d}$
- 3: $z_{ss8} = \text{嵌入}(x_{ss8}) \triangleright \mathbb{R}^{L \times d}$
- 4: $z_{sasa} = \text{嵌入}(x_{sasa}) \triangleright \mathbb{R}^{L \times d}$
- 5: $h_{func,i} = \text{嵌入}([x_{func}]_{:,i}) \triangleright \mathbb{R}^{L \times d_{ss}}$
- 6: $z_{func} = [h_{func,1} \parallel h_{func,2} \parallel \dots \parallel h_{func,8}] \triangleright \mathbb{R}^{L \times d}$
- 7: $z_{剩余} = x_{剩余} W_{剩余} \triangleright \mathbb{R}^{L \times d}$
- 8: $z_{pLDDT} = \text{pLDDT_嵌入}(x_{pLDDT}, x_{avgpLDDT}) \triangleright \mathbb{R}^{L \times d}$
- 9: 返回 $z_{seq} + z_{pLDDT} + z_{structure} + z_{ss8} + z_{sasa} + z_{func} + z_{res}$

A.1.5.2. 逻辑值

我们使用一个 回归_头 来接收 d 维度的最后一层隐藏特征，并生成 c_{track} 维度的逻辑值，用于每条轨道，其中 c_{track} 对应于每条轨道的词汇表大小。请注意，对于关键字函数令牌，我们生成 $c_{func} \times 8$ 逻辑值，并在计算损失时对每一个独立的 8 进行 Softmax。

用语言模型模拟五亿年的进化

参数 n_{layers}	d_{model}	d_{head}	上下文 长度	学习率	预热步数	以标记为 单位的批 量大小	编号 步骤	总计 标记	FLOPs
1.4B 48 1536 64 2048 1				4.0e-4	5K	, 572 , 864 50K		~80B	6.72×10^{20}
1.4B 48 1536 64 2048 1				4.0e-4	5K	, 572 , 864 20万		~320B	2.7×10^{21}
70亿 96 2560 128 2048 3				2.5e-4	5K	, 932 , 160 140K		~550B	2.47×10^{22}
98.5B 216 6144 128 2048 4				1.0e-4	20K	, 194 , 304 430K		~1.8T	1.07×10^{24}

表 S1. 不同模型配置的参数详细信息。

算法 4 回归

输入: $x \in \mathbb{R}^{\dots \times d}$

```

1:  $z = \text{proj}_{\text{in}}(x)$ 
2:  $z = \text{GeLU}(z)$ 
3:  $z = \text{LayerNorm}(z)$ 
4:  $z = \text{proj}_{\text{out}}(z)$ 
5: 返回  $z$ 

```

除了结构坐标之外, 我们输出附录 A.1.5.1 中详细描述
的每个轨迹的预测: (a) 序列, (b) 结构标记, (c)
SS8, (d) 量化的 SASA, (e) 函数关键词标记以及 (f)
残基 (InterPro) 注释的二进制特征。除了多热残基注
释之外, 所有其他轨迹都被预测为可能标记的分类分
布。

A.1.6. 几何注意力

如附录A.1.5.1中提到的, ESM3以两种独立的方式处
理结构信息:

几何注意力在算法6中描述, 利用对主链原子原子坐标
的条件化来利用细粒度的三维信息。坐标仅用作模型
输入。结构标记在附录A.1.7中描述, 结构标记由于丰
富的局部邻域语义被压缩为标记, 从而实现更快的学
习。结构标记通常用作模型输出。

几何注意力使得高速编码蛋白质结构成为可能。蛋白
质主链结构可以通过每个残基主链坐标定义的框架的
相对距离和方向表示。当仅提供部分结构时, 对框架
相对方向的推理对于捕捉局部主链几何形状至关重要。
几何注意力是一种 $SE(3)$ 不变的全对全注意力机制,
它在输入中对所有定义框架的相对距离和方向进行推
理。

(图S2)。因为这个注意力操作可以实现
使用与注意力相同的计算原语, 因此它易于扩展。我
们首先提供帧的概述, 然后描述几何注意力如何使用
帧:

A.1.6.1. 帧

帧是封装每个残基在蛋白质中的位置和方向的表示。
我们使用类似于Ingraham等人 (70) 的公式。每个
帧 $T \in SE(3)$ 由旋转矩阵 $\mathbf{R} \in SO(3)$ 和一个平移向量
 $\mathbf{t} \in \mathbb{R}^3$ 组成。

定义: 用于残基 i 的框架 T_i 定义如下:

$$T_i = \begin{bmatrix} \mathbf{R}_i & \mathbf{t}_i \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix} \in SE(3)$$

其中 $\mathbf{R}_i \in SO(3)$ 和 $\mathbf{t}_i \in \mathbb{R}^3$ 。旋转矩阵: 用于残基
 i 的旋转矩阵 $\mathbf{R}_i$ 由三维向量 $[\hat{x}, \hat{e}_1, \hat{e}_2]$ 组成: 1. $\hat{x}$
和 $\hat{e}_1$ 是 $N - C_\alpha - C$ 平面上的正交单位向量。2. $\hat{e}_2$ 是
垂直于 $\hat{x}$ 和 $\hat{e}_1$ 的单位向量。该矩阵将向量旋转到局部
坐标系统中。

其中对应残基的 $N - C_\alpha - C$ 平面展开了 xy 平
面。平移向量: 平移向量 $\mathbf{t}_i$ 指定残基的 C_α 的位置。
变换: 要将点 $\mathbf{p} \in \mathbb{R}^3$ 从残基 i 的局部框架变换到全
局坐标系统, 使用以下方程:

$$\mathbf{p}_{\text{global}} = T_i(\mathbf{p}) = \mathbf{R}_i \mathbf{p} + \mathbf{t}_i$$

逆变换: 要将点 $\mathbf{p}_{\text{global}} \in \mathbb{R}^3$ 从全局坐标系统变换回局
部

残基 i 的框架, 使用以下方程:

$$\mathbf{p} = T_i^{-1}(\mathbf{p}_{\text{global}}) = \mathbf{R}_i^{-1}(\mathbf{p}_{\text{global}} - \mathbf{t}_i)$$

使用语言模型模拟五亿年的进化




图 S2. 几何注意力。几何注意力是一种对所有元素均不变的 SE(3) 关注机制, 其中注意力得分矩阵是两个项的加权和: (1) 查询和键之间的成对距离, 经过各自骨干框架的旋转和平移, 以及 (2) 查询和键之间的成对点积, 同样经过各自骨干框架的旋转。该注意力机制以与变换器中标准注意力操作相当的吞吐量编码结构信息。

使用语言模型模拟五亿年的演化

为了创建框架, 我们所需的仅是一个平移向量 $\vec{t}$, 以及两个向量 $\vec{x}$ 和 $\vec{y}$, 它们定义了转换为全局坐标后的局部 xy 平面, 从该平面可以通过标准的 Gram-Schmidt 算法计算框架 T :

算法5 gram

输入: $\vec{t} \in \mathbb{R}^{L \times 3}, \vec{x} \in \mathbb{R}^{L \times 3}, \vec{y} \in \mathbb{R}^{L \times 3}$

- 1: $\hat{x} = \frac{\vec{x}}{\|\vec{x}\|}$
- 2: $\vec{e}_1 = \vec{y} - (\hat{x} \cdot \vec{y}) \hat{x}$
- 3: $\hat{e}_1 = \frac{\vec{e}_1}{\|\vec{e}_1\|}$
- 4: $\hat{e}_2 = \frac{\vec{x} - (\hat{x} \cdot \vec{x}) \hat{x} - (\hat{e}_1 \cdot \vec{x}) \hat{e}_1}{\|\vec{x} - (\hat{x} \cdot \vec{x}) \hat{x} - (\hat{e}_1 \cdot \vec{x}) \hat{e}_1\|}$
- 5: $R = [\hat{x}, \hat{e}_1, \hat{e}_2]$ $\triangleright SO(3)^L$
- 6: $T = \begin{bmatrix} R & \vec{t} \\ 0_{1 \times 3} & 1 \end{bmatrix}$ $\triangleright SE(3)^L$
- 7: 返回 T

我们构造框架, 使得 C_α 位于框架的原点 ($\vec{t}$), C 位于负 x 轴上 ($-\vec{x}$), 而 N 位于 xy 平面上。

A.1.6.2. 几何自注意力

算法 6 详细介绍了几何自注意力层。该层可以利用与 FlashAttention (71) 相似的思路高效实现。在我们的系统中, 该层被使用了两次: 在 VQ-VAE 编码器中用于结构标记 (附录 A.1.7.1), 以及在 ESM3 的第一层。

与仅在每个残基嵌入上操作的常规自注意力不同, 几何注意力整合了每个残基框架 T , 以以旋转和位移不变的方式整合几何信息。形成注意力矩阵 A 的过程如下:

1. QKV 投影: 两个键和值的查询集 (Q_r, K_r) 和 (Q_d, K_d), 加上 V , 所有这些的形状为 $\in \mathbb{R}^{L \times h \times 3}$, 它们都是从层输入 X 线性投影而来的。 L 为序列长度, h 为头的数量。
2. 将 QKV 转换为全局框架: 每个查询、键和值最初被假定处于其对应残基的局部框架中。(a) 转换为全局旋转框架: 我们将 Q_r, K_r, V 中的每个向量从其局部框架 (其中 xy 平面是每个残基的 $N-C_\alpha-C$ 平面) 转换到全局旋转框架 (其中 xy 平面对齐于所有残基) 通过应用 R_i (算法 6, 第 3 行, 第 4 行)。(b) 转换为全局距离框架: 我们将 Q_d, K_d 中的每个向量从其局部框架转换为全局框架通过应用 T_i (算法 6, 第 5 行, 第 6 行)。

3. 方向注意力: 键与查询之间的逐对、每个头的 h 旋转相似性 R 是通过点积 $[R]_{i,j}$ 来计算的, $j, h = \frac{1}{\sqrt{3}} [q_r]_{i,j}, h, [k_r]_{j,h}$ 。这相当于投影点之间的余弦距离。

4. 距离注意力: 每个头的成对 h 距离相似性 D 在键 i 和查询 j 之间, 使用 L_2 差的范数 $[D]_{i,j}$ 计算, $j, h = \frac{1}{\sqrt{3}} \|[q_r]_{i,j}, h, -[k_r]_{j,h}\|_2$ 。

5. 缩放因子: R 和 D 分别使用学习到的标量 $[\bar{w}_r]_h$ 和 $[\bar{w}_d]_h$ 进行每个头的缩放, 其中 $\bar{w}_r, \bar{w}_d \in \mathbb{R}^h$ 。我们使用 softplus 函数将权重转换为 $[0, \infty)^h$ 。这种缩放允许某些头专注于通过距离或方向注意力进行关注。

算法 6 几何

输入: $X \in \mathbb{R}^{L \times d}, T \in SE(3)^L$

- 1: $Q_r, K_r, Q_d, K_d, V = \text{线性}(X)$ $\triangleright (\mathbb{R}^{L \times h \times 3})_{\times 5}$
- 2: $(R_i, t_i) = T_i$ $\triangleright (SO(3)^L, \mathbb{R}^{L \times 3})$
- 3: $[Q_r]_{i,h,:} = R_i([Q_r]_{i,h,:})$ $\triangleright \mathbb{R}^{L \times h \times 3}$
- 4: $[K_r]_{i,h,:} = R_i([K_r]_{i,h,:})$ $\triangleright \mathbb{R}^{L \times h \times 3}$
- 5: $[Q_d]_{i,h,:} = T_i([Q_d]_{i,h,:})$ $\triangleright \mathbb{R}^{L \times h \times 3}$
- 6: $[K_d]_{i,h,:} = T_i([K_d]_{i,h,:})$ $\triangleright \mathbb{R}^{L \times h \times 3}$
- 7: $[R]_{i,j,h} = \frac{1}{\sqrt{3}} [q_r]_{i,h,:} \cdot [k_r]_{j,h,:}$ $\triangleright \mathbb{R}^{L \times L \times h}$
- 8: $[D]_{i,j,h} = \frac{1}{\sqrt{3}} \|[q_r]_{i,h,:} - [k_r]_{j,h,:}\|_2$ $\triangleright \mathbb{R}^{L \times L \times h}$
- 9: $A = \text{softplus}(\bar{w}_r)R - \text{softplus}(\bar{w}_d)D$ $\triangleright \mathbb{R}^{L \times L \times h}$
- 10: $A = \text{Softmax}_j(A)$
- 11: $[V]_{i,h,:} = R_i([V]_{i,h,:})$
- 12: $O = A \cdot V$ $\triangleright \mathbb{R}^{L \times h \times 3}$
- 13: $[O]_{i,h,:} = R_i^{-1}([O]_{i,h,:})$
- 14: $X = X + \text{线性}(O)$ $\triangleright \mathbb{R}^{L \times d}$

A.1.7. 结构标记器

每个残基与 4,096 个结构标记 (+4 特定标记) 相关联, 旨在提供其局部邻域的丰富的学习表征。先前的研究表明, 结构标记可以用于搜索 (41), 提高表征学习 (72) 以及生成 (16), 但我们训练了自己的标记器以优化结构生成。标记是通过 VQ-VAE 编码器生成的, 并配备相应的解码器, 以便将生成的标记解码回三维坐标。

A.1.7.1. 编码器

VQ-VAE 编码器 f_{enc} 由两个几何注意力模块组成 (变换器模块, 但自注意力被几何_多头注意力机制) 与嵌入宽度

使用语言模型模拟五亿年的进化

每个几何注意力层有1024和128个几何头。

VQ-VAE编码器对骨干帧和局部结构中残基的相对序列位置进行推理。相对序列位置通过学习的位置信息嵌入进行编码。序列位置是相对于查询残基确定的

（即，如果查询残基的残基索引为56，则索引为58的残基具有一个 +2 序列位置）。相对序列位置在编码之前被限制在 ± 32 ，这意味着长距离接触共享序列位置嵌入。相对序列位置嵌入定义了初始编码器状态 N ，其形状为 $L \times 16 \times d$ (算法7，第4行)。值得注意的是，这意味着VQ-VAE编码器的输入完全是结构性的：这里不使用序列（氨基酸）、功能或其他信息。此外，每个邻域都是完全独立地处理的；对于每个残基，编码器仅使用其16个最近邻的消息。

几何注意力模块的操作方式类似于变换器模块，因为它们根据注意力操作（geometric_mha）和前馈网络（SwiGLU MLP）转换状态。因此，输出的形状与输入相同。在这种情况下，这意味着编码器每个残基输出16个潜变量。然而，我们希望学习单个标记，即每个残基一个潜变量，因此我们取对应于查询残基位置 N 的嵌入， $0, \infty$ 。

生成结构标记的过程（算法7）基于蛋白质的完整三维坐标，步骤如下：

1. 局部邻域：对于每个残基，获得16个最近残基（按 C_α 距离测量）的索引 $N_{\text{idx}} \in \{0..L-1\}^{L \times 16}$ 。这16个邻居中的第一个总是残基本身。我们还根据 T_{knn} 为局部邻域中的每个残基获得帧。
2. 嵌入邻居：在序列空间中嵌入每个邻居的相对距离， $\Delta i = \text{clamp}(N_{\text{idx}} - i, -32, 32)$ 以形成 $N \in \mathbb{R}^{L \times 16 \times d}$ 。
3. 编码：将 N 通过一个浅层编码器 f_{enc} 传递，该编码器由2个变换器模块组成，常规多头自注意力被几何的_mha 替换。注意力是无掩蔽的，全面覆盖整个邻域。
4. 量化：提取邻域中的第一个元素 $N_{:,0,:}$ 这对应于残基本身。将其线性投影，并通过用代码本中最近的向量替换来进行量化。这为每个残基产生了结构标记。

算法 7 结构

输入： $x_{C_\alpha} \in \mathbb{R}^{L \times 3}, T \in SE(3)^L$

- 1: $N_{\text{idx}} = \text{knn}(x_{C_\alpha}) \triangleright \{0..L-1\}^{L \times 16}$
- 2: $T_{\text{knn}} = T[N_{\text{idx}}] \triangleright SE(3)^{L \times 16}$
- 3: $\Delta i = \text{夹紧}(N_{\text{idx}} - i, -32, 32)$
- 4: $N = \text{嵌入}(\Delta i) \triangleright \mathbb{R}^{L \times 16 \times d}$
- 5: $N = f_{\text{enc}}(N, T_{\text{knn}}) \triangleright \mathbb{R}^{L \times 16 \times d}$
- 6: $z = \text{线性}(N_{:,0,:}) \triangleright \mathbb{R}^{L \times d'}$
- 7: $z = \text{量化}(z) \triangleright \{0..4095\}^L$

A.1.7.1.1. 代码本学习

量化 将 L 潜变量转换为 L 离散标记。由于最初提出 VQ-VAE 以来 (73)，已经开发出许多方法和技巧来解决代码本利用率低和不稳定训练的问题。我们选择将代码本学习为编码器输出的指数移动平均 (73–75)。为提高代码本的利用率，未使用的代码被重新初始化为编码器输出。

A.1.7.2. 并行编码 为了提高训练和推断效率，我们以并行方式编码蛋白质中的所有局部结构图。实际上，这意味着对于一批平均序列长度为 L 的 B 蛋白质，结构编码器的输入将具有形状 $BL \times 16 \times d$ 。

A.1.7.2. 解码器

虽然编码器独立并行地处理所有局部结构，但解码器 f_{dec} 会在整个 L 标记集上进行关注，以重构完整的结构。它由一系列双向变换器模块和常规自注意力构成。

正如附录 A.1.7.3 中讨论的，VQ-VAE 是分两阶段训练的。在第一阶段，一个包含 8 个宽度为 1024 的变换器模块、旋转位置嵌入和多层感知机的小型解码器主干被训练仅用于预测骨架坐标。在第二阶段，解码器的权重被重新初始化，网络规模扩大到 30 层，每层具有 1280 的嵌入维度（~600M 参数）以预测所有原子坐标。

将结构标记转换回三维全原子坐标的确切步骤使用解码器提供在算法8中详细说明如下，

1. 变换器：我们嵌入结构标记并通过一堆变换器模块传递它们 f_{dec} （常规自注意力 + 多层感知机子层，无几何注意力）。

使用语言模型模拟五亿年的进化

2. 投影头: 我们使用投影头对每个残基回归3个三维向量: 一个平移向量 $\vec{t}$, 以及2个向量 $-\vec{x}$ 和 $\vec{y}$, 它们定义了每个残基在旋转到位后所处的 $N-C_{\alpha}-C$ 平面。该投影头还预测多达7个侧链扭转角的未归一化正弦和余弦分量。

3. 计算 T : 我们使用格拉姆_施密特将 $\vec{t}$ 、 $-\vec{x}$ 和 $\vec{y}$ 转换为框架 $T \in SE(3)^L$ 。

4. 计算 T_{local} : 我们对正弦和余弦分量进行归一化, 并将其转换为框架 $T_{\text{local}} \in SE(3)^{L \times 7}$, 对应于侧链上前一个元素的旋转。

5. 组合框架: 我们在以 T 为根的树上, 组合 T_{local} 的每个元素及其前驱, 以形成 $T_{\text{global}} \in SE(3)^{L \times 14}$, 对应于每个残基中重原子的变换, 这些变换以 atom14表示法显示。→

6. 应用框架: 然后, 我们将框架应用于 $X_{\text{ref}} \in \mathbb{R}^{L \times 14 \times 3}$ 中的坐标, 在参考框架中旋转并转换每个残基到其最终位置。算法8结构_解码输入:
 $z \in \{0..4099\}^{L \times 161}$: $z = \text{embed}(z)$

2: $z = f_{\text{dec}}(z)$ $\triangleright \mathbb{R}^{L \times d}$
3: $\vec{t}, \vec{x}, \vec{y}, \sin \theta, \cos \theta = \text{proj}(z)$ $\triangleright (\mathbb{R}^{L \times 3})_{\times 3}, (\mathbb{R}^{L \times 7})_{\times 2}$
4: $T = \text{Gram_Schmidt}(\vec{t}, -\vec{x}, \vec{y})$ $\triangleright SE(3)^L$
5: $\sin \theta = \frac{\sqrt{\text{正弦}^2 + \text{余弦}^2}}{\text{弦}^2}$ $\triangleright [-1, 1]^{L \times 7}$
6: $\cos \theta = \frac{\sqrt{\text{正弦}^2 + \text{余弦}^2}}{\text{弦}^2}$ $\triangleright [-1, 1]^{L \times 7}$
7: $T_{\text{local}} = \text{Rot}(\sin \theta, \cos \theta)$ $\triangleright SE(3)^{L \times 7}$
8: $T_{\text{global}} = \text{Compose}(T, T_{\text{local}})$ $\triangleright SE(3)^{L \times 14}$
9: $\vec{X} = T_{\text{global}}(X_{\text{ref}})$ $\triangleright \mathbb{R}^{L \times 14 \times 3}$

A.1.7.3. 训练

在使用 VQ-VAE 学习最大化重建质量的离散表示时, 通常在自编码器中分两个阶段进行训练 (76)。在第一阶段, 使用相对较小且高效的解码器学习编码器和代码本。在第二阶段, 编码器和代码本被冻结, 并训练一个更大或计算成本更高的解码器以最大化重建质量。我们遵循这种两阶段训练方法以进行结构标记器的训练。

A.1.7.3.1. 阶段 1.

VQ-VAE 在来自 PDB、AFDB 和 ESMAtlas 的单链蛋白质数据集上训练了 90,000 步。我们

使用 AdamW 优化器 (Loshchilov et al. 2017), 其学习率根据余弦衰减计划从 4e-4 进行退火。蛋白质被剪切到最大序列长度为 512。使用五个损失来监督这一训练阶段。几何距离和几何方向损失负责监督高质量骨架结构的重建。

此外, 分箱距离和方向分类损失用于引导结构预测, 但对重建最终并无实质性影响。我们发现, 这些 *formulierte* 作为分类任务的结构预测损失在训练初期改善了收敛性。为了生成这些成对逻辑斯蒂, 我们使用一个 *成对_proj_head*,

该函数接受 $x \in \mathbb{R}^{L \times d}$ 并返回逻辑值 $z \in \mathbb{R}^{L \times L \times d'}$ 。其工作原理如下:

算法 9 成对

输入: $x \in \mathbb{R}^{L \times d}$

- 1: $q, k = \text{投影}(x)$, $\text{投影}(x)$
- 2: 乘积 $q_{i,j}$, 差异 $k_{i,j} = q_{i,j} \odot k_{i,j}$, $q_{j,i} - k_{i,j}$; $z = \text{回归}$
—头部
- 4: 返回 z

最后, 反向折叠标记预测损失 (即, 预测序列与真实值序列之间的交叉熵损失) 是一种辅助损失, 旨在鼓励学习到的表示包含与序列相关任务相关的信息。

这五个损失的详细内容如下:

1. 骨架距离损失: 计算预测与真实坐标间的 L_2 距离矩阵, 包含3个骨架原子 (N, C_{α}, C)。设 $D_{\text{pred}}, D \in \mathbb{R}^{3L \times 3L}$ 。计算 $(D_{\text{pred}} - D)^2$, 限制最大误差为 $(5^\circ \text{Å})^2$, 并取均值。算法 10 骨架_距离_损失输入:

1: $\hat{Z}, Z = \text{展开}(\hat{X}), \text{展开}(X)$ $\triangleright \mathbb{R}^{3L \times 3}, \mathbb{R}^{3L \times 3}$
2: $[D_{\text{pred}}]_{i,j} = \|\hat{Z}_{i,:} - \hat{Z}_{j,:}\|_2^2$ $\triangleright \mathbb{R}^{3L \times 3L}$
3: $[D]_{i,j} = \|Z_{i,:} - Z_{j,:}\|_2^2$ $\triangleright \mathbb{R}^{3L \times 3L}$
4: $E = (D_{\text{pred}} - D)^2$
5: $E = \min(E, 25)$
6: $l = \text{均值}_{i,j}(E)$ $\triangleright \mathbb{R}$
7: 返回 l

2. 骨架方向损失: 为每个残基计算预测坐标和真实值坐标的六个向量:

使用语言模型模拟五亿年的进化

- (a) $N \rightarrow C_\alpha$
- (b) $C_\alpha \rightarrow C$
- (c) $C \rightarrow N_{\text{next}}$
- (d) $n_{C_\alpha} = -(N \rightarrow C_\alpha) \times (C_\alpha \rightarrow C)$
- (e) $n_N = (C_{\text{prev}} \rightarrow N) \times (N \rightarrow C_\alpha)$
- (f) $n_C = (C_\alpha \rightarrow C) \times (C \rightarrow N_{\text{next}})$

计算成对的点积, 形成 $D_{\text{pred}}, D \in \mathbb{R}^{6L \times 6L}$ 。计算 $(D_{\text{pred}} - D)^2$, 将最大误差限制为 20, 并取其均值。

以算法形式 (与 计算_向量 计算上述六个向量) :

算法 11 主干

```

输入:  $\hat{X} \in \mathbb{R}^{L \times 3 \times 3}, X \in \mathbb{R}^{L \times 3 \times 3}$ 
1:  $\hat{X} \rightarrow \mathbb{R}^{6L \times 3}$ 
2:  $[D_{\text{pred}}]_{i,j} = [\hat{V}]_{i,:} [\hat{V}]_{j,:}$   $\mathbb{R}^{6L \times 3}$ 
3:  $[D]_{i,j} = [V]_{i,:} [V]_{j,:}$   $\mathbb{R}^{6L \times 6L}$ 
4:  $[D]_{i,j} = [V]_{i,:} \cdot [V]_{j,:}$   $\mathbb{R}^{6L \times 6L}$ 
5:  $E = (D_{\text{pred}} - D)^2$ 
6:  $E = \min(E, 20)$ 
7:  $l = \text{平均}_{i,j}(E)$   $\mathbb{R}$ 
8: 返回  $l$ 

```

3. 分箱方向分类损失: 该损失捕捉了真实值与预测方向之间的粗略相似性, 以稳定早期训练。它使用解码器的最后一层表示, 而不是预测坐标。该过程如下: (a) 单位向量: 从真实值坐标计算每个残基的三个向量: $C_\alpha \rightarrow C$, $C_\alpha \rightarrow N$, 以及 $n_{C_\alpha} = (C_\alpha \rightarrow C) \times (C_\alpha \rightarrow N)$, 并将它们归一化为单位长度。 (b) 点积: 计算所有残基中每对向量之间的成对点积, 形成 $D \in [-1, 1]^{L \times L \times 6}$ 。将点积分箱为16个均匀分布的箱, 存储在 $[-1, 1]$ 中, 形成分类标签 $y \in \{0..15\}^{L \times L}$ 。 (c) 成对逻辑斯蒂: 将解码器的最后一层表示 $h \in \mathbb{R}^{L \times d}$ 通过成对_proj_头以获取逻辑值 $z \in \mathbb{R}^{L \times L \times 6 \times 16}$ 。 (d) 交叉熵: 使用来自真实值结构的标签 y 和逻辑值 z 计算交叉熵损失, 并对所有 $L \times L \times 6$ 值进行平均。

4. 分箱距离分类损失: 类似于分箱方向分类损失, 该损失对残基之间的真实距离进行分箱 (具体而言, 它们的

C_β) 以获取真实值目标, 并计算这些目标与成对逻辑斯蒂之间的交叉熵。具体而言:

(a) 计算 C_β : 给定真实值 N , C_α 和 C 坐标, 我们计算 C_β 的位置:

i. 获取三个向量 $N \rightarrow C_\alpha$, $C_\alpha \rightarrow C$ 和 $n = (N \rightarrow C_\alpha) \times (C_\alpha \rightarrow C)$ 。 ii. 定义以下标量:

$$a = -0.58273431$$

$$b = 0.56802827$$

$$c = -0.54067466$$

iii. 使用公式计算 C_β 的位置:

$$C_\beta = an + b(N \rightarrow C_\alpha) + c(C_\alpha \rightarrow C) + C_\alpha \quad (1)$$

(b) 成对 C_β 距离: 计算 $L \times L$ 的成对距离矩阵, 并将其划分到64个区间中的一个, 区间下限为 $[0, 2.3125^2, (2.3125 + 0.3075)^2, \dots, 21.6875^2]$, 形成标签 $y \in \{0..63\}^{L \times L}$ 。

(c) 成对逻辑值: 将解码器的最终层表示 $h \in \mathbb{R}^{L \times d}$ 传递通过成对_proj_头, 以获得逻辑值 $z \in \mathbb{R}^{L \times L \times 64}$ 。

(d) 交叉熵: 使用从真实值结构计算得出的标签 y 和逻辑值 z 计算交叉熵, 然后对所有 $L \times L$ 值进行平均。

5. 反向折叠损失: 将解码器的最终层表示通过回归头传递以生成逻辑值 z 。使用真实值残基作为标签 y , 计算用于从最终层表示预测残基的分类任务的交叉熵。

A.1.7.3.2. 第二阶段。

在 VQ-VAE 训练的第二阶段, 编码器和代码本被冻结, 并训练一个新的、更深的解码器。这一训练阶段的目的有多个。首先, 更大的解码器提高了重建质量。其次, 增加了来自 ESM3 的增强结构标记, 以便能够学习 pAE 和 pLDDT 头部。第三, 我们增加序列条件, 并使用全原子几何损失进行训练, 以能够解码全原子蛋白质结构。第四, 我们扩展了解码器的上下文长度, 以便能够解码多聚体和更大的单链蛋白质。

第二阶段的训练数据包括 AFDB 和 ESMAtlas 中的预测结构, 以及单链和多聚体,

使用语言模型模拟五亿年的进化

以及来自 PDB 的抗体-抗原复合物。序列条件通过学习的嵌入添加到解码器, 这些嵌入与传递到解码器堆栈的结构标记嵌入相加。

结构标记解码器的训练分为三个阶段: 2A、2B、2C, 具体细节见表S2。阶段2A的目的是高效学习全原子结构的解码。通过保持短上下文长度并省略pAE和pLDDT损失(这两者都占用大量内存且可能与强重建质量存在竞争), 从而实现训练效率的提升。在阶段2B中, 我们添加了pAE和pLDDT损失。这些结构置信头只有在结构标记得到增强, 使得ESM3预测的结构标记位于训练分布内时, 才能进行校准。为此, 在阶段2B和2C中, 我们将真实值结构标记以50%的时间替换为ESM3预测的结构标记。在阶段2C中, 我们将上下文长度扩展至2048, 并相对于预测结构上采样实验结构。

1. 全原子距离损失: 我们通过计算每个残基的atom14表示法中14个原子之间的成对距离矩阵, 向所有原子推广骨架距离损失。这导致了 D_{pred} , $D \in \mathbb{R}^{14L \times 14L}$ 。计算的其余部分与之前相同: $(D_{\text{pred}} - D)^2$, 将其限制在 $(5^\circ \text{A})^2$, 并取平均, 同时对无效对进行掩盖(其中任何atom14表示法都是“空的”)。

2. 全原子方向损失: 我们将骨架方向损失扩展到所有重原子: (a) 识别每个残基中重原子之间的所有共价键。(b) 对于每个至少有两个共价键的原子, 计算一个与其前两个共价键所张成的平面的法向量(z轴)。这导致形成一组z轴和键向量。(c) 计算z轴和键向量之间的全对成对点积, 形成 D_{pred} , $D \in \mathbb{R}^{n \times n}$ 。计算 $(D_{\text{pred}} - D)^2$, 将最大值限制为20, 并取平均。

3. pLDDT 头部: 使用具有50个输出类别的回归头部(每个类别捕获0到100之间的0.02单位)。将预测的结构与真实值进行比较, 以计算每个残基的pLDDT值, 并通过交叉熵损失进行监督。

4. pAE 头部: 使用成对投影头产生每对残基 64 个逻辑值 $\in \mathbb{R}^{L \times L \times d}$, 通过 Softmax 转换为概率 p 。每个概率对应于一个代表 0.5°A 的位置误差的区间, 其中心为 $[0.25, 0.75, \dots, 31.25, 31.75]$ 。计算损失:

(a) 计算预测结构与真实值结构之间的残基成对距离, 从而得到距离矩阵 D_{pred} 和 $D \in \mathbb{R}^{L \times L}$ 。

(b) 计算差异 $(D_{\text{pred}} - D)$ 。

(c) 将这些差异分入64个区间, 生成逻辑值的分类目标。

(d) 使用这些目标和逻辑值之间的交叉熵计算损失。

计算pAE: 将概率乘以区间中心并求和, 以获得每对残基的预期位置误差, 值为 $\in [0.25, 31.75]$ 。

计算pTM: 此外, 成对逻辑值用于计算pTM(预测模板建模)得分, 如下所示:

(a) 计算 f_d 对于序列长度 L 如下:

$$d_0 = 1.24 \cdot (\max(L, 19) - 15)^{\frac{1}{3}} - 1.8$$

$$f_d = \frac{1}{1 + \left(\frac{\text{bins}}{d_0}\right)^2}$$

(b) 使用先前计算的概率 p 计算pTM:

$$\text{pTM} = \max_i \left[\frac{1}{L} \sum_j \left(\sum_{\text{bin}} [p]_{i,j,\text{bin}} [f_d]_{\text{bin}} \right) \right]$$

A.1.7.4. 评估

我们在训练的第1阶段和第2阶段后, 使用一组CAMEO、CASP14和CASP15蛋白质评估结构标记器的重建质量, 这些蛋白质是在训练截止日期之后获得的(图.S3)。两个解码器始终达到骨架RMSD $< 1^\circ \text{A}$, LDDT-CA > 0.98 。结构标记解码器的重新训练在所有测试集的重建质量上带来了显著的改善。第2阶段解码器以全原子重建损失和序列输入进行训练, 亦实现了强大的全原子重建(图.S3C)。我们还在CAMEO测试集上可视化了一组随机样本的骨架重建(图.S4A)。观察到重建质量较差的蛋白质时, 我们发现长的区域缺乏三级接触、无序区域以及未解决的坐标可能导致结构元素的全局取向不准确, 而局部结构重建则保持大量无误(图.S4B)。这种行为可以通过标记器依赖于三级接触来解决残基的全局取向来解释。

我们还通过可视化映射局部邻域来调查结构标记器所学习的词汇表,

利用语言模型模拟五亿年的进化

阶段	步骤	全原子几何损失	pAE pLDDT 损失	和 增强与ESM3预测的标记	上下文长度	数据混合
2A	90k				512	预测和实验结构的近似均匀采样
2B	20k				512	预测和实验结构的近似均匀采样
2C	30k				2048	上采样实验结构

表 S2. 全原子结构标记解码器第二阶段训练的训练细节。

以相同的结构标记为学习结构标记。我们发现许多结构标记编码了语义上连贯的局部邻域集合 (图. S5A)。然而, 许多标记似乎代表多个局部邻域 (图. S5B)。尽管单个标记的含义可能模糊, 但解码器所展现的高保真重建质量表明, 它能够在完整的结构标记集合中根据周围上下文进行消歧。

图 S6 表明 pLDDT 和 pTM 具有良好的预测能力。我们使用 ESM3 7B 预测的结构标记评估 CAMEO 测试集上结构置信头的校准情况。大多数 pLDDT 的预测沿对角线分布, 尽管存在对更自信预测的轻微偏差。由于 pTM 是 TM-score 的悲观估计器, 我们发现 pTM 存在向下偏差。根据轶事, 我们还发现 pLDDT 在一些生成的序列中可能校准不佳, 特别是在 α 螺旋区域, 此时它可能被高估。

A.1.8. 函数标记化

ESM3 通过两个轨道处理蛋白质的功能特征注释: 功能令牌和残基注释。两者支持输入条件和生成的输出头。附录 A.1.5.1 概述了标记如何被处理到网络中。我们在本节进一步描述了标记的创建过程。

A.1.8.1. 功能令牌

功能令牌是从每个残基的InterPro和基因本体 (GO) 术语的自由文本描述中提取的蛋白质功能特征的密集语义表示。在训练时, 通过一个多步骤过程生成功能令牌, 该过程展示于图. S7. 从高层次看:

1. 对于每个残基, 我们通过注释术语名称收集每个 InterPro 注释的自由文本, 通过 InterPro2GO 映射关联的 GO 术语和所有祖先 GO 术语。我们解析自由文本

为来自 68,103 个关键词的词汇表统计数量。该词汇表由从我们训练数据集中所有有效 InterPro 注释 (及其关联的 GO/祖先 GO 术语) 的自由文本中提取的单元词和二元词组组成。

2. 关键词被转换为每个InterPro注释的稀疏 TF-IDF向量。在训练期间, 我们还通过在蛋白质级别丢弃关键词 (即相同的关键词在所有残基上的计数被设置为0) 以15%的概率生成一个损坏的版本。
3. 为了从每个注释向量创建每个残基的向量, 我们对每个残基的注释的TF-IDF向量进行最大池化。在训练期间, 我们通过在蛋白质级别丢弃注释 (即相同的注释从所有残基的最大池中移除) 以15%的概率进一步引入损坏。

4. 然后我们将每个残基的向量 (一个高度稀疏的浮点数向量) 量化为适合作为标记输入到语言模型的离散表示, 通过应用一系列固定的8个局部敏感哈希 (LSH), 每个哈希具有8个超平面。结果是一系列包含8个标记的序列, 每个标记的值范围从0到255, 针对每个残基。我们保留一个特殊的标记<none> 以表示没有InterPro注释的空集合位置。对于缺乏任何功能注释的蛋白质, 这些标记使用 <pad> 标记填充, 其嵌入值固定为全零。在测试时, 我们可以使用所描述的过程生成每个残基的向量, 或直接创建一个带有关键词的TF-IDF向量。在预训练期间, 我们使用功能令牌的损坏版本作为输入, 预测在被屏蔽位置的未损坏版本功能令牌。90%的时间, 整个输入被替换为 <mask>。另外10%的时间, 我们替换所选的所有8个标记。

用语言模型模拟五亿年的演化




图 S3. 结构标记器重建质量。VQ-VAE 解码器训练的第一阶段和第二阶段后, 结构标记器的重建质量评估在时间上保留的 CAMEO、CASP14 和 CASP15 上。(A) 重建 LDDT-CA。(B) 重建骨架 RMSD。(C) 从第二阶段解码器获得的全原子重建 RMSD, 该解码器还接受序列输入。

残基与一个 <掩码>, 每个残基的选择概率是从每个蛋白质的余弦掩码调度中采样的。该模型具有一个输出头, 它预测每个功能令牌在具有 <掩码> 的位置信息, 并使用分类交叉熵损失进行训练。

与较简单的方法 (例如, 使用专门的 InterPro 标签词汇表) 相比, 函数标记化提供了几个关键优势。使用通用功能关键词词汇编码功能注释, 使得在测试时通过未在训练期间遇到的关键词组合灵活地提示模型成为可能。这增强了 ESM3 的可编程性, 以设计具有先前未观察到的功能特征的新型蛋白质。

函数标记化也可以从数据压缩的角度来看待。这种表示选择将输入/输出空间从所有可能的 InterPro 组合的 35k 比特, 缩减到一个 8 个标记 x 8 比特/标记 = 64 比特的减小空间。这还通过消除执行多类多标签二元分类的需要, 在预训练期间显著节省内存。

A.1.8.2. 功能预测

ESM3 经过训练能够预测所有 8 个功能令牌, 每个功能令牌覆盖 256 种可能值。为了从 ESM3 提取可解释的蛋白质功能预测, 我们使用单独训练的功能令牌解码器将预测的功能令牌解码为功能关键词。

A.1.8.2.1. 功能令牌解码器

我们训练了一个 3 层变换器模型, 以学习功能标记化过程的反向映射。该模型的输入为 8 个功能令牌, 代表功能关键词的局部敏感哈希。它为每个残基输出二元分类预测, 预测每个功能关键词的存在, 以及预测关键词来源的 InterPro 注释。我们发现, 将 8 位 LSH 令牌展开为单个位令牌改善了功能令牌解码器的训练动态。我们使用从 UniRef 注释蛋白质中组合的 InterPro 标签离线训练功能令牌解码器。由于功能令牌词汇固定, 解码器在不同 ESM3 模型大小上应用一致。

A.1.8.2. 评估为了评估 ESM3 在预测蛋白质功能方面的性能, 我们计算平均精度, 这是一种标准的信息检索衡量方法, 使用来自 UniRef 的蛋白质及其相关的 InterProScan 功能注释的验证集。我们在图中呈现结果。S8.

A.1.8.3. 残基注释跟踪 残基注释标记了蛋白质的功能残基位点, 使用由 InterProScan 发出的 1474 个多热标记的词汇表。为了收集这些数据, 我们在我们的 UniRef 和 MGnify 数据集的所有集群成员 (序列 ID 90 集群) 上运行 InterProScan, 数据库包括 (SFLD, CDD, PIR)。我们提取所有在 UniRef90 和 MGnify90 的超过 1000 个蛋白质中出现的独特残基注释描述, 并通过标点符号和不区分大小写来消除重复标签。

利用语言模型模拟五亿年的演化




图 S4. 结构标记器主干重建的可视化。(A) 结构标记器在测试集上重建的随机样本。绝大多数结构的主干重建几乎完美。(B) 测试集中最差重建的选择。长段无序区域、缺乏三级接触和未解决坐标可能导致结构元素的全球方向不准确，而局部结构重建在很大程度上保持无误。

使用语言模型模拟五亿年的进化




图 S5. 可视化映射到相同学习结构标记的局部邻域。VQ-VAE 编码器对局部结构邻域进行推理（用红色突出显示），其中包括查询残基及其在结构空间中的 15 个最近邻居。(A) 行对应于标记索引 585、59 和 3692，分别代表顶部、中间和底部。列显示映射到相同标记的不同局部结构。(B) 一些标记代表多种类型的局部邻域。B 中的所有局部邻域都映射到相同的代码本索引 3276。尽管单个标记的含义可能模糊不清，但解码器能够在总体结构标记序列的上下文中消除歧义。

用语言模型模拟五亿年的演化




图 S6. pTM 和 pLDDT 校准。结构标记解码器 pLDDT 和 pTM (使用 ESM3 7B 作为结构标记预测模型) 在 CAMEO 测试集上的校准。




图 S7. 函数标记化示意图。蛋白质功能的 InterPro 和 GO 描述集合通过 TF-IDF 模型向量化, 然后通过局部敏感哈希进行哈希处理, 从而产生 8 个每个包含 8 位的标记。

使用语言模型模拟五亿年的进化




图 S8. 功能预测基准结果。功能关键词预测的平均精度（mAP）。预测与标签在每个位置进行比较，以评估模型在通过诸如“活性位点”等关键词局部化位点特定功能属性的能力。我们报告针对完整关键词集的 mAP（红色），使用“微”平均，因为许多关键词在验证集中具有少量或没有标签。为了报告“宏”平均 mAP，我们计算评估集中前 1,000 个最常见关键词的 mAP（丢弃诸如“the”等无信息关键词），并报告均匀平均（蓝色）。95% 置信区间通过阴影显示。

我们将这些注释整合到我们的 UniRef、MGnify、AFDB 和 ESMAtlas 数据集中以进行训练。

如附录中介绍的 A.1.5.1，ESM3 配有一个专门处理残基注释的轨道，支持输入条件化，以及一个用于预测和生成的输出头。蛋白质的残基注释标签被标记为与蛋白质长度相等的标记集序列。在每个位置上，有一个无序的标记集，表示该位置存在的残基注释。这些标记首先通过嵌入查找输入到 ESM3，随后进行嵌入的求和。求和的排列不变性保持了标签作为无序集合的表示。然后，逐位置的嵌入求和添加到逐位置的序列嵌入中，然后输入到第一个变换器块。没有残基注释的位置由一个 <pad> 标记表示，其嵌入固定为零。

残基注释轨道具有输出头，该输出头输出一组二分类逻辑值，以预测每个位置上每个残基注释在词汇表中的存在或缺失。我们应用掩蔽程序以部分/完全掩蔽残基注释标签，并使用二元交叉熵损失函数训练输出头，以重建完整的残基注释。在预训练中，以90%的概率所有残基注释被掩蔽，其余情况下我们独立地采样位置进行掩蔽，采用平方根调度。

A.1.9. 其他轨迹

A.1.9.1. 置信度轨迹

如附录中所述A.1.5.1，ESM3 具有两个额外的轨道，仅在预训练期间使用，并且只作为输入使用（我们没有预测这些值的输出头）。第一个是每个残基的 pLDDT：对于真实值 PDB 结构，这些值均为1；对于 AlphaFold-DB/ESMFold 结构，我们使用提供的 pLDDT。当提供结构时，我们还提供所有残基的平均 pLDDT（否则为1），该平均值在任何标记被掩蔽之前计算。

这些信息使模型能够区分金标准结构与计算预测结构；在推理时，我们将这些值设置为 1，目的是生成比用于预训练模型的计算预测更优的结构。嵌入本身是直接的，其中 pLDDT 值首先应用了径向基函数，然后再应用了线性层：

算法 12 径向基

输入： $x \in \mathbb{R}^{\dots \times L}$, $a \in \mathbb{R}$, $b \in \mathbb{R}$, $n \in \mathbb{Z}^+$

- 1: $\Delta = \frac{b-a}{n-1}$ $\triangleright \mathbb{R}$
- 2: $c = [a, a + \Delta, a + 2\Delta, \dots, a + (n-2)\Delta, b]$ $\triangleright \mathbb{R}^n$
- 3: $\sigma = \frac{b-a}{n}$ $\triangleright \mathbb{R}$
- 4: $[z]_{\dots, i, j} = \frac{1}{\sigma}([x]_{\dots, i} - [c]_j)$ $\triangleright \mathbb{R}^{\dots \times L \times n}$
- 5: 返回 $\exp(-z^2)$ $\triangleright \mathbb{R}^{\dots \times L \times n}$

算法 13 pLDDI

输入： $x_{\text{plddt}} \in [0, 1]^L$, $x_{\text{avgplddt}} \in [0, 1]$

- 1: $\text{rbf}_{\text{plddt}} = \text{rbf}(x_{\text{plddt}}, 0.0, 1.0, 16)$ $\triangleright \mathbb{R}^{L \times 16}$
- 2: $\text{rbf}_{\text{avgplddt}} = \text{rbf}(x_{\text{avgplddt}}, 0.0, 1.0, 16)$ $\triangleright \mathbb{R}^{16}$
- 3: $z_{\text{avgplddt}} = \text{线性}(\text{径向基函数}_{\text{avgplddt}})$ $\triangleright \mathbb{R}^d$
- 4: $z_{\text{plddt}} = \text{线性}(\text{rbf}_{\text{plddt}})$ $\triangleright \mathbb{R}^{L \times d}$
- 5: $[z_{\text{plddt}}]_{i,:} = [z_{\text{plddt}}]_{i,:} + z_{\text{avgplddt}}$ $\triangleright \mathbb{R}^{L \times d}$
- 6: 返回 z_{plddt}

A.1.9.2. 分类法跟踪 98B变体的ESM3在预训练中的最终30,000步包括一个用于处理生物体的分类和物种分类的轨道，该生物体是蛋白质序列的来源。对于每个蛋白质，分类和物种分类被连接以生成完整的分类谱系。然后使用包含训练数据集中前40,000个分类术语的词汇表对术语列表进行标记。在输入时，谱系中每个术语的学习嵌入（维度768）被汇总并通过学习的线性投影投影到一个

使用语言模型模拟五亿年的进化

单一的 d_{model} 嵌入被重复应用于序列的长度, 并与所有其他轨迹的嵌入相加。在此训练阶段的开始, 线性投影被初始化为零, 以保持模型行为, 从而使预训练的连续进行不会导致性能下降。

在预训练中, 我们对分类谱系应用随机腐蚀, 训练 ESM3 通过预测丢失的术语来重建完整的谱系, 使用在最终层表示上训练的浅层多层感知机 (MLP) 头部。为了腐蚀分类谱系, 我们要么丢弃所有术语 (概率为 25%), 要么随机均匀选择一个大小在 1 到谱系长度之间的特定术语集合 (概率为 25%) 来丢弃。我们还独立地以 10% 的概率丢弃任何分类术语。输出头部为全套 40,000 个分类谱系术语输出二分类逻辑值, 并通过二元交叉熵损失训练以预测缺失的术语。

A.1.10. ESM3 推理

由于 ESM3 是一种双向变换器, 能够以任意顺序或组合表示联合概率的任意分解, 因此在推理过程中我们具有显著的灵活性。我们可以基于其他轨迹的任意组合生成序列、结构或功能。我们还可以选择在生成过程中应用多少计算资源。

通常的推理策略是固定一个提示 (这可以是任何轨迹的组合, 完全或部分指定), 并选择一个用于生成的轨迹 (该轨迹可能已被部分指定)。在预测生成轨迹的标记时, 有多种策略可供选择。这里我们讨论两种显著的策略。Argmax 解码, 该策略在模型的单次前向传递中预测生成轨迹中的所有标记; 该计算为 $O(L^2)$, 以蛋白质的长度为单位, 且效率极高。另一方面, 迭代解码则一次采样一个位置的标记, 并根据已采样的标记条件生成后续预测。迭代解码的运行时间为 $O(L^3)$, 以蛋白质的长度为单位。

此外, 解码步骤的数量可以在运行时选择。Argmax 解码等同于一步解码, 而迭代解码则等同于在 L 步进行解码。可以在这两种极端之间选择任何数量的解码步骤, 以寻找特定用例中计算与准确性之间的最佳权衡。请参见附录 A.3.4 中的结构预测案例研究, 其中生成轨迹是结构标记轨迹。

在使用迭代解码时, ESM3 进一步允许在选择下一个解码位置方面具有灵活性。我们根据 ESM3 输出的逻辑值选择该位置, 并且对于

本文的结果利用了两种策略: 熵解码, 选择软最大后熵值最低的位置, 或者最大逻辑解码, 选择具有最大逻辑值的位置。为了在一次传递中生成 k 标记, 我们通过熵或最大逻辑对位置进行排序, 并选择前 k 个位置。

在以下算法中, 假设 ESM3 的单个前向传递是提示 x 的函数 f , 并且我们可以通过下标访问特定标记轨迹的逻辑值; 例如, 序列逻辑值将为 $f_{\text{sequence}}(x) \in \mathbb{R}^{L \times 32}$ 。此外, 记作 $\pi(($

$z)$ 是由逻辑值 z 引发的概率分布, 包括一个隐式的 Softmax 和 $T \in \mathbb{R}^L$ 温度调度。

算法 14 从轨迹

```

输入:  $x_{\text{prompt}}, n_{\text{decode}} \in \{1..L\}, T \in \mathbb{R}^{n_{\text{decode}}}$ 
1:  $k = L/n_{\text{decode}}$   $\triangleright$  # 每个步骤解码的步骤
2: 对于  $s \in \{1..n_{\text{decode}}\}$  do
3:    $z_{\text{logits}} = \text{pt}$   $\triangleright z \in \mathbb{R}^{L \times C_{\text{track}}}$ 
4:    $\{p_1, \dots, p_k\} = \text{C选择P位置}(z)$ 
5:   对于  $i \in \{p_1, \dots, p_k\}$  并行执行 do
6:      $x_i \sim \pi(x; z_i/T_s)$   $\triangleright$  示例  $i$  与 temp  $T_s$ 
7:      $x_{\text{prompt}} = \{x_{\text{prompt}}, x_i\}$   $\triangleright$  更新提示
8:   结束
9: 结束

```

A.2. 训练 ESM3

A.2.1. 预训练数据

A.2.1.1. 序列数据库

UniRef发布2023年02月从官方UniRef网站下载并解析 (77)。MGnify90版本2023年02月从MGnify下载并解析 (37)。2023年7月31日, 在JGI中可用的所有非限制性研究被下载并连接到JGI数据集 (78)。OAS包含来自80个研究的超过十亿个抗体序列, 下载并以95%的序列同一性进行聚类 (38)。

A.2.1.2. C聚类在所有情况下, 数据使用mmseqs2进行聚类 (79), 使用标志 `--kmer-per-seq100 --cluster-mode2 --cov-mode1 --c0.8--min-seq-id<seqid>`。在训练过程中, 我们通过聚类重新权重数据分布。我们首先在外层随机抽取一个集群, 然后随机抽样该集群的一个成员。为了去重集群成员, 我们在高序列同一性水平 (例如90%) 上执行首次聚类步骤, 每个集群选择一个代表。然后我们对这些进行聚类

利用语言模型模拟五亿年的进化

在较低的序列一致性水平 (例如70%) 下去重的序列。我们将一个集群内的样本数量限制为20。

A.2.1.3. 反向折叠 作为数据增强, 我们训练一个具有200M参数的反向折叠模型, 并利用它创建额外的训练示例。该反向折叠模型使用几何注意力进行结构化, 并采用输出投影头来生成序列逻辑值, 类似于ESM3。与ESM3不同的是, 该变换器堆在几何注意力块和标准注意力块之间交替。该模型在PDB、AlphaFold-DB和ESMAtlas中的序列与结构对上训练, 唯一的训练任务是 (并计算损失) 在输入结构的基础上预测输出的序列。模型的架构和训练方法在其他方面与ESM3基本相似。该模型用于生成与ESM3训练数据中每个结构相对应的额外序列 (对于ESMAtlas和AlphaFold-DB, 每个结构5个序列, 对于PDB, 每个结构64个序列)。在训练ESM3时, 以50%的概率将原始序列和结构对作为训练示例呈现给模型。而在另50%的情况下, 反向折叠得到的序列与结构配对作为ESM3看到的训练示例。

A.2.1.4. FUNCTIONALLABELS功能标签来自InterPro (40) 和InterProScan (80), 均为95.0版本。所有UniProtKB的注释均通过 ‘protein2ipr.dat.gz’ 文件从InterPro网站下载。InterProScan被应用于整个MGnify90, 附带标志--goterms --iprlookup--pathways --disable-precvalc。结果值被视为模型训练的真实值功能标签。

A.2.1.5. STRUCTURALDATA我们使用所有PDB链, 根据唯一的PDB ID和PDB结构内的实体ID进行聚类。我们过滤出所有在2020年5月1日之前提交的结构, 通过X射线晶体学确定, 并且分辨率优于 $9^\circ \text{\AA}$ (39)。AlphaFoldDB下载为其网站上指定的v4版本 (4)。我们注意到具有较高pLDDT的结构在 α -螺旋中所占比例较高。因此, 我们通过测量链中远距离 (>12 序列距离) 接触的数量来确保球状性。如果此值小于 $< 0.5L$ (L 为序列长度的蛋白质), 我们将其从训练集中剔除。我们还过滤掉所有 $< \text{pLDDT} < 0.7$ 小于0.7。ESMAtlas下载为v0和v2023 02版。Sim-

同样地, 我们使用 < 0.7 pLDDT 过滤器。我们也使用 0.7 的 pTM 截止值以强制执行球状性。高 pTM 结构往往更加紧凑。

结构数据还包括与对应序列存在的任何功能标签。

A.2.1.6. 溶剂可接触的表面区域和二级结构对于溶剂可接触表面面积, 我们使用在 biotite 中实现的 Shrake-Rupley 滚动探针算法 (81)。这生成一组真实数值, 或在未提供结构坐标时生成一个纳值。同样, SS8 标签是使用 mkdssp 工具 (82) 生成的, 并作为真实值标签。为 AlphaFoldDB 和 ESMAtlas 数据集生成了 SS8 和 SASA 轨道。

A.2.1.7. 清除验证序列 我们跟踪来自每个训练集: UniRef、MGnify 和 JGI 的一组排除序列的验证集性能。为了正确保持一个足够多样化的验证蛋白质集, 我们首先从每个数据集中抽取 25000 个蛋白质。然后, 我们使用 mmseqs easy-search 以 70% 的序列一致性阈值过滤掉该集合中的蛋白质。我们选择来自训练集的蛋白质集合作为 “查询” 集, 将验证蛋白质集合视为 mmseqs 的 “目标” 集。我们使用标志 --alignment-mode 3 -c 0.8 {cov-mode 0 --max-seqs 300 --max-accept 3 --start-sens 2 -s 7 --sens-steps 3。该查询设计为使早期停止在 mmseqs 中不会影响我们是否能在 “查询” 训练集中找到匹配。运行训练清除以生成黑名单上的 UniRef、MGnify 和 JGI ID 列表, 这些 ID 将从训练集中移除。

A.2.1.8. TOKENCOUNTS数据集在表S3 中计算, 限制大型集群为20后进行计算。标记的数量通过将序列的数量与数据集的平均长度相乘来计算。为计算训练期间看到的序列和标记的近似数量, 我们首先计算数据集在集群级别重复的次数。给定重复的次数, 我们知道在替换抽样时, 看到的独特样本的预期数量是 $n \left(1 - \left(1 - \frac{1}{n}\right)^k\right)$, 集群的大小为 n , 选定的 k 项目数量。对每个集群的大小和数据集重复的数量进行计算, 结果在表S4中显示近似标记的数量。我们最大的模型在所有这些数据上进行训练, 而我们较小的模型则使用一部分数据。

这取决于模型的标记预算。

A.2.2. 预训练任务

A.2.2.1. 噪声调度

在掩蔽生成框架中, 损坏会施加到模型的每个输入上。为了使生成能够进行, 施加到输入上的噪声量是从一个概率质量分布中抽样的, 该分布的值范围在0到1之间。

我们为不同的轨道选择了各种噪声调度, 考虑了多个目标。首先, ESM3应接收所有轨道的组合作为输入和输出, 使其能够根据任意输入生成和预测。其次, ESM3应保持强表征学习与高质量生成之间的平衡。第三, 提供的输入类型应能够代表用户希望提示模型的内容。

在初步实验中, 我们发现固定的15%噪声调度导致生成结果不佳, 而线性噪声调度的每个掩蔽率概率保持不变则导致生成良好但表征学习结果不佳。通过从混合分布中抽样噪声调度, 我们发现表征学习与生成之间的良好权衡。80%的时间, 掩蔽率是从一个 $\beta(3, 9)$ 分布中抽样的, 平均掩蔽率为25%。20%的时间, 掩蔽率是从均匀分布中抽样, 导致整体平均掩蔽率为30%。

应用于每个输入的噪声调度列于表格S6。对于结构坐标轨道, 我们还修改了掩蔽的应用方式, 每次以50%的概率进行跨度丢弃。这确保模型看到被掩蔽和提供的坐标的连续区域, 这更好地模拟了用户可能提供的输入类型。

A.2.2.2. 轨道丢失

在对每条轨道施加噪声的同时, 我们希望确保ESM3在某些轨道完全没有提供的情况下仍能表现良好 (例如, 在未提供任何结构作为输入时执行结构预测)。我们通过以不同的概率完全丢弃某些轨道来实现这一点, 具体见表S6。

A.2.2.3. 结构噪声 我们对模型作为输入的所有坐标施加标准差为0.1的高斯噪声。

A.2.2.4. 三级协调采样 生成蛋白质模型的一个有趣用例涉及对关键结构信息的条件处理, 例如

一个活性位点, 并生成包含此信息的蛋白质的序列和结构。可以将三维协调任务定义为在结构空间中互相接触的3个残基 ($C\alpha - C\alpha$ 距离 $< 6 \text{ \AA}$), 但是在序列空间中相距较远 (≥ 10 位置距离) (26)。在这种条件下的训练可能使模型更好地执行活性位点取样所需的三维协调类型。

虽然该任务将在标准噪声调度下以一定概率进行采样, 但我们也在结构可用时手动以5%的概率进行任务采样。如果该任务被采样且找到有效的三级配位三元组, 则该三元组的结构坐标将展示给模型。对于三元组中的每个残基, 相邻残基也以50%的概率独立展示, 从而导致总数在3到9个残基之间。所有其他结构坐标均被屏蔽。其他轨迹应用正常屏蔽。

A.2.2.5. 三级界面采样 预测和生成结合界面是生成蛋白质模型的另一个重要任务。为了帮助实现这一能力, 我们增加了模拟结合界面任务的计算数据增强。我们将三级界面定义为涉及长距离接触的界面 ($C\alpha - C\alpha$ 距离 $< 8 \text{ \AA} \geq 24$ 序列位置)。当该任务被采样 (在结构存在时, 概率为5%) 并且找到长距离接触时, 链将被拆分为两个链, 每个链包含接触界面的一侧。假设接触位置由索引 i, j 给出。那么第一条链将包含残基在 $[\text{RANDINT}(1, i - 3), \text{RANDINT}(i + 3, j - 15)]$ 之间, 而第二条链将包含残基在 $[\text{RANDINT}(i + 15, j - 3), \text{RANDINT}(j + 15, L)]$ 之间。这确保了两个伪链之间始终存在残基间隙。插入一个链断符号 “—” 以表示残基间隙。

A.2.2.6. 残基间隙增强 为了鼓励模型学习使用链断符号表示残基间隙, 我们引入了一项任务, 该任务随机将单个链分割为多个子链。首先, 从几何分布中抽样出待抽样的链的数量, 概率为0.9, 最多可达到9个可能的链。如果抽样的链的数量为1, 则不应用额外的变换。定义链之间的最小分离为10个残基。链的序列长度及其间隙从狄利克雷分布中抽样, 以维护每个链相同分布的序列长度。此变换适用于所有样本。

使用语言模型模拟五亿年的演化

数据集	类型	聚类级别	扩展级别	标记	发布
UniRef	序列	70% (83M)	90% (156M)	54.6B	2023_02
MGnify	序列	70% (372M)	90% (621M)	105.5B	2023年02月
JGI	序列	70% (2029M)	-	256B	所有未受限制的研究均可在2023年7月30日。
OAS	序列	95% (1192M)	-	132B	所有序列均可在7月30日获得, 2023。
PDB	结构	- (203K)	-	0.054B	在 RCSB 上可用的所有链, 截止于
PDB聚类	结构	70% (46K)	100% (100K)	0.027B	2020年5月1日
AlphaFoldDB	结构	70% (36M)	90% (69M)	40.5B	v4
ESMatlas	结构	70% (87M)	90% (179M)	23.5B	v0, 2023年02月

表S3. 预训练数据集统计。包括标记数量、发布和聚类级别。数字是在数据集过滤后得出的。

数据集名称	唯一样本 (百万)	唯一标记 (百万)
UniRef	133	40,177
MGnify	406	65,780
JGI	2,039	265,070
OAS	203	22,363
PDB	0.2	55
AFDB	68	20,510
ESMatlas	168	38,674
AFDB 逆折叠	111	33,300
ESMatlas 逆折叠	251	57,730
序列	3,143	484,441
结构	236	177,710
注释	539	105,957
总独特训练标记		768,109

表S4. 预训练唯一标记统计数据。按标记类型和数据集类型进行分类。

数据集	反向折叠	函数标签	SASA	二级结构
UniRef	>	>	-	-
MGnify	>	>	-	-
JGI			-	-
OAS			-	-
PDB				
AlphaFoldDB	>	>	>	>
ESMatlas	>	>	>	>

表 S5. 应用到每个数据集的数据增强和条件信息。

使用语言模型模拟五亿年的进化

轨迹	噪声调度	丢弃概率
序列	betalinear30	0
结构标记	余弦	0.25
结构坐标	立方	0.5
二级结构 (8类)	平方根	0.9
SASA	平方根	0.9
功能令牌	平方根	0.9
残基注释	平方根	0.9

表 S6. 噪声调度和丢弃概率。




图 S9. 使用的噪声调度的可视化。左侧显示所有使用的噪声调度的概率密度函数。右侧显示betalinear30分布 (其以 $\beta(3, 9)$ 的80%概率和线性分布的20%概率绘制) 与beta30分布 (由 $\beta(3, 7)$ 定义) 及线性分布的对比。

A.2.2.7. 几何注意力掩蔽

在从接口采样或残基缺口扩增任务中向模型提供多个链的情况下, 我们对几何注意力层进行掩蔽, 以防止模型关注跨链坐标。这模拟了已知单个链的结构但未知接口的任务。

A.2.3. 训练细节

A.2.3.1. 超参数

我们使用 AdamW 优化器对所有模型进行训练 (83), 并采用以下超参数: $\beta_1 = 0.9$, $\beta_2 = 0.95$ 。我们使用 0.01 的权重衰减和 1.0 的梯度裁剪。我们在达到最大学习率之前, 使用 5K 到 20K 的热身步数, 并利用余弦衰减调度器在训练结束时将学习率衰减至最大学习率的 10%。

A.2.3.2. 基础设施

我们的训练代码库使用 Pytorch。我们使用 Pytorch 的 FSDP (84) 实现数据并行性。我们还使用来自 TransformerEngine (85) 库的自定义组件。

我们进行了几项优化, 以提高我们模型的训练速度。对于多头注意力的使用, 我们采用了来自xformers的内存高效实现。

库 (86)。我们还在必要时保存训练过程中计算成本高昂的激活值。我们采用混合精度训练, 根据准确性要求和整个网络中内核的可用性, 利用FP8、BF16和FP32。

A.2.3.3. 稳定性

将 ESM3 扩展到 98 十亿个参数, 结合其新颖的架构、多模态输入和低精度计算要求, 面临着重大的训练稳定性挑战。我们的模型明显比其 NLP 对应物更深, 文献表明, 较深的网络由于注意力崩溃 (87) 而更难训练。

我们在架构创新阶段早期观察到了训练不稳定性, 我们通过几个变更来解决这一问题。我们在注意力机制中的查询和键向量上应用了层归一化 (88)。我们观察到较长的热身有帮助 (89)。另一个不稳定的来源是预训练任务中的遮罩率。我们发现, 过高的遮罩率比较低的遮罩率更可能导致训练发散, 尤其是在训练早期。选择偏向较低遮罩率的遮罩调度改善了性能和训练稳定性。有趣的是, 来自其他模态的条件引入也改善了训练稳定性, 这或许表明稳定性与任务的不足规范程度相关。

设置不正确的学习率是另一个不稳定的来源-

为了确保学习有效性与稳定性之间的正确平衡，我们在较小的模型上优化了学习率，并根据 (90, 91) 中概述的最佳实践进行缩放。我们实证发现，初始化对模型稳定性的影响很小，而大多数稳定性来自于在适当的速率下简单缩放学习率。通过在宽度 μ_P 和深度 μ_P 中应用规则，我们可以简单地将学习率按参数数量的平方根成反比进行缩放，发现这能实现稳定训练。

在进行这些修改后，我们成功训练了我们的980亿参数模型，没有遇到与训练不稳定相关的任何问题。

A.2.3.4. 分阶段训练

我们通过分阶段训练来改变数据集的组成，在较长的上下文上进行训练，该上下文对于整个预训练来说过于昂贵，或引入特征，例如分类法跟踪 (A.1.9.2)。

A.3. 模型评估

ESM3既是生成模型也是表示学习模型，可适用于预测任务。在本节中，我们展示了这两种能力的基准测试结果。

A.3.1. 模型

ESM3模型在三个规模上进行训练——1.4B、70亿和98B参数——分别基于约75B、560B和1.8T的训练标记。

ESM3 1.4B模型在75B标记上训练，以其小巧和快速而著称，允许在训练和推理期间进行快速迭代。通过从一系列较小的运行中推断，研究最优模型大小和训练标记数量，考虑到训练计算预算、模型架构和数据集特征 (22, 24)。在确定训练的计算最优性后，还考虑了多种因素，如发布频率、推理量、易用性和使用模式，以确定训练模型的理想标记数量。为了使研究社区能够进行高效推理，我们额外训练了两个版本的ESM3 1.4B，分别命名为1.4B Overtrained和1.4B Open，这两个版本是在300B标记上训练的，远超其计算训练的最优性。

A.3. 2. 数据在本节的基准测试中，除非另有说明，否则模型在902种蛋白质的测试集上进行评估，这些蛋白质的结构暂时从ESM3中排除。

训练集。蛋白质来源于2020年5月1日至2023年8月1日发布的连续自动模型评估 (CAMEO) 目标 (92)。

对于接触和结构预测评估，我们还在CASP14 (71种蛋白质) 和CASP15 (70种蛋白质) 结构预测基准上进行评估 (93, 94)。CASP14和CASP15数据集直接由组织者提供。

A.3. 3. 表征学习接触预测模型是一个独立操作于每对氨基酸的表征的多层感知机 (MLP) 头，输出它们之间的接触概率。我们使用 LoRA (95) 进行微调，这是一种常见的全权重微调的替代方案，它在达到较强性能的同时使用更少的内存。LoRA 被应用于基础模型进行微调，同时 MLP 和 LoRA 权重通过交叉熵损失相对于真实值接触预测图进行端到端训练。对于真实值，所有在序列中至少相隔6个位置并且在 $8^\circ \text{AC}\alpha\text{-C}\alpha$ 距离内的残基被标记为接触。所有模型均以 LoRA 等级 4、批量大小 64 和学习率 $1\text{e-}3$ 在 PDB、AlphaFold-DB、ESMAtlas 和 OAS 预测结构的数据的混合上训练 10k 步。数据按 1:3:3:0.03 的比例从这些数据集中抽样。表S7 显示了每个结构测试集的性能，通过L时的精度指标 (P@L)，该指标评估最有信心的前L个预测的精度，其中L是蛋白质的序列长度。最小的 ESM3 模型，拥有 1.4B 参数，在 CAMEO 测试集上达到 P@L 为 0.76 ± 0.02 ，超过了 3B 参数的 ESM2 模型 (0.75 ± 0.02)。此外，它在预训练期间计算量少了一个数量级 (6.72×10^{20} FLOPs 对比 1.8×10^{22} FLOPs)，展示了多模态预训练的优势。

A.3. 4. 结构预测ESM3 可以直接预测蛋白质结构，而无需额外的微调，方法是首先预测结构标记，然后将这些标记解码为坐标。在预测结构标记时，我们遵循附录A.1.10 中概述的策略，并测试 argmax 解码和完全迭代解码。对于更困难的数据集，如 CASP14 和 CASP15，迭代解码具有显著影响 (见表S8)，而对于较简单的数据集如 CAMEO，argmax 预测是足够的。在 CAMEO 和 CASP15 数据集中，70亿模型的 argmax 预测与 ESM-Fold 相当，而 ESM3 98B 的迭代解码超越了

使用语言模型模拟五亿年的演化

模型	CASP14	CASP15	CAMEO
ESM2 3B	0.57 (0.49 - 0.64)	0.57 (0.48 - 0.65)	0.75 (0.73 - 0.77)
ESM3 1.4B	0.56 (0.48 - 0.64)	0.59 (0.50 - 0.66)	0.76 (0.74 - 0.78)
ESM3 7B	0.62 (0.54 - 0.70)	0.64 (0.56 - 0.73)	0.82 (0.80 - 0.84)
ESM3 98B	0.66 (0.57 - 0.74)	0.66 (0.57 - 0.75)	0.85 (0.83 - 0.86)

表 S7. 精确度@L 结果。在 CASP14、CASP15 和 CAMEO 上测量, 适用于 ESM3 模型系列。区间表示自助抽样的 95% 置信区间。




图 S10. 结构预测的缩放曲线。误差条为单个标准差。

ESMFold。作为训练计算的函数, 结构预测缩放曲线见图。S10。

A.3.5. 条件似然

给定提示的输出的条件似然作为模型生成能力的代理。图 S11 和表S9 评估了ESM3作为条件生成模型的性能, 使用其在测试集上的负对数似然 (NLL)。对于每个轨迹——序列、结构、功能、SASA和二级结构——NLL既进行了无条件评估, 也在每个其他轨迹的基础上进行了评估。

与自回归模型不同, ESM3是针对掩蔽模式的生成模型, 因此其训练是为了在给定任何掩蔽模式的情况下预测标记。样本在ESM3下的NLL由 $\frac{1}{L} \sum_{o \in \mathcal{O}} \frac{1}{L} \sum_{i=1}^L \log p(x_{o_i} | x_{o_1}, \dots, x_{o_{i-1}})$ 给出, 其中 $\mathcal{O}$ 是包含归一化常数 $Z = \frac{1}{L!}$ 的所有解码顺序的集合。此计算是不可计算的 (因为所有解码顺序的集合在蛋白质的长度上是指数级的), 但可以通过抽样单个解码顺序来逼近。

o 针对我们数据集中每个 x 。在每一步中, 教师强制用于用真实值标记替换遮盖标记, 并报告输出标记的平均负对数似然。

我们在这些结果中观察到许多有趣的趋势。正如预期的那样, 无条件负对数似然 (图。S11, 黑线) 始终高于条件负对数似然, 且对完整三维结构的条件化将二级结构预测的损失降低到几乎为零 (1.4B: 0.24, 70亿: 0.19, 98B: 0.16)。与二级结构进行条件化相比, 序列条件化产生的结构预测损失较低 (98B; 序列: 3.13, 二级结构: 3.37)。我们观察到在每种条件化下, 预训练FLOPs与序列轨道的负对数似然之间存在明显的对数线性关系。

A.3.6. 无条件生成

为了评估模型的无条件生成能力, 我们从PDB中随机抽取了100个蛋白质长度, 并使用ESM3 98B以0.7的恒定温度生成了1,024条序列。抽样长度分布如图S13所示。每个序列的结构是使用ESM3 7B预测的, pTM和pLDDT的分布如图S13B所示。与仅使用固定掩码率在序列上进行简单MLM目标训练的ESM2相比, ESM3生成了更多高质量的结构。使用mmseqs2计算与训练集的序列相似性 (79), 其参数如下: `--cov-mode 2 -c 0.8 -s 6.0`。无条件生成的蛋白质与训练集中发现的蛋白质相似——但不完全相同 (图 S15) 并且对训练集具有很高的覆盖率 (图1E), 这证明模型已经正确拟合训练分布, 并未出现模式崩溃。我们观察到有一簇生成序列与训练集具有非常高的序列一致性; 这些序列对应于抗体序列, 框架区域导致了高序列一致性。

我们使用 pTM 来评估来自 ESM3 的结构预测, 而不是 pLDDT。这是因为 pLDDT 可能会对生成的结构进行错误校准, 并可能高估预测的信心。pLDDT 对局部结构信心存在偏倚, 这可能导致如非常长的 α -螺旋在所有位置具有高 pLDDT 的病理现象。pTM 是对结构信心的更全球性度量, 且对这些病理现象更加稳健。图。S12显示生成的序列的 pTM 与 pLDDT 相关性下降 (皮尔逊 r : 自然 = 0.85, 生成 = 0.79),

使用语言模型模拟五亿年的进化

模型	迭代 / $O(L^3)$			最大化 / $O(L^2)$		
	CAMEO	CASP14	CASP15	CAMEO	CASP14	CASP15
1.4B 开放	0.830	0.705	0.733	0.805	0.640	0.677
1.4B 过度训练	0.846	0.714	0.750	0.825	0.651	0.700
1.4B	0.807	0.693	0.697	0.775	0.608	0.636
7B	0.870	0.742	0.764	0.852	0.607	0.726
98B	0.895	0.763	0.801	0.884	0.719	0.770
ESMFold	0.865	0.728	0.735			
AlphaFold2	0.904	0.846	0.826			

表 S8. 蛋白质结构预测结果。我们基准测试 ESMFold、ESM3 模型和 AlphaFold2。左侧：基于序列的 ESM3 迭代推理结构标记。由于迭代推理的长度为 $O(L^3)$ 的蛋白质序列，因此它与 ESMFold 和 AF2 相当，二者的运行时复杂度相同。右侧面板：给定序列的单个最大结构标记。在所有情况下，数据集越困难，迭代解码似乎越能提供帮助——在 CASP14 上，98B 具有 +4.4 的 LDDT 增益，而在 CAMEO 上则为 +1.0 的 LDDT 增益。开放模型和过拟合模型均训练至 200k 步。1.4B 模型用于尺度比较，训练至 50k 步。

	模型	条件化				
		序列	结构	功能	SASA	二级结构
序列	1.4B	2.31	1.71	2.28	1.81	2.02
	7B	2.04	1.43	2.00	1.47	1.74
	98	1.84	1.21	1.76	1.21	1.50
结构	1.4B	4.09	4.98	4.93	4.39	4.42
	7B	3.42	4.2	4.18	3.62	3.71
	98	3.13	3.85	3.8	3.24	3.37
函数	1.4B	1.81	1.98	4.52	2.29	2.24
	7B	1.22	1.47	3.75	1.67	1.70
	98	0.93	1.20	3.63	1.41	1.40
SASA	1.4B	1.78	1.81	2.42	2.48	2.10
	7B	1.57	1.66	2.26	2.31	1.92
	98	1.46	1.56	2.15	2.23	1.82
二级结构	1.4B	0.42	0.24	0.70	0.50	0.83
	7B	0.31	0.19	0.57	0.31	0.6
	98	0.26	0.16	0.50	0.25	0.54

表 S9. 条件于其他轨迹的每个轨迹的负对数似然。每行是一个模型大小，生成特定的模态。每列是条件。对角线部分用斜体突出显示，则是每个轨迹的无条件 NLL。我们观察到，确实添加条件在所有情况下都改善了 NLL。




图 S11. 每个轨迹的条件和无条件缩放行为。损失在测试集上显示 (附录 A.3.2).

用语言模型模拟五亿年的进化




图 S12. pTM 和 pLDDT 的分布. 在 ESM3 70亿 结构预测下, 对自然 (左) 和生成 (右) 序列进行测量。生成序列显示出明显较低的相关性 (皮尔逊 $r = 0.79$ 对比 0.85) , 以及存在高 pLDDT 但低 pTM 的序列模式。自然序列来自测试集 (附录 A.33 982.) , 生成是来自 ESM B 的无条件生成。

并且出现高pLDDT (> 0.8) 但低pTM (< 0.6) 的明显模式。

为了可视化无条件生成的分布, 我们通过提取仅由序列输入运行 ESM3 70亿 产生的最后一层输出, 计算序列嵌入。蛋白质级嵌入通过对序列中的所有位置取平均来计算, 以产生一个2560维的嵌入。然后, 我们使用 UMAP 投影将这些嵌入投影到二维空间中 (96), 其适配于来自 UniProt 的 50,000 个随机抽样序列的背景分布, 最小距离为 0.1, 邻居数为 25。通过使用 Foldseek-cluster (使用默认参数) 计算结构集群并从每个集群中采样具有最高 ESM3 pTM 的示例, 选择示例。这些集群代表的子集在图中展示。1E。

为了评估ESM3是否偏向特定的二级结构, 我们使用 DSSP预测高置信度(pTM > 0.8 , 平均pLDDT > 0.8) 生成的三类二级结构, 并测量形成 α -螺旋和 β -折叠的残基百分比。与在PDB上计算的背景分布相比, 我们发现ESM3与已知蛋白质的二级结构分布高度匹配 (图S13D), 而其他方法则优先生成螺旋结构 (15, 26, 28)。最后, 为了确认ESM3预测的高置信度结构是可设计的, 我们使用ESM3 7B进行了逆折叠和重新折叠。大多数生成的结构成功重新折叠, TM-score大于0.8, 表明ESM3对其自身高置信度设计具有较高的自一致性 (图S13C)。

为了探索生成蛋白质的替代方法, 我们评估通过链式思维 (CoT) 程序生成的蛋白质质量, 在该程序中, ESM3 7B 生成二级结构 (SS8标记), 然后是三维骨架坐标 (结构标记), 最后生成氨基酸序列。

(序列标记) (图. S14). 我们将通过该CoT程序生成的氨基酸序列的质量与上述无条件直接生成氨基酸序列的方法进行比较。我们发现, CoT程序生成的序列在 pTM和平均pLDDT (图. S14A) 测量下, 具有比直接生成的序列更高的信心ESM3预测结构。与高信心 (pTM > 0.8 , 平均pLDDT > 0.8) 直接生成的序列相比, CoT生成序列的高信心子集也更易于设计: CoT生成的序列具有其逆折叠然后重新折叠的结构, 与最初预测的结构具有更高的TM评分 (图. S14C)。与直接生成的序列相比, CoT生成的序列在高 α 和 β 比例方面显示出小的偏向 (图. S14D)。

A.3.7. 响应式评估

为了评估 ESM 跟随提示的能力, 我们使用一组如附录中描述的保持不变的蛋白质A.3.2。测试集进一步过滤, 以去除长度大于 1024 的蛋白质, 这样从测试集中去除了 7 个蛋白质。为了构建结构坐标、二级结构和 SASA 跟踪的提示, 我们随机抽取原始蛋白质长度的 15% 的跨度。然后向模型展示相应的随机采样跨度的轨迹, 并要求其生成整条蛋白质的序列。例如, 对于结构轨迹, 对于长度为 100 的蛋白质, 我们可以从残基 20-35 中随机抽样 15 个残基的跨度。然后, 模型必须生成一个长度为 100 的蛋白质序列, 该序列基于来自原始测试蛋白质的残基 20-35 的结构坐标条件。对于二级结构和 SASA 跟踪也应用相同的程序。对于功能跟踪, 我们通过对与每个序列相关的 InterProScan 注释中的关键词进行标记化来形成提示。用于所有生成的 ESM3 7B 模型-

用语言模型模拟五亿年的进化




图 S13。使用 ESM3 无条件生成高质量和多样化的蛋白质。(A) 无条件生成数据集中序列长度的分布。(B) ESM3 的无条件生成与使用 3B-参数 ESM2 模型设计的序列相比的 pLDDT 和 pTM。(C) 使用 ESM3 的高可信度生成的往返成功率。预测的结构被逆向折叠以预测新序列, 然后重新折叠以生成新结构。成功通过原始设计与重新折叠设计之间的 TM-score 大于 0.8 来衡量。(D) 无条件生成的二级结构组成相对于 PDB 中蛋白质的分布, 以灰色显示。

使用语言模型模拟五亿年的演化




图 S14. 使用思维链生成序列。首先生成 SS8 标记, 其次生成结构标记, 最后使用 ESM3 7B 模型生成氨基酸序列。(A) 由思维链生成的序列的平均 pLDDT 和 pTM 的分布 (“SS8 优先”) 与直接生成序列 (“仅序列”) 相比。(B) SS8 标记的样本生成及其相应 CoT 序列预测结构。(C) 高置信度 (pTM > 0.8, 平均 pLDDT > 0.8) 生成序列的预测结构与其相应的逆折叠再折叠结构之间的 TM-score。(D) 高置信度生成序列的二级结构组成与 PDB 中蛋白质的分布进行比较。

在温度为0.7和 L 解码步骤下(其中 L 为序列长度)。模型为每个提示生成64个序列, 我们用其计算 pass@64。

为了评估生成结果, 我们使用ESMFold对由ESM3生成的序列进行折叠。对于结构坐标、二级结构和SASA轨迹, 对齐指标(主链cRMSD、三类二级结构准确性和SASA Spearman ρ) 可以通过在ESMFold预测的结构与原始模板蛋白之间的相关跨度计算得到。继续前面的示例, 对于结构轨迹, 我们将计算ESMFold预测的ESM3生成序列中残基20-35与原始测试蛋白中残基20-35之间的RMSD。对于功能注释轨迹, 我们在每个生成的序列上运行InterProScan (40), 并从发出的注释中提取功能关键词。我们报告在蛋白质层面上的功能关键词恢复, 计算提示中所有功能关键词与生成的InterProScan注释中的功能关键词的出现比例。

A.3.8. 可引导设计

为了测试ESM3在提示下超越其训练分布的泛化能力, 我们评估了两种提示场景。首先, 我们识别出在我们的训练截止日期(2020年十二月)之后被存储在PDB中的蛋白质, 并选择了八个 $TM < 0.7$ 与我们训练数据集中任意结构的相似性(PDB ID: 2JVN链A, 2KAF链A, 2L8K链A, 2MJM链A, 7ZUO链A, 8EXF链B)。使用DSSP, 我们计算了这些蛋白质的残基级SS8和SASA, 以提示ESM3, 同时屏蔽所有其他轨迹。我们在图S15A中展示生成的蛋白质具有多样性、球状性, 并与SS8和SASA提示密切相符, 同时在训练集中没有近似的序列或结构邻居。有趣的是, ESMFold对原始蛋白质序列的折叠信心或准确性并不高(平均pTM 0.44, 平均TM-score与参考值为0.33), 这表明这些蛋白质是折叠的挑战性目标。由ESM3生成的序列具有相似的信心(平均pTM 0.45), 但准确性更高(平均TM-score 0.64)。

其次, 我们使用 DSSP 对一组八个对称的蛋白质骨架进行残基级别的二级结构分类。这些蛋白质之前是使用 ESMFold 设计的 (5, 97) 并具有不同的二级结构 (α 和 β) 和不同的对称性 (5 重和 8 重)。再一次, ESM3 能够以高置信度成功设计这些蛋白质 (pTM > 0.8 , pLDDT > 0.8) 并与训练集的序列相似性较低, 如图。S15B。这些设计的结构相似性适中, 因为每个设计中的原型单元具有较高的结构保守性。所有设计均使用恒定的温度 0.7 生成,

$L/2$ 解码步骤, 其中 L 是蛋白质长度。我们为每个提示采样 256 条序列, 并通过 pTM (> 0.8), pLDDT (> 0.8) 和满足 SS8 提示的准确性 (SS8 准确性 > 0.8) 来过滤生成。最终示例通过视觉检查从这些过滤设计中选出。使用与无条件生成相同的程序计算与训练集的序列相似性, 并使用 Foldseek (41) 在 TM-score 模式下 (对齐类型 1) 计算结构相似性, 灵敏度设置为 $-s \ 7.5$ 。

A.3.9. 编写提示

ESM3能够在其输入轨道上编写多模态提示——序列、结构、SS8、SASA和功能关键词——以生成具有新特征的蛋白质。为了证明这一点, 我们通过额外的条件增强标准功能基序支架任务(即部分结构和序列提示), 以指定供ESM3设计的支架类型。功能位点包括由序列中远程的残基协调的配体结合位点的组合以及由短局部基序定义的位点。对于每个基序, 来自参考PDB结构的所有残基的坐标和氨基酸身份被输入到模型中, 同时随机打乱和增强每个活性位点之间的间隙。请参见附录A.4.5以获取此增强过程的描述及所选配体结合位点的规格。除了这些位点外, 我们还创建了一组由保守功能基序衍生的12个部分序列和结构提示(表S10)。这些基序是使用Watson et al. (26)中的基准数据集和来自Prosit数据库的保守序列模式 (98) 的组合来定义的。

支架条件的定义采用SS8标记(用于指定二级结构组成)或由InterPro获取编号定义的函数关键词(用于指定特定的折叠)。对于每个功能位点和支架提示的组合, 我们在256到2048次之间进行采样, 以生成具有多样化和新颖特征的蛋白质。所有设计均使用7B-参数模型生成, 温度保持在0.7, 并且 $L/2$ 为长度为 L 的蛋白质进行解码步骤。

二级结构提示。我们生成了四种主要二级结构组成的蛋白质: 主要是 α -螺旋, 主要是 β -折叠, 以及混合的 α - β 蛋白质(分为 α/β 、 $\alpha/\beta/\alpha$ 和 $\beta/\alpha/\beta$ 拓扑)。对于每一次生成, 我们使用一组随机的SS8范围来提示模型, 直到总长度 L , 中间插入掩码标记。例如, 一个针对长度为 $L=20$ 的蛋白质的全 α SS8提示可能看起来像——HHHH——HHHHH——HH, 而一个 β - α - β 提示可能看起来像——EEE——HHHHH——EE, 其中H是 α -螺旋中的残基, E是 β -折叠中的残基。

使用语言模型模拟五亿年的进化




图 S15. 提示 ESM3 超越其训练分布的泛化能力。(A) 使用来自 PDB 的与训练集结构相似度较低的近期结构所衍生的 SS8 和 SASA 提示设计的蛋白质。沿蛋白质长度的提示在每次生成上方可视化; 二级结构使用三类 (α = 蓝色, β = 橙色, 卷曲 = 灰色) 表示, SASA 以线图形式显示, 颜色由残基索引匹配下方的漫画图。(B) 使用 SS8 提示设计的对称蛋白质。直方图显示与最近的训练集蛋白质在结构 (TM-score) 和序列 (一致性) 上的相似性, 相较于无条件生成。

	基序 PDB ID	链 ID	PDB 残基标识符
ACE2 结合	6vw1	A	19-89, 319-366
铁氧还蛋白	6e6r	A	1-44
Barstar结合	7mrx	B	25-47
P53结合	1ycr	B	19-28
PD-1结合	5ius	A	63-83, 119-141
DNA结合螺旋转弯螺旋	1lcc	A	1-52
P环	5ze9	A	229-243
双EF手	1a2x	A	103-115, 139-152
乳酸脱氢酶	1ldb	A	186-206
肾脏二肽酶	1itu	A	124-147
泛素激活酶E1C结合	1yov	B	213-223
DNA拓扑异构酶	1a4l	A	248-280

表S10. 保守区域的功能基序定义。

链。然后, 我们将其与由功能位点模体提供的增强部分结构和序列轨迹相结合。为了提高支架的多样性并最大化生成物理可实现的提示组合的概率, 我们为每个SS8和功能位点模体的组合生成256到1024个设计。对于每次生成, 我们均匀地从150到400之间随机抽取一个长度 L 。接着, 我们生成一组长度为5-20个残基的二级结构区间, 每个区间之间相隔3-10个残基, 使得总长度加起来为 L 。最后, 为了避免部分结构和二级结构约束之间的不兼容性, 我们还会掩蔽在功能位点提示所指定的结构位置处的SS8标记。通过对设计的序列运行DSSP并测量被提示的残基分配到正确的二级结构的比例来评估二级结构提示的设计。成功的判定基于 $pTM > 0.8$ 、全原子cRMSD < 1.5 与功能位点的匹配, 以及SS8准确率 > 0.8 。

关键词提示。为了提示模型生成具有特定折叠的蛋白质, 我们提取了与来自测试集的一组蛋白质相关联的InterPro标签, 这些蛋白质的ESM3关键字恢复率超过了80% (图. 2A)。随后将这些标签转换为关键词, 并与部分序列和结构约束结合使用, 提示模型。提示和功能标签的列表见表S11。关键词提示的设计通过自我一致性评估来进行评估, 即模型是否成功预测为设计序列所提示的任何InterPro访问号。成功的标准是 $pTM > 0.8$, 所有原子cRMSD < 2.0 , 以及恢复的InterPro访问号的数量 > 0 。

我们通过测量生成的支架与源自该模体的链之间的TM-score来评估每个模体-支架组合的新颖性 (表S12)。这确认模型并未检索原始模体支架, 特别是在二级结构提示的支架中, 我们并未提供任何显式指令以产生多样化的设计。对于源自配体结合残基 (镁、血清素、钙、锌、蛋白酶抑制剂017和Mcl-1抑制剂YLT) 的模体, 我们另外使用Foldseek在PDB中搜索任何共享该模体的其他蛋白质 (如BioLiP所定义 (99)), 作为对新颖性的更严格评估。除了锌结合和镁结合模体外, Foldseek在1.0的E值阈值下未发现显著的命中。对于锌和镁发现的命中仅有适度的TM-score (0.76和0.64), 表明模型仍然为这些配体找到新颖的支架解决方案。为了评估生成的支架是否可能是可设计的, 我们通过逆折叠计算模型下测量自一致TM-score (scTM)。

使用 ESM-IF1 的签名结构 (42) (使用温度 0。

5) 和使用ESMFold进行重新折叠 (5)。我们在表中报告了8个反向折叠设计中的最佳scTMS12。

A.3.10. 多模态编辑示例

首先, 我们描述生成图中所示蛋白质压缩示例的过程。2D。构建了一系列长度为150的提示。催化三联体胰蛋白酶 (PDB 1Y3V) 的序列和结构 (H57、D102、S195) 通过如下程序放置在提示中: 随机抽取20到130之间的三个残基编号, 确保每个残基之间的最小位置差异不小于20。然后, 将模板胰蛋白酶中的H57放置在最低抽取的编号处, D102放置在第二低的编号处, S195放置在最大编号处, 从而遵循模板胰蛋白酶中催化三联体的从左到右的顺序。通过此过程生成了128个提示。每个提示与源自模板蛋白的函数关键词提示相结合, 具体为InterPro (40) 标签IPR001254 (丝氨酸蛋白酶, 胰蛋白酶域) 和IPR009003 (肽酶S1, PA类), 以得出最终的128个提示集。然后, 基础的ESM 7B模型被提示生成其余147个残基的序列, 这些残基的序列是以随机放置的催化三联体序列和结构坐标以及函数关键词为条件生成的。 $L = 150$ 解码步骤的温度设置为0.7, 每个提示生成32个样本。随后, 通过所有原子RMSD、提示位置、ESM3 pTM和InterPro Scan关键词输出对生成结果进行了过滤, 最终通过目视检查选取了图中所示的生成结果。2D。

生成质量是通过使用ESMFold (5) 生成序列的pTM进行测量的, 此外还考虑自一致性。对于自一致性, 我们使用ESM-IF1反折叠生成的ESM3预测结构 (42) 8次, 并使用ESMFold重新折叠, 报告8个ESMFold预测结构与ESM3预测结构之间的TM-score的平均值和标准差。为了执行序列的比对搜索, 我们使用标准的蛋白质比对搜索 (54)。我们将最大目标序列参数设置为5000, 并根据序列长度和序列一致性对结果进行排序, 选择第一个为丝氨酸蛋白酶的序列。这得到了参考WP 260327207, 其序列长度为164个残基, 并与生成物具有33%的序列一致性。

我们展示两个进一步的蛋白质编辑示例。首先, ESM3被提示将一个暴露的螺旋埋入一个具有交替的阿尔法-贝塔三明治折叠的蛋白质中。提示的构造如下: 提示的长度与模板蛋白 (PDB 1LBS) 相同。我们识别模板蛋白中残基106-116之间的一个埋藏螺旋 (平均SASA 0.32 $^{\circ}\text{A}^2$)。该区域的结构坐标为

使用语言模型模拟五亿年的进化

支架	参考	InterPro 标签	序列长度
β -螺旋	8siuA	IPR001680 (1-350)	353
		IPR036322 (1-350)	
		IPR015943 (1-350)	
TIM桶	7rpnA	IPR000652 (0-248)	252
		IPR020861 (164-175)	
		IPR035990 (0-249)	
		IPR013785 (0-251)	
		IPR000652 (2-249)	
MFS 转运蛋白	4ikvA	IPR022896 (1-249)	380
		IPR011701 (1-380)	
		IPR020846 (1-380)	
免疫球蛋白	7sbdH	IPR036259 (1-380)	209
		IPR036179 (0-116; 124-199)	
		IPR013783 (0-206)	
		IPR003597 (124-202)	
		IPR007110 (0-115; 121-207)	
组氨酸激酶	8dvqA	IPR003599 (6-115)	166
		IPR013106 (11-114)	
		IPR003594 (47-156)	
		IPR003594 (47-158)	
		IPR004358 (118-137)	
		IPR004358 (141-155)	
		IPR004358 (101-112)	
α/β 水解酶	7yiiA	IPR005467 (0-158)	276
		IPR036890 (4-159)	
		IPR036890 (3-156)	

表 S11. 从CAMEO测试集蛋白质中提取的InterPro标签, 用于折叠规格的提示。

位点	支架	新颖性 (TM与原始的比较)	可设计性 (scTM)
017	β	0.264	0.967
ACE2	α	0.606	0.871
CA	免疫球蛋白	0.441	0.781
双EF手	ab水解酶	0.293	0.969
MG	TIM桶	0.328	0.980
肾二肽酶	阿尔法-贝塔-阿尔法	0.644	0.933
SRO	mfs转运蛋白	0.345	0.992
拓扑异构酶	组氨酸激酶	0.269	0.948
YLT	阿尔法-贝塔	0.229	0.899
ZN	α	0.567	0.996

表 S12. 新颖性和可设计性指标。在图样中显示的支架的指标。2C. 新颖性通过计算与原始支架的 TM-score 来衡量, 原始支架是从中派生出该图样的。可设计性根据八个样本的自一致性 TM-score, 通过与 ESM-IF1 的反向折叠及与 ESMFold 的重新折叠来衡量。所有设计均与其原始支架不同, 同时保持高度的可设计性。

在提示中放置在相同的残基索引位置, 以提示ESM3生成相同的螺旋。这是与每个11个螺旋残基的40.0的SASA提示组合而成的, 提示ESM3将此螺旋放置在蛋白质的表面上。最后, 我们用围绕埋藏的螺旋(残基33-36、62-65、99-103、125-130和179-182)的5个中心 β 链的二级结构进行提示。然后使用ESM3 70亿生成基于此提示的512个蛋白质序列, 使用 L_2 解码步骤和0.7的温度。设计通过ESM3 pTM和对SASA提示的遵循进行过滤。最终生成通过目视检查进行选择。生成的评估如上所述(ESMFold pTM 0.71, scTM平均值0.82, 标准差0.045)。检查生成的结果, ESM3能够满足输入约束: 生成的蛋白质保持螺旋的结构(主链cRMSD 0.18 Å)和交替的 α - β 折叠(生成和模板都有7个链与螺旋交替), 同时将螺旋模体暴露于表面(平均SASA 28.35 Å²)。此外, 生成在结构上是独特的: Foldseek搜索(41)在TM-align模式下对AlphaFold-DB、ESMAtlas和PDB进行的检查未发现TM-score大于0.76的命中。

我们还使用ESM3生成具有11重对称性的理想化TIM桶。此生成分为两个步骤进行。首先, 我们从参考TIM桶(PDB 5EKY)派生出二级结构和功能关键词提示。参考蛋白质的二级结构使用DSSP计算, 然后被理想化以构建ESM3的提示。为了构建二级结构提示, 每个螺旋和链的长度固定为7个残基。然后每个螺旋和链区域之间用3个掩膜标记分隔, 同时在提示的N端和C端也附加一个掩膜标记。这产生的二级结构提示总长度为159, 与从参考蛋白质派生的功能关键词提示结合: 关键词来自IPR013785(醛缩酶型TIM桶)和IPR000887(KDPG/KHG醛缩酶)。随后使用ESM3 7B生成256个样本, 解码步骤为 L , 温度为0.7。所示设计通过ESM3 pTM筛选和目视检查进行选择。在第二步中, 第一步的二级结构提示扩展为包含11个螺旋-链亚单元, 提示总长度为225个残基(现在在N端和C端附加了4个掩膜标记, 而不仅仅是1个)。随后使用ESM3 7B生成256个样本, 解码步骤为 L , 温度为0.7, 生成的结果通过ESM3 pTM筛选和目视检查进行筛选。生成的结果如上述所述进行评估(ESMFold pTM 0.69, scTM均值0.97, 标准差0.011)。生成的结构上是独特的: Foldseek搜索。

(41)的AlphaFold-DB、ESMAtlas和PDB在TM-align模式下未能发现TM-score大于.61的匹配。

A.4. 对齐

A.4.1. 算法

自从引入 RLHF (44) 以来, 已经开发出多个算法来调整通过无监督学习训练的大型模型, 以更好地遵循指令, 并普遍使其生成与用户偏好对齐 (45, 46, 100, 101)。我们使用 IRPO (迭代推理偏好优化), 因为其实简单且表现良好。IRPO 损失将监督微调与来自偏好对的对比学习相结合。IRPO 在一个数据集上操作 $\mathcal{D} \sim (y_w, y_l, x)$, 该数据集由提示 x 和一对完成 y_w (优选) 和 y_l (非优选) 组成。它还在两个独立的模型上运行: 参考模型 π_{ref} 和当前模型 π_{θ} 。参考模型 π_{ref} 是相同规模的固定基本模型, 而当前模型 π_{θ} 是正在优化的模型。

$$\begin{aligned} \mathcal{L}_{\text{IRPO}}(\pi_{\theta}; \pi_{\text{ref}}) = & \mathcal{L}_{\text{NLL}} + \alpha \mathcal{L}_{\text{DPO}} = \\ & - \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\frac{\log \pi_{\theta}(y_w | x)}{|y_w| + |x|} + \right. \\ & \left. \alpha \log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right] \quad (2) \end{aligned}$$

IRPO损失包含两个项。 $\mathcal{L}_{\text{NLL}}$ 该项最大化经过序列长度归一化的优选示例的对数似然, 为模型提供强化良好生成的信号。该 $\mathcal{L}_{\text{DPO}}$ 项为对比优先调优项, 它增加了优选与非优选示例之间对数似然的差异, 同时保持与参考模型的接近程度 (45)。使用参考模型作为正则化器, 防止对偏好数据集过拟合, 而偏好数据集通常较小。有两个超参数, α 和 β 。 α 的权重控制监督损失与偏好损失的相对重要性, 而 β 参数则控制我们与参考模型的接近程度: β 越高, 我们就越接近。我们通过当前模型参数最小化该损失。 θ 。

ESM3是一个多模态模型, 因此提示可以是(部分)序列、结构和功能的输入轨道的任意组合, 而生成的 y 可以是任何输出轨道。在我们的实验中, 我们始终生成氨基酸序列, 因此从现在开始, 这将是我们的示例。由于氨基酸序列 y 可以通过多种多步骤方式从提示 x 生成, 因此计算完整的似然 $\pi(y|x)$ 将涉及对所有可能的多步骤解码路径进行积分。由于这一计算是不可行的, 我们使用一个替代方法, 反映了预训练, 如公式 (3) 所示, 下文进行描述。

$$\log \pi(y|x) \approx \mathbb{E}_m \left[\sum_{i \in m} \log p(y_i | y_{\setminus m}, x) \right] \quad (3)$$

使用语言模型模拟五亿年的进化




图 S16. 使用 ESM3 的多模态蛋白质编辑。(A) ESM3 在保持蛋白质交替的阿尔法-贝塔三明治折叠结构的同时, 暴露了蛋白质中一个埋藏的螺旋。(B) ESM3 在迭代编辑中使用, 首先通过二级结构提示和功能提示对参考 TIM 桶进行理想化。然后使用二级结构提示将 TIM 桶中的亚单位数量从 8 增加到 11。

为近似从提示 x 生成 y 的可能性, 我们使用从线性噪声调度中抽样得到的掩码对 y 进行掩膜处理, 使用提示 ESM3 与 $\{y_{\setminus m}, x\}$, 并计算掩膜位置的 ESM3 逻辑值的交叉熵。

y . 在训练期间, 使用相同的掩码来计算参考策略与当前策略的可能性, 以及首选样本与非首选样本的可能性。

A.4.2. 偏好调整直觉

重新排列损失函数中的 DPO 项为模型的偏好对提供了一些见解。

$$\mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [-\log \sigma(-\beta z_{\theta}(x, y_l, y_w))] \quad (4)$$

其中

$$\begin{aligned} z_{\theta}(x, y_l, y_w) &= \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} - \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} \\ &= \log \frac{\pi_{\text{ref}}(y_w|x)}{\pi_{\text{ref}}(y_l|x)} - \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\theta}(y_l|x)} \end{aligned}$$

函数 $f(z) = -\log \sigma(-\beta z) = \log(1 + \exp(\beta z))$ 是 softplus 函数, 并且是铰链函数的近似; 换句话说 $f(z) = \beta z$ 当 $z \gg 0$ 和 $f(z) = 0$ 当 $z \ll 0$ 。由于这一特性, 有两种情况。在其中一种情况下

$$\log \frac{\pi_{\text{ref}}(y_w|x)}{\pi_{\text{ref}}(y_l|x)} \gg \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\theta}(y_l|x)} \quad (5)$$

$f(z)$ 位于线性区域, 因此损失函数仅仅是最大化似然比 $\log \frac{\pi_{\theta}(y_w|x)}{\pi_{\theta}(y_l|x)}$ 。在此情况下

其中

$$\log \frac{\pi_{\text{ref}}(y_w|x)}{\pi_{\text{ref}}(y_l|x)} \ll \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\theta}(y_l|x)} \quad (6)$$

损失已经饱和。这确保我们不会偏离参考模型过远。

这些动态在 ESM3 微调的情况下同样适用。尽管我们使用的是替代品而不是实际的似然, 但损失将会增加优选对的替代品, 相对于非优选对, 直到当前模型过于偏离参考模型。

A.4.3. 评估指标

偏好调优中可能最重要的部分是如何将生成的结果分隔成优选对。生成的目标是质量和正确性。质量是指序列作为稳定蛋白质的可行性。正确性是指它遵循给定提示的程度; 也称为提示一致性。本节仅涉及结构坐标提示, 因此可以通过约束位点 RMSD (cRMSD) 来衡量提示一致性, cRMSD 是提示的主链坐标与生成序列的预测结构中相应坐标之间的 RMSD。序列质量可以通过生成序列的结构预测器的预测-TM (pTM) 来衡量。

与任何度量一样, 尤其是作为结构预测器的替代指标, 存在过度优化的风险: 模型不断提高特定度量, 例如在我们的案例中 pTM, 但实际关注的属性, 即序列作为稳定蛋白质的可行性, 停止与该度量相关 (102)。使用正交模型

对我们的训练数据集进行排序与执行评估有助于缓解这一问题。

为了创建训练数据集, 生成物根据ESM3 7B的主链cRMSD和pTM进行评估, 以维持所有数据集中一致的结构预测器。在偏好调优阶段之后, 从调优模型中生成的物使用ESMFold主链cRMSD和pTM作为正交模型进行评估。使用ESM3评分的偏好对进行训练, 同时使用ESMFold进行评估, 提供了更为客观的评估。

A.4.4. 训练数据集

所有ESM3模型的规模均使用IRPO损失 (公式 (2)) 在各自预构建的训练数据集上进行训练, 该数据集由结构坐标提示和生成物组成。每个数据集包含来自各自ESM3模型的30,000个提示的16个生成物。通过指标的阈值来确定偏好选择。如果样本的ESM3 7BpTM > 0.8 和主链cRMSD 与其结构提示 < 1.5 °A.被认为是“良好”的。

每个“好”样本与一个“坏”样本配对以创建偏好对。我们发现强制在配对生成的度量之间保持间隔可以提高结果, 因此, 要符合“坏”样本的标准, 生成必须具有 $\Delta pTM = pTM_{good} - pTM_{bad} \geq 0.2$ 和 $\Delta backbone\ cRMSD = cRMSD_{good} - cRMSD_{bad} < -2^\circ A$ 。每个提示可以具有多个偏好对, 而没有有效偏好对的提示将被丢弃。

结构提示由我们预训练管道中改编的各种蛋白质构成。50% 的提示为合成活性位点, 而另 50% 的提示为随机掩蔽的结构坐标, 掩蔽方式采用噪声调度。所有结构提示均来源于在 2020年5月1日之前的 PDB 结构。

合成活性位点是通过从具有协调残基的 PDB 中找到序列而获得的。对于这些结构, 氨基酸的身份也包含在提示中。

剩余的结构轨迹提示根据余弦噪声调度进行掩蔽。50%的噪声调度提示在完全随机的位置被掩蔽, 另 50%的提示根据优先选择顺序掩蔽的位置的自相关机制进行掩蔽。

每个模型的训练数据集由其自身参考模型的生成组成。对于每个提示, 我们使用具有 $L/4$ 步的迭代解码从相应的ESM3模型规模生成样本, 其中 L 是提示的长度。我们在解码步骤中将温度从1.0退火到0.5。

A.4. 5. 评估数据集: 三级协调三级协调任务需要生成满足具有挑战性的三级相互作用约束的蛋白质。模型根据一组在三维空间中接近但在序列上相距较远的残基的序列和坐标进行提示。为了评估在这些任务上的表现, 我们从Biolip数据集中挑选包含46个具有配体结合位点的蛋白质数据集 (99)。所有选定的蛋白质在训练集截止日期 (2020年12月1日) 之后已被存放在PDB中。提供给模型的协调残基来自Biolip数据集中定义的配体结合位点 (表S13)。ESM3根据特定配体结合位点的残基的序列和坐标进行提示。我们要求ESM3通过对提示应用多重变换生成新结构。总序列长度均匀地采样为150、250或350个残基 (与原序列长度无关)。接下来, 我们定义为提示残基的连续协同残基跨度, 在其间少于5个序列位置。连续残基跨度的顺序和距离被打乱。这保证了例如, 原始蛋白质将不再满足提示。我们认为生成成功如果主链 $cRMSD < 1.5^\circ A$ 和 $pTM > 0.8$ 。我们为每个配体构建总共1024个提示, 并使用我们正在评估的模型为每个提示生成一个完成结果。我们报告Pass@128, 它是对每个配体在128个提示后至少有一个成功完成的配体比例的估计。我们使用无偏估计器 (Chen et al. (103), 第3页) 根据1024个提示的成功率进行估计。我们在图S18中可视化随机选择的成功生成, 适用于基础模型和微调模型。

A.4. 6. 监督微调为了评估偏好调优的价值, 我们还训练了一个监督微调 (SFT) 的基线, 在此基线上我们微调模型以提高高质量样本的似然性, 而不使用偏好调优损失。1.4B、70亿和98B模型在128次生成中分别解决了14.2%、33.7%和44.6%的第三协调任务, 这一结果相比基础模型有所改善, 但仍远低于相应的偏好调优版本。

A.4. 7. 训练超参数每个IRPO模型使用RMSPProp训练1000步。学习率分别为1e-5、1e-5和5e-6, 适用于1.4B、70亿和98B模型, 在经过150步预热后使用余弦调度进行逐步降低。梯度范数被剪切到1.0。

使用语言模型模拟五亿年的进化

PDB ID	协调残基	配体 ID
7map	D25 G27 A28 D29 D30 G48 G49 V50	017
7n3u	I305 F310 V313 A326 K328 N376 C379 G382 D386 F433	05J
7exd	D103 I104 C107 T108 I174 H176 T182 W306 F309 E313 Y337	05X
8gxp	W317 C320 A321 H323 V376 F377 序列长度396 I400 H479 Y502	06L
7n4z	M66 C67 R124 序列长度130 C134 Y135 D152 F155	08N
7vrd	A40 S41 H161 Q169 E170 E213 D248 D324 K349 H377 R378 S379 K400	2PG
7zyk	V53 V66 V116 H160 N161 I174 D175	ADP
6yj7	K23 V24 A25 Y45 T46 A47 F115 I128	AMP
8ppb	H185 F198 K209 Q249 D250 序列长度 L251 D262 K336 I415 D416	ATP
7knv	E33 F94 E95 D125	CA
7xer	Y466 L505 T525	CLR
7tj6	F366 G367 T378 R418	CMP
6xm7	H167 H218 H284 H476	CO
70lZfr	Q62 X126 H248	CO3
6xlr	X272 Y495 H496 H581	CU
6tnh	N40 A41 S127 T128 Q187 序列长度191 C201 T202 V236	DGP
7ndr	F73 S101 F102 D103 R106	EDO
8axy	H68 H109 E144	FE
7o6c	E62 E107 Q141	FE2
8aul	P31 M32 T33 Q106 H185 R237 S319 G320 G321 G342 R343 F369 Y370	FMN
7vcp	N37 D38 Q54 函数97 S98 R159 D160 E214 Y276 W297	FRU
70lZ7f	G167 T168 G189 W195	FUC
8d0w	F73 序列长度136 E137 F329	GAL
7yua	T13 T14 I15 D40 H85 S86 D87 D110 N290	GDP
7w1a	L44 Y88 L91 I212	GMP
7ljn	G71 S72 D91 K236 S253 V254 D309 R310	GTP
6s4f	Y84 N87 K88 V131 Q132 序列长度133 D155 f157 I276 P309 G310 G313 P314 V317	KUN
7mg7	Y12 G98 序列长度99 Y100 A207 D208 G227 R228	MAN
7qow	D12 T118 E268	MG
7dmm	E181 E217 D245 D287	MN
7qoz	G11 G12 I13 Y34 D35 V36 A86 G87 V126 T127 N128 H185 M235	NAD
7v2r	G89 F93 K98 F101 E121 Y204 E209 F229	NAI
7a7b	F51 Y128 K165 N166 S167 Y186 R187 I248 G249 A299	NAP
7pae	M20 序列长度22 序列长度38 V49 I53 C56 K57 R61 Q78 V80 W90 I109 M117 I129 序列长度147 Y149	O7T
8egy	H82 K83 S186 G230 S231 N232 E345 S368 G369	PLP
7qow	S65 R129 D273 H465	PO4
7wmk	E77 序列长度124 R129 S174 T189 Q191 W241 D304 E306 K349 D410 W411 Y486	PQQ
7pl9	D607 A608 Y637 M638 Y705 G706 M735 K736	RET
7yf2	G153 E174 序列长度 L209 N210 L211 Y295	SAH
7v6j	G207 D230 序列长度 D250 M251 K264	SAM
7ys6	D106 C110 N288	SRO
6w8m	A22 A23 G70 S110 T111 G112 V113 Y114	TJY
8g27	S258 D294 K435 R717	用户数据报协议
7xyk	R24 C170 R190 S191 D193 N201 H231 Y233	UMP
8g3s	H224 F228 V249 M250 V253 R263 T266 序列长度267 F270	YLT
8it9	T92 P93 R96 Y108 序列长度109 K216 V228 S229 H231 H232	ZL6

表 S13. 三级协调数据集。每个蛋白质样本的已选 PDB 和协调残基（连同结合配体）在三级协调数据集中。

对于所有的IRPO运行 $\beta = 0.05$ 和{name}。SFT基线使用相同的超参数, 但 $\alpha = 0.0$ 以忽略偏好调优项。

A.5. 绿荧光蛋白

ESM3生成了一个暗淡的远程GFP, B8, 以及一个明亮的远程蛋白质, esmGFP。以下提供了关于计算方法、实验协议、结果和实验后分析的详细信息。

A.5.1. 生成和选择

基础的ESM3 7B模型利用单个提示及通过序列和结构标记的思维链生成用于实验室测试的候选GFP设计。候选者在多个步骤中通过指标进行筛选和排序。实验1 测试候选者在与模板的序列一致性范围内, 产生多个GFP, 包括暗淡的命中B8。实验2包含以B8的序列开始思维链的设计, 产生多个明亮的GFP, 包括我们称之为esmGFP的C10。本节详细阐述了生成和选择实验1和实验2候选GFP设计的计算协议, 如图4B。协议、指标和选择惯例将单独介绍, 然后在两项实验的描述中进行综合, 位于本节的末尾。

A.5.1.1. 模型

所有候选 GFP 设计均使用基础的 ESM3 7B 模型创建, 无需微调。在生成过程中, 模型被防止解码半胱氨酸残基。

A.5.1.2. P提示在实验1中, 所有候选 GFP 设计都是以由单一提示开始的思考链产生的。提示的目标是捕捉颜色基团形成和荧光所需的基本残基身份和结构特征, 同时为模型生成多样化设计留下其他自由度。模板为此, 我们使用从模板蛋白中提取的16个残基在色团形成位点附近的最少序列和结构信息对 ESM3 提出提示。我们选择来自 (53) 的预环化中间晶体结构, PDB ID 1QY3, 作为我们的模板。我们在1QY3中反转色团成熟减缓突变 R96A, 使提示包含 Arg96。随后, 我们将带有突变 A96R 的1QY3的完整序列和结构称为1QY3 A96R 或模板。序列提示我们提示的序列部分由7个模板残基组成: Met1、Thr62、Thr65、Tyr66、Gly67、Arg96 和 Glu222。残基 65-67 形成色团。Met1 确保适当的起始密码子位置。残基 62、96 和 222 在 (53) 和其他文献中被描述为在色团形成中发挥关键催化作用。

用语言模型模拟五亿年的进化




图 S17. 对齐改善模型生成。来自98B基础模型和对齐模型的pTM、主链cRMSD分布, 用于三级协调数据集中所有配体的生成。每个配体/模型对拥有1024个生成。

使用语言模型模拟五亿年的进化




图 S18. 从基础和微调的98B参数模型随机选择的成功生成。选择随机样本的配体, 并用真实值PDB链进行可视化, 该链是配体所取自的。ESM3产生的解决方案多样化, 微调模型在1024个总样本中显著提供了更多成功。

使用语言模型模拟五亿年的进化

结构提示我们提示的结构部分由结构标记和来自位置 96、222以及58-71 (包括) 的16个模板残基的主链原子坐标组成, 这大致捕捉了中心 α 螺旋。已知中心 α 螺旋的独特几何形状对色团形成至关重要 (53)。

提示中所有其他位置和轨迹均被屏蔽。整体提示长度为229, 与模板一致。残基索引连续, 并从1开始。

A.5.1.3. 联合序列结构优化

我们采用以下程序在实验过程中联合优化设计的序列和结构: 在温度从1线性退火到0的过程中, 我们进行多次迭代, 首先预测设计序列的结构, 然后针对该预测结构对序列中的每个位置进行吉布斯采样。其算法形式为:

算法15吉布斯

输入: ESM3 f , 序列 $x \in \{0..20\}^L$, 结构 y , 温度 t
1: 对 $i = \text{shuffle}(\{1, \dots, L\})$ 做 2: $x_i \sim \exp(\log f(x_i | x_{\setminus i}, y)/t)$ 3: 结束循环 4: 返回 x

算法16联合_1

输入: ESM3 f , 初始序列 x_1 , 迭代 I , 初始温度 t_1 , 最终温度 t_f 1: 对于 $i = 1, \dots, I$ 做 2: $t_i = (t_f - t_1)$

· $(i/(I-1)) + t_1$ 3: $y_i = \text{生成}_{struct}(f, x_i, \text{len}(x_i) - 1, T = 0)$ 4: $x_{i+1} = \text{吉布斯}_{序列_给定_结构}(f, x_i, y_i, t_i)$ 5: 结束循环 6: 返回 x_{I+1}

在联合_优化的实验中, 采用了吉布斯_序列_给定_结构的三种变体用于实验1和实验2。联合优化在温度回火至低值时, 偶尔会产生重复的氨基酸序列。变体1和变体2旨在通过不同方式解决此问题。变体3则是通过已知的自然绿荧光蛋白的PSSM来偏置逻辑值的实验。实验2中的一半候选者是使用变体3生成的, 而这一半不包括esmGFP。

1. 变体1: 负局部序列引导 我们将模型的逻辑值偏离那些产生的值

仅从序列的高度局部范围。具体来说, 我们使用无分类器引导 (104):

$$\text{logits}' = \text{weight} * (\text{logits}_{\text{cond}} - \text{logits}_{\text{uncond}}) + \text{logits}_{\text{uncond}}$$

但是, 对于通过输入仅以被采样位置为中心的 7 个残基, 权重为 2 而不使用其他任何内容所产生的逻辑值, 进行推开处理。所有其他序列位置和所有其他模型输入均留为空白。

$$\text{logits}' = 2 * (\text{logits}_{\text{cond}} - \text{logits}_{\text{local_seq}}) + \text{logits}_{\text{local_seq}}$$

2. 变体 2: 最大解码熵阈值 我们可选地跳过吉布斯采样中在其序列标记的熵超过用户指定阈值的位置的序列重采样。
3. 变体 3: PSSM 偏置 在实验 2 中, 我们实验性地包括和排除在吉布斯序列采样期间基于 PSSM 的偏置。具体来说, 我们从 71 个自然绿荧光蛋白中构建了一个 PSSM (详见附录 A.5.1.4), 并直接将其添加到模型的序列输出逻辑值中, 使用用户指定的权重。esmGFP 不使用此选项; 它的权重为 0。

A.5.1.4. 度量

GFP 设计是通过多个 ESM3 派生和独立度量生成和评分的。除非另行说明, 否则设计的结构是使用 ESM3 仅以序列作为输入进行预测的, 采用温度为 0 的结构标记的迭代解码, 以及使用较旧版本的结构标记解码器对主链坐标进行后续解码。

以下是使用的指标的详尽清单。有关特定指标使用的确切细分, 可以在附录 A.5.1.5、附录 A.5.1.6 和附录 A.5.1.7 中找到。

模板色素位点RMSD 通过对位于预测结构和模板 (晶体) 结构中的位置62、65、66、67、96和222的 N、C、CA和推断的CB原子的最佳对齐 (105) 进行计算。

模板螺旋RMSD以相同的方式计算, 但仅限于设计和模板位置58-71 (含)。

1EMA螺旋RMSD 是 (106) 中提出的一个指标。RMSD是在预测设计结构和avGFP的特定晶体结构之间的 α 螺旋残基之间计算的, PDB ID1EMA。我们的计算与 (106) 略有不同。我们计算 RMSD为

使用语言模型模拟五亿年的进化

N、C、CA 和推断的 O 原子, 仅考虑位置 60-64 和 68-74 (两个范围均包括在内), 以排除发色团位置 65-67。

序列伪困惑度的计算方法如定义所示

(107)。给定一个蛋白质序列, 逐个位置进行掩蔽, 掩蔽位置的输入标记的负对数似然值在序列的所有位置上平均, 结果被指数化。往返困惑度 是通过预测其结构并使用 ESM3 评估该序列在给定预测结构下的困惑度而计算得出的, 在 ESM3 的单次前向传递过程中进行评估。N-gram得分 的计算方法为 E_{ngram} 中定义的项

(11)。该得分评估设计序列中残基的 N-gram 频率与背景分布中发现的频率之间的差异, 该背景分布源自 UniRef50 2018 03。具体而言, 对于函数 ngram_i , 该函数接收一个序列 x 和一个 N-gram 顺序 i 以及一个预先计算的背景 N-gram 频率分布 $\text{ngram}_{i, \text{bg}}$, 得分计算如下:

$$E_{\text{ngram}} = \sum_{i \in \{1, 2, 3\}} D_{KL}(\text{ngram}_i(x), \text{ngram}_{i, \text{bg}}) \quad (7)$$

PSSM 位置特异性得分矩阵 (PSSM) 是通过将 71 个自然绿荧光蛋白 (108) 的 MSA 构建而成的。具体而言, 在与我们的模板对齐的位置上, 20 种经典氨基酸 (不包括缺口) 的频率通过除以均匀背景 ($p(aa) = 0.05$) 转换为对数赔率, 并添加 $1e-9$ 的 epsilon, 然后应用以 2 为底的对数。这将产生一个大小为 229 x 20 的得分矩阵。

PSSM得分 我们提取输入序列中 (位置, 氨基酸) 对 的 PSSM 值。这些值被平均以生成一个得分。

N末端卷曲计数 是一个旨在测量设计 N 末端结构无序程度的指标。我们观察到预测结构在此区域具有不同程度的无序性。为了对其进行量化以便进行可能的过滤, 我们将 mkdssp (82) 应用于设计的 ESM3 预测结构, 并记录前 12 个位置中有多少被报告为具有 SS8 标签在 {S, T, C}。

A.5.1.5. 选择标准

在实验 1 和实验 2 之间, 通过首先应用一组过滤器来选择设计进行测试, 然后根据基于得分的排名选择前 N 个设计。得分通过对几个指标的数值进行求和计算, 这些指标

在各设计之间进行归一化处理, 使其具有零均值和单位方差, 并在适当时进行否定, 以确保较低的值总是更好。

常见过滤器 在实验 1 和实验 2 中应用了以下过滤器。

- 模板色素位点 RMSD $< 1.5^\circ \text{A}$
- 模板螺旋 RMSD $< 1.5^\circ \text{A}$
- N-gram 得分 < 5

常见得分术语 在实验 1 和实验 2 中使用了以下得分术语。

- 序列伪困惑度
- 往返困惑度
- ESM3 pTM

A.5.1.6. 实验 1 的设计生成和选择

在本实验中, 我们生成了一组针对实验测试的 GFP 设计, 其序列与模板的相似度范围不同。这些设计是通过一系列思维过程生成的: 从提示开始, ESM3 解码所有被遮蔽的结构标记, 然后解码所有被遮蔽的序列标记。最后, 序列和结构标记被联合优化。

初始生成 从提示开始, 我们首先通过逐一解码遮蔽的结构标记生成 38,000 个结构, 使用从 (0, 1.25) 范围内均匀采样的固定温度进行每次生成。为了将计算集中在最有前景的结构上, 我们根据模板色素位点 RMSD $< 1^\circ \text{A}$ 进行过滤, 得到 24,000 个选定结构。接下来, 我们为每个结构生成 ≈ 4 序列, 使用从 (0, 0.6) 范围内均匀采样的温度, 最终生成 92,000 个总序列。

选择 我们选择一组有前景的初始生成进行进一步优化, 通过应用常见过滤器, N-gram 得分的阈值调整为 < 5.5 , 按照 {常见得分术语、平均 ESM3 pLDDT、平均 ESMFold pLDDT 和 ESMFold pTM} 进行设计排名, 并选择每个 0.1 序列一致性区间内的最佳 40 个设计, 针对模板序列在 [0.2, 总共 1.0], 320 个设计。

联合序列结构优化 随后我们共同优化设计的序列和结构。在每种情况下使用 30 次迭代, 我们运行 5 个种子的优化, 最大解码熵阈值为 $= 1.5$, 并以负局部序列引导 $= 2.0$ 进行 2 个种子的优化, 共生成 67k 个设计。每次迭代的设计都被纳入这个池中。

使用语言模型模拟五亿年的进化

选择为了选择一组用于实验室测试的设计, 我们应用{常见过滤器、N末端螺旋计数 <6}, 根据{常见得分术语、ESMFold pTM、15 * PSSM得分}对设计进行排名, 并在范围 [0 中以宽度为 0.1 的区间选择 88 个最佳设计, 这些设计在序列相似性方面与我们的模板相符合。2, 1}。

A.5.1.7. 实验 2 的设计生成和选择

在本实验中, 我们对在实验 1 中发现的微弱、遥远的 GFP 进行进一步的细化, B10。为了产生多样化的设计, 我们遍历多个设置: 执行两种细化变体, 并使用 2 种选择协议。

局部联合优化从我们的微弱 GFP 设计 B10 开始, 我们执行联合_优化, 使用以下设置的一整套网格搜索: 初始温度 {0.001、0.01、0.05、0.1、0.5}, PSSM 偏置权重 {0, 0.01、0.05、0.1、0.5}, 最大解码熵阈值 {0.8、1、1.25、1.5、2.0}。对于每个唯一的设置组合, 我们使用 20 次优化迭代和 3 个种子, 持续进行吉布斯采样的最终步骤, 直到收敛。在考虑到某些分布式系统机器故障后, 这产生了 6.3k 个候选设计。

选择我们选择了两个设计集, 每个包含45个设计, 供实验室测试, 利用两个过滤器和一套共享的排序标准。

1. 集 1: 我们根据 {PSSM 偏置 $\neq$ 0、常见过滤器、与起始结构的 RMSD <1 °A 以及与起始序列的相似度在 (0.7, 1.0) 之间 } 进行过滤。
2. 集 2: 我们根据 {PSSM 偏置 = 0 (无偏置)、常见过滤器、与起始结构的 RMSD <1 °A, 以及与起始序列的相似度在 (0.9, 1.0) 之间 } 进行过滤。esmGFP 来自此池。对于每个集合, 我们根据 {常见得分术语、8 * PSSM 得分、15 * 1EMA 螺旋 RMSD } 排序, 并每个集合选择 45 个设计进行测试。

A.5.2. 实验方法与数据分析

A.5.2.1. 菌株与质粒

我们设计了一个定制的细菌表达载体, 包含一个氨苄青霉素抗性基因, BBa R0040 TetR 启动子, BBa B0015 终止子, 以及一个位于启动子和终止子之间的 Bsa-I 金门位点。GFP 的设计经过了针对 大肠杆菌 表达的密码子优化, 兼容

添加了金门重叠序列, 并从 IDT (集成设备技术公司) 订购了序列。随后, 它们通过金门组装克隆到载体中。我们在大肠杆菌宿主 Mach1 中评估了我们的 GFP 设计。

A.5.2.2. GFP 设计的荧光测定

为了评估我们的GFP设计的荧光, 我们将设计转化为 Mach1 细胞。对于每个设计的两个重复实验, 种植一个菌落于包含 50 μ g/mL 氨苄青霉素的 1 mL TB 培养基中。在 37 °C 的 Infors HT Multitron 摇床中, 培养在 96 孔深孔板中以 1000 RPM 的摇动速度培养 24 小时。24 小时后, 将 1 μ L 的培养物稀释于 200 μ L 经 0.2 μ m 过滤的 DPBS 中。

样品的荧光强度在单细胞水平上使用 NovoCyte Quanteon 流式细胞仪定量 (图 S19)。

剩余的培养物以 4000 g 离心 10 分钟, 重悬并用 300 μ L 裂解缓冲液 (1x bugbuster, 500 mM NaCl, 20 mM Tris-HCl pH 8, 10% 甘油, cOmpleteTM, 无 EDTA 蛋白酶抑制剂鸡尾酒) 裂解, 在室温下在 Belly Dancer 摇床上孵育 10 分钟, 然后在 4000 g 下离心 20 分钟澄清裂解液。100-120 μ L 裂解液转移至 96 孔黑色清底板, 并使用 Tecan Spark 读数器测量 GFP 荧光。在 515 nm 处捕获荧光发射, 带宽为 10 nm, 并在 485 nm 处激发, 带宽为 10 nm。280 nm 处的吸光度被捕获, 带宽为 3.5 nm, 以评估每孔的总蛋白质含量。对于较长时间点, 含有裂解液的板被封闭并在 37°C 孵育长达 7 天, 然后测量荧光。GFP 荧光值首先根据其在 280 nm 处的吸光度在孔内进行比率归一化, 然后使用来自于不含 GFP 的负对照大肠杆菌测量的值在孔之间进一步进行比率归一化。来自两个重复实验的数据随后被平均 (图 4B 底部) 和 (图 4C)。

板的概述照片 (图 4B 上) 是在 Invitrogen Safe Imager 2.0 蓝光透射仪的蓝光照明下, 使用 iPhone 12 mini 拍摄的。

对于激发光谱, 发射在 570 nm 处捕获, 带宽为 50 nm, 而激发波长在 350 到 520 nm 之间变化, 带宽为 10 nm。对于发射光谱, 使用 430 nm 的激发波长, 带宽为 50 nm, 而发射则在 480 到 650 nm 的不同波长下进行捕获, 带宽为 10 nm。激发和发射光谱通过其最大值进行了归一化 (图 4C)。

使用语言模型模拟五亿年的进化




图 S19. 流式细胞术数据确认表达 esmGFP 的细胞可以在单细胞水平上被检测到。正向散射-面积 (FSC-A)，作为细胞大小的测量，与荧光异硫氰酸酯-面积 (FITC-A)，作为 GFP 类荧光信号的测量，针对表达 1QY3 A96R、esmGFP 和不表达任何 GFP 的负对照。为负对照数据设定了 99.9% 分位数的门，量化通过该门的细胞比例，针对每个样本进行评估。




图 S20. 设计 B8 的复制和选择控制。结果是两个板块中八个孔的平均值。




图 S21. 发色团缺失突变。T65G 和 Y66G 将 1QY3 A96R 和 esmGFP 的荧光降低至背景水平。

A.5.2.3. 附加 GFP 实验

板块概述照片 (图. 4B顶部) 自初始裂解液生成以来的两周内拍摄，并且在最终板读定量完成后的一周内，因此可能显示出来自缓慢色素成熟设计的额外亮度。我们观察到在实验 1 的照片中，H11井（无 GFP 或设计的载体）和 H12井（仅裂解缓冲液）有一些低水平的污染 (图. 4B左上)。在初始板读定量过程中，H12井中的一些污染已经可见 (图. 4B左下)。为了解决潜在的污染问题，我们对 B8 进行了额外的重复实验，并观察到与实验 1 相似的亮度水平（比自然 GFPs 亮度低 50 倍）(图. S20)。

mGFP 通过额外的 T65G 和 Y66G 突变创造。这些变体与 1QY3 和 esmGFP 一起，被合成并作为 Genscript 进行的独立重复实验的一部分进行测量，遵循大肠杆菌 基于荧光平板读数检测的描述。测量细胞在裂解前的 OD600 以进行标准化。其余分析如上所述进行。对每个设计进行了两次重复实验，结果取平均值。发色团缺失使荧光降低到背景水平 (图. S21)。

发色团缺失版本的 1QY3 A96R 和 es-

A.5. 3. 序列搜索和比较

A.5.3.1. 数据库搜索

BLAST nr 搜索: esmGFP 的序列通过使用非冗余序列数据库nr 的 BLAST 在线服务器进行了搜索, 采用所有默认设置。tagRFP 的序列取自最顶部的命中。找到的确切顶部命中是TagRFP [克隆载体 pLX-B2-TagRFP-T, 序列 ID ASG92118.1, 其完整内容在表S14中显示。

训练集搜索: MMseqs2 (79), 版本 15.6f452, 被用于搜索所有在最大可用扩展级别上ESM3训练的数据集; 对于聚类重采样数据集, 所有聚类成员都被搜索, 而不仅仅是聚类中心。目标是搜索ESM3在预训练期间可能见过的每一个序列。选择的设置用于进行高灵敏度搜索: `-s 6-a --max-seqs10000`。

A.5.3.2. SEQUENCE IDENTITY CALCULATIONS 为了计算涉及两个高亮显示的GFP设计 (B8, esmGFP) 和选择的参考蛋白质的序列一致性, 采用以下程序。MAFFT (109) v7.525在所有默认设置下应用于B8、esmGFP、通过BLAST找到的顶级tagRFP序列、eqFP578 (来自FPBase (110)), 模板 (PDB ID 1QY3, 含有突变A96R) 以及avGFP (来自FPBase) 的序列。在对齐位置上, 两个序列之间的一致性通过匹配的非缺口残基数除以查询和目标蛋白质的最小非缺口长度来计算。这与附录 A.5.4中使用的序列一致性公式相同。对齐的序列、一致性和到esmGFP的突变计数在表S14中提供。

A.5.3.3. INNER-BARREL MUTATION COUNT 在esmGFP中, 若其SASA < 5 小于5, 则描述为内部位置。在全原子结构的esmGFP中, SASA的计算方式与附录 A.2.1.6) 一致, 该结构是通过ESM3 7B进行预测的。

A.5. 4. 系统发育分析从 FPBase (110) 获取了天然和设计的荧光蛋白的序列及元数据。根据以下标准筛选出最初的 1000 种蛋白质: 存在指定的亲本生物, 氨基酸序列长度在 200 到 300 残基之间, 指定的发射最大值, 以及无辅因子。使用 NCBI 分类数据库获取每个物种的分类信息。这些序列进一步过滤, 以保留那些由 NCBI 发现的物种, 并且是真核生物但不属于绿藻 (以排除 Channel-




图 S22. esmGFP 的序列一致性。与自然界中发现的四大主要类群中的天然和设计 绿荧光蛋白 进行比较。

视紫红质样蛋白)。通过这些标准筛选出的 648 个序列, 以及 esmGFP 的序列, 使用 MAFFT 进行了多序列比对, 并按照上述描述计算了每对序列之间的序列一致性。考虑了所有类群内外的配对 (图. 4F)。所有设计的序列被视为属于标注为其亲本生物的物种。

所有648个使用的序列属于侧头目 (例如laGFP)、六足幼虫类 (例如ppluGFP)、水母 (例如avGFP) 或珊瑚虫 (例如efasGFP) 类别。esmGFP与这些类别中的每种蛋白质的序列一致性被计算得出 (图. S22)。发现esmGFP与珊瑚虫的绿荧光蛋白具有最高的相似性 (平均序列一致性为51.4%), 同时也与水母的绿荧光蛋白共享一些序列一致性 (平均序列一致性为33.4%)。

为了估算 esmGFP 与已知荧光蛋白之间的百万年 (MY) 进化距离, 我们建立了一个估算器, 以根据 GFP 之间的序列一致性来计算相距多少百万年。我们使用了以下六种刺胞动物物种米氏珊瑚, 佛罗里达海葵, 大洞石珊瑚, 黄条珊瑚, 盘海葵, 直立扁海葵, 以及六种 GFP amilGFP, rfloGFP, mcavGFP, pporGFP, dis3GFP, efasGFP。选择这些物种和 GFP 是因为它们在最近的时间校准刺胞动物系统发育分析中被注释 (57) 和在最近的 GFP 研究中被注释 (48)。每种物种都包含多个类似 GFP 的序列, 包括红色和青色荧光蛋白。这些特定的 GFP 被选择是因为它们被注释为每个物种的主要 GFP。每种物种之间的百万年估计为最后一个共同祖先的百万年数的两倍, 该祖先在时间校准的系统发育分析中被注释。使用 statsmodels (111), 在百万年与序列一致性之间拟合了一条最佳拟合线。该线必须通过序列一致性为 1.0 和 0 MY。然后使用这条线估计 esmGFP 的百万年数

使用语言模型模拟五亿年的进化

以及 esmGFP 与最近已知蛋白质的序列一致性。

A.6. 开放模型

我们正在发布开放模型 ESM3-open 的 ESM3 源代码和模型权重。ESM3-open 是一个 1.4B 参数模型, 我们在不使用 OAS 抗体序列的情况下进行了训练, 并采取了谨慎的风险缓解措施, 以便向学术研究社区发布。

作为此次发布的一部分, 我们遵循《人工智能在生物设计中负责任发展的原则》(112)。我们采用了在附录 A.6.1 中描述的谨慎风险缓解措施, 并进行了在附录 A.6.2 中详细说明了风险评估。此外, 我们与科学界的专家对发布 ESM3-open 的风险和利益进行了审核。我们向评审人员提供了对 ESM3-open 的访问权限, 以及有关我们风险评估的详细技术报告。我们收到了评审人员一致反馈, 认为发布该模型的好处大大超过了任何潜在风险。

我们将此次发布视为第一步, 并计划与科学界合作, 继续改善与负责任发展相关的过程。开放模型使科学界能够更好地理解和减少生物设计工具的潜在风险。随着我们理解的不断发展以及未来模型能力的提升, 我们计划持续改善我们的评估框架、安全措施和缓解策略。

A.6.1. ESM3开放缓解

作为一种预防措施, 我们过滤了 ESM3-open 的训练数据, 以最小化模型在潜在关注序列上的表现, 同时保持其他方面的表现。我们还移除了模型跟随与病毒和毒素相关的提示的能力。

过滤潜在关注的序列。先前的研究表明, 蛋白质语言模型的性能与训练数据中相似序列的数量密切相关 (5)。因此, 我们从训练数据中移除了与潜在关注蛋白质对齐的序列, 以降低 ESM3-open 在这些序列上的能力。

我们识别并移除独特于病毒的序列, 以及选择性病原体及毒素名单中 (113) 的病毒和非病毒序列, 该名单由 CDC 和 USDA 维护。美国卫生与公众服务部建议根据选择性病原体名单进行过滤, 以作为其合成核酸提供者 and 用户筛选框架指导的一部分 (114)。

为了筛选数据, 我们创建了两个拒绝列表: 病毒拒绝列表和

选择性病原体拒绝列表。然后, 我们移除从训练集中检测到与拒绝列表中序列比对的所有序列, 这些序列由 mmseqs2 在或高于给定的序列一致性阈值所检测。

为了创建病毒拒绝列表, 我们识别 ~4 在 UniProt 中注释为病毒的 M 序列, 并几乎仅与 UniProt 中的其他病毒序列对齐。这为我们提供了一种程序, 能够以高敏感性和特异性 (根据 UniProt 的分类注释进行测量) 去除病毒蛋白。为了创建选择性病原体拒绝列表, 我们识别所有属于选择性病原体及毒素名单 (113) 的 UniProt 中的序列。此过程为我们提供了 147K 非病毒序列和 40K 额外的病毒序列。

对于每个拒绝列表, 使用 MMseqs 对完整的训练数据库集进行查询 (包括 PDB、UniRef、MGnify 和 JGI), 并从训练集中移除所有命中。这一过滤器在所有训练集中总共移除了 10.6M 序列。

去除相关关键词。我们旨在去除与病毒和毒素相关的多个关键词提示。我们首先通过以下步骤识别有害关键词列表:

1. 我们整理了一份与病毒和毒素相关的过滤词汇列表。完整的过滤词汇列表可根据请求提供。
2. 然后, 我们识别所有自由文本术语名称中包含至少一个过滤词的 InterPro 标签。
3. 我们识别与标记的 InterPro 标签相关的关键词, 但与未标记的 InterPro 标签无关。我们移除这些关键词。与标记和未标记的 InterPro 标签均相关的关键词 (例如 “细胞外区域”) 不被移除。

4. 我们还移除所有直接包含一个过滤词的关键词。在原本的 68,103 个关键词中, ESM3 训练所用的该过滤去除了 9,462 个 (14%), 形成了一个新的词汇表, 共 58,641 个关键词。函数词汇表是通过代表词频逆文档频率 (TF-IDF) 的向量定义的, 然后使用局部敏感哈希 (LSH) 进行分词, 如附录 A.1.8 中先前所述。为了移除标记关键词, 首先从 TF-IDF 词汇表中去除与标记关键词对应的条目。这将 TF-IDF 向量大小减少到 58,641。LSH 分词由 64 个超平面定义, 每个超平面在 TF-IDF 空间中定义, 即欧几里得空间。

使用语言模型模拟五亿年的进化

蛋白质	与es mGFP的序 列一致性	与esmGFP的 突变	对齐序列
B8	0.93 15		-MSKVEELIKPEMKMKLEMEGEVNGHKFSIEAEGEGKPYEGKQTIKAWSTT-GKLPFAW DILSTSLTYGFRMFTKYPEGLEEHDYFKQSFPEGYSWERTTTYEDGATVKVTSISLED GVLINKIKFKGTNFPSDGPVM-QKKTGWEPSTELITPDATGGLKGEVKMRLKLEGGG HLLADFKTTYRSKKKEK-LPLPGVHYVDHTIRNEKAPHPEGKEYVVQYETAVARLA--- -----
esmGFP	1.0	0	-MSKVEELIKPDMKMKLEMEGEVNGHKFSIEAEGEGKPYEGKQTIKAWSTT-GKLPFAW DILSTSLTYGNRAFTKYPEGLEQHDFFKQSFPEGYSWERTTTYEDGATVKVTADISLED GVLINKVKFKGENFPSDGPVM-QKKTGWEEASTELITPDATGGLKGEVKMRLKLEGGG HLLADFKTTYRSKKKEK-LPLPGVHYVDHRVNEKATHPEGKEYMIQYEHAVARLA--- -----
tagRFP	0.58 96		MVSKGEELIKENMHMKLYMEGTVNNHHFKCTSEGEKPYEGTQTMRIKVVEGGPLPFAF DILATSFMYGSRTFINHTQGIP--DFFKQSFPEGFTWERVTTYEDGGVLTATQDTSIQD GCLIIYNVKIRGVNFPSPNGPVM-QKKTLGWEANTEMLY--PADGGLEGRTDMALKLVGGG HLICNFKTTYRSKKPAKNLKMPPGVYVDHRL--ERIKEADKETVVEQHEVAVARYCDLP SKLGHKLN
eqFP578	0.53 107		---MSELIKENMHMKLYMEGTVNNHHFKCTSEGERKPYEGTQTMKIKVVEGGPLPFAF DILATSFMYGSKTFINHTQGIP--DLFKQSFPEGFTWERITTYEDGGVLTATQDTSIQN GCLIIYNVKINGVNFPSPNGSVM-QKKTLGWEANTEMLY--PADGGLRGHSQMALKLVGGG YLHCSFKTTYRSKKPAKNLKMPPGFHFVDHRL--ERIKEADKETVVEQHEMAVAKYCDLP SKLGHR--
模板	0.38 143		-MSKGEELFTGVVPILVELDGDVNGHKFSVSGEGEGDATYGKLTCLKFICTT-GKLPVPW PTLVTTTLYGVQCFSRYPDHMKQHDFFKSAMPEGYVQERTISFKDDGNYKTRAEVKFEG DTLVNRIELKGIDFKEDGNILGHKLEYNYSNHNYYITADKQKNGIKANFKIRHNIEDGS VQLADHYQQNTPIGDGP-VLLPDNHYLSTQSALSKDPN-EKRDMVLLFEVTAAGI--- -----
avGFP	0.36 146		-MSKGEELFTGVVPILVELDGDVNGHKFSVSGEGEGDATYGKLTCLKFICTT-GKLPVPW PTLVTTTFSYGVQCFSRYPDHMKQHDFFKSAMPEGYVQERTIFFKDDGNYKTRAEVKFEG DTLVNRIELKGIDFKEDGNILGHKLEYNYSNHNYYIMADKQKNGIKVNFKIRHNIEDGS VQLADHYQQNTPIGDGP-VLLPDNHYLSTQSALSKDPN-EKRDMVLLFEVTAAGITHG MDELYK--

表 S14. 选定的 GFP 设计 (B8, esmGFP) 和参考蛋白质的多序列对齐。模板是我们模板结构的完整序列 (PDB ID 1QY3), 发色团慢化突变 A96R 被去除。tagRFP 是非冗余数据库 nr 中 BLAST 搜索返回的最佳命中序列的完整序列, avGFP 和 eqFP578 来自 FPBase。GFP 设计的序列相似性通常计算为对齐位置上非缺口匹配的数量, 除以查询序列和目标无缺口序列的最小长度。在这里, 仅显示与 esmGFP 的序列相似性。同样, 针对 esmGFP 的突变数量计算为在对齐位置上 esmGFP 没有缺口的错配数量。

使用语言模型模拟五亿年的进化




图 S23. ESM3-open 是一个强大的结构和功能预测器, 经过开放发布的训练。A: 结构预测ESM3-open (蓝色) 在结构预测方面与 ESMFold (橙色) 竞争, 就 LDDT 在 CAMEO 和 CASP14/15 的测量结果而言。详见附录A.3.4 中关于此评估的详细信息。B: 表征学习ESM3-open (蓝色) 在表征学习方面与 ESM2-3B (橙色) 竞争, 就微调表征的接触预测 P@L 测量而言。详见附录A.3.3 中关于此评估的详细信息。C: 功能关键词预测。ESM3-open 在功能关键词上的功能预测性能, 按照功能关键词的平均平均精确度进行测量。ESM3-open 在所有关键词上的精度为 0.81, 在测试集中最常见的前 1K 关键词上的精度为 0.89 (附录A.3.2)。我们使用与附录A.1.8.2.2中相同的评估框架。我们报告了与图S8一致的宏平均和微平均。在上述所有评估中, 数据缓解对性能的影响最小, 与没有数据缓解的计算匹配模型 (带阴影的蓝色) 相比。D: 零样本适应性预测。根据 217 个在 ProteinGym 中整理的深度突变扫描数据集的相关性 (Spearman ρ) 测量的适应性预测性能。左侧和右侧的子图表示病毒 (左) 和非病毒 (右) DMS 数据集。每组的四列表示不同的模型。ESM3-open 在病毒适应性预测方面的表现显著低于 EVMutation (紫色), 而在非病毒适应性预测中与 ESM2 (橙色) 竞争。数据缓解对病毒适应性预测的影响显著, 而对非病毒适应性预测的影响并不显著 (带阴影的蓝色)。

每个关键词对应一个维度的空间。我们通过移除与标记关键词相对应的维度, 重新定义超平面在降维空间中的位置。这永久性地去除了标记关键词分词所需的信息。这种缓解措施具有高度选择性, 并且不会改变任何未标记关键词的分词。

A.6.2. ESM3开放评估

在下面的章节中, 我们概述了ESM3-open的性能评估。在适当情况下, 我们将ESM3-open与现有的开放模型 (例如ESM2或ESM-Fold) 进行比较, 或与未经任何数据缓解训练的ESM3-open的计算匹配版本进行对比。

结构预测在图S23A中, 我们展示了ESM3-open在结构预测方面的竞争性表现, 依据LDDT对CASP14、15和CAMEO的测量结果, 显示出与我们无数据过滤的计算匹配1.4B模型相比, 仅有非常轻微的退化。评估框架详述于附录A.3.4。

我们还测量了ESM3预测一部分病毒蛋白结构的能力。在图S23A中, 我们评估了基于从PDB训练集中移除的病毒衍生结构集的结构预测。对于在PDB中的链, 这些链与病毒拒绝列表的 > 70%序列一致性命中, 我们在40%序列一致性处进行聚类, 然后从每个聚类中选择最长的链 (长度为 ≤ 1024)。

ESMfold和ESM3-open在病毒结构上的平均LDDT分别达到了0.66和0.63。如果没有数据减轻, 计算匹配的ESM3-open的平均LDDT将为0.66。这显著低于在CAMEO和CASP14上进行一般结构预测的表现, 其中ESMfold的平均LDDT为0.86和0.73, 而ESM3-open的平均LDDT为0.83和0.70。

表征学习。ESM3-open在表征学习上表现出色, 在接触预测方面略微超过了ESM2 (3B), 通过在源自CASP14/15和CAMEO的结构上测得的序列长度L的精度(P@L)进行评估, 见图。S23B. 评估框架在附录A.3.3中进行了描述。

功能关键词预测。ESM3-open能够预测来自UniRef的验证集中的蛋白质的功能关键词, 这些蛋白质已通过InterProScan进行注释, 见图。S23C. ESM3-open对所有关键词的平均平均精确度为0.81 (宏观平均), 对于前1000个关键词的精度为0.89 (微观平均), 排除了诸如 “the” 等常见术语。评估框架与附录A.1.8.2.2中描述的相同。

零-shot病毒适应度预测。我们测量了ESM3识别有效序列的能力, 并理解突变对病毒蛋白的影响。评估由来自217个深度突变扫描(DMS)数据集的单突变体组成, 这些数据集在ProteinGym中收集 (115)。

这包括来自病毒蛋白的28个DMS景观以及189 从其他蛋白质中。我们评估预测变体效应与测量变体效应之间的相关性 (Spearman ρ) 变体效应。预测的变体效应被测量为变体等位基因的 logit 值与给定掩蔽下的野生型等位基因的 logit 值之间的差异位置 (18)。首先，我们比较 ESM3-open 的性能与未经过任何数据过滤的计算匹配版本的 ESM3-open 的性能。实施数据过滤作为一种缓解措施，将病毒适应度预测的平均 Spearman ρ 性能从 0.28 (ESM3-small) 降低到 0.17

(ESM3-open)，而非病毒蛋白的性能并未受到不利影响，从 0.46 (ESM3-small) 变为 0.45 (ESM3-open)。我们还比较了 ESM3-open 的性能与现有开放模型基准的性能。图。S23D

评估相对于 EVMutation (116) 基线的性能。EVmutation 是一种马尔可夫随机场模型（非深度学习基础），基于目标蛋白的多序列比对进行训练。BLOSUM62 是基于

关于氨基酸替代频率。在采取缓解措施后，ESM3-open在病毒景观上的表现相较于 EVMutation较低，并且与BLOSUM62持平。

图表目录

S1 ESM3架构	22
S2 几何注意力	25
S3 结构标记器重建质量	32
S4 结构标记器重建的可视化	33
S5 映射到相同学习的结构标记的局部邻域可视化	34
S6 pTM 和 pLDDT 校准	35
S7 函数标记化的示意图	35
S8 函数预测基准测试结果	36
S9 使用的噪声调度的可视化	41
S10 结构预测的缩放曲线	43
S11 每条轨道的条件和无条件缩放行为	44
S12 pTM 和 pLDDT 的分布	45
S13 使用ESM3进行高质量和多样性蛋白质的无条件生成	46
S14 使用思维链生成序列	47
S15 提示ESM3超越其训练分布进行泛化	49
S16 通过ESM3进行多模态蛋白质编辑	53
S17 对齐改善模型生成	57
S18 从基础模型和微调模型中随机选择成功生成	58
S19 流式细胞术数据确认表达 esmGFP 的细胞可以在单细胞水平上被检测到	62
S20 B8 重复制	62
S21 发色团敲除突变	62
S22 esmGFP 的序列一致性	63
S23 ESM3-open 是一个强大的结构和功能预测器，经过开放发布训练	66

表格清单

S1 不同模型配置的参数细节	24
S2 全原子结构标记解码器第二阶段训练的训练细节	31
S3 预训练数据集统计	40
S4 预训练唯一标记统计	40
S5 应用到每个数据集的数据增强和条件信息	40
S6 噪声调度和丢弃概率	41
S7 精度@L	43
S8 蛋白质结构预测结果	44
S9 基于其他轨迹的每条轨迹的负对数似然	44
S10 保护性功能基序的定义区域	49

使用语言模型模拟五亿年的进化

从测试集蛋白质中提取的 S11 InterPro 标签，用于
带有折叠规范的提示..... 51

S12 新颖性和可设计性指标..... 51

S13 三级协调数据集 55S14 选择性
GFP 设计（B8，esmGFP）和参考蛋白质的多序
列比对 65