

基于强化学习的蛋白质语言模型功能对齐

收稿日期：2025年9月15日

接收日期：2026年8月19日

Published online: 12 September 2026

 检查更新纳撒尼尔·布拉洛克^{1,2}、Srinath Seshadri²、Kensuke Nakamura^{2,3}、Agrim Babbar⁴、Sarah A. Fahlberg⁴、Ameya Kulkarni²及 Philip A. Romero^{2,4}✉

蛋白质语言模型（pLMs）能够实现新型蛋白质序列的生成式设计，但在根本上仍与蛋白质工程目标不符，因为它们缺乏对功能的明确理解，且往往无法提升超越自然界中已发现的蛋白质特性。我们引入了基于实验反馈的强化学习（RLXF）——这是一个通用框架，旨在将蛋白质语言模型与实验测得的功能目标对齐，其设计灵感源自用于对齐如ChatGPT等大型语言模型的方法。在五个不同蛋白质家族中应用 RLXF 后，该框架相较于预训练基线模型，能够生成具有更高功能的变体。我们以不依赖氧气的荧光蛋白CreiLOV为例，展示了这一成果：经过 RLXF 对齐的模型生成了荧光强度显著增强的序列，其中包括迄今为止报道的荧光强度最高的CreiLOV变体。我们的研究表明，RLXF 对齐模型能够有效整合预训练pLMs中编码的进化知识与实验观察结果，从而提高生成序列的成功率，并有助于发现通过零样本或进化方法难以识别的协同突变组合。RLXF 提供了一种可扩展且易于使用的方法，可将生成模型引导至所需的生化特性，从而实现超越自然进化限制的函数驱动型蛋白质设计。

蛋白质语言模型（pLMs）利用自然语言处理（NLP）领域的技术进步，学习蛋白质中氨基酸的线性排列如何编码其结构、功能及动力学特性。基于Transformer架构构建的pLMs可生成能够捕捉蛋白质生物学意义的表征——例如其折叠构象、分子活性或进化角色——而非仅依赖序列相似性^{1,2}。这些学习得到的表征已在多种任务中展现出强大效能，包括结构预测^{3,4}、功能注释^{5,6}、变异效应预测^{7,8}以及进化建模^{9,10}。近年来，pLMs已成为生成式蛋白质设计领域的前沿工具，能够构建新型且具有功能的蛋白质序列，包括绿色荧光蛋白^{1,11}、溶菌酶¹²、碳酸酐酶¹³、

乳酸脱氢酶¹³、磷酸丙糖异构酶¹⁴以及肽结合蛋白^{15,16}的变体，这些序列与任何已知天然蛋白质均存在显著差异。

pLMs，例如 UniRep⁹和进化尺度建模（ESM）³，均在从进化树中采样的大量天然蛋白质序列集上训练。通过使用自监督学习目标，如自回归下一令牌预测^{12,17-19}或掩码语言建模^{1,20-22}，这些模型学习能够捕捉天然蛋白质中嵌入的结构特征、生物功能及进化约束的上下文感知表征。当用于序列生成时，pLMs可生成高度多样化的输出，这些输出反映了天然蛋白质中存在的统计模式与相关性¹²。尽管这些序列可能与训

¹美国威斯康星州麦迪逊市，威斯康星大学麦迪逊分校化学与生物工程系。²美国北卡罗来纳州达勒姆市，杜克大学生物医学工程系。³日本东京，第一三共株式会社模态研究实验室II。⁴美国威斯康星州麦迪逊市，威斯康星大学麦迪逊分校生物化学系。✉电子邮箱：philip.romero@duke.edu

练数据中的任何单个样本相距甚远，但它们仍源自同一分布，从而在序列上具备新颖性，但在功能上则不具备。由于 pLMs 缺乏对功能的显式理解，它们往往无法生成具有增强或非天然活性的蛋白质^{11,12}。因此，这些研究在根本上仍与蛋白质工程的核心目标——即创造超越进化已探索范围的蛋白质——相悖。

在本研究中，我们提出了基于实验反馈的强化学习（RLXF）——一种将大语言模型（pLMs）与实验推导的生物分子功能概念对齐的框架。该框架支持根据用户定义的目标，生成具有增强特性的蛋白质。我们的方法借鉴了将大语言模型（LLMs）与人类偏好对齐的强化学习技术，这些技术已催生出诸如 ChatGPT²³ 和 Claude²⁴ 等变革性工具。在 RLXF 中，一个奖励函数（例如监督式序列-功能预测器或任意序列评分模型）向 pLM 提供反馈，引导其生成具有更优功能的序列。最终结果是一个功能对齐的模型，该模型可被反复采样，以生成针对所需特性优化的多样化序列。

我们在五种不同的蛋白质类别中应用了 RLXF，以证明其在生成优化序列方面的泛化能力和有效性，这些序列是通过学习预训练阶段未能捕捉到的功能约束而获得的。作为案例研究，我们将拥有 650M 参数的 ESM-2 模型与来自 CreiLOV 荧光蛋白的实验荧光数据进行了对齐。对齐后的模型学会了优先选择能够增强荧光的突变，其中许多突变被基础模型遗漏。实验验证表明，经过 RLXF 对齐的模型生成了更高比例的功能性序列，产生了更多比 CreiLOV 荧光蛋白荧光更强的序列，以及若干变体比已知最亮的荧光蛋白荧光更强。我们的研究结果强调了将 pLMs 与工程目标对齐的重要性，这有助于超越自然分布，释放蛋白质设计中的功能潜力。

结果

蛋白质语言模型的功能对齐

大型语言模型（LLMs）最初仅以文本补全任务进行预训练，学习语言的句法和语义，但并未捕捉人类意图或偏好。ChatGPT 的关键突破在于采用基于人类反馈的强化学习（RLHF），将预训练的 LLMs 与人类目标对齐，从而生成更具实用性、真实性及安全性的响应²³⁻²⁶。蛋白质语言模型（pLMs）与 LLMs 有许多相似之处。它们也能生成句法和语义上有效的蛋白质序列，但这些序列未必适用于人类生物技术应用，如可持续能源、化学或医学领域。同样，pLMs 也需要与人类意图对齐，以生成具有人类指定的生物物理或生化特性的蛋白质。

受 RLHF 的启发，我们引入了基于实验反馈的强化学习（RLXF），用于对齐 pLMs，以生成具有增强或非天然活性的序列（图1a）。RLXF 的核心是一个用户定义的奖励模型，该模型对基础 pLM 进行修改，以生成具有高奖励值的序列。此奖励模型可以是任何基于序列或结构的评分函数。我们专注于使用实验序列-功能数据训练的监督模型，因为这些模型能够准确捕捉复杂的生物物理和生化特性²⁷⁻²⁹。

RLXF 采用与 RLHF 类似的两阶段训练策略：首先进行监督微调（SFT），帮助模型在序列空间的正确区域初始化；随后进行近端策略优化（PPO），直接将序列生成与奖励模型对齐（图1b、c）。在 SFT 阶段，我们利用奖励模型探索序列空间，识别出一系列高奖励序列。这

些序列随后被用于微调生成式 pLM，使其倾向于采样这些理想序列中观察到的氨基酸。在 PPO 阶段，直接从 pLM 中采样序列，由奖励模型评分，并将获得的奖励值反馈以更新 pLM，从而进一步提高生成高奖励序列的概率。SFT 与 PPO 共同作用，将生成式 pLM 与人类定义的目标对齐，使其能够生成具有优化功能特性的蛋白质序列。

RLXF 是一个通用框架，可应用于任何蛋白质序列生成模型，包括变分自编码器³⁰、基于结构的图神经网络如 ProteinMPNN³¹、序列扩散模型如 EvoDiff³²、自回归模型如 ProGen^{2,12,33}，以及掩码语言模型如 ESM-2³。在本研究中，我们主要聚焦于使用掩码语言建模进行序列生成的 ESM 系列模型。我们利用 CreiLOV 荧光蛋白开发了并评估了 RLXF。我们使用现有的 CreiLOV 变体深度突变扫描（DMS）数据³⁴训练了一个监督奖励模型，以从序列预测荧光信号（补充图1）。我们利用 CreiLOV 系统性地探索了预训练 ESM 模型的生成能力、不同的生成采样策略、监督微调方法、参数高效训练技术、ESM 模型缩放效应，以及将 RLXF 与相关方法直接偏好优化进行基准对比（补充图1-7）。

功能对齐可提升跨多种蛋白质类别的序列生成性能

pLMs（如 ESM-2）缺乏对生物分子功能的明确定义，因此难以生成具有增强或非天然活性的蛋白质。RLXF 提供了一个通用框架，用于将 pLMs 与人类定义的功能目标对齐，从而生成具有改进且可调控生化特性的序列。为评估 RLXF 的普适性，我们将该框架应用于涵盖多种大小、结构折叠及分子功能的五类蛋白质：poly(A)结合蛋白（Pab1）³⁵、 β -葡萄糖苷酶（Bgl3）³⁶、泛素化因子 E4B（Ube4b）³⁷、Aequorea victoria 绿色荧光蛋白（avGFP）³⁸ 以及 G 蛋白 B1 结构域（GB1）³⁹（见补充表1及补充图8）。我们保留了大多数超参数与 RLXF 在 CreiLOV 上开发时所选参数保持一致（见补充表2-9）。针对每个系统，我们在 DMS 数据集上训练了一个监督奖励模型，并利用该模型对齐规模递增的 ESM-2 模型（参数数分别为 8M、35M、150M 及 650M）（见补充表2-4）。

为了更好地理解 RLXF 如何整合功能信息以改进序列生成，我们比较了三种模型变体：基础 ESM-2 模型、仅使用监督微调（SFT）训练的模型，以及同时使用 SFT 和 PPO 训练的模型。我们采用自然语言处理领域常用的胜率指标^{23,26}来评估生成性能，该指标在此定义为：模型生成一个预测奖励高于基础 ESM-2 650M 模型所生成序列的次数所占百分比。across 不同蛋白质类别和模型规模，RLXF 相较于基础模型显著提高了胜率（图2a）。没有某一特定模型规模在所有情况下均优于其他模型。最佳性能模型则因具体蛋白质系统而异。

最大的提升通常来自 SFT 阶段，而 PPO 则带来了额外但较为有限的改进。在某些情况下，PPO 几乎没有带来提升，因为 SFT 模型已经达到了近乎完美的胜率；而在其他情况下，这种平台期可能反映了我们有限的超参数优化（见补充表6和7）。通过分析每个训练阶段生成的序列的奖励分数，我们发现 RLXF 对齐模型 consistently 采样的序列，其预测功能均高于野生型及基于基础 ESM-2 模型生成的序列（图2b）。这些模型还采样的序列超出了奖励模型训练数据的分布范围，同时展现出这两种特性。




图1 | 基于实验反馈的强化学习（RLXF）。a RLXF 将蛋白质语言模型的生成分布与功能实验测量结果对齐，从而引导序列设计向增强活性方向发展。b RLXF 从预训练的蛋白质语言模型（如 ESM-2）出发，在序列-功能数据上训练奖励模型，并利用该奖励模型对齐蛋白质语言模型的生成分布。监督微调（SFT）阶段将模型初始化至序列空间中功能丰富的区域，引导其生成高奖励序列。c PPO 直接优化蛋白质语言模型的生成性能。PPO 在每个训练周期内对 ESM-2 的权重进行 N 次迭代更新，以提高生成高奖励及多样化序列设计的概率。对于每个采样到的氨基酸，PPO 的目

标函数采用概率比值：分子为当前（已对齐）模型赋予的概率，分母为先前（SFT）模型对该位置相同氨基酸赋予的概率。梯度通过已对齐模型的概率进行反向传播，使其生成分布向更高奖励序列方向调整。总奖励由三个部分组成：归一化的序列-函数奖励模型分数、用于促进序列多样性的成对汉明距离项，以及用于约束更新并防止在 ESM-2 中遗忘预训练知识的 Kullback-Leibler 散度惩罚项（ D_{KL} ）。为了稳定训练过程，PPO 损失函数使用阈值 ϵ 进行裁剪，以限制策略更新的幅度。

更多的突变及更高的预测功能值（图2b）。值得注意的是，RLXF 能够生成包含多达 20 个突变的高回报变体，同时仍优于基础模型（补充图 9）。

为了理解 RLXF 如何将 PLMs 的进化先验与奖励模型提供的功能信号相结合，我们分析了该模型在 RLXF 训练过程中氨基酸偏好性的变化。具体而言，我们考察了野生型序列在每个比对阶段中单突变体对数值的分布情况（见补充图 10 和 11）。对于具有广泛进化覆盖度的蛋白质（即来自大型且多样化的序列家族），RLXF 增加了位置熵，并降低了每个位点上预测的氨基酸概率最大值。这表明基础 PLM 编码了

强烈的进化偏向，而 RLXF 则将这些偏向转向探索新的、由功能驱动的突变。相比之下，对于进化覆盖度较浅的蛋白质，RLXF 降低了熵值并提高了置信度，表明模型通过从奖励模型中学习新的功能约束，变得更加专注。Bgl3 尽管属于一个庞大且代表性强的蛋白质家族，但在 RLXF 训练过程中仍表现出熵值下降和置信度上升的趋势。这很可能反映了其奖励模型训练数据与进化模式之间的高度一致性³⁶，从而导致 RLXF 倾向于强化已知的替换，而非探索新的替换。




图 2 | 功能对齐可提升生成序列的特性。 **a** 不同规模的预训练模型、SFT 及 PPO ESM-2 模型生成的序列设计相对于预训练 ESM-2 (650M) 的获胜率。 **b** 核密度估计图展示了 ESM-2 (n = 1000) 在功能对齐各阶段生成的序列设计的预测功能分布。箱线图汇总了奖励模型训练、验证及测试序列按突变机制分层的预测功能结果。中线表示中位数，箱体表示四分位距（第 25 至第 75 百分位数），须线延伸至 1.5 倍四分位距内的最极端值。我们使用了 (a) 中获胜率最高的 ESM-2 模型规模

（模型规模见括号内标注）。父序列的预测功能值以虚线表示。 **c** AlphaFold3⁸¹ 预测的父蛋白结构，叠加 PPO ESM-2 生成的序列设计的突变频率，并标注了具有显著高置信度的突变位点。在低 N 值环境下，使用最多 1000 个序列变体训练奖励模型时，与预训练的 ESM-2 (650M) 相比，来自预训练模型、SFT 及 PPO ESM-2 (650M) 的 100 个序列设计的获胜率。平均获胜率基于 3 个奖励模型数据划分 (n = 3) 报告，误差条表示标准差。

基础模型 ESM-2 与 RLXF 对齐模型展现出不同的突变偏好，反映出从进化上保守的替换向能够增强实验测得功能的突变转变（图 2c）。在结合哺乳动物 IgG 的 GB1 中，RLXF 对齐模型强烈倾向于将 V29 替换为结合界面附近带正电荷的残基。对 GB1-IgG 复合物的结构分析表明，这种替换可促成与 IgG 上邻近天冬氨酸形成盐桥。由于这一酸性残基在 IgG 同源蛋白中并不保守，基于进化的 PLM 模型并不青睐这种盐桥相互作用。在 Ube4b 中，RLXF 模型倾向于选择 D68N、D139N 和 N142T 这些已知可增强自身泛素化或稳定活性 E2~Ub~E4B 复合物的突变。尽管这些突变可能驱动致癌活性，且不被进化所青睐，但 RLXF 模型仍因其生化益处而选择这些突变，从而将功能优化与进化约束解

耦。在 Pab1 中，RLXF 模型优先选择了 Q94C 突变——这也是奖励模型训练数据中富集度最高的突变。然而，最初的 DMS 研究将 Q94C 判定为假阳性，其对生长并无可测量的影响。这说明了训练数据中的实验伪影如何在对齐过程中误导模型，从而以非预期方式影响序列生成。在 avGFP 中，RLXF 优先选择已充分表征的突变（V163G、D180E 和 T108G），这些突变已知可增强亮度与结构稳定性。在 Bgl3 中，RLXF 则优先选择 A150D——一种先前已被证实可在热应激条件下提升酶活性的热稳定化替换。这些结果共同表明，RLXF 系统性地将对突变偏好从进化上保守的残基转向功能优化方向（补充图 12）。这使得生成具有超越自然变异所能达到的增强特性的序列成为可能。

大多数蛋白质工程研究在实验数据有限的情况下进行。因此，我们评估了 RLXF 是否能够通过使用基于较少已表征变体训练而成的奖励模型来指导功能性序列生成。对于奖励模型，我们采用了结合进化特征的简单线性回归（见补充图13–19及补充表10），该模型在低数据环境下表现良好²⁹。即使仅使用10–100个变体，功能性比对也能可靠地引导生成过程朝向更高的预测适应度，并相较于基础 ESM -2（650M）模型提高了获胜率（图2d）。

具有更高自然多样性的蛋白质家族，在使用低N奖励模型时，从 RLXF 中获得的性能提升更为显著。这一趋势得到了UniRef100数据库中每个蛋白质家族的有效序列数（ N_{eff} ）与所分析的六个蛋白质家族的胜率提升之间直接相关性的支持（补充图20）。尽管该奖励模型确实包含了基于家族多序列比对训练的进化特征，但我们发现奖励模型的性能与 N_{eff} 之间几乎没有相关性。相反，我们推测这种效应源于 ESM -2的进化先验在校准、强度及稳定性方面的差异。

我们使用三个指标评估了基础 ESM -2模型的进化先验：掩码下的野生型保留率以评估logit校准度、熵膨胀值以评估置信度稳定性，以及自一致性间隙以评估预测一致性（补充图21–25）。GB1和avGFP这两种具有有限进化代表性的蛋白质，在所有指标上均表现出较差的校准度与稳定性，包括较低的野生型概率、掩码后的高不确定性以及不一致的预测结果。这些结果表明，对于具有较弱或不稳定先验的蛋白质，即使奖励模型准确，RLXF 对齐方法仍效果欠佳，因为该模型缺乏实现功能导向的可靠基础。

CreiLOV 荧光蛋白的生成式设计

CreiLOV是一种不依赖氧气的荧光报告蛋白，特别适用于低氧或厌氧环境，在这些环境中普遍存在的氧依赖性绿色荧光蛋白（GFP）无法发挥作用^{40,41}。这使得CreiLOV成为在低氧环境中应用（如肠道微生物组、肿瘤微环境及高密度发酵）的极具潜力的工具⁴²。然而，天然及工程改造的CreiLOV变体仍显著弱于 GFP，这限制了它们的实际应用价值^{34,40,43}。值得注意的是，CreiLOV及其他含LOV结构域的蛋白在藻类、真菌和植物中作为蓝光受体存在，而其荧光特性并非其生物学功能的一部分。因此，天然序列及其构建的质粒不太可能编码增强这种非天然但具有生物技术应用价值的荧光特性所需的信息。故而，设计更明亮的CreiLOV变体，需要明确引导模型朝着超越自然进化的功能目标发展。

我们发现，预训练的 ESM 模型更倾向于选择天然 CreiLOV 序列，而非已知能增强荧光强度的突变，这凸显了这些模型对进化保守性的偏好，而非功能优化。例如，FMN 结合口袋中的 C43A 突变是一种合理设计的替换，它破坏了天然光循环，并显著增强了荧光发射⁴³。ESM 模型始终更倾向于保留第 43 位的天然半胱氨酸，以牺牲荧光强度为代价来恢复原始光受体功能（补充图 26–28）。同样，大多数预训练模型也不青睐 T7S 突变——这是 CreiLOV DMS 数据集中识别到的亮度最高的单一变体³⁴。唯一的例外是 ESM -2 (650M) 模型，该模型对 T7S 突变表现出适度的偏好，这可能反映了模型规模效应或预训练过程中的随机差异，这些差异偶然地与增强荧光的特征相吻合（补充图 27）。这些结果强调了仅依赖预训练模型进行非天然功能优化的局限性。

我们使用基于 CreiLOV DMS 数据训练的奖励模型，将 RLXF 应用于 CreiLOV，以预测变异序列的荧光强度。在测试的预训练模型中，ESM -2（650M）在平均和最大预测荧光强度方面均表现出最高的基线性能，因此被选作比对的基础模型（补充图 2）。我们还评估了一个基于天然 CreiLOV 同源物多序列比对训练的变分自编码器（VAE），鉴于此前 VAE 已成功生成多样化且具功能的荧光素酶变体³⁰。ESM -2 模型采用我们提出的两阶段 RLXF 流程进行比对：先进行 SFT，随后进行 PPO。我们省略了对 VAE 的监督微调步骤，因为我们的 VAE 已能生成与 CreiLOV 序列相似性相近的变体，这表明 VAE 无需 SFT 来初始化比对参数（补充图 29）。

与 RLXF 进行功能对齐显著提升了两个模型的序列生成能力（图3a）。经过对齐的 ESM -2 模型相较于其基础版本实现了 100% 的胜率，并生成了具有最高、平均、中位数及最小预测荧光值的序列（补充表 11）。此外，RLXF 对齐使 ESM -2 能够生成包含多达 45 个突变的高回报序列，这些序列与野生型存在显著差异，同时仍保持了增强的预测功能（图3b）。这些结果表明，RLXF 在推动功能创新方面具有显著效果，其效果超越了仅使用预训练模型或进化先验所能达到的水平。

我们观察到每个模型生成的序列存在显著差异，这表明它们优先关注序列空间中的不同区域（图3c及补充图12）。预训练的 VAE 与 ESM -2模型在采样行为上存在一定的重叠，这可能是因为两者均基于天然序列进行训练。相比之下，RLXF 对齐过程——尤其是 SFT 阶段——显著将 ESM -2的采样分布向与高荧光特性相关的区域偏移。PPO阶段则进一步细化了这一聚焦，将采样集中在这些高奖励区域内。为了更好地理解每个模型如何探索序列空间，我们分析了每个位置上生成序列的氨基酸多样性。对齐后的 ESM -2模型始终倾向于采用非天然C43A替换，并引入了一组非天然突变——T7S、R5D、G26T和K112I——这些突变在预训练模型中要么不存在，要么极为罕见（图3d及补充图26–29）。香农熵差异进一步表明，经过对齐处理的 ESM -2 对这些与增强荧光强烈相关的突变做出了熵值较低、因而更具置信度的预测，且除 C43A 外，并未破坏关键的菲avin 结合残基（图3d）。将突变概率映射到 CreiLOV 结构上发现，预训练模型在许多位点上仍保持较低的突变概率，而对齐后的模型则在关键位点上特异性地提高了突变概率，这凸显了 RLXF 对齐后对有益序列空间的更具针对性且更可靠的探索（图3e及补充图 30）。

功能对齐模型可生成高性能 CreiLOV 变体

我们利用预训练模型及功能对齐模型生成的 CreiLOV 序列进行了表征分析，以评估功能对齐是否能提升序列生成质量，并有助于发现具有超出自然界中观察到的特性的变体。我们共选择了 60 种设计：从预训练模型 VAE 中选取 10 种 5 位点突变变体，从对齐后的 VAE 中选取 10 种 5 位点突变变体，从预训练模型 ESM -2 中选取 10 种 5 位点突变变体，从对齐后的 ESM -2 中选取 10 种 5 位点突变变体，从预训练模型 ESM -2 中选取 10 种 10 位点突变变体，以及从对齐后的 ESM -2 中选取 10 种 10 位点突变变体。此外，我们还将 CreiLOV 及已知最亮变体 CreiLOV-T7S³⁴作为对照。我们将这些变体在大肠杆菌 BL21(DE3) 中表达，并测量细胞总荧光强度以评估其功能表现。




图3 | 对齐模型学习生成更多具有荧光特性的CreiLOV变体。 **a** 核密度估计图展示了在每个对齐阶段，由VAE或ESM-2（650M）生成的5个突变设计（ $n = 1000$ ）的预测对数荧光分布。箱线图总结了奖励模型训练、验证及测试序列中，按突变类型分类的预测功能。中心线表示中位数，箱体表示四分位距（第25至第75百分位数），须线延伸至1.5倍四分位距内的最极端值。CreiLOV亲本的预测对数荧光值以虚线表示。 **b** 由SFT或PPO ESM-2（650M）生成的具有不同数量突变的序列设计的获胜率，与预训练的ESM-2（650M）相比。 **c** 基于DMS数据训练的奖励模型所用序列及生成模型采样序列的多维尺度分析（MDS）可视化图。生成模型可外推至DMS数据范围之外，而对齐模型则采样景观中的高荧光区域。 **d**（顶部行）：基于预训练及对齐模型生成的30个序列设计中的突变频率，展示了每个模型在CreiLOV序列特定位置引入突变的概率。（底部行）：基于预训练及对齐模型生成的30个序列设计中计算的香农熵，反映了CreiLOV序列各位置所选氨基酸的多样性。 **e**：将预训练及对齐模型的突变概率映射至由AlphaFold3⁸¹预测的CreiLOV蛋白质结构上。

我们发现，与预训练的模型相比，经过RLXF对齐的模型 consistently 生成了具有增强荧光强度的序列（图4a及补充图31）。来自对齐后的ESM-2模型的5突变体和10突变体设计，在十个采样变体中，其平均荧光强度均较预训练的ESM-2模型有统计学显著增加。所有设计中的荧光值分布呈双峰分布，且围绕CreiLOV荧光强度的69%处存在一个明显的分界点（补充图32）。基于此，我们




图4| 预训练及RLXF对齐的CreiLOV变体的实验表征。a 由预训练及对齐的 VAE 与 ESM-2模型生成的变体相对于CreiLOV的平均荧光强度。每个柱状图代表来自不同菌落的独立生物学重复实验的平均值 ($n = 3$)，各重复实验值叠加显示。误差条表示生物学重复实验的标准差。CreiLOV与T7S以灰色显示。虚线标示CreiLOV及CreiLOV-T7S的平均荧光值。统计显著性通过预训练与对齐模型条件间的双尾t检验确定。b 被归类为低、中、高荧光强度的变体比例。c 荧光强度最高的10个突变体的

AlphaFold3⁸¹结构图，所有10个突变体均以青色高亮显示，FMN辅因子则以珊瑚色显示。d RLXF对齐模型与预训练 ESM-2 (650M) 模型间氨基酸概率的比较，突出RLXF对齐过程中习得的突变偏好。最后一行展示了比对模型与预训练模型之间为非 CreiLOV 氨基酸分配的累积概率差异，从而凸显每个模型在每个位点引入突变的概率。

定义了相对于CreiLOV的三种荧光强度类别：低 (<69%)、中等 (69–100%) 和高 (>100%)。预训练模型生成的序列中，超过80%属于低荧光强度类别，而对齐后的模型则主要选取中等及高荧光强度类别的序列 (图4b)。值得注意的是，来自对齐后的 ESM-2模型的10个5位点突变体中，有6个的荧光强度超过了CreiLOV，其余4个则属于中等类别。对齐后的 ESM-2模型生成了三个荧光强度值高于CreiLOVT7S的序列，后者是目前已知最亮的菲avin结合荧光蛋白 (图4a)。我们还发现，合理组合前5或10个有益单突变³⁴，会产生无功能的变体 (补充图33)。这凸显了 RLXF 模型具备学习协同、上位性突变组合的能力，而这些组合无法通过简单累加单个突变效应来识别。

我们筛选出的前三位 RLXF 生成变体，其总细胞荧光强度均高于 CreiLOV-T7S。总细胞荧光强度取决于多个因素，包括蛋白质表达水平、FMN 结合亲和力与动力学特性，以及固有光学性质，如消光系数和量子产率。因此，我们试图确定这些因素中哪些对 RLXF 变体荧光

强度的提升起到了作用。对固有光物理性质的测定显示，RLXF 变体的量子产率约为 0.6，这一数值高于野生型 CreiLOV，但与 CreiLOV-T7S 相当。由于它们的量子产率与 CreiLOV-T7S 相当，细胞荧光强度的额外提升很可能归因于其他因素，如 FMN 结合能力的增强、发色团负载或成熟效率的提高，以及蛋白质表达量的增加。

RLXF 在很大程度上保留了在 ESM-2 预训练期间习得的突变景观，同时增强了与荧光相关的位点的氨基酸偏好性 (图4c、d)。例如，对齐后的模型将第 43 位点从进化上更青睐的半胱氨酸替换为丙氨酸——这是一种经过合理设计的替换，已知可提升 CreiLOV 的荧光强度。RLXF 还始终优先选择一组高置信度突变 (R5D、T7S、G26T 和 K112I)。最亮型的 RLXF 设计包含 10 个突变，与先前最佳变体 CreiLOV-T7S 相比，其荧光强度提升了 1.2 倍 ($p = 0.02$ ，双尾 t 检验) (图4c)。该变体将这四个高置信度替换与若干排名极低或

在 DMS 数据集中未出现。具体而言, F8I、P16E、E55L、R60K 和 R72I 分别排名第 1376 位、第 105 位、第 330 位、第 53 位和第 986 位, 而 R77K 在 DMS 数据集中则不存在。仅使用单突变指标, 这些突变难以进行优先级排序。综上所述, 这些结果表明, RLXF 利用进化预训练来探索序列多样性, 同时借助实验反馈, 发现能够提升荧光强度的协同且非显而易见的突变组合。

讨论

在本研究中, 我们引入了基于实验反馈的强化学习 (RLXF), 这是一个将蛋白质语言模型与人类定义的函数目标对齐的通用框架。借鉴将大型语言模型与人类偏好对齐的研究进展, RLXF 使用基于实验数据的奖励模型, 引导序列生成朝着预期的生物物理或生化特性发展。我们通过将 RLXF 应用于五种不同的蛋白质系统, 证明了其有效性, 结果表明功能对齐能够持续提升高性能序列的生成能力, 超越预训练模型所能达到的水平。我们使用不依赖氧气的荧光蛋白 CreiLOV 进行了实验验证, 结果显示, 经过功能对齐处理的模型比预训练模型能生成具有更高整体荧光值的功能性序列。这些结果共同表明, 功能对齐可显著扩展蛋白质语言模型的设计能力, 突破自然进化的限制。

奖励模型是将生成式蛋白质语言模型与人类蛋白质工程目标对齐的核心要素。它向生成模型提供反馈, 引导其采样过程倾向于生成具有理想特性的序列。原则上, RLXF 中的奖励模型可以是任何基于序列或结构的评分函数, 包括零样本预测器^{7,44}、进化 Potts 模型^{45,46}、基于 Rosetta 的能量函数^{47,48}、溶解度预测器⁴⁹、免疫原性预测器^{50,51}, 甚至多目标准则。在本研究中, 我们采用基于实验序列-功能数据训练的监督模型, 因为它们能对复杂蛋白质特性提供高度准确的预测^{27,28}。重要的是, 通过直接从实验数据中学习, 这些模型能够引导序列生成朝着预期的功能目标发展, 即使底层生物物理机制尚不十分清楚。

RLXF 采用一个通用 pLM, 该模型最初基于进化序列数据训练, 并为其赋予明确的生化功能概念。我们发现, RLXF 将模型的突变偏好从单纯模仿进化相关序列转向优先考虑由实验功能数据支持的突变。我们对 RLXF-aligned 模型偏好突变的分析表明, 序列比对驱动模型根据奖励模型数据优化序列, 从而在进化约束与实验定义的功能目标之间取得平衡。当预训练的 pLM 先验充分校准时, RLXF 在奖励模型中使用少于 100 个标注的序列变体即可显著提升获胜率。对于先验较弱的蛋白质, 在此低样本量环境下则需要更精细的校准。校准效果可通过生物物理模拟数据提升, 例如此前研究已证实, 使用 Rosetta 衍生的模拟数据集可在低样本量环境下显著改善针对 avGFP 和 GB1 序列变体的微调 ESM-2 模型的预测性能¹¹。综上所述, 这些研究结果共同表明: 对齐质量取决于奖励信号与先验分布——高质量实验数据至关重要, 因为您最终获得的是您所优化的目标; 而精准校准的进化先验则对于可靠地将生成过程导向功能增强具有关键作用。

RLXF 训练的两个阶段——监督微调 (SFT) 和近端策略优化 (PPO)——通过结合定位与受控探索, 共同重塑 pLM。在 SFT 阶段, 模型学习与功能提升密切相关的突变模式, 将其锚定在序列空间中的有利区域。随后, PPO 通过鼓励发现更多有益突变, 以及通过更广

泛的采样和评估来减少对 SFT 训练集的过拟合, 进一步优化模型。这一探索步骤至关重要, 因为仅使用监督微调已被证明会限制生成多样性, 并难以完成分布外生成任务⁵², 这使得 PPO 对于构建稳健且功能对齐的生成模型不可或缺。

与 RLXF 对齐的 ESM-2 模型生成了多个比 CreiLOV 亲本具有更高荧光强度的序列。我们假设, 表现最佳的 10 个突变体通过多种突变的协同组合, 优化了 FMN 辅因子的定位, 同时使整个蛋白质结构在具备荧光能力的构象中更加稳定, 从而实现 1.7 倍的荧光增强。四个核心突变 (R5D、T7S、G26T 和 K112I) 在高性能变体中均一致出现, 这些突变可能稳定了发色团环境, 这与先前研究结果一致——即 T7S 是荧光强度最高的 CreiLOV 变体³⁴。然而, 我们的变体性能优于 CreiLOV-T7S, 这很可能归因于额外的突变 (P16E、F8I、E55L、R60K、R72I 和 R77K), 这些突变在 DMS 数据中单独表现较差, 但通过协同作用进一步增强了细胞内的荧光强度³⁴。结构分析表明, 这些突变并未显著改变 FMN 的位置, 而是减少了口袋中的溶剂化作用, 并略微调整了发色团-蛋白质的氢键网络。值得注意的是, R60K 突变选择性削弱了胍基与 FMN 之间的相互作用, 同时保留了口袋的整体堆积结构。这些 strategically 定位的突变可能使发色团口袋更加刚性化, 从而创造一个更具疏水性的环境, 减少猝灭碰撞, 这一机制与先前关于发色团刚性化可提高量子产率的观察结果相一致。这突显了 RLXF 技术如何能够揭示仅凭单突变体数据难以预测的组合效应。

直接偏好优化 (DPO) 是基于人类反馈的强化学习 (RLHF) 的一种更简单的替代方案, 它无需单独的奖励模型和政策优化⁵³。DPO 不采用强化学习, 而是直接微调模型, 使其偏好被人类反馈评为更高排名的输出。然而, 在自然语言处理领域的复杂生成任务中, RLHF 始终优于 DPO, 因为它允许模型探索并优化超出固定偏好数据集的范围^{54,55}。使用 RLHF 及 PPO 等策略优化方法时, 随着模型采样新输出、接收反馈并不断调整, 训练分布可动态变化, 从而发现原始数据中不存在的更高质量解决方案。这种主动探索与外推的能力, 在优化复杂且映射关系不明确的空间时尤为关键。因此, 尽管与 DPO 相比, 基于 PPO 的 RLHF 计算成本更高且训练稳定性较低, 它仍是训练顶尖基础模型的首选方法。

近期多项研究已将 DPO 应用于将 pLM 与功能目标对齐^{1,20,56-58}。Hie 等人提出了 ProteinDPO, 将 DPO 应用于结构约束的 pLM (ESM-IF1⁵⁹), 以将序列生成与热稳定性的实验测量结果对齐⁵⁶。他们证明, DPO 对齐技术可提升跨多种数据集的稳定性预测性能, 并能推广至结合亲和力预测等新任务, 同时支持在计算机上生成更稳定的蛋白质序列——尽管他们并未对新设计的蛋白质进行实验验证。Stocco 等人开发了 DPO_pLM, 将 DPO 适配于自回归 pLM, 并证实其在优化结构质量与结合亲和力等特性方面的有效性⁵⁷。他们通过设计表皮生长因子受体 (EGFR) 结合剂进行了实验验证, 其中多个结合剂达到了纳摩尔级亲和力和, 显示出相较于野生型配体的功能增强效果。综上所述, 这些研究表明, 基于 DPO 的微调可以提升 pLMs 的功能能力, 尽管探索范围仍局限于可用偏好数据所定义的区域, 这与 PPO 等强化学习方法不同, 后者允许在训练集之外进行主动探索^{52,54,55}。

RLXF 是一个通用框架，可应用于具有不同折叠结构和功能的蛋白质。它对新用户友好，且仅需适度的计算资源即可实现。我们的典型工作流程大约需要 3 天：1 天用于训练奖励模型，1 天通过模拟退火生成适用于 SFT 的高奖励序列数据集，以及 1 天在单个 GPU 上执行 SFT 和 PPO。我们建议训练一个简单的序列到功能奖励模型。在我们的研究中，我们使用了一个由全连接神经网络组成的集成模型，这些网络以独热编码的氨基酸序列作为输入，输出预测的功能评分。我们还建议测试多个不同规模的开源预训练 pLM，以找出最适合功能对齐的基础模型。在我们的实验中，ESM-2（650M）模型通常取得了最佳的整体性能，尽管最佳模型规模因具体蛋白质系统而异。无论模型规模如何，我们强烈推荐使用参数高效微调方法，因为在 SFT 和 PPO 训练过程中，这些方法均能减少预训练模型知识的灾难性遗忘，其性能始终优于全参数微调。

功能对齐的 pLMs 日益取得的成功，标志着一种更广泛的转变：从被动提取天然序列中编码的信息，转向主动、实验性地引导生成模型朝着人类定义的工程目标发展^{1,2,20,56,57,60–62}。RLXF 提供了一个通用且灵活的框架，可将 pLMs 与几乎任何可测量的属性对齐，从而快速生成多样化的高适配度序列库。展望未来，RLXF 及相关方法可整合到迭代式多目标工作流程中，在这些流程中，模型通过自主运行实验室中的实验反馈持续优化^{63,64}。通过将预训练模型的强大能力与实验反馈相结合，我们有望开拓序列空间的广阔疆域，设计出具有全新功能的蛋白质——这些功能远超自然进化所能产生的产物。

方法

奖励模型的数据整理

我们使用了一个广泛的 CreiLOV DMS 数据集³⁴来训练奖励模型。训练集包含 2204 个单突变体（覆盖度 92.6%）、176 个双突变体、978 个三突变体以及 3565 个四突变体。对于 9603 个五突变体，验证集和测试集均采用 75/25 的数据划分方式进行构建。对于旨在指导不同蛋白质类别中 ESM-2 序列对齐的奖励模型，我们也采用了类似的数据划分方式（见补充表 2）。

奖励模型训练

我们使用固定的训练集、验证集和测试集划分，训练了 100 个多层感知机，以监督方式利用均方误差（MSE）损失函数预测 CreiLOV 序列变体的对数平均荧光强度。每个集成模型中的多层感知机均使用不同的种子值进行初始化。输入序列经过 one-hot 编码处理。每个多层感知机奖励模型的超参数均相同（见补充表 3）。

VAE 的数据整理

我们从蛋白质数据库 UniRef90⁶⁵中利用隐马尔可夫模型同源搜索工具 Jackhmmer⁶⁶筛选出 260,349 条与 CreiLOV 相关的天然序列，从而获得一个包含与 CreiLOV 相关蛋白质的多序列比对（MSA），最多进行 2 次迭代（N=2）。我们剔除了长度小于 CreiLOV⁴⁴的 75% 的序列、连续出现 10 次相同氨基酸的序列，以及 MSA 中不与 CreiLOV 对应的位点³⁰。随后，我们将剩余 243,682 条序列中汉明距离/序列长度大于 0.98 的邻近序列重新加权，以减少因采样不均导致的系统发育偏差^{44,67,68}。鉴于这些序列未标注，我们从重新加权的 MSA 中剔除 100 条序列，将其作为伪测试集，用于后续评估 VAE 对训练集的过拟合情况。最后，

我们将剩余的 243,582 条序列以 90/10 的比例随机划分为训练集与验证集。

VAE 预训练

VAE 是通过最大化一个改进版的证据下界（ELBO）来训练的，该改进版有效最小化了变分近似与真实后验分布之间的 Kullback–Leibler 散度⁴⁴，如等式 1 所示：

$$\text{ELBO} = \mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x|z)] - \beta D_{KL}(q_{\phi}(z|x) || p(z)) \quad (1)$$

第一项可视作为一种重构损失，该损失是通过输入独热编码序列与输出似然值之间的交叉熵计算得出。 β 是对 Kullback–Leibler 散度项 D_{KL} 的权重系数，其先验分布为 $N(0, I)$ 。超参数通过包含 673 种组合的网格搜索进行优化（见补充表 8）。

生成监督微调序列数据集

我们通过改编文献²⁸中的代码，借助 100 次模拟退火模拟，生成了用于监督微调的序列数据集。根据我们的奖励模型，我们设计了具有固定突变次数及高预测功能的变体。在模拟退火的每一步中，我们每次从泊松分布（ $\lambda=1$ ）中采样 2 个突变，并受限于允许的突变总数。我们采用奖励模型集合中第 5 百分位数的保守评分来预测变体的功能：能增强功能的突变被自动接受，其余突变则根据等式 2 计算概率后接受。

$$\text{接受概率} = \exp(\Delta \text{function}/T) \quad (2)$$

其中，T 随对数温度梯度递减，该梯度的选择标准为：对于不提升功能的突变，初始接受概率接近 40%，以促进早期探索；而在 50,000 步运行结束时，接受概率趋近于 0%（见补充表 5）。我们从各次试验的最终序列中剔除重复序列，最终获得用于监督微调的序列数据集。

监督微调 ESM-2

我们使用标准的掩码语言建模（MLM）目标函数对 ESM-2 进行了监督微调。在 C43A⁴³突变之前，我们对序列数据集中每个序列的位点进行掩码处理，掩码位点相对于天然 CreiLOV 序列进行设定。在训练过程中，我们计算掩码残基的交叉熵损失，以最小化等式 3：

$$L_{\text{cross-entropy}} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^M y_{ij} \log(p_{ij}) \quad (3)$$

其中 N 表示小批量中被掩码位置的总数，M 表示 ESM-2 分词器所用氨基酸词表的大小，y 表示被掩码位置 i（token j）处真实氨基酸的独热指示变量，p 则是 ESM-2 对该氨基酸的预测概率。

我们在 ESM-2（650M）模型的语言模型头部、最后一个 Transformer 块以及倒数第二个 Transformer 块的 LayerNorm 权重与偏置参数上进行了训练，其余参数则保持冻结。我们使用 Adam 优化器，基础学习率为 0.00511，权重衰减率为 0.00351。我们将参数划分为语言模型头部和 Transformer 层特定参数组，初始值采用基础学习率，随后每个连续参数组的衰减系数为 0.89。我们将 Adam 优化器封装在 CosineAnnealingWarmRestarts 调度器中（ $T_0=10$, $T_{\text{mult}}=1$ ），在单轮训练中使用批大小为 8。我们应用了梯度范数裁剪，最大范数为 3。超参数通过 Optuna⁶⁹选定。

在使用 Tree-Parzen 估计量 (TPE) 采样器及一个自定义 PyTorch 回调函数 (当模型参数在每个小批量训练后变为非有限值——即 NaN 或无穷大时终止试验——见补充表 6) 进行 1000 次超参数优化后。

采用顶部 p 值采样阈值生成序列变体

我们分两个独立步骤生成序列变体, 旨在模拟定向进化实验的操作流程。首先, 我们逐个位点对 CreiLOV 进行掩蔽处理, 并计算每个位点上各氨基酸出现的概率; 若任一非天然氨基酸的出现概率超过预设的高置信度阈值, 则将该突变引入所有序列变体中。随后, 我们再次逐个位点对已含高置信度突变的 CreiLOV 进行掩蔽处理, 并重新计算各位点上各氨基酸的出现概率。接着, 我们统计每个位点上非天然突变概率的总和, 并依据该累积概率对位点进行加权采样。为规避采样可能不利于功能优化的位点, 我们采用第二个累积概率阈值进行筛选。对于每个被选中的位点, 我们根据各氨基酸 (包括天然氨基酸) 的出现概率进行加权采样。如此迭代采样, 直至获得预期数量的突变体。

近端策略优化

我们的 PPO 实现使用了两个 SFT ESM-2 副本或预训练的 VAE 权重。其中一个副本保持冻结, 而另一个模型则拥有可训练参数。根据强化学习术语, 在本节中我们将这个可训练的生成模型称为策略。近端策略优化依赖于对等式 4 中裁剪后的代理目标函数的最小化:

$$L_{CLIP}(\theta) = \mathbb{E}_t \frac{1}{2} \min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \quad (4)$$

其中, 概率比 $r_t(\theta)$ 是在可训练策略 π_θ 与冻结模型 $\pi_{\theta_{ref}}$ 之间计算得出, ref 如等式 5 所示:

$$r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{ref}}(a_t|s_t)} \quad (5)$$

其中, 该比值用于比较冻结模型与策略模型在策略模型于状态 s_t 下采样的 a_t 对应的概率。等式 4 中的超参数 ϵ 为概率比值设定了一个悲观界, 以防止模型更新幅度过大, 并有助于平衡探索与利用。我们的总奖励 $R(x, y)$ 通过等式 6 计算得出:

$$R(x, y) = r_\theta(x, y) + \gamma H(x, y) - \beta D_{KL}(x, y) \quad (6)$$

其中, 引导策略的源序列为 x , 而经过采样氨基酸突变后的序列变体为 y 。

我们针对“学习生成具有功能增强性突变且相对于亲本序列的蛋白质序列变体”这一特定任务, 对预测的功能奖励 $r_\theta(x, y)$ 进行归一化处理。与 GRPO^{70,71} 类似, 我们并不依赖评判模型⁷²来估计 $\hat{A}_t$ 。在本研究中, 我们改为通过为同一父序列 x 生成多个序列变体, 并将该父序列作为群体基线, 从而降低用于策略梯度的预测奖励方差, 以此估算 $\hat{A}_t$ 。首先, 我们采用与生成序列变体时相同的采样策略 (基于 top- p 采样阈值), 将策略知识融入流程, 以聚焦探索更有可能增强功能的突变。对于每个序列变体, 我们利用奖励模型集成结果的第 5 百分位数计算一个保守的预测函数奖励值; 随后对批次内所有保守预测函数奖励值取最大值, 以此作为生成具有增强功能的序列变体的策略状态

估计值。最后, 我们将该归一化奖励值除以父序列的预测函数值。

为此, 我们发现这些简化处理使我们能够利用 $R(x, y)$ 估计 $\hat{A}_t$, 并提升 PPO 后对序列变体的预测函数性能。针对每批生成的序列变体, 我们采用等式 7 计算平均成对汉明距离项 $H(y)$, 以促进生成多样化的序列:

$$H(x, y) = \frac{2}{B(B-1)} \sum_{i \neq j} \sum_{k=1}^L \mathbb{I}[y_k^{(i)} \neq y_k^{(j)}] \quad (7)$$

其中 B 表示批次中生成的序列变体数量, L 表示变体序列的长度, 且 $\frac{B(B-1)}{2}$ 表示唯一配对的数量。我们将平均成对汉明距离项以系数 γ 进行加权。为防止策略相对于冻结模型发生剧烈变化, 我们采用等式 8 计算策略与冻结模型之间的 Kullback-Leibler 散度惩罚项 D_{KL} :

$$D_{KL}(x, y) = \log \frac{\pi_\theta(y|x)}{\pi_{\theta_{ref}}(y|x)} \quad (8)$$

其中 y 是父序列提示 x 生成的序列变异。在对齐 ESM-2 时, 我们在训练前, 对每个父序列位置进行迭代掩码处理, 以生成基于冻结模型的单个氨基酸突变的对数概率。这一耗时计算需要对父序列提示的每个位置进行一次前向传播, 但无需在冻结模型上重复此操作。我们在 PPO 的每个训练周期中, 为可训练策略重新计算了对数概率。我们采用此方法简化并加速了每个训练周期中 D_{KL} 的计算过程。我们将该项以系数 β 加权。

我们用于对齐掩码语言模型目标 pLM ESM-2 的 PPO 变体可概括为以下步骤:

1. 迭代地掩蔽父序列中的位点, 并针对每个位点上的氨基酸采用冻结策略生成氨基酸对数概率。
2. 迭代地掩码父序列中的各位置, 并利用针对每个位置可训练的氨基酸策略生成相应氨基酸的对数概率。
3. 计算 D_{KL} , 即步骤 1 与步骤 2 所得对数概率之间的散度。
4. 根据可训练策略, 将亲本序列中氨基酸突变概率高于高置信度阈值的所有位点进行掩码处理, 并基于该策略及冻结模型为这些位点生成氨基酸概率分布。
5. 将高置信度氨基酸添加到母序列中。
6. 迭代地用高置信度突变位点对变异序列进行掩码处理, 并利用针对每个位点氨基酸的可训练策略生成氨基酸对数概率。
7. 计算每个位点上氨基酸突变的累积概率。
8. 对于批次中的每个序列, 使用累积概率权重迭代采样位点, 并利用策略模型与冻结模型生成对数概率值。随后, 根据策略模型, 按采样位点上各氨基酸的出现概率对氨基酸进行加权采样。重复上述过程, 直至引入指定数量的突变。
9. 针对在步骤 4 至 8 中获得的对数概率的序列变体中存在的氨基酸突变, 计算比值 $r_t(\theta)$ 。
10. 根据序列变体计算总奖励 $R(x, y)$ 。
11. 计算 $L_{CLIP}(\theta)$ 。
12. 通过在对可训练策略参数进行梯度下降时, 最小化 $L_{CLIP}(\theta)$ 。

13. 若在一个训练周期内迭代次数大于1, 则重复步骤4、8、9、11和12, 通过对可训练策略参数进行梯度下降, 并利用更新后的 $r_t(\theta)$, 以最小化 $L_{CLIP}(\theta)$ 。
14. 对 PPO 的每个 epoch 重复执行步骤2–13。

当通过 PPO 对齐 aVAE 时, 我们会递归地将高斯噪声 $N(0, \sigma^2)$ 添加到父序列的均值潜在表示中, 以确定在每轮训练开始时生成一批具有指定突变数量的序列变体所需的方差。我们考虑来自可训练和冻结的 VAE 策略所生成的小批量序列变体的似然矩阵, 用以计算 D_{KL} 。这些似然矩阵的尺寸为 $21 \times L$, 其中 21 表示序列位置可能包含的 20 种氨基酸及间隙标记的数量, L 则表示父序列提示的长度。我们从可训练的 VAE 策略中采样似然矩阵的每一列, 从而生成一批中的每个序列变体。

我们实现了一种参数高效的近端策略优化方法, 通过在语言模型头部、最后一个 Transformer 块, 以及 ESM-2 (650M) 模型中倒数第二个 Transformer 块的 LayerNorm 和密集输出权重与偏置参数中进行训练, 同时冻结 ESM-2 的其他参数, 以保留对分布外生成任务至关重要的 ESM-2 预训练知识⁷³。从第一个训练周期起, 我们解锁了更多参数, 将语言模型头部及最后5个 Transformer 块中的参数纳入优化范围。该策略借鉴自近期的一项研究, 即对 ESM-2 进行微调¹。我们使用 Adam 优化器, 基础学习率为 0.00866, 权重衰减率为 0.00995。我们将参数划分为特定层级的组别, 初始学习率与基础学习率相同, 随后以 0.885 的系数递减, 为每个后续组别分配相应学习率。我们将 Adam 优化器封装于 CosineAnnealingWarmRestarts 调度器中 ($T_0=1$, $T_{mult}=2$), 在 2 个训练周期内运行, 初始批次大小为 1, 每轮训练周期递增 1。此外, 我们还应用了梯度范数裁剪, 最大范数为 6.82, 并采用指数移动平均法对参数进行平滑更新。计算 $L_{CLIP}(\theta)$ 时, 我们使用了以下超参数: $\epsilon = 0.174$, $\gamma = 1.0e^{-6}$, β_1 (首轮训练) = $1.0e^{-8}$, β_2 (后续训练) = $1.0e^{-7}$ (7,9)。

为 EVE 模型筛选多序列比对结果

遵循 EVE⁷⁴ 存储库工作流程 (<https://github.com/OATML-Markslab/EVE>), 我们使用 Jackhmmer 对 UniRef100 进行迭代性谱系-HMM 同源搜索, 并采用 EVCouplings^{75,76} 流程 (<https://github.com/debbiemarkslab/EVCouplings>) 生成多序列比对 (MSA)。我们保留了与目标序列长度至少匹配 50% 的同源序列, 并过滤比对列, 要求残基占据率 $\geq 70\%$ 。为为每个蛋白质选择最终 MSA, 我们探索了多种阈值范围, 优先选择具有高目标覆盖率和足够深度的比对结果, 优先考虑覆盖度 $L_{cov} \geq 0.8L$ 且总序列数 N 满足 $10L \leq N \leq 100,000$ 的配置, 这与 EVE 指南一致 (补充表 10)。

训练 EVE 模型

针对每种蛋白质, 均按照 EVE⁷⁴ 存储库工作流程 (GitHub 仓库: <https://github.com/OATML-Markslab/EVE>) 训练 EVE 模型。

从 TranceptEVE 中提取进化密度特征。

为了在多个蛋白质家族中一致地呈现这一进化特征, 我们采用了 TranceptEVE⁷⁷——该模型在 ProteinGym 数据集⁷⁸上, 基于序列的基准模型中取得了最佳的平均 Top-10% 召回率。TranceptEVE 将无家族依赖性的自回归 pLM 模型 Tranception⁷⁹ 的输出与家族特异性 EVE 模型相结合, 并在推理阶段利用多序列比对 (MSA) 检索。我们为每个蛋白质从 UniRef100 数据库中提取 MSA 数据, 训练出家族特异性 EVE 模型, 并将这些模型与 Tranception 整合, 从而为每个蛋白质构建出 TranceptEVE 模型。我们按照

等式 9 所述, 使用 TranceptEVE 计算了进化密度特征:

$$F(x) = \log P_{\text{TranceptEVE}(x_{\text{mut}})} - \log P_{\text{TranceptEVE}(x_{\text{wt}})} \quad (9)$$

每个位点的对数似然值是通过以下三种方式获得的: 一是采用 Tranception S⁷⁹ (<https://github.com/OATML-Markslab/Tranception>) 中的对数似然函数 $\log PT(x_i | x_{<i})$; 二是采用我们训练过的蛋白质家族特异性 EVE 模型中的 $EVE(x_i)$ ——该模型通过将获取 MSA 的野生型序列输入 VAE, 然后对解码器网络在近似后验分布及解码器参数分布上生成的对数 softmax 输出结果, 基于大量样本进行平均计算而得, 如前文所述; 三是采用从检索到的 MSA 中每个位点上的氨基酸分布获得的 $\log P_{\text{MSA}}(x_i)$, 具体如等式 10 所述。

$$F(x) = (1 - \alpha_p)^{1/2} (1 - \beta_p) \cdot \log P_T(x_i | x_{<i}) + \beta_p \log P_{\text{MSA}}(x_i) + \alpha_p \log P_{\text{EVE}}(x_i) \quad (10)$$

常数 α_p 与 β_p 的取值取决于 MSA 深度, 具体如先前文献⁷⁷中所建议。

增强型岭回归奖励模型的数据整理

我们使用了相同的训练集、验证集和测试集来训练用于引导 ESM-2 在多种蛋白质类别中对齐的奖励模型 (见补充表 2)。我们通过以多种目标大小从完整训练集中均匀采样来构建训练子集, 同时保持测试集不变。对于每个目标训练大小, 我们生成了 10 个独立重复样本。

训练增强型岭回归奖励模型

我们训练了增强型岭回归奖励模型, 以从序列同一性特征与基于 TranceptEVE 衍生的进化密度特征的组合中预测实验功能评分, 具体方法如先前文献⁷⁷所述。每个序列变体均采用氨基酸同一性的逐位独热编码表示, 并附加一个单一连续进化特征²⁹。岭回归最小化等式 11 中的目标函数:

$$L = \sum_i^n (y_{i, \text{actual}} - y_{i, \text{predicted}})^2 + \lambda \sum_j^m w_j^2 \quad (11)$$

其中 n 表示训练样本数量, m 表示特征数量, w_j 为模型系数。模型均在 scikit-learn 中实现, 惩罚强度设为 $\lambda=1$ 。为调节进化特征的相对贡献度, 当每个训练子集内至少包含五个训练样本时, 我们在该子集内执行 5 折交叉验证。通过最大化各折间平均斯皮尔曼相关系数, 我们从 10^{-3} 、 10^{-4} 、 5×10^{-5} 、 10^{-5} 中选取进化特征缩放/正则化设置, 随后使用所选设置在完整训练子集上重新训练最终模型。

采用增强型脊回归奖励模型的低-N RLXF

对于低 N 值功能比对, 我们使用了 10 个增强岭回归模型中的 3 个, 这些模型分别使用每种蛋白质对应的 10、100、200、500 或 1000 种组合变体进行训练。与我们之前描述的比对流程相比, 唯一的修改在于构建 SFT 训练数据集。我们从已训练的岭回归模型中提取出权重最高的前 40 个非野生型氨基酸替换 (排除终止密码子), 枚举所有可能的 5 位点组合突变变体, 并使用 TranceptEVE 对候选变体进行评分, 以获取岭回归模型所需的进化密度特征。随后, 我们使用相同的岭回归模型对候选变体重评分, 最终筛选出 150 个高评分变体。为了减少冗余, 我们采用基于

归一化汉明距离的贪心最远点选择算法，精选出25个多样化的序列变体子集。这些精选变体被用作 SFT 训练数据集。SFT 优化及所有PPO流程（策略参数化、rollout 策略、奖励计算及超参数设置）均与我们主要的 RLXF 比协议相同，仅将增强后的岭回归模型作为相应重复实验中的PPO奖励函数。

计算 SFT 与 PPO 之间 pLM 先验分布的偏移，以及对预训练 pLM 先验分布的校准。为了量化 RLXF 如何改变序列先验，我们在对齐的每个阶段从 ESM-2 对数概率中计算了一组校准与分布偏移指标。对于每个蛋白质野生型序列 $x = (x_1, \dots, x_L)$ ，我们使用公式12中的伪对数似然评分计算了掩码位置对数概率，并使用公式13中无需掩码的单次前向传播计算了全序列对数概率。

$$p_i^{\text{mask}}(t) = \text{softmax}(\ell_i^{\text{mask}})_t \quad (12)$$

$$p_i^{\text{full}}(t) = \text{softmax}(\ell_i^{\text{full}})_t \quad (13)$$

其中， $l_{\text{mask}i}$ 与 $l_{\text{full}i}$ 分别是位置 i 上在分词器词汇表 V 上对应的逻辑值。评估指标要么基于野生型序列 ($k=0$) 计算，要么沿高置信度突变轨迹 $\{x^{(k)}_{k=0}\}$ 计算，其中 $x^{(k)}$ 包含概率超过固定阈值 p_{fixed} 的前 (k) 个替换位点，该阈值源自 RLXFaligned ESM-2。下文中的 a 表示 20 种标准氨基酸。

对于每个阶段（预训练、SFT、对齐），我们基于高置信度突变轨迹 $\{x^{(k)}\}_{k=0}$ ，计算了等式14、15、16及17中的各项指标。这使我们能够量化：随着越来越多高置信度替换被引入，局部分布与校准如何演变；以及在相同突变条件下，SFT 与 PPO 如何相对于预训练模型调整先验分布。为量化模型局部残基分布相对于参考阶段的偏移程度，我们在等式14中计算了每个位点上仅含氨基酸的掩码分布之间的余弦相似度，并取所有位点的平均值：

$$\text{Cosine similarity} = \frac{1}{L} \sum_{i=1}^L \cos(\hat{p}_{i,s}^{\text{mask}}, \hat{p}_{i,\text{ref}}^{\text{mask}}) \quad (14)$$

其中 $\hat{p}_{i,s}^{\text{mask}} \in \mathbb{R}^{|A|}$ 是源自等式12的掩码分布，且仅限于氨基酸 A 。值接近 1 表示分布偏移极小，而较小值则表示相对于参考阶段分布的偏离程度更大。

我们采用等式15中所有氨基酸的平均位置熵，在掩码推断下测量了局部不确定性：

$$H_A^{\text{mask}}(x) = \frac{1}{L} \sum_{i=1}^L \left[- \sum_{a \in A} \hat{p}_i^{\text{mask}}(a) \log \hat{p}_i^{\text{mask}}(a) \right] \quad (15)$$

其中 $\hat{p}_{\text{mask}i}$ 由限定于氨基酸 A 的等式12推导得出。熵值越高，表示残基不确定性越广；熵值越低，则表示残基偏好性越明确。

为量化分布锐度，我们根据等式16计算了每个位点的平均最大氨基酸概率：

$$\text{Max Probability}_A^{\text{mask}}(x) = \frac{1}{L} \sum_{i=1}^L \max_{a \in A} \hat{p}_i^{\text{mask}}(a) \quad (16)$$

其中 $\hat{p}_{\text{mask}i}$ 由等式12推导得出。数值越大，表示分布越尖锐。

我们利用等式17，根据每个位点上观测残基的掩码伪对数似然值，计算了伪困惑度：

$$\text{PP}(x) = \exp \left[- \frac{1}{L} \sum_{i=1}^L \log p_i^{\text{mask}}(x_i) \right] \quad (17)$$

其中 $p_{\text{mask}i}$ 的定义见等式12。较低的伪困惑度意味着在掩码推断下野生型的似然度更高，因而对应更强的校准先验。

为量化野生型残基是否在掩码推断下的前 K 个预测结果之列，我们计算了等式18。

$$\text{Top K Wildtype Retention Probability} = \frac{1}{L} \sum_{i=1}^L \mathbf{1}[x_i \in \text{TopK}(p_i^{\text{mask}})] \quad (18)$$

其中 $\text{TopK}(p)$ 根据等式12返回概率最高的 K 个标记。我们针对 $K \in \{1, \dots, 20\}$ 计算了该指标。此外，我们还根据等式19，将掩码推断与完整推断相比时野生型残基的排名变化，计算了野生型排名差距：

$$\text{Rank Gap} = \frac{1}{L} \sum_{i=1}^L [\text{rank}(x_i; p_i^{\text{mask}}) - \text{rank}(x_i; p_i^{\text{full}})] \quad (19)$$

其中 $\text{rank}(x_i; p)$ 表示在按概率 p 对标记进行排序时， x_i 的 0 起始秩次（秩次 0 对应最高概率），而 $p_{\text{mask}i}$ 与 $p_{\text{full}i}$ 的定义见公式12与13。正值表示掩码处理平均会降低 WT 秩次。

我们采用自洽性间隙来量化对掩码的敏感性，该指标定义为在完整推断与掩码推断条件下，野生型对数概率的差值，如等式20所示：

$$\text{SCG}(x) = \frac{1}{L} \sum_{i=1}^L [\log p_i^{\text{full}}(x_i) - \log p_i^{\text{mask}}(x_i)] \quad (20)$$

其中 $p_{\text{full}i}$ 与 $p_{\text{mask}i}$ 的定义见公式12和13。SCG 值越大，表明模型对全局背景的依赖越强，或缺乏对局部演化的理解。

为量化掩码处理下不确定性的增加幅度，我们计算了熵膨胀值——即在整个词汇表 V 上掩码处理后的熵与完整熵之差——并代入等式21计算该差值：

$$\Delta H(x) = \frac{1}{L} \sum_{i=1}^L [H(p_i^{\text{mask}}) - H(p_i^{\text{full}})] \quad (21)$$

其中，标记分布熵如等式22所示：

$$H(p) = - \sum_{t \in V} p(t) \log p(t) \quad (22)$$

此处， $p_{\text{mask}i}$ 与 $p_{\text{full}i}$ 分别由公式12与13定义。 ΔH 值越大，表明掩码处理对模型置信度的破坏程度越高。

直接偏好优化

为与强化学习术语保持一致，在本节中我们将可训练的生成模型称为策略。直接偏好优化依赖于对等式23中目标函数的最小化：

$$L_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l) \sim D} \log \sigma(\beta \log \frac{p_{\theta}(y_{\text{preferred}}|x)}{p_{\theta, \text{ref}}(y_{\text{preferred}}|x)} - \beta \log \frac{p_{\theta}(y_{\text{rejected}}|x)}{p_{\theta, \text{ref}}(y_{\text{rejected}}|x)}) \quad (23)$$

其中 θ 为具有可训练参数的策略， θ_{ref} 为预训练模型， β 为超参数，用于确定策略模型相对于预训练模型的权重， x 表示预处理序列数据集 D

中的一个批量序列, y 表示该小批量序列中根据实验函数被标记为偏好或拒绝的序列标签。 $L_{DPO}(\theta, \theta_{\text{ref}})$ 比较策略模型与预训练模型的对数似然值, 并微调策略参数, 以增大偏好序列相对于拒绝序列的比率。对于序列数据集 D , 我们根据每个突变机制的实验荧光值³⁴, 将奖励模型训练数据划分为拒绝序列与偏好序列。为缩短训练时间, 我们预先计算了整个序列数据集在预训练模型下的对数似然值——该值在整个训练过程中保持不变。我们采用文献^{56,57}中提供的两组超参数, 实现了直接偏好优化。

计算相关性

我们使用实验性对数荧光值³⁴及常用评分方法⁷⁸, 与采用奖励模型测试集中序列的对齐 ESM-2 和 VAE 模型 (补充表2), 计算了前10%的召回率及Spearman秩相关系数。掩码边缘分数⁷通过等式24计算得出:

$$\text{masked marginal} = \sum_{i \in M} [\log p(x_i = x_i^{\text{mt}} | x_M) - \log p(x_i = x_i^{\text{wt}} | x_M)] \quad (24)$$

其中 M 表示突变位点的集合, x^{wt} 表示未发生氨基酸突变的父代序列, x^{mt} 表示在位置 i 处发生氨基酸突变的序列, 而 x_M 表示在位置 i 处设置掩码的序列, 该掩码用于标识 x^{mt} 相对于 x^{wt} 发生的突变。突变边缘分数⁷同样可通过等式25计算得出:

$$\text{mutant marginal} = \sum_{i \in M} [\log p(x_i = x_i^{\text{mt}} | x^{\text{mt}}) - \log p(x_i = x_i^{\text{wt}} | x^{\text{mt}})] \quad (25)$$

其中 x^{mt} 是一个未掩码氨基酸突变的序列。我们利用等式26计算伪困惑度 $PP(x)$ ^{3,80}:

$$PP(x) = \exp \left[-\frac{1}{L} \sum_{i=1}^L \log p(x_i | x_{j \neq i}) \right] \quad (26)$$

其中 L 表示序列的长度, $p(x_i | x_{j \neq i})$ 表示在给定序列中其他氨基酸 $x_{j \neq i}$ 的条件下, 第 i 位出现氨基酸 x 的概率。对于 VAE 模型, 我们使用等式27计算对数比值^{44,45}:

$$\text{logratio}(\theta) = \log \frac{p(x_{\text{mutant}} | \theta)}{p(x_{\text{wildtype}} | \theta)} \quad (27)$$

其中 x 表示突变体或野生型序列, θ 表示 VAE 参数。

序列变体的体内表征

为在体内评估模型设计, 所有设计 (包括野生型CreiLOV及CreiLOV-T7S) 均从Twist Bioscience公司订购为克隆型pET-28a (+) 载体构建体, 同时订购空载体pET-28a (+) 作为基线对照。所有构建体均按标准热激方案转化至大肠杆菌BL21(DE3)感受态细胞 (Thermo Scientific, 货号EC0114) 中, 接种于含50 $\mu\text{g/mL}$ 硫酸卡那霉素 (Sigma-Aldrich, 货号K4000) 的LB琼脂平板, 37 °C培养过夜。挑取单菌落, 接种至含50 $\mu\text{g/mL}$ 卡那霉素的2 mL LB起始培养液中, 于37 °C、225 rpm轨道振荡条件下培养过夜。取2 μL 各浑浊菌液样本 (含野生型及空载体), 分别接种至黑色光学底面96孔板 (Thermo Scientific, 货号237105) 的独立孔

内, 每孔加入200 μL 含50 $\mu\text{g/mL}$ 卡那霉素的LB培养基。将培养板置于Agilent Biotek Synergy H1酶标仪中, 自动调节增益与Z轴位置 (分别为142与4.75 mm), 激发与发射带宽均设为9 nm。酶标仪设置为37 °C, 轨道摇床转速设为237 cpm, 所有孔均培养至OD600 nm值约为0.5, 每30分钟读取一次A600 nm值。达到预期汇合度后, 所有孔均用0.5 mM IPTG (Gold Biotechnology, 目录号12481C) 诱导, 然后重新放入酶标仪中。细胞继续培养210分钟, 每30分钟读取一次A600值; 此时, 酶标仪使用450 nm激发波长和495 nm发射波长测量每个孔的荧光强度。我们采用等式28计算每个设计相对于野生型CreiLOV的荧光强度:

$$\frac{\left(\frac{\text{Design F495}}{\text{Design OD600}} - \frac{\text{Empty Plasmid F495}}{\text{Empty Plasmid OD600}} \right)}{\left(\frac{\text{Wildtype F495}}{\text{Wildtype OD600}} - \frac{\text{Empty Plasmid F495}}{\text{Empty Plasmid OD600}} \right)} \quad (28)$$

为确保实验测量结果的一致性, 本研究采用与上述相同的酶标仪参数进行了三次生物学重复实验。实验结果以这些测量值的平均值及该平均值的标准误表示。

序列变体的体外表征

为了在体外表征模型设计, 所有设计 (包括野生型CreiLOV和CreiLOV-T7S) 均作为克隆型pET-28a (+) 构建体订购, 这些构建体均带有来自Twist Bioscience的C端Hisx8标签。表达与纯化主要参照Chen2021AC-SSynBio中所述方法进行。简言之, CreiLOV构建体在E. coli BL21(DE3) 细胞中, 于37 °C下表达3小时, 诱导条件为向培养基中加入终浓度为0.5 mM的IPTG, 直至600 nm处光密度达到0.4–0.6。细胞裂解后, 使用HisPur NiNTA树脂 (Thermo Scientific) 纯化蛋白, 并在缓冲液交换至测定缓冲液 (25 mM TrisHCl pH 9.0, 1 M 氯化钠) 中。

在量子产率测定实验中, 将按A450值标准化的200 μL 蛋白溶液加入96孔微孔板中。样品置于Agilent公司BioTek Synergy H1微孔板读数仪内, 于450 nm波长处激发。记录480–610 nm范围内的发射光谱, 以空白对照读数的平均值进行扣除后积分。量子产率计算方式为: 将积分面积除以WT CreiLOV组的平均积分面积, 再乘以文献报道的WT菌株量子产率值0.47。

报告摘要

有关研究设计的更多信息, 请参阅本文附带的《Nature Portfolio》研究报告摘要。

数据可用性

本研究使用了六组先前发表的深度突变扫描数据集。GB1、GFP、Ube4B、Bgl3 和 Pab1 数据集均取自先前一篇论文中汇编的数据集[<https://www.pnas.org/doi/10.1073/pnas.2104878118>]²⁷ 及其关联的 GitHub 代码库 [https://github.com/gitter-lab/nn4dms/tree/master/data]; CreiLOV 数据集则取自 Chen 等人论文[https://pubs.acs.org/doi/10.1021/acssynbio.2c00662]³⁴ 中的数据集 S1 与 S2。本研究中生成的所有荧光测量数据、量子产率测量数据及序列设计均已发布于遵循 Apache License 2.0 协议的公共 GitHub 代码库[https://github.com/RomeroLab/RL-XF]。经训练的 CreiLOV RLXaligned ESM-2 模型权重可通过 Hugging Face 平台获取, 遵循 Apache License 2.0 协议[https://huggingface.co/RomeroLab/Duke/creilov-rlxf-esm2-650m]。原始数据已随本文一同提供。

代码可用性

运行 RLXF 的所有代码均可在公开的开源 GitHub 代码库中获取: [<https://github.com/RomeroLab/RLXF>] 本代码基于 Apache 2.0 许可证发布, 并已上传至 Zenodo 平台[<https://doi.org/10.5281/zenodo.21420321>].

参考文献

- Hayes, T. 等。利用语言模型模拟 5 亿年的演化过程。《科学》杂志 387, eads0018 (2025)。
- Bhatnagar, A. 等人。规模化技术拓展了蛋白质的生成范围, 并深化了对蛋白质功能的理解。预印本见 <https://doi.org/10.1101/2025.04.15.649055> (2025)。
- Lin, Z. 等。利用语言模型进行原子级蛋白质结构的进化尺度预测。《科学》杂志 379, 1123–1130 (2023)。
- Chowdhury, R. 等。基于语言模型与深度学习的单序列蛋白质结构预测。《自然·生物技术》40, 1617–1623 (2022)。
- Elnaggar, A. 等。ProtTrans: 通过自监督学习探索生命语言。IEEE Trans. Pattern Anal. Mach. Intell. 44, 7112–7127 (2022)。
- Unsal, S. 等。利用语言模型学习蛋白质的功能特性。《自然·机器学习》4, 227–245 (2022)。
- Meier, J. 等。语言模型可实现对突变对蛋白质功能影响的零样本预测 https://proceedings.neurips.cc/paper_files/paper/2021/hash/f51338d736f95dd42427296047067694-Abstract.html (2021)。
- Su, J. 等。SaProt: 基于结构感知词汇表的蛋白质语言建模。预印本发布于 <https://doi.org/10.1101/2023.10.01.560349> (2024)。
- Alley, E. C., Khimulya, G., Biswas, S., AlQuraishi, M. & Church, G. M. 基于序列深度表征学习的统一理性蛋白质工程。《自然·方法》16, 1315–1322 (2019)。
- Hie, B. L., Yang, K. K. & Kim, P. S. 基于蛋白质语言模型的进化速率可预测多种蛋白质的进化动态。《细胞系统》13, 274–285 (2022)。
- Gelman, S. 等。基于生物物理学的蛋白质语言模型在蛋白质工程中的应用。《自然·方法》22, 1868–1879 (2025)。
- Madani, A. 等。大型语言模型可生成涵盖多种蛋白家族的功能性蛋白质序列。《自然·生物技术》41, 1099–1106 (2023)。
- Munsamy, G. 等。条件语言模型可实现高效设计高效酶。预印本发布于 <https://doi.org/10.1101/2024.05.03.592223> (2024)。
- Romero-Romero, S. 等。利用生成式语言模型对磷酸丙糖异构酶进行从头设计。预印本发布于 <https://doi.org/10.1101/2024.11.10.622869> (2024)。
- Chen, L. T. 等。利用掩码语言建模实现肽结合剂的靶序列条件化设计。《自然·生物技术》1–9 <https://doi.org/10.1038/s41587-025-02761-2> (2025)。
- Bhat, S. 等。利用对比语言建模技术, 针对构象多样性靶点从头设计肽结合剂。《科学进展》11, eadr8638 (2025)。
- Truong Jr., T. F. & Bepler, T. PoET: 一种将蛋白质家族建模为序列之序列的生成式模型。预印本发布于 <https://doi.org/10.48550/arXiv.2306.06156> (2023)。
- Ferruz, N., Schmidt, S. & Hocker, B. ProtGPT2: 一种用于蛋白质设计的深度无监督语言模型。Nat. Commun. 13, 4348 (2022)。
- Hesslow, D., Zanichelli, N., Notin, P., Poli, I. & Marks, D. 《RITA: 生成式蛋白质序列模型规模化研究》。预印本发布于 <https://doi.org/10.48550/arXiv.2205.05789> (2022)。
- Chen, B. 等著。xTrimoPGLM: 用于解析蛋白质语言的统一 1000 亿参数规模预训练 Transformer 模型。预印本发布于 <https://doi.org/10.48550/arXiv.2401.06199> (2024 年)。
- Yang, K. K., Fusi, N. & Lu, A. X. 卷积网络在蛋白质序列预训练中可与 Transformer 模型相媲美。Cell Syst. 15, 286–294 (2024)。
- Peng, Z., Schussheim, B. & Chatterjee, P. PTM-Mamba: 一种具备双向门控 Mamba 块的 PTM 感知蛋白质语言模型。预印本发布于 <https://doi.org/10.1101/2024.02.28.581983> (2024)。
- Ouyang, L. 等。利用人类反馈训练语言模型遵循指令。预印本发布于 <https://doi.org/10.48550/arXiv.2203.02155> (2022)。
- Bai, Y. 等。《宪法式人工智能: 从 AI 反馈中实现无害性》。预印本发布于 <https://doi.org/10.48550/arXiv.2212.08073> (2022)。
- Stiennon, N. 等。基于人类反馈的摘要生成学习。载于《Proceedings of the Advances in Neural Information Processing Systems》第 33 卷, 第 3008–3021 页 (Curran Associates, Inc., 2020)。
- Touvron, H. 等。Llama 2: 开源基础版与微调版对话模型。预印本发布于 <https://doi.org/10.48550/arXiv.2307.09288> (2023)。
- Gelman, S., Fahlberg, S. A., Heinzelman, P., Romero, P. A. & Gitter, A. 利用神经网络从深度突变扫描数据中学习蛋白质序列-功能关系。《美国国家科学院院刊》118, e2104878118 (2021)。
- Freschlin, C. R., Fahlberg, S. A., Heinzelman, P. & Romero, P. A. 利用神经网络对蛋白质适应度景观中远端区域进行外推。《自然·通讯》15, 6405 (2024)。
- Hsu, C., Nisonoff, H., Fannjiang, C. & Listgarten, J. 基于进化数据与检测标记数据构建蛋白质适应度模型。《自然·生物技术》40, 1114–1122 (2022)。
- Hawkins-Hooker, A. 等。利用变分自编码器生成具有变分特性的蛋白质变体。PLoS Comput. Biol. 17, e1008736 (2021)。
- Dauparas, J. 等。基于 ProteinMPNN 的鲁棒性深度学习蛋白质序列设计。《Science》378, 49–56 (2022)。
- Alamdari, S. 等。基于进化扩散的蛋白质生成: 仅需序列信息。预印本发布于 <https://doi.org/10.1101/2023.09.11.556673> (2024)。
- Nijkamp, E., Ruffolo, J., Weinstein, E. N., Naik, N. & Madani, A. ProGen2: 探索蛋白质语言模型的边界。预印本发布于 <https://doi.org/10.48550/arXiv.2206.13517> (2022)。
- Chen, Y. 等。对一种不依赖氧气的荧光蛋白 CreiLOV 进行深度突变扫描, 以全面解析突变效应与上位效应。ACS Synth. Biol. 12, 1461–1473 (2023)。
- Melamed, D., Young, D. L., Gamble, C. E., Miller, C. R. & Fields, S. 对酿酒酵母多聚(A)结合蛋白的 RRM 结构域进行深度突变扫描。《RNA》第 19 卷, 第 1537–1551 页 (2013)。
- Romero, P. A., Tran, T. M. & Abate, A. R. 利用基于微流控技术的深度突变扫描解析酶功能。《美国国家科学院院刊》112, 7159–7164 (2015)。
- Starita, L. M. 等。通过高通量诱变技术鉴定出一种 E3 泛素连接酶中的活性增强突变。《美国国家科学院院刊》110, E1263–E1272 (2013)。
- Sarkisyan, K. S. 等。绿色荧光蛋白的局部适应度景观。《自然》533, 397–401 (2016)。
- Olson, C. A., Wu, N. C. & Sun, R. 对整个蛋白质结构域中成对上位效应的综合生物物理学描述。《当代生物学》24, 2643–2651 (2014)。
- Mukherjee, A. 等。从莱茵衣藻与弗氏沃切里亚中工程化构建及表征新型基于 LOV 的荧光蛋白。《ACS Synth. Biol.》4, 371–377 (2015)。
- Mukherjee, A., Walker, J., Weyant, K. B. & Schroeder, C. M. 基于咪唑啉的荧光蛋白特性研究: 一类新兴的荧光报告蛋白。PLoS ONE 8, e64753 (2013)。
- Ozbakir, H. F., Anderson, N. T., Fan, K.-C. & Mukherjee, A. 超越绿色荧光蛋白: 用于厌氧及深组织成像的生物分子报告分子。《Bioconjugate Chem.》31, 293–302 (2020)。

43. Swartz, T. E.等.蓝光光感受器 phototropin* 中非avin 结合域的光循环研究*.《生物化学杂志》276,36493–36500 (2001).
44. Riesselman, A. J., Ingraham, J. B. & Marks, D. S. 基因变异的深度生成模型可捕捉突变效应。《自然-方法》15,816–822 (2018)。
45. Hopf, T. A. 等。基于序列共变预测的突变效应。《自然-生物技术》35,128–135 (2017)。
46. Mann, J. K. 等。HIV-1 Gag 的适应度景观：先进的建模方法及通过体外实验验证模型预测结果。PLoS Comput. Biol. 10, e1003776 (2014)。
47. Rohl, C. A., Strauss, C. E. M., Misura, K. M. S. & Baker, D. 使用 Rosetta 进行蛋白质结构预测。载于《酶学方法》第 383 卷, 第 66–93 页 (Academic Press, 2004)。
48. Meiler, J. & Baker, D.《RosettaLigand: 支持完整侧链柔性的蛋白质-小分子对接》。《Proteins Struct. Funct. Bioinform.》65,538–548 (2006)。
49. Goverde, C. A. 等。可溶性功能型膜蛋白类似物的计算设计。《自然》杂志 631,449–458 (2024)。
50. Marks, C., Hummer, A. M., Chin, M. & Deane, C. M. 基于大规模抗体库数据的机器学习方法实现抗体人源化。《生物信息学》37,4041–4047 (2021)。
51. Prihoda, D. 等。BioPhi: 基于天然抗体库与深度学习的抗体设计、人源化及人源化评估平台。mAbs 14,2020203 (2022)。
52. Chu, T. 等人 SFT 记忆,RL 泛化:基础模型后训练的对比研究.预印本见 <https://doi.org/10.48550/arXiv.2501.17161>(2025)。
53. Rafailov, R. 等。直接偏好优化: 你的语言模型本质上是一个奖励模型。预印本见 <https://doi.org/10.48550/arXiv.2305.18290> (2024)。
54. Xu, S. 等。DPO 在 LLM 对齐任务中是否优于 PPO? 一项全面研究。预印本发布于<https://doi.org/10.48550/arXiv.2404.10719>(2024)。
55. Iverson, H. 等。《解析 DPO 与 PPO: 从偏好反馈中学习的最佳实践剖析》。预印本发布于 <https://doi.org/10.48550/arXiv.2406.09279> (2024)。
56. Widatalla, T., Rafailov, R. & Hie, B. 通过直接偏好优化将蛋白质生成模型与实验适应度对齐。预印本发布于 <https://doi.org/10.1101/2024.05.20.595026> (2024)。
57. Stocco, F. 等。利用强化学习引导生成式蛋白质语言模型。预印本发布于<https://doi.org/10.48550/arXiv.2412.12979>(2024)。
58. Mistani, P. & Mysore, V. 蛋白质语言模型的偏好优化: 一种多目标结合剂设计范式。预印本发布于 <https://doi.org/10.48550/arXiv.2403.04187> (2024)。
59. Hsu, C. 等。从数百万个预测结构中学习反向折叠<https://proceedings.mlr.press/v162/hsu22a.html>(2022)。
60. Xu, X. 等。AB-Gen: 基于生成式预训练 Transformer 与深度强化学习的抗体库设计方法。Genom. Proteom. Bioinform. 21,1043–1053 (2023)。
61. Sternke, M. & Karpiak, J. ProteinRL: 基于生成式蛋白质语言模型的强化学习, 用于属性导向的序列设计。(2023)。
62. Angermueller, C.等.基于模型的强化学习在生物序列设计中的应用。(2020)
63. Rapp, J. T., Bremer, B. J. & Romero, P. A. 自主驱动实验室: 在蛋白质适应度景观中实现自主导航。《自然-化学工程》1,97–107 (2024)。
64. Singh, N. 等。基于人工智能驱动的自主蛋白质工程通用平台。预印本发布于<https://doi.org/10.1101/2025.02.12.637932> (2025)。
65. UniProt 联盟。《UniProt: 2023 年的通用蛋白质知识库》。《核酸研究》51, D523–D531 (2023)。
66. Johnson, L. S., Eddy, S. R. & Portugaly, E. 隐马尔可夫模型速度启发式方法与迭代式 HMM 搜索流程。BMC Bioinform. 11,431 (2010)。
67. Detlefsen, N. S., Hauberg, S. & Boomsma, W. 学习蛋白质序列的有意义表征。Nat. Commun. 13,1914 (2022)。
68. Ding, X., Zou, Z. & Brooks, C. L. III 利用潜在空间模型解析蛋白质进化与适应度景观。《自然-通讯》10,5644 (2019)。
69. Akiba, T., Sano, S., Yanase, T., Ohta, T. & Koyama, M. Optuna: 下一代超参数优化框架。载于《第25届ACM SIGKDD 知识发现与数据挖掘国际会议论文集》, 第 2623–2631 页 <https://doi.org/10.1145/3292500.3330701> (美国计算机协会, 2019)。
70. Shao, Z. 等。DeepSeekMath: 在开放语言模型中拓展数学推理的边界。预印本发布于 <https://doi.org/10.48550/arXiv.2402.03300> (2024)。
71. DeepSeek-AI等.DeepSeek-R1:通过强化学习提升大语言模型的推理能力.预印本发布于<https://doi.org/10.48550/arXiv.2501.12948>(2025)。
72. Schulman, J., Moritz, P., Levine, S., Jordan, M. & Abbeel, P. 基于广义优势估计的高维连续控制。预印本发布于<https://doi.org/10.48550/arXiv.1506.02438> (2018)。
73. Kumar, A., Raghunathan, A., Jones, R., Ma, T. & Liang, P. 微调可能扭曲预训练特征,并导致在分布外场景下性能下降。预印本见<https://doi.org/10.48550/arXiv.2202.10054>(2022)。
74. Frazer, J. 等。基于进化数据的深度生成模型进行疾病变异预测。《自然》杂志 599,91–95 (2021)。
75. Hopf, T. A. 等。用于共进化序列分析的 EVCouplings Python 框架。《Bioinformatics》35,1582–1584 (2019)。
76. Marks, D. S.等.基于进化序列变异计算的蛋白质三维结构.PLoS ONE 6,e28766 (2011)。
77. Notin, P. 等。TranceptEVE: 结合蛋白质序列的家族特异性与家族非特异性模型以提升适应度预测性能。预印本发布于 <https://doi.org/10.1101/2022.12.07.519495> (2022)。
78. Notin, P. 等。ProteinGym: 蛋白质适配度预测与设计的大规模基准数据集。NeurIPS 数据集与基准测试 (2023)。
79. Notin, P. 等。《Transception: 基于自回归变换器与推理时检索的蛋白质适配度预测》。预印本发布于<https://doi.org/10.48550/arXiv.2205.13760> (2022)。
80. Salazar, J., Liang, D., Nguyen, T. Q. & Kirchhoff, K. 掩码语言模型评分。载于《第 58 届计算语言学协会年会论文集》, 第 2699–2712 页 <https://doi.org/10.18653/v1/2020.acl-main.240>(2020)。
81. Abramson, J. 等。利用 AlphaFold 3 实现生物分子相互作用的精准结构预测。《自然》杂志 1–3 <https://doi.org/10.1038/s41586-024-07487-w>(2024)。

致谢

作者感谢 Tom Sercu 对 ESM-2 模型评估的深刻见解, 以及 Adithyan Unni、Sam Gelman 和 Chase Freschlin 提供的宝贵意见与讨论, 这些贡献为本研究提供了重要支持。同时, 作者也感谢 Sameer D 'Costa 提供的服务器管理服务, 以及威斯康星大学麦迪逊分校的高通量计算中心提供的计算资源。

作者贡献

注: 概念化、数据管理、形式化分析、研究实施、方法论 (强化学习、奖励模型及变分自编码器训练与计算基准测试)、软件应用、验证、可视化、文稿撰写 (初稿准备)。S.S.: 概念化、形式化分析、方法论 (监督微调优化及体内特性分析)、验证、可视化、文稿撰写 (审阅与

编辑)。K. N.: 形式化分析、研究实施、方法论(体外特性分析)及验证。A. B.: 研究实施与方法论(强化学习)。S. A. F.: 研究实施与方法论(体内特性分析)。A. K.: 软件应用与验证(计算基准测试及代码可复现性)。P. A. R.: 概念化、形式化分析、资金获取、项目管理、监督指导及文稿撰写(审阅与编辑)。

资金

我们感谢美国国家科学基金会(资助编号: 2226383)和美国国立卫生研究院 NIGMS 项目(资助编号: 5R01GM150929-02)对本研究的资助。

利益冲突

作者声明不存在竞争性利益冲突。

补充信息

补充信息: 在线版本包含可在<https://doi.org/10.1038/s41467-026-77557-2>处获取的补充材料。

通讯及材料索取事宜, 请致函 Philip A. Romero。

同行评审信息: 《Nature Communications》谨向 Gabriel Rocklin 及其他匿名审稿人对本研究的审稿工作做出贡献表示感谢。同行评审文件已可供获取。

重印及授权相关信息请参阅以下网址:

<http://www.nature.com/reprints>

出版方声明: Springer Nature 对于已发表地图中的司法管辖权主张及机构隶属关系保持中立立场。

开放获取: 本文采用“知识共享 署名-非商业性使用-禁止演绎 4.0 国际许可协议”授权, 该许可允许在任何媒介或格式下进行非商业性使用、分享、分发及复制, 但您须向原作者及来源提供适当署名, 提供指向本知识共享许可协议的链接, 并标明您是否对许可材料进行了修改。根据本许可协议, 您无权分享基于本文或其部分内容改编的衍生材料。本文中的图像或其他第三方材料均包含在本文章本的知识共享许可协议范围内, 除非相关材料在署名栏中另有说明。若某材料未包含在本文章本的知识共享许可协议中, 且您的预期用途不受法定法规许可或超出许可范围, 则您需直接向版权持有人获取许可。如需查看本许可协议全文, 请访问<http://creativecommons.org/licenses/by-nc-nd/4.0/>。

© 作者 2026

本篇已发表文章将提前分享, 以便您更快获取最新研究成果。该文章可供引用, 并拥有永久 DOI 标识; 最终修订版将自动取代本版本。