

语言模型超越天然蛋白质进行概括

罗伯特·维尔基尔^{1*} 奥里·卡贝利^{1*} 杜逸伦^{1,2} 巴西尔·I·M·维基^{3,4} 卢卡斯·F·米勒斯^{3,4} 尤斯塔斯·道帕拉斯^{3,4} 大卫·贝克^{3,4,5} 谢尔盖·奥夫奇尼科夫⁶ 汤姆·塞尔库¹ 亚历山大·里夫斯^{1,7}

摘要

学习跨越进化的序列中蛋白质的设计模式, 可能对生成性蛋白质设计有前景。然而, 目前尚不清楚训练于天然蛋白质序列的语言模型, 是否能够超越对现有蛋白质家族的记忆。我们在此展示, 语言模型超越天然蛋白质, 能够生成新设计蛋白质。我们专注于两项蛋白质设计任务: 固定主链设计(即结构已指定) 和无约束生成(即结构从模型中采样)。值得注意的是, 尽管模型仅在序列上训练, 我们发现它们能够设计结构。共评估了228种生成的蛋白质, 在尺寸排除色谱法中, 高达67%的成功率(152/228), 能够产生可溶且为单体的物种。在152种实验成功设计中, 有35种与已知天然蛋白质没有显著的序列匹配。在剩下的117种中, 最近序列匹配的序列相似性中位数为27%, 6种设计低于20%, 3种设计低至18%。对于固定主链设计, 语言模型为每个八个实验评估的人工创建的固定主链目标生成成功设计。在无约束生成中, 采样的蛋白质涵盖了多样的拓扑结构和二级结构组成, 并且具有高实验成功率(71/129或55%)。这些设计反映出序列与结构之间的深层模式, 包括在相关天然结构中出现的基本序, 以及在已知蛋白质家族的相似结构背景中未观察到的基本序。结果表明, 尽管语言模型仅在序列上训练, 但它们学习了一种深层语法, 使得蛋白质结构的设计超越了天然蛋白质。

介绍

生成式人工智能在生物学领域有潜力开启超越天然蛋白质的蛋白质设计空间。由于氨基酸序列是蛋白质的基本编码, 因此用语言模型学习读取和编写这些编码可能具有前景。语言模型在最近的人工智能进展中发挥了核心作用(1), 包括在复杂推理、数学问题解决、图像生成和自然语言生成中的发展(2-4)。缩放法则将模型的性能与训练时使用的计算、数据和参数数量联系起来(5), 并且随着规模的增加, 观察到更高水平能力的出现(6)。在生物学中, 最近关于蛋白质的进化规模语言模型的工作表明, 从蛋白质序列训练获得的深刻生物学内在特性的知识显现出来(7)。关于蛋白质折叠的三维结构的信息在模型中发展, 并延伸到原子分辨率结构(8)。这一信息通过仅在序列上进行训练而显现。同时, 作为训练序列的结果所出现的结构信息已被证明依赖于可用的进化信息, 随训练数据中相关蛋白质数量的变化而变化(8, 9)。在各个领域, 关于语言模型在多大程度上能够概括超出其训练数据仍然是一个开放的问题。在生物学中, 目前不清楚语言模型是否可以用来探索超越天然蛋白质的设计空间。

在这里, 我们展示了语言模型在生成新设计蛋白质方面的泛化能力, 这些蛋白质在序列和结构上与天然蛋白质不同。我们通过实验验证了大量不同拓扑和序列的设计。我们发现, 尽管语言模型仅在蛋白质的序列上进行训练, 但它们能够设计蛋白质结构, 包括与天然蛋白质明显不同的人工设计新设计蛋白质的结构。以新设计蛋白质结构的骨架作为目标, 语言模型生成预测将折叠为指定结构的序列。当序列和结构都是自由时, 语言模型产生的设计跨越广泛的折叠拓扑和二级结构组成, 创造出既重叠天然序列分布又超越它的蛋白质。在样本蛋白质空间中, 设计在实验中成功, 包括许多在序列上与天然蛋白质相距甚远的设计。该模型生成了将序列与结构设计联系起来的模体, 并能在新的序列和结构上下文中应用这些模体, 包括复杂氢键等模体。

*平等贡献 ¹Meta基础人工智能研究蛋白团队 (FAIR)。 ²麻省理工学院。作为访问研究员在Meta FAIR进行的工作。 ³华盛顿大学生物化学系, 美国华盛顿州西雅图。 ⁴华盛顿大学蛋白质设计研究所, 美国华盛顿州西雅图。 ⁵霍华德·休斯医学研究所, 华盛顿大学, 美国华盛顿州西雅图。 ⁶约翰·哈佛杰出科学奖学金计划, 哈佛大学, 美国马萨诸塞州剑桥。 ⁷纽约大学。数据可在以下链接获取: <<https://github.com/facebookresearch/esm>>.

†通讯至

<arives@meta.com>.

语言模型超越天然蛋白质的概括能力




图 1. 概述. (A) 蛋白质序列空间的示意图。天然序列 (灰色) 覆盖了可能的蛋白质序列的一小部分。为了超越天然序列, 语言模型需要访问潜在的设计模式。我们在以下两个任务中评估语言模型: (i) 使用一组新设计蛋白质 (绿色) 的固定骨架序列设计任务, 以及 (ii) 通过一个不受限制的新设计蛋白质生成任务 (橙色)。 (B) 语言模型 ESM2 使用在进化过程中对数百万种不同天然蛋白质的掩码语言建模进行训练。 (C) 训练后, 模型的内部注意力状态可以识别关于三级结构的信息。线性投影将序列中一对位置的注意力转换为氨基酸之间距离的分布。 (D) 序列的概率。模型为蛋白质中每个位置的每种氨基酸输出一个概率, 这里展示的是设计的蛋白质 6W3W。模型对表面残基的亲水性氨基酸给予更高的概率, 而对核心中的疏水性氨基酸给予较低的概率。 (E) 给定序列的结构概率。对于给定的序列, 投影测量语言模型的内部表示与结构的兼容性。通过在氨基酸之间距离小于 8 Å 的概率质量来识别三级结构。对于 6W3W, 投影结构 (对角线以上) 与真实结构 (对角线以下) 之间有很好的匹配。 (F) 生成序列的概率和结构的两个项用于生成序列。对于固定目标设计, 我们使用 MCMC 生成给定特定骨架结构的序列, 方法是从给定结构的序列条件分布中抽样。 (G) 对于不受限制的生成, 我们允许序列和结构同时变化。 (H) 预测的结构 (使用 AlphaFold) 在单一自由生成轨迹中以均等间隔显示。模型在缩小到一个拓扑的细化之前, 先对一系列可能的拓扑进行抽样。

语言模型超越天然蛋白质的泛化能力

这些网络在序列上或结构上与已知蛋白质相似的情况下并不存在。总体实验成功率较高, 在 228 个被评估的蛋白质中, 有 152 个 (67%) 通过尺寸排斥色谱法 (SEC) 产生了可溶且单体的物种。这一高成功率适用于与天然蛋白质相远离的蛋白质, 其中 49 个实验评估的蛋白质中有 31 个 (63%) 成功。

蛋白质序列的深层语法

我们假设蛋白质序列中存在深层的基础语法, 使得语言模型能够进行泛化。为了超越天然蛋白质, 语言模型需要访问扩展到天然蛋白质空间之外的设计模式。传统上, 这种形式的泛化是通过一个基于物理的能量函数实现的, 该函数捕捉到本征折叠状态 (10)。最近, 基于结构的深度学习新方法被提出作为解决这一问题的新方法, 通过反转结构预测 (11, 12), 或依赖主链结构 (13–15)。通过在训练期间显式建模结构, 新型深度学习新方法可能会捕捉到类似于物理能量的东西 (16)。语言模型在这个问题上的成功表明, 序列中的深层模式可能提供一种独立于所基于物理学的明确模型的泛化替代路径。

从序列进行进化推理的经典观点是, 关于蛋白质特性的信息通过保护和共同进化在进化相关的蛋白质的序列模式中进行编码。这一观点源自于对蛋白质家族统计的观察, 这些统计反映了作用于序列进化的约束, 包括生物学的结构与功能 (17, 18)。这一洞察为从蛋白质家族的序列推测结构与功能奠定了基础 (19), 并且最近也成功地被生成模型应用于从现有的蛋白质家族中生成新的示例 (20–22)。迄今为止, 基于序列的蛋白质设计模型的实验验证仅限于自然蛋白质家族。

访问一个新设计的设计空间, 这与自然产生的蛋白质家族相距甚远, 是一个根本上更具挑战性的问题。根据定义, 这个问题无法通过生成来自自然发生的蛋白质家族的新样本来解决。要使用一个基于序列的模型解决这个问题, 就必须学习超越单个蛋白质家族的序列模式。进化规模语言模型通过在进化过程中对多样序列进行训练, 超越经典的蛋白质家族模型, 这意味着它们有潜力学习所有蛋白质的深层模式, 包括那里没有实验结构的地方。已有证据表明, 在序列中存在超越单个蛋白质家族的局部模式, 这些模式以模体的形式存在, 模体在序列中是局部的 (23), 以及模体在三维空间中是局部的 (24)。然而, 序列与结构之间的映射并不是一一对应的 (25), 而设计序列以达到良好折叠的本征状态需要解决一个指数级大的组合问题, 以选择一组局部序列模式。

这些模式进行非局部交互, 以指定一个连贯的结构 (26)。为了设计蛋白质结构, 语言模型必须发展出对序列如何决定结构的隐含理解, 包括将结构设计与序列链接的局部规则, 以及确定序列是否连贯并将折叠成本征状态的全局规则。

使用语言模型进行生成性蛋白质设计

我们评估语言模型的生成能力, 重点关注超越天然蛋白质的泛化。通过进化采样的已知蛋白质序列仅代表了可能的蛋白质数量的一个小部分 (图 1A)。要在进化探索过的蛋白质空间之外进行泛化, 将有必要获取适用于该空间之外的蛋白质设计的深层模式。我们专注于两个生成蛋白质设计任务。第一个是固定主链设计, 目标是生成一个可以折叠成目标结构的序列。该任务评估了仅仅在序列上进行训练的语言模型设计蛋白质结构的能力。第二个任务是自由生成, 结构不受限制, 可以与序列一起变化。这使得能够表征模型在多样的序列和结构模式中全面的生成能力, 以理解模型可访问的蛋白质空间。

一个测试集新设计的人工作蛋白质用于评估超越天然蛋白质结构的泛化能力。测试集包括一系列多样化的选择 ($N = 39$) 来自蛋白质数据银行 (PDB) 中经过结构验证的人工蛋白质结构 (27), 这些结构跨越不同的长度 ($67 \leq L \leq 184$) 和拓扑 (图 S1 及附录 A.1)。重要的是, 这些新设计的蛋白质在理想性、完全重复性和元素对称性等方面与属于天然折叠的蛋白质存在显著的结构差异。由于语言模型没有在蛋白质结构上进行训练, 生成这些骨架的设计考验了模型对其训练序列的天然蛋白质不同的结构进行泛化的能力。

语言模型 ESM2 是一个蛋白质序列的进化规模模型, 已在天然蛋白质序列的全部范围内进行训练 (28)。训练数据集排除了人工序列, 以及任何与用于评估的新设计蛋白质测试集相似的序列 (附录 A.1)。ESM2 使用掩码语言建模目标进行训练 (29), 以从序列的其余部分的上下文中恢复氨基酸的身份 (图 1B)。该训练目标已被证明能够在模型的内部表示中体现蛋白质的折叠结构信息 (7–9, 30)。由于语言模型的训练仅基于序列, 因此出现的结构信息必须是对序列中模式的无监督学习结果。

来自语言模型注意力图的线性投影识别出反映蛋白质结构的内部状态。之前的研究表明, 变压器蛋白质语言模型中特定的注意力图, 如 ESM2, 编码了残基的相近性

语言模型在天然蛋白质之外的推广




图 2. 序列设计用于新设计结构。(A) 使用计算机模拟甲骨文对新设计目标集的总体评估。设计结构 (甲骨文预测) 和目标结构之间的 C- α 原子的均方根偏差 (RMSD) 图示为每个目标的优化目标排名前 10 的设计。目标按长度递增排序。语言模型生成的序列在测试集中对于大多数新设计骨架预计可以折叠成目标结构。(33/39 的中位 RMSD 为 < 2.5 Å)。(B) ESM 设计的实验结果。总共选择了 79 个设计, 涵盖 6 个新设计骨架目标, 依据多个标准, 包括序列新颖性和对有趣基序的人工检查。设计在可溶且在大小排阻色谱法 (SEC) 中预期洗脱体积出现峰值时被视为成功。当唯一峰位于预期洗脱体积时, 设计被分类为单分散。整体上, 78% 成功, 39% 为单分散。(style id='21'>C) 比较使用和不使用语言模型的设计的实验结果。对于四个目标, 按优化目标选择了 200 个设计中排名前 5 的进行实验评估。整体上, 有语言模型的设计成功率为 95%, 而没有语言模型的大多数设计由于不可溶而失败。(style id='23'>D) (左) 优化轨迹显示由语言模型指定的能量与目标的 RMSD 随 MCMC 优化过程的变化。能量减少并向低 RMSD 汇聚。(右) 每个轨迹结束时按照能量选择的前 5 个设计的可视化。(style id='25'>E) 设计的语言建模困惑度。语言模型设计被语言模型视为可能, 而基线设计的高困惑度表明它们的序列被视为不太可能。这与实验成功相吻合。(style id='27'>F) 使用和不使用语言模型的设计之间 SEC 痕迹的比较。绝大多数语言模型设计是可溶的, 并在预期洗脱体积处有峰值; 相比之下, 少数没有语言模型的设计是可溶的。(style id='29'>G) 一组额外的成功语言模型设计在已知天然蛋白质的背景下是新颖的。展示了四种不同骨架的示例, 设计与针对天然蛋白质的序列搜索的最高重要性命中的预测结构重叠。在每种情况下, 最接近的天然序列具有低序列相似性 (< 0.3) 和预测的不同拓扑结构。

结构中的对 (9, 30)。我们拟合一个线性投影, 它将蛋白质序列中两个位置之间的注意力进行处理, 并输出成对距离的分布 (图. 1C)。这将660维的内部注意力状态映射到18个残基间距箱中。由于参数数量有限 (每个距离箱660个, 总计为11,898个, 包括每个距离箱的偏差), 远远不足以表示可能蛋白质结构的巨大复杂性, 因此输出可以被解释为模型内部状态捕获的结构投影。该投影定义了一个能量景观 (一个表示语言模型表征状态的函数, 而不是物理能量), 可以用来评估任意给定结构与语言模型生成的序列表示之间的兼容性。对新设计目标集的应用显示出对现有新设计蛋白质的理解 (表 S1和图. S2和S3)。

模型的序列和给定序列的结构一起指定了由语言模型定义的蛋白质生成模型。序列模型为任何序列分配一个概率, 通过给出蛋白质每个位置上每个氨基酸的概率 (图. 1D)。对于天然蛋白质, 这些概率反映了突变的功能效应、氨基酸的结构偏好以及生化功能的一些方面 (31)。结构的投影给出了语言模型的序列表示与三维结构之间的兼容性 (图. 1E)。在这项工作中, 我们考虑这些模型来指定蛋白质设计的生成模型:

$$p(\text{sequence}, \text{structure}) = p(\text{structure}|\text{sequence})p(\text{sequence})$$

对于固定主链设计, 蛋白质序列是通过在马尔可夫链蒙特卡罗 (MCMC) 和模拟退火的条件下, 从语言模型指定的条件分布中提取低温样本生成的 (图. 1F, 附录 A.3.1)。自由生成完全移除了对结构的约束, 并通过从语言模型指定的序列和结构的联合分布中抽样来生成新蛋白质。引入了一种阻塞吉布斯采样方法, 该方法交替进行: 在当前序列的基础上抽样新结构, 以及在当前结构的基础上抽样新序列 (图. 1G, 附录 A.3.3)。图中显示了一个自由生成轨迹的示例。1H。随着温度的降低, 轨迹从一个抽样多种可能拓扑结构的阶段开始, 随后收敛到一个拓扑结构, 并在优化的最后阶段精炼为一个自信预测的结构。

我们对来自语言模型的228个设计进行了广泛的实验测试。被认为成功的设计具备良好的表达、可溶性, 并通过大小排斥色谱 (SEC) 测试, 其分子 (流体动力学) 半径能指示正确折叠的单体物种 (附录A.7)。生成蛋白质中相当一部分的实验成功, 以及对其结构的独立计算评估, 表明语言模型能够进入超越天然蛋白质的设计空间。

语言模型设计的序列折叠成新设计结构

固定主链设计评估序列的生成, 以实现特定的目标结构。使用新设计结构作为目标要求模型超越天然蛋白质进行概括, 因此需要采用更一般的模式来设计结构。该任务的成功表明模型理解蛋白质结构的基础设计原则, 并能够概括出未被天然序列编码的结构。

在39个人工设计的新设计蛋白质结构的测试集中, 由语言模型生成的固定骨架设计被预测与目标结构紧密匹配, 使用的是AlphaFold高分辨率结构预测甲骨文。我们为每个新设计目标结构生成200个不同的设计 (附录A.4)。生成模型在绝大多数目标中成功地产生了低均方根偏差设计, 在新设计测试集中 (图. 2A)。通过语言模型的优化目标对200个设计中最好的10个进行子集筛选, 中位均方根偏差为 $< 2.5^\circ\text{A}$, 对于84% (33/39) 的目标, 最小均方根偏差为 $< 2^\circ\text{A}$, 对于90% (35/39) 的目标。结构的预测也具有非常高的信心, 中位pTM > 0.7 , 适用于56% (22/39), 最大pTM > 0.7 , 适用于90% (35/39)。与目标的平均序列相似性较低 (22%), 这表明语言模型正在寻找与原始序列不同的设计问题解决方案。

生成的蛋白质在实验室中的整体实验成功率很高。我们进行了额外的一组固定骨架设计轨迹, 以探索从模型生成的设计基序的多样性。总共选择了79个固定骨架设计, 涵盖6新的设计目标, 从一个池中选择, 包括附加的轨迹, 以多种标准进行评估, 包括有趣的结构基序的存在 (附录A.6)。在这组经过实验测试的蛋白质中, 97% (77/79) 是可溶的, 78% (62/79) 是成功的, 经过SEC测试, 显示出在预期洗脱体积处存在峰, 指示折叠的单体物种, 39% (31/79) 是单分散的, 只在预期洗脱体积处展示出一个SEC峰 (图. 2B)。成功的设计横跨多种拓扑结构, 包括一个长度为182的成功新设计 TIM桶 6WVS, 其具有高度理想化的对称结构 (图. S4)。在这组实验成功中, 目标结构原始序列的序列同一性较低 (平均 = 24%), 这表明语言模型正在为目标结构探索新的设计空间。

我们进行了一项受控实验, 以了解语言模型在设计实验成功中的作用。作为比较, 我们使用AlphaFold作为给定序列的结构概率模型。对于一组四个固定主链新设计目标, 这些目标具有不同的折叠, 我们使用每种方法生成200个设计, 并为每种方法选择优化目标前5名进行实验评估 (附录A.3)。实验结果显示, 95% (19/20) 的语言模型序列设计成功, 而没有语言模型的设计成功率为5% (1/20) (图. 2C)。通过n-gram先验增强AlphaFold, 未能挽救这些设计 (成功率为0%, 0/20) (表格S3和 S4)。

语言模型的泛化超越了天然蛋白质




图 3. 语言模型具体化了蛋白质设计的深层模式, 生成类似天然的和新设计模体。(A) 脯氨酸或甘氨酸在三种不同设计蛋白质中的位置引发了 α -螺旋、 β -折叠和转角的弯曲。(B,C) 转角中的氢键网络。(B) 螺旋偶极末端形成氢键以遮蔽最终螺旋转角中的极性主链原子。(C) 涉及 β -折叠的转角中形成的氢键网络。(D,E) 设计与天然蛋白质中模体的比较。设计(左)与通过序列搜索(中)和结构搜索(右)找到的天然蛋白质中最接近的模体进行了比较。命中按模体位置匹配的氨基酸仅进行排序。(D) 用于其中一个设计的氢键模体示例。在对齐位置中发现的序列匹配具有相同的模体。然而, 周围的序列上下文有显著不同, 序列相似性为26%。(E) 可能的 redesign 氢键网络的示例。不仅序列上下文不同, 模体本身在任何匹配的天然序列或结构的对齐位置中都不存在。

语言模型困惑度将成功与失败区分开来, 适用于两种设计方法。语言模型的MCMC轨迹随着能量降低而汇聚到低均方根偏差, 平均均方根偏差值范围从 1.1°A 到 2.4°A (图2D)。值得注意的是, 尽管AlphaFold自信地预测语言模型设计的结构, 但语言模型对AlphaFold设计的序列赋予的高可能性不高。选定的AlphaFold设计序列的语言模型困惑度范围从10.6到13.1(图. 2E), 显著高于平均的新设计目标序列困惑度6.7。其他指标识别实验成功的能力有限(图. S5 和表 S4): 用于建模和设计的Rosetta全原子能量函数(32, 33)认为这两组都是良好的设计, 包装指标相似, 但稍微偏向(不成功的)AlphaFold设计, 而疏水性和SAP得分则偏向语言模型设计。最近, 自回归逆折叠模型直接基于目标结构进行了条件处理, 展示了在实验室中的高成功率(15)。我们使用ProteinMPNN和ESM-IF1生成了序列(14)。这两个模型都实现了高局部置信度pLDDT (> 90 均值)。它们的ESM伪困惑度分别为5.76和5.79, 高于ESM设计且显著低于AlphaFold设计(表S2), 与这些方法报告的高实验成功率一致。

对两个设计集(有语言模型和没有语言模型)进行的实验评估表明, 19/20 的语言模型设计成功, 9/20 为单体(图 2F)。目标 6D0T 从语言模型中没有单体设计, 尽管真实值新设计序列在作为阳性对照时也被发现为非单体(附录A.7)。没有语言模型的设计大多由于不溶解性而失败。

包括受控比较的结果以及评估的更大设计集, 语言模型实验性地为总共8个新设计骨架生成了成功的设计。一种可能性是, 语言模型设计之所以成功, 是因为模型从训练集中检索到与目标相似的蛋白质。为了排除此可能性, 我们分析了81个实验成功案例的整体集。每个设计都与UniRef90(该数据库完全包括用于训练语言模型的序列)进行了比对, 以识别相似序列(附录A.5)。在涵盖4个骨架的17个成功设计中, 训练集中根本没有显著的(E值 < 1)序列匹配。这其中有四个展示在图2G中。在剩余的64个设计中, 平均与最近序列匹配的序列相似性仅为27%, 并且对于64个设计中的41个, 相似性仅为 $< 30\%$ 。这表明模型并不是通过检索它所记住的相似序列来解决设计问题的。

语言模型超越天然蛋白质的泛化

为了进一步了解模型是否在序列相似性的检测阈值上使用同源性, 我们获得了AlphaFold预测的命中结构, 包括那些没有达到显著性截止值的结构 (附录A.5; 图S6)。在19/81个实验成功案例中, 排名最高的Jackhmmer命中并未与设计结构匹配。在覆盖4个骨架的19个设计中, 排名前10的Jackhmmer命中的TM-score均为 < 0.6 。对于这些设计中涵盖相同4个骨架的8个设计, 排名前10的命中都可能是不同的折叠 (TM-score < 0.5)。这表明, 尽管在某些情况下模型能够在检测阈值上使用序列同源性, 但也存在一些案例显示它似乎已经超越了这一点, 进一步证据表明在许多情况下, 语言模型生成了与真实序列和天然蛋白质有所不同的新颖设计解决方案。

语言模型实现蛋白质设计的深层模式

生成的蛋白质显示出使用蛋白质结构设计的深层模式的证据。这些模式以结构模体的形式出现, 应用于在显著不同的序列背景下设计的天然蛋白质, 以及形成在相关结构中无法找到的模体。序列决定结构的两个广泛研究的方法是通过氨基酸限制主链几何形状, 以及化学多样化侧链在确定稳定蛋白质特定折叠构象中的作用。影响主链几何的两种氨基酸是脯氨酸和甘氨酸。这两种氨基酸分别增加了蛋白质主链的柔韧性和弯曲性。在三个示例设计中, 语言模型放置这些残基以诱导各种次级结构元素的曲率: 脯氨酸弯曲 α -螺旋, 甘氨酸在 β -折叠中的规律性放置促进了形成 β -桶的灵活性, 而在NTF2设计中除了一个甘氨酸外, 其余的都放置在环中 (图3A)。一个基于侧链的模体存在于固定骨架设计中, 称为螺旋偶极子封闭, 其中 α -螺旋末端氨基酸的侧链遮蔽了最终 α -螺旋转弯中暴露的极性主链原子 (图3B)。第二个基于侧链的模体是在含有肿块的 β -回转中的氢键网络, 这些网络存在于 β -桶的固定骨架设计中, 如6D0T和6CZJ (图.3C)。这个以及在图中的 β -链中的周期性甘氨酸在更大程度上被识别为促进成功新设计目标 β -桶的天然模体 (34)。

设计还体现出复杂的氢键网络。一些设计成功的案例包括在结构内部四个或更多极性甚至带电残基之间的氢键网络。由于能量上满足这些相互作用的几何约束, 设计埋藏的极性和带电相互作用是困难的 (35)。值得注意的是, 所示的键网络跨越了一系列分子间力类别: 在预测的结构中, F129, 一个 β -桶, 包含盐桥, F025包含 π -阳离子键, F030包含T型 π - π 相互作用

(图.S7)。所示示例的原始设计具有纯粹的疏水内部。虽然这些氢键网络只有通过高分辨率结构研究才能完全确认, 但观察到的生物物理特性 (单分散蛋白质的高产量以及预期的保留体积) 与其准确性一致, 因为这些残基的不准确放置可能导致错误折叠和聚集。

带有极性残基的氢键网络在新的序列上下文中被实现, 显示出一种超越用于训练模型的序列的强烈泛化形式。我们通过Jackhmmer查询UniRef90检索最相似的对齐序列, 并通过Foldseek查询相似的对齐结构 (36) 在AlphaFold DB (37) 中。返回的序列全部按对齐的基序位置的最小编辑距离排序, 并显示出最接近的匹配基序。(附录A.5.4)。对于生成的蛋白质F030 (图.3D, 图.S7), 序列搜索确实在对齐位置中找到了一个带有此基序的天然蛋白质。然而, 设计中的周围序列上下文是不相似的, 具有26%的全序列相似性。对于F129和F092 (图.3E, 图.S7), 周围的序列上下文不仅具有低序列相似性, 而且该基序本身在任何匹配的天然序列或结构的对齐位置中都不存在。在固定骨架设计中使用这些基序是一种显著的泛化形式, 因为模型在新的序列上下文以及天然蛋白质不同的结构中应用它们。

语言模型生成新的结构和序列

语言模型生成的新蛋白质序列与天然序列有显著不同。我们没有对结构施加约束, 采样了一大组 ($N = 25,000$) 固定长度 ($L = 100$) 的蛋白质。阻塞吉布斯采样方法遍历了序列和结构的联合景观, 提供了比以前的无约束生成方法更加多样化的蛋白质集合 (表 S5)。

生成的序列涵盖了多种拓扑, 整体上与天然蛋白质明显不同。使用AlphaFold预测所有生成序列的结构, 并基于TM-score测量的成对结构距离, 使用t-SNE将生成结果投影到二维 (图.4A)。在结构的层次聚类中, 识别出了7,663个独特的簇, TM-score阈值为0.75。生成的次级结构分布显示出多种模式, 其中52%的生成结果主要包含 α -螺旋, 22%主要包含 β -片, 28%则是 α -螺旋和 β -片的混合 (图.4B)。大量的生成结果得到了甲骨文的良好预测 (中位数pLDDT = 84.49, 70% pLDDT > 70 ; 图.4C)。

许多生成的序列与天然蛋白质的距离较远。我们通过在AlphaFold数据库中搜索与200M天然序列的每个生成序列来测量生成序列与天然蛋白质的距离 (37)。这也使得可以比较最近序列匹配的结构与生成的蛋白质的结构。总体而言, 语言模型生成的蛋白质

语言模型在天然蛋白质之外进行泛化




图 4. 语言模型生成新颖的结构和序列。(A) 使用 t-SNE 嵌入生成蛋白质所跨越的结构空间。颜色指示与最佳匹配的天然序列的序列相似性。很大一部分空间与天然蛋白质的序列相似性较低，16% 的生成物与天然蛋白质没有显著的序列匹配。通过绿色星星标示实验评估中成功的设计。(B) 生成物的二级结构分布。在不同的二级结构组成中观察到实验成功的设计（绿色）。(C) pLDDT 和 pTM 的分布表明设计是良好预测的（中位数 pLDDT 为 84.5）通过计算机模拟 甲骨文。(D) 序列和与天然蛋白质结构相似性的密度图。每个生成的蛋白质都从 AlphaFoldDB 检索出最佳匹配的天然序列。每个生成的蛋白质通过其序列相似性（x 轴）和与匹配的结构相似性（y 轴）进行绘制，未通过显著性阈值的命中在 x 轴标记为零。生成的蛋白质占据与天然蛋白质不同的空间的一部分，其中一些在与天然蛋白质的序列相似性较小（左下象限）。与通过计算机模拟筛选和实验成功的设计与生成的整体分布重合。(E) 实验评估的整体结果。大多数测试设计（55%）通过了溶解度测试，并在正确的置信区间内具有洗脱体积峰（顶部）。此外，高百分比（63%）的与天然序列相距较远的评估蛋白质是成功的（底部）。(F) 六个实验成功预测的结构（顶部）。这些结构与天然蛋白质的序列搜索中最显著命中的甲骨文预测结构进行了对齐（底部）；在所有示例中，预测的拓扑结构都是不同的。(G) 对于面板 F 中的生成物，显示与图 3A - 3C 中相同的基序：脯氨酸和甘氨酸诱导的曲率、螺旋封顶和转弯中的氢键网络。即使在与天然蛋白质相似性较小的蛋白质上，语言模型也能产生已知的基序。

语言模型超越天然蛋白质的泛化

与天然蛋白质的分布清晰分隔, 包括一部分远离已知蛋白质的样本。图. 4D显示了与已知蛋白质相似性的分布, 其中每一代根据其序列 (x轴) 和结构 (y轴) 与其最优序列命中相似性进行绘制, insignificant (E 值 > 1) 命中被置于 $x=0$ (总共 16.6% 的世代)。生成的蛋白质的结构与其最近序列匹配的预测结构不同, 这进一步证明该模型并非仅仅记忆已知的蛋白质。还显示了一组 15k 的天然蛋白质。天然蛋白质聚集在右上角, 而生成的蛋白质则占据了这一区域的不同部分。语言模型生成的蛋白质中有相当一部分 (15.5%) 与天然蛋白质的相似性极低 (左下象限), 与最近匹配的序列相似性最小 ($\text{Seq-id} < 0.2$), 且预测的结构可能属于不同的折叠 ($\text{TM-score} < 0.5$)。

大部分设计, 包括那些与天然蛋白质相距较远的设计, 在实验上都成功。我们选择了一些通过我们计算机模拟质量过滤器进行实验评估的设计。在全部生成中, 20% ($N = 5,198$) 通过了质量过滤器 (附录A.4)。该组中总共有 129 个设计被表达和评估, 其中 55% (71/129) 被发现是实验成功的。这 71 个结构及其指标显示在图中。S8, 在图中以绿色星标记。4A, 4B 和 4D。总的来说, 96% 的被评估的自由生成是可溶的, 55% 的洗脱体积在正确的置信区间内出现峰值, 30% 是单分散的 (图. 4E 顶部, 附录 A.7)。

对于远离天然蛋白质的生成, 观察到较高的成功率。对于一组49个远离的生成 (图. 4D, 左下象限), 49个中有31个 (63%) 在实验评估中成功。对于这31个实验成功案例, 我们对其与天然蛋白质的相似性进行更深入的分析。我们进一步将每个案例与UniRef90进行对比, UniRef90提供了天然蛋白质的全面覆盖, 并完全包含了语言模型的训练集。在31个远离的设计中, 16个没有显著的 (E 值 $<$

1) 序列匹配 (图. S9)。无论其重要性如何, 我们获得了前10个序列匹配的预测结构。在31个远端设计中, 12个的序列匹配中 (其中5个显示在图. 4F), 没有一个序列匹配很可能具有相同的折叠 ($\text{TM-score} < 0.5$) (图. S9)。预测的结构通常是可信的 (78%的预测具有 $\text{pLDDT} > 70$, 平均 $\text{pLDDT} = 81.24$)。在固定骨架设计中观察到的结构基序, 如脯氨酸和甘氨酸的位置、螺旋封口以及氢键网络, 也出现在新设计的生成中 (图. 4G)。总体来看, 这些结果表明, 语言模型在天然蛋白质之外进行泛化, 以生成新设计蛋白质。

进化规模语言模型

变压器蛋白质语言模型由 (7) 引入, 研究发现无监督训练产生了关于功能和三级结构的信息。在较小规模的同时工作中, 检查了基于LSTM的模型 (38–40)。大规模蛋白质语言模型参数达到数十亿-

参数现在已开源 (8, 41–43)。生成语言模型的使用最近已通过计算机模拟研究 (44, 45), 并通过确认生成的新序列对已有蛋白质家族的功能进行了实验证实 (22)。截至目前, 我们所知, 基于序列的模型经过实验证实的工作 (20, 22, 46) 尚未达到与天然蛋白质的%身份阈值的 < 30 。

结论

经典的序列空间图景将其视为围绕每个蛋白质家族的独立局部进化景观, 会暗示语言模型仅限于对天然蛋白质空间的记忆。与此一致的是, 在蛋白质的语言模型中出现的关于结构的信息被证明依赖于在训练期间模型可用的进化信息, 这似乎对生成性地使用语言模型超越天然蛋白质的潜力并不乐观。我们在这里提供了相反的证据: 语言模型超越天然蛋白质家族对序列空间进行概括, 以生成远离天然蛋白质的蛋白质。我们的结果是首次证明纯基于序列的方法能够超越天然蛋白质进行概括, 并且对基于序列的生成性人工智能在新设计蛋白质设计方面充满希望, 在那里我们证明存在一个远离自然界的新设计蛋白质空间, 可以被生成语言模型设计。

这种概括指向了潜在于自然序列的更深层结构, 及一个可由语言模型学习的深层语法的存在。我们的结果表明, 通过进化生成的广泛的蛋白质序列包含生物结构和功能的图像, 揭示了可跨蛋白质应用的设计模式, 这些模式可以被完全基于序列的模型学习和重新组合。超越天然蛋白质的概括并不一定表明语言模型正在学习物理能量。语言模型可能仍在学习模式, 而不是物理能量, 但可以推测, 在无限序列数据的极限下, 这些模式可能接近物理能量。至少, 语言模型必须发展出蛋白质的全球一致性的理解, 连接序列和折叠结构。

在蛋白质之间存在深层语法将解释表面上似乎相互矛盾的两个观察: 一是对天然蛋白质的理解依赖于训练数据中的进化支持, 二是语言模型在已知的天然蛋白质家族之外进行概括。如果可学习模式存在幂律分布, 那么预期许多蛋白质结构将能够使用在训练数据中获得最多支持的常见模式进行设计。同时, 模式在训练数据中出现的频率将与这些模式的可学习性相关。学习稀有模式需要更多的训练数据和模型容量。这与观察到的新设计空间的概括 (通过已学习的模式可访问) 及对训练中支持的依赖是一致的。

语言模型超越天然蛋白质的概括能力

数据 (由稀有模式组成的蛋白质更难以学习)。如果缩放法则继续适用于蛋白质语言模型, 我们可以预期它们的生成能力将继续提高。随着模型和数据的扩大, 存在可学习的基础语法将预测稀有模式将被学习, 从而扩展模型的预测能力和可访问的设计空间。

致谢

我们要感谢哈利尔·阿金、萨尔瓦托雷·坎迪多、布莱恩·希、亚当·勒雷、朱仲凯、陆文婷、罗尚·拉奥、雅尼夫·舒梅利、尼基塔·斯梅塔宁和坪山幸太郎提供的技术支持、反馈和讨论, 这些对塑造本项目有着重要帮助。我们感谢克里斯托弗·诺恩和安娜斯塔西亚·沃罗比耶娃对新设计蛋白质结构的见解, 也感谢伊万·阿尼申科分享的新设计蛋白质目标集合。我们感谢加布里埃尔·洛克林和坪山幸太郎在项目初期进行的稳定性实验。我们感谢劳伦斯·范德马滕、阿迈尔·里兹维、乔恩·谢泼德和乔·斯皮萨克的项目支持。

本工作得到了在蛋白质设计研究所的大胆计划 (D.B.) 提供的资金支持, 以及来自欧洲分子生物学组织的长远研究奖学金 (ALTF 139-2018, 给予 B.I.M.W.), 开放慈善项目改善蛋白质设计基金 (J.D. 和 D.B.), 人类前沿科学计划跨学科奖学金 (LT000395/2020-C, 给予 L.F.M.), 欧洲分子生物学组织非补贴奖学金 (ALTF 1047-2019, 给予 L.F.M.), Meta 的资助 (D.B.), 以及霍华德·休斯医学研究所 (D.B.)。在此项目中, S.O. 获得了 NIH 赠款 DP5OD026389 和 NSF 赠款 MCB2032259 的支持。

参考文献

- [1] Meta 基础人工智能研究外交小组 (FAIR), Anton Bakhtin, Noam Brown, Emily Dinan, Gabriele Farina, Colin Flaherty, Daniel Fried, Andrew Goff, Jonathan Gray, Hengyuan Hu 等。通过结合语言模型与战略推理, 实现人类水平的外交游戏玩法。科学, 页面 eade9097, 2022。
- [2] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell 等。语言模型是少量学习者。arXiv:2005.14165, 2020。
- [3] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, 以及 Denny Zhou。思维链提示在大型语言模型中引发推理。2022 年 6 月。网址 <http://arxiv.org/abs/2201.11903>。arXiv:2201.11903 [cs]。
- [4] Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai 和 Quoc V Le。微调语言模型是零-shot 学习者。第 46 页, 2022 年。
- [5] 贾里德·卡普兰, 萨姆·麦坤立什, 汤姆·亨尼根, 汤姆·B 布朗, 本杰明·切斯, 瑞翁·查尔德, 斯科特·格雷, 阿列克·拉德福德, 杰弗里·吴和达里奥·阿莫代。神经语言模型的扩展规律。arXiv:2001.08361, 2020。
- [6] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann 等。Palm: 通过路径扩展语言建模。arXiv:2204.02311, 2022 年。
- [7] 亚历山大·里夫斯, Joshua Meier, 汤姆·塞尔库, Siddharth Goyal, Zeming Lin, 杰森·刘, Demi Guo, Myle Ott, C. Lawrence Zitnick, Jerry Ma 和 Rob Fergus。生物结构和功能是通过将无监督学习扩展到 2.5 亿蛋白质序列而产生的。美国国家科学院院刊, 118(15): e2016239118, 2021 年 4 月。doi: 10.1073/pnas.2016239118。URL <https://www.pnas.org/doi/full/10.1073/pnas.2016239118>。出版者: 美国国家科学院院刊。
- [8] 陆文婷、哈利尔·阿金、罗尚·拉奥、布莱恩·希、朱仲凯、Wenting Lu、尼基塔·斯梅塔宁、罗伯特·维尔基尔、奥里·卡贝利、雅尼夫·舒梅利、Allan dos Santos Costa、Maryam Fazel-Zarandi、汤姆·塞尔库、萨尔瓦托雷·坎迪多和亚历山大·里夫斯。使用语言模型进行进化规模的原子级蛋白质结构预测, 2022 年 10 月。URL <https://www.biorxiv.org/content/10.1101/2022.07.20.500902v2>。页码: 2022.07.20.500902 部分: 新结果。
- [9] 罗尚·拉奥、Joshua Meier、汤姆·塞尔库、谢尔盖·欧夫钦科夫和亚历山大·里夫斯。变压器蛋白语言模型是无监督结构学习者。2021 年 3 月。URL <https://openreview.net/forum?id=fylclEgvgd>。
- [10] Po-Ssu Huang、斯科特·E·博伊肯和大卫·贝克。新蛋白设计的成熟。自然, 537(7620): 320–327, 2016 年 9 月。ISSN 1476-4687。doi: 10.1038/nature19946。网址 <https://www.nature.com/articles/nature19946>。编号: 7620 出版社: 自然出版集团。
- [11] 伊万·阿尼申科、塞缪尔·J·佩洛克、塔穆卡·M·奇迪亚乌西库、特雷莎·A·拉梅洛特、谢尔盖·欧夫钦科夫、浩晶洲、库什布·巴夫纳、克里斯托弗·诺恩、亚历克斯·康、阿西姆·K·贝拉、弗兰克·迪马约、劳伦·卡特、卡梅隆·M·周、盖塔诺·T·蒙特利昂和大卫·贝克。通过深度网络幻觉进行新蛋白设计。自然, 600(7889): 547–552, 2021 年 12 月。ISSN 1476-4687。doi: 10.1038/s41586-021-04184-w。网址 <https://www.nature.com/articles/s41586-021-04184-w>。编号: 7889 出版社: 自然出版集团。
- [12] 王璐、西德尼·利桑扎、大卫·尤根斯、道格·蒂舍尔、约瑟夫·L·沃森、卡拉·M·卡斯特罗、罗伯特·拉戈特、阿米·贾伊·萨拉戈维、卢卡斯·F·米勒斯、白敏京、伊万·安涅申科、杨伟、德里克·R·希克斯、马克·Exp'osit,

语言模型超越天然蛋白质的概括能力

- 托马斯·施利赫塔尔、郑弘在、尤斯塔斯·道帕拉斯、内森·贝内特、巴西尔·I·M·维基、安德鲁·穆恩克斯、弗兰克·迪马约、布鲁诺·科雷亚、谢尔盖·奥夫奇尼科夫和大卫·贝克。利用深度学习搭建蛋白质功能位点。科学, 377(6604):387–394, 2022年7月。doi: 10.1126/science.abn2100。URL <https://www.science.org/doi/10.1126/science.abn2100>。出版社: 美国科学促进会。
- [13] 约翰·英格雷汉、维卡斯·戈尔、瑞吉娜·巴尔齐莱和汤米·贾卡拉。用于基于图形的蛋白质设计的生成模型。在 H. 瓦拉赫、H. 拉罗谢尔、A. 贝格尔齐默、F. d'Alché-Buc、E. 福克斯和 R. 加内特编辑, 神经信息处理系统进展, 第 32 卷。卡伦协会公司, 2019。网址 <https://proceedings.neurips.cc/paper/2019/file/f3a4ff4839c56a5f460c88cce3666a2b-Paper.pdf>。
- [14] 克洛伊·徐、罗伯特·维尔基尔、杰森·刘、Zeming Lin、布莱恩·希、汤姆·塞尔库、亚当·勒雷和亚历山大·里夫斯。学习从数百万个预测结构中进行反折叠。在第 39 届国际机器学习会议论文集, 页码 8946–8970。PMLR, 2022年6月。网址 <https://proceedings.mlr.press/v162/hsu22a.html>。ISSN: 2640-3498。
- [15] J. 道帕拉斯, I. 阿尼申科, N. 贝内特, H. 白, R. J. 拉戈特, L. F. 米尔斯, B. I. M. 威基, A. 库尔贝, R. J. 德哈斯, N. 贝瑟尔, P. J. Y. 梁, T. F. 哈迪, S. 佩洛克, D. 蒂舍尔, F. 陈, B. 科普尼克, H. 阮, A. 康, B. 桑卡然, A. K. 贝拉, N. P. 金, 以及 D. 贝克。基于深度学习的稳健蛋白质序列设计使用 ProteinMPNN。科学, 378(6615): 49–56, 2022年10月。doi: 10.1126/science.add2187。网址 <https://www.science.org/doi/10.1126/science.add2187>。出版商: 美国科学促进会。
- [16] 詹姆斯·P·罗尼和谢尔盖·奥夫奇尼科夫。利用 AlphaFold 进行蛋白质模型准确性最先进的评估。物理评论快报, 129(23): 238101, 2022年11月。doi: 10.1103/PhysRevLett.129.238101。URL <https://link.aps.org/doi/10.1103/PhysRevLett.129.238101>。出版商: 美国物理学会。
- [17] D. Altschuh, A. M. Lesk, A. C. Bloomer 和 A. Klug。与烟草花叶病毒相关的病毒中协调的氨基酸替换与功能的相关性。分子生物学杂志, 193(4): 693–707, 1987年2月。ISSN 0022-2836。doi: 10.1016/0022-2836(87)90352-4。URL <https://www.sciencedirect.com/science/article/pii/0022283687903524>。
- [18] Ulrike G̃obel, Chris Sander, Reinhard Schneider 和 Alfonso Valencia。蛋白质中的相关突变和残基接触。蛋白质: 结构, 功能与生物信息学, 18(4):309–317, 1994年。
- ISSN 1097-0134。doi: 10.1002/prot.340180402。URL <https://onlinelibrary.wiley.com/doi/abs/10.1002/prot.340180402>。电子版: 抱歉, 我无法访问外部链接。请提供您希望翻译的具体文本内容。
- [19] C. Yanofsky, B. C. Carlton, J. R. Guest, D. R. Helinski 和 U. Henning。关于基因结构与蛋白质结构的共线性*美国国家科学院院刊, 51(2):266–272, 1964年2月。doi: 10.1073/pnas.51.2.266。URL <https://www.pnas.org/doi/abs/10.1073/pnas.51.2.266>。出版商: 美国国家科学院院刊。
- [20] William P. Russ, Matteo Figliuzzi, Christian Stocker, Pierre Barrat-Charlaix, Michael Socolich, Peter Kast, Donald Hilvert, Remi Monasson, Simona Cocco, Martin Weigt 和 Rama Ranganathan。一种基于进化的酶设计模型, 用于设计酪氨酸突变酶。科学, 369(6502):440–445, 2020年7月。doi: 10.1126/science.aba3304。URL <https://www.science.org/doi/abs/10.1126/science.aba3304>。出版商: 美国科学促进会。
- [21] Jung-Eun Shin, Adam J. Riesselman, Aaron W. Kol-lasch, Conor McMahon, Elana Simon, Chris Sander, Aashish Manglik, Andrew C. Kruse, 和 Debora S. Marks。使用自回归生成模型进行蛋白质设计和变体预测。自然通讯, 12(1): 2403, 2021年4月。ISSN 2041-1723。doi: 10.1038/s41467-021-22732-w。URL <https://www.nature.com/articles/s41467-021-22732-w>。号码: 1 出版商: 自然出版集团。
- [22] Ali Madani, Ben Krause, Eric R. Greene, Subu Subramanian, Benjamin P. Mohr, James M. Holton, Jose Luis Olmos, Caiming Xiong, Zachary Z. Sun, Richard Socher, James S. Fraser 和 Nikhil Naik。深度神经语言建模能够跨家族生成功能性蛋白质, 2021年7月。网址 <https://www.biorxiv.org/content/10.1101/2021.07.18.452833v1>。页码: 2021.07.18.452833 部分: 新结果。
- [23] K F Han 和 D Baker。局部氨基酸序列与蛋白质局部结构之间映射的全局属性。美国国家科学院院刊, 93(12):5814–5818, 1996年6月。doi: 10.1073/pnas.93.12.5814。URL <https://www.pnas.org/doi/abs/10.1073/pnas.93.12.5814>。出版社: 美国国家科学院院刊。
- [24] Craig O. Mackenzie, Jianfu Zhou 和 Gevorg Grigoryan。可观察到的蛋白质结构宇宙的三级字母。美国国家科学院院刊, 113(47):E7438–E7447, 2016年11月。doi: 10.1073/pnas.1607178113。URL <https://www.pnas.org/doi/full/10.1073/pnas.1607178113>。出版社: 美国国家科学院院刊。

语言模型超越了天然蛋白质的普遍化

- [25] W Kabsch 和 C Sander. 关于利用序列同源性预测蛋白质结构: 相同的肽链可能会有完全不同的构象。美国国家科学院院刊, 81 (4):1075–1078, 1984年2月。doi: 10.1073/pnas.81.4.1075. URL <https://www.pnas.org/doi/abs/10.1073/pnas.81.4.1075>. 发表者: 美国国家科学院院刊。
- [26] 小贺信康, 辰巳小贺梨惠, 刘高华, 肖荣, 托马斯·B·阿克顿, 盖塔诺·T·蒙特利昂和大卫·贝克。理想蛋白质结构设计的原则。自然, 491(7423): 222–227, 2012年11月。ISSN 1476-4687. doi: 10.1038/nature11600. URL <https://www.nature.com/articles/nature11600>. 期号: 7423 出版者: 自然出版集团。
- [27] 斯蒂芬·K·伯利, 海伦·M·伯曼, 查尔米·比哈基蒂亚, 邢春晓, 李晨, 路易吉·迪·科斯坦佐, 科尔·克里斯蒂, 肯·达伦博格, 何塞·M·杜阿特, 舒奇斯基塔·达塔, 冯足康, 苏塔帕·戈什, 大卫·S·古德塞尔, 瑞切尔·K·格林, 弗拉基米尔·古拉诺维奇, 季米特罗·古赞科, 布莱恩·P·哈德森, 塔拉·卡尔罗, 余鹤两, 罗伯特·洛, 哈利·南孔, 艾兹拉·佩萨赫, 伊琳娜·佩里斯科娃, 安德烈亚斯·普利克, 克里斯·兰德尔, 亚历山大·罗斯, 彼得·罗斯, 劳尔·萨拉, 莫妮卡·塞卡兰, 单承华, 李华·谭, 姚平·陶, 雅娜·瓦拉萨塔瓦, 玛丽亚·沃伊特, 约翰·韦斯特布鲁克, 杰西·吴, 欢王杨, 贾斯敏·杨, 玛丽娜·朱拉夫列娃和克里斯汀·扎尔德基。RCSB 蛋白质数据银行: 为基础生物学、生物医学、生物技术和能源的研究及教育提供生物大分子结构。核酸研究, 47(D1): D464–D474, 2019年1月。ISSN 1362-4962. doi: 10.1093/nar/gky1004.
- [28] 巴里斯·E·苏泽克、王宇祺、黄洪瞻、彼得·B·麦卡维、吴凯西和UniProt联合体。UniRef集群: 一种全面且可扩展的替代方法, 用于改进序列相似性搜索。生物信息学, 第31卷 (6):926–932, 2015年3月。ISSN 1367-4803. doi: 10.1093/bioinformatics/btu739. URL <https://doi.org/10.1093/bioinformatics/btu739>.
- [29] 雅各布·德夫林、张铭伟、肯顿·李和克里斯蒂娜·托塔诺娃。BERT: 用于语言理解的深度双向变换器的预训练。在2019年北美计算语言学协会会议论文集: 人类语言技术, 第1卷 (长文和短文), 第4171–4186页, 明尼阿波利斯, 明尼苏达州, 2019年6月。计算语言学协会。doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423>.
- [30] 杰西·维格, Ali Madani, 拉夫·R·瓦尔什尼, Caiming Xiong, Richard Socher, 和 纳兹宁·法蒂玛·拉贾尼。BERT学科与生物学相遇: 解读蛋白质语言模型中的注意力, 2021年3月。URL <http://arxiv.org/abs/2006.15222>. arXiv:2006.15222 [cs, q-bio].
- [31] 乔舒亚·迈尔、罗尚·拉奥、罗伯特·维尔基尔、杰森·刘、汤姆·塞尔库和亚历克斯·里维斯。语言模型使得零-shot预测突变对蛋白质功能的影响。在神经信息处理系统进展, 第34卷, 第29287–29303页。卡伦协会公司, 2021。网址 <https://proceedings.neurips.cc/paper/2021/hash/f51338d736f95dd42427296047067694-Abstract.html>.
- [32] 丽贝卡·F·阿尔福德, 安德鲁·利弗-费, 杰利亚兹科·R·杰利亚兹科夫, 马修·J·奥梅拉, 弗兰克·P·迪迈奥, 朴汉博, 马克西姆·V·沙波瓦洛夫, P·道格拉斯·伦弗鲁, 维克拉姆·K·穆利根, 卡莉·卡佩尔, 杰森·W·拉邦特, 迈克尔·S·帕切拉, 理查德·博诺, 菲利普·布拉德利, 罗兰·L·邓布拉克, 瑞基·达斯, 大卫·贝克, 布莱恩·库尔曼, 坦雅·科尔特梅, 杰弗里·J·格雷。《Rosetta全原子能量函数用于大分子建模与设计》。《化学理论与计算杂志》, 13 (6): 3031–3048, 2017年6月。ISSN 1549-9618. doi: 10.1021/acs.jctc.7b00125. URL <https://doi.org/10.1021/acs.jctc.7b00125>. 出版商: 美国化学学会。
- [33] 朱莉亚·科勒·莱曼、布赖恩·D·韦茨纳、史蒂文·M·刘易斯、贾勒德·阿道夫·布里福格尔、诺萨德·阿拉姆、丽贝卡·F·阿尔福德、梅兰妮·阿普拉哈米安、大卫·贝克、凯尔·A·巴洛、帕特里克·巴尔特、本杰明·巴桑塔、布赖恩·J·本德、克里斯汀·布莱克洛克、哈梅·博内特、斯科特·博伊肯、菲尔·布拉德利、克里斯·拜斯特罗夫、帕特里克·康威、赛斯·库珀、布鲁诺·E·科雷亚、布赖恩·考文·特里、瑞基·达斯、瑞妮·M·德容、弗兰克·迪马约、洛娜·德西尔瓦、罗兰·邓布拉克、亚历克斯·福特、布兰登·弗伦茨、达尔文·Y·福、凯勒布·杰尼埃斯、卢卡斯·戈德施密特、拉古尔·高塔曼、杰弗瑞·J·格雷、多米尼克·格朗特、沙龙·古菲、斯科特·霍洛维茨、Po-Ssu Huang、托马斯·胡贝尔、蒂姆·M·雅各布斯、杰利亚兹科·R·杰利亚兹科夫、大卫·K·约翰逊、卡莉·卡佩尔、约翰·卡拉尼科拉斯、哈梅德·哈克扎德、凯伦·R·卡尔、萨加尔·D·卡雷、菲拉斯·哈提布、阿丽莎·赫拉穆申、靛蓝·C·金、罗伯特·克莱夫纳、布赖恩·科普尼克、坦雅·科尔特梅、乔治·库恩采、布莱恩·库尔曼、黑田大辅、杰森·W·拉邦特、杰森·K·赖、基德昂·拉皮多斯、安德鲁·利弗-费、斯特芬·林代特、托马斯·林斯基、宁尔·伦敦、约瑟夫·H·卢宾、谢尔盖·利斯科夫、杰克·麦圭尔、拉尔斯·马尔姆斯特罗姆、恩里克·马尔科斯基、奥尔利·马尔库、尼古拉斯·A·马尔泽、延斯·迈勒、罗科·莫雷蒂、维克拉姆·基普尔·穆利根、圣图普提·内尔利、克里斯托弗·诺恩、香农·史密斯、诺亚·奥利凯宁、谢尔盖·奥夫奇尼科夫、迈克尔·S·帕切拉、潘星杰、朴汉博、瑞安·E·帕夫洛维茨、马娜西·佩特、布赖恩·G·皮尔斯、卡拉·巴拉特·皮拉、巴拉克·拉维赫、P·道格拉斯·伦弗鲁、绍里亚·S·罗伊·巴尔蒙、阿丽莎·鲁本斯坦、玛丽昂·F·索尔、安德烈亚斯·舍克、威廉·希夫、奥拉·施威勒-弗曼、尤瓦尔·塞丹、亚历山大·M·塞维、尼古拉斯·G·斯古拉基斯、施雷、贾斯廷·西格尔、丹尼尔·阿德里亚诺·席尔瓦、香农·史密斯、易凡·宋、阿美丽·施泰因、玛丽亚·塞杰迪、弗兰克·D·蒂茨、萨默·B·泰姆、王育瑞、安德鲁·沃特金斯、利奥尔·齐默尔曼和理查德·博诺。宏观分子建模与设计在Rosetta中的应用: 最近的方法和框架。自然

语言模型超越天然蛋白质的概括能力

- 方法, 17(7):665–680, 2020 年 7 月。ISSN 1548-7091。doi: 10.1038/s41592-020-0848-2。网址<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7603796/>.
- [34] 周佳怡, 阿纳斯塔西娅·沃罗比耶娃, 威廉·谢夫勒, 林赛·A·道尔, 朴汉博, 马修·J·比克, 毛彬晨, 格伦娜·W·福特, 李敏延, 劳伦·A·甘农, 劳伦·卡特, 班努马蒂·桑卡兰, 谢尔盖·欧夫钦科夫, 恩里克·马尔科斯, Po-Ssu Huang, 约书亚·C·沃恩, 巴里·L·斯托达德, 大卫·贝克。新设计一种荧光激活 β -桶状蛋白。自然, 561(7724): 485–491, 2018 年 9 月。ISSN 1476-4687。doi: 10.1038/s41586-018-0509-0。网址<https://www.nature.com/articles/s41586-018-0509-0>。编号: 7724 出版社: 自然出版集团。
- [35] 斯科特·E·博伊肯, 陈子博, 本杰明·格罗夫斯, 罗伯特·A·兰甘, 古斯塔夫·奥伯多费尔, 亚历克斯·福特, 贾森·M·吉尔莫, 许春福, 弗兰克·迪马约, 何塞·亨利克·佩雷拉, 班努马蒂·桑卡兰, 乔治·西利格, 彼得·H·兹瓦特, 大卫·贝克。新设计具有模块氢键网络介导特性的蛋白质同聚体。科学, 352(6286): 680–687, 2016 年 5 月。doi: 10.1126/science.aad8865。网址 <https://www.science.org/doi/10.1126/science.aad8865>。出版社: 美国科学促进会。
- [36] 米歇尔·范·肯潘, 斯蒂芬妮·金, 夏洛特·图梅谢特, 米洛特·米尔迪塔, 卡梅伦·L·M·吉尔克里斯特, 约翰内斯·S·奥丁和马丁·斯坦尼杰。Foldseek: 快速且准确的蛋白质结构搜索, 2022 年 9 月。网址<https://www.biorxiv.org/content/10.1101/2022.02.07.479398v4>。页面: 2022.02.07.479398 部分: 新结果。
- [37] 米哈伊·瓦拉迪, 斯蒂芬·安扬戈, 曼达尔·德什潘德, 斯里纳斯·纳尔, 辛迪·纳塔西亚, 加拉比娜·约尔达诺娃, 大卫·袁, 奥安娜·斯特罗, 杰玛·伍德, 阿加塔·莱顿, 奥古斯丁·V·Zidek, 蒂姆·格林, 凯瑟琳·图尼亚苏瓦纳库尔, 斯蒂格·彼得森, 约翰·贾波, 艾伦·克兰西, 理查德·格林, 安库尔·沃拉, 米拉·卢特菲, 迈克尔·菲古尔诺夫, 安德鲁·考威, 尼科尔·霍布斯, 普什梅特·科利, 杰拉德·克莱韦格特, 伊万·伯尼, 德米斯·哈萨比斯和萨米尔·维兰卡。AlphaFold 蛋白质结构数据库: 大幅扩展蛋白质序列空间的结构覆盖范围, 提供高精度模型。核酸研究, 50(D1):D439–D444, 2022 年 1 月。ISSN 0305-1048。doi: 10.1093/nar/gkab1061。网址<https://doi.org/10.1093/nar/gkab1061>。
- [38] 特里斯坦·贝普勒与邦妮·伯杰。利用结构信息学习蛋白质序列嵌入。在国际学习表征会议, 2019 年。
- [39] 伊桑·C·阿利, 格里戈里·基穆利亚, 苏罗吉特·比斯瓦斯, 穆罕默德·阿尔库拉伊希, 以及乔治·M·丘奇。基于序列的深度表示学习的统一理性蛋白质工程。自然方法, 16(12):1315–1322, 2019 年 12 月。ISSN 1548-7105。doi: 10.1038/s41592-019-0598-1。URL<https://www.nature.com/articles/s41592-019-0598-1>。期号: 12 出版社: 自然出版集团。
- [40] 迈克尔·海因辛格、阿赫梅德·埃尔纳格尔、吴宇、克里斯蒂安·达拉戈、德米特里·涅恰耶夫、弗洛里安·马特斯和布尔哈德·罗斯特。通过迁移学习建模生命语言的各个方面。BMC 生物信息学, 20(1):723, 2019 年 12 月。ISSN 1471-2105。doi: 10.1186/s12859-019-3220-8。网址<https://doi.org/10.1186/s12859-019-3220-8>。
- [41] 阿赫梅德·埃尔纳格尔、迈克尔·海因辛格、克里斯蒂安·达拉戈、加利亚·瑞哈维、吴宇、利昂·琼斯、汤姆·吉布斯、塔玛斯·费赫尔、克里斯托弗·安格雷、马丁·斯坦尼杰、德布辛杜·博米克和布尔哈德·罗斯特。ProtTrans: 通过自我监督学习理解生命的语言。IEEE 模式分析与机器学习汇刊, 44(10):7112–7127, 2022 年 10 月。ISSN 1939-3539。doi: 10.1109/TPAMI.2021.3095381。会议名称: IEEE 模式分析与机器学习汇刊。
- [42] 丹尼尔·赫斯洛, 尼科洛·扎尼切利, 帕斯卡尔·诺丁, 雅科波·波利和德博拉·马克斯。RITA: 关于扩展生成蛋白质序列模型的研究, 2022 年 7 月。URL<http://arxiv.org/abs/2205.05789>。arXiv:2205.05789[cs, q-bio]。
- [43] 埃里克·奈坎普, 杰弗里·鲁福洛, 伊莱·N·温斯坦, Nikhil Naik 和 Ali Madani。ProGen2: 探索蛋白质语言模型的边界, 2022 年 6 月。URL<http://arxiv.org/abs/2206.13517>。arXiv:2206.13517[cs, q-bio]。
- [44] 路易斯·莫法特, 肖恩·M·坎达希尔和大卫·T·琼斯。设计在黑暗中: 学习深度生成模型进行新蛋白设计, 2022 年 1 月。URL<https://www.biorxiv.org/content/10.1101/2022.01.27.478087v1>。页码: 2022.01.27.478087 章节: 新结果。
- [45] Noelia Ferruz, Steffen Schmidt 和 Birte Hocker。Prot-GPT2 是一个用于蛋白质设计的深度无监督语言模型。自然通讯, 13(1): 4348, 2022 年 7 月。ISSN 2041-1723。doi: 10.1038/s41467-022-32007-7。URL<https://www.nature.com/articles/s41467-022-32007-7>。出版号: 1 发行人: 自然出版集团。
- [46] 田鹏飞、约翰·M·路易斯、詹姆斯·L·巴伯、安妮·阿尼安娜和罗伯特·B·贝斯特。序列设计的共进化适应性景观。应用化学国际版, 57(20): 5674–5678, 2018 年。ISSN 1521-3773。doi: 10.1002/anie.201713220。URL <https://onlinelibrary.wiley.com/doi/abs/10.1002/anie.201713220>。电子版: <https://onlinelibrary.wiley.com/doi/pdf/10.1002/anie.201713220>。

语言模型超越天然蛋白质的泛化

- [47] 布莱恩·库尔曼、高坦·丹塔斯、格雷戈里·C·艾尔顿、加布丽埃尔·瓦拉尼、巴里·L·斯托达德和大卫·贝克。设计具有原子级精度的新型球形蛋白质折叠。科学, 302(5649):1364–1368, 2003年11月。doi: 10.1126/science.1089427。URL<https://www.science.org/doi/10.1126/science.1089427>。出版商: 美国科学促进会。
- [48] 印地戈·克里斯·金, 詹姆斯·格莱克斯纳, 林赛·道尔, 亚历克斯·库金, 约翰·F·亨特, 肖荣, 盖坦诺·T·蒙泰利昂, 巴里·L·斯多达德, 弗兰克·迪马约和大卫·贝克。通过新设计的构建块精确组装复杂的 β 片层拓扑。eLife, 4:e11012, 2015年12月。ISSN 2050-084X。doi: 10.7554/eLife.11012。URL<https://doi.org/10.7554/eLife.11012>。出版商: eLife科学出版公司, 有限公司。
- [49] 恩里克·马尔科斯, 本杰明·巴桑塔, 塔穆卡·M·奇迪亚乌西库, 岳峰·唐, 古斯塔夫·奥伯多费尔, 刘高华, G.V.T.斯瓦普纳, 关荣金, 丹尼尔·阿德里亚诺·席尔瓦, 周佳怡, 何塞·亨利克·佩雷拉, 肖荣, 班努马蒂·桑卡兰, 彼得·H·兹瓦特, 盖塔诺·T·蒙特利昂和大卫·贝克。设计带有弯曲形成的空腔的蛋白质的原则 β 片层。科学, 355(6321):201–206, 2017年1月。doi: 10.1126/science.aah7389。URL<https://www.science.org/doi/10.1126/science.aah7389>。出版商: 美国科学促进会。
- [50] 恩里克·马尔科斯, 塔穆卡·M·奇迪亚乌西库, 安德鲁·C·麦克香, 托马斯·埃万杰利迪斯, 圣图普提·内尔利, 劳伦·卡特, 卢卡斯·G·尼夫, 奥德里·戴维斯, 古斯塔夫·奥伯多费尔, 康斯坦丁诺斯·特里普西安斯, 尼古拉斯·G·斯古拉基斯以及大卫·贝克。新设计一种具有高稳定性和准确性的非局部 $\beta\beta$ -片段蛋白。自然结构与分子生物学, 25 (11):1028–1034, 2018年11月。ISSN 1545-9985。doi: 10.1038/s41594-018-0141-6。网址<https://www.nature.com/articles/s41594-018-0141-6>。编号: 11 出版社: 自然出版集团。
- [51] 丹尼尔·阿德里亚诺·席尔瓦, 肖恩·余, 乌穆特·Y·乌尔格, 杰米·B·斯潘格勒, 凯文·M·朱德, 卡洛斯拉布·ao-Almeida, 列斯塔·R·阿里, 阿尔弗雷多·基哈诺·鲁比奥, 迈克尔·鲁特布希, 伊莎贝尔·梁, 塔玛拉·比亚里, 斯蒂芬妮·J·克劳利, 恩里克·马尔科斯, 卡尔·D·沃基, 布赖恩·D·韦茨纳, Fátima Pardo-Avila, 哈维尔·卡斯特兰诺斯, 劳伦·卡特, 兰斯·斯图尔特, 斯坦利·R·里德尔, 玛丽昂·佩珀, Gonçalo J. L. Bernardes, 迈克尔·杜根, K·克里斯托弗·加西亚, 和大卫·贝克。新设计强效且选择性IL-2和IL-15的模拟物。自然, 565 (7738):186–191, 2019年1月。ISSN 1476-4687。doi: 10.1038/s41586-018-0830-7。URL<https://www.nature.com/articles/s41586-018-0830-7>。号码: 7738 出版商: 自然出版集团。
- [52] 布赖恩·科普尼克, 杰夫·弗拉滕, 塔米尔·胡赛因, 亚历克斯·福特, 丹尼尔·阿德里亚诺·席尔瓦, 马修·J·比克, 亚伦·鲍尔, 刘高华, 石田洋次郎, 亚历山大·博伊科夫, 罗杰·D·埃斯特普, 苏珊·克莱因费尔特, 托克·诺尔加德·索拉诺, 琳达·韦, Foldit Players, 盖塔诺·T·蒙特利昂, 弗兰克·迪马约, 佐兰·波波维ć, 菲拉斯·哈提布, 塞思·库珀, 大卫·贝克。由公民科学家进行的新蛋白设计。自然, 570 (7761):390–394, 2019年6月。ISSN 1476-4687。doi: 10.1038/s41586-019-1274-4。URL<https://www.nature.com/articles/s41586-019-1274-4>。编号: 7761 出版社: 自然出版集团。
- [53] 小贺信康、山本真美、久杉隆宏、小林直宏、杉木敏彦、藤原俊道和小贺信康。即使大部分核心突变为缬氨酸, 经过新设计的理想蛋白质仍能稳健折叠。美国国家科学院院刊, 117(49):31149–31156, 2020年12月。ISSN 0027-8424, 1091-6490。doi: 10.1073/pnas.2002120117。URL<https://pnas.org/doi/full/10.1073/pnas.2002120117>。
- [54] 肖恩·J·考德威尔、伊恩·C·海登、尼科莱塔·皮佩里杜、黄博树、马修·J·比克、H·塞巴斯蒂安·斯特罗斯“ost”om、唐纳德·希尔维特、大卫·贝克和Cathleen Zeymer。在经过新设计的具有较大内部空腔的对称结构融合的TIM桶中, 紧密且特异性结合。美国国家科学院院刊, 117(48):30362–30369, 2020年12月。doi: 10.1073/pnas.2008535117。URL<https://www.pnas.org/doi/full/10.1073/pnas.2008535117>。出版社: 美国国家科学院院刊。
- [55] 本杰明·巴桑塔, 马修·J·比克, 阿西姆·K·贝拉, 克里斯托弗·诺恩, 卡梅隆·M·周, 劳伦·P·卡特, 因娜·戈尔什尼克, 弗兰克·迪马约, 大卫·贝克。一种用于新设计具有多样口袋结构的蛋白质的枚举算法。美国国家科学院院刊, 117(36):22135–22145, 2020年9月。doi: 10.1073/pnas.2005412117。URL<https://www.pnas.org/doi/full/10.1073/pnas.2005412117>。出版社: 美国国家科学院院刊。
- [56] Namrata Anand, Raphael Eguchi, Irimpan I. Mathews, Carla P. Perez, Alexander Derry, Russ B. Altman, 和 Po-Ssu Huang。基于学习潜力的蛋白质序列设计。自然通讯, 13(1):746, 2022年2月。ISSN 2041-1723。doi: 10.1038/s41467-022-28313-9。URL<https://www.nature.com/articles/s41467-022-28313-9>。号码: 1 出版社: 自然出版集团。
- [57] UniProt 联合体。UniProt: 2023年的通用蛋白知识库。核酸研究, 页码 gkac1052, 2022年11月。ISSN 0305-1048。doi: 10.1093/nar/gkac1052。URL<https://doi.org/10.1093/nar/gkac1052>。
- [58] Sean R. Eddy。加速的剖面HMM搜索。PLOS计算生物学, 7(10): e1002195, 2011年10月。ISSN 1553-7358。doi: 10.1371/journal.pcbi.1002195。URL<https://journals.plos.org/ploscompbiol/article?id=10.1371/journal.pcbi.1002195>。出版商: 科学公共图书馆。

语言模型的泛化超出了天然蛋白质

- [59] 杨建义, 伊万·阿尼申科, 朴汉博, 彭真灵, 谢尔盖·奥夫奇尼科夫和大卫·贝克. 利用预测的残基间方向改进蛋白质结构预测。《国家科学院院刊》, 117(3): 1496–1503, 2020年1月。doi: 10.1073/pnas.1914677117. 网址<https://www.pnas.org/doi/full/10.1073/pnas.1914677117>. 出版商: 国家科学院院刊。
- [60] 马丁·斯坦尼杰和约翰内斯·Söding. MMseqs2 能够对大规模数据集进行敏感的蛋白质序列搜索分析。自然生物技术, 35(11): 1026–1028, 2017年11月。ISSN 1546-1696. doi: 10.1038/nbt.3988. URL<https://www.nature.com/articles/nbt.3988>. 出版号: 11 发行者: 自然出版集团。
- [61] 朱利安·萨拉扎尔、戴维斯·梁、阮庆源和卡特琳·基尔霍夫. 掩蔽语言模型评分。在第58届计算语言学协会年会议论文集, 第2699–2712页, 在线, 2020年7月。计算语言学协会。doi: 10.18653/v1/2020.acl-main.240. URL<https://aclanthology.org/2020.acl-main.240>.
- [62] 安德鲁·W·西尼尔、理查德·埃文斯、约翰·贾波、詹姆斯·柯克帕特里克、洛朗·西弗、蒂姆·格林、秦重立、奥古斯丁·Ž, 亚历山大·W·R·纳尔逊、亚历克斯·布里奇兰、雨果·佩内东斯、斯蒂格·彼得森、卡伦·西蒙扬、史蒂夫·克罗斯安、普什米特·科利、大卫·T·琼斯、大卫·西尔弗、科拉伊·卡武克丘格和德米斯·哈萨比斯。利用深度学习的潜力改进蛋白质结构预测。自然, 577(7792):706–710, 2020年1月。ISSN 1476-4687. doi: 10.1038/s41586-019-1923-7. URL<https://www.nature.com/articles/s41586-019-1923-7>. 编号: 7792 出版商: 自然出版集团。
- [63] 丹尼尔·朱拉夫斯基、查克·伍特斯、加里·泰赫曼、乔纳森·塞加尔、安德烈亚斯·斯托尔克、埃里克·福斯勒和尼尔森·摩根。《伯克利餐厅项目》。第2139–2142页, 1994年。
- [64] 蒂莫西·M·劳尔、尼拉杰·J·阿格拉瓦尔、纳雷什·陈纳姆塞提、卡马尔·埃戈达格、伯恩哈德·赫尔克和伯恩哈德·L·特劳特。开发性指数: 一种快速的计算机模拟工具, 用于筛选抗体聚集倾向。药科学期刊, 101(1): 102–115, 2012年1月。ISSN 0022-3549. doi: 10.1002/jps.22758. 网址<https://www.sciencedirect.com/science/article/pii/S0022354915317780>.
- [65] 曹龙兴, 布莱恩·科文特里, 英娜·戈雷什尼克, 黄步伟, 威廉·谢夫勒, 朴俊成, 凯文·M·朱德, 伊娃·马尔科维奇, 拉梅什瓦尔·U·卡达姆, 科恩·H·G·维尔舒伦, 肯尼斯·费斯特拉特, 斯科特·托马斯·拉塞尔·沃尔什, 内森·贝内特, 阿希什·法尔, 艾琳·杨, 丽莎·科佐多伊, 迈克尔·德威特, 洛拉·皮克顿, 劳伦·米勒, 埃娃·玛丽亚·施特劳希, 尼古拉斯·D·德布弗, 艾莉森·皮雷斯, 阿西姆·K·贝拉, 萨迈尔·哈拉比亚, 布拉德利·汉默森, 杨伟, 斯特芬·伯纳德, 兰斯·斯图尔特, 伊恩·A·威尔逊, 哈内尔·鲁霍拉-贝克, 约瑟夫·施莱辛格, 李相源, 萨瓦斯·N·萨夫瓦迪斯, K. 克里斯托弗·加西亚和大卫·贝克。从目标结构单独设计结合蛋白质。自然, 605 (7910): 551–560, 2022年5月。ISSN 1476-4687. doi: 10.1038/s41586-022-04654-9. 网址<https://www.nature.com/articles/s41586-022-04654-9>. 编号: 7910 出版商: 自然出版集团。
- [66] Will Sheffler 和大卫·贝克. RosettaHoles: 蛋白质核心打包的快速评估以用于结构预测、改进、设计和验证。蛋白质科学, 18(1):229–239, 2009. ISSN1469-896X.doi: 10.1002/pro.8. URL<https://onlinelibrary.wiley.com/doi/abs/10.1002/pro.8>. eprint:<https://onlinelibrary.wiley.com/doi/pdf/10.1002/pro.8>.
- [67] Michael C. Lawrence 和 Peter M. Colman. 蛋白质/蛋白质界面的形状互补性. 分子生物学杂志, 234(4):946–950, 1993年12月。ISSN 0022-2836. doi: 10.1006/jmbi.1993.1648. URL<https://www.sciencedirect.com/science/article/pii/S0022283683716487>.
- [68] 肯·A·迪尔、金舒克·戈什和杰瑞米·D·施密特。细胞和蛋白质组的物理极限。美国国家科学院院刊, 108(44): 17876–17882, 2011年11月。doi: 10.1073/pnas.1114477108. URL<https://www.pnas.org/doi/full/10.1073/pnas.1114477108>. 出版商: 美国国家科学院院刊。
- [69] HMMER. URL <http://hmmer.org/documentation.html>.
- [70] 帕特里克·库恩茨曼和凯·哈马赫。Biotite: 一个统一的开放源代码计算生物学框架, 采用Python语言。BMC生物信息学, 19(1):346, 2018年10月。ISSN 1471-2105. doi: 10.1186/s12859-018-2367-z. URL<https://doi.org/10.1186/s12859-018-2367-z>.
- [71] 杨·张与杰弗里·斯科尔尼克。TM-align: 一种基于 TM-score 的蛋白质结构对齐算法。核酸研究, 33(7): 2302–2309, 2005年4月。ISSN 0305-1048. doi: 10.1093/nar/gki524. 网址<https://doi.org/10.1093/nar/gki524>.
- [72] 约翰·贾波, 理查德·埃文斯, 亚历山大·普里策尔, 蒂姆·格林, 迈克尔·菲古尔诺夫, 奥拉夫·罗纳贝尔格, 凯瑟琳·图尼亚苏-吕纳库, 拉斯·贝茨, 奥古斯丁·Ž伊德, 安娜·波塔彭科, 亚历克斯·布里奇兰, 克莱门斯·迈耶, 西蒙·A·A·科尔, 安德鲁·J·巴拉德, 安德鲁·考威, 贝尔纳迪诺·罗梅拉·帕雷德斯, 斯坦尼斯拉夫·尼科洛夫, 里什布·贾因, 乔纳斯·阿德勒, 特雷弗·巴克, 斯蒂格·彼得森, 大卫·雷曼, 艾伦·克兰西, 米哈乌·齐连斯基, 马丁·斯坦尼杰, 米哈琳娜·帕霍尔斯卡, 塔马斯·贝尔哈默, 塞巴斯蒂安·博登斯坦, 大卫·西尔弗, 奥里奥尔·维尼亚尔斯, 安德鲁·W·西尼尔, 科拉伊·卡武克丘格, 普什米特·科利与德米斯·哈萨比斯。高精度蛋白质

语言模型超越天然蛋白质的泛化

利用AlphaFold进行结构预测。自然, 596(7873): 583–589, 2021年8月。ISSN 1476-4687。doi: 10.1038/s41586-021-03819-2。URL<https://www.nature.com/articles/s41586-021-03819-2>。期号: 7873 出版社: 自然出版集团。

- [73] Christiam Camacho, George Coulouris, Vahram Avagyan, Ning Ma, Jason Papadopoulos, Kevin Bealer, 和 Thomas L. Madden. BLAST+: 架构和应用。 *BMC生物信息学*, 10(1):421, 2009年12月。ISSN 1471-2105. doi: 10.1186/1471-2105-10-421. URL<https://doi.org/10.1186/1471-2105-10-421>.
- [74] Peter J. A. Cock, Tiago Antao, Jeffrey T. Chang, Brad A. Chapman, Cymon J. Cox, Andrew Dalke, Iddo Friedberg, Thomas Hamelryck, Frank Kauff, Bartek Wilczynski, 和 Michiel J. L. de Hoon. Biopython: 自由可用的用于计算分子生物学和生物信息学的Python工具。 *生物信息学*, 25(11):1422–1423, 2009年6月。ISSN 1367-4803. doi: 10.1093/bioinformatics/btp163. URL<https://doi.org/10.1093/bioinformatics/btp163>.
- [75] B. I. M. Wicky, L. F. 米尔斯, A. 库尔贝, R. J. 拉戈特, J. Dau- paras, E. Kinfu, S. Tipps, R. D. Kibler, M. Baek, F. Di- Maio, X. Li, L. Carter, A. 康, H. 阮, A. K. 贝拉, 和 D. Baker. 幻觉对称蛋白质组装。 *科学*, 378(6615):56–61, 2022年10月。doi: 10.1126/science.add1964. URL<https://www.science.org/doi/10.1126/science.add1964>。出版社: 美国科学促进协会。
- [76] Curt B. Boschek, David O. Apiyo, Thereza A. Soares, Heather E. Engelmann, Noah B. Pefaur, Tjerk P. Straatsma, 和 Cheryl L. Baird. 基于 Top7 工程化超稳定亲和试剂。 *蛋白质工程、设计与选择*, 22(5):325–332, 2009年5月。ISSN 1741-0126. doi: 10.1093/protein/gzp007. URL<https://doi.org/10.1093/protein/gzp007>.

A. 方法

A.1. 数据

A.1.1. 新设计目标集合

一个保留的集合新设计的蛋白质用于固定目标骨架的设计任务。一组多样的 ($N = 39$) 新设计的结构来自蛋白质数据银行 (27)，这些结构涵盖了一系列的长度 ($67 \leq L \leq 184$)、折叠（例如， α -束， β -桶，NTF2，Rossmann）以及新设计的方法 (26, 34, 47–56)。请参见图 S1，以查看所有构成新设计目标集合的 X 射线晶体结构的可视化展示。这些蛋白质是由人类设计的，而非自然进化过程产生的。重要的是，这些新设计的蛋白质与属于自然折叠的蛋白质在结构上具有实质性的差异。例如，NTF2 目标具有不自然的结合口袋 (55)， β -桶更狭窄，并且具有短的 β -回转 (34)，某些设计在创建时完全是新的折叠 (47)。尽管这些蛋白质在序列和结构上被定义为与天然蛋白质不同，但目标集中的每个蛋白质都与 UniRef100 (28) 进行查询，该数据库包含 ESM2 的训练集，所有通过 Jackhmmer 搜索返回的匹配序列都被排除在语言模型的训练之外，详见下一节。

蛋白质数据银行识别码 (PDB 编号) 为新设计目标集提供了：

1QYS, 2KL8, 2KPO, 2LN3, 2LTA, 2LVB, 2N2T, 2N2U, 2N3Z, 2N76, 4KY3, 4KYZ, 5CW9, 5KPE, 5KPH, 5L33, 5TPJ, 5TRV, 6CZG, 6CZH, 6CZI, 6CZJ, 6D0T, 6DG6, 6DKM.A, 6DKM.B, 6DLM.A, 6DLM.B, 6E5C, 6LLQ, 6MRR, 6MRS, 6MSP, 6NUK, 6W3F, 6W3W, 6WI5, 6WVS, 7MCD

A.1.2. 用于训练 ESM2 的序列数据集

本研究使用的语言模型是 ESM2 650M (8)。因此，该文中描述的所有预训练设置适用于这里使用的语言模型。

为了测试语言模型对蛋白质的理解是否能从天然蛋白质推广到新设计领域，关键是模型在训练时没有看到新设计蛋白质。为此，我们首先从 ESM2 的训练集中移除所有在 UniProt (57) 网站上标记为“人造构造”的序列，当时 2021 04 是最近的发布版本（总共有 1,027 个蛋白质）。为了防止标签错误的蛋白质，并进一步移除训练集中可能与目标集相似的序列，我们还对每个新设计序列执行 Jackhmmer (58) 搜索，针对 UniRef100 2021 04 使用标记 `--num-iter 1 {max}`，并从 ESM2 的训练集中移除工具返回的所有命中 (58,462 个蛋白质)。

A.1.3. 结构投影数据集 该结构投影网络是在来自 PDB 的非冗余数据集上训练的，包含 15,051 个蛋白质（结构发布日期在 2018 年 5 月 1 日之前），用于 Yang 等人 (59)。

A.1.4. 自然蛋白质的留出集 一个小 ($N = 214$) 的天然蛋白质集，其在 PDB 中具有结构，被选中作为基线比较，在评估语言模型新设计蛋白质理解时，如图 S1 和 S2 及表 S1 中。该数据集由 2020 年 7 月可用的 PDB 组成，具有序列相似性 < 0.3 与用于训练结构投影的数据集相比，依据 mmseqs2 (60)。应用了一个长度过滤器 $50 \leq L < 250$ ，大致匹配新设计目标集的长度分布 ($67 \leq L \leq 184$)。

A.2. 模型

A.2.1. ESM2

我们使用 ESM2 650M (8) 作为我们在本研究中选择的大规模蛋白质语言模型。ESM2 是一个通过掩码语言建模训练的 Transformer 模型，涉及已知的自然蛋白质序列。在训练时，蛋白质序列以部分残基被掩码、随机重排为不同的氨基酸或保持不变的方式呈现给模型，遵循标准 BERT 噪声概率。

(7). 模型的任务是根据输入中所有未遮蔽氨基酸的双向上下文预测那些遮蔽的残基。ESM2 仅在自然蛋白质序列上进行训练；被标注为人工构建的序列以及通过序列搜索与新设计目标集查询匹配的序列从语言模型的训练集中移除，附录 A.1.2。该语言模型用于近似 $p(\text{sequence})$ 通过伪似然 (61)。首先定义在位置 $p_\theta(x_i|x_{-i})$ 上可能氨基酸的概率 i 在序列中 x ，条件是序列的其余部分。这个条件概率是通过构造 x_{-i} 用 i 替换的氨基酸 <掩码>，并计算在位置 i 的语言模型概率获得的。然后定义伪似然为 $\prod_i p(x_i|x_{-i})$ 。

A.2.2. 结构投影

结构投影是一个从 ESM2 内部表示到残基间距离的单一学习的仿射投影（带有偏置项的线性投影），它被应用于蛋白质的每个位置对 $[i, j]$ 。

在其实现中，ESM2 推理期间为给定序列计算的 ($N = 660$) 注意力图作为线性投影的输入。在位置 $[i, j]$ 处，我们计算 z_{ij} ，其维度为 ($N = 18$)： $z_{ij} = W_{\text{projection}} \text{注意力图}_{ij} + b_{\text{projection}}$ 。向量 z_{ij} 是 softmax logits，定义了碳 β 原子之间的分箱残基间距离的类别分布 $p(d_{ij}|\text{sequence})$ ，称为 distogram (62)。在条件对称独立假设下，我们使用 $\prod_{i,j, j \neq i} P(d_{ij}|\text{sequence})$ 来近似 $p(\text{structure}|\text{sequence})$ 。总共有 660 个

* $18 + 18 = 11$ ，在结构投影中总共有 898 个学习参数。模型的分箱分辨率为 $\approx 1^\circ \text{A}$ ，16 个箱覆盖范围 $[2.5^\circ \text{A}, 20^\circ \text{A}]$ 。非常

语言模型超越天然蛋白质进行泛化

第一个区间表示 $<2.5^\circ\text{\AA}$, 而最后一个区间表示 $>20^\circ\text{\AA}$ 。对预测对数进行了对称处理, 因为根据定义, Distogram 是对称的 ($d_{ij} = d_{ji}$)。在结构投影的训练过程中, ESM2 模型的权重被冻结。

结构投影是在Yang等 (59) 附录A.1.3中发布的80%序列和结构对的随机子集上训练的。与该工作中一样, 利用推断的蛋白质主链的碳 β 坐标构建distogram。我们对模型进行了10个epoch的训练, 批大小为4, 学习率为 $1e-2$, 使用分类交叉熵损失函数, 计算预测的distogram与真实值distogram之间的所有 $[i, j]$ 对。用于学习结构投影的数据集与新设计目标集之间没有共同的结构。

A.2.3. N-gram 先验

一元、二元和三元(n-gram)氨基酸频率的背景分布是通过在UniRef50, 发布于2018年03中氨基酸频率确定的。在设计过程中, 计算背景分布的n-gram频率与设计序列的n-gram频率之间的Kullback-Leibler散度 (D_{KL})。 D_{KL} 这些项以相等的权重添加, 以生成一个单一的n-gram能量项。从概念上讲, 这也可以看作是将n-gram用作语言模型 $p(\text{sequence})$ (63), 可以与ESM变换器语言模型结合。具体而言, 能量函数是定义于我们设计序列和背景的n-gram频率之间:

$$E_{n\text{-gram}} = \sum_{i \in \{1, 2, 3\}} D_{KL}(n\text{gram}_i(x), n\text{gram}_{i,bg})$$

A.3. 任务

A.3.1. 固定主链设计

固定主链设计的目标是生成一个蛋白质序列 x , 针对目标主链 y 。如同 (59) 中所述, 主链是由蛋白质的碳- β 原子的三维坐标 (针对甘氨酸进行推断) 所派生, 其长度等于蛋白质中残基的数量。这些三维坐标被转换为一个距离的distogram, 按照附录A.2.2.

我们希望根据目标主链 Y , 采样出高可能性的序列 x :

$$x \sim p(x|y = Y)$$

为了从这个分布中采样, 我们首先注意到根据贝叶斯法则, 这相当于从无条件序列先验 $p(x)$ 和条件结构分布 $p(y|x)$ 的未归一化乘积中进行采样:

$$p(x|y = Y) = \frac{p(x)p(y = Y|x)}{p(y = Y)} \propto p(x)p(y = Y|x)$$

- $p(x)$: 由通过乘法边际似然计算的语言模型伪似然近似

在屏蔽每个单独的标记时, 以及 n-gram 先验。

- $p(y = Y|x)$: 通过具有结构投影头的语言模型中的distogram分布进行近似, 针对目标 Y 进行已评估。

- $p(y = Y)$: 常量, 在固定目标的情况下。

为了从 $p(x|y = Y)$ 进行采样, 我们利用基于能量的采样过程, 通过马尔可夫链蒙特卡洛 (MCMC)。形式上, 我们用于从 $p(x)p(y = Y|x)$ 进行采样的完整能量函数是针对随机选择的序列索引 i 的以下表达式:

$$E(x) = \lambda_p E_{\text{projection}}(y = Y|x) + \lambda_{LM} E_{LM}(x) + \lambda_n E_{n\text{-gram}}(x)$$

其中:

$$E_{\text{projection}}(y = Y|x) = - \sum_{ij, d_{ij} < 10\text{\AA}} \log p(y_{ij} = Y_{ij}|x) / L^2$$

$$E_{LM}(x) = - \sum_i \log p(x'_i|x_1) \mathbb{1}(x'_1 = x_1) / L$$

$$E_{n\text{-gram}}(x) = \sum_{i \in \{1, 2, 3\}} D_{KL}(n\text{gram}_i(x), n\text{gram}_{i,bg})$$

在上述能量函数 $E(x)$ 中, 第一个项 $E_{\text{projection}}$ 指定了序列-结构一致性, 仅考虑在目标中接触的成对位置, 即具有残基间距离 $d_{ij} < 10\text{\AA}$ 。项 E_{LM} 指定序列的负对数似然, 而项 $E_{n\text{-gram}}$ 基于序列似然的 n-gram 模型。各项通过单独的权重 $\lambda_p = 3$, $\lambda_{LM} = 2$, $\lambda_n = 1$ 组合在一起, 以强制每个目标的不同优先级, 这些优先级是通过超参数遍历确定的。整体能量函数 $E(x)$ 定义了玻尔兹曼分布:

$$p(x) = \frac{1}{Z} e^{-E(x)/T} \propto e^{-E(x)/T}$$

在每一步中, 提议以均匀随机的氨基酸突变 x'_i 在随机选择的序列索引 i 处进行, 接受率为Metropolis α :

$$\alpha = \min(1, e^{-E(x')/T} / e^{-E(x)/T})$$

由于半胱氨酸的存在会干扰实验评估, 因此不允许进行半胱氨酸突变。请注意, 通过将接受定义为 $E(x')$ 与 $E(x)$ 的比率, 可以在语言模型中通过一次正向传递有效地近似 $E_{LM}(x')$ 与 $E_{LM}(x)$ 之间的相对比率 (通过计算替换位置的边际替换似然), 而不是需要L次正向传递来明确计算 $E_{LM}(x)$ 。

语言模型的概括超出了天然蛋白质

我们执行了 170,000 步 MCMC 采样。我们使用几何衰减的温度计划进行模拟退火。每 10,000 步，我们将温度 T 从初始值 8 衰减 2，最终值约为 $6e-5$ 。对于序列长度 ≈ 100 的固定骨架设计，完整的设计轨迹需要 ≈ 10 小时，在一台 32GB Volta GPU 上。我们能够在大多数目标上实现成功的设计（根据甲骨文的低目标均方根偏差），而所需步骤较少，但步数增加以达到最佳性能，尤其是对于较长的固定骨架设计，例如 6WVS ($L = 182$)。

A.3.2. 无语言模型的固定骨架设计

与无语言模型（“no-LM”）的强大结构预测基线相比，语言模型（“LM”）的设计被进行比较。对于该基线，使用 AlphaFold 作为结构模型。

为了保持与语言模型设计的比较一致，使用了 AlphaFold 的成对距离（距离图）输出作为 $p(\text{structure} = \text{Target} | \text{sequence})$ 。由于未使用变换器语言模型，因此没有 $p(\text{sequence})$ 项，固定主链设计在没有语言模型的情况下优化具有高可能性的序列 $p(\text{structure} | \text{sequence})$ 。此外，为了确保与语言模型设计之间的完全匹配比较，生成了第二组无 LM 设计，这些设计包括用于 LM 设计的相同 E_{ngram} 项，附录 A.2.3。额外的 n-gram 项可以解释为添加一个弱 n-gram 语言模型。该 n-gram 项的系数是通过一个线性扫描表 S3 选择的。在主要比较中，我们仅展示来自不带 n-gram 项的那组的结果，因为该组实验上更成功（1/20 成功 vs. 0/20 成功有 n-gram 项）。

使用了一种基于梯度的公共算法来生成基于 AlphaFold 的设计。通过 ColabDesign 生成了基线设计（12, 16）（提交哈希 e7bb3def），使用了设计 `3stage() AfDesign` 配方，该配方交替并同时在所有 5 个 AlphaFold pTM 模型副本上进行优化。发现更多的步骤有助于优化过程中收敛到低目标 RMSD，因此使用的默认步骤数量增加了 5 倍，共计 1500 个软迭代、500 个温度迭代和 50 个硬迭代。由于采用基于梯度的优化，这一设计协议需要的优化步骤较少；该算法可以在每一步更新序列中的每个位置，而我们采用的 MCMC 协议每一步只能进行一次突变。尽管优化的是 AlphaFold 的距离图输出，而不是其原子结构预测输出，但所有设计都已验证与目标的 $< 1\text{\AA}$ RMSD 和 > 0.8 根据 AlphaFold 甲骨文的 pTM 附录 A.4.1。

使用 LM 和无 LM 协议为每个目标生成 200 个设计。根据每个协议的优化目标，简单地选择前 5/200 种子（每个目标）用于实验评估设计的选择附录 A.6.2。

A.3.3. 自由生成

自由（无约束）生成的目标是设计一个新的蛋白质序列 x ，该序列从所有可能序列 x 及其相关骨架 y 的宇宙中抽样。与前一部分一样，设计的骨架由成对距离的 distogram 分布表示。特别地，我们希望以高联合概率抽样序列 x 和相关结构 y ：

$$x, y \sim p(x, y)$$

我们利用一种基于能量的采样程序，从这个联合分布中对序列 x 和结构主链 y 进行采样。具体来说，我们采用阻塞吉布斯 MCMC 采样程序，从一个最初随机的序列 x 开始，对当前序列采样一个确定的主链 y 。

$$y_{\text{sampled}} \sim p(y|x)$$

然后，根据当前的主链 y 采样更新的序列 x' 。

$$x' \sim p(x|y = y_{\text{sampled}})$$

在 $p(y|x)$ 采样阶段，所有配对位置的 distogram 中的残基间距离是独立采样的。在 $p(x|y)$ 采样阶段，执行固定主链设计的 MCMC 协议的 3 步（见前一节），其中采样的主链 y_{sampled} 被用作目标。

总共执行 170,000 步 MCMC，其中一步包括一个 $p(y|x)$ 采样阶段和一个 $p(x|y)$ 采样阶段。对于 $p(x|y)$ 采样，使用的温度计划与固定主链设计中的相同：温度每 10,000 步减小一个因子 2，从 8 降到 $\approx 6e-5$ 。在结构采样步骤中，固定温度为 1。退火这两个温度导致了低多样性（ α -束）解决方案，实际上具有非常高的 $p(y|x)$ 和 $p(x|y)$ ，而在固定 $p(y|x)$ 温度下并未发生这种情况。通过使用这个联合分布的采样协议，生成了一组多样的拓扑结构，具有不同的二级结构内容（如图 4A；图 4B）。最后，与固定主链设计一样，不允许对半胱氨酸进行突变，因为它们的存在会干扰实验测试。

A.4. 计算机模拟质量指标

A.4.1. 甲骨文

设计的序列作为输入被提供给 AlphaFold，以对其结构进行计算机模拟评估。AlphaFold 作为一种强大的正交预测器，能够预测蛋白质结构，因为 AlphaFold 模型在其架构、目标和训练数据上与 ESM2 不同。在评估设计时，序列作为输入，但不生成多序列比对（MSA）或使用任何

语言模型超越天然蛋白质进行推广

模板。我们遵循标准协议，利用所有5个公开发表的模型来预测结构和信心评分（pTM捕捉全局信心，pLDDT捕捉局部信心），然后通过pLDDT选择最自信的输出。对所选预测结构进行了Amber松弛。本研究中设计的所有预测结构均来自此流程，接下来的章节中描述的结构指标是基于这些预测计算的。信心指标pTM和pLDDT，以及可用时与目标结构的RMSD，可以用于选择设计，另见附录A.6。

A.4.2. 可溶性和聚集指标

为了过滤出那些有强烈证据表明它们不会是可溶或单体的候选者，使用了三个计算机模拟指标：

1. 疏水溶剂可接触表面积（SASA）为每个疏水残基计算SASA。它量化了蛋白质表面中，能够接触溶剂的部分有多少是疏水性的。高疏水性SASA是有问题的，因为对于单体蛋白质，我们期望SASA主要是极性的，以便保持在溶液中，而不是通过暴露的疏水表面积聚集。

2. 净电荷：通过计算序列中带正电和带负电的氨基酸数量来简化的基于序列的净电荷，以此尽量避免零净电荷的蛋白质，因为这可能导致在极性溶剂中聚集。

3. 空间聚集倾向 (SAP) 是一个引入的指标，用于量化聚集倾向，即蛋白质是否会聚集成非功能性且通常不溶解的组装（64）。SAP得分识别表面暴露的疏水残基斑块，并计算具有正疏水性得分的原子的加权总和。SAP指标对于研究和筛选固定骨架设计和自由生成都很有用，因为在这两种情况下，我们的目标是设计单体蛋白质。这要求单体能够溶解，并且表面大多数为亲水性氨基酸，对应于低SAP得分（65）。该指标与疏水性SASA相关，但可以作为补充。为了比较序列长度，我们使用平均SAP得分，即对残基进行平均。对于经过实验测试的固定骨架设计，我们在选择过程中使用SAP得分，除了“LM与无LM”比较的情况，在这些情况下不使用额外的计算指标进行筛选（方法；实验评估设计的选择）。在筛选自由生成时，我们使用所有三种疏水性指标，并且阈值相对宽松，并将它们通过逻辑“与”结合，即候选者必须通过所有筛选。首先，疏水性SASA < 1.7 乘以使用相同长度蛋白质的理想球体计算的“理想表面”。其次，我们要求基于序列的净电荷 ≥ 2 或 ≤ -2 。最后，我们筛选平均SAP得分 ≤ 0.4 ，并将该阈值放宽至0.5当预测结构包含至少25%的 β 链时。

- A.4. 3. 打包度量：使用两个度量来过滤可能打包不良的候选者：

1. 蛋白质打包通过 Rosetta PackStat 过滤器进行量化，并且是 RosettaHoles 的一种近似实现（66）。这是一种随机算法，因此它在100次重复中取平均。它返回一个介于0和1之间的分数，其中1意味着完美的打包。我们仅在打包 > 0.55 时保留自由生成候选。

2. 结构中次级结构元素的形状互补性（67）在 Rosetta SSShapeComplementarity过滤器中实现，带有环节=“真实”螺旋=“真实”。这个度量旨在量化来自不同相互作用的次级结构的表面法线是否对齐良好，表明次级结构元素之间配合良好。我们只保留形状互补性 > 0.6 。打包和形状互补度量计算了两次：一次是在AlphaFold管道经过Amber松弛后的结构上，另一次是在Rosetta最小化的附加步骤后，beta nov16（32）。结构过滤器之间使用逻辑“或”：如果任一结构通过过滤器，则过滤器满足条件。

A.4.4. 球形度指标

一组最终的指标用于筛选出不是球形且具有长形状的蛋白质，例如延伸的螺旋束。我们遵循 Dill 等人（68）的定义，根据残基数量定义蛋白质的理想回转半径为 $2.24 * (\text{num residues})^{0.392}$ （68），并基于该半径计算其理想表面积。使用这些作为参考值，我们定义相对 SASA 和相对回转半径。所使用的指标和阈值如下：

1. 回转半径是从质心的均方根距离（未考虑残基重量）。如果相对回转半径是 < 1.5 ，我们将保留候选者。
2. 由 Rosetta TotalSasa 计算的总溶剂可接触表面积（SASA）。如果相对 SASA 是 < 3 ，我们将保留候选者。
3. 计算了接触顺序，但我们没有根据该指标进行筛选。自由生成的样本涵盖了一系列接触顺序值。

A.5. 与天然蛋白质的比较

A.5.1. 用于序列搜索的设置

设计的序列通过与大规模序列数据库查询，测试其与天然蛋白质序列的距离。我们强调，在整个过程中描述的比较

语言模型在天然蛋白质之外进行概括

本节（除非是基序的情况）是为序列搜索返回的命中而制作的；设计的预测结构与已知结构数据库的比较始终返回可能具有相似折叠的命中（图。S10）。

用于序列搜索，我们使用jackhmmer 3.3.2，这是HMMER套件中的一个序列搜索工具（58）。基于分析中观察到的失败模式，将两个jackhmmer设置从默认值进行了修改，旨在查询远序列/新设计序列对大规模（> 100M序列）搜索数据库进行搜索：

1. **一次迭代。** Jackhmmer仅运行1次迭代，而不是多次（即默认设置）。之所以做出这一改变，是因为观察到在输入远序列时，额外的迭代导致返回的虚假命中数量逐渐增加，例如新设计的真实序列。具体来说，对于具有少量天然序列同源物的查询序列，假阳性越来越主导后续jackhmmer搜索迭代中使用的查询轮廓。

2. **按最佳得分域的E值排序。** 在本文中，Jackhmmer结果始终根据最佳域(而不是全序列) E值进行排序。发现按全序列E值排名命中的方式常常导致更多的虚假顶级命中。具体来说，设计——由固定主链设计中的单一域组成，并在自由生成中具有类似单域的球状结构——往往会与包含重复域的长且重复的命中序列匹配。在这些情况下，多个较弱的每域匹配导致高的累计全序列显著性，即使该设计在命中序列中的任何单一域上没有强匹配。这是在用户指南中明确说明的潜在失败模式之一（69）。虽然显著性是通过最佳域匹配的E值来确定的，但当随后分析顶级jackhmmer命中时（例如，用于计算序列相似性和预测结构），将使用完整的命中序列。总体而言，Jackhmmer是使用非默认设置运行的（-n 1 -seed 0）。设计在三个主要轴上与其序列命中进行比较：**E值**，**序列相似性**，和**TM-score**：

1. **E值。** Jackhmmer 为每个命中返回一个 E 值，该值量化了每个命中序列与查询匹配的显著性。具体而言，E 值是指由于随机机会而预计会获得与给定命中同样或更高分数的假阳性数量。具有（最佳域）E 值 < 1 的命中被视为显著。在这一显著性水平下，我们预计每个设计在查询某个大型序列数据库时，平均会有一个命中被错误地认为是显著的。
2. **序列相似性。** 设计与其每个命中的序列相似性是通过与 Biotite 的本地比对计算得出的（70）`biotite.sequence.align.align_optimal()`

考虑到应用于设计的完整序列和命中的完整序列的 BLOSUM62 替代矩阵。序列相似性是通过两个对齐序列中匹配字符的数量除以原始查询序列的完整长度（而不仅仅是对齐区域的长度）来计算的。

3. **TM-score。** 设计还通过 TM-align 工具的 T M-score 将其预测结构与一些顶级命中的部分进行比较（71）。设计的预测结构是使用（AlphaFold, 单序列）结构甲骨文获得的（附录A.4.1）。顶级 Jackhmmer 命中的（完整序列的）预测结构则是从 AlphaFold 数据库获得的，或在输入为 MSA（而不是单个序列）时从结构甲骨文获得。<style>

A.5.2. 将所有自由生成与AlphaFold数据库中的天然蛋白质进行比较

在图4D的案例中，查询了25k个自由生成和来自（≈15k个天然蛋白质）的序列，**查询对象是AlphaFold数据库中的序列**（37），这些序列包含UniProt 2021 04（57）。由于该数据库中的所有序列都有AlphaFold预测的结构，因此针对该数据库的搜索可以使预测结构的比较规模化。我们仅将设计与其单个最显著的（按最佳域E值）命中进行比较，比较基础是预测结构的序列相似性和TM-score，数据源来自网址：https://alphafold.ebi.ac.uk/files/AF-<UniProtID>-F1-model_v3.pdb。图的左下象限4D中，序列相似性 < 0.2和预测结构的TM-score < 0.5 用于定义49个远程自由生成，其中31个（67%）在实验中成功。没有显著（最佳域E值 < 1）命中的生成在该图中的序列相似性为0，以便将它们与具有显著命中的生成在视觉上区分开。此比较的结果用于图4D、引言中“49个远程自由生成”的定义以及自由生成的分析。

A.5.3. 实验评估设计与自然蛋白质在UniRef90中的比较

在所有其他情况下，当我们将实验评估的设计与已知自然蛋白质进行比较时，我们会查询UniRef90 2021 04（28），该版本完全包含语言模型在训练期间看到的序列集合。

与在比较设计与天然蛋白质AlphaFold数据库时仅考虑顶部命中统计的情况不同，我们进行了更全面的分析：

1. **E值。** 与对AlphaFold数据库的比较相同。（最佳域）顶部命中的E值 = 最低 由于排序而针对所有命中。
2. **序列相似性。** 计算为所有 显著（最佳域E值 < 1）命中的序列相似性的最大 值。

语言模型在天然蛋白质之外进行泛化

3.TM-score. 计算为前10个序列命中中的最大值。预测的结构是通过折叠其（完整）序列获取的，使用 jackhmmer 在 UniRef90 上生成的 MSA（设置与 Jumper 等人（72）相同）作为输入，而不仅仅是单个命中序列。228*10=2280个 jackhmmer 命中在整篇论文中考虑，有 4 个（1 个显著）因未在 AlphaFold 数据库中而被排除在分析之外，并由于 GPU 内存限制而在甲骨文结构预测过程中失败（所有都具有长度> 1000）。这些错误不会影响 jackhmmer 命中的序列统计（序列同一性、E值）。

距离邻居以MSA形式显示（仅针对模体位置），并在图中呈现。**3D**, **3E** 和图。**S7**。

A.6. 实验评估设计的选择

A.6.1. 概述

总共验证了276种独特的蛋白质：来自语言模型的228种设计，来自“无LM”基线的40种设计，以及对应于新设计目标的8条真实序列，这些目标用于固定骨架设计。设计按“FXXX”或“GXXX”方案进行区分，分别表示固定骨架设计和生成，其中XXX是一个索引，范围为[0, 267]，涵盖所有测试的序列，排除真实值。

实验评估轮次：

总共进行了两轮实验评估，使用了一致的协议：

1. 第 1 = 44 轮固定骨架设计，48个自由生成，4个真实值
2. 第 2 = 95 固定骨架设计，81个自由生成和4个真实值

A.6.2. 固定骨架设计

设计池：

考虑了两个候选设计池进行选择：

1. 200个设计使用不同的随机初始化和随机种子，针对每个新设计目标。
2. 扩展设计集 - 创建了9,060个额外设计，目标大致平均分配：1QYS (1990x)、6MRS (1500x)、6D0T (1604x)、6W3W (1968x)。

甲骨文质量过滤器：

以下甲骨文指标用于几个（但不是所有）经过实验测试的设计池：

1. 甲骨文 (AlphaFold) 均方根偏差 < 2.5
2. 甲骨文 (AlphaFold) pTM > 0.7
3. SAP得分 < 0.35

第一轮 (48x)：

目标：从语言模型中选择最有前景的设计，使用来自语言模型、甲骨文、Rosetta 以及手动检查的信息。

目标：4个目标，因其 x 射线晶体结构涵盖了一系列典型拓扑（尤其是那些具有高 β -片段含量的，如 6CZJ）和序列长度而被选中。

- 1QYS (前7)
- 6W3W (NTF2)
- 6CZJ (β -桶)
- 6WVS (TIM桶)

来源：每个目标200种子运行（设计池1）过滤（每个目标）：

UniRef90并不是ESM2在训练期间看到的确切序列集。应用了两个过滤器，以去除UniProt标记为“人工”的序列（N = 1,027）和在使用真实值序列查询时被Jackhmmer命中的所有序列（N = 58,462）附录A.1.2. 发现对于许多固定骨架设计，在UniRef90中找到的最佳匹配属于已被移除的序列。因此，在计算上述3个（E值、序列相似性、TM-score）指标时，我们将所有已从ESM2训练集中移除的匹配排除在外。

本比较的结果用于本文大部分关于序列新颖性的陈述中。具体来说：在摘要中关于天然序列差异性的陈述，以及对实验评估的固定主链和自由生成设计与天然蛋白质的详细比较（图。2，图。4F 和 4G，图。S6，图S8）。

A.5. 4. MOTIF分析氢键网络模体被评估其与通过序列和结构搜索检索到的天然蛋白质（对齐）位置的相似性。为了测试语言模型是否在其训练中从相似序列中复制模体，设计被搜索以对抗UniRef90，再次使用 `-n 1 --seed 0`。为了测试语言模型是否从相似结构中复制模体，设计通过使用 Foldseek3 (36) 进行搜索，该工具是一个开源工具，用于对结构进行大规模搜索以匹配结构数据库。使用了版本 7d0c07f89a，并且采用了非默认标志 `--alignment-type 1` 以及 AlphaFold/UniProt（AlphaFold数据库）Foldseek结构数据库。在序列和结构搜索的情况下，每个工具返回的MSA根据模体位置的编辑距离进行排序。MSA经历了最小过滤，以使编辑距离的计算集中在重要或结构相似的命中上。具体来说，jackhmmer的结果被过滤为最佳域E值 < 10，而Foldseek的结果被过滤为 TM-score > 0.7。预测的命中结构通过TM-align与设计结构对齐。设计的模体与最小编辑的比较结果

语言模型超越天然蛋白质的泛化能力

1. 优化目标 ≤ 75 百分位数, 跨越200种子 2. $\langle$ Oracle质量过滤器 $\rangle$ 3. (仅限6CZJ) 手动过滤不完全闭合的 β 折叠结构, 根据结构甲骨文。选择, 过滤后 (按目标):

1. 前五名按最小白化 (甲骨文 RMSD) + 白化 (SAP / 长度) • 其中操作白化(x) = $(x - \text{np.mean}(x)) / \text{np.std}(x)$ 用于值 x 的数组。

2. 第一名按最小优化目标

3. 前五名按 (与 $E - \text{value} < 1$ 的 Blastp 命中中最大序列相似性) 最小值 • BLAST 针对 ESM2 的精确训练集运行, 使用所有默认设置。 4. 1 真实值

结果: (已评估 / 可溶 / 成功 / +单分散)

	甲骨文 RMSD 和 SAP	优化 优化目标	Blastp 序列标识	地面 真相
1QYS	5/5/5/3	1/1/1/1	5/5/5/3	1/1/0/0
6CZJ	5/5/5/3	1/1/1/1	5/5/5/3	1/1/1/1
6W3W	5/5/2/0	1/1/1/0	5/5/5/3	1/0/0/0
6WVS	5/5/1/0	1/1/0/0	5/4/0/0	1/1/1/1

第二轮 (语言模型 vs. 无LM) (64x):

目标: 在匹配比较中, 比较使用语言模型生成的设计与没有语言模型的强结构预测器 (AlphaFold) 生成的设计。无 LM 方法中去除了 n-gram 先验。关键是这一比较没有进行任何过滤, 这意味着在选择顶级设计时, 仅考虑用于设计的优化目标。有趣的是, 在过滤最少的设置中, 语言模型设计的成功率最高 (19/20)。为了实现清晰、无偏的比较, 本次实验选择了一组新的目标, 与第一轮测试的目标不同。

模型: 4个目标 * 5个框架 = 20设计, 每个

- (20x) $p(y|x)$ = 语言模型结构投影, $p(x)$ = 语言模型 +n-gram
- (20x) $p(y|x)$ = AlphaFold Distogram, $p(x)$ = 均匀
- (20x) $p(y|x)$ = AlphaFold Distogram, $p(x)$ = n-gram

目标: 4个具有晶体结构的目标, 与第一轮中测试的结构不同, 因具有多样的结构和二级结构内容而被选中。

- 5长度33 (NTF2)
- 6D0T (贝塔桶)
- 6 MRS (Foldit, Peak6)
- 6NUK (Foldit, Ferredox-Diesel)

来源: 针对每个目标的200种子运行 (设计池1)

过滤: 无 (以便根据用于生成设计的模型的偏好单独评估设计)

筛选后的选择 (按目标):

- 前五名按最小优化目标
- 1真实值

结果: (已评估 / 可溶 / 成功 / +单分散)

	LM 设计	AlphaFold 设计	AF +n-gram 设计	真实值 真实值
5L33	5/5/5/0	5/2/1/0	5/0/0/0	1/1/1/1
6D0T	5/5/4/0	5/0/0/0	5/2/0/0	1/1/0/0
6MRS	5/5/5/4	5/0/0/0	5/1/0/0	1/1/0/0
6NUK	5/5/5/5	5/0/0/0	5/2/0/0	1/1/1/1

第二轮 (远序列) (24x): 目标: 测试与天然蛋白质远离的语言模型设计。来源: 扩展设计集 (设计池 2) 目标:

- 1QYS (前七名)
- 6CZJ (β -桶)
- 6D0T (贝塔桶)
- 6MRS (Foldit, Peak6)

过滤器 (按目标):

1. $\langle$ 甲骨文质量过滤器 $\rangle$

2. BlastP 非冗余最小值 $E - \text{value} > -1$ 作为对天然蛋白质的距离的快速测试, 设计的序列在 BLAST (73) v5 非冗余数据库中被搜索, 该数据库于2022年9月12日下载, 使用所有默认设置。

3. Jackhmmer 最高命中 (按最佳域 E 值) $\text{TM-score} < 0.5$ 过滤后的选择: 无

结果: (已评估 / 可溶 / 成功 / +单分散)

	结果
1QYS	8/8/7/4
6CZJ	6/6/6/4
6D0T	2/2/1/0
6MRS	8/7/7/4

第二轮 (基序) (11x):

目标: 突出在固定主链设计过程中由语言模型生成的有趣设计基序。来源: 扩展设计集 (设计池 2)

目标:

- 1QYS (前7名)
- 6CZJ (贝塔桶)
- 6D0T (贝塔桶)

过滤器: $\langle$ 甲骨文质量过滤器 $\rangle$ 选择, 过滤后:

1. 检测埋藏的极性残基。编码了一个启发式函数, 大致评估了不在蛋白质表面的极性氨基酸的数量。每个蛋白质的“深度”和溶剂可接触表面积 (SASA) 分别使用 BioPython 中的 ShakeRupley 和 ResidueDepth 类计算 (74)。对所有氨基酸的 SASA 百分位 < 0.4 或深度百分位 < 0.6 (在设计序列中所有氨基酸中) 进行了求和。所有具有总和 > 12 的设计被选中进行实验评估。

2. 氢键网络的检测。HB- NetScore (Boyken 等人 2016) 来源于

语言模型超越天然蛋白质的泛化能力

pyrosetta.rosetta.protocols.hbnet 用于检测设计中的氢键网络。添加了一个 HB-NetScore 分数项到 beta nov16 罗塞塔能量函数 (32) 权重为 1, 并为每个设计计算该组件分数。所有得分 < -100 的设计被选择用于实验评估。

结果: (已评估 / 可溶 / 成功 / +单分散)

	埋藏的极性	HBnets
1QYS	1/1/1/1	0/0/0/0
6CZJ	1/1/1/0	5/5/5/1
6DOT	2/2/2/0	1/1/1/0
6W3W	1/1/0/0	0/0/0/0

A.6. 3. 自由生成

设计池:

考虑了两个自由生成的池, 使用相同的协议进行选择:

1. 10k个生成, 产生于第一轮实验评估之前。
2. 额外产生了一组15k个生成, 使得可以为第二轮实验评估选择总共25k个生成。

AlphaFold和Rosetta质量过滤器:

我们使用结构甲骨文 (AlphaFold) 信心预测pLDDT和pTM, 并选择在两者pTM > 0.7 和pLDDT > 70均符合要求的蛋白质。然后, 我们应用附录A.4中介绍的所有剩余三类过滤器, 以选择有前景的自由生成设计进行实验评估。在这25k个自由生成中, 20.1% ($N = 5, 198$) 通过了这些过滤器。

第一轮 (48x):

来源: 10k代数过滤:

• (AlphaFold 和 Rosetta质量过滤器)

选择:

1. 12个序列与PDB中最近邻的TM-score < 0.64
2. 36个序列没有显著的BLAST命中; 是每个结构簇中前2个的子样本。
3. 结构簇由基于成对结构相似性的聚合聚类定义, 其TM-score阈值为0.75, 适用于所有计算机模拟过滤的世代。

结果: (已评估 / 可溶 / 成功 / +单分散)

	结果
世代	48 / 46 / 22 / 11

第二轮 (手动选择) (24x):

来源: 10k 代

过滤器: (AlphaFold 和 Rosetta质量过滤器)

选择: 手动选择一个在结构上有趣且多样的子集, 包含经过计算机模拟验证的蛋白质。

结果: (已评估 / 可溶 / 成功 / +单分散)

	结果
代数	24 / 22 / 14 / 8

第二轮 (远距离世代) (57倍):

来源: 25k世代

过滤器: (AlphaFold 和 Rosetta质量过滤器) 选择:

1. 从过滤后的蛋白质集中, 我们选择了一小部分设计进行实验评估, 这些设计与天然蛋白质相隔较远。在蛋白质的序列新颖性方面, 我们没有遵循附录A.5中所述的方法, 而是使用一个单独的工具 (BLAST) 来评估序列的新颖性, 以便在图4D中选择更多样化的蛋白质。

2. 在BLAST中没有显著匹配的序列 (最小E值 >

3. 在上述结果中, 以Jackhammer的最佳命中序列的TM-score < 0.5 进行选择。结果: (已评估 / 可溶 / 成功 / +单分散) 结果世代

	57 / 56 / 35 / 21
--	-------------------

A.7. 实验评估

A.7.1. 质粒构建

用于表达蛋白质的质粒是根据以下程序, 由合成DNA构建的, 如同在 (75) 所示: 线性DNA片段 (综合DNA技术, IDT eblocks) 编码设计序列, 并包括适合BsaI限制性消化的突出部分, 使用金门组装法克隆到定制目标载体中。所有的亚克隆反应都产生了C端带有HIS标签的构建体: MSG-design-GSGSHHWGSTHHHHHH (入口载体 LM627), 下划线部分是用于切割HIS标签的SNAC标签 (68), (此工作中未使用切割), 它还包含一个色氨酸残基, 以确保蛋白质在280纳米处具有可测量的吸光度。

金门克隆的入口载体是经过修改的pET29b+载体, 这些载体在BsaI限制性位点之间包含一个致死的ccdb基因, 该基因是由一个组成性启动子控制, 并且在T7阅读框内。致死基因通过确保不包含插入序列的质粒 (因此仍携带致死基因) 杀死转化体, 减少了背景。载体在对ccdb耐药的NEB稳定细胞中传播 (新英格兰生物实验室C3040H, 总是从新鲜转化体中培养)。LM627可通过addgene获取 (ID: 191551)

金门反应 (每孔1微升) 是在使用ECHO声学液体处理器 (Labcyte ECHO 525, Beckmann Coulter) 的96孔PCR板上设置的:

- 10× T4缓冲液 0.5微升 10× T4缓冲液 (新英格兰生物实验室 B0202S)
- 载体 3 fmol 载体 (LM627)
- BsaI-HFv2 3U 0.0.06微升 BsaI-HFv2 (新英格兰生物实验室

语言模型超越天然蛋白质进行泛化

R3733L)

- T4连接酶 100U 0.1uL T4连接酶 (新英格兰生物实验室 M0202L)
- (6 fmol) 线性DNA片段, 通常为4 ng/uL的库存
- 用无核酸酶的水补充至5 uL的反应总体积。

反应在37 °C下培养20分钟, 然后在60 °C下培养5分钟 (IKA干块加热器3)。

A.7.2. 小规模蛋白质溶解性筛选

在实验筛选中, 黄金门反应混合物被转化为BL21(DE3) (新英格兰生物实验室), 具体如下: 1 μ L的反应混合物与6 μ L的感受态细胞在冰上于96孔PCR板中孵育。混合物在冰上孵育30分钟, 然后在42 °C的加热器 (IKA干块加热器3) 中热激10秒, 之后在冰上静置2分钟。随后, 向细胞中添加100 μ L室温SOC培养基 (新英格兰生物实验室), 然后在37 °C和1000 rpm的摇床上孵育。

转化产物随后在灭菌的LB培养基中于96孔深孔板 (每孔总容积2 mL) 中生长, 培养基中补充了50 μ g mL⁻¹的卡那霉素, 培养温度为37 °C, 转速为1000 rpm。在接下来的所有培养过程中, 生长板都用透气膜 (透气膜, 多元生物技术) 覆盖。

第二天, 从过夜培养物制备了甘油库存 (50% [v/v] 甘油与100 μ L细菌培养物混合, 冷冻保存于-80 °C)。随后, 准备了两个96孔深孔板, 每孔加入900 μ L灭菌的特级肉汤II (MP生物医学), 并补充50 μ g mL⁻¹的卡那霉素, 接着添加100 μ L的过夜培养物, 在37 °C、1200 rpm (海多夫 Titramax1000 / 培养箱1000) 下培养1.5小时。然后通过每孔中添加10 μ L的100 mM IPTG (最终浓度约为1 mM) 来诱导培养, 并继续在37 °C、1200 rpm下培养4小时。将培养物合并到一个96孔板中, 最终培养体积为2 mL, 通过以4000 x g离心5分钟进行收获。快速颠倒板子丢弃生长培养基, 收获的细胞沉淀可直接处理, 也可冷冻保存于-80 °C。

蛋白质通过基于HIS标签的固定化金属亲和色谱(IMAC)进行纯化。细菌沉淀在每毫升培养体积100 uL B-PER化学裂解缓冲液 (赛默飞世尔科技) 中重新悬浮并裂解, 该缓冲液中补充了0.1 mg mL⁻¹ 溶菌酶 (来自50% [v/v] 甘油的100 mg mL⁻¹原液, 保存在-20 °C, 米利步西门子), 每毫升50单位苄腺苷酶 (默克/米利步西门子, 存放于-20 °C), 以及1 mM PMSF (罗氏诊断, 来自存放于室温的丙醇的100 mM原液)。该板被密封。

铝箔盖并涡旋几分钟, 直到细菌沉淀完全重新悬浮 (在 Vortex Genie 上)

II, 科学工业)。裂解液在摇动下孵育5分钟, 然后在4000 x g下离心15分钟。与此同时, 将50 uL的镍-NTA树脂床体积 (赛默飞科学, 树脂在每次运行前再生并储存在20%[v/v] 乙醇中) 添加到96孔滤板的每个孔中 (25 μ m滤, 安捷伦 200953-100)。为了提高洗涤步骤的速度, 树脂在真空歧管板 (Supelco, Sigma) 上平衡, 通过真空歧管以最低压力设置抽取3 x 500 uL的洗涤缓冲液 (20 mM Tris, 300 mM 氯化钠, 25 mM 咪唑, pH 8.0) 在树脂上流动。

离心后提取裂解液的上清液, 施放到已平衡的树脂上, 并让其在5分钟内缓慢滴流。随后, 树脂在真空歧管上以每孔3 x 500 uL的洗涤缓冲液进行洗涤。最后, 将滤板的喷嘴在纸巾上轻轻拍打以排除多余的洗涤缓冲液。然后, 向每个孔中加入200 uL的洗脱缓冲液 (20 mM Tris, 300 mM 氯化钠, 500 mM 咪唑, pH 8.0), 并孵育5分钟, 然后通过以1500 x g的离心将蛋白质洗脱到96孔收集板中。洗脱液在4 °C储存。

A.7.3. 尺寸排除色谱

在实验室中, 设计通过可溶性筛选和尺寸排除色谱 (SEC) 进行测试, 使用赛信维的 S75 5/150柱, 以0.45 mL / min 的运行速度在 20 mM 磷酸盐、100 mM 氯化钠, pH 7.4 的条件下, 用 Akta pure (赛信维) 和自动取样模块进行。在 280 纳米处监测吸光度。所有设计和缓冲液在运行仪器之前通过 0.2微米滤器进行无菌过滤。

A.7. 4. C实验结果的分类如果从 4x1mL 准备中获得的总可溶产量 (以毫克为单位) $\leq 0 \leq 0.05$ mg, 则设计被标记为可溶。如果设计可溶, 并且由 `scipy.signal.findpeaks` (SEC trace y vals, height=0=0.1, prominence=0=0.01)(其中 SEC trace y vals 被归一化到范围 [0,1]), 那么其最右侧峰值在与上面描述的与洗脱体积相关的水动力半径的校准曲线的一个标准差以内。所有基准控制都在其预期的保留体积处或稍后洗脱, 从而确认了其单体状态 (除了 1QYS, 它在文献中被认为形成一个同源二聚体 (76))。如果 `findpeaks()` 调用在所给分子量的预期洗脱体积处返回一个单峰, 则设计被视为单分散。校准曲线是在使用与设计相同的运行缓冲液的 S75 5/150柱 (赛信维) 上使用低分子量校准工具包 (LMW 工具包, 赛信维) 记录的。

B. 补充图

补充图表概览：

- 图.S1：新设计目标集合的概述。
- 图.S2：语言模型理解新设计蛋白质。
- 图.S3：语言模型对实验测试的新设计目标的理解。
- 图.S4：固定骨架设计在所有实验测试的骨架上均取得成功。
- 图.S5：针对不同方法的固定骨架设计分析。
- 图.S6：固定骨架设计，与天然蛋白质的比较。
- 图.S7：基序的详细分析。
- 图.S8：自由生成：实验成功案例
- 图.S9：自由生成，与天然蛋白质的比较
- 图.S10：自由生成的最佳结构匹配在PDB中的表现
- 图.S11：所有测试设计的实验评估概述。

语言模型在天然蛋白质之外进行概括




图 S1。目标集概述新设计目标集。所有蛋白质在新设计目标集中 (N = 39) 的晶体/NMR结构。目标按序列长度递增排序 (范围 [67,184])。残基从N-端到C-端呈彩虹色。目标是手动选择的, 需满足条件为新设计, 拥有高质量的实验结构, 以及在结构上具有多样性: 目标具有多种折叠形式 (例如, α -束、罗斯曼、NTF2、 β -桶、铁氧还蛋白、TIM桶) 和二级结构内容。

语言模型在天然蛋白质之外进行泛化




图 S2. 语言模型理解新型蛋白质。(A) 在 ESM2 650k 预训练检查点下接触和序列预测统计数据。X 轴显示 ESM2 下序列的伪困惑度。Y 轴显示通过结构投影预测的长程接触 (≥ 24 分离) 中前 L 的精确度，相对于最大可实现值的比例，其中 L 为序列长度。(B) 根据最终的 ESM2 650k 模型检查点 (在本研究中使用)，天然 (蓝色) 和新型 (橙色) 蛋白质的接触和序列预测统计的直方图 (按数据集大小标准化)。尽管只在天然序列上进行训练，但语言模型的结构投影对考虑的天然和新型蛋白质集合 (顶部) 获得了类似的结构分数。(底部) 对于天然序列，伪困惑度更好 (更低)，但与 30% 混合的新型序列、100% 混合的新型序列和 UniRef50 2018 03 中氨基酸频率的单词模型相比，天然序列和新型序列的理解良好，作为基线。(C) 语言模型对新型序列中被掩蔽氨基酸的预测的校准图。完美的校准是一条从 (0, 0) 到 (1, 1) 的对角线，以虚线红色表示。由于新设计靶点集中序列数量较少 ($N = 39$)，省略了有 < 5 样本的分箱概率的真实正例计数。(C) 被掩蔽氨基酸预测正确地将疏水性残基放置在新型蛋白质结构的核心中。箱线图显示在新型序列的掩蔽-1 输出预测中疏水性 (粉色) 和亲水性 (浅灰色) 氨基酸的总概率质量。核心和表面标签由每个 C-alpha 原子内 $10^\circ \text{\AA}$ 内的 C-alpha 邻居数 (核心: ≥ 24 邻居; 表面: < 16 邻居) 决定。

语言模型超越天然蛋白质进行归纳




图 S3。语言模型对实验测试的新设计目标的理解。该图展示了对目标的理解, 基于它们(真实值)序列。针对新设计集中的所有目标都产生了固定骨架设计, 但其中 8 个目标的设计经过了实验测试。上述两个整体列中的每一行展示了单个目标的理解。每一行中最左侧的列显示了目标(主链, X 射线晶体)结构, 呈现从 N 端到 C 端的彩虹色。第二和第三列显示了语言模型的结构投影对目标结构的结构理解, 仅基于保留的(附录 A.1.2)新设计序列。第二列比较了预测的和真实的分箱残基间距离, 这是结构投影的本地输出。第三列比较了目标主链(灰色)与来自语言模型的结构投影 distogram (蓝色)受限折叠生成的主链, 后者通过 trRosetta2 的折叠脚本(69)进行折叠。该列中的均方根偏差范围为 1.8 Å 到 3.9 Å。第四列展示了语言模型的疏水性(品红色)与亲水性(白色)氨基酸预测的总概率质量, 经过逐个遮罩真实值序列中的每个位置。新设计结构表面的侧链通常被预测为比核心中的更亲水。

语言模型超越天然蛋白质进行泛化




图 S4. 展示蛋白质设计在所有实验测试的骨架上取得的成功。该图展示了针对目标的设计。所有经过实验测试的目标骨架至少有一个成功设计。目标链的不同长度 ($L = \{77, 142\}$) 和构型 (丝氨酸, NTP2, α -螺旋, TIMM)。每一行展示了与目标的最小均方根偏差 (RMSD) 相关的设计。根据结构甲斐文, 以序列列出了该目标的结构体固定骨架设计实验结果。每行的第一列显示了设计结构的甲斐文预测, 新红色从 N 端到 C 端覆盖在目标晶体结构上。呈灰色。第二列显示了疏水残基的排列, 预测的主链呈灰色。疏水侧链呈橙色。第三列显示了来自 SEC 的色谱图。预期的洗脱体积和一个标准差置信区间分别以虚线灰色和浅蓝色表示。所有设计中的峰都位于 SEC 下预期洗脱体积的范围内, 表明适当折叠的单体物种。两个设计, F093 (6NUK) 和 F100 (6W3W) 是单分散的——每一一般测到的峰是位于预期洗脱体积的峰。

语言模型超越了天然蛋白质的普遍性






图 S5. 不同方法中固定骨架设计的分析。由语言模型设计的序列与无 LM 设计、使用 n-gram 项的 AlphaFold 设计的序列的评估指标。我们展示了对每个四个直接比较的目标所选的最佳 5 个设计的结果 (PDB 目标 ID: 5L33、6D0T、6MRS、6NUK)。AlphaFold 的 RMSD 对于 AlphaFold 设计的结果较低（更好）。罗塞塔能量对两种设计的结果都为负值（好），但无法区分实验结果，尽管罗塞塔能量函数是为蛋白质建模和设计而开发的（我们使用 beta nov16 罗塞塔能量函数，长度标准化）。LM 伪困惑度将没有强 LM 设计的序列识别为不太可能（低伪困惑度），并且可以预测该比较中的实验成功。计算机模拟 质量指标 (附录 A.4) 表明，没有 LM 的 AlphaFold 设计在包装或形状互补性方面不容易区分，但往往具有更多的表面憎水性和更高（更差）的 SAP 得分。将 n-gram LM 项添加到 AlphaFold 固定骨架优化目标 (附录 A.3) 按预期改善 n-gram（或 k-mer）统计，并轻微提高 SAP 得分，但失败率为 100%（相比之下无 n-gram 失败率为 95%）。该比较的聚合统计数据也报告在表 S2。

语言模型超越天然蛋白质的泛化能力



图S6. 固定骨架设计, 与天然蛋白质的比较。显示了选择的成功固定骨架设计与天然蛋白质的比较的详细信息。每个图展示了前10个最显著的Jackhmmer命中(蓝点)的序列和结构匹配统计数据, 当用设计的序列查询UniRef90时(附录A.5.3)。我们展示了两个集合的联合中31个成功设计的子集: 17个没有显著序列命中的设计和19个与邻近预测结构的最大TM-score $6 < 0$ 。X轴显示了根据最佳域的 $\log_{10}(\text{E值})$ (基于序列的)匹配显著性。位于E值的虚线垂直线左侧的命中被认为是显著的。在图中展示的所有命中中, 仅有18个是显著的(E值)而仅有3个, 设计F094,F {的E值为0.1。命中还标记了它们与设计序列的序列相似度。显著命中的序列相似度中位数为26%, 且14/17 $\geq 30\%$ 。Y轴通过AlphaFold预测结构之间的TM-score来比较设计及其顶级命中(方法; 比较)。图形按照最大TM-score递增的顺序排序。位于图底部的设计可能使用了超出我们显著性阈值的同源性, 但许多设计与它们的顶级命中中没有强结构匹配。设计F044,F135,F003,F {及其最具显著性的命中在图2G中展示。

语言模型在天然蛋白质之外进行概括



语言模型的泛化超出了天然蛋白质的范围




图 S7. 基序的详细分析。(A) 设计中的氢键网络基序与天然邻居对齐位置的比较。与图中的视图相比, 3D, 3E, 展示了另外 2 个设计 (F026, F025) 以及前 3 个而非前 1 个对齐的序列和结构搜索邻居。否则, 视图与图中的相同。3D, 3E。该设计显示了基序的侧链, 键网络以虚线形式绘制。从 Uniref90 中天然序列的 Jackhmmer 搜索和 AlphaFold 数据库中天然结构的 Foldseek 搜索中获得邻居。这两个搜索的完整 MSA 按照与设计基序对齐位置的编辑距离进行排序。显示了最小编辑距离邻居, 侧链在对齐位置上显示。当邻居中的匹配氨基酸不在设计基序中时, 侧链呈灰色。(B) 尺寸排除色谱 (SEC) 档案显示在图的底部。在所有情况下, 在预期洗脱体积附近检测到一个峰, 表明根据校准曲线 (附录 A.7) 存在正确折叠的单体种类。在 4/5 的情况下, 预期洗脱体积处的峰是主导的, 高于任何其他峰。F129 是单分散的 - 唯一检测到的峰是预期洗脱体积处的峰。

语言模型超越天然蛋白质的泛化能力




语言模型的泛化超越了天然蛋白质



图 S8。自由生成: 实验成功 所有 71 个实验成功的自由生成的预测结构概述 (G230 除外, 由于空间限制随机省略)。所设计的结构来自计算机模拟 结构甲骨文 (AlphaFold), 以 pLDDT 着色, pLDDT 是局部预测置信度的测量。每个设计在 AlphaFold 数据库中最显著的序列搜索命中的统计数据 (序列相似性、TM-score 和显著性) 显示。前 31 个设计来自图 4D 的左下方 新设计 象限, 这意味着在与 AlphaFold 数据库搜索后, 它们从天然序列中找到的比较遥远 (附录 A.5.2)。

语言模型在天然蛋白质之外进行推广



图S9。自由生成，与天然蛋白质的比较如图。S6，我们展示了成功的、遥远的自由生成与天然蛋白质的比较的详细序列搜索统计数据。每个面板代表了图4D的左下象限中31/49个实验成功的蛋白质之一，该蛋白质在UniProt 2021 04 / AlphaFold数据库中与其最高序列命中相距较远。对于这31个成功的自由生成，我们进行了更深入的分析：与完全包含语言模型训练集的UniRef90进行比较，并考虑的不仅仅是最高命中(附录A.5.3)。图表格式与图S6中的图表相同：每个图表对应一个自由生成，从搜索UniRef90中得到的前10个Jackhmmer命中中显示为蓝色点，x轴表示序列匹配强度，y轴显示预测结构的TM-score比较，并为每个点标注序列相似性。图表按升序最大TM-score排序。总体而言，UniRef90搜索的结果与其在搜索AlphaFold数据库时的分类为遥远的结果之间存在强的吻合。16/31的成功案例没有显著的(E值 <

1) 命中，并且在所有中未检测到 E 值为 < 0.1 的命中

31. 预测结构的比较进一步证实了每一代与其顶级自然序列命中的不相似性。12/31 的设计中，所有前 10 名序列命中中可能具有不同的折叠(最大 TM-score < 0.5)。那几个具有高 TM-score 的命中(> 0.7)一般具有 3 到 10 范围内的 E 值。设计的结构 {G216,G228,G231,G189,G144} 及其顶级显著命中在图中展示。4F.

语言模型超越了天然蛋白质的概括能力




图 S10. 自由生成的蛋白质数据库中的顶部基于结构的匹配 我们展示了在蛋白质数据银行（PDB）中，对于每个自由（无约束）生成，已知蛋白质结构与最近匹配的相似度的分布。最近邻是通过使用 Foldseek 进行基于结构的搜索来定义的，相似度是来自 TMalign 的 TM-score（范围在 0 到 1 之间，其中 0.5 通常被视为属于另一个折叠的阈值）。我们认为设计的结构匹配可能可以通过自由生成的相对较短长度（L=100）来解释，这使得它们可能部分匹配更大的结构。尽管为生成的蛋白质找到了结构匹配，但对于许多设计，基于同源序列搜索并未找到任何匹配（图 4D）。

语言模型超越天然蛋白质的概括能力




图 S11. 所有测试设计的实验评估概述。共测试了268种设计蛋白质的溶解性和通过大小排阻色谱法 (SEC) 获得预期的水动力半径。此处显示的是所有268种已评估蛋白质的SEC痕迹, 按照在 (附录A.6) 中描述类别进行分类。LM与“无LM”的比较设计在中间行分开, 按照设计所用的模型进行分类。图表显示在280纳米 (y轴) 处的色谱吸光度与保留体积 (x轴) 的关系。半径较大的颗粒通过多孔柱的流速更快, 并且在较低的体积处洗脱 (向左)。单体物质是最小的颗粒, 且其峰值位于最右侧。每种序列的预期洗脱体积不同, 但作为视觉指南, 我们用虚线黑色标注长度为100的序列的平均预期洗脱体积 (1.9 mL)。痕迹根据实验成功的定义着色: 绿色表示成功, 红色表示失败 (附录A.7.4)。

C. 补充表

补充表概述：

- 表S1：ESM2与基线的序列和结构理解比较。
- 表S2：固定骨架设计的比较。
- 表S3：AlphaFold的n-gram语言模型损失系数的线性扫描 + n-gram语言模型。
- 表 S4：不同方法下固定骨架设计的分析。
- 表 S5：使用语言模型的不同自由生成方法的比较。

语言模型超越天然蛋白质的概括能力

	精度@L 长期		伪困惑度	
	新设计	自然	新设计	自然
最佳可达	0.82	0.94	1.00	1.00
先验	0.05	0.04	17.17	18.72
未训练的 ESM2	0.05	0.04	17.59	19.42
训练后的 ESM2 ($\approx 500k$ 更新)	0.49	0.57	7.73	6.66

表 S1. ESM2 与基线的序列和结构理解比较。ESM2 与基线的结构和序列理解比较。行表示预测器, 列表示指标和数据集。(列) 第一列描述了语言模型的结构理解, 附录中介绍的最小结构投影 A.2.2 的特点。所示指标是预测的最长距离 ($separation \geq 24$ 主链位点) 接触的精度, 其中 L 为序列长度。第二列描述了序列理解。所示指标是序列的困惑度, 或者在 ESM2 的情况下是伪困惑度。(行) “最佳可达” 行甲骨文显示每个指标的最佳可达分数。“先验” 行对于结构显示每个序列长度的背景模型分数, 该模型被定义为 500 个随机选择的自然序列的平均预测 Distograms, 其长度为 L, 由本文使用的训练结构投影预测。“先验” 行对于序列显示基于 UniRef50 中氨基酸频率训练的 unigram 模型的困惑度 (2018年03) 附录 A.2.3。表中的最后两行按顺序显示未训练和完全训练的 ESM2 的性能。

分数	均方根偏差	AlphaFold (pLDDT)	ESM (伪困惑度)
真实值	0.00	91.11	7.27
AlphaFold	0.58	95.18	13.05
AlphaFold + n-gram	0.80	92.62	10.14
ESM 逆折叠	0.99	90.76	5.15
ProteinMPNN	1.03	91.13	4.96
ESM2 (我们的)	1.90	87.94	2.1

表 S2. 固定骨架设计的比较。我们提供了计算机模拟的额外基准固定骨架设计方法的指标: 使用 ESM 逆折叠 (14) 和 ProteinMPNN (15)。每种方法的结果 (除 “真实值” 外的所有行) 是针对四种不同的主要比较结果所使用 的 20 个序列设计所得到的新设计骨架目标 (图. 2、S3 和 S5)。使用这两个逆折叠模型设计的序列是在默认温度为 0.1 的情况下进行采样的。逆折叠设计的甲骨文结构预测接近目标骨架, 均方根偏差接近 1 Å。这些序列也被 AlphaFold 甲骨文视为可信的 (具有 pLDDT > 90 的自信结构预测)。ESM2

与 AlphaFold 设计和真实序列相比, 逆折叠设计的伪困惑度较低, 这意味着这些序列在 ESM 下是合理的。考虑到 ProteinMPNN 在其他目标上展示的高实验成功率, 这些结果支持了 ESM2 能够理解设计模式到可指示实验成功级别的假设。

语言模型设计 (参考)	λ_{ngram}	甲骨文 RMSD	甲骨文 pLDDT	E_{ngram}
	1	2.1	86	4.5
AlphaFold + n-gram 设计	1	0.82 92		5.23
	2 (已选择)	0.82 92		5.09
	5	1.07 90		4.89
	7	1.27 87		4.76
	10	1.97 83		4.67
	15	2.19 77		4.57
	20	3.41 71		4.42
	30	6.85 61		4.32
	50	8.87 54		4.21

表 S3. AlphaFold 的 n-gram LM 损失系数线性扫描 + n-gram LM. 进行了一次线性扫描, 以确定 λ_{ngram} , 用于 E_{ngram} AlphaFold + n-gram 设计的系数。下面每一行显示了 40 个总设计的平均统计数据, 每个目标主链 (5L33、6D0T、6MRS、6NUK) 有 10 个设计。对于顶行, 统计数据是从为每个主链生成的 200 个固定主链设计中随机选择的。对于其他每一行, ($4 \times 10 = 40$) 通过基于 AlphaFold 的设计用特定 n-gram 能量函数系数生成了新设计。相同的甲骨文 (AlphaFold) 结构预测流程被应用于所有设计序列。从线性扫描中选择了系数 2, 因为它是最高的值, 且不会降低甲骨文结构的准确性 (均方根偏差) 和置信度 (pLDDT) 指标。在遵循我们的完整生成、过滤和选择协议后 (附录 A.6.2), 最终 E_{ngram} 值大致匹配 (4.59 vs. 4.77), 用于 LM 和 AlphaFold+n-gram 设计 (表 S4)。

语言模型超越天然蛋白质的泛化能力

	语言模型设计	AlphaFold 设计	AF + n-gram
实验成功	0.95	0.05	0.00
甲骨文 (AlphaFold) 均方根偏差	1.90	0.58	0.80
LM 伪困惑度	2.10	13.05	10.14
罗塞塔能量	-1.04	-1.57	-1.37
打包	0.56	0.63	0.58
形状互补性	0.68	0.71	0.69
疏水性SASA	3043.98	3299.73	3216.39
SAP得分	0.34	0.76	0.57
n-gram损失	4.59	6.61	4.77

表 S4. 不同方法下固定骨架设计的分析。本表显示了与图 S5 中的图表对应的汇总统计数据，展示了语言模型与AlphaFold（无LM）与 AlphaFold + n-gram LM 在四种不同的 新设计 骨架目标上设计的20个序列之间的比较。有关更多细节，请参考图例说明。

方法	N（样本数量）	pLDDT	pTM	根据 TM-score 的簇
p(x,y) 采样（子集）	400	81.49	0.67	242/400 簇
p(x) 采样	400	76.22	0.53	372/400 簇
距离图 KL (11)	400	80.22	0.56	282/400 集群
p(x,y) 采样（完整）	25,000	81.09	0.66	7663/25000 集群

方法	成对序列相似性	罗塞塔能量	SAP得分	螺旋/片段/环比
p(x,y) 采样（子集）	0.13	-0.19	0.45	0.51/0.23/0.26
p(x) 取样	0.15	1.93	0.65	0.15/0.36/0.50
距离图 KL (11)	0.13	0.65	0.73	0.40/0.29/0.31
p(x,y) 采样（完整）	0.12	-0.21	0.46	0.52/0.21/0.26

表 S5. 使用语言模型自由生成的不同方法的比较。除了描述的阻塞吉布斯采样方法
在本文中，我们测试了两种其他程序，以进行蛋白质的自由生成：p(x) 取样 - 其中仅使用 ESM2 和一个 ngram 项，通过马尔可夫链取样可能的氨基酸序列，但没有使用结构采样。此外，我们遵循了距离图 KL 最大化过程 (11)，其中结构步骤的采样目标是距离图与背景分布之间的 KL 散度。最大化这个 KL 可以被视为最小化距离图的熵，这意味着目标引导到自信的结构预测。上表比较了这些方法之间的关键统计数据。值得注意的是，我们观察到 p(x) 取样常常产生重复的序列模式。距离图 KL 方法，结合低能力结构预测头，其缺点在于提出的阻塞吉布斯方法。距离图 KL 方法倾向于生成几乎没有 α -螺旋和 β -片混合的结构，并且 pTM、罗塞塔能量和 SAP 得分更差。