

几何交互图神经网络用于从三维结构预测蛋白质-配体结合亲和力和力 (GIGN)

杨子多, 钟惟赫, 吕秋洁, 董铁军, 和 Calvin Yu-Chian Chen*

引用此文: *J. Phys. Chem. Lett.* 2023, 14, 2020–2033

在线阅读


访问

指标与更多

文章推荐

支持信息

摘要: 预测蛋白质-配体结合亲和力 (PLA) 是药物发现中的一个核心问题。最近的进展显示, 机器学习 (ML) 在 PLA 预测中的应用具有巨大潜力。然而, 绝大多数研究忽略了复合物的三维结构和蛋白质与配体之间的物理交互, 这被视为理解结合机制的必要因素。本文提出了一种几何交互图神经网络 (GIGN), 其结合了三维结构和物理交互来预测蛋白质-配体结合亲和力。具体而言, 我们设计了一个异质交互层, 将共价与非共价交互统一到信息传递阶段, 以更有效地学习节点表示。



异质交互层还遵循基本生物化学法则, 包括对复合物的平移和旋转的不变性, 从而避免了昂贵的数据增强策略。GIGN 在三个外部测试集上实现了最先进性能。此外, 通过可视化学习到的蛋白质-配体复合物的表示, 我们展示了 GIGN 的预测在生物学上具有意义。

药物发现^{rug} 是一个成本高昂的过程。

通常, 单一药物的研发费用可高达约10亿美元, 并且需要10年的开发和测试才能可能获得FDA批准。¹ 此外, 这一过程在任何阶段都可能因不良反应或对有前景的治疗效果的实验性反驳而失败。药物发现中的一个关键问题是预测蛋白质-配体结合亲和力 (PLA), 该参数描述了配体 (药物候选物) 与蛋白质 (靶标) 之间结合相互作用的强度。为了识别对特定蛋白质有效且安全的药物, 药理学家必须测试数千种化合物。² 然而, 实验性地测量 PLA 既耗时又耗资源。计算机模拟方法能够通过药物候选物进行排名并优先筛选更优者, 从而加速药物筛选的过程。

到 PLA 的预测

随着高质量实验确定的蛋白质-小分子结构及其结合亲和力数量的增加, 机器学习 (ML) 方法已被广泛应用于预测蛋白质-小分子结合亲和力或通过识别数据中的有用模式来进行相互作用。^{2–7, 7–27} 现有的基于机器学习的 PLA 预测方法可以根据模型是否依赖于物理交互进行决策, 分为两类: 无交互和基于交互的方法, 如图 1 所示。

无交互方法^{2, 17–19, 23–25, 28–32} 隐含假设机器学习模型可以从揭示物理蛋白质-配体相互作用的数据中预测 PLA。因此, 配体通常通过简化分子输入线条符号系统 (SMILES) 来表示,

而蛋白质则通过序列表示, 原子相互作用被为了简化而省略。例如, DeepDTA¹⁷ 使用 SMILES 字符串和蛋白质序列作为输入, 通过两个卷积神经网络 (CNNs) 提取特征。另一方面, GraphDTA¹⁸ 和 MGraphDTA² 将配体表示为二维分子图, 以保留二维结构信息。无交互方法可用于在没有三维结构和物理相互作用信息的情况下预测结合亲和力。但是, 已证明三维结构和物理相互作用先验对于提高模型的概括能力至关重要。³³

相反, 基于交互的模型^{3–7, 7–16, 34} 基于复合物的三维结构和蛋白质与配体的物理交互进行预测。在基于交互的模型中, 三维卷积神经网络 (3D-CNNs)^{5, 12} 和交互图神经网络 (IGNNs)^{3, 8, 11, 15, 33} 最常用于从含有原子交互信息的三维结构中预测结合亲和力。3D-CNNs 将复合物表示为三维网格并提取

收到时间: 2022年12月26日
接受时间: 2023年2月13日发
表时间: 2023年2月16日






图 1. 无交互和基于交互的方法用于PLA 预测。

使用三维卷积从三维网格中提取结构和交互信息，这效率较低，因为大多数体素并不包含关于结构的有用信息。此外，由于每个体素的位置不是不变的，旋转原子坐标将改变结合亲和力的预测值，这与生物事实不一致。另一方面，IGNNs将蛋白质-配体复合物表示为交互图，其中节点对应于原子，边对应于共价或非共价键/交互。将结构信息注入IGNNs的最常见方法是使用从其三维坐标^{3,11}计算出的成对原子-原子距离，这确保了IGNNs对复合物的平移和旋转的不变性。

尽管IGNNs在PLA预测中具有巨大的潜力，但由于其不足的泛化能力，它们可能尚未准备好用于实际应用。^{3,35} 我们总结了现有IGNNs在结合亲和力预测中的两个潜在问题。首先，现有IGNNs通常将共价交互和非共价交互视为相同类型的交互。^{33,35-37} 在这种情况下，配体节点可以在消息传递过程中同时接收来自其共价和非共价邻居的消息，如图2(a)所示。尽管这一假设简化了建模，但它有一个显著的缺点。非共价交互的数量远大于共价交互的数量（见补充材料C以获取更多细节），因此非共价交互将在计算中占主导地位（即，关于共价交互的信息可能会被非共价交互的信息淹没）。其次，几何先验（或




图 2. 提出方法的动机。(a) 配体节点接收来自其共价和非共价邻居的消息。在此示例中，配体节点有3个共价邻居和17个非共价邻居。因此，非共价交互将在计算中占主导地位。(b) 预测结合亲和力应对不同的初始三维放置保持不变。

对称先验是一个重要的归纳偏差，可以通过利用问题的对称性限制神经网络到相关功能，从而提高模型泛化能力。^{138–40} 例如，对于相同的蛋白质–配体复合物，不同的初始位置（例如，不同的位置和方向）下，预测结合亲和力应保持不变，如图 2(b)所示。然而，这种不变性特性仍然未得到充分探索（例如，针对 IGNNs 通过考虑不变性特性获益的研究较少）。

为了解决上述问题，我们提出了一种几何交互图神经网络（GIGN），该网络结合了三维结构和物理交互，并引入不变性约束以预测蛋白质–配体结合亲和力。GIGN的主要贡献包括以下几点：

- GIGN采用了一种异质交互层，将共价和非共价交互统一纳入信息传递阶段，以更有效地学习节点表示。异质交互层将共价和非共价交互视为不同类型的交互，并在信息传递过程中独立处理它们，从而避免了在图 2(a)中描述的缺陷。
- GIGN强制神经网络满足关于输入平移和旋转的不变性特性。我们展示了，通过考虑不变性特性，模型的泛化能力可以得到显著提高。
- 实验结果表明，GIGN 在三个外部测试集上实现了最先进性能，且具有低计算成本，这使其更易于应用于大规模数据库。
- 可视化结果显示，GIGN 能够捕捉与结合相关的基本特征。

■ 问题定义

在本研究中，一个复合物被表示为一个三维交互图，其中和分别是配体和蛋白质节点（即原子）的集合；和分别是配体和蛋白质共价边（即共价键/相互作用）的集合；是非共价边（即非共价键/相互作用）的集合；和分别是配体和蛋白质节点的三维坐标集合。

每个节点具有其初始特征和三维坐标。当原子 v_i 和 v_j 通过共价键连接时，存在一个共价边 e_{ij} 。当 $d_{ik} < r_{ij}$ 时，存在一个非共价边 e_{ik} 。

其中 $d_{ik} = \|r_i - r_k\|$ 是配体原子与蛋白质原子之间的距离。用于节点的初始特征可以在补充材料 A 表 S1 中找到。给定一个三维交互图，我们的目标是学习一个模型 f ，该模型满足不变性，以预测结合亲和力，如，其中。

■ 图神经网络

图神经网络（GNNs）是对图数据进行操作的置换等价网络。^{39,41} 具体而言，GNN模型使用消息传递函数⁴¹通过聚合来自其邻近节点的消息，迭代更新节点的表示，遵循

$$m_{ji} = M(h_j^{(t)}, h_i^{(t)}) \quad (1)$$

$$m_i = \sum_{v_j \in N(v_i)} m_{ji} \quad (2)$$

$$h_i^{(t+1)} = U(h_i^{(t)}, m_i) \quad (3)$$

其中 $h_i^{(t)}$ 表示 v_i 在GNNs的 t -层的节点表示， $h_i^{(0)} = Wx_i$ 是 v_i 的邻居集合， M 和 U 是可微分函数，如多层感知器（MLPs）。

■ 不变性

设有 T -组变换（例如，旋转、平移、反射或置换）。若图神经网络对 T 在 X 上不变， f ：

$$f(T(X)) = f(X) \quad (4)$$

在本研究中，我们探讨以下两种类型的不变性：

- 平移不变性，其中通过平移向量 g 对输入进行平移的结果是一个不变的输出（即， $f(X+g) = f(X)$ ）。
- 旋转不变性，其中通过旋转矩阵 Q 对输入进行旋转会产生不变的输出（即， $f(QX) = f(X)$ ）。




图 3. (a) GIGN的计算流程。(b) 异质交互层。(c) 异质交互层中共价和非共价交互的细节。

几何交互图神经网络

GIGN的整体计算流程如图 3(a)所示。GIGN使用一个异质交互层，将共价交互和非共价交互统一到信息传递阶段，以更有效地学习节点表示，如图 3(b)所示。具体而言，对于一个具有节点特征 $(x_1, x_2, \dots, x_N)$ 和三维坐标 $(r_1, r_2, \dots, r_N)$ 的三维交互图，异质交互层可以定义为

$$m_{ji}^{(cov)} = M^{(cov)}(h_j^{(t)}, h_i^{(t)}, \lambda(\|r_j - r_i\|^2)), \forall e_{ji} \in \mathcal{E}_l \cup \mathcal{E}_p \quad (5)$$

$$m_{ki}^{(ncov)} = M^{(ncov)}(h_k^{(t)}, h_i^{(t)}, \lambda(\|r_k - r_i\|^2)), \forall e_{ki} \in \mathcal{E}_{lp} \quad (6)$$

$$m_i^{(cov)} = \sum_{v_j \in N(v_i)} m_{ji}^{(cov)}, \forall e_{ji} \in \mathcal{E}_l \cup \mathcal{E}_p \quad (7)$$

$$m_i^{(ncov)} = \sum_{v_k \in N(v_i)} m_{ki}^{(ncov)}, \forall e_{ki} \in \mathcal{E}_{lp} \quad (8)$$

$$h_i^{(t+1)} = U^{(cov)}(h_i^{(t)}, m_i^{(cov)}) + U^{(ncov)}(h_i^{(t)}, m_i^{(ncov)}) \quad (9)$$

在 $M^{(cov)}$ 和 $M^{(ncov)}$ 分别实现为 $\odot$ 元素级乘积，如图 3(c)所示， $U^{(cov)}$ 和 $U^{(ncov)}$ 被实现为多层感知器，且 λ 是 $\odot$ 以 $\|r_j - r_i\|^2$ 几何交互图神经网络用于从三维结构预测蛋白质-配体结合亲和力和力 (GIGN) 的 (相关系数) 的 (2) 2

高斯径向基函数 (RBFs)⁴² 的线性组合位于中心 $0 \text{ \AA}$ $\leq h_k \leq 6 \text{ \AA}$ 每 $2/3 \text{ \AA}$ 与 $\sigma = 2/3 \text{ \AA}$ 。这是为了确保在 $5 \text{ \AA}$ 内的所有距离都被覆盖。通过公式 5 和 (6)，我们将结构信息 $\lambda(\|r_j - r_i\|^2)$ 和 $\lambda(\|r_k - r_i\|^2)$ 注入模型中。从直观上看， $m_i^{(cov)}$ 和 $m_i^{(ncov)}$ 处于不同的尺度，因为非共价交互的数量远大于共价交互的数量。因此，我们使用 $U^{(cov)}$ 和 $U^{(ncov)}$ 将 $m_i^{(cov)}$ 和 $m_i^{(ncov)}$ 转换为相同的尺度，然后进行整合，如公式 9 所示，这避免了图 2 (a) 中描述的问题。请注意，配体 (或蛋白质) 内的非共价交互也被包含在内，因为图神经网络的感受野可以通过增加层数而扩展^{2,43} (即，原子可以访问其 k-hop 邻居，对于 k 层图神经网络)。

对GIGN的不变性分析

请注意，异质交互层 F 对于平移和旋转是不变的。从形式上来看， F 满足

$$H^{(t+1)} = F(R, H^{(t)}) = F(QR + g, H^{(t)}) \quad (10)$$

其中是具有 N 个节点的图的节点表示矩阵，是三维坐标矩阵，是平移向量，以及是旋转矩阵 (正交矩阵)。

g^3
初始节点特征矩阵对于在 R 上的变换 (平移和旋转) 是不可变的；换句话说，我们并未注入关于 R 的任何位置信息。

进入 X 。因此, $H^{(0)} = WX$ 对于变换也是不变的。考虑到两个节点之间的距离对平移是不变的 $\| (r_j + g) - (r_i + g) \|^2 = \| r_j - r_i \|^2$ 和

$$\begin{aligned} \text{rotations } \|Qr_j - Qr_i\|^2 &= [Q(r_j - r_i)]^T [Q(r_j - r_i)] \text{, we can} \\ &= (r_j - r_i)^T Q^T Q (r_j - r_i) \\ &= \|r_j - r_i\|^2 \end{aligned}$$

得出该信息 m_{ji}^{cov} 在公式 5 中也是不变的:

$$\begin{aligned} m_{ji}^{(\text{cov})} &= M^{(\text{cov})}(h_j^{(t)}, h_i^{(t)}, \lambda(\|(Qr_j + g) - (Qr_i + g)\|^2)) \\ &= M^{(\text{cov})}(h_j^{(t)}, h_i^{(t)}, \lambda(\|r_j - r_i\|^2)) \end{aligned} \quad (11)$$

类似地, $m_{ji}^{(\text{ncov})}$ 在公式 6 中是不变的。因此, $m_i^{(\text{cov})}$ 、 $m_i^{(\text{ncov})}$ 和 $h_i^{(t+1)}$ 在公式 7–9 中也是不变的, 因为它们仅依赖于 $m_{ji}^{(\text{cov})}$ 、 $m_{ji}^{(\text{ncov})}$ 和 $h_i^{(t)}$, 因此我们可以得出结论 $F(QR + g, H^{(t)}) = F(R, H^{(t)})$ 。

■ 结合亲和力预测

我们使用全局求和池将最后一层图卷积层 (T -th 层) 的节点级表示封装成图级向量, 如

$$h_g = \sum_{v_i \in V} h_i^{(T)} \quad (12)$$

使用 MLP (多层感知器) 将其映射到一个标量, y 以指示结合亲和力。该模型经过训练, 最小化以下均方误差损失函数:

$$L_{\text{mse}} = \frac{1}{|D|} \sum_{n=1}^{|D|} (\hat{y}_n - y_n)^2 \quad (13)$$

其中 y_n 是数据集中第 n 个样本的实验结合亲和力, 且为样本大小。

■ 实施细节

实验是在具有 16 GB 内存的 NVIDIA GeForce RTX A4000 上进行的。使用带有 5×10^{-4} 学习率的 Adam 优化器来更新模型参数。我们应用一个 1×10^{-6} 的权重衰减来减少 GIGN 的过拟合。批量大小设定为 128。GIGN 的源代码可在 <https://github.com/guaguabujianle/GIGN> 找到。

■ 数据集准备

所提出的 GIGN 在 PDBbind 2016 版上进行了训练和验证。共有 13 285 个复合物 (一般和精炼集合), 实验结合亲和力以 pK_a ($-\log K_a$ 或者 $-\log K_i$) 值的形式收集自 PDBbind 网站 (<http://www.pdbbind.org.cn/>)。我们去除了 381 个无法通过 RDkit 处理的样本。其余的 12904 个样本随机分为训练 ($N = 11904$) 和验证 ($N = 1000$) 集合。三个独立的外部测试集合, 即 PDBbind 2013 核心集 ($N = 107$), 2016 核心集 ($N = 285$) 和 2019 保留集 ($N = 4366$), 用于测试 GIGN 的泛化能力。2013 和 2016 核心集是评估结合亲和力预测性能的两个常用基准。^{3,5,10,14,35} 然而, 它们的小样本量往往导致过于乐观的结果。⁴ 因此, 我们从 PDBbind 2019 版收集了 4366 个样本。

在其他四个数据集中不可用的作为新的外部保留集, 模拟了一种真实的时间分割场景, 在该场景中, 对新发布的结构的结合亲和力通过在过去的结构数据上训练的模型进行预测。这种时间分割设置是一项更困难的任务, 并且更准确地反映了药物发现的真实情况。⁴⁴ 注意, 这五个数据集之间的复合物没有重叠。为了证明 CSAR-HiQ 能够推广到非 PDBbind 数据集, 我们还在 CSAR-HiQ 数据集中对其进行了验证。⁴⁵ CSAR-HiQ 数据集包含两个子集, 总共有 343 个复合物。在剔除与上述五个数据集重叠并不能被 RDkit 处理的复合物后, 我们保留了 47 个样本作为非 PDBbind 外部测试集。在处理过程中, 距离大于 5 Å 的配体-蛋白质原子对被移除, 这遵循了之前的研究。^{11,33}

■ 性能指标

模型性能通过皮尔逊相关系数 (R_p) 和均方根误差 (RMSE) 进行评估, 其定义如下。

$$\text{RMSE} = \sqrt{\frac{1}{|D|} \sum_{n=1}^{|D|} (\hat{y}_n - y_n)^2} \quad (14)$$

$$R_p = \frac{\sum_{i=1}^{|D|} (\hat{y}_n - \bar{\hat{y}})(y_n - \bar{y})}{\sqrt{\sum_{i=1}^{|D|} (\hat{y}_n - \bar{\hat{y}})^2 (y_n - \bar{y})^2}} \quad (15)$$

■ 基线

我们将 GIGN 与以下代表性方法进行比较。

- 无交互方法:
 - DeepDTA¹⁷ 将配体和蛋白质分别表示为 SMILES 和序列, 并建立两个卷积神经网络从 SMILES 和序列中提取特征。
 - GraphDTA¹⁸ 与 DeepDTA 相似, 但将配体表示为二维图, 并使用图神经网络 (包括 GCN、GAT、GIN 和 GAT-GCN) 从图中学习表示。
 - MGraphDTA² 也将配体表示为二维图, 并使用多尺度图神经网络从图中学习表示。
- 基于交互的方法:
 - Pafnucy⁵ 是一个代表性的三维卷积神经网络模型, 它能够学习蛋白质-配体复合物的空间结构和物理交互。
 - OnionNet¹⁴ 基于蛋白质-配体交互壳中的接触数量生成基于交互的特征, 并使用二维卷积神经网络学习表示以进行预测。
 - PotentialNet¹⁵ 提出了一种分阶段的门控图神经网络, 以同时包含配体和蛋白质之间的分子内交互和非共价交互。
 - GNN-DTI¹¹ 是一种基于 GNN 的方法, 它结合了三维结构信息, 并使用距离感知的图注意力来区分每个相互作用对结合亲和力的贡献。

表1. 提议的 GIGN 与三个外部测试集的基线比较结果

模型		2013 核心集 (N = 107)		2016 核心集 (N = 285)		2019保留集 (N = 4366)	
		均方根误差	R_p	均方根误差	R_p	均方根误差	R_p
无交互方法	DeepDTA	1.639 (0.026)	0.718 (0.014)	1.357 (0.015)	0.785 (0.007)	1.485 (0.023)	0.586 (0.012)
	GCN	1.749 (0.062)	0.662 (0.032)	1.513 (0.048)	0.719 (0.023)	1.763 (0.039)	0.439 (0.021)
	GAT	2.043 (0.029)	0.476 (0.022)	1.748 (0.019)	0.594 (0.010)	1.663 (0.027)	0.432 (0.016)
	图同质网络	1.691 (0.124)	0.694 (0.059)	1.470 (0.065)	0.743 (0.027)	1.676 (0.032)	0.472 (0.021)
	图注意力-图卷积网络	1.645 (0.085)	0.711 (0.036)	1.434 (0.064)	0.754 (0.025)	1.705 (0.075)	0.474 (0.028)
基于交互的方法	MGraphDTA	1.680 (0.093)	0.696 (0.046)	1.439 (0.047)	0.753 (0.022)	1.553 (0.028)	0.538 (0.013)
	Pafnucy	1.517 (0.014)	0.783 (0.005)	1.450 (0.047)	0.769 (0.019)	1.438 (0.016)	0.612 (0.014)
	OnionNet	1.583 (0.079)	0.741 (0.037)	1.399 (0.076)	0.770 (0.027)	1.510 (0.034)	0.573 (0.014)
	PotentialNet	1.607 (0.027)	0.773 (0.010)	1.503 (0.033)	0.772 (0.007)	1.514 (0.028)	0.564 (0.014)
	GNN-DTI	1.533 (0.084)	0.767 (0.040)	1.384 (0.013)	0.779 (0.008)	1.446 (0.006)	0.614 (0.007)
	IGN	1.428 (0.020)	0.807 (0.001)	1.269 (0.030)	0.821 (0.013)	1.410 (0.015)	0.630 (0.008)
	SchNet	1.570 (0.029)	0.754 (0.030)	1.390 (0.023)	0.787 (0.016)	1.522 (0.071)	0.560 (0.028)
	EGNN	1.498 (0.025)	0.782 (0.015)	1.289 (0.021)	0.816 (0.011)	1.399 (0.013)	0.628 (0.010)
	GIGN (我们的)	1.380 (0.009)	0.821 (0.003)	1.190 (0.017)	0.840 (0.007)	1.393 (0.007)	0.641 (0.006)




图 4. 用于比较 GIGN 在 (a) 验证集、(b) 2013 核心集、(c) 2016 核心集和 (d) 2019 保留集上预测和实验结合亲和力的 Bland-Altman 图，其中 x 轴表示均值 (即, $(\hat{y} + y)/2$) 和 y 轴表示差值 (即, $\hat{y} - y$)。

•IGN³ 设计了两个堆叠的GNN模块，以分别顺序学习分子内和分子间相互作用。

•SchNet⁴² 使用连续滤波器卷积层来建模局部相关性，并且对平移和旋转不变。

表2. 三个外部测试集的消融研究的实验结果

模型	2013 核心集		2016 核心集		2019保留集	
	均方根误差	R_p	均方根误差	R_p	均方根误差	R_p
GIGN _TMP	1.460 (0.008)	0.791 (0.003)	1.242 (0.015)	0.822 (0.004)	1.409 (0.004)	0.634 (0.004)
GIGN _TRVar	1.518 (0.047)	0.763 (0.019)	1.416 (0.024)	0.760 (0.010)	1.530 (0.004)	0.550 (0.007)
GIGN _RVar	1.520 (0.010)	0.765 (0.007)	1.344 (0.033)	0.788 (0.013)	1.447 (0.023)	0.608 (0.006)
GIGN (我们的)	1.380 (0.009)	0.821 (0.003)	1.190 (0.017)	0.840 (0.007)	1.393 (0.007)	0.641 (0.006)

- EGNN³⁹ 通过探索三维平移和旋转对称性来实现最先进行性能。

所有基线模型均使用原始论文提供的源代码进行实现。请注意, GNN-DTI、SchNet 和 EGNN 最初并未针对 PLA 预测而设计。因此, 我们对它们进行了调整, 以适应 PLA 预测任务。

■ 总体比较

所有模型共用相同的训练、验证和外部测试集。所有实验重复三次, 每次使用不同的随机种子。验证集用于选择验证均方根误差 (RMSE) 最低的最佳模型。所选的最佳模型用于评估在三个外部测试集上的 PLA 预测性能。最终, 我们根据三次独立运行报告性能的均值和标准差。

如 表1 所示, 在三个外部数据集上观察到 GIGN 的性能最佳, 分别在验证集、2013 核心集、2016 核心集和 2019 保留集上, 相比最佳基线模型提高了 1.7%、2.3% 和 1.7% 的 R_p 。图 4 展示了 GIGN 在验证集、2013 核心集、2016 核心集和 2019 保留集上的布兰德-阿尔特曼图, 其中预测结合亲和力与实验结合亲和力之间的差异相对于亲和力的平均值进行绘制。均值差为估计偏差, 差异的标准差 (SD) 则衡量了该均值周围的随机波动。观察到四个数据集的均值差均接近零, 这表明预测结合亲和力通常偏差较小。四个数据集中, 分别有 94.60%、95.37%、95.08% 和 94.71% 的点落在 95% 协议限内 (均值差 ± 1.96 标准差) 之内, 这表明预测与实验结合亲和力之间存在良好一致性。此外, 我们有以下观察。

如 表1 所示, 在无交互方法中, GraphDTA 和 MGraphDTA 的表现优于 DeepDTA。然而, 这两种基于 2D 图的方法在 Davis ($N = 30056$) 和 KIBA ($N = 118254$) 数据集上相较于基于 SMILES 的方法 (例如, DeepDTA) 表现较差,^{2,17} 后者在样本规模上远大于 PDBbind 2016 版 ($N = 13285$)。这一结果表明, 当样本规模相对较小时, 基于 2D 图的方法容易过拟合训练数据。另一方面, 我们可以观察到, 结合 3D 结构和物理交互的模型 (即, PotentialNet、GNN-DTI、I GIGN 和 GIGN) 优于那些基于 2D 图的方法。这一结果表明, 当数据稀缺时, 有必要将结构和交互的归纳偏见注入到机器学习模型中, 以避免从不足量的数据中学习这些先验知识。

值得注意的是, 所有方法在更具挑战性的 PDBind 2019 版本保留集上仅显示出适度的泛化能力。这个结果表明, 准确预测 PLA 仍然是一项挑战。考虑到 R_p 的阈值为 0.600,

通常用于确定一个好的预测定量结构-活性关系模型的^{35,46}, 仅有 Pafnucy、GNN-DTI、IGN、EGNN 和 GIGN 可以被视为令人满意。

为探讨为何模型在 2019 保留集中的表现较差, 我们计算了测试集与训练集之间的蛋白质重叠率和配体重叠率。重叠率表示在测试集中可以在训练集中找到的蛋白质 (或配体) 的百分比。2013 测试集、2016 测试集和 2019 保留集的蛋白质重叠率分别为 100.0%、99.6% 和 68.9%。这三个数据集的配体重叠率分别为 37.4%、30.9% 和 24.8%。显然, 2013 测试集和 2016 测试集的蛋白质和配体重叠率远高于 2019 保留集, 这可以解释为何模型在 2019 保留集中的表现较差。尽管 2013 和 2016 测试集中的复合物与训练集完全不同, 但高的蛋白质和配体重叠率可能导致信息泄露, 从而导致过于乐观的结果。

■ 消融研究

为了验证所提出的异质交互层和不变性约束的有效性, 我们在三个基准上比较 GIGN 及其三个变体。

- GIGN_TMP 采用传统的消息传递, 其中共价交互和非共价交互被视为同一种交互类型。
- GIGN VarTR 对平移和旋转具有变体。具体而言, 我们将相应的坐标 r_i ($\times 0.1$ 以稳定训练) 添加到节点 v_i 的初始特征 x_i 中 (即, $(r_i \times 0.1) \parallel x_i$, 其中 $\parallel$ 是连接) 以在初始节点特征中注入结构信息。显然, 这些坐标对平移和旋转具有变体, 因此 $(r_i \times 0.1) \parallel x_i$ 也对这些变换具有变体。
- GIGN_VarR 仅对旋转具有变体。络合物的坐标通过减去配体的质心进行归一化, 然后再将其添加到初始特征 x_i 中。

表2 总结了消融研究的实验结果。观察到 GIGN 超越了三个变体, 展示了异质交互设置和不变性约束的必要性。具体而言, GIGN_VarR 在 2016 核心集和 2019 保留集中显著超过 GIGN_VarTR, 这证明了平移不变性的重要性。如果没有平移不变性, 该模型不太能够辨别同一蛋白质-配体复合物在不同位置的表现 (即, 它为不同位置的相同复合物预测不同的结合亲和力)。GIGN_VarR 通过规范化坐标解决了这个问题, 从而带来了更好的泛化能力。此外, 可以观察到 GIGN 大幅超过 GIGN_VarR, 这表明了旋转不变性的意义。另一种缓解

旋转不变性的方法是使用数据增强（即在训练期间随机旋转输入复合物），这是Pafnucy所采用的策略。GIGN通过不变性约束强制模型识别具有不同初始位置的相同蛋白质-配体复合物，从而避免昂贵的数据增强策略。

■ 在非-PDBbind外部测试集上的性能评估

为了进一步评估IGNNs的泛化能力，我们还在CSAR-HiQ数据集上对其进行评估。如表3所示，IGN、SchNet、EGNN和GIGN取得了可喜的

表3. 六种 IGNN 在 CSAR-HiQ 数据集上的性能评估

模型	均方根误差	R_p
PotentialNet	1.761 (0.073)	0.647 (0.037)
GNN-DTI	1.740 (0.094)	0.657 (0.049)
IGN	1.618 (0.130)	0.714 (0.057)
SchNet	1.587 (0.077)	0.746 (0.016)
EGNN	1.538 (0.010)	0.760 (0.012)
GIGN (我们的)	1.498 (0.058)	0.774 (0.025)

在此非-PDBbind外部测试集中的表现，这表明在PDBbind数据集上的高性能可能会转化为在实际虚拟筛选和药物开发中的高性能。

■ GIGN在重dock结构中保持其优越性

存在一个风险，即仅使用实验结构训练的模型无法推广到重dock结构¹⁴（即，模型的鲁棒性可能存在疑问）。为了评估GIGN的鲁棒性，我们还使用重dock结构对其进行评估。具体而言，对于2016测试集中的每一个复合体，我们从CASF-2016基准中选择具有最低RMSD（ $RMSD < 2 \text{ \AA}$ ，也称为本征类似构象）的重dock结构。⁴⁷ 我们使用GIGN预测这些重dock结构的结合亲和力。对于重dock结构的预测结合亲和力与实验结合亲和力的 R_p 和均方根误差（RMSE）值分别为0.826（0.005）和1.261（0.014）。这些结果表明，重dock结构的预测结合亲和力也接近实验结合亲和力。

■ 在冷启动设置下的性能评估

为了进一步防止蛋白质或配体的结构信息泄漏到测试集中，我们分割了原始

训练集（ $N = 11904$ ）按照30%蛋白质序列相似性或配体支架的比例分成新的训练集、验证集和测试集，比例为8:1:1（也称为冷启动设置²）。我们使用随机划分设置作为对照组。在冷启动设置中模型的性能远不及其他设置，这并不令人惊讶，如表4所示，因为冷启动设置防止了蛋白质或配体的结构信息泄漏到测试集中。此外，可以观察到GIGN在随机和支架划分设置中取得了更好的性能，而在序列相似性划分设置中表现相对较差。这是因为GIGN的异质交互层主要旨在增强配体原子的节点表示，而非蛋白质原子的节点表示。

■ GIGN的认知不确定性量化

基于ML的方法在那些域外复合物上可能产生不可靠的预测。减少不可靠预测的一个可能方法是根据估计的不确定性过滤预测。⁸ 我们使用蒙特卡罗丢弃（MCDO）来量化预测的认知不确定性⁴⁸。具体而言，我们估计2019保留集的预测不确定性，该集样本量相对较大。首先根据估计的不确定性对预测进行排名。然后，我们选择不确定性最低的三分之一样本（低组）和不确定性最高的三分之一样本（高组）。作为比较，我们从2019保留集中随机选择三分之一样本，并将其标记为随机组。为了更好地说明，还提供了一个简单地使用数据集中所有样本的基准组。图5(a)显示了四组在 R_p 方面的比较。我们可以观察到低组的 R_p 远大于随机组和高组，这表明估计的不确定性可以用于过滤不可靠的预测。

为了弄清楚为什么机器学习模型会对某些预测产生较高的不确定性，我们首先绘制了训练集的实验结合亲和力的直方图，以及2019保留集中实验结合亲和力与估计不确定性之间的散点图，如图5(b)和(c)所示。观察到实验结合亲和力通常遵循正态分布，如图5(b)所示。直观上，模型对于那些低/高实验结合亲和力的复合物会表现出高不确定性，这是由于样本量较小。然而，图5(c)中所示的结果显示，样本量较小并不是预测高度不确定性的主要原因，因为那些低/高实验结合亲和力的复合物的估计不确定性并不会比其他复合物高太多。一个可能的

表4. 在随机划分和冷启动（基于序列相似性和支架的划分）场景中对六个IGNN的性能评估

模型	随机		序列相似性 (30%)		支架	
	均方根误差	R_p	均方根误差	R_p	均方根误差	R_p
PotentialNet	1.360 (0.030)	0.691 (0.013)	1.582 (0.017)	0.507 (0.006)	1.538 (0.006)	0.532 (0.015)
GNN-DTI	1.403 (0.011)	0.666 (0.007)	1.499 (0.008)	0.562 (0.006)	1.401 (0.027)	0.631 (0.018)
IGN	1.295 (0.011)	0.732 (0.006)	1.509 (0.034)	0.561 (0.025)	1.361 (0.041)	0.665 (0.023)
SchNet	1.398 (0.044)	0.672 (0.021)	1.499 (0.022)	0.566 (0.020)	1.456 (0.046)	0.607 (0.014)
EGNN	1.285 (0.025)	0.730 (0.012)	1.483 (0.029)	0.579 (0.017)	1.395 (0.036)	0.635 (0.029)
GIGN (我们的)	1.264 (0.015)	0.746 (0.006)	1.521 (0.012)	0.565 (0.007)	1.353 (0.002)	0.685 (0.004)




图5. GIGN预测的不确定性估计。(a) 2019保留集的基线、随机、低和高组的 R_p 值(基线, 使用整个数据集; 随机, 随机选择三分之一的样本; 低, 具有最低不确定性的三分之一样本; 高, 具有最高不确定性的三分之一样本)。(b) 训练集的实验结合亲和力和力直方图。(c) 2019保留集的不确定性与实验结合亲和力的散点图。(d) 2013核心集、2016核心集和2019保留集的预测不确定性估计。

高不确定性的原因在于某些输入为域外复合物。具体而言, 图5(d)描述了在2013核心集、2016核心集和2019保留集中的预测估计不确定性(估计不确定性的分布在补充材料B图S1中显示)。可以观察到, 2019保留集的估计不确定性远高于2013和2016核心集。2019保留集是按照时间拆分设置收集的, 且它包含的新发布结构可能与训练集中的复合物表现出不同模式(即, 域外复合物), 这可以解释其估计不确定性为何高于2013和2016核心集, 以及为何GIGN在该数据集中表现相对较差。

GIGN的可视化解释

在没有理解和验证其工作机制的情况下, 图神经网络(GNNs)无法得到完全信任,^{43,49}这限制了它们的

在药物发现场景中的应用。在本节中, 我们进行两项可视化解释实验, 以合理化GIGN。

为了证明复合物的图级表示(即在eq 12中)是有意义的, 我们在训练的某些阶段对它们进行可视化。具体而言, 我们从PDBbind 2016版中随机选择256个复合物, 并使用GIGN将它们映射为 m 维向量($m = 256$ 在本研究中)。256维向量类似于复合物的指纹表示, 通过t-SNE被降维为二维嵌入。⁵⁰图6显示了在第1、80、175和302个epoch的二维嵌入分布(具有最低验证均方根误差的最佳epoch)。如图6所示, 散点图在开始时显示出一定程度的混乱, 然后根据结合亲和力在训练过程中聚集成簇, 这表明学习到的图表示是有意义的。

为了进一步探索哪些配体原子对PLA预测贡献最大, 我们可视化了




图6. 复合物嵌入在训练周期(a) 1, (b) 80, (c) 175, 以及(d) 302的可视化结果。

使用Grad-AAM的配体原子重要性。² 图7展示了可视化结果, 其中原子重要性的分布与结合模式密切匹配 (更多示例见补充材料B图S2)。具体而言, 我们有两个以下观察。首先, 权重较高的配体原子往往位于被普遍认为是促进蛋白质-配体结合的氢键的位置。其次, 那些权重较低的配体原子通常位于结合口袋之外, 这表明GIGN对结合姿势敏感。我们还提供了一个关于使用Grad-AAM可视化蛋白质原子重要性的案例 (图8)。同样, 可以观察到原子重要性与氢键之间的关系。总体而言, 这些结果表明GIGN能够捕捉与结合相关的基本特征。

■ 参数敏感性分析

在本实验中, 测试了 GIGN 的两个主要超参数, 即异构交互层的数量 T 以及隐藏通道的数量 m 。我们分析了 T 从1到6的影响。如图9所示, 当使用2-4异构交互层时, 模型实现了更好的性能。从理论上讲, 随着 T 的增加, GNN的感受野可以扩大⁴³ (即模型可以检测到更大的分子亚结构)。然而, 增加 T 还会导致过平滑问题。⁴³ 因此, 为GIGN应用三个异构层已经足以捕捉到足够的结构信息。我们通过将 m 设置为不同的值(32、64、128、192、256和320)来分析其影响。如图9所示, 随着 m 从32增加, 可以观察到一个普遍的上升趋势。

256. 这是因为相对较大的隐藏通道可以编码更多信息。然而, 如果我们

继续将其增加到320, 则可能会出现轻微的性能下降, 这可能是由过拟合问题引起的。

■ 模型复杂性

除了在PLA预测上表现最先进, GIGN的另一个优势是低计算成本。

图10显示了六个IGNNs (PotentialNet、GNN-DTI、IGN、SchNet、EGNN和GIGN) 的参数数量和浮点运算数(FLOPs)。在表现优于其他模型的前三个IGNNs (IGN、EGNN和GIGN) 中, 如表1所示, GIGN的计算成本明显低于IGN和EGNN。这种轻量级优势意味着GIGN更易于应用于大规模数据库。

■ 局限性

基于交互的模型的一个缺点是它们在很大程度上依赖于优化后的结构。具体而言, PDBbind数据集中所有复合物都是依据最小能量标准进行优化的, 这意味着在训练基于交互的模型时, 必须提供配体结合结构 (即配体的最佳位置和取向)。然而, 优化后的结构在实际应用中并不总是可用。幸运的是, EQUIBIND¹表明, 使用深度学习来预测配体结合结构是可能的, 并且比传统对接具有显著的速度提升和更好的质量。如果优化后的结构未知, EQUIBIND可以成为预测配体如何与蛋白质结合的有用工具。

本研究专注于如何有效地将复合物的三维结构和蛋白-配体的物理交互纳入图神经网络(GNNs)中。为此, 我们提出了一个简单但有效的基于GNN的模型GIGN, 以预测




图7. 使用Grad-AAM对具有PDB ID (a) 2f6v, (b) 2r1x, (c) 1bju和(d) 1cnx的复合物的配体原子重要性进行可视化, 其中左列和右列分别为显示氢键的三维和二维结合模式。在二维结合模式中, 原子重要性使用蓝色/橙色表示。




图 8. 使用Grad-AAM对PDB ID 4ym2的复合物进行的蛋白质原子重要性的可视化。(a) 带有原子标签的配体。(b) 带有氢键的蛋白质，其中O:4表示原子标签为4的配体原子O。




图 9. T 和 m 在三个外部测试集上的参数分析。




图 10. 模型复杂性方面的分析，包括(a) 参数数量（越低越好）和(b) FLOPs（越低越好）。

来自三维结构和物理交互的PLA。GIGN的核心是一个异质交互层，它将共价和非共价交互统一到信息传递阶段，同时保持对输入的不变性特性。

平移和旋转，从而避免数据增强的计算负担。除了较其他基准模型具有更好的泛化能力，可视化结果显示GIGN能够捕获与结合相关的基本特征。我们

希望所提出的GIGN能够激发其他类型生物三维相互作用的设计。

■ 关联内容

数据可用性声明

对GIGN和其他基准的演示、说明、代码和数据可在<https://github.com/guaguabujianle/GIGN>获取。

● 支持信息

支持信息可免费获得，网址为<https://pubs.acs.org/doi/10.1021/acs.jpcllett.2c03906>。

原子特征的详细信息、额外的可视化结果，以及共价和非共价交互数量的定量分析 (PDF)

■ 作者信息

通信作者

Calvin Yu-Chian Chen – 智能医学研究中心，智能系统工程学院，中山大学，深圳，广东 510275，中国；中国医科大学附属第一医院，台中 40447，台湾；亚太大学，生物信息学与医学工程系，台中 41354，台湾；orcid.org/0000-0001-9213-9832；电子邮件：chenyuchian@mail.sysu.edu.cn

作者

Ziduo Yang – 智能医学研究中心，智能系统工程学院，中山大学，深圳，广东 510275，中国 **Weihe Zhong** – 智能医学研究中心，智能系统工程学院，中山大学，深圳，广东 510275，中国 **Qiuji Lv** – 智能医学研究中心，智能系统工程学院，中山大学，深圳，广东 510275，中国 **Tiejun Dong** – 智能医学研究中心，智能系统工程学院，中山大学，深圳，广东 510275，中国；orcid.org/0000-0003-3434-3370

完整的联系信息可在以下地址查阅：

<https://pubs.acs.org/10.1021/acs.jpcllett.2c03906>

作者贡献

¶ 平等贡献者。

备注

作者声明没有竞争性的经济利益。

■ 致谢

本研究得到了中国国家自然科学基金（基金编号 62176272）和中国医科大学附属第一医院（DMR-112-085）的支持。

■ 参考文献

(1) Stärk, H.; Ganea, O.; Pattanaik, L.; Barzilay, R.; Jaakkola, T. Equibind: 几何深度学习用于药物结合结构预测。在 第39届国际机器学习会议论文集；机器学习研究会议论文集，第162卷；PMLR, 2022；第 20503–20521页。

(2) 杨志；钟伟；赵黎；陈嘉铭 MGraphDTA: 深度多尺度图神经网络用于可解释药物-靶点结合亲和力预测。化学科学2022, 13, 816–833。

(3) 姜丹；谢才义；吴泽；康雨；王骏；王珂；廖博；沈琦；徐龙；吴军；等人 Interactiongraphnet: 一种新颖有效的深度图表示学习框架，用于准确的蛋白质-配体相互作用预测。医学化学杂志2021, 64, 18209–18232。

(4) Sánchez-Cruz, N.; Medina-Franco, J. L.; Mestres, J.; Barril, X. 扩展连接交互特征：通过化学描述提高结合亲和力预测。生物信息学 2021, 37, 1376–1382。

(5) Stepniewska-Dziubinska, M. M.; Zielenkiewicz, P.; Siedlecki, P. 开发和评估一种深度学习模型用于蛋白质-配体结合亲和力预测。生物信息学 2018, 34, 3666–3674。

(6) 王, Y.; 吴, S.; 段, Y.; 黄, Y. 一种基于点云的深度学习策略用于蛋白质-配体结合亲和力预测。Briefings Bioinf. 2022, 23, bbab474。

(7) 郑, L.; 孟, J.; 姜, K.; 兰, H.; 王, Z.; 林, M.; 李, W.; 郭, H.; 韦, Y.; 穆, Y. 通过引入评分函数修正项来提高蛋白质-配体对接和筛选的准确性。Briefings Bioinf. 2022, 23, bbac051。

(8) 月, S.; 钟, W.; 杨, S.; 林, J.; 金, W. Y. PIGNet: 一种以物理为基础的深度学习模型用于普适的药物-靶标相互作用预测。化学科学 2022, 13, 3661–3673。

(9) 王, Z.; 郑, L.; 刘, Y.; 崔, Y.; 李, Y.-Q.; 赵, M.; 穆, Y.; 李, W. OnionNet-2: 一种基于残基-原子接触壳层的卷积神经网络模型，用于预测蛋白质-配体结合亲和力。前沿化学 2021, 9, 753002。

(10) 乔恩斯, D.; 金, H.; 张, X.; 泽姆拉, A.; 史蒂文森, G.; 贝内特, W. D.; 基尔施纳, D.; 黄, S. E.; 莱斯特通, F. C.; 艾伦, J. E. 基于结构的深度融合推理改善蛋白质-配体结合亲和力预测。化学信息模型杂志 2021年, 61, 1583–1592。

(11) 林, J.; 柳, S.; 朴, K.; 车, Y. J.; 哈姆, J.; 金, W. Y. 使用新颖的图神经网络和三维结构嵌入图表示预测药物-靶点相互作用。化学信息模型杂志 2019年, 59, 3981–3988。

(12) 拉戈扎, M.; 霍库利, J.; 伊德罗博, E.; 桑塞里, J.; 科斯, D. R. 使用卷积神经网络进行蛋白质-配体评分。化学信息模型杂志 2017年, 57, 942–957。

(13) 托恩, W.; 阿尔特曼, R. B. 图卷积神经网络用于预测药物-靶标相互作用。化学信息模型杂志2019, 59, 4131–4149。

(14) 郑丽；范, J.; 穆, Y. Onionnet: 一种基于多层分子接触的卷积神经网络用于蛋白质-配体结合亲和力预测。ACS omega 2019, 4, 15956–15965。

(15) 费因贝格, E. N.; 苏尔, D.; 吴, Z.; 休西克, B. E.; 麦, H.; 李, Y.; 孙, S.; 杨, J.; 拉姆苏达尔, B.; 潘德, V. S. PotentialNet 用于分子性质预测。ACS. 中心科学2018, 4, 1520–1530。

(16) 吉门兹, J.; 斯卡利克, M.; 马丁内斯-罗塞尔, G.; 德·法布里提斯, G. K. deep: 通过 3D 卷积神经网络进行蛋白质-配体绝对结合亲和力预测。化学信息模型杂志2018, 58, 287–296。

(17) Öztürk, H.; Özgür, A.; Ozkirimli, E. DeepDTA: 深度药物-靶点结合亲和力预测。生物信息学2018, 34, 1821–1829。

(18) 阮, T.; 乐, H.; 奎因, T. P.; 阮, T.; 乐, T. D.; 文卡泰什, S. GraphDTA: 使用图神经网络预测药物-靶点结合亲和力。生物信息学 2021, 37, 1140–1147。

(19) 杨志, Z.; 钟伟, W.; 赵, L.; 陈嘉铭, C. Y.-C. ML-DTI: 用于可解释药物-靶点相互作用预测的互学习机制。J. Phys. Chem. Lett. 2021, 12, 4247–4261。

(20) 椿木, M.; 富田, K.; 佐世, J. 复合-蛋白质相互作用预测，通过图形和序列的神经网络端到端学习实现。生物信息学2019, 35, 309–318。

(21) 陈亮；谭旭；王东；钟芳；刘, X.; 杨涛；罗兴；陈可；姜华；郑梅。TransformerCPI: 通过基于序列的深度学习结合自注意力机制和标签反转实验提高化合物与蛋白质相互作用的预测。生物信息学2020, 36, 4406–4414。

(22) 郑, S.; 李, Y.; 陈, S.; 徐, J.; 杨, Y. 使用准视觉问答系统预测药物-蛋白质相互作用。自然机器智能2020, 2, 134–140。

- (23) 李, I.; 金, J.; 南, H. DeepConv-DTI: 通过对蛋白质序列进行卷积的深度预测药物-靶标相互作用。 *PLoS Comput. Biol.* 2019, 15, No. e1007129.
- (24) Abbasi, K.; Razzaghi, P.; Poso, A.; Amanlou, M.; Ghasemi, J. B.; Masoudi-Nejad, A. DeepCDA: 通过LSTM和卷积神经网络进行深度跨领域化合物-蛋白亲和力预测。 *生物信息学* 2020, 36, 4633–4642.
- (25) Rifaoglu, A. S.; Cetin Atalay, R.; Cansen Kahraman, D.; Dogan, T.; Martin, M.; Atalay, V. MDDeePred: 在药物发现中基于深度学习的结合亲和力和预测的新型多通道蛋白特征化。 *生物信息学* 2021, 37, 693–704.
- (26) Chu, Y.; Kaushik, A. C.; Wang, X.; Wang, W.; Zhang, Y.; Shan, X.; Salahub, D. R.; Xiong, Y.; Wei, D.-Q. DTI-CDF: 一种基于混合特征的化合物-靶标相互作用预测的级联深度森林模型。 *Briefings Bioinf* 2021, 22, 451–462.
- (27) Rifaoglu, A. S.; Nalbat, E.; Atalay, V.; Martin, M. J.; Cetin-Atalay, R.; Dogan, T. DEEPScreen: 高性能药物-靶点相互作用预测, 使用基于卷积神经网络的二维结构化合物表示。 *化学科学* 2020, 11, 2531–2557.
- (28) Huang, L.; Lin, J.; Liu, R.; Zheng, Z.; Meng, L.; Chen, X.; Li, X.; Wong, K.-C. CoaDTI: 基于多模态共同注意力的药物-靶点相互作用注解框架。 *Briefings Bioinf* 2022, 23, bbac446.
- (29) Yuan, W.; Chen, G.; Chen, C. Y.-C. FusionDTA: 基于注意力的特征聚合器和知识蒸馏, 用于药物靶点结合亲和力和预测。 *Briefings Bioinf* 2022, 23, bbab506.
- (30) 黄, K.; Xiao, C.; Glass, L. M.; Sun, J. MolTrans: 分子相互作用变换器用于药物-靶点相互作用预测。 *生物信息学* 2021, 37, 830–836.
- (31) Zeng, Y.; Chen, X.; Luo, Y.; Li, X.; Peng, D. 结合多个注意块的深度药物-靶点结合亲和力和预测。 *Briefings Bioinf* 2021, 22, bbab117.
- (32) Wang, K.; Zhou, R.; Li, Y.; Li, M. DeepDTAF: 一种深度学习用于预测蛋白质-配体结合亲和力的。 *Briefings Bioinf* 2021, 22, bbab072.
- (33) Li, S.; Zhou, J.; Xu, T.; Huang, L.; Wang, F.; Xiong, H.; Huang, W.; Dou, D.; Xiong, H. 结构感知交互图神经网络用于预测蛋白质-配体结合亲和力。在 **第27届 ACM SIGKDD 知识发现会议论文集&数据挖掘**; 计算机协会: 纽约, NY, 2021; pp 975–985.
- (34) 巴列斯特, P. J.; 米切尔, J. B. 一种机器学习方法用于预测蛋白质-配体结合亲和力及其在分子对接中的应用。 *生物信息学* 2010, 26, 1169–1175.
- (35) 伏尔科夫, M.; 图尔克, J.-A.; 德里扎尔, N.; 马丁, N.; 霍夫曼, B.; 加斯顿-马特, Y.; 罗尼昂, D. 关于从蛋白质-配体结构预测结合亲和力的挫折, 采用深度神经网络的方法。 *医学化学杂志* 2022, 65, 7946–7958.
- (36) 姜, H.; 王, J.; 从, W.; 黄, Y.; 拉梅扎尼, M.; 萨尔马, A.; 多霍良, N. V.; 马赫达维, M.; 坎德米尔, M. T. 使用图神经网络预测蛋白质-配体对接结构。 *化学信息模型杂志* 2022, 62, 2923–2932.
- (37) 莫罗恩, J. A.; 韦伯, J. K.; 胡印, T.; 罗, H.; 康奈尔, W. D. 结合对接姿势排名和结构的深度学习改善了蛋白质-配体结合模式预测, 相较于基线对接方法。 *化学信息模型杂志* 2020, 60, 4170–4179.
- (38) 阿茨, K.; 格里索尼, F.; 施耐德, G. 在分子表征的几何深度学习。 *自然机器学习* 2021, 3, 1023–1032.
- (39) 萨托拉斯, V. G.; 霍格博姆, E.; 威林, M. E(n) 等变图神经网络。见 **第38届国际机器学习会议论文集**; 机器学习研究会议论文集, 第 139 卷; PMLR, 2021; 第 9323–9332页.
- (40) 加尼亚, O.-E.; 黄, X.; 布纳, C.; 边, Y.; 巴兹利, R.; 雅卡拉, T.; 克劳斯, A. 独立SE(3)等变模型用于端到端刚性蛋白质对接。见 **学习表征国际会议论文集**, 2022年4月25日; OpenReview, 2022.
- (41) 吉尔默, J.; 舍恩霍兹, S. S.; 赖利, P. F.; 维尼亚尔斯, O.; 达尔, G. E. 神经信息传播在量子化学中的应用。见 **会议记录**
- 第34届国际机器学习会议; 机器学习研究会议记录, 第 70 卷; PMLR, 2017年; 第 1263–1272页.
- (42) Schütt, K.; 金德曼斯, P.-J.; 索塞达, H.; 哈米耶拉, S.; 特卡岑科, A.; 穆勒, K.-R. SchNet: 一种用于建模量子相互作用的连续滤波卷积神经网络。载于 **第30届神经信息处理系统会议进展**; Guyon, I., Von Luxburg, U., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., Garnett, R., Eds.; 神经信息处理系统基金会: 加州圣地亚哥, 2017年; 载于 pp 992–1002.
- (43) 杨志; 钟伟; 吕青; 陈嘉铭. 通过子结构-aware 图神经网络学习大小自适应分子子结构以进行可解释的药物-药物相互作用预测。 *化学科学* 2022, 13, 8693–8703.
- (44) 费因贝格; 乔希; 潘德; 程. 利用多任务深度特征化提高ADMET预测。 *医学化学杂志* 2020, 63, 8835–8848.
- (45) 邓巴, J. B., Jr.; 史密斯, R. D.; 杨, C.-Y.; 翁, P. M.-U.; 列克萨, K. W.; 哈赞诺夫, N. A.; 斯图基, J. A.; 王, S.; 卡尔森, H. A. 2010年 CSAR基准测试: 蛋白质-配体复合物的选择。 *化学信息模型杂志* 2011, 51, 2036–2046.
- (46) 马丁, E. J.; 波利亚科夫, V. R.; 朱, X.-W.; 田, L.; 穆克吉, P.; 刘, X. 全测定-Max2 pQSAR: 活性预测的准确性与8558项诺华测定的四浓度IC50相当。 *化学信息模型杂志* 2019, 59, 4450–4459.
- (47) 苏, M.; 杨, Q.; 杜, Y.; 冯, G.; 刘, Z.; 李, Y.; 王, R. 评分函数的比较评估: CASF-2016更新。 *化学信息模型杂志* 2019, 59, 895–913.
- (48) 加尔, Y.; 加哈拉马尼, Z. 随机失活作为贝叶斯近似: 在深度学习中表示模型不确定性。见 **第33届国际机器学习会议纪要**; 机器学习研究会议记录, 第 48 卷; PMLR, 2016; pp 1050–1059.
- (49) 杨志; 钟伟; 吕青; 陈嘉铭. 多任务深度学习与动态任务平衡, 用于量子力学性质预测。 *物理化学化学物理* 2022, 24, 5383–5393.
- (50) 范德马滕, L.; 希顿, G. 使用t-SNE可视化数据。 *机器学习研究期刊* 2008, 9, 2579–2605.