

利用 IDPFold 精确生成固有无序蛋白质的构象集合

朱俊杰、李正新、郑卓奇、张波、钟波子涛、白杰、洪晓坤、
王泰峰、魏婷*、杨建义*、陈海峰*

内在无序蛋白质 (IDPs) 在多种生物学功能中发挥着关键作用, 其动态结构与多种人类疾病密切相关, 包括癌症、糖尿病及阿尔茨海默病。对 IDPs 进行结构研究通常结合分子动力学 (MD) 模拟与实验数据, 以减轻模拟方法中存在的固有偏差; 然而, 这些模拟方法所需的高昂计算成本以及实验数据的有限可得性, 显著限制了其应用范围。尽管近年来针对结构化蛋白质的结构预测技术取得了进展, 但理解 IDPs 的构象特性仍具挑战性——这部分源于无序蛋白质序列的保守性较差以及实验表征数据的匮乏。本文引入了 IDPFold 这一新方法, 该方法能够利用经过精细调参的扩散模型, 直接从 IDPs 的序列中生成其构象集合。IDPFold 无需依赖多序列比对 (MSA) 或实验数据, 从而能够对 IDP 构象集合中的结构特征进行更详尽的表征。在涵盖 27 个 IDP 系统的评估中, IDPFold 对 C α 级化学位移与实验值的 Rg 误差为 0.06, RMSD 值为 0.65 ppm, 这一表现显著优于所有现有的生成式深度学习方法。IDPFold 可用于阐明 IDPs 的“序列-无序-功能”研究范式。

1. 引言

内在无序蛋白质 (IDPs) 是一类在生理条件下具有不稳定性结构的蛋白质。^[1]这类蛋白质占真核生物蛋白质组的 40% 以上,^[2,3]参与多种生物学功能, 包括信号转导、分子识别及细胞周期调控。^[4,5,6]IDPs 还与多种重大疾病密切相关, 例如癌症、帕金森病以及获得性免疫缺陷综合征 (AIDS)。^[7,8,9]与具有一个或少数几种稳定构象的结构化蛋白质不同, IDPs 在多种构象之间发生转变, 且这些转变所需的能量势垒极低; 在生理条件下, 它们始终在广泛的结构集合中持续波动。^[10,11,12]因此, 解析 IDPs 的构象集合对 X 射线晶体学、冷冻电子显微镜及核磁共振 (NMR) 等实验方法而言是一项重大挑战。^[13–16]

J. 朱志、李志、郑斌、张斌、钟斌、白杰、魏涛、陈洪飞
微生物代谢国家重点实验室 (生物信息学与生物
统计学系) SJTU-耶鲁大学联合生物统计学中心
国家生命科学与生物技术实验教学中心
生命科学学院
上海交通大学
中国上海市, 邮编: 200240
电子邮件: weiting@sjtu.edu.cn; haifengchen@sjtu.edu.cn

X. 商行
生物科学与工程学院
福州大学
中国福建省福州市, 邮编: 350116
T. 王
BioMap
10 北京市永腾北路北仑工业园区 (邮编: 100080)
J. 阳
山东省教育厅前沿科学中心——非线性期望研究中心; 山东
大学数学与交叉科学研究中心
中国青岛市 266237
电子邮箱: yangjy@sdu.edu.cn

 本文作者的 ORCID 标识符
可查阅 <https://doi.org/10.1002/advs.202511636> © 2025 作者。本文由
Wiley-VCH GmbH 出版, 属于《Advanced Science》期刊发表的开放获取文
章。本文章依据[知识共享署名许可协议](#)发布; 该协议允许在任何媒介上使用
、分发和复制本文, 前提是须对原作品进行 proper citation (正确引用)。

DOI: 10.1002/advs.202511636

尽管对无序区域的识别已得到广泛研究——众多计算工具（如 IUPred 和 IDP-ELM）能够对无序区域进行准确且快速的预测——但对 IDPs 进行结构采样仍面临显著更大的挑战。^[17,18]目前，分子动力学（MD）模拟是用于采样构象系统最常用且最有效的工具。^[19,20]通过基于第一性原理对目标分子体系进行迭代采样，可从模拟结果中获得对构象系统的估计。根据分辨率的不同，MD 模拟大致可分为全原子模拟和粗粒化（CG）模拟两类。

全原子模拟虽能提供详尽的分子动力学洞察，但往往面临巨大的计算成本，使得对构象系统进行穷举采样变得十分困难。此外，常用于描述内在无序蛋白（IDPs）的全原子力场（如 ff03CMAP^[21]、a99SB-disp^[20]、ESFF1^[22]）在模拟过程中对 IDPs 的局部及全局性质进行估算时，仍存在相当大的误差^[23,24]；相反，粗粒度（CG）模拟在解析 IDP 动力学方面展现出卓越的效率与准确性——采用基于残基的 CG 力场（如 calvados 和 Mpipi）对单链 IDP 进行平衡系统采样通常仅需数分钟，且在估算 IDPs 的压缩程度时往往具有较高准确性^[25,26]；然而，CG 模拟会丢失蛋白质中局部动力学的细节，仅提供一个平滑化的自由能景观^[27]。

对内在无序蛋白（IDPs）进行实验表征有助于将全原子模拟结果相互关联，补充粗粒度（CG）模拟中缺失的细节，并开发无需依赖模拟的采样方法。^[28,29,30]然而，目前通过实验手段表征的 IDPs 数量仍然有限。生物磁共振数据库（BMRB）收集了生物体系的核磁共振（NMR）数据，这些数据是深入了解蛋白质（尤其是 IDPs）局部动力学行为的重要资源。^[31]但目前 BMRB 中仅包含 17,071 条记录，其中仅有不到一半的记录拥有解析结构。关于蛋白质整体动力学的数据则更为稀少，这类动力学行为通常通过单分子荧光共振能量转移（smFRET）和小角 X 射线散射（SAXS）技术进行研究。^[32]

另一方面，众多深度学习方法已被开发并广泛应用于结构化蛋白质的结构预测领域，例如 AlphaFold2 和 ESMFold。^[33,34]同时，在蛋白质设计任务中，多种生成式模型（如 RFdiffusion 和 Chroma）已被用于生成多样化的蛋白质主链结构。^[35,36]因此，探讨是否可利用深度学习方法对 IDPs 的构象集合进行快速、准确的预测，是十分合理的。

然而，目前与无序蛋白质（IDPs）相关的结构数据极为匮乏。PDB 数据库包含超过 220,000 条结构条目，^[37]而蛋白质集合数据库（Protein Ensemble Database）仅包含 553 条蛋白质集合数据。^[38]MobiDB 是研究 IDPs 的一个重要资源，它汇总了超过 2.45 亿种蛋白质的无序状态注释，但针对这些无序蛋白质的高质量结构——更不用说构象集合——仍然十分稀少。^[39,40]这一挑战的症结在于，针对 IDPs 的高质量多序列比对（MSA）数据往往匮乏。实践证明，MSA 仅在涉及 IDPs 折叠状态或结合状态的功能研究中具有成效，而在预测更无序的构象方面作用有限。^[41]这些显著的数据局限性使得利用深度学习来稳健地预测 IDPs 的构象集合变得极为困难。尽管

Janson 等人……此前，研究人员曾致力于 IDP 构象生成工作，并提出了 idpGAN 模型用于预测 IDP 构象集合；然而，这些方法主要侧重于生成粗粒度的 IDP 构象，且常受过度采样问题影响，从而在粗粒度乃至全原子分子动力学（MD）模拟领域仍存在空白。^[42,43]

本文引入 IDPFold，该工具基于生成式深度学习模型，直接从蛋白质序列预测其构象动力学（IDP dynamics）。IDPFold 利用蛋白质语言模型提取序列信息，随后将这些信息输入到结构生成模块中，从而实现无需多序列比对（MSA）的构象生成。为解决数据不足的问题，我们采用了一个由晶体结构、核磁共振（NMR）结构及分子动力学（MD）轨迹组成的混合数据集对 IDPFold 进行训练。实验获得的结构数据使模型能够学习蛋白质的基本特征，而 MD 轨迹则提供了充足的 IDP 结构数据，确保在 IDP 系统上进行精确采样。IDPFold 在蛋白质主链水平上生成 IDP 构象集合，其结果与实验观测值的吻合度优于其他前沿方法。IDPFold 能够对蛋白质的结构化与非结构化状态均进行采样，为研究 IDPs 的结构与功能之间的关联性提供了重要见解。

2. 结果

IDPFold 采用一种条件扩散模型框架，用于根据蛋白质序列生成蛋白质构象集合（图 1A）。该框架包含一个前向扩散过程（在真实蛋白质结构中逐步添加噪声）和一个反向扩散过程（利用深度学习网络进行去噪）。通过在反向扩散过程中将特定的蛋白质序列特征整合到模型中，我们可利用该架构为特定蛋白质生成构象集合。去噪网络以由 ESM2 提取的序列特征作为输入，该网络由一个初始化模块和四个去噪模块组成（图 1B）。初始化模块整合了序列特征、噪声尺度和噪声结构；而去噪模块则将不变点注意力机制（IPA）与传统 Transformer 模型相结合，以捕捉蛋白质中的链状结构以及每个残基的旋转/平移状态（图 1C）。如需了解更多详情，请参阅“材料与方法”部分。

2.1. IDPFold 可复现 IDPs 的全局特征

我们首先在粗粒度层面对 IDPFold 预测的集合进行了评估，主要关注这些预测集合的全局特征——尤其是回转半径（Rg）。Rg 是一个反映 IDPs 全局特性的关键物理量，其数值与蛋白质的整体松散度呈正相关，因此可作为描述并区分 IDPs 与结构化蛋白质的经验性度量指标。^[44,45]我们首先参照 Tessei 等人针对粗粒度力场 Calvados 2 开展的评估方法，计算了 IDPFold 预测集合在该力场测试集上的 Rg 误差。在剔除训练集中已包含的序列后，该测试集包含 58 个 IDP 系统。在这




图 1.IDPFold 的架构。A) 生成蛋白质集合的扩散过程；B) 去噪网络的结构；C) 初始化块与去噪块的详细架构。

些蛋白质中，IDPFold 预测集合的平均 R_g 误差为 $\sim 6\%$ (图 2A)。我们进一步分析了每个系统中预测集合的 R_g 分布，并将其与粗粒度动力学轨迹进行了比较。结果表明，对于大多数体系而言，IDPFold 预测的系综的 R_g 分布范围与粗粒度模拟所得的分布范围高度吻合 (图 2B；图 S1，支持信息)，尽管在某些体系 (如 PaaA2 和 drkN-SH3) 中存在显著偏差。

2.2. IDPFold 用于捕捉 IDP 系统的全球分布情况

为进一步评估 IDPFold 的稳健性，我们收集了 27 个具有丰富实验观测数据且未出现在训练集中的 IDP 系统 (参见支持信息中的表 S1 与 S2)。我们将 IDPFold 预测的集成结果与 calvados 2 的模拟结果以及粗粒度深度学习 idpGAN 在这些系统上的预测结果进行了比较。^[42,46] 结果表明，IDPFold 预测集成在该测试集上的平均 R_g 误差 ($\epsilon_{R_g} = \Delta R_g / R_g = 0.06$) 显著小于 idpGAN 的误差 ($\epsilon_{R_g} = 0.12$ ，配对 t 检验 p 值为

0.02)。模拟轨迹的 R_g 误差为 0.02，其绝对值优于两种深度学习方法，但与 IDPFold 相比则无显著差异 (配对 t 检验 p 值为 0.12)。与粗粒化模拟相比，IDPFold 对 IDP 的 R_g 值往往略有低估，尤其对于较长蛋白质而言。这在一定程度上源于长链无序蛋白 (IDPs) 所具有的高度构象空间复杂性，这使得对其构象集合进行建模变得更为困难。尽管经过微调的 IDPFold 版本在一定程度上修正了生成构象中的无序倾向，但对于大型系统而言，该工具仍会生成部分结构化的构象估计值，并导致压缩度被高估。总体而言，对于大型系统，IDPFold 预测的构象集合中高延伸构象所占比例往往较低。这一发现为未来提升全局特征估计值的准确性指明了方向：可通过重新加权来增加此类延伸构象在构象集合中的占比。

接下来，我们旨在观察三种方法在特定案例中生成的系综分布与主要构象。在此，我们以粗粒度模拟得到的初始构象作为参考，计算了每个系综的 R_g -RMSD 分布。结果表明，idpGAN 在所有测试体系中均存在过度采样现象，且该现象具有显著性。




图 2. IDPFold 生成的构象集合与使用 Calvados 2 进行的粗粒度分子动力学 (MD) 模拟结果之间的对比。A) IDPFold 预测的回转半径与 Calvados 2 测试集上实验测得的回转半径之间的相对误差；B) IDPFold 生成的构象集合 (彩色曲线) 与 Calvados 模拟结果 (黑色虚线) 的 R_g 分布。 R_g 的单位为埃 (Å)；实验值以黑色实线表示。对于每个体系，IDPFold 采样了 300 个构象或从 MD 轨迹中提取了这些构象。

在估算主要构象时存在偏差。作为对比，由 IDPFold 估算出的系综分布更接近粗粒度轨迹；其对自由能位点的估算结果比 idpGAN 的估算结果更为精确 (图3A, C, E)。尽管 IDPFold 的采样范围小于粗粒度轨迹的采样范围，但其对系综玻尔兹曼分布的估算结果比 idpGAN 更精确。

从聚类结果来看，在三个系统中，由 IDPFold 采样的主要构象及其占比与模拟结果更为接近，而 idpGAN 的结果则不然。在 Histatin5 蛋白中，IDPFold 预测的构象集合与模拟轨迹均以伸展构象作为主要结构；相比之下，idpGAN 预测的主要构象则处于半折叠状态 (图3B)。在两个规模较大的系统——人类钙蛋白酶抑制剂 (Human Calpastatin) 和 β Synuclein 中，idpGAN 的问题更为突出：其预测出的主构象呈塌陷状态，导致对这两种蛋白质的平均 R_g 值进行了严重低估 (图3D, F)。这表明 idpGAN 对构象集合分布的估计不准确。另一方面，IDPFold 预测的构象集合更准确地反映了主要构象的形态。尽管 IDPFold 由于高估了 β Synuclein 结构中的螺旋倾向而低估了其 R_g 值，但其对伸展构象与折叠构象占比的估计值则更接近于模拟结果。

2.3. IDPFold 预测的 IDP 集合与全原子分子动力学模拟结果相当

与前述粗粒化模拟相比，IDPFold 的一个主要优势在于它能够主链水平上生成蛋白质，从而使我们能够以更高的精度更好地理解蛋白质的动态特性。因此，我们对测试集中的 27 个 IDP 系统进行了全原子分子动力学模拟，以评估 IDPFold 预测的蛋白质集合中局部特征的质量。我们使用了专为 IDPs 参数化的 ESFF1 力场和溶剂模型 OPC3-B。^[22,24]为了证明模拟的收敛性，我们对其中 10 种蛋白质进行了三次独立模拟，记录了平行轨迹中实验观测到的物理量的分布及平均值。收敛性分析的结果如图S2 (支持信息) 所示。随后，我们比较了 IDPFold 预测的结果

将上述系综结果与全原子分子动力学 (MD) 模拟结果进行对比。我们分析了 IDPFold 所预测的键长、键角及二面角的分布情况。就键长与键角的分布而言，IDPFold 预测的系综与在 MD 轨迹中观测到的分布高度吻合，这表明该模型已有效学习了蛋白质残基中侧链的排布规律，能够准确预测相邻原子之间的距离与空间构型 (图S3A, 支持信息)。此外， Ω an 的分布——




图 3.对比 IDPFold 生成的构象集合与粗粒度深度学习方法 idpGAN 生成的构象集合。A、B: Histatin5 上预测构象集合的 Rg- RMSD 分布(A)与聚类中心(B); C、D: Human Calpastatin 上预测构象集合的 Rg- RMSD 分布(C)与聚类中心(D); E、F: β Synuclein 上预测构象集合的 Rg- RMSD 分布(E)与聚类中心(F)。每个体系均采样了 300 个构象。




图4. IDPFold与采用不同力场进行的全原子分子动力学 (MD) 模拟的性能对比。A) IDPFold在估算局部特征 (C_{α} , C_{β} 化学位移) 及全局特征Rg方面的准确性与MD模拟结果的对比; B) IDPFold生成的构象集合与采用a99SB-disp方法对 α -突触核蛋白进行MD模拟所得结果的Rg- RMSD分布对比; C) 对 α -突触核蛋白应用a99SB-disp与IDPFold生成的构象集合与实验观测值之间的误差; D-G) IDPFold生成的构象集合与采用a99SB-disp方法对 α -突触核蛋白进行MD模拟所得结果的局部特征对比: 包括 C_{α} 化学位移(D)、 C 化学位移(E)、 HN 化学位移(F)及 $^3J(HN, H_{\alpha})$ (G)。每个体系均采样了300个构象。

模型生成的构象中出现的GLES结构与在分子动力学 (MD) 轨迹中观察到的结构相似, 其中存在一个约180°的峰值, 这表明模型生成的局部肽键平面构象是稳定的, 并与蛋白质的普遍特征相吻合 (图S3B, 支持信息)。此外, ϕ - ψ 角的Ramachandran图显示, 所生成构象的主链二面角大多处于合理范围内。不同区域的密度估计值也与MD轨迹中观测到的分布高度吻合 (图S3C-E, 支持信息)。具体而言, 与未经微调的版本相比, 基于IDRome数据进行微调的IDPFold模型在左上角的ppII区域概率上取得了显著提升, 其分布更接近MD轨迹。这表明, 微调使模型能够生成更多无序结构, 从而更精确地捕捉目标蛋白质的内在偏好性。

尽管键波动仅代表在模拟中快速收敛的局部特征, 但全局特征几乎无法在微秒量级内收敛。因此, 我们额外收集了Robustelli等人用于测试a99SB-disp力场的长时程轨迹, 以及其他用于对比的力场轨迹。^[20]我们分析了IDPFold与四种全原子分子动力学模拟在七种与我们的测试集重叠的蛋白质上的性能差异。我们主要关注Rg误差以及 C_{α} 和 C_{β} 次级化学位移

的RMSD (图4A; 图S3F-H, 支持信息)。

在化学位移精度方面, IDPFold预测的构象集合所对应的误差水平与a99SB-disp相当, 甚至优于a99SB-ILDN和CHARMM36m等传统力场。^[19,47]此外, 与所有四种力场相比, IDPFold在Rg误差方面表现出显著更优的性能, 这表明IDPFold能够准确捕捉IDPs的全局特征, 同时在局部结构预测方面达到了与当前最先进力场相当的精度水平。以 α -Synuclein蛋白为例, 我们对比了IDPFold采样的构象集合与基于a99SB-disp力场获得的70微秒分子动力学轨迹之间的差异。我们通过两种方法计算了 R_g - R_{e2e} 分布, 结果发现: a99SB-disp采样了更广泛的构象范围并捕获了更多伸展状态, 而IDPFold则主要采样了更紧凑的构象 (图4B)。在 C_{α} 化学位移方面, 我们观察到 α -Synuclein蛋白N端区域的螺旋倾向性被高估了 (图4C, D)。在drkN-SH3的第35-50位残基之间也观察到相当数量的 β -折叠片结构。这表明IDPFold可能更容易捕捉这些IDP的折叠状态而非其未折叠状态, 这很可能源于训练集中药物相似折叠结构的普遍性。还需注意的是,

表 1. IDPFold 及其他方法的基准测试结果。粗体显示最佳结果。

方法	有效性	ϵ_{Rg}	$RMSD_{\delta C_{\alpha}}$ (ppm)	$RMSD_{\delta C_{\beta}}$ (ppm)	$RMSD_{^3J(H_N, H_{\alpha})}$ (Hz)	$RMSD_{RDC_{NH}}$ (Hz)
Calvados 2 ^[48]	—	0.02	—	—	—	—
idpGAN ^[42]	0.91	− 0.12	—	—	—	—
idpSAM ^[49]	0.95	− 0.55	—	—	—	—
棕鸟 ^[50]	0.93	0.06	—	—	—	—
a99SB-disp ^[20] (7 套系统)	—	0.11	0.65	0.49	0.72	4.30
MD 3*1 μ s ESFF1+OPC3-B	—	− 0.19	0.81	0.64	0.96	3.37
bAles ^[51]	0.92	− 0.10	0.66	0.67	0.89	3.83
AF-聚类 ^[52]	0.99	− 0.12	0.74	1.30	1.81	3.84
AlphaFlow ^[53]	0.97	− 0.24	0.71	1.16	1.26	4.02
BioEmu ^[54]	0.97	− 0.18	0.88	1.28	1.05	5.21
IDPFold	0.95	− 0.06	0.65	0.53	1.01	3.27

AlphaFold 和 ESMFold 对 α -突触核蛋白预测的结构也呈现高度螺旋状，更类似于膜结合型突触核蛋白的结构。这表明所有这些模型在序列模型中都存在某种未能反映溶液状态的偏差。对于 C 和 HN 次级化学位移，IDPFold 的 RMSD 值略高于 a99SB-disp；而在 $^3J(H_N, H_{\alpha})$ 标量耦合中，IDPFold 的表现略优于 a99SB-disp。总体而言，我们得出结论：IDPFold 对 IDP 局部特征的表征能力与传统力场相当，且其对 α -突触核蛋白的采样耗时约 20 分钟，显著快于传统分子动力学模拟所需的数百小时。这充分展示了 IDPFold 作为传统力场采样方法的补充工具所具有的强大作用，有望在较长时间尺度上探索大分子体系开辟道路。

2.4. IDPFold 在性能上超越现有基于深度学习的方法

最后，我们在测试集上将 IDPFold 与现有的基于深度学习的方法进行比较，以实验观测结果作为主要参考基准，为集成预测方法建立一个基准（表1）。该基准包含三种粗粒度方法和四种在主干层或更高精度水平上具有竞争力的方法；其中，性能最佳的 AlphaFlow (AF-PDB-base) 被纳入其中（表S3，支持信息）。就 Rg 等全局特征而言，IDPFold 的表现略逊于粗粒度力场 calvados 2（图S4–S9，支持信息）。在某些情况下，IDPFold 生成的集成预测结果与实验测得的 Rg 存在显著偏差，这主要是由于对高度无序构象体比例的低估所致。calvados 2 模拟的构象处于完全无序状态；尽管其对 Rg 的估算较为准确，但未能采样到 IDP 的折叠或部分折叠状态。相比之下，IDPFold能够对这些结构进行采样，并在大多数主链级方法中取得了最佳的局部指标性能（图S10–S15，支持信息）。我们还评估了由各种深度学习方法（定义见“材料与方法”部分）生成的构象的有效性。结果表明，所有现有深度学习方

法生成的构象均具有较高的有效性。然而，我们观察到经微调后，IDPFold生成的构象集合的有效性略有下降；这可能是由于用于微调的轨迹数据相较于实验获得的结构存在更大的局部结构波动，从而导致生成的构象中出现更显著的局部波动（图S16，支持信息）。总体而言，在所有实验观测中，IDPFold预测的构象集合均优于现有深度学习方法，其性能与传统分子动力学（MD）模拟相当甚至更优。

3. 讨论

在本研究中，我们开发了 IDPFold——一款基于深度学习技术的用于生成 IDP 构象集合的工具。IDPFold 采用条件扩散模型架构实现端到端的蛋白质构象生成，其中整合了蛋白质语言模型用于序列特征提取，以及 DenoisingIPA 模块用于构象去噪。通过分别基于实验数据和 IDPs 的分子动力学（MD）轨迹进行两阶段训练策略，IDPFold 能够高效且准确地对 IDP 构象集合进行采样。此外，我们针对包含 IDRs 的 27 个蛋白质体系建立了一个构象采样方法的基准测试集。IDPFold 能精准捕捉 IDPs 的整体紧凑度及局部二级结构特征；与现有的基于 MD 或深度学习的方法相比，其预测的构象集合所呈现的特征值更接近实验观测结果。此外，IDPFold 可对蛋白质中的结构化与无序状态均进行构象采样，展现出广泛的采样范围及在集合采样方面的高效率。这一功能为研究 IDPs 的构象变化与功能提供了重要依据。

IDPFold 在估算 IDP 构象集合时所达到的准确度与传统分子动力学（MD）模拟相当甚至更高，其采样过程不受能量势垒的限制。这一特性不仅对研究 IDP 构象至关重要，对于诸如变构蛋白和酶等动态蛋白质——这些蛋白质在功能执行过程中会经历大规模构象变化——而言也具有巨大的应用前景。尽管本研究主要针对 IDPs 模型的训练展开，因此其对变

构蛋白集合的直接预测性能可能并非最优，但该方法学很可能可迁移至各类蛋白质体系，从而实现对这些功能关键性蛋白质中构象转变的更精确估算（图S17及视频S1，支持信息）。

尽管 IDPFold 在预测构象集合方面展现出强大的鲁棒性与精确度，但与部分现有深度学习方法相比，其推理时间相对较长——采样整个系统平均需约 20 分钟。虽然这一速度远快于传统的分子动力学（MD）模拟，但模型效率仍有提升空间。为实现更高的采样精度及更精确的蛋白质主链特征提取，我们采用了更复杂的网络架构和更长的扩散步长，但这可能会牺牲采样效率。为提升模型的推理效率，可探索相关优化方案，例如减少扩散模型中的扩散步长数量，或通过采用在时间和空间效率上更优的架构来优化 Transformer 组件。

[50]此外，本研究目前仅对单链蛋白质对 IDPFold 进行了训练与测试，尚未评估其在蛋白质复合物或多链组装体上的性能。因此，未来的研究将致力于将基于深度学习的结构生成方法扩展到这些更复杂的系统中，从而实现对动态分子间相互作用的高效采样与机制性阐释。[55]尽管 IDPFold 的平均 Rg 误差较低，但在某些系统中仍存在显著误差（图2A），这主要源于对折叠状态比例（例如 PaaA2 中的 α -螺旋及 drkN-SH3 中的 β -折叠片）的估算不准确。这与粗粒度（CG）模拟形成对比——后者能够准确估算 Rg，但往往无法对稳定折叠结构进行充分采样。这表明，在准确估算全局特征与对稳定局部结构进行采样之间存在一种关键的权衡关系。针对未来研究的一个潜在解决方案可采用混合建模方法：由 CG 模块负责全局动力学模拟，而全原子模块负责处理局部结构细节，从而实现对这两个方面的精准建模。

还需注意的是，在本研究中，我们主要采用一组有限的实验特征来评估预测的构象集合。这些实验表征结合其他计算方法所提供的见解，也为优化预测的构象集合具有重要潜力。近期多项研究证实，AlphaFold2预测的静态结构可作为进行 IDP 构象集合贝叶斯推断的重要参考依据。[56,57]同样，将如Rg等实验特征融入扩散模型中，已被证明有助于实现更精确的构象集合预测。[55]此外，CG参数已被证明能有效捕捉 IDRs 之间的动态相互作用。[58]IDPFold提供了一套端到端的流程，可仅基于蛋白质序列预测 IDP 构象集合。展望未来，通过整合更多实验特征并利用更先进的计算参考方法，可进一步挖掘这些预测构象集合之间的相关性并对其进行优化。

近期的研究进展凸显了基于序列信息预测复杂分子间相互作用的潜在价值。Garrett M. Ginell 等人提出了“Finches”框架，该框架利用 CG 力场中的化学势来直接估算由 IDR 介导的吸引与排斥相互作用，生成分子间相互作用图谱，并仅凭

序列信息预测同型相图。[58]与此同时，Soren von Bulow 等人将粗粒度分子动力学与主动学习相结合，训练出能够准确预测 IDR 相分离自由能及饱和浓度的机器学习模型；他们将该模型应用于约 27,000 个人类 IDR 区域，识别出其中约 5% 的区域易发生同型相分离。[59]这些研究展示了基于序列信息预测 IDR 相关分子间相互作用的高效方法。然而，这些方法对 CG 力场的依赖性，本质上将分析分辨率限制在非键合相互作用模式及平均场行为范围内。为全面揭示蛋白质-蛋白质相互作用中详细的原子级决定因素，关键在于扩展构象生成模型或将这些相互作用预测器整合到全原子分辨率的计算框架中。

构象集合预测是继静态结构预测之后，蛋白质结构研究领域的一个重要前沿方向。对蛋白质构象集合进行精确表征有助于我们理解蛋白质的动态行为，以及它们在与底物结合或在生理条件下发生生化反应时所经历的关键构象变化。尽管基于深度学习的工具尚未得到广泛应用，且大多数动力学分析仍依赖于分子动力学（MD）模拟，但我们的研究表明，利用深度学习预测的性质可能比MD模拟具有更高的准确性，因而可作为MD模拟的补充性乃至替代性研究手段。然而，当前基于深度学习的构象集合预测方法仍面临若干挑战，例如：构象自由能的估算不准确、相较于传统方法鲁棒性较低，以及无法捕捉构象之间的时序自相关性（即无法捕捉动态特征）。

多项研究表明，分子力场的单点能量估计法可用于训练扩散模型，从而使模型在结构数据匮乏的情况下能够更全面地学习构象空间信息。[60,61]这种利用力场能量而非结构数据进行训练的方法，能够更准确地捕捉构象空间分布并提升模型的鲁棒性。然而，该训练策略也使得模型对力场的经验参数较为敏感，因此对分子力场的精度要求较高。此外，还有一些基于流模型或评分匹配模型的研究，旨在拟合分子动力学（MD）轨迹的动态特性；这些方法或许可为当前生成式模型难以捕捉构象间时序自相关性的问题提供解决方案。[62]

除了稀疏的训练数据和有限的模型表征能力所带来的挑战外，构象集成预测任务还面临另一个重大问题：评估指标的稀缺性与不统一性。尽管我们为本研究收集了一组实验观测数据作为金标准，但大量蛋白质系统缺乏实验注释，这使得评估计算模型在这些系统上的生成性能变得颇具挑战性。因此，我们认为，构建一种类似于蛋白质结构预测中 pLDDT 的构象集成生成置信度量指标，对于蛋白质构象集成模型的评估与优化也具有重要意义。

4. 实验部分

数据集：用于训练 IDPFold 的数据集由三个部分组成：来自 PDB 数据集的高质量晶体结构；以及源自 IDPs 的 NMR 与分子动力学 (MD) 模拟数据集的结构——该数据集是通过粗粒化轨迹进行广泛的反向映射和能量最小化处理而获得的。

对于晶体结构，我们参考了 trRosetta 数据库，共收集了 15,051 个分辨率 ≤ 2.5 Å 且序列冗余度 $\leq 30\%$ 的 X 射线解析结构。^[63] 这些结构为模型提供了基础的蛋白质特征信息，例如键长、键角分布以及 C_α 基团的手性。然而，晶体结构通常反映的是蛋白质的稳定构象（即结构化构象）。若仅基于晶体结构对模型进行训练，将严重低估内在无序蛋白 (IDPs) 的无序倾向，从而导致单个蛋白质序列在构象生成方面多样性不足。因此，我们额外从 PDB 数据库中收集了 12,339 个核磁共振 (NMR) 解析的蛋白质构象集合。这些 NMR 记录根据其自身之间以及与晶体结构之间的 30% 序列相似性进行了筛选，最终得到 539 个系统，包含共计 10,454 个结构。通过将晶体结构与 NMR 构象集合相结合，我们为 IDPFold 训练的初始阶段获得了总计 25,495 个实验结构。这些结构定义清晰且具有较高的结构化倾向，从而确保该模型能够有效捕捉蛋白质的局部物理特征。

针对 IDP 轨迹数据，我们从 IDRome 中获取了大规模粗粒化模拟数据，该数据记录了人类蛋白质组中的绝大多数无序区域 (IDRs)。^[46] 这些粗粒化模拟能够准确捕捉 IDPs (及 IDRs) 的全局特征，例如构象集合的平均回转半径 (Rg)，但其仅保留了 C_α 原子，而这些原子的分辨率无法满足模型训练的要求。因此，我们筛选出所有残基数超过 256 个的体系，共计 3880 个体系。选择较大规模的体系主要基于以下原因：这些较长的无序片段涵盖了较小体系中发现的绝大多数序列与结构特征；在更大规模的体系上对模型进行训练有助于提升其泛化能力。对于这些体系，我们首先使用 pdbfixer 将其结构从粗粒化模型恢复为全原子模型，随后对所有蛋白质结构采用 ff14SB^[64] 力场进行 100 步能量最小化计算。在 IDPFold 训练的第二阶段中，共使用了 77,600 个经过优化的全原子构象；这些构象整体上呈现出更高的无序性，可助力模型学习天然 IDP 的独特构象特征。

此外，用于评估 IDPFold 生成结果性能的数据集包含 27 个通过实验完整表征且未包含在训练集中的 IDP 系统。针对这些系统，采用专为 IDP 设计的 ESFF1 力场及 OPC3-B 溶剂模型进行了时长为 1 μ s 的全原子分子动力学 (MD) 模拟。^[22,65] 这些全原子模拟轨迹描述了 IDPs 的动力学与热力学特性，适用于评估 IDPFold 生成的构象集合的质量。

IDPFold——基于蛋白质结构的扩散建模方法：为使 IDPFold 能够捕捉蛋白质构象在平衡状态下的玻尔兹曼分布，本研究采用了基于评分的生成建模 (SGM) 方法，从蛋白质结构数据中学习概率分布。SGM 可表示为一个扩散过程 $x_t \in \mathbb{R}^n$ ，该过程由随机微分方程 (SDE) 定义。^[66] 前向扩散过程的特征由以下方程描述：

$$dx = f(x, t) dt + g(t) dw \quad (1)$$

其中 $t \in [0, T]$ 为连续索引，而 $w \in \mathbb{R}^n$ 为标准维纳过程（亦称布朗运动）。 $f(x, t) \in \mathbb{R}^n$ 是一个称为漂移系数的向量值函数，而 $g(t) \in \mathbb{R}$ 是一个称为扩散系数的标量函数。随后，相应的逆向扩散过程（或去噪过程）亦可由 SDE^[67] 定义：

$$dx = [f(x, t) - g^2(t) \nabla_x \log p_t(x)] dt + g(t) dw \quad (2)$$

其中 dw 是一个标准维纳过程，对应于连续时间 t 从 T 到 0 的逆向流动，而 dt 为一个无穷小负时间步长。 $x_t|_{t=0}$ 在此代表真实数据（即蛋白质构象），而 $x_t|_{t=T}$ 则从高斯分布中采样。因此，通过求解该逆向 SDE 过程，可从高斯分布中采样出符合玻尔兹曼分布的多样化蛋白质构象。在公式 (2) 中，除 x 的得分项 $\nabla_x \log p_t(x)$ 外，其余各项均可求解。因此，仅需构建一个得分匹配网络，用于在每个时间步长上拟合 $\nabla_x \log p_t(x)$ ，从而实现生成构象的目的。

基于上述 SGM 的标准公式，还要求整个构象生成过程应满足 SE(3) 等变性——即扩散过程与网络变换对蛋白质结构的整体旋转和平移均不敏感。SE(3) 等变性可通过以下方程描述：

$$F \circ \rho(x) = \rho \circ F(x) \quad (3)$$

其中 F 表示诸如网络预测与扩散过程等数据变换， ρ 代表全局旋转与平移。通常，蛋白质构象 x 由笛卡尔坐标 $c_i \in \mathbb{R}^3$ ， $1 \leq i \leq N$ 表征，其中 N 表示原子数。然而，对笛卡尔坐标进行数据变换计算量巨大，且难以满足 SE(3) 等变性。因此，本研究采用主链坐标系参数化，将蛋白质构象 x 表示为 $Tj \triangleq [Rj, vj]$ ， $1 \leq j \leq n$ ，其中 n 表示残基数。每个主链坐标系包含一个 3×3 旋转矩阵 $Rj \in SO(3)$ 及一个平移向量 $v_j \in \mathbb{R}^3$ 。框架 Tj 可表示残基 j 中每个原子从局部坐标系 c_{local} 到全局坐标系 c_{global} 的欧几里得变换，即 $c_{global} = Tj \circ c_{local} \triangleq Rj c_{local} + v_j$ 。遵循 FrameDiff^[61] 中描述的方法，在扩散过程中，旋转矩阵 Rj_{on} （属于 $SO(3)$ 流形）与平移向量 v_j （定义在 $\mathbb{R}^3$ 中）被独立处理，其数学表达式如下：

$$d T_t = \left[0, -\frac{1}{2} \beta(t) P v_t \right] dt + \left[\sqrt{\frac{d}{dt} \sigma^2(t)} dw^{(SO(3))}, \sqrt{\beta(t)} P dw^{(\mathbb{R}^3)} \right] \quad (4)$$

其中， (t) 与 $\beta(t)$ 控制扩散过程中的噪声尺度， w^M 表示定义在流形 M 上的布朗运动，而 $P: \mathbb{R}^{3n} \rightarrow \mathbb{R}^{3n}$ 用于消除质心。在前向扩散或加噪过程中，对旋转矩阵施加噪声的操作由噪声核 $p_{H0}(R_t | R_0)$ 决定，该核函数源自 $SO(3)$ 流形上的各向同性高斯分布。该分布可表述为：

$$IG_{SO(3)}(R_t; R_0, \sigma^2) = f(\omega_{H0}) := \frac{1 - \cos(\omega_{H0})}{\pi} \sum_{l=0}^{\infty} f_l \gamma_l (2l+1) e^{-\frac{l(l+1)\sigma^2}{2} \frac{\sin((l+0.5)\omega_{H0})}{\sin(0.5\omega_{H0})}} \quad (5)$$

此处， $(z)_{H0} = \text{Axis_angle}(R_0^T R_t)$ 是复合旋转矩阵 $R_0^T R_t$ 的轴角变换表示法。对于平移向量，其噪声添加过程遵循奥恩斯坦-乌伦贝克过程（亦称 VP-SDE）；该平移向量的噪声核较为简单，最终收敛于 $N(0, I)$ ，如以下公式所示。

$$p_{H0}(v_t | v_0) = \mathcal{N} \left(v_t; v_0 e^{-\frac{1}{2} \int_0^t \beta(s) ds}, I - I e^{-\int_0^t \beta(s) ds} \right) \quad (6)$$

IDPFold 的构建——网络设计与训练：为实现从序列预测构象集合的目标，我们对——

设计了一个基于序列条件的评分匹配模型 $s_\theta(xt, x, seq)$ 用于去噪过程。由于该扩散过程被设计为严格满足 SE(3) 等变性，因此网络变换显然应保持这一特性。因此，采用了 AlphaFold2 中结构模块的一个变体（图 1A）来更新主链帧。^[33,43]在此，采用不变点注意力（IPA）机制来捕捉邻近残基之间的相互作用与关系，随后使用 Transformer 来学习全局特征及长程相互作用。已有研究表明，该架构有助于促进模型训练及高质量蛋白质构象的生成。上述网络设计要求每个层接收三个输入：一维向量表示 s_l 、成对特征表示 z_l 以及旋转与平移更新集 T_l 。采用 ESM2-650M 模型提取蛋白质序列特征，将其与残基位置编码及由三角函数表示的时间编码拼接，从而构建初始一维向量表示 s_0 。基于相对位置编码，从 s_0 中推导出成对特征表示 z_0 。在每一层 IPA-Transformer 变换后，该一维向量表示通过全连接网络进行更新，继而通过叉积运算更新成对特征。

分值匹配网络的目标与传统神经网络的训练目标有所不同：其目的并非直接拟合蛋白质构象，而是拟合经不同程度扰动后的数据所对应的分值，即拟合扰动数据的分布。为衡量预测分值与实际分布之间的拟合程度，采用以下方式计算 DSM 损失函数：

$$\mathcal{L}_{dsm} = \mathbb{E}_{t \in [0, T]} \left\{ \lambda(t) \mathbb{E}_{T_0} \mathbb{E}_{T_t | T_0} \left[\left\| s_\theta(T_t, t) - \nabla_{T_t} \log p_{t|0}(T_t | T_0) \right\|^2 \right] \right\} \quad (7)$$

为确保在所有时间步 t 下的 DSM 损失值均对应于 1 的完美拟合得分，从而保证每个时间步对损失函数的贡献相等，权重设置如下：

$$\lambda(t) = \frac{1}{\mathbb{E} \left[\nabla_{T_t} \log p_{t|0}(T_t | T_0) \right]} \quad (8)$$

此外，为确保模型能够学习蛋白质结构的详细特征，除对旋转矩阵和平移矩阵应用 DSM 损失函数外，还针对前向扩散步数较少的样本（ $t < \frac{T}{4}$ ），在主链原子位置及距离矩阵上的差异方面引入了均方误差（MSE）监督机制。^[4]因此，完整的网络训练损失函数可表示为：

$$\mathcal{L} = \mathcal{L}_{dsm} + (t)_1 \mathcal{L}_{bb} + (t)_2 \mathcal{L}_{dist} \quad (9)$$

其中 $(t)_1 = (t)_2 = 0.25$ 用于控制构象质量损失的权重。

在训练过程中，当最大时间步长 $T = 1.0$ 时，采用学习率为 10^{-4} 的 Adam 优化器对 Denoising IPA 进行优化。^[68]对于网络训练中的平移向量部分，我们在 VP-SDE 框架下采用线性噪声策略；而对于旋转矩阵部分，我们在 VE-SDE 框架下采用对数噪声策略，如以下公式^[66]所示：

$$\beta_{min} + \frac{t}{T} (\beta_{max} - \beta_{min}), \quad \beta_{min} = 0.1, \quad \beta_{max} = 20 \quad (10)$$

$$\alpha(t) = \log(\text{te}^{\sigma_{max} + (T-t)e^{\sigma_{min}}}), \quad \sigma_{min} = 0.1, \quad \sigma_{max} = 1.5 \quad (11)$$

IDPFold 的构建——实现细节：IDPFold 的训练包含两个阶段：针对实验结构进行预训练，以及针对分子动力学（MD）轨迹进行微调。在表 2 中列出了在这两个训练阶段中所使用的模型超参数。

评估指标与分析工具：对 IDPFold 预测的 IDP 构象集合的质量从两个维度进行了评估：生成结构的局部特征与构象集合的全局特征。针对局部特征，采用 Biotite 工具计算所有生成构象中的残基间键长与键

表 2：IDPFold 的超参数与训练细节。

超参数	训练阶段	
	训练已启动 实验数据	训练已启动 分子动力学轨迹
单代表通道		256
配对表示通道		128
隐藏通道		256
IPA 层级		4
Transformer 模块		2
变压器头		8
型号尺寸	17.8 M 参数	
学习率	10^{-4}	10^{-5}
批量大小	8	32
迭代次数	1.12 M	0.44 M
时间	≈9 GPU 天	≈15 GPU 天

角。^[69]同时，通过分析主链二面角的分布来评估模型对 C_α 手性及二等级结构的预测精度。此外，利用 mdtraj 计算 HN 与 $H\alpha$ 之间的标量耦合，采用 sparta+ 计算化学位移，随后进行集合平均处理。^[70,71]这些分析有助于判断蛋白质主链的局部环境是否与实验观测结果相符。

针对全局特征，计算了所生成构象的 Rg 值，并将该集合平均值与实验结果进行对比；此外，还计算了所生成构象与分子动力学（MD）模拟中所用初始结构之间的 RMSD 值，以构建 RgRMSD 空间。通过对所生成构象进行聚类并将它们投影到 Rg-RMSD 空间中，可分析这些构象的多样性，并评估该模型在从训练集中的 MD 轨迹中捕获玻尔兹曼分布信息方面的学习效能。采用 MMTSB 工具集进行聚类验证。

由于当前大多数基于序列生成蛋白质构象集合的研究均采用粗粒度表示法（仅生成 C_α 坐标），因此生成的结构首先使用 pdbfixer 进行固定，并执行了 100 步能量最小化计算。在最小化过程中，对 C_α 坐标施加了约束条件，以确保优化后的主链与原始主链差异不大。该过程每构象耗时约 6 秒。随后对结构的有效性与保真度进行了评估，并将 IDPFold 的性能与现有方法进行了比较。

有效性评估用于判断生成的构象是否包含不合理 C_α 距离。在蛋白质结构中，由于原子间存在范德华力相互作用， C_α 距离不应过近；此外，由于蛋白质主链中相邻的 C_α 原子通过具有特定键长的 $C-N$ 键连接， C_α 距离也不应相差过大。因此，借鉴 Str2Str 方法，将 C_α 距离的合理范围定义如下：

$$\delta_{vdw} < d_{C-C_\alpha} < \delta_{bond} \quad (12)$$

其中， $\delta_{vdw} = 2 \times 1.7 - 0.4$ 被定义为两个 C_α 范德华半径之和减去 0.4 的可接受重叠距离。^[72] δ_{bond} 被设定为在每个测试体系的分子动力学（MD）轨迹中观测到的最大 C_α 距离。由于定义了合理的范围，因此将有效性定义为有效构象所占的比例；较高的有效性意味着 C_α 距离被误估的概率较低，从而表明其性能更优。

保真度是指模型生成的集合与实验观测结果之间的吻合程度。 R_g 、 C_α 与 C_β 的二级化学位移、HN 与 $H\alpha$ 之间的 J 耦合常数以及主链 N-HN RDC 值被选作目标物理量，用于衡量模型的保真度，其计算——

使用以下公式计算模型生成的构象集合与实验观测结果之间的误差:

$$\epsilon_{Rg} = \frac{\langle Rg \rangle^{pred} - \langle Rg \rangle^{exp}}{\langle Rg \rangle^{exp}} \quad (13)$$

$$RMSD_{(A)} = \sqrt{E(A)^{pred} - (A)^{exp}^2} \quad (14)$$

其中 $\langle Rg \rangle$ 表示系综平均 Rg ; $\langle Rg \rangle^{pred}$ 为生成的系综平均 Rg , 而 $\langle Rg \rangle^{exp}$ 为实验观测值。类似地, $\langle A \rangle^{pred}$ 与 $\langle A \rangle^{exp}$ 分别表示系综平均物理量 (如化学位移和 J-耦合) 与实验观测值。基于上述定义, 我们计算了 ϵ_{Rg} 、 $RMSD_{\delta C_{\alpha}}$ 、 $RMSD_{\delta C_{\beta}}$ 、 $RMSD_{3J(HN, Ha)}$ 以及 $RMSD_{RDC_{NH}}$ 用于对当前构象生成方法进行基准测试, 目标是使所有指标的数值均趋近于零。 ϵ_{Rg} 反映了模型生成的构象在紧凑性方面的合理性, 而其他物理量上的 $RMSD$ 则反映了生成的构象与局部结构实验观测值的吻合程度。

为评估模型生成的构象集合, 除 AF-cluster 方法外, 其余所有方法均生成了 300 个构象用于后续评估。^[73,74] 此数量的构象此前已被证明能够充分反映与我们测试集中最大蛋白质尺寸相近的内在无序蛋白质的结构多样性。此外, 如图 S18 (支持信息) 所示, 对 IDPFold 生成的构象集合进行了收敛性测试。AF-cluster 方法生成的构象数量受 MSA 中聚类数量的影响, 本研究采用了默认的 MSA 及聚类设置。所有构象生成均在 NVIDIA A100 GPU 上完成。

统计学分析: 数据以均值 $\pm$ 标准差或分布形式呈现。各项分析的样本量(n)均预先确定并列于前文。所有统计学分析均使用 Python 3.9 及其 SciPy 与 NumPy 库完成; 分子动力学轨迹及生成的构象则通过 MDTraj 与 Biotite 软件进行加载与分析。采用双尾配对 t 检验对两组相关数据的均值进行比较。统计学显著性由特定的 p 值判定, $p < 0.05$ 被视为具有统计学意义; 上述 p 值均在正文及图注中予以报告。

支持性信息

补充材料可从 Wiley Online Library 或作者处获取。

致谢

J.Z. 与 Z.L. 对本研究贡献均等。本研究得到了上海市科学技术重大专项、SJTU Kunpeng & Ascend 卓越中心、UoL- SJTU 种子基金、上海交通大学 HPC 中心以及中国国家重点研发计划 (项目编号: 2025YFA0921000 和 2023YFF1205102)、中央高校基本科研业务费 (项目编号: YG2023LC03) 和中国国家自然科学基金 (项目编号: 32571435、32171242 和 T2222012) 的资助。

违背公众利益的行为

作者声明不存在利益冲突。

数据可用性声明

用于训练和评估 IDPFold 的原始数据可从 PDB (<http://www.rcsb.org/>) 以及 IDRome (KULLCentre/_2023_Tesei_IDRome) 数据库公开获取。处理后的数据可根据需求提供共享。

关键词

精确生成、动态构象系综、微调、IDPFold、固有无序蛋白质

收稿日期: 2025年6月24日

修订日期: 2025年9月24日

在线发表日期: 2025年10月13日

- [1] R. van der Lee, M. Buljan, B. Lang, R. J. Weatheritt, G. W. Daughdrill, A. K. Dunker, M. Fuxreiter, J. Gough, J. Gsponer, D. T. Jones, P. M. Kim, R. W. Kriwacki, C. J. Oldfield, R. V. Pappu, P. Tompa, V. N. Uversky, P. E. Wright, M. M. Babu, 《化学评论》2014, 第1卷第14期, 第6589页。
- [2] A. K. Dunker, C. J. Oldfield, J. Meng, P. Romero, J. Y. Yang, J. Chen, V. Vacic, Z. Obradovic, V. N. Uversky, *BMC Genomics* 2008, 9, S1.
- [3] A. S. Holehouse, B. B. Kragelund, 《自然·分子细胞生物学评论》2024, 25, 187.
- [4] A. K. Dunker, C. J. Brown, J. D. Lawson, L. M. Iakoucheva, Z. Obradovic, 《生物化学》2002, 第41卷, 第6573页。
- [5] V. N. Uversky, C. J. Oldfield, A. K. Dunker, 《生物物理年评》2008, 第37卷, 第215页。
- [6] L. M. Iakoucheva, C. J. Brown, J. D. Lawson, Z. Obradovic, A. K. Dunker, 《分子生物学杂志》2002, 323, 第573页。
- [7] R. Zhao, K. Gish, M. Murphy, Y. Yin, D. Notterman, W. H. Hoffman, E. Tom, D. H. Mack, A. J. Levine, 《基因发育》2000, 第14卷, 第981页。
- [8] A. B. Singleton, M. Farrer, J. Johnson, A. Singleton, S. Hague, J. Kachergus, M. Hulihan, T. Peuralinna, A. Dutra, R. Nussbaum, S. Lincoln, A. Crawley, M. Hanson, D. Maraganore, C. Adler, M. R. Cookson, M. Muentner, M. Baptista, D. Miller, J. Blancato, J. Hardy, K. Gwinn-Hardy, 《科学》2003年, 第302卷, 第841页。
- [9] F. Casu, B. M. Duggan, M. Hennig, 《生物物理学杂志》2013, 105, 第1004页。
- [10] A. Fernandez, H. A. Scheraga, 《美国国家科学院院刊》2003, 100, 第113页。
- [11] S. F. Banani, H. O. Lee, A. A. Hyman, M. K. Rosen, 《自然·分子细胞生物学评论》2017, 18, 第285页。
- [12] T. Mittag, R. V. Pappu, 《分子细胞》2022, 82, 2201.
- [13] M. Chruszcz, D. Borek, M. Domagalski, Z. Otwinowski, W. Minor, 《先进蛋白质化学与结构生物学》2009, 77, 第23页。
- [14] V. P. Dandey, W. C. Budell, H. Wei, D. Bobe, K. Maruthi, M. Kopylov, E. T. Eng, P. A. Kahn, J. E. Hinshaw, N. Kundu, C. M. Nimigeon, C. Fan, N. Sukomon, S. A. Darst, R. M. Saecker, J. Chen, B. Malone, C. S. Potter, B. Carragher, 《自然·方法》2020, 第17卷, 第897页。
- [15] A. McDermott, 《生物物理年评》2009, 第38卷, 第385页。
- [16] M. R. Jensen, M. Zweckstetter, J. Huang, M. Blackledge, 《化学评论》2014, 第1卷第14期, 第6632页。
- [17] S. Xu, A. Onoda, 《J. Chem. Inf. Model.》2023, 64, 2901.
- [18] Z. Dosztanyi, V. Csizmek, P. Tompa, I. Simon, 《分子生物学》2005, 347, 第827页。
- [19] J. Huang, S. Rauscher, G. Nawrocki, T. Ran, M. Feig, B. L. de Groot, H. Grubmuller, A. D. MacKerell, 《自然·方法》2017, 第14卷, 第71页。
- [20] P. Robustelli, S. Piana, D. E. Shaw, 《美国国家科学院院刊》2018, 115, E4758.
- [21] 张 Y、刘 H、杨 S、罗 R、陈 H-F., 《化学理论与计算》2019, 15, 6769.
- [22] D. Song, H. Liu, R. Luo, H-F. Chen, 《化学信息学与建模》2020, 60, 第2257页。
- [23] B. Zhong, G. Song, H-F. Chen, *Int. J. Mol. Sci.* 2022, 23, 11285.
- [24] J. Mu, Z. Pan, H-F. Chen, 《化学信息学与建模》2021, 第61卷, 第5141页。
- [25] S. von Bulow, I. Yasuda, F. Cao, T. K. Schulze, A. Ida Trolle, A. Symon Rau, R. Crehuet, K. Lindorff-Larsen, G. Tesei, *arxiv* 2025, arXiv:250410408.

- [26] J. A. Joseph, A. Reinhardt, A. Aguirre, P. Y. Chew, K. O. Russell, J. R. Espinosa, A. Garaizar, R. Collepardo-Guevara, 《自然·计算科学》**2021**, 第1卷, 第732页。
- [27] S. Kmiecik, D. Gront, M. Kolinski, L. Wieteska, A. E. Dawid, A. Kolinski, 《化学评论》**2016**, 第1卷第16页, 第7898页。
- [28] P. Bernado, E. Mylonas, M. V. Petoukhov, M. Blackledge, D. I. Svergun, 《美国化学会志》**2007**, 129, 第5656页。
- [29] V. Ozenne, F. Bauer, L. Salmon, J. R. Huang, M. R. Jensen, S. Segard, P. Bernado, C. Charavay, M. Blackledge, 《生物信息学》**2012**, 第28卷, 第1463页。
- [30] H. J. Feldman, C. W. V. Hogue, 《蛋白质》**2000**, 第39卷, 第112页。
- [31] J. C. Hoch 等, 《核酸研究》**2023**, 第51卷, D368。
- [32] M. C. Aspromonte 等, 《核酸研究》**2024**, 第52卷, D434。
- [33] J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Zidek, A. Potapenko, A. Bridgland, C. Meyer, S. A. A. Kohl, A. J. Ballard, A. Cowie, B. Romera-Paredes, S. Nikolov, R. Jain, J. Adler, T. Back, S. Petersen, D. Reiman, E. Clancy, M. Zielinski, M. Steinegger, M. Pacholska, T. Berghammer, S. Bodenstein, D. Silver, O. Vinyals 等, 《自然》**2021**, 第596卷, 第583页。
- [34] Z. Lin, H. Akin, R. Rao, B. Hie, Z. Zhu, W. Lu, N. Smetanin, R. Verkuil, O. Kabeli, Y. Shmueli, A. dos Santos Costa, M. Fazel-Zarandi, T. Sercu, S. Candido, A. Rives, 《科学》**2023**, 379, 第1123页。
- [35] J. L. Watson, D. Juergens, N. R. Bennett, B. L. Trippe, J. Yim, H. E. Eisenach, W. Ahern, A. J. Borst, R. J. Ragotte, L. F. Milles, B. I. M. Wicky, N. Hanikel, S. J. Pellock, A. Courbet, W. Sheffler, J. Wang, P. Venkatesh, I. Sappington, S. V. Torres, A. Lauko, V. De Bortoli, E. Mathieu, S. Ovchinnikov, R. Barzilay, T. S. Jaakkola, F. DiMaio, M. Baek, D. Baker, 《自然》**2023**, 620, 第1089页。
- [36] J. B. Ingraham, M. Baranov, Z. Costello, K. W. Barber, W. Wang, A. Ismail, V. Frappier, D. M. Lord, C. Ng-Thow-Hing, E. R. Van Vlack, S. Tie, V. Xue, S. C. Cowles, A. Leung, J. V. Rodrigues, C. L. MoralesPerez, A. M. Ayoub, R. Green, K. Puentes, F. Oplinger, N. V. Panwar, F. Obermeyer, A. R. Root, A. L. Beam, F. J. Poelwijk, G. Grigoryan, 《自然》**2023**, 623, 第1070页。
- [37] H. M. Berman, 《核酸研究》**2000**, 第28卷, 第235页。
- [38] T. Lazar, E. Martinez-Perez, F. Quaglia, A. Hatos, L. B. Chemes, J. A. Iserte, N. A. Mendez, N. A. Garrone, T. E. Saldano, J. Marchetti, A. J. V. Rueda, P. Bernado, M. Blackledge, T. N. Cordeiro, E. Fagerberg, J. D. Forman-Kay, M. S. Fornasari, T. J. Gibson, G.-N. W. Gomes, C. C. Gradinaru, T. Head-Gordon, M. R. Jensen, E. A. Lemke, S. Longhi, C. Marino-Buslje, G. Minervini, T. Mittag, A. M. Monzon, R. V. Pappu, G. Parisi 等, 《核酸研究》**2020**年, 第49卷, D404页。
- [39] D. Piovesan 等, 《核酸研究》**2025**, 第53卷, D495。
- [40] K. Majila, S. Viswanath, *bioRxiv* **2024**, 609111。
- [41] A. C. Riley, D. A. Ashlock, S. P. Graether, 《PLOS One》**2023**, 18, 0288388。
- [42] G. Janson, G. Valdes-Garcia, L. Heo, M. Feig, 《自然·通讯》**2023**, 14, 774。
- [43] J. Lu, B. Zhong, Z. Zhang, J. Tang, *arXiv* **2023**, arXiv:230603117。
- [44] C. Cragnell, D. Durand, B. Cabane, M. Skepo, 《蛋白质结构与功能生物信息学》**2016**, 第84卷, 第777页。
- [45] K. Moncoq, I. Broutin, C. T. Craescu, P. Vachette, A. Ducruix, D. Durand, 《生物物理杂志》**2004**, 87, 第4056页。
- [46] G. Tesei, A. I. Trolle, N. Jonsson, J. Betz, F. E. Knudsen, F. Pesce, K. E. Johansson, K. Lindorff-Larsen, 《自然》**2024**, 第626卷, 第897页。
- [47] K. Lindorff-Larsen, S. Piana, K. Palmo, P. Maragakis, J. L. Klepeis, R. O. Dror, D. E. Shaw, 《蛋白质》**2010**, 第78卷, 第1950页。
- [48] G. Tesei, K. Lindorff-Larsen, *Open Res. Eur.* **2023**, 2, 94。
- [49] G. Janson, M. Feig, *bioRxiv* **2024**, 579522。
- [50] B. Novak, J. M. Lotthammer, R. J. Emenecker, A. S. Holehouse, *bioRxiv* **2025**, 638373。
- [51] V. Schnapka, T. I. Morozova, S. Sen, M. Bonomi, *bioRxiv* **2025**, 660298。
- [52] H. K. Wayment-Steele, A. Ojoawo, R. Otten, J. M. Apitz, W. Pitsawong, M. Homberger, S. Ovchinnikov, L. Colwell, D. Kern, 《自然》**2024**, 第625卷, 第832页。
- [53] B. Jing, B. Berger, T. Jaakkola, *arXiv* **2024**, arXiv:240204845。
- [54] S. Lewis, T. Hempel, J. Jimenez-Luna, M. Gastegger, Yu Xie, A. Y. K. Foong, V. G. Satorras, O. Abdin, B. S. Veeling, I. Zaporozhets, Y. Chen, S. Yang, A. E. Foster, A. Schneuing, J. Nigam, F. Barbero, V. Stimper, A. Campbell, J. Yim, M. Lienen, Y. Shi, S. Zheng, H. Schulz, U. Munir, R. Sordillo, R. Tomioka, C. Clementi, F. Noe, 《科学》**2025**, 第389卷, adv9817。
- [55] O. Zhang, Z. H. Liu, J. D. Forman-Kay, T. Head-Gordon, *arXiv* **2025**, arXiv:250211326。
- [56] Z. F. Brotzakis, S. Zhang, M. H. Murtada, M. Vendruscolo, 《自然·通讯》**2025**, 第16卷, 第1632页。
- [57] V. Schnapka, T. I. Morozova, S. Sen, M. Bonomi, *bioRxiv* **2025**, 660298。
- [58] G. M. Ginell, R. J. Emenecker, J. M. Lotthammer, A. T. Keeley, S. P. Plassmeyer, N. Razo, E. T. Usher, J. F. Pelham, A. S. Holehouse, 《科学》**2025**, 第388页, adq8381。
- [59] S. von Bulow, G. Tesei, F. K. Zaidi, T. Mittag, K. Lindorff-Larsen, 《美国国家科学院院刊》**2025**, 122, 2417920122。
- [60] S. Zheng, J. He, C. Liu, Y. Shi, Z. Lu, W. Feng, F. Ju, J. Wang, J. Zhu, Y. Min, H. Zhang, S. Tang, H. Hao, P. Jin, C. Chen, F. Noe, H. Liu, T.-Y. Liu, *arxiv* **2023**, arXiv:230605445。
- [61] J. Yim, B. L. Trippe, V. De Bortoli, E. Mathieu, A. Doucet, R. Barzilay, T. Jaakkola, *arxiv* **2023**, arxiv:230202277。
- [62] F. Noe, S. Olsson, J. Kohler, H. Wu, 《科学》**2019**, 第365卷, aaw1147。
- [63] J. Yang, I. Anishchenko, H. Park, Z. Peng, S. Ovchinnikov, D. Baker, 《美国国家科学院院刊》**2020**, 第1卷第17页, 第1496页。
- [64] J. A. Maier, C. Martinez, K. Kasavajhala, L. Wickstrom, K. E. Hauser, C. Simmerling, 《J. Chem. Theory Comput. **2015**, 第1卷第1期, 第3696页。
- [65] 潘 Z、穆 J、陈 H.-F., 《化学理论与计算》**2023**, 第19卷, 第4837页。
- [66] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, B. Poole, *arxiv* **2021**, arxiv:201113456。
- [67] B. D. O. Anderson, 《随机过程及其应用》**1982**, 第12卷, 第313页。
- [68] D. P. Kingma, J. A. Ba, *arxiv* **2017**, arxiv:14126980。
- [69] P. Kunzmann, K. Hamacher, 《BMC Bioinformatics》**2018**, 19, 346。
- [70] R. T. McGibbon, K. A. Beauchamp, M. P. Harrigan, C. Klein, J. M. Swails, C. X. Hernandez, C. R. Schwantes, L. P. Wang, T. J. Lane, V. S. Pande, 《生物物理科学杂志》**2015**, 109, 第1528页。
- [71] Y. Shen, A. Bax, *J. Biomol. NMR* **2010**, 48, 13。
- [72] S. Ramachandran, P. Kota, F. Ding, N. V. Dokholyan, 《蛋白质》**2011**, 第79卷, 第261页。
- [73] G. W. Daughdrill, S. Kashtanov, A. Stancik, S. E. Hill, G. Helms, M. Muschol, V. Receveur-Brechot, F. M Ytreberg, 《分子与生物系统》**2012**, 第8卷, 第308页。
- [74] M. Schwalbe, V. Ozenne, S. Bibow, M. Jaremko, L. Jaremko, M. Gajda, M. R. Jensen, J. Biernat, S. Becker, E. Mandelkow, M. Zweckstetter, M. Blackledge, 《结构》**2014**年, 第22卷, 第238页。