自然计算科学

资源 https://doi.org/10.1038/s43588-026-01073-y

用于精确预测T细胞受体–pHLA结合的机器学习数据集与基准

收到日期：2025年8月3日

接受日期：2026年9月25日

Published online: 26 October 2026

检查更新

朱新源[1,5]，卢佳东[2,3,5]、吕易清[2]、张玉燕[4]及 冯富利[2]

免疫学和治疗设计中的一个核心挑战是准确预测T细胞受体与肽-人类白细胞抗原（pHLA）复合物之间的多样化相互作用。现有的机器学习工具受限于不完整的序列数据和存在偏倚的非结合样本。在此，我们提出Hi-TPH——一个大规模分层数据集，采用无果蝇筛选方法生成非结合数据。我们进一步开发了Hi-TPH-PLMs，这是一组具有不同架构和规模的蛋白质语言模型（PLMs）的集合，基于Hi-TPH进行微调。这些模型在外部湿实验室测试集上较最先进工具实现了19.2%的性能提升。利用Hi-TPH的分层结构，我们通过详细分析解析了不同分子组分对结合预测的贡献，并揭示了它们的协同作用；例如，HLA的预测贡献依赖于完整T细胞受体链的存在。Hi-TPH和Hi-TPH-PLMs已公开发布，旨在支持开发更可靠的工具，以推动高级免疫信息学研究和个性化免疫疗法的进展。

准确预测T细胞受体（TCR）与肽-人类白细胞抗原（pHLA）复合物之间结合的能力，是现代免疫学的基石，也是下一代治疗手段的关键推动因素[1–4]。然而，通过实验手段全面表征这些相互作用的庞大谱系是一项艰巨任务，其受到TCR、肽和HLA高度多样性以及高昂成本和长期周期的限制。因此，该领域日益广泛地采用计算方法，尤其是先进的机器学习模型[5–8]。这些计算机模拟工具能够实现快速且大规模的分析，这一能力对于加速癌症疫苗开发[9–12]以及预测免疫疗法疗效[13,14]至关重要。

尽管TCR–pHLA结合预测模型取得了快速进展，但其性能和实际效用从根本上受到两个以数据为中心的挑战的限制：不完整的序列数据和存在偏倚的非结合TCR–pHLA对[15,16]。现有数据集中的绝大多数主要聚焦于TCR的互补决定区3β（CDR3β）环[17–19]。忽略TCR–pHLA的其他组成部分会阻碍全面预测模型的开发以及对预测贡献的理解[20,21]，因为有力的生物学证据表明，CDR3 α环和完整的TCR可变链在决定结合特异性方面可能起决定性作用[20–22]。常见做法在整个训练过程中依赖固定的非结合数据，这可能会引入严重的偏倚，导致模型学习到的是负样本集的伪影，而非非结合的真实生物物理原理。

为应对这些挑战，我们推出了Hi-TPH——一个针对TCR–pHLA结合预测的大规模、精心筛选且具有层次化结构的数据集，该数据集专门聚焦于HLA class I（下文简称HLA）。Hi-TPH按分子组分从基础肽/CDR3β到更复杂的四个层级进行分层（图1）。

[1]中国科学技术大学信息科学与技术学院，中国合肥。[2]中国科学技术大学人工智能与数据科学学院，中国合肥。[3]中关村研究院，中国北京。[4]中国科学技术大学网络科学与技术学院，中国合肥。[5]这些作者贡献相同：Xinyuan Zhu、Jiadong Lu。

电子邮箱：fengfl@ustc.edu.cn

https://doi.org/10.1038/s43588-026-01073-y

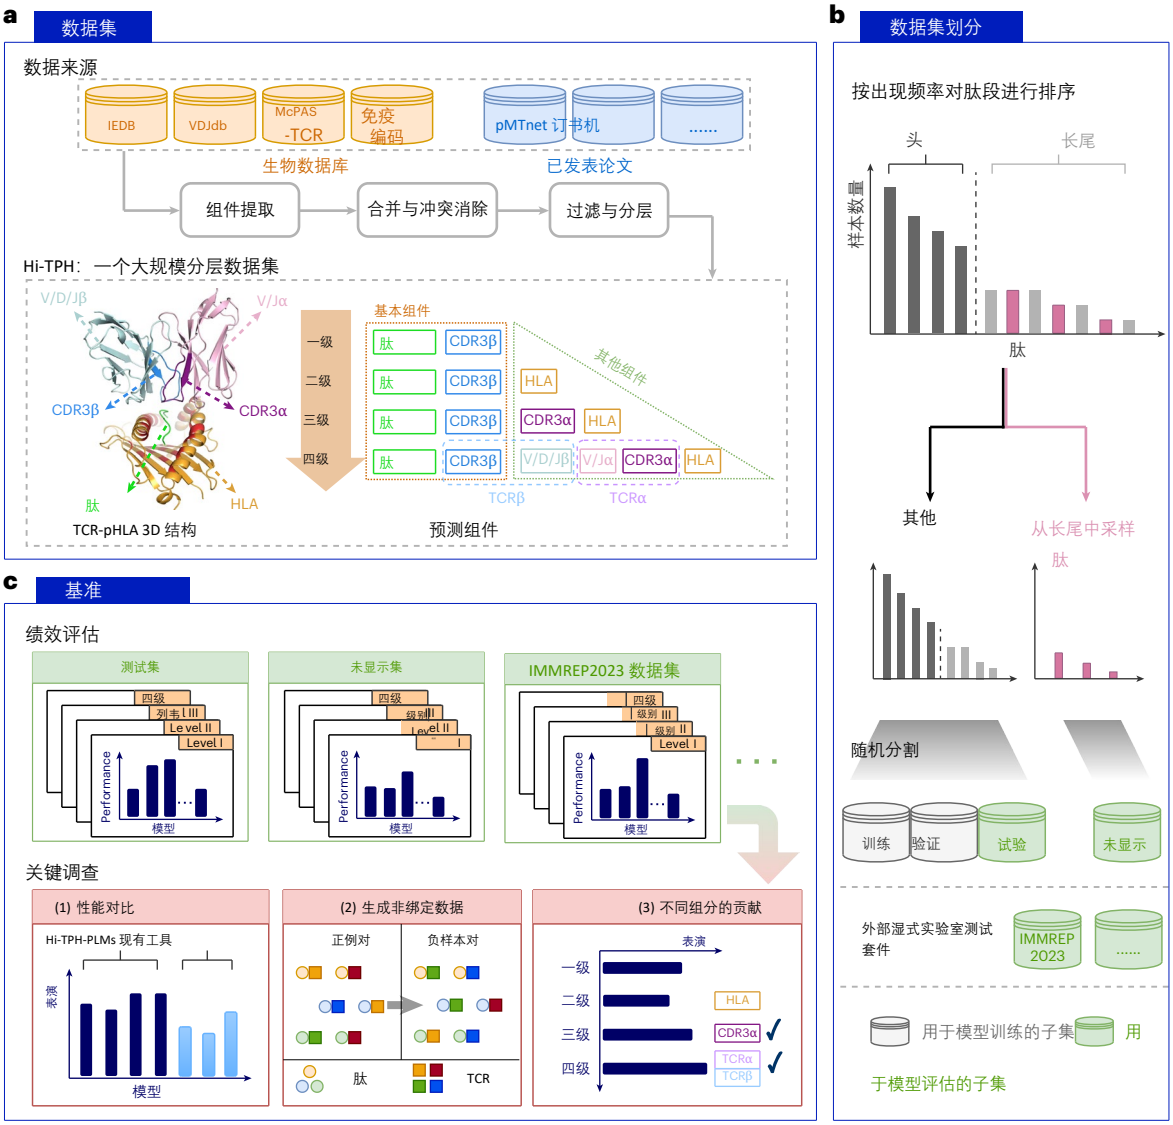


图 1 | Hi.TPH 数据集构建、结构与TCR–pHLA结合预测的基准策略。a，Hi-TPH数据集构建。通过组件提取、冲突消除和分层，从关键生物数据库（例如IEDBand和VDJdb）及已发表文献中筛选数据，构建Hi-TPH。该大规模数据集分为四个层级（I–IV），逐步纳入更多TCR–pHLA组件：层级I（肽段、CDR3β）、层级II（加入HLA）、层级III（肽段、CDR3β、CDR3α和HLA）以及层级IV（肽段、HLA、含V(D)J基因注释的完整TCR α/β链）。一个示意性三维结构展示了TCR–pHLA相互作用。**b**，数据集划分。肽段根据其结合的TCR呈现沿尾部的频率分布。数据被划分如下：从长尾部随机采样肽段构成未见集，其余肽段则随机分配至训练集、验证集和测试集。IMMREP2023作为外部测试集，其结合标签经过湿实验室验证。**c**，针对基准数据集的关键研究包括：(1) 在外部湿实验室验证的 IMMREP2023 数据集上，对现有工具与 Hi-TPH-PLMs（一组在 Hi-TPH 上微调的 PLMs）的性能进行比较；(2) 实时选择非结合数据的影响；以及 (3) 不同预测组件对模型性能的贡献。

从序列（I 级）到包含 HLA 数据和 V(D)J 基因注释的完整 TCR α/β 链（IV 级）。Hi-TPH 的每个层级都是同类资源中最为全面且规模最大的公开数据集。在功能最丰富的 IV 级层级中，Hi-TPH 相较于此前可用的资源实现了近六倍的扩展，并提供了完整的 TCR 链信息。此外，Hi-TPH 采用“非结合数据生成”的无标签选择策略，以消除模型训练过程中静态数据固有的偏差。

由于数据规模的扩大，我们进一步在Hi-TPH数据集上开发了Hi-TPH-PLMs，这是一系列具有不同架构和规模的蛋白质语言模型（PLMs）。这些模型在湿实验室验证的IMMREP2023数据集上与现有工具进行了相当程度的基准测试[23]，结果显示，在受试者操作特征曲线下面积（AUROC）方面，结合预测准确率提高了19.2%。一些广泛使用的工具在IMMREP2023上的表现接近随机水平，这是由于数据覆盖有限以及对未见过肽段的泛化能力较弱[18,23]。此外，当模型仅依赖肽段和CDR3β信息时，未见过肽段的性能下降最为明显。这些观察结果进一步强调了像Hi-TPH这样具有更广泛肽段覆盖和更完整分子组件的数据集的重要性。基准测试还证实了动态非结合数据生成优于传统的固定负样本集，这有助于减少数据集偏差并促进生物物理原理的学习。

除了开发最先进的（SOTA）模型外，Hi-TPH 独特的层次化架构以及各层级的扩展规模，还便于系统性地分析不同分子组分如何影响结合预测。

https://doi.org/10.1038/s43588-026-01073-y

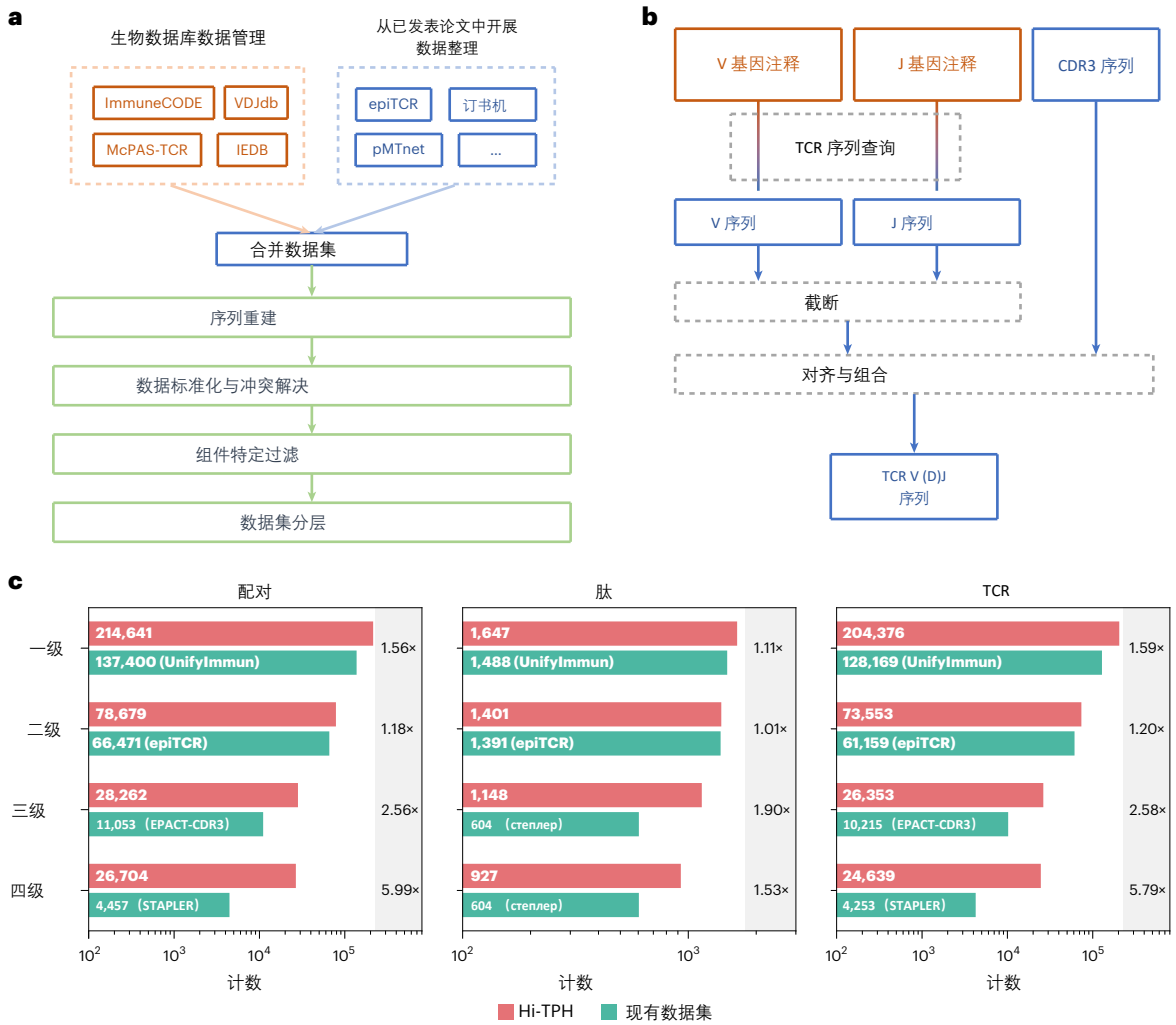


图 2 | Hi-TPH 数据集的数据收集流程及统计特征。a，阳性数据收集流程示意图。该流程始于从生物数据库（ImmuneCODE、VDJdb、McPAS-TCRandIEDB）及已发表研究（epiTCR、stapler、pMTnet 及即将推出的研究）中筛选 TCR–pHLA 结合实例。后续步骤包括序列重建、数据标准化、冲突解决、组件特异性过滤及数据集分层。**b**，V(D) 映射的详细步骤将 J 基因注释与其对应的完整 TCRV (D)J 区域序列进行关联。这包括对 VandJ 基因进行注释查询、提取 CDR3 序列，随后进行截断、比对和组合步骤，以重建完整的 V(D)J 序列。**c**，Hi-TPH 数据集规模的比较分析。图表将 Hi-TPH 中的 TCR–肽段对数量、独特肽段数量和独特 TCR 数量，与四个层级中规模最大的可比公共数据集进行了对比。计数以对数刻度表示。

我们的研究揭示了这些组分之间的协同相互作用。例如，引入TCR-CDR3α序列可直接提升性能，而HLA序列的贡献则具有情境依赖性。当仅与TCRCDR3环配对时，其预测价值可忽略不计甚至产生负面影响；但一旦将完整的TCR链纳入模型，其预测价值则显著转为正面。这些发现提供了关键见解，可指导未来模型的开发，并深化我们对TCR–pHLA识别机制的基础性理解。

本研究为学术界提供了一个以机器学习为导向的数据集Hi-TPH以及一个基准平台，旨在解决TCR–pHLA结合预测中持续存在的以数据为中心的挑战。通过微调PLMson Hi-TPH，我们建立了一种简洁而强大的方法，其泛化性能优于现有的 SOTA 工具。我们证明，这一成功得益于Hi-TPH的关键特性，包括其实时非结合数据生成能力以及更广泛的TCR和肽段覆盖范围。此外，Hi-TPH的层次结构为剖析单个分子组分的协同作用提供了框架。我们预计，Hi-TPH将成为免疫信息学领域的重要资源，加速开发更可靠且更具临床相关性的预测模型。

结果

Hi-TPH 数据集

为应对基础数据挑战，本研究引入了Hi-TPH——一个用于TCR–pHLA结合预测的大规模、主动维护且层次化结构的数据集（图1a）。Hi-TPH的构建是一个细致过程，包括从生物数据库中聚合结合数据（IEDB [24]、VDJdb [25]、McPAS-TCR [26]和ImmuneCODE [27]）以及对有影响力的已发表研究数据的整理[15,17]。随后进行了严格的组件提取、冲突解决和数据分层，从而形成了一个标准化且高质量的资源，这对机器学习模型的开发至关重要（图2a）。我们处理流程的一个关键成果是将V(D)J基因注释标准化映射到完整的 TCRV (D)J区域序列（图2b），从而为TCR–pHLA结合预测提供了更清晰、更全面的输入特征。

Hi-TPH 的首个重大贡献在于其规模之庞大，这大幅超越了现有公开可用的数据集。如详细所述

https://doi.org/10.1038/s43588-026-01073-y

表1 | TCR–pHLA结合预测数据集的比较性概述

数据集	样本数量			蛋白质序列						基因		HLA 类型	数据收藏品	年
	配对	肽	TCR	肽	CDR3β	HLA	CDR3α	TCRα	TCRβ	V/Jα	V/D/Jβ			
DLpTCR[19]	7,121	304	6,583	✓	✓							HLA I	策展	2021
PanPep[18]	32,080	699	29,467	✓	✓							HLA I	策展	2023
TEIM[36]	45,481	355	44,227	✓	✓							HLA I	策展	2023
Daisy [56]	70,491	127	64,166	✓	✓							HLA I	策展	2025
UnifyImmun[28]	137,400	1,488	128,169	✓	✓							HLA I	策展	2025
NetTCR-2.0[57]	11,431	17	11,425	✓	✓		✓*					HLA I	策展	2021
pMTnet[13]	32,070	602	28,864	✓	✓	✓						HLA I	策展	2021
epiTCR[17]	66,471	1,391	61,159	✓	✓	✓						HLA I	策展	2023
赛道[40]	32,508	607	29,687	✓	✓	✓						HLA I	策展	2024
Epact-CDR3 [58]	11,053	240	10,215	✓	✓	✓	✓					HLA I	策展	2024
日食[58]	9,936	179	9,265	✓	✓	✓	✓			✓	✓	HLA I	策展	2024
TCRAI[59]	8,130	16	8,101	✓	✓	✓	✓			✓*	✓*	HLA I/II	策展 + 实验	2021
ERGO-II[20]	27,260	389	26,548	✓	✓	✓	✓*			✓*	✓*	HLA I/II	策展	2021
订书机[15]	4,457	604	4,253	✓	✓	✓	✓	✓	✓	✓	✓	HLA I	策展	2023
高TPH水平 I	214,641	1,647	204,376	✓	✓							HLA I	策展	2025
高TPH水平 II	78,679	1,401	73,553	✓	✓	✓						HLA I	策展	
高TPH水平 III级	28,262	1,148	26,353	✓	✓	✓	✓					HLA I	策展	
高TPH水平 IV级	26,704	927	24,639	✓	✓	✓	✓	✓	✓	✓	✓	HLA I	策展	

本表汇总了与Hi-TPH数据集并列的公开可用数据集的特征，包括样本数量（配对、肽段和TCR）、蛋白质序列特征的存在情况（肽段、CDR3β、HLA、CDR3α、TCRα和TCRβ）、基因注释（V/Jα和V/D/Jβ）、HLA类型、数据收集方法及各资源的发表年份。统计仅考虑阳性（结合）TCR–pHLA配对。‘ç*’表示部分信息可用。TCR ŗ 和TCR Ř序列表示完整可变区（V、D和J片段），不包括恒定区。

在下面的比较分析中（表1和图2c），Hi-TPH在分子细节的每个层级都提供了大量数据。例如，包含基础肽和CDR3 Ř序列的Hi-TPH Level I包含超过210,000个结合对，比次大可比数据集[28]大50%。在其最具特征丰富性的层级，Hi-TPH Level IV数据集表示TCR–pHLA配对相互作用较任何先前可用数据集[15]扩展了5.99倍。Hi-TPH的规模扩大使得能够训练更大、更深的模型，例如针对TCR–pHLA结合预测调优PLM。

除了规模优势外，Hi-TPH还因其全面性而脱颖而出，其涵盖的TCR序列和肽库范围远广于现有数据集（图2c）。这种多样性在其各层级中均显而易见。例如，在第三层级，Hi-TPH提供的独特肽数量较次大可比数据集[15]扩展了1.9倍。同样，在其最具特征丰富性的第四层级，独特TCR数量扩展了5.8倍[15]，使得利用全长TCR序列的模型能够在更广泛的肽库上进行训练。这种扩展的覆盖范围使模型在训练过程中能够探索更多样化的分子空间，从而接触更广泛的TCR–pHLA结合模式。

我们数据集的另一个重要贡献在于其战略性且层次化的结构。该数据集被有意识地划分为四个层级，每个层级包含 progressively richer 的分子信息；这一设计为系统性地研究不同分子组分的相对贡献提供了可能。这种分层结构从包含基础肽段和 TCRCDR3 Ř 序列的 I 级开始，随后各层级逐步增加更多数据：II 级纳入 HLA 序列；III 级整合肽段、CDR3 Ř、CDR3 ŗ 和 HLA 序列；IV 级则提供最全面的特征集，包括完整的 TCR ŗ 链和 Ř 链、肽段、HLA 以及 V(D)J 基因注释（图1a）。这种层次化设计便于开展受控的计算机模拟实验，使我们能够系统性地分离出各分子组分的预测贡献。由于现有数据集具有碎片化且不一致的特性，此前难以实现这种程度的受控分析。

基于Hi-TPH-PLMs的更优TCR–pHLA结合预测

为了展示Hi-TPH作为构建先进TCR–pHLA结合预测模型基础的能力，我们开发了Hi-TPH-PLMs，这是一套基于其大规模、全面且层次化结构数据的微调PLMs（图3）。随后，我们在IMMREP2023数据集上[23]将Hi-TPH-PLMs与现有的 SOTA 工具进行了基准测试。作为外部且经过湿实验室验证的基准，IMMREP2023提供了跨数据集泛化的测试。为避免评估数据与我们的模型开发数据之间可能存在的重叠，在报告结果前，我们移除了所有在IMMREP2023和我们的Hi-TPH训练/验证划分之间识别出的重叠TCR–pHLA对，涵盖所有层级。

我们的研究结果明确证明了基于Hi-TPH训练的模型具有优越性。表现最佳的Hi-TPH- PLM 在AUROC方面实现了显著的19.2%相对提升，超过现有顶级工具在III级上的表现（表2和补充图1）。相比之下，许多成熟工具在这一困难任务中表现不佳，其中一些工具的AUROC 分数接近0.5，即随机概率水平。这一结果不仅突显了该领域普遍存在的泛化挑战，还展示了通过Hi-TPH数据训练所带来的性能提升。进一步分析表明，相同的PLM在Hi-TPH上的表现优于在先前数据集上训练的同类模型（补充表2），并且在Hi-TPH上重新训练成熟工具也能获得相对性能提升（补充表3）。此外，Hi-TPH-PLM在相似性过滤后的IMMREP2023子集上仍位居性能最佳模型之列（补充表11和12），并在Hi-TPH测试集上优于可重新训练的基线模型（补充表9）。这些结果验证了Hi-TPH对Hi-TPH-PLM性能优势的核心贡献。

https://doi.org/10.1038/s43588-026-01073-y

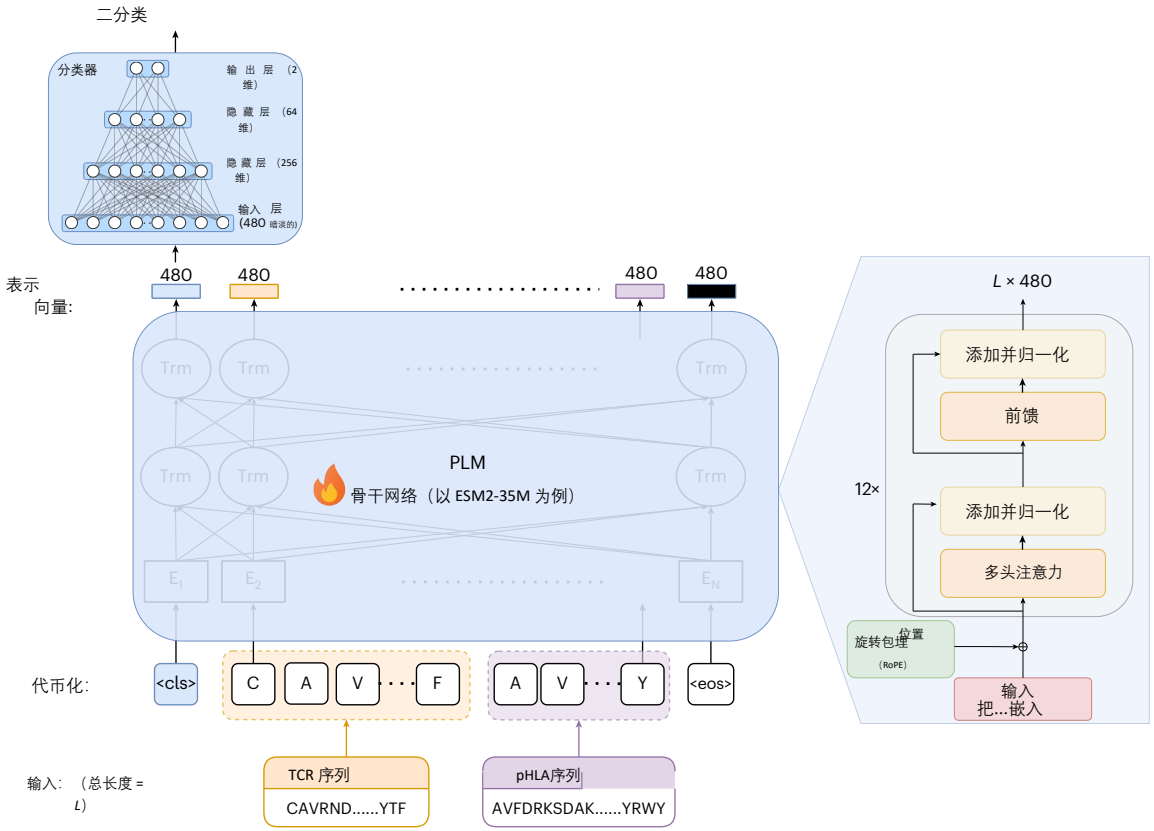


图3 | Hi-TPH-PLMs的架构。给定aTCR序列和pHLA序列（肽段与HLA拼接而成），我们将它们拼接成一个总长度为L的单一输入序列，在开头添加一个分类标记（<cls>），并在末尾添加一个序列结束标记（<eos>）。将所得序列输入到预训练的 PLM 中（以ESM2为例）。我们提取<cls>标记的上下文嵌入（d维表示，例如对于ESM2-35M，d= 480），并将其输入到多层感知器分类器中，以输出最终的结合预测。

为精准定位这种泛化能力挑战的成因，我们对 Hi-TPH-PLMs 进行了内部分析。分析结果显示存在一个关键性缺陷：对于仅依赖肽段和CDR3β序列的模型，其在未见肽段上的性能下降最为严重（图4a，b及补充表1）。这一发现直接验证了 Hi-TPH 的核心设计理念；它证实，采用基础预测组件这一普遍做法是导致泛化失败的关键因素，从而凸显了 Hi-TPH 方法的必要性：即提供更广泛的肽段覆盖范围，并整合构建稳健且具有临床相关性的预测模型所必需的综合性组件。

针对非绑定数据的即时选择方法的有效性

我们 Hi-TPH 数据集的一个核心特性，是采用了集成式实时选择方法，用于生成非结合数据。我们假设，这种动态方法会为每个训练批次生成新的负例，其性能将优于依赖固定非结合配对集合的传统方法。为验证这一假设，我们在多种实验条件下，将实时选择方法与两种常用的固定集合基线方法进行了基准对比（详见“用于非结合数据生成的实时选择方法”一节，位于“方法”部分）。

图4c，d展示了即时选择方法的优越性，无论模型规模、Hi-TPH数据级别或评估集如何，该方法始终优于随机基线和基于频率的固定集基线（补充表 5）。这种优势在 IMMREP2023 数据集上尤为明显，在 IV 级别即时选择非结合数据时，相对于最具竞争力的基线，相对AUROC 提升分别为 5.22%（ESM2-35M）和 4.80%（ESM2-150M）。

这种持续的优势凸显了 Hi-TPH 的实时非结合数据生成选择机制的强大能力。通过将模型暴露于更广泛且更具挑战性的非结合样本集合中，该方法有效缓解了模型对静态且可能存在偏倚的负向分布的过拟合问题[29]，促使模型学习出更具鲁棒性的决策边界。因此，实时非结合数据生成是 Hi-TPH 数据集的核心组成部分，直接推动了更优预测模型的开发。

组分对TCR–pHLA结合预测的贡献

除了通过其规模、全面性和即时非绑定数据生成能力实现 SOTA 模型的训练外，Hi-TPH的核心优势还在于其层次化设计，能够实现对组件贡献的受控分析。我们在Hi-TPH第四级上训练了Hi-TPH-PLM，以不同的预测组件作为输入，从而剖析TCR和HLA序列对模型性能的特定贡献。

在 IMMREP2023 数据集上，随着逐步纳入 CDR3α 和完整 TCR 序列，Hi-TPH-PLMs 的性能呈现持续提升（图4e及补充图 4a）。以 ESM 2-35M 为例，与仅使用肽段、HLA 和 CDR3β 作为模型输入相比，加入CDR3α 序列后，相对于 AUROCas 的相对增益达到 18.2%；将输入从CDR3α 和 CDR3β 扩展至完整 TCR 序列后，性能提升进一步增至33.9%。这些显著的提升表明，全面的 TCR 序列上下文能够捕捉到实现准确结合预测所必需的关键决定因素。

HLA序列的贡献具有上下文依赖性，并随TCR序列的完整性而变化。当以肽段和CDR3β作为模型输入时，引入HLA序列会导致性能下

https://doi.org/10.1038/s43588-026-01073-y

表2 | TCR–pHLA结合预测模型的性能评估，包括现有工具及基于我们Hi-TPH数据集训练的新模型

模型	一级		二级		三级		四级	
	AUROC	AUPRC	AUROC	AUPRC	AUROC	AUPRC	AUROC	AUPRC
PanPep[18]	0.5263	0.1635	–	–	–	–	–	–
TEIM[36]	0.5588	0.2586	–	–	–	–	–	–
UnifyImmun[28]	0.5072	0.1583	–	–	–	–	–	–
Daisy[56]	0.5194	0.1703	–	–	–	–	–	–
epiTCR[17]	0.5603	0.2435	0.5730	0.2442	–	–	–	–
$PISTE_{random}$[40]	–	–	0.5785	0.2025	–	–	–	–
$PISTE_{unipep}$[40]	–	–	0.5889	0.2850	–	–	–	–
ERGO-II[20]	–	–	–	–	0.5040	0.1718	0.5048	0.1720
订书机[15]	–	–	–	–	–	–	0.7391	0.5405
日食[58]	–	–	–	–	0.6011	0.3383	0.7500	0.5204
ESM2-8M	**0.6567**	0.3790	*0.5938*	0.3759	0.6770	0.3813	0.7404	0.5069
ESM2-35M	0.6290	0.3754	**0.5965**	0.3676	0.6740	0.4314	0.7574	*0.5493*
ESM2-150M	0.6372	0.3765	0.5867	0.3526	0.6828	0.4157	0.7399	0.4725
ESM2-650M	0.6235	0.3593	0.5748	0.3561	*0.7100*	0.4546	*0.7655*	0.5395
TAPE-BERT（38M）	0.6407	*0.3885*	0.5911	0.3740	0.6571	0.3935	0.7550	0.4839
Amplify-120M-base	0.6138	0.3708	0.5878	0.3531	0.6711	0.4181	0.7165	0.5262
AMPLIFY-120M	0.6365	0.3774	0.5820	0.3707	0.6943	0.4278	0.7551	0.5259
AMPLIFY-350M	0.6309	0.3611	0.5790	0.3783	0.6996	*0.4671*	0.7617	0.5038
ProtBERT (420M)	0.6236	0.3657	0.5877	*0.3856*	0.6829	0.4244	0.7531	0.5141
Hi-TPH-PLMs-Avg.	0.6324	0.3726	0.5866	0.3682	0.6832	0.4238	0.7494	0.5136
Hi-TPH-PLMs-Ens.	*0.6508*	**0.4072**	0.5918	**0.3925**	**0.7163**	**0.4745**	**0.7979**	**0.5800**

Hi-TPH-PLMs-Avg. 和 Hi-TPH-PLMs-Ens. 分别表示所有 Hi-TPH-PLMs 的平均性能及其集成模型的性能（参见“模型集成与指标平均”部分）。性能在四个 Hi-TPH 级别的外部 IMMREP2023 数据集上进行了评估。比较结果通过 AUROC 和 AUPRC 两种指标衡量。每列中的最高得分以粗体显示，第二高得分则以斜体显示。

降（图4f，左图，及补充图4b）。相反，在获得完整TCR序列时，加入HLA会持续提升性能（图4f，右图，及补充图4b）。这些结果表明，预测模型需要CDR1和CDR2区域的信息作为上下文，以解释HLA在TCR–pHLA结合中的作用。这也与已确立的TCR–pHLA识别的生物物理原理相一致，即CDR1和CDR2环与HLA螺旋发生相互作用[30]。

为进一步验证这些发现，我们针对 Hi-TPH 水平 II 和 III 开展了类似的消融研究；结果显示，CDR3α 与 HLA 对预测性能的影响呈相反趋势（补充表 6）。鉴于 PLMs 通过注意力权重识别相互作用，我们进一步进行了注意力图分析（补充图 5）；分析表明，注意力权重的分布呈现出组件感知模式，反映出相似的组件贡献度及协同相互作用。

讨论

在本研究中，我们推出了Hi-TPH——一个旨在解决TCR–pHLA结合预测中数据中心性挑战的大规模数据集。Hi-TPH相较于以往资源实现了约六倍的扩展，包含完整的TCR α/β链及V(D)J基因注释，从而在很大程度上缓解了不完整序列数据的影响。通过采用实时筛选方法，Hi-TPH缓解了非结合数据偏差问题。基于Hi-TPH训练的Hi-TPH-PLM在外部IMMREP2023数据集上展现出持续优势；该数据集是一个具有挑战性的基准测试集，许多成熟工具在此上的表现接近随机水平。Hi-TPH-PLM的性能优势还归因于通过实时筛选非结合数据来学习具有鲁棒性的决策边界，从而避免对数据集伪影的过拟合。这些结果凸显了从追求纯算法复杂度向利用高质量数据与基础PLM之间协同效应的关键转变。

借助Hi-TPH的层次化设计，我们的分析表明，预测组件的贡献是协同性的，而非简单的累加性。具体而言，虽然TCRCDR3α序列发挥着不可或缺的作用，但HLA序列的贡献高度依赖于上下文，仅当提供完整的TCR序列时才会显现。注意力图分析进一步验证，Hi-TPH-PLMs中的组件贡献与已建立的TCR–pHLA识别生物物理模型相一致。这些发现强调了对TCR–pHLA界面进行整体表征的必要性，以捕捉其各组件间的协同相互作用，这也进一步体现了大型PLM在此类结合预测任务中的潜力。

Hi-TPH 和 Hi-TPH-PLMs 为免疫信息学研究建立了基础平台，该平台提供了一套经过验证的工具集，可适应真实世界研究中不同数据完整度的需求，涵盖从基础肽段/CDR3β 序列到完整 TCR 序列的多种数据类型。该平台可集成到诸如 BioSeq-BLM [31,32]等多功能框架中，从而使其模型和数据能够应用于更广泛的任务。这种将高质量数据与先进模型相结合的方法重新定义了性能标准，并为构建可靠且具有临床实用价值的个性化免疫治疗预测工具提供了清晰路径。

未来，Hi-TPH 可通过加入定量结合亲和力数据进行优化，从而构建适用于治疗场景的模型；这类场景需要对手部相互作用强度的细致理解。此外，还可进一步改进该模型以纳入 HLA II 类分子，从而实现直接应用于 $CD4^+$的情况。

https://doi.org/10.1038/s43588-026-01073-y

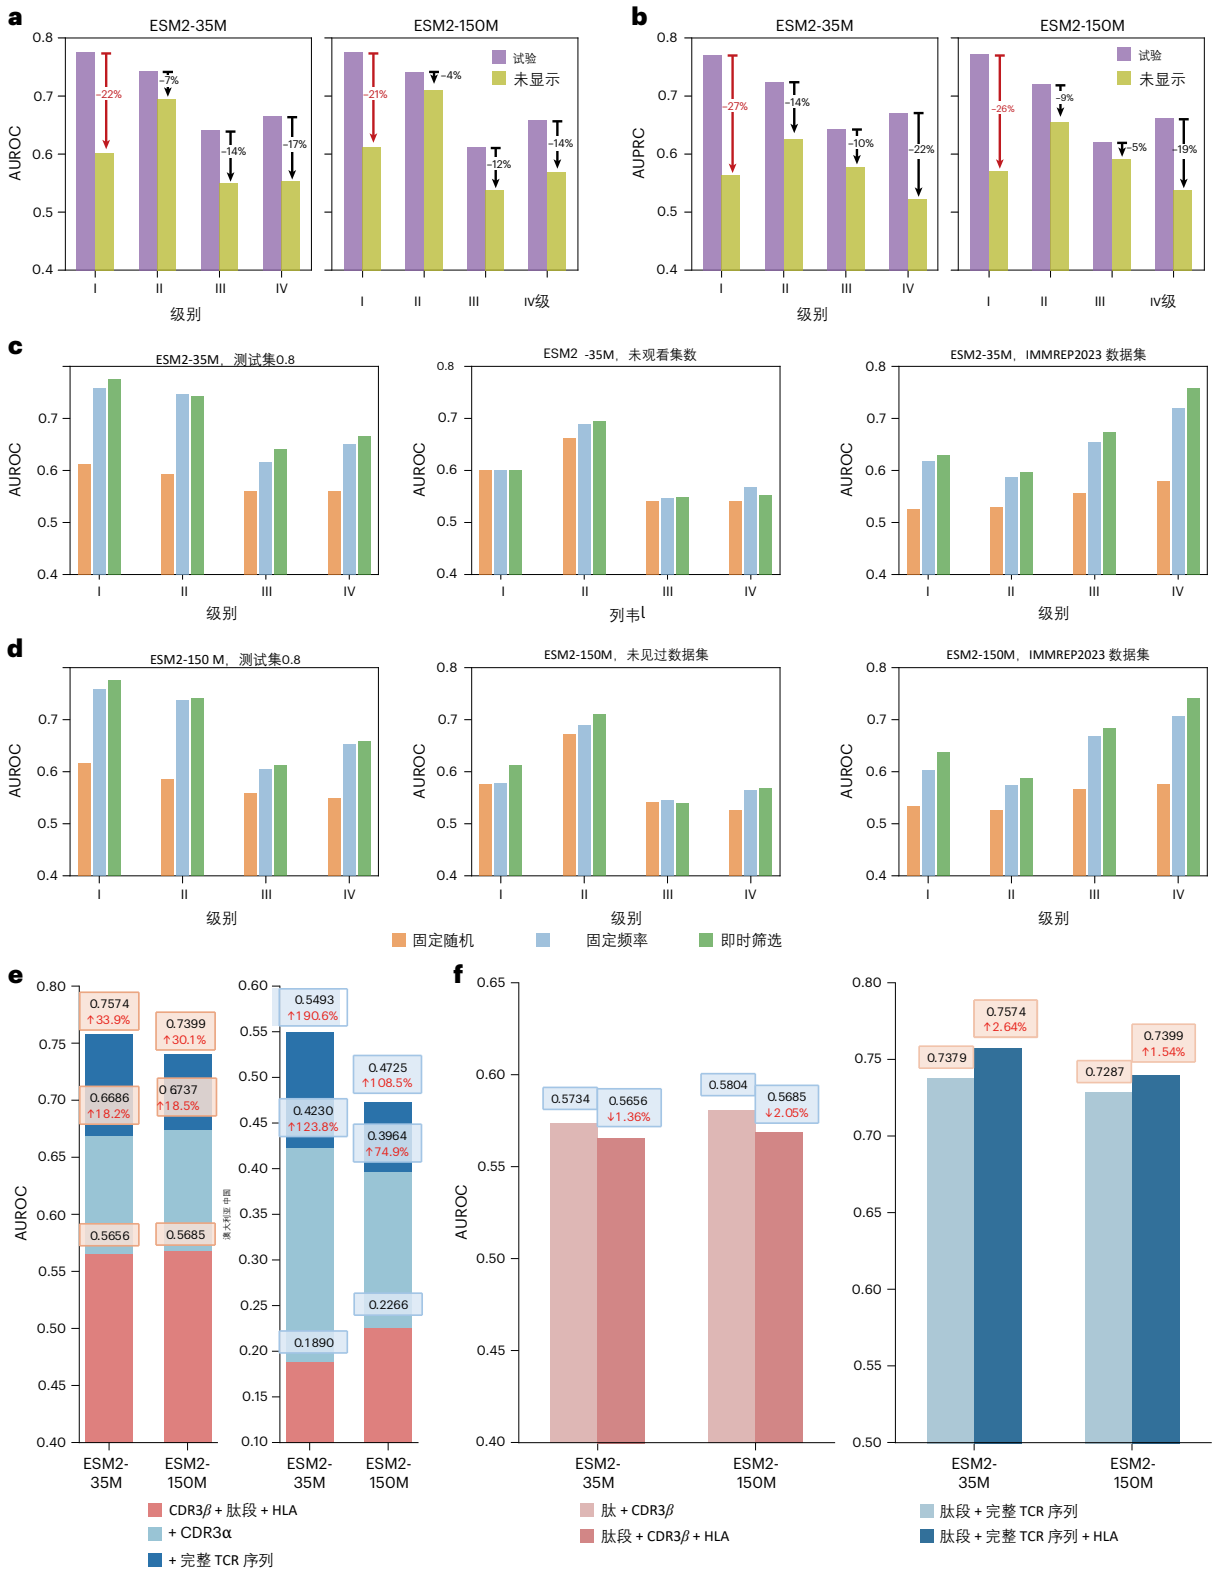


图4 | 使用Hi-TPHPLMs进行未见过肽泛化、非结合数据即时选择及组件贡献的基准测试结果。a，b，Hi-TPH-PLMs的肽泛化。展示了当在Hi-TPH级别I-IV上预测测试集与未见过集的结合能力时，ESM2-35M和ESM2-150M模型的AUROC（**a**）和AUPRC（**b**）分数。**c，d，**即时选择用于生成非结合数据的效能。在测试集、未见过集和IMMREP2023集上评估了ESM2-35M（**c**）和ESM2-150M（**d**）的AUROC分数。即时选择方法与固定随机和固定频率方法进行了基准比较。**e**，TCR组件对IMMREP2023集上模型性能的增量贡献。堆叠条形图显示了在CDR3α和完整TCR序列被添加到使用肽、HLA和CDR3β的模型时，ESM2-35M和ESM2-150M的AUROC提升。百分比表示每个额外组件带来的相对增益。**f**，通过比较在两种不同TCR输入序列（肽段 + CDR3β，左图；肽段 + 完整TCR序列，右图）下使用与不使用HLA序列的模型，分析HLA对IMMREP2023数据集上模型性能的上下文依赖性贡献。

T 细胞应答。Hi-TPH 会表现出源自原始数据源的偏差，例如序列长度和 HLA 等位基因分布不均，导致经 Hi-TPH 训练的模型更倾向于选择更常见的长度（9 聚体肽和 15 个残基的 CDR3；见补充图 9）或特定的 HLA 等位基因（见补充表 7 和补充图 10）。为实现更广泛的适用性，值得探索一些策略，以减轻这些偏差的影响。

此外，Hi-TPH-PLMs的性能仅当输入数据足够复杂时才会随模型规模而提升（补充图2和3），这有必要进一步研究如何将持续发展的PLM优势迁移至TCR–pHLA结合预测任务。Hi-TPH-PLMs还可作为高效的一级筛选模型，在计算密集型基于结构的排序[33]之前缩小庞大的候选空间。我们还在近期发布的IMMREP2025 [34]基准测试集上评估了现有工具及Hi-TPH-PLMs（补充表17）。IMMREP2025设计了更具挑战性的设置：对于每个阳性TCR–pHLA配对，通过将该TCR与同一HLA内的其他肽段配对生成阴性样本，且这些肽段刻意与已发表的表位保持距离。这些选择减少了基于序列模型可利用的肽段侧基序相似性，导致整体性能较低，且与IMMREP2023相比方法差异较小。与 IMMREP 2025 报告[34]的结论一致，其中表现最佳的方法采用了结构建模；因此，细粒度肽特异性预测若能与折叠模型及基于结构的重新评分相结合，可能会获得更大收益。利用 Hi-TPH 构建能够捕捉细微肽依赖性结合模式的定制化训练数据集，是进一步提升 Hi-TPH-PLMs 的另一个具有前景的方向[35]。

方法

Hi-TPH 数据集构建

结合数据收集。Hi-TPH数据集通过从两个独立来源收集阳性（结合）TCR–pHLA相互作用数据构建而成，并辅以序列重建流程以确保对现有结合证据的全面覆盖。对于来源1（生物数据库收集），主要数据从四个免疫学数据库汇总而来，包括免疫表位数据库[24]（IEDB；2024年4月访问）、VDJdb [25]（2023-06-01版本）、McPAS-TCR [26]（2022-09-10版本）和ImmuneCODE-Mira [27]（release-002.1版本）；其中IEDB数据仅限于在人类宿主中经T细胞检测呈阳性的线性肽，而ImmuneCODE-Mira条目经过去重处理，仅保留唯一的肽–TCR组合。对于来源2（已发表文献整合），从经过同行评审的出版物中提取了额外的TCR–pHLA结合对，这些数据整合了与已确立的计算工具相关的数据集，包括Pan-Pep [18]、pMTnet [13]、 TEIM [36]、epiTCR [17]和stapler [15]。为了进行序列重建，全面扩展数据集覆盖范围，使其超越已收集的氨基酸序列，我们通过areconstruction流程处理V(D)J基因注释，以生成完整的TCR可变区序列。如图2b所示，该流程采用基于标准化基因定义的组装方法。首先，将VandJ基因注释与 IMGT /Gene-DB数据库[37]进行交叉引用，以获取相应的胚系氨基酸序列。随后提取实验确定的CDR3序列，作为高变区连接点。通过在保守的重组信号基序处精确截断胚系VandJ序列，并将其与CDR3区域拼接，我们重建了TCR α链和β链的完整可变区。与现有的Stitchr [38]等用于完整重建的工具相比，我们的流程省略了对于预测模型区分结合对与非结合对而言无意义的恒定区。此外，我们的流程通过直接查询最新的参考数据库，保持了较高的保真度，从而避免了潜在的序列错配（补充图 6）。

数据治理与层级结构。在完成结合数据收集后，所有记录均经过多步骤数据治理流程，以确保其质量、一致性以及适用于机器学习应用。首先，我们进行了数据标准化和冲突解决；将来自不同来源的记录映射到统一的模式中。随后，我们应用了一系列针对特定组件的过滤器，将数据集聚焦于最常见且特征最明确的相互作用类型，同时剔除可能干扰模型训练的潜在异常值。

- HLA 类型：仅保留与 HLA class I 分子相关的记录。
- 肽段长度：我们将数据集限定为长度为 8–15 个氨基酸的肽段，以与天然呈递肽段的典型长度分布相一致。
- CDR3 长度：同样地，将 CDR3 序列过滤至 9–19 个氨基酸的长度范围，这与在人类 TCR 库中观察到的主要长度分布相一致。
- 完整的 TCR 链长度：对于重建后的序列，我们设置了 105–121（TCR α）和 109–121（TCR β）个氨基酸的长度约束，以消除潜在的重建伪影或异常值。

这一严格的筛选流程最终生成了一个干净且高质量的结合相互作用主数据集。基于这一统一资源，我们定义了四个层级，以便对各组成部分的贡献进行系统性剖析（图1a）。每个层级代表一组逐步更加丰富的分子信息：

- I 级：代表最简的组分组合，仅由肽段和 TCRCDR3β 组成。
- 二级：在一级基础上进一步扩展，纳入 HLA 序列。
- 第三级：包含该肽段、HLA 以及 TCR CDR3α 和 CDR3β 序列。
- 第四级：最全面的层级，涵盖肽段、HLA 以及完整的 TCR α 和 β 可变区序列。

这种层级结构是 Hi-TPH 的核心特征，使 Hi-TPH 划分为四个子集，分别称为 Hi-TPH 第 I–IV 级；这些子集的预测组件数量逐级增加，规模则逐级减小。

用于非绑定数据生成的即时选择方法。

现有的TCR–pHLA结合预测工具通常依赖于在所有训练周期中反复使用的静态阴性数据集[5]，这可能会引入系统性偏差，且无法充分表征广阔的非结合相互作用空间。固定随机法和固定频率法是训练前生成不可变非结合配对集合的常用方法。固定随机法通过独特肽段与TCR的组合配对构建该集合，同时排除已知的阳性配对[7,18,36,39,40]。固定频率法则通过按肽段在阳性数据集中的频率进行采样，并将其与随机选择的TCR配对来生成非结合数据，同时严格排除已知的阳性配对。这确保了阴性集合中的肽段分布与阳性类别相匹配[40,41]。

在线选择方法会在训练过程中根据每个训练步骤中的阳性TCR–pHLA对动态生成阴性样本。对于每个阳性TCR–pHLA对中的肽段，通过将该肽段与从训练集中随机选取的TCR配对来生成一个阴性实例。需要注意的是，任何与训练集中已知结合对匹配的生成配对都会被丢弃（补充算法1）。这种动态方法确保了不同训练周期间的多样性，并保留了在阳性数据集中观察到的肽段频率分布[29]。不同训练周期间的多样性将扩大肽段和TCR的覆盖范围，这对于预测模型的学习至关重要（补充表4）。

实验设置基准测试

任务定义。TCR–pHLA结合预测任务被构建为一个二分类问题，用于预测给定的TCR是否与特定的pHLA复合物结合。Hi-TPH不仅提供阳性结合对，还采用了一种非果蝇来源的非结合数据生成选择方法，以创建平衡的训练集和评估集。

数据集划分。数据集划分策略旨在评估模型在不同泛化场景下的性能。首先根据肽段出现频率对其进行排序，从而构建从高频头部肽段到低频长尾肽段的分布。在本研究中，结合样本数少于 50 个的肽段被视为长尾肽段。为评估对新型肽段的泛化能力，我们从长尾肽段池中随机选取 100 个肽段，通过剔除与这些肽段相关的所有样本构建一个未见样本集，确保该肽段与其余任何分区均无重叠。随后，将剩余数据按 8:1:1 的比例随机划分为训练集、验证集和内部测试集，以进行标准留出式评估。该划分策略可形成三种评估设置：用于评估整体性能的内部测试集、用于评估对未见肽段泛化能力的未见样本集，以及用于外部验证的 IMMREP2023 数据集[23]。

为 IMMREP2023 的外部评估而进行的重叠项剔除。为了为减少外部IMMREP2023基准与模型开发所用数据之间的潜在重叠，我们在每个层级（层级I–IV）明确筛选了IMMREP2023与Hi-TPH训练集和验证集之间重叠的TCR–pHLA对。由于不同Hi-TPH层级采用不同的配对表示方式，因此对每个层级分别进行重叠筛选，所得重叠统计量汇总于补充表13中。在模型训练和评估前，已识别出的任何重叠配对均被移除。所有基于IMMREP2023的报告结果均在此重叠移除步骤后获得。通过比较IMMREP2023在过滤数据集上重新训练前后的性能，进一步量化了该过滤措施的影响（补充表14）。此外，如补充图8所示，IMMREP2023包含高比例的在Hi-TPH训练集中未出现的肽段和TCR，这使其成为评估真实世界泛化能力的挑战性基准。

评估指标。模型性能通过两个主要指标进行评估：AUROC 和精确率-召回率曲线下面积（AUPRC）。 AUROC 通过绘制所有分类阈值下的真阳性率与假阳性率的关系图，衡量模型区分正类和负类的能力。AUPRC 则通过在不同阈值下绘制精确率与召回率的关系图来评估性能，从而揭示模型在数据不平衡情况下的表现。对于内部测试集和未见过数据集，我们报告了五次独立运行中的平均指标，每次运行使用不同的随机采样负样本，以维持严格的 1:1 比例。IMMREP2023 数据集则直接在其固有的类别分布不平衡的情况下进行评估，未进行额外采样。

输入表示与模型实现

输入表示。为了为 Hi-TPH-PLMs 准备序列数据，我们开发了一套标准化的输入流程。对于在给定 Hi-TPH 级别上训练的每个模型，其输入是通过将相应的预测组件拼接成一个单一序列而构建的。为了满足 Transformer 架构对固定长度输入的要求，所有序列首先通过填充一个指定的特殊字符(X)来归一化为统一长度。与像 TCR- ESM [42]那样将每个组件单独通过 PLM 后再拼接表示相比，序列级拼接能够更有效地利用 PLMs 的能力（见补充表 8 和补充图 7）。

模型实现。Hi-TPH-PLMs 包含一个预训练的 PLM，作为特征提取器（“骨干”），以及一个多层分类器（“头部”），两者在训练阶段共同优化（图 3）。

- PLM 主干模型：我们选择了一系列多样化的 PLM 作为主干模型，以系统评估模型规模、架构和预训练数据对预测性能的影响。我们的选择涵盖了蛋白质变换器的演进历程，从早期的模型如 TAPE-BERT [43]和 ProtBERT [44]，到被广泛采用的 ESM2 家族[45]，包括参数规模从 8M 到 650M 的变体，以评估模型缩放的影响（补充图 2 和 3）。为了与最新进展进行基准比较，我们纳入了来自 amplify 家族[46]的 amplify-120M-base、amplify-120M 和 amplify-350M。这些模型整合了现代架构改进，例如 SwiGLU [47]、RMSNorm [48]和 FlashAttention [49]，并在包含 UniRef100 [50]、OAS [51]和 SCOP [52]在内的庞大蛋白质序列语料库上进行了预训练。
- 分类头：为了使这些强大的特征提取器适应我们的特定二元分类任务，分类头被附加到每个 PLM 的最终隐藏状态上。该投影头由两个全连接隐藏层组成，采用整流线性单元（ReLU）激活函数，这些隐藏层处理已学习的蛋白质表示，从而生成最终的结合预测。

模型集成与指标平均。对于每个 Hi-TPH 级别，Hi-TPH-PLMs-Ens. 是通过以相等的权重对表2（ESM2-8M/35M/150M/650M、TAPE-BERT、amplify-120M-base/120M/350M 和 ProtBERT）中报告的所有单个 Hi-TPH-PLMs 的预测分数取平均值而构建的。形式上，对于处于ℓ层级的输入对 x，集成预测$f_{\mathrm{E}}^{(\ell_{\mathrm{ns}})}(\mathrm{x})$ 定义为

$$f_{\mathrm{Ens}}^{(\ell)}(x) = \frac{1}{M_\ell} \sum_{m=1}^{M_\ell} f_m^{(\ell)}(x),$$

其中$\mathrm{f}_m^{(\ell)}(\mathrm{x})$表示在$\ell$层级下，第$m$个 Hi-TPH- PLM 预测的结合分数；$M_\ell$ 表示在该层级下所包含的独立模型数量。对于 IMMREP2023 的集成，未进行任何模型选择、权重分配或超参数调优。此外，我们还将这一完整集成与 IMMREP2023 及预留的 Hi-TPH 测试集上的不同集成策略进行了比较（补充表 15 和 16）。

Hi-TPH-PLMs-Avg. 是一种指标级别的参考摘要，而非额外的预测模型或模型集成。对于每个评估指标（例如，AUROCor AUPRC），其计算方式为

$$s_{\mathrm{Avg}}^{(\ell)} = \frac{1}{M_\ell} \sum_{m=1}^{M_\ell} s_m^{(\ell)},$$

其中$\mathrm{s}_m^{(\ell)}$ 表示第m 个 Hi-TPH-PLMat 层级ℓ的性能指标。

模型训练流程

所有 Hi-TPH-PLM 均使用 Adam 优化器[53]和交叉熵损失函数进行了微调。训练在 PyTorch [54]中实现，并分布在四个 NVIDIA RTX 3090 图形处理单元上，以确保可行的训练时间。为了防止过拟合并选择最佳模型检查点进行评估，我们采用了早期停止协议。每个训练周期结束后，使用 AUROCas 作为主要指标在验证集上评估模型性能。如果验证 AUROC 连续四个周期未能改善（耐心值为 4），则终止训练过程。保

存与验证 AUROC 最高的周期相对应的模型检查点，并将其用于后续所有测试集上的评估。对于大多数模型，批次大小设置为每个图形处理单元 32。为了适应更大骨干网络的内存需求，对于 ESM2-150M、amplify-350M 和 ProtBERT，批次大小减少至 8；对于 ESM2-650M 在 IV 级别，进一步减少至 2。批次大小的减少对这些模型的性能影响可以忽略不计（补充表 10）。学习率根据验证集上的 AUROC 从 {1e_4,8 e_5,5e_5,3e_5,1e_5} 中选取。

报告摘要

有关研究设计的更多信息，请参阅与本文链接的 Nature Portfolio 报告摘要。

数据可用性

Hi-TPH 数据集可通过 GitHub 在 https://github.com/Jiadong001/Hi-TpH 以及通过 Zenodo 在 https://doi.org/10.5281/zenodo.22647655 公开获取（参考文献55），采用知识共享署名-非商业性使用4.0国际许可协议（CC BY-NC 4.0）授权。源数据随本文一同提供。

代码可用性

使用Hi-TPH的代码及基准数据可通过GitHub获取，地址为https://github.com/Jiadong001/Hi-TpH，也可通过Zenodo获取。https://doi.org/10.5281/zenodo.22647655（参考文献55）。

参考文献

1. Davis，M. M. 与 Bjorkman，P. J. T 细胞抗原受体基因与 T 细胞识别。*Nature* **334**，395–402（1988 年）。
2. Glanville, J.等.识别 T 细胞受体库中的特异性组.*Nature* **547**, 94–98(2017 年).
3. Schumacher，T. N. M. 与 Schreiber，R. D.。癌症免疫治疗中的新抗原。*Science* **348**，69–74（2015年）。
4. Ott, P. A.等.一种用于黑色素瘤患者的免疫原性个体新抗原疫苗. *Nature* **547**,217–221(2017年).
5. Wang，M.、Kurgan，L. 和 Li，M. 对 HLA I 类肽结合预测工具的全面评估与比较。*Brief. Bioinform.***24**，bbad150（2023 年）。
6. Meysman, P.等.针对 T 细胞受体表位预测问题的解决方案基准评估: IMMREP22 研讨会报告.*ImmunoInformatics* **9**,100024(2023 年).
7. Chen, J.et al. TEPCAM :通过可解释性深度学习预测 T 细胞受体–表位结合特异性.*Protein Sci.***33**,e4841(2023 年).
8. Zhou, Z.et al. GRATCR :利用数据高效预训练模型生成表位特异性 T 细胞受体序列.*IEEE J. Biomed. Health Inform.***29**,2271–2283(2025 年).
9. Foy, S. P.等.用于个体化细胞治疗的非病毒精准 T 细胞受体替换. *Nature* **615**,687–696(2022 年).
10. Hu，Z.，Ott，P. A. 与 Wu，C. J. 迈向个性化、肿瘤特异性癌症治疗性疫苗。*Nat. Rev. Immunol.***18**，168–182（2017 年）。
11. Chu, Y.等.一种基于变压器的模型,用于预测肽–HLA I类结合并优化用于疫苗设计的突变肽.*Nat. Mach. Intell.***4**,300–311(2022年).
12. Zhu, X.等.用于零样本肽-HLA 结合预测及自动抗原肽设计的分层渐进式学习.*Cell Rep.***44**,115763(2025 年).
13. Lu, T.等.基于深度学习的 T 细胞受体–抗原结合特异性预测.*Nat. Mach. Intell.***3**,864–875(2021 年).
14. Sidhom, J.-W.等.深度学习揭示了免疫组库中可用于免疫治疗的预测性序列概念.*Sci. Adv.***8**,eabq5089(2022年).
15. Kwee, B. P. Y.et al. stapler:基于全长 TCR-肽数据高效学习 TCR-肽特异性预测 . 预印本发表于 *bioRxivhttps*://doi.org/10.1101/2023.04.25.538237 (2023 年).
16. Dens，C.、Laukens，K.、Bittremieux，W. 及 Meysman，P. 关于 T 细胞表位特异性挑战中负向数据偏倚的陷阱。*Nat. Mach. Intell.***5**，1060–1062（2023 年）。
17. Pham，M.-D. N. 等人。epiTCR：一种高灵敏度的 TCR-肽结合预测因子。*Bioinformatics* **39**，btad284（2023 年）。
18. Gao, Y.等.基于泛肽元学习的 T 细胞受体–抗原结合识别.*Nat. Mach. Intell.***5**,236–249(2023 年).
19. Xu, Z.等.DLpTCR:一种用于预测 T 细胞受体识别的免疫原性肽的集成深度学习框架.*Brief. Bioinform.***22**,bbab335(2021 年).
20. Springer，I.、Tickotsky，N. 和 Louzoun，Y. T 细胞受体 α 和 β CDR3、MHC 分型以及 V 和 J 基因对肽结合预测的贡献。*Front. Immunol.***12**，664514（2021 年）。
21. Carter, J. A.等.单 T 细胞测序揭示了 αβ TCR 配对在细胞谱系和抗原特异性中的功能作用.*Front. Immunol.***10**,1516(2019 年).
22. La Gruta，N. L.；Gras，S.；Daley，S. R.；Thomas，P. G. 及 Rossjohn，J. 理解 T 细胞受体 MHC 限制的驱动因素。*Nat. Rev. Immunol.***18**，467–478（2018 年）。
23. Nielsen, M.等.从 IMMREP23 TCR-表位预测挑战中获得的经验. *ImmunoInformatics* **16**,100045(2024年).
24. Vita，R. 等。免疫表位数据库 (IEDB)：2018 年更新。*Nucleic Acids Res.***47**，D339–D343 (2018)。
25. Bagaev, D. V.等.VDJdb 2019 年版本:数据库扩展, 新型分析基础设施及 T 细胞受体基序汇编.*Nucleic Acids Res.***48**,D1057–D1062(2019 年).
26. Tickotsky，N.、Sagiv，T.、Prilusky，J.、Shifrut，E. 及 Friedman，N. McPAS-TCR：一个人工整理的与病理相关的T细胞受体序列目录。*生物信息学* **33**，2924–2929（2017年）。
27. Nolan, S.等.一个基于自然暴露和人工暴露于 SARS-CoV-2 所获得的 T 细胞受体 β 序列及结合关联的大规模数据库 .*Front. Immunol.***16**,1488851(2025 年).
28. Yu，C.、Fang，X.、Tian，S. 和 Liu，H. 一种用于预测对抗原与 HLA 及 TCR 分子结合特异性的统一交叉注意力模型。*Nat. Mach. Intell.***7**，278–292（2025 年）。
29. Yang, Z.等.负采样是否重要?一篇结合其理论及应用见解的综述.*IEEE Trans. Pattern Anal. Mach. Intell.***46**,5692–5711(2024年).
30. Croce, G.等.噬菌体展示技术可实现基于机器学习的癌症抗原特异性 TCR 发现.*Sci. Adv.***11**,eads5589(2025 年).
31. Li，H.、Pang，Y. 和 Liu，B. 提出 BioSeq-BLM：一个基于生物语言模型用于分析 DNA、RNA 和蛋白质序列的平台。*Nucleic Acids Res.***49**，e129（2021 年）。
32. Liu，B.、Gao，X. 和 Zhang，H. 著，《BioSeq-Analysis2.0：基于机器学习方法的DNA、RNA及蛋白质序列在序列水平和残基水平分析的最新平台》。*Nucleic Acids Res.***47**，e127（2019年）。
33. Slone, J. K.等.Stag-llm:利用蛋白质语言模型和计算生成的三维结构预测 tcr-phla 结合.*Comput. Struct. Biotechnol. J.***27**,3885–3896(2025 年).
34. Richardson, E.等.IMMREP25:未见肽.预印本发表于*bioRxiv* https://doi.org/10.64898/2026.03.30.715276(2026 年).
35. Noceda，M. G. 等。Immset：基于序列的预测工具 tcr-pmhc 的规模化特异性。预印本见 https://doi.org/10.48550/arXiv.2603.26994(2026)。
36. Peng, X.等.利用深度学习方法表征 T 细胞受体与表位之间的相互作用构象.*Nat. Mach. Intell.***5**,395–407(2023 年).
37. Lefranc，M.-P. IMGT，国际免疫遗传学信息系统。*Cold Spring Harb. Protoc.***6**，595–603（2011年）。

38. Heather, J. M.等.Stitchr:基于 V/J/CDR3 信息对 TCR 核苷酸序列进行拼接.*Nucleic Acids Res.***50**,e68(2021 年).
39. Springer，I.、Besser，H.、Tickotsky-Moskovitz，N.、Dvorkin，S. 及 Louzoun，Y. 基于大型 TCR–肽对词典预测特异性 TCR–肽结合。*Front. Immunol.***11**，1803（2019 年）。
40. Feng, Z.等.用于预测 T 细胞受体–抗原–人类白细胞抗原结合的滑动注意力 Transformer 神经架构.*Nat. Mach. Intell.***6**,1216–1230(2024 年).
41. Jiang，Y.、Huo，M. 和 Li，S. C. TEINet：一种用于预测 TCR–表位结合特异性的深度学习框架。*Brief. Bioinform.***24**，bbad086（2023 年）。
42. Yadav，S.，Vora，D. S.，Sundar，D. & Dhanjal，J. K. TCR- ESM：采用蛋白质语言嵌入进行预测 TCR- 肽 -MHC 结合。*Comput. Struct. Biotechnol. J.***23**，165–173 (2023)。
43. Rao, R.等.利用 TAPE 评估蛋白质迁移学习.*Adv. 《神经信息处理系统》* **32**，9689–9701 (2019)。
44. Elnaggar, A.等.ProtTrans:通过自监督学习探索生命语言.*IEEE Trans. Pattern Anal. Mach. Intell.***44**,7112–7127(2021年).
45. Lin, Z.等.利用语言模型进行进化尺度上的原子级蛋白质结构预测.*Science* **379**,1123–1130(2023年).
46. Fournier, Q.等.蛋白质语言模型:规模扩展是否必要?预印本发布于 *bioRxivhttps*://doi.org/10.1101/2024.09.23.614603(2024 年).
47. Shazeer，N. M. GLU 变体提升了 Transformer 的性能。预印本见 https://doi.org/10.48550/arXiv.2002.05202（2020 年）。
48. Zhang，B. 与 Sennrich，R. 层均方根归一化。*Adv. Neural Inf. Process. Syst.***32**，12381–12392 (2019) .
49. Dao，T.、Fu，D.、Ermon，S.、Rudra，A. 及 Ré，C. FlashAttention：一种兼具 IO 感知能力且快速且内存高效的精确注意力机制。*Adv. Neural Inf. Process. Syst.***35**，16344–16359（2022 年）。
50. Suzek，B. E.、Huang，H.、McGarvey，P.、Mazumder，R. 及 Wu，C. H. UniRef：全面且无冗余的 UniProt 参考簇。*生物信息学* **23**，1282–1288（2007年）。
51. Olsen，T. H.、Boyles，F. 和 Deane，C. M.《Observed Antibody Space》：一个包含经过清洗、注释及翻译的未配对与配对抗体序列的多样化数据库。*Protein Sci.***31**，141–146（2021 年）。
52. Murzin，A. G.、Brenner，S. E.、Hubbard，T. J. P. 及 Chothia，C. SCOP：一种用于序列与结构研究的蛋白质结构分类数据库。*J. Mol. Biol.***247**，536–40（1995年）。
53. Kingma，D. P. 与 Ba，J. Adam：一种随机优化方法。载于*《国际学习表示会议论文集》*（ICLR，2015年）。
54. Paszke, A.等.Pytorch:一种命令式，高性能深度学习库.*Adv. Neural Inf. Process. Syst.***32**,8026–8037(2019年).
55. Zhu，X.，Lu，J.，Lu，Y.，Zhang，Y. & Feng，F. 用于精确预测T细胞受体–pHLA结合的机器学习数据集及基准。*Zenodo* https://doi.org/10.5281/zenodo.22647655(2026)。
56. Yuan, Y.等.一种基于生物学知识的视觉引导框架,用于可解释的 T 细胞受体–表位结合预测.*Adv. Sci.***13**,e12544(2025 年).
57. Montemurro, A.等.NetTCR-2.0 通过利用成对的 TCRα 和 β 序列数据，实现了对 TCR-肽段结合的精准预测.*Commun. Biol.***4**,1060(2021 年).
58. Zhang, Y.等.基于表位锚定的对比迁移学习用于配对 $CD8^+$T 细胞受体–抗原识别.*Nat. Mach. Intell.***6**,1344–1358(2024年).
59. Zhang, W.等.一种用于高度多重化右旋体图谱构建及将 T 细胞受体序列映射至抗原特异性预测的框架.*Sci. Adv.***7**,eabf5835(2021 年).

致谢

我们感谢T. Jin在有益讨论方面的贡献。同时，我们也感谢使本研究成为可能的公共生物数据库及数据集的开发者和维护者，包括免疫表位数据库（IEDB）、VDJdb、McPAS-TCR、ImmuneCODE以及来自 IMMREP 竞赛的评估数据集。

作者贡献

X.Z.、J. L. 和 F. F. 提出本研究构想；J. L. 负责数据收集与处理；J. L.、Y. L. 和 Y.Z. 负责实验实施；X.Z. 和 J. L. 负责结果分析、图表制作及原始文稿撰写；F. F. 负责文稿审阅与修订；所有作者均阅读并批准了该文稿。

资金

本研究得到了安徽省重点科技项目（项目编号：202523n10050009）和中关村研究院（项目编号：C20250401）的资助。

利益冲突

作者声明不存在任何利益冲突。

补充信息

补充信息在线版本包含补充材料，可通过https://doi.org/10.1038/s43588-026-01073-y获取。

通信及材料索取请求请寄至 Feng Fuli。

同行评审信息*Nature Computational Science*感谢 Jared Slone、Dong-Qing Wei 以及其他匿名评审者对本研究的同行评审所作出的贡献。主要负责编辑：Michelle Badri，与*Nature Computational Science*团队合作完成。同行评审报告可供查阅。

重印及授权信息可在www.nature.com/reprints**获取。**

出版者注Springer Nature 对于已发表地图中的管辖权主张及机构隶属关系保持中立。

Springer Nature 或其许可方（例如某个学会或其他合作伙伴）根据与作者或其他权利持有人签订的出版协议，对该文章享有排他性权利；作者对本文被接收的稿件版本进行自存档，完全受该出版协议条款及适用法律的约束。

© 作者（们），经 Springer Nature America，Inc. 独家许可，2026 年

McPAS-TCR, and https://clients.adaptivebiotech.com/pub/covid-2020. The IMMREP2023 test set is obtained at https://github.com/justin-barton/IMMREP23/. The prepared benchmarking set is available at https://github.com/Jiadong001/Hi-TpH.

Research involving human participants, their data, or biological material

Policy information about studies with human participants or human data. See also policy information about sex, gender (identity/presentation), and sexual orientation and race, ethnicity and racism.

Reporting on sex and gender	n/a
Reporting on race, ethnicity, or other socially relevant groupings	n/a
Population characteristics	n/a
Recruitment	n/a
Ethics oversight	n/a

Note that full information on the approval of the study protocol must also be provided in the manuscript.

Field-specific reporting

Please select the one below that is the best fit for your research. If you are not sure, read the appropriate sections before making your selection.

☒ Life sciences ☐ Behavioural & social sciences ☐ Ecological, evolutionary & environmental sciences

For a reference copy of the document with all sections, see nature.com/documents/nr-reporting-summary-flat.pdf

Life sciences study design

All studies must disclose on these points even when the disclosure is negative.

Sample size	The datasets were selected based on the availability of relevant TCR–pHLA binding data and the need to evaluate different levels of molecular information and generalization. Hi-TPH integrates data from four public databases (IEDB, VDJdb, McPAS-TCR and ImmuneCODE) and five published collections. Following curation, the data were organized into four hierarchical subsets containing 214,641, 78,679, 28,262 and 26,704 binding pairs, respectively. Evaluation used an internal held-out Test set, an Unseen set comprising held-out peptides, and the external IMMREP2023 set. The scale and molecular diversity of Hi-TPH support model training and controlled component analyses, while the complementary evaluation settings assess performance on held-out interactions, unseen peptides and external data.
Data exclusions	In benchmark, we limited the peptide length to 8-15 for level I and 8-10 for levels II-IV, the CDR3 length to 9-19 for levels I-IV, and the full TCR**α**和**β** sequence lengths to 105-121 and 109-121, respectively, for level IV. Samples that did not meet these requirements were 排除 .
Replication	Model Training and model evaluation were performed five times with five different random seeds, and the results were consistent. All attempts at replication were successful.
Randomization	Allocation to experimental groups was not applicable because this study involved computational analyses of existing datasets, with no experimental subjects or treatment groups. For model development and evaluation, 100 peptides were randomly selected from the long-tail peptide pool, and all associated samples were held out as the Unseen set. The remaining data were randomly divided into training, validation and test sets at an 8:1:1 ratio.
Blinding	Blinding to group allocation was not applicable because this study involved computational analyses of existing datasets, with no experimental subjects or treatment-group allocation. No new wet-lab data were collected.

Reporting for specific materials, systems and methods

We require information from authors about some types of materials, experimental systems and methods used in many studies. Here, indicate whether each material, system or method listed is relevant to your study. If you are not sure if a list item applies to your research, read the appropriate section before selecting a response.

材料与实验系统

n/a	参与本研究
☒	□抗体
☒	□真核细胞系
☒	
☒	□古生物学与考古学□动物及其他生物□临床数据
☒	
☒	
☒	□双用途研究关注对象□植物

方法

n/a	参与 chlp-se 研究q基于流式细胞术的 MRI
☒	☐
☒	☐
☒	☐ 神经成像

植物

种子库存	不适用于本研究。
新型植物基因型	不适用于本研究。
身份验证	不适用于本研究。